



Analiza avansată a seriilor de timp și previziune

Capitolul 1: Evaluarea prognozelor, reguli de scor și combinarea prognozelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- **AI:** Artificial Intelligence (inteligență artificială)
- **ALFRED:** ArchivaL Federal Reserve Economic Data (arhiva vintage-urilor FRED (Fed St. Louis))
- **AO:** Atkeson–Ohanian (naive inflation forecast) — prognoza naivă a inflației Atkeson–Ohanian
- **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- **ARX:** AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- **BCE:** Banca Centrală Europeană
- **BNR:** Banca Națională a României
- **CPI:** Consumer Price Index (indicele prețurilor de consum)
- **CRPS:** Continuous Ranked Probability Score (scorul probabilistic continuu)
- **CW:** Clark–West (test for nested models) — testul Clark–West pentru modele imbricate
- **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- **ENTSO-E:** European Network of Transmission System Operators for Electricity (Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- **ES:** Expected Shortfall (pierderea așteptată în coadă)
- **FRED:** Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- **GARCH:** Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)

Acronime folosite în acest material (2/3)

- ▣ **GARCH-N**: GARCH with Normal innovations (GARCH cu inovații din distribuția Normală)
- ▣ **GW**: Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- ▣ **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- ▣ **HICP**: Harmonised Index of Consumer Prices (indicele armonizat al prețurilor de consum (IAPC))
- ▣ **HLN**: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **INS**: Institutul Național de Statistică
- ▣ **IPC**: Indicele prețurilor de consum
- ▣ **ISE**: (Fraunhofer) Institute for Solar Energy Systems (Institutul Fraunhofer pentru sisteme de energie solară)
- ▣ **LLM**: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MAPE**: Mean Absolute Percentage Error (eroarea procentuală absolută medie)
- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **MCS**: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **MSPE**: Mean Squared Prediction Error (eroarea medie pătratică de prognoză)

Acronime folosite în acest material (3/3)

- ▣ **MW:** MegaWatt (megawatt)
- ▣ **MZ:** Mincer–Zarnowitz (regression) — regresia Mincer–Zarnowitz
- ▣ **OLS:** Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **PIB:** Produsul intern brut
- ▣ **PIT:** Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ **QLIKE:** Quasi-LIKElihood loss (pierderea de tip cvasi-verosimilitate)
- ▣ **RC:** White's Reality Check (for data snooping) — testul Reality Check al lui White (pentru data snooping)
- ▣ **RMSE:** Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **RTDSM:** Real-Time Data Set for Macroeconomists (Philadelphia Fed) — setul de date în timp real pentru macroeconiști (Philadelphia Fed)
- ▣ **RW:** Random Walk (mers aleator)
- ▣ **SE:** Standard Error (eroare standard)
- ▣ **SPA:** Superior Predictive Ability (test) — testul abilității predictive superioare
- ▣ **SPF:** Survey of Professional Forecasters (Federal Reserve Bank of Philadelphia) — ancheta trimestrială a prognozatorilor profesioniști (Banca Rezervei Federale din Philadelphia)
- ▣ **SUA:** Statele Unite ale Americii
- ▣ **TSA:** Time Series Analysis (Serii de timp, cursul de licență)
- ▣ **UIP:** Uncovered Interest Parity (paritatea neacoperită a dobânzilor)
- ▣ **VAR:** Vector AutoRegression (model vector autoregresiv)
- ▣ **ZE:** Zona euro

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cînd este o prognoză *cu adevărat* mai bună decît alta și ce cîștigăm combinîndu-le?
 - ▶ „mai bună” cere o funcție de pierdere sau un scor, o distribuție de referință pentru comparație și un plan de evaluare corect, fixat dinainte
- ▣ **Traseul** capitolului
 - ▶ prognoze punctuale: ce funcțională răsplătește o funcție de pierdere (consistență, pierderi Bregman)
 - ▶ prognoze probabilistice: calibrare, sharpness, PIT, reguli de scor proprii, elicitalitate
 - ▶ compararea prognozelor: DM cu HAC și corecții de eșantion mic, GW, Clark–West, MZ, încadrare, RC, SPA, MCS
 - ▶ combinare: Bates–Granger, paradoxul combinării, combinarea densităților, lecțiile M4 și M5; date în timp real
- ▣ Pornim de la [TSA, Capitolul 0](#) și [TSA, Capitolul 4](#) (MAE, RMSE, MASE, evaluarea cu origine mobilă, testul DM de bază) și de la [Capitolul 0](#) (HAC, bootstrap); Seminarul 1 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Deduceți prognoza punctuală optimă pentru pierderile pătratică, absolută, pinball și asimetrice și recunoașteți pierderile consistente pentru medie (Bregman)
- ▣ Evaluați calibrarea prognozelor de densitate cu histograme PIT și teste și ierarhizați-le cu scoruri proprii (scorul logaritmic, CRPS, scorul de interval și energy score)
- ▣ Explicați elicitabilitatea și de ce VaR este elicitabil, iar ES este elicitabil doar împreună cu VaR
- ▣ Testați corect egalitatea capacității predictive: DM–HLN cu varianță HAC, GW, Clark–West pentru modele imbricate, MZ, încadrare, SPA și MCS
- ▣ Combinați prognoze punctuale și de densitate și explicați paradoxul combinării prognozelor; evaluați prognoze cu date în timp real

Bibliografie, date și instrumente

- ▣ Sinteze: Petropoulos et al. (2022) (acces liber), Gneiting și Katzfuss (2014), Elliott și Timmermann (2008), Timmermann (2006), Wang et al. (2023)
 - ▶ manuale: Hamilton (1994), cap. 4 (prognoza); Kilian și Lütkepohl (2017); legătura cu licența: Huang și Petukhina (2022)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_01](#)
 - ▶ DM–HLN, GW, Clark–West, MZ, încadrare, Berkowitz, CRPS și MCS scrise explicit în `numpy`; SPA a lui Hansen din pachetul `arch`
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Utilizare
Inflația IAPC, România (anuală, lunar)	Eurostat (prc_hicp_minr)	DM, GW
IPC și șomajul, SUA (trimestrial)	FRED (CPIAUCSL, UNRATE)	Atkeson–Ohanian
EUR/RON și dobânzile la 3 luni RO, ZE (lunar)	cursul de referință BNR; Eurostat (irt_st_m)	Clark–West, SPA
S&P 500, închidere zilnică	EODHD	PIT, scoruri
Consumul de electricitate, România (orar)	Energy-Charts (Fraunhofer ISE), date	pinball, MCS
Proгноze individuale, SPF din SUA	ENTSO-E	
PIB real SUA, toate versiunile publicate	Federal Reserve Bank of Philadelphia Philadelphia Fed, RTDSM	combinare timp real

- ▣ Toate sursele sînt publice și nu cer cont sau cheie; datele zilnice și lunare merg pînă în septembrie 2026
- ▣ IAPC (HICP): indicele armonizat al prețurilor de consum; IPC (CPI): indicele prețurilor de consum; SPF: Survey of Professional Forecasters; RTDSM: Real-Time Data Set for Macroeconomists

De la prognoza vremii la verificarea prognozelor



Robert FitzRoy (1805–1865)

Portret: Charles Hemus (c. 1910); domeniu public;

[Wikimedia Commons](#)



Lewis Fry Richardson (1881–1953)

Foto: NOAA; domeniu public; [Wikimedia Commons](#)

- 1861: FitzRoy, conducătorul noului Meteorological Office, publică zilnic „prognoze” în The Times
 - ▶ el a dat cuvîntului sensul modern; prognozele greșeau des și erau ironizate public
- 1922: Richardson calculează o prognoză meteo prin integrarea numerică a ecuațiilor de mișcare, de mînă
- 1950: [Brier \(1950\)](#) propune un scor pentru prognozele probabilistice de ploaie; meteorologia conduce verificarea prognozelor în următorii cincizeci de ani
 - ▶ economia adoptă aceleași instrumente tîrziu: PIT [Diebold](#), [Gunther](#) și [Tay \(1998\)](#), scoruri proprii [Gneiting și Raftery \(2007\)](#), calibrare [Gneiting](#), [Balabdaoui și Raftery \(2007\)](#)
- Lecția: o prognoză este utilă doar în măsura în care știm să o evaluăm

Cadrul și notațiile

- Ținta Y_{t+h} , mulțimea de informații $\mathcal{F}_t$, orizontul h ; o **proгноză punctuală** $\hat{y}_{t+h|t}$ este măsurabilă în raport cu $\mathcal{F}_t$
 - ▶ măsurabilă în raport cu $\mathcal{F}_t$: calculată doar din informația disponibilă la momentul t
 - ▶ o **proгноză probabilistică** este o distribuție predictivă $F_{t+h|t}$ (densitate, cuantile, interval, ansamblu)
- Plan în afara eșantionului: R observații pentru estimare, P progноze pentru evaluare, $R + P + h - 1 = T$
 - ▶ scheme: **fixă** (o singură estimare), **mobilă** (ultimele R), **recursivă** (tot trecutul); în [TSA, Capitolul 4](#) aceasta este evaluarea cu origine mobilă
 - ▶ T : eșantionul total; ultima progноză, făcută la $R + P - 1$, are ținta T ; schema contează pentru inferență: [West \(1996\)](#) față de [Giacomini și White \(2006\)](#), secțiunea 4
- Cunoscute din [TSA, Capitolul 0](#): MAE, RMSE, MAPE și MASE, independentă de scală [Hyndman și Koehler \(2006\)](#)
 - ▶ $MAE = P^{-1} \sum |e_t|$, $RMSE = (P^{-1} \sum e_t^2)^{1/2}$, $MAPE = 100P^{-1} \sum |e_t/y_t|$; MASE: MAE împărțit la MAE-ul în eșantion al progноzei naive
 - ▶ aici întrebarea este alta: ce pierdere și ce răsplătește ea?


Proгноza punctuală optimă și consistența (1/2)

- Dată o pierdere $L(x, y)$ și o distribuție predictivă F , progноza **optimă** (Bayes) minimizează pierderea așteptată:
 - ▶ $x^* = \arg \min_x \mathbb{E}_F[L(x, Y)]$
 - ▶ x : progноza punctuală; y : realizarea; $L(x, y) \geq 0$: penalizarea; $\mathbb{E}_F$: media calculată cînd $Y \sim F$
- O **funcțională** $T(F)$ asociază unei distribuții un număr: media, mediana, o cuantilă
 - ▶ L este **consistentă** pentru T dacă $\mathbb{E}_F L(T(F), Y) \leq \mathbb{E}_F L(x, Y)$ pentru orice x și F [Gneiting \(2011\)](#)
 - ▶ adică raportarea lui $T(F)$ este optimă oricare ar fi F ; consistentă **strict**: egalitate doar pentru $x = T(F)$

Proгноza punctuală optimă și consistența (2/2)

- Trei cazuri clasice, cu eroarea de prognoză $e = y - x$; anulăm derivata pierderii așteptate
 - ▶ pătratică e^2 : $\frac{d}{dx} \mathbb{E}(Y - x)^2 = -2\mathbb{E}(Y - x) = 0 \Rightarrow x^* = \mathbb{E}Y$ (media)
 - ▶ absolută $|e|$: $\frac{d}{dx} \mathbb{E}|Y - x| = F(x) - (1 - F(x)) = 0 \Rightarrow F(x^*) = 1/2$ (mediana)
 - ▶ pinball $\rho_\tau(e) = (\tau - 1\{e < 0\})e$: $F(x) - \tau = 0 \Rightarrow x^* = F^{-1}(\tau)$ (cuantila τ)
- Notățiile pierderii pinball
 - ▶ $\tau \in (0, 1)$: nivelul cuantilei; $1\{e < 0\}$: 1 dacă prognoza este prea mare, 0 altfel; F^{-1} : funcția cuantilă
 - ▶ prognozele prea mici costă $\tau|e|$, cele prea mari $(1 - \tau)|e|$: un τ mare împinge prognoza în sus
- Consecință: anunțați pierderea *înainte* de a cere o prognoză; o prognoză-mediană judecată prin RMSE este judecată nedrept [Gneiting \(2011\)](#)

Trei pierderi, trei prognoze optime



□ Y log-normal cu $\ln Y \sim N(0, 0.6^2)$; pierderea așteptată ca funcție de prognoza punctuală x (simulare, 2×10^5 extrageri)

ATS_ch1_loss_functions

Interpretarea celor trei puncte de minim

- ▣ Media 1,20, mediana 1, cuantila de nivel 0,9: 2,16; trei prognoze „cele mai bune” diferite pentru aceeași variabilă
 - ▶ pentru o țintă asimetrică la dreapta (salarii, consum de energie, prețuri, volatilitate) diferența este mare
- ▣ Curba pinball este plată în jurul minimului: prognozele de cuantilă se deosebesc greu cu puține observații
- ▣ Un prognozator care cunoaște pierderea raportează funcționala potrivită; ierarhizarea cu altă pierdere răsplătește un comportament greșit

Pierderile Bregman: toate pierderile consistente pentru medie (1/2)

- ▣ **Teoremă Savage (1971), Gneiting (2011):** în condiții de regularitate, L este consistentă pentru medie dacă și numai dacă este o pierdere **Bregman**
 - ▶ $L(x, y) = \phi(y) - \phi(x) - \phi'(x)(y - x)$
 - ▶ ϕ : o funcție convexă, ϕ' derivata ei; L este distanța dintre $\phi(y)$ și tangenta la ϕ în x , deci $L \geq 0$ (până la termeni care depind doar de y)
- ▣ Doi membri ai familiei
 - ▶ $\phi(x) = x^2$: eroarea pătratică $(y - x)^2$
 - ▶ $\phi(x) = -\ln x$: **QLIKE** $y/x - \ln(y/x) - 1$, pentru o prognoză de varianță $x > 0$ și un indicator al varianței $y > 0$ ([Capitolul 8](#))
 - ▶ media condiționată este optimă pentru orice pierdere Bregman [Banerjee et al. \(2005\)](#); demonstrația pentru cuantilă în [▶ Anexă](#)

Pierderile Bregman: toate pierderile consistente pentru medie (2/2)

- Schița demonstrației, cu $\mu = \mathbb{E}Y$:
 - ▶ $\mathbb{E}L(x, Y) - \mathbb{E}L(\mu, Y) = \phi(\mu) - \phi(x) - \phi'(x)(\mu - x) \geq 0$
 - ▶ termenul liniar dispare deoarece $\mathbb{E}(Y - \mu) = 0$; inegalitatea este convexitatea lui ϕ
- Prognozele corect specificate se ierarhizează la fel sub orice pierdere Bregman; cele greșit specificate nu neapărat [Patton \(2020\)](#)
 - ▶ diagramele Murphy [Ehm et al. \(2016\)](#) reprezintă scorul pe toată familia: o prognoză domină doar dacă este mai jos peste tot
 - ▶ pentru volatilitate cu un indicator zgomotos, doar unele pierderi păstrează ierarhia [Patton \(2011\)](#)

Pierderi asimetrice

- ▣ Pierderea **LinEx** $L(e) = b[\exp(ae) - ae - 1]$, $e = y - x$: liniară de o parte, exponențială de cealaltă
 - ▶ $b > 0$: o scală; a : asimetria; $a > 0$ penalizează exponențial prognozele prea mici ($e > 0$) și aproximativ liniar pe cele prea mari
 - ▶ prognoza optimă $x^* = a^{-1} \ln \mathbb{E} e^{aY}$; cu $Y | \mathcal{F}_t \sim N(\mu_t, \sigma_t^2)$: $x^* = \mu_t + a\sigma_t^2/2$ Christoffersen și Diebold (1997)
 - ▶ prognoza optimă este **deplasată**, iar deplasarea se mișcă odată cu varianța condiționată
- ▣ Consecințe pentru evaluare
 - ▶ un prognozator rațional cu pierdere asimetrică pică testul MZ de nedeplasare (secțiunea 4)
 - ▶ pierderea pinball este cazul liniar pe porțiuni: prognoza optimă este o cuantilă
- ▣ Exemple: un operator de rețea (subestimarea consumului costă mai mult decât supraestimarea), o bancă centrală cu costuri asimetrice ale inflației, capitalul unei bănci (Capitolul 9)

Recapitulare: прогноze punctuale și funcții de pierdere

- ▣ Pierderea definește funcționala-țintă: pătratică $\rightarrow$ medie, absolută $\rightarrow$ mediană, pinball $\rightarrow$ cuantilă
- ▣ Pierderile Bregman sînt exact cele consistente pentru medie; QLIKE este una dintre ele
- ▣ Sub pierdere asimetrică prognoza optimă este deplasată prin construcție
- ▣ Cu modele greșit specificate ierarhia poate depinde de pierdere: fixați-o dinainte


Sharpness maxim sub condiția de calibrare

- **Calibrarea:** consistența statistică dintre prognozele F_t și realizările y_t (o proprietate comună a lor) [Gneiting, Balabdaoui și Raftery \(2007\)](#)
 - ▶ calibrare **probabilistică:** PIT (probability integral transform) $u_t = F_t(y_t)$, probabilitatea prognozată a unei realizări sub y_t , este în medie uniform
 - ▶ calibrare **marginală:** $\frac{1}{T} \sum_t F_t(x) \rightarrow G(x)$ pentru orice x , cu G limita distribuției empirice a lui y_t
- **Sharpness:** concentrarea distribuțiilor predictive; o proprietate doar a prognozelor
 - ▶ măsurată prin lățimea medie a intervalelor centrale sau prin varianța predictivă medie
- Paradigma [Gneiting, Balabdaoui și Raftery \(2007\)](#): dintre prognozele calibrate, o preferăm pe cea mai concentrată
 - ▶ prognoza climatologică (distribuția necondiționată) este calibrată, dar nu este concentrată
 - ▶ scorurile proprii (secțiunea următoare) le răsplătesc pe amîndouă deodată

Transformarea integrală de probabilitate (PIT)

- ▣ **Teoremă Dawid (1984), Diebold, Gunther și Tay (1998):** dacă F_t este adevărata distribuție condiționată a lui Y_t dată fiind $\mathcal{F}_{t-1}$ și este continuă, atunci $u_t = F_t(y_t)$ sînt i.i.d. $U(0, 1)$
 - ▶ uniform: pentru orice $v \in (0, 1)$, $P(u_t \leq v \mid \mathcal{F}_{t-1}) = P(Y_t \leq F_t^{-1}(v) \mid \mathcal{F}_{t-1}) = v$, oricare ar fi trecutul
 - ▶ independent: o distribuție condiționată care nu depinde de trecut implică independența șirului
- ▣ Pentru $h > 1$, valorile PIT sînt uniforme, dar dependente pînă la lagul $h - 1$ (orizonturi care se suprapun)
 - ▶ testele trebuie să permită această dependență Rossi și Sekhposyan (2019)
- ▣ Uniformitatea este necesară, nu suficientă: Hamill (2001) și Gneiting, Balabdaoui și Raftery (2007) construiesc prognozatori necalibrați al căror PIT este uniform în medie
 - ▶ verificați PIT condiționat: pe subeșantioane, pe regimuri, pe orizonturi

Formele histogramelor PIT



□ $Y \sim N(0, 1)$, 5000 de extrageri; patru prognoze Normale; linia întreruptă: densitatea uniformă

ATS_ch1_calibration_scores

Interpretarea formelor PIT

- ▣ **Forma de U:** prea multe realizări în ambele cozi (32% în afara intervalului central de 90%, față de 10%): prognoza este prea concentrată, intervalele prea înguste
- ▣ **Cocoașă:** prea puține realizări în cozi (1,0%): prognoza este prea largă, intervalele risipesc informație
- ▣ **Pantă:** poziție deplasată; aici media prognozei este prea mare, deci valorile PIT se adună lângă 0
- ▣ CRPS (mai mic este mai bine): ideală 0,567, prea concentrată 0,595, prea largă 0,604, deplasată 0,637: scorul propriu pune prognoza ideală pe primul loc

Testarea calibrării (1/2)

- ▣ **Testul Berkowitz** [Berkowitz \(2001\)](#): dacă valorile PIT sînt i.i.d. uniforme, $z_t = \Phi^{-1}(u_t)$ este i.i.d. $N(0, 1)$
 - ▶ Φ^{-1} : funcția cuantilă a distribuției Normale standard
- ▣ Estimăm un AR(1) gaussian pentru z_t și îi testăm parametrii:
 - ▶ $z_t = \mu + \rho(z_{t-1} - \mu) + \varepsilon_t$, $\varepsilon_t \sim N(0, \sigma^2(1 - \rho^2))$
 - ▶ μ : media lui z_t ; σ^2 : varianța lui; ρ : autocorelația de ordinul întâi; calibrarea înseamnă $\mu = 0$, $\sigma = 1$, $\rho = 0$
 - ▶ statistica LR (raportul de verosimilitate) $2(\ell_1 - \ell_0) \sim \chi^2(3)$ sub H_0 ; ℓ_1, ℓ_0 : log-verosimilitățile maxime fără și cu restricții
 - ▶ transformarea în z face cozile vizibile; testul verifică doar primele două momente și dependența AR(1)


Testarea calibrării (2/2)

- ▣ **Corelogramele** lui $(u_t - \bar{u})^k$, $k = 1, 2$ [Diebold, Gunther și Tay \(1998\)](#): dependență în nivel și în volatilitate
 - ▶ $\bar{u}$: media valorilor PIT; testul Ljung–Box pe $(u_t - \bar{u})^2$ detectează dinamica de volatilitate omisă
- ▣ Estimarea parametrilor schimbă distribuția sub ipoteza nulă a testelor PIT
 - ▶ cu P/R mic (puține prognoze față de eșantionul de estimare) efectul poate fi ignorat, altfel folosiți [Rossi și Sekhposyan \(2019\)](#)
- ▣ Prognozele de interval: acoperirea și independența depășirilor [Christoffersen \(1998\)](#)
 - ▶ depășire: o realizare în afara intervalului; pentru VaR aceasta devine backtesting ([Capitolul 9](#))

Studiu de caz: Diebold, Gunther și Tay (1998)

- ▣ Lucrarea: randamente zilnice S&P 500; parametrii estimați o singură dată pe prima parte a eșantionului, prognozele de densitate evaluate pe partea a doua cu histograme PIT și corelograme ale lui $(u - \bar{u})^k$ Diebold, Gunther și Tay (1998)
 - ▶ modelele lor: i.i.d. Normal; MA(1)-GARCH(1,1) cu inovații Normale și cu inovații Student- t Bollerslev (1987)
- ▣ Replicarea noastră: aceleași trei modele, estimate prin verosimilitate maximă pe 2000–2012, parametri ficși, prognoze de densitate la o zi pentru 2013–2026 (3 448 zile)
 - ▶ modelul: $r_t = c + \varepsilon_t + \theta\varepsilon_{t-1}$, $\varepsilon_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$; z_t Normal sau Student- t cu ν grade de libertate
 - ▶ GARCH- t : $\hat{\theta} = -0,061$, $\hat{\alpha} + \hat{\beta} = 0,996$ (persistența volatilității), $\hat{\nu} = 8,0$ (cozi groase)
- ▣ Întrebarea: care prognoză de densitate este calibrată și sînt de acord scorurile proprii cu diagnosticul PIT?

Diagnosticul PIT pentru trei prognoze de densitate ale S&P 500



□ Sus: histograme PIT (20 de intervale); jos: autocorelațiile lui $(u - \bar{u})$ și $(u - \bar{u})^2$, cu benzile $\pm 2/\sqrt{T}$

Interpretarea diagnosticului pentru S&P 500

- ▣ i.i.d. Normal: o cocoașă și autocorelație puternică a lui $(u - \bar{u})^2$: prognoza ignoră volatility clustering; Berkowitz LR 428,8 ($p < 0,001$)
 - ▶ prea largă în perioadele calme, prea îngustă în cele agitate: cele două erori se compun într-o cocoașă
- ▣ GARCH elimină cea mai mare parte a dependenței; varianta t are o coadă stîngă mai bună
 - ▶ Berkowitz: GARCH-N LR 9,3 (p 0,026), GARCH- t LR 10,0 (p 0,019); σ_z estimat $0,97 < 1$
 - ▶ în afara intervalului central de 90%: 8,4% din zile: cu parametri înghețați în 2012, prognozele sînt puțin prea largi după 2013
- ▣ În acord cu [Diebold, Gunther și Tay \(1998\)](#): heteroscedasticitatea condiționată este esențială, cozile groase ajută; rămîne o mică necalibrare reziduală

Recapitulare: calibrarea

- ▣ Calibrarea este o proprietate comună a prognozelor și a realizărilor; sharpness este o proprietate a prognozelor
- ▣ Densitățile corecte la un pas dau valori PIT i.i.d. uniforme; pentru $h > 1$ ele sînt dependente
- ▣ Forma de U: prea concentrată; cocoașa: prea largă; panta: deplasare; corelograma lui $(u - \bar{u})^2$: dinamica de volatilitate omisă
- ▣ S&P 500: GARCH- t este aproape calibrat, i.i.d. Normal nu este

Reguli de scor proprii

- O **regulă de scor** $S(F, y)$ atribuie o penalizare prognozei F când se realizează y (orientare negativă: mai mic este mai bine)
 - ▶ **proprie**: $\mathbb{E}_G S(G, Y) \leq \mathbb{E}_G S(F, Y)$ pentru orice F, G [Gneiting și Raftery \(2007\)](#)
 - ▶ G : distribuția în care crede prognozatorul; $\mathbb{E}_G$: media sub G ; raportarea convingerii adevărate este optimă
 - ▶ **strict proprie**: egalitate doar dacă $F = G$; atunci scorul nu poate fi manipulat
- Scorurile proprii răsplătesc calibrarea și sharpness împreună: scorul așteptat se descompune în incertitudine, minus rezoluție, plus fiabilitate
 - ▶ scorul Brier $(p - 1\{\text{eveniment}\})^2$, cu p probabilitatea prognozată a unui eveniment binar, este cel mai vechi exemplu [Brier \(1950\)](#)
- Un scor propriu al unei prognoze probabilistice devine o pierdere consistentă a unei prognoze punctuale când F este o masă punctuală (CRPS $\rightarrow$ eroarea absolută)

Scorul logaritmic

- $\text{LogS}(f, y) = -\ln f(y)$ [Good \(1952\)](#): singurul scor propriu **local** (depinde de f doar în y , până la echivalență)
 - ▶ f : densitatea prognozată; g : densitatea adevărată; caracterul propriu:
 $\mathbb{E}_g[\text{LogS}(f, Y)] - \mathbb{E}_g[\text{LogS}(g, Y)] = \int g \ln(g/f) = \text{KL}(g\|f) \geq 0$
 - ▶ KL: divergența Kullback–Leibler, nenegativă și nulă doar dacă $f = g$ (inegalitatea Gibbs)
- Legături: scorul logaritmic mediu = minus log-verosimilitatea în afara eșantionului; diferența a două scoruri logaritmice este un raport de verosimilitate predictivă
 - ▶ factorii Bayes și alegerea predictivă a modelelor din [Geweke și Amisano \(2011\)](#) se construiesc pe el
- Slăbiciuni: infinit dacă $f(y) = 0$; foarte sensibil la evenimentele din coadă; cere o densitate
 - ▶ nu poate evalua direct ansambluri sau prognoze de cuantile

Scorul probabilistic continuu (CRPS) (1/2)

- Definiția **Matheson și Winkler (1976)**: distanța pătratică dintre funcția de repartiție prognozată și funcția treaptă a realizării
 - ▶ $\text{CRPS}(F, y) = \int_{-\infty}^{\infty} (F(z) - 1\{y \leq z\})^2 dz$
 - ▶ z : un prag; $1\{y \leq z\}$: „funcția de repartiție” a realizării, 0 sub y și 1 peste y ; unitatea de măsură: cea a lui y
- Forma cu nucleu **Gneiting și Raftery (2007)** (demonstrația în [▶ Anexă](#)):
 - ▶ $\text{CRPS}(F, y) = \mathbb{E}_F|X - y| - \frac{1}{2}\mathbb{E}_F|X - X'|$, $X, X' \sim F$ independente
 - ▶ primul termen: acuratețea; al doilea: o recompensă pentru dispersie care împiedică scorul să favorizeze masele punctuale
 - ▶ pentru o prognoză punctuală (F masă punctuală în x) devine eroarea absolută $|y - x|$

Scorul probabilistic continuu (CRPS) (2/2)

- ▣ Forma închisă pentru $F = N(\mu, \sigma^2)$, cu $z = (y - \mu)/\sigma$:
 - ▶ $\text{CRPS} = \sigma [z(2\Phi(z) - 1) + 2\varphi(z) - 1/\sqrt{\pi}]$
 - ▶ Φ, φ : funcția de repartiție și densitatea lui $N(0, 1)$; există o formă închisă și pentru Student t (Quantlet)
 - ▶ ansambluri: înlocuim F cu distribuția empirică a membrilor
- ▣ Descompuneri:
 - ▶ $\text{CRPS} = \int \text{BS}_z dz = 2 \int_0^1 \rho_\tau(y - F^{-1}(\tau)) d\tau$
 - ▶ BS_z : scorul Brier al evenimentului $\{y \leq z\}$; ρ_τ : pierderea pinball la nivelul τ
 - ▶ deci media pinball pe cele 99 de percentile (GEFCom2014) aproximează $\text{CRPS}/2$ [Hong et al. \(2016\)](#)

Scoruri pentru cuantile, intervale și vectori (1/2)

- ▣ **Scorul de cuantilă:** $\rho_{\tau}(y - q)$ pentru o prognoză q a cuantilei τ , strict consistent [Gneiting \(2011\)](#)
 - ▶ orice funcție crescătoare g dă un alt scor consistent: $(1\{y \leq q\} - \tau)(g(q) - g(y))$
- ▣ **Scorul de interval** al unui interval central $(1 - \alpha)$, $[l, u]$ [Gneiting și Raftery \(2007\)](#)
 - ▶ $IS_{\alpha} = (u - l) + \frac{2}{\alpha}(l - y)1\{y < l\} + \frac{2}{\alpha}(y - u)1\{y > u\}$
 - ▶ l, u : limitele inferioară și superioară; lățimea plus o penalizare $2/\alpha$ pe unitatea de rată
 - ▶ este egal cu $\frac{2}{\alpha}[\rho_{\alpha/2}(y - l) + \rho_{1-\alpha/2}(y - u)]$; acoperirea singură nu este un scor

Scoruri pentru cuantile, intervale și vectori (2/2)


▣ **Energy score** pentru vectori, CRPS multivariat:

- ▶ $ES(F, y) = \mathbb{E}\|X - y\| - \frac{1}{2}\mathbb{E}\|X - X'\|$
- ▶ y : vectorul realizărilor; X, X' : extrageri independente din prognoza F ; $\|\cdot\|$: norma euclidiană
- ▶ slab în detectarea corelațiilor greșite; **variogram score** [Scheuerer și Hamill \(2015\)](#) vizează structura de dependență (24 de consumuri orare, o traiectorie VAR)
- ▶ $VS_p = \sum_{i,j} w_{ij}(|y_i - y_j|^p - \mathbb{E}|X_i - X_j|^p)^2$: compară diferențele observate și prognozate dintre componente; $w_{ij} \geq 0$: ponderi, p : de obicei 0,5


▣ Cozile: CRPS ponderat pe praguri rămîne propriu [Gneiting și Ranjan \(2011\)](#)

- ▶ $\int (F(z) - 1\{y \leq z\})^2 w(z) dz$
- ▶ $w(z) \geq 0$: o pondere care accentuează pragurile de interes (de exemplu coada stîngă); raportul de verosimilitate ponderat din [Amisano și Giacomini \(2007\)](#) nu rămîne propriu [Gneiting și Ranjan \(2011\)](#)


Scoruri proprii și improprii



— expected log score
- - - true spread $s = 1$



— expected CRPS
- - - true spread $s = 1$



— expected linear score $-f(y)$
- - - true spread $s = 1$

- ▣ Adevărul $Y \sim N(0, 1)$; prognoza $N(0, s^2)$; scorul așteptat ca funcție de dispersia s (forme închise)
- ▣ Scorul logaritmic și CRPS: minim la $s = 1$; scorul liniar $-f(y)$: $\mathbb{E}f(Y) = [2\pi(1 + s^2)]^{-1/2}$ crește când $s \rightarrow 0$: răsplătește excesul de încredere

Interpretarea scorurilor așteptate

- Scorul logaritm și CRPS sînt minime pentru dispersia adevărată: prognozatorul își maximizează recompensa așteptată raportînd ceea ce crede
- Scorul logaritm penalizează excesul de încredere mult mai mult decît dispersia prea mare (ramura stîngă abruptă); CRPS este mai simetric și mărginit de eroarea absolută
- Scorul liniar este optimizat de o masă punctuală: ar răsplăti un prognozator care raportează mereu un vîrf, deci nu trebuie folosit la evaluare

Elicitabilitate

- O funcțională T este **elicitabilă** dacă există o pierdere strict consistentă pentru ea [Gneiting \(2011\)](#)
 - ▶ media, cuantilele, expectilele, rapoartele de medii: elicitabile
 - ▶ doar funcționalele elicitabile pot fi comparate și ierarhizate cu sens prin prognoze punctuale
- **Condiție necesară** (Osband): mulțimi de nivel convexe: $T(F_0) = T(F_1) = t \Rightarrow T(\lambda F_0 + (1 - \lambda)F_1) = t$
 - ▶ F_0, F_1 : două distribuții cu aceeași valoare t ; $\lambda \in [0, 1]$: ponderea mixturii
 - ▶ **varianța** nu o îndeplinește, deci nu este elicitabilă; perechea (medie, al doilea moment) este
- Măsurile de risc cu $\text{VaR}_\alpha(X) = -q_\alpha(X)$, q_α cuantila de ordin α a randamentului X (VaR 1%: $\alpha = 0,01$)
 - ▶ VaR este o cuantilă: elicitabil prin pierderea pinball
 - ▶ ES (expected shortfall, pierderea medie dincolo de VaR) are mulțimi de nivel neconvexe: **nu este elicitabil** singur [Weber \(2006\)](#), [Gneiting \(2011\)](#); perechea (VaR, ES) este elicitabilă **împreună** [Fissler și Ziegel \(2016\)](#)
 - ▶ funcțiile de scor Fissler–Ziegel și testele construite pe ele: [Capitolul 9](#)

Scorurile prognozelor de densitate pentru S&P 500

Model	Scor logaritmic	CRPS	În afara 90%	Berkowitz p
i.i.d. Normal	1,531	0,564	3,9%	< 0,001
MA(1)-GARCH(1,1)-N	1,265	0,509	8,0%	0,026
MA(1)-GARCH(1,1)- t	1,233	0,507	8,4%	0,019

- Diferențele de scor testate cu DM pe scorurile zilnice ([Amisano și Giacomini \(2007\)](#)), neponderat
 - GARCH- t față de GARCH-N: HLN $-5,9$ (scor logaritmic), $-6,4$ (CRPS); GARCH-N față de i.i.d.: $-12,7$ și $-21,5$
- Ambele scoruri ordonează modelele ca diagnosticul PIT; scorul logaritmic separă mai net cozile
- Ierarhizarea și calibrarea sînt întrebări diferite: modelul cu cel mai bun scor poate pica totuși un test de calibrare

Recapitulare: scoruri proprii și elicitabilitate

- ▣ Scorurile proprii fac optimă raportarea sinceră; cele strict proprii nu pot fi manipulate
- ▣ LogS: local, sensibil la cozi; CRPS: robust, merge pentru ansambluri, egal cu dublul pierderii pinball integrate
- ▣ Scorul de interval pentru intervale, energy și variogram score pentru vectori
- ▣ Elicitabile: media, cuantila (VaR); neelicitabile: varianța, ES singur; (VaR, ES) împreună

Două întrebări despre capacitatea predictivă

- ▣ **Populație West (1996):** sînt *modelele*, la parametrii lor pseudo-adevărați, la fel de precise?
 - ▶ eroarea de estimare intră în varianța asimptotică, cu excepția cazului $P/R \rightarrow 0$ sau cînd pierderea este cea folosită la estimare
- ▣ **Eșantion finit Giacomini și White (2006):** sînt *metodele de prognoză*, cu ferestrele lor de estimare, la fel de precise?
 - ▶ fereastră mobilă de dimensiune fixă R : zgomotul de estimare face parte din metodă; modelele imbricate sînt permise
- ▣ **Diebold–Mariano Diebold și Mariano (1995)** tratează prognozele ca date („primitive”): compară prognoze, nu modele **Diebold (2015)**
 - ▶ folosirea DM pentru a compara modele cu parametri estimați cere cadrul West sau GW


Testul Diebold–Mariano cu varianță HAC (1/2)

- Diferențialul de pierdere $d_t = L(e_{1t}) - L(e_{2t})$; $H_0: \mathbb{E}d_t = 0$ (acuratețe egală)
 - ▶ e_{it} : eroarea prognozei i la momentul t ; $d_t > 0$: prognoza 2 a fost mai bună la t ; presupunem d_t staționar în covarianță
- Statistica: diferențialul mediu împărțit la eroarea lui standard HAC
 - ▶ $DM = \bar{d} / \sqrt{\hat{\sigma}_{LR}^2 / P} \rightarrow N(0, 1)$, $\sigma_{LR}^2 = \gamma_0 + 2 \sum_{k \geq 1} \gamma_k$
 - ▶ $\bar{d}$: media lui d_t pe cele P prognoze; γ_k : autocovarianțele lui d_t ; σ_{LR}^2 : varianța lui de termen lung ([Capitolul 0](#))
 - ▶ un DM mare și pozitiv: prognoza 2 este mai precisă; respingem la 5% dacă $|DM| > 1,96$

Testul Diebold–Mariano cu varianță HAC (2/2)

- Erorile optime la h pași sînt cel mult $MA(h-1)$, deci DM trunchiază la $h-1$ laguri cu un nucleu **dreptunghiular**
 - ▶ estimarea dreptunghiulară poate fi **negativă**; ponderile Newey–West (Bartlett) o păstrează pozitivă Newey și West (1987), cu prețul unei deplasări în jos
 - ▶ prognozele suboptimale au erori cu memorie mai lungă: folosiți o lățime de bandă aleasă din date (Capitolul 0)
- **Corecția HLN** Harvey, Leybourne și Newbold (1997): o rescalare a lui DM pentru eșantioane mici
 - ▶ $DM^* = DM \sqrt{(P+1-2h+h(h-1)/P)/P}$, comparat cu t_{P-1}
 - ▶ factorul (sub 1) elimină deplasarea estimatorului varianței pentru erori $MA(h-1)$; t_{P-1} : distribuția Student t cu $P-1$ grade de libertate, pentru P mic

Mărimea testelor DM și HLN în eșantioane mici



- Două serii de erori $MA(h-1)$ independente, cu varianțe egale, pierdere pătratică; proporția respingerilor la 5% în 4 000 de replicări


Interpretarea experimentului de mărime

- $h = 1$: ambele teste sînt aproape de 5%; DM respinge prea des doar la $P = 16$ (7,4%)
- $h = 8, P = 16$: DM respinge o ipoteză nulă adevărată în 43,6% din cazuri, HLN în 14,6%; la $P = 64$: 13,2% și 8,1%
 - ▶ varianța HAC cu puține observații și multe laguri este zgomotoasă și deplasată în jos
- Regulă: la orizonturi de mai mulți pași și cu mai puțin de aproximativ 100 de prognoze, folosiți HLN și tratați p-value-urile din jurul lui 5% ca neconcludente; valorile critice fixed- b ([Capitolul 0](#)) sînt o alternativă

Inflația din România cu un an înainte: planul de evaluare

- ▣ Ținta: inflația IAPC, anuală, cu 12 luni înainte; originile prognozelor din ianuarie 2013, ținte de la ianuarie 2014 până în august 2026, $P = 152$ prognoze
 - ▶ inflația IAPC în august 2026: 6,3%
- ▣ Prognozele
 - ▶ **fără schimbare**: $\hat{\pi}_{t+12} = \pi_t$; **AR(3) direct**: π_{t+12} pe $1, \pi_t, \pi_{t-1}, \pi_{t-2}$, OLS pe o fereastră mobilă de 10 ani
 - ▶ **ținta**: ținta de inflație a BNR, 2,5%; **media** dintre AR(3) și fără schimbare
- ▣ Ținte de 12 luni care se suprapun: erorile sînt autocorelate pînă la lagul 11; DM cu $h = 12$

Prognoze ale inflației din România cu un an înainte



- Stînga: inflația și prognozele făcute cu 12 luni înainte; dreapta: suma cumulată a $e_{nc,t}^2 - e_{m,t}^2$ (scade: modelul m pierde în fața prognozei fără schimbare)

Interpretarea comparației pentru inflația din România

Proгноza	RMSE	DM	HLN	p (HLN)	p , pierdere abs.
fără schimbare	3,57	–	–	–	–
AR(3)	4,23	1,43	1,32	0,188	0,381
ținta BNR	4,43	1,30	1,21	0,230	0,319
media	3,76	0,96	0,88	0,378	0,795

- Fiecare model are RMSE mai mare decât prognoza fără schimbare, totuși nicio diferență nu este semnificativă: cu $P = 152$ ținte suprapuse, eșantionul efectiv este mic
- Newey–West în locul nucleului dreptunghiular: HLN 1,47 pentru AR(3); concluzia nu depinde de nucleu
- RMSE relativ al AR(3): 1,44 înainte de iulie 2021, 1,10 după: ierarhia nu este stabilă în timp [Giacomini și Rossi \(2010\)](#)

Capacitatea predictivă condiționată: Giacomini–White (1/2)

□ $H_0: \mathbb{E}[d_{t+h} | \mathcal{G}_t] = 0$ Giacomini și White (2006)

- ▶ $\mathcal{G}_t$: informația de la originea prognozei; H_0 : niciun instrument $h_t \in \mathcal{G}_t$ nu prezice care metodă câștigă
- ▶ h_t : un vector de q instrumente (nu orizontul h), de exemplu o constantă și ultimul diferențial de pierdere

□ Statistica: un test Wald că instrumentele nu prezic d_{t+h}

- ▶ $GW = P \bar{Z}' \hat{\Omega}^{-1} \bar{Z} \rightarrow \chi^2(q)$, $Z_t = h_t d_{t+h}$
- ▶ $\bar{Z}$: media lui Z_t ; $\hat{\Omega}$: matricea ei de covarianță HAC cu $h - 1$ laguri; $\chi^2(q)$: distribuția hi-pătrat cu q grade de libertate
- ▶ $h_t = 1$ dă testul necondiționat; adăugînd d_t sau o variabilă de stare testăm dacă trecutul prezice câștigătorul

Capacitatea predictivă condiționată: Giacomini–White (2/2)

- Valid cu o fereastră **mobilă** de dimensiune fixă, modele imbricate sau nu, orice pierdere; nevalid cu o fereastră recursivă
 - ▶ o respingere sugerează o regulă de decizie: folosiți modelul 1 când $\hat{\delta}'h_t > 0$, cu $\hat{\delta}$ coeficienții regresiei lui d_{t+h} pe h_t
- Inflația din România, AR(3) față de fără schimbare, $h_t = (1, d_t, \pi_t - 2,5)$
 - ▶ $\pi_t - 2,5$: distanța inflației față de ținta BNR
 - ▶ $GW = 3,19$, p-value 0,363: nici pierderea recentă, nici distanța față de țintă nu prezic câștigătorul

Modele imbricate: eșecul testului DM și testul Clark–West (1/2)

- Modelul 1 (mic, de exemplu mersul aleator) este imbricat în modelul 2; sub H_0 coeficienții suplimentari sînt nuli
 - ▶ MSPE: eroarea medie pătratică de prognoză; în populație, MSPE-urile sînt egale, iar d_t este degenerat
 - ▶ de aceea statistica DM nu este asimptotic Normală [Clark și McCracken \(2001\)](#)
- În eșantion finit, modelul 2 estimează cu zgomot niște coeficienți nuli
 - ▶ MSPE-ul lui este **mai mare** decît al modelului 1: DM respinge prea rar și are putere mică


Modele imbricate: eșecul testului DM și testul Clark–West (2/2)

- ▣ **Clark–West Clark și West (2007):** corectăm modelul mare pentru zgomotul pe care îl adaugă
 - ▶ $f_t = e_{1t}^2 - [e_{2t}^2 - (\hat{y}_{1t} - \hat{y}_{2t})^2]$
 - ▶ e_{1t}, e_{2t} : erorile modelului mic și ale celui mare; $\hat{y}_{1t}, \hat{y}_{2t}$: prognozele lor; diferența la pătrat dintre prognoze este zgomotul adăugat de modelul 2
 - ▶ test t unilateral pentru $\mathbb{E}f_t = 0$ față de $\mathbb{E}f_t > 0$ (modelul 2 mai bun), cu valori critice Normale
- ▣ De ce funcționează corecția
 - ▶ sub H_0 , $\mathbb{E}e_1^2 - \mathbb{E}e_2^2 = -\mathbb{E}(\hat{y}_1 - \hat{y}_2)^2$: corecția recentrează diferențialul (▶ Anexă)
 - ▶ aproximativ Normal pentru schemele mobile și recursive; valorile critice exacte din Clark și McCracken (2001) sînt nestandard

Studiu de caz: Meese și Rogoff pentru EUR/RON

- Meese și Rogoff (1983): modelele structurale ale cursului de schimb nu bat mersul aleator în afara eșantionului la orizonturi de până la un an
 - ▶ planul lor: prognoze în afara eșantionului cu origine mobilă, RMSE față de mersul aleator; rezultatul a rezistat patruzeci de ani
- Datele noastre: EUR/RON lunar (cursul de referință BNR, sfârșitul lunii), $\Delta s_{t+1} = 100 \Delta \ln S_{t+1}$; estimare recursivă, prognoze din ianuarie 2010 până în august 2026 ($P = 200$)
 - ▶ S_t : cursul (lei pentru un euro); Δs_{t+1} : variația lui logaritmică lunară, în %, pozitivă când leul se depreciază
 - ▶ imbricate în mersul aleator ($\Delta \hat{s} = 0$): deriva, AR(p), regresia UIP $\Delta s_{t+1} = a + b(i_t^{RO} - i_t^{ZE})/12 + u$ Fama (1984)
 - ▶ i_t^{RO}, i_t^{ZE} : dobânzile la 3 luni, în % pe an (împărțite la 12: pe lună); a, b : coeficienții regresiei
 - ▶ fără parametri estimați: UIP impusă ($a = 0, b = 1$), momentum (media ultimelor trei variații)
- UIP: paritatea neacoperită a dobânzilor, deprecierea așteptată este egală cu diferențialul de dobândă

EUR/RON: modele față de mersul aleator



- Suma cumulată $\sum_t (e_{RW,t}^2 - e_{m,t}^2)$ Welch și Goyal (2008): o linie sub zero arată că modelul m a acumulat mai multă eroare pătratică decât mersul aleator

Interpretarea testelor pentru EUR/RON

Model	RMSE / RW	DM (HLN)	CW	p (CW, unilateral)
deriva	1,006	0,27	1,06	0,145
AR(1)	1,055	1,13	-0,15	0,561
AR(4)	1,062	1,29	-0,43	0,666
regresia UIP	1,016	0,76	0,10	0,458
UIP impusă	1,033	0,99	-	-
momentum	1,183	2,61	-	-
media modelelor	1,026	0,85	-	-

- Toate modelele au RMSE mai mare decât mersul aleator (RMSE al mersului aleator: 0,86 puncte procentuale pe lună); rezultatul Meese–Rogoff se confirmă pentru leu
- Nici Clark–West nu respinge: corecția nu este suficientă pentru ca AR sau UIP să devină utile; doar deriva se apropie
- Managed float: BNR netezește cursul EUR/RON, deci variațiile lunare sînt mici și aproape imprevizibile cu acești predictorii

Raționalitate: Mincer–Zarnowitz și încadrarea (1/2)

- ▣ **Mincer–Zarnowitz** Mincer și Zarnowitz (1969): regresăm realizarea pe prognoză
 - ▶ $y_{t+h} = a + b\hat{y}_{t+h|t} + u_{t+h}$
 - ▶ sub pierdere pătratică o prognoză optimă are $(a, b) = (0, 1)$: fără deplasare, iar o variație cu o unitate a prognozei anunță o variație cu o unitate a realizării
 - ▶ test Wald pentru $(a, b) = (0, 1)$ cu erori HAC (u este $MA(h-1)$); $b < 1$: prognoze prea volatile; $b > 1$: prea timide
 - ▶ versiunea extinsă: adăugăm variabile din $\mathcal{F}_t$; un coeficient semnificativ înseamnă informație nefolosită
- ▣ MZ presupune pierdere pătratică: sub pierdere asimetrică o prognoză rațională este deplasată (secțiunea 1)



Raționalitate: Mincer–Zarnowitz și încadrarea (2/2)

- ▣ **Încadrarea** Chong și Hendry (1986), Harvey, Leybourne și Newbold (1998): prognoza 1 o încadrează pe prognoza 2 dacă 2 nu adaugă nimic la 1
 - ▶ $y = (1 - \lambda)\hat{y}_1 + \lambda\hat{y}_2 + \varepsilon$, $H_0: \lambda = 0$
 - ▶ λ : ponderea prognozei 2 în cea mai bună combinație; $\lambda = 0$: prognoza 2 este inutilă dacă avem prognoza 1
 - ▶ testul HLN: DM–HLN pe $d_t = e_{1t}(e_{1t} - e_{2t})$, unilateral ($\mathbb{E}d_t > 0$ înseamnă $\lambda > 0$)
- ▣ Dacă niciuna nu o încadrează pe cealaltă, o combinație le bate pe amîndouă (secțiunea 5)

Studiu de caz: Atkeson și Ohanian (2001)

- ▣ Atkeson și Ohanian (2001): o prognoză naivă, „inflația din următoarele patru trimestre este egală cu inflația din ultimele patru”, bate prognozele pe baza curbei Phillips în SUA după 1984
 - ▶ curba Phillips din Stock și Watson (1999): $\pi_{t+4}^4 - \pi_t^4 = a + \beta(L)u_t + \gamma(L)\Delta\pi_t + e_{t+4}$
 - ▶ π_t^4 : inflația pe ultimele patru trimestre; π_t : inflația trimestrială; u_t : rata șomajului; $\beta(L), \gamma(L)$: polinoame de laguri (cîte patru laguri)
- ▣ Actualizarea noastră: IPC (media trimestrială) și rata șomajului (FRED); cîte patru laguri, fereastră mobilă de 15 ani; ținte din T1 1985 pînă în T2 2026 ($P = 166$)
 - ▶ IPC pentru octombrie 2025 nu a fost publicat; media pentru T4 2025 folosește două luni
- ▣ Teste: DM–HLN cu $h = 4$; GW cu $h_t = (1, d_t)$ și $h_t = (1, u_t)$; încadrare în ambele direcții

Prognoza naivă față de curba Phillips



- Stînga: inflația IPC pe patru trimestre și cele două prognoze făcute cu patru trimestre înainte; dreapta: raportul MSE pe o fereastră mobilă de 10 ani

Interpretarea actualizării Atkeson–Ohanian

- RMSE: naivă 1,69, curba Phillips 2,97 (raport 1,75); pe perioade: 1,29 (1985–2007), 1,10 (2008–2019), 2,38 (2020–2026)
- Totuși DM–HLN = 1,16, p-value 0,248: erorile mari de după 2020 măresc varianța HAC la fel de mult ca media
 - ▶ raportul pe fereastră mobilă atinge 10,3 în T3 2021: curba Phillips a extrapolat saltul șomajului din pandemie
- GW: p-value 0,355 cu diferențialul din perioada anterioară, 0,322 cu șomajul
 - ▶ încadrare, H_0 „prognoza naivă încadrează curba Phillips”: p-value 0,289
 - ▶ încadrare, H_0 „curba Phillips încadrează prognoza naivă”: p-value 0,118
- Concluzia AO se păstrează în estimările punctuale, iar un test pe 41 de ani de date suprapuse nu le poate separa

Multe modele: data snooping, reality check și SPA

- Testarea a k modele față de un reper și raportarea celui mai mic p-value înseamnă **data snooping**
 - ▶ H_0 : $\max_{j \leq k} \mathbb{E}[d_{j,t}] \leq 0$ cu $d_{j,t} = L_{0,t} - L_{j,t}$: niciun model nu bate reperul
 - ▶ $L_{0,t}$: pierderea reperului; $L_{j,t}$: pierderea modelului j ; $d_{j,t} > 0$: modelul j a fost mai bun la t
- **Reality check White (2000)**: statistica $\max_j \sqrt{P} \bar{d}_j$, p-value-ul din bootstrap-ul staționar ([Capitolul 0](#)) sub configurația cea mai puțin favorabilă
 - ▶ conservator: modelele foarte slabe deplasează în sus distribuția sub ipoteza nulă
- **SPA Hansen (2005)**: studentizăm fiecare $\bar{d}_j$ și scoatem modelele clar inferioare din distribuția sub ipoteza nulă (p-value consistent)
 - ▶ p-value-urile inferior și superior îl încadrează; cel superior este RC cu studentizare
 - ▶ StepM [Romano și Wolf \(2005\)](#) identifică care modele bat reperul
- EUR/RON, $k = 9$ modele față de mersul aleator: p-value SPA = 0,53 (inferior), 0,85 (consistent), 0,88 (superior): niciun model nu îl bate


Mulțimea de încredere a modelelor (MCS) (1/2)

- ▣ **MCS Hansen, Lunde și Nason (2011):** mulțimea $\hat{\mathcal{M}}_{1-\alpha}$ care conține cel mai bun model (sau modelele cele mai bune) cu probabilitatea de cel puțin $1 - \alpha$, asimptotic
 - ▶ fără reper: toate modelele sînt tratate simetric; analog unui interval de încredere pentru un parametru
- ▣ Testul de echivalență pentru cele m modele rămase în mulțime
 - ▶ $H_0: \mathbb{E}[d_{i\cdot,t}] = 0$ pentru orice i , $d_{i\cdot,t} = L_{i,t} - \frac{1}{m} \sum_j L_{j,t}$
 - ▶ $d_{i\cdot,t}$: pierderea modelului i minus pierderea medie a tuturor modelelor; pozitiv: modelul i este mai slab decît media
 - ▶ statistica $T_{\max} = \max_i t_i$, $t_i = \bar{d}_{i\cdot} / \widehat{\text{se}}(\bar{d}_{i\cdot})$: cel mai slab model față de medie, standardizat

Mulțimea de încredere a modelelor (MCS) (2/2)

- Algoritmul: pornim cu toate modelele
 - ▶ dacă testul de echivalență respinge, **eliminăm** modelul cu cel mai mare t_i și repetăm; ne oprim la prima nerespingere
 - ▶ un bootstrap pe blocuri dă distribuția sub H_0 și erorile standard
 - ▶ p-value-ul MCS al unui model: cel mai mare p-value al testelor pînă la eliminarea lui; modelul rămîne în $\hat{\mathcal{M}}_{1-\alpha}$ dacă acesta depășește α
- O mulțime MCS mare este și ea un rezultat
 - ▶ datele nu pot separa modelele (un eșantion slab, nu modele egale)

Studiu de caz: consumul de electricitate din România pentru ziua următoare




O linie de 400 kV, Pasul Predeluș (2018)

Foto: Drprv (2018); CC BY-SA 3.0; Wikimedia Commons


- Ținta: cele 24 de consumuri orare ale zilei $d + 1$, cu date pînă în ziua d ; 1 ianuarie 2025 – 30 septembrie 2026 (638 zile); media 5,98 GW
 - ▶ prognoze de cuantile la cele 99 de percentile, evaluate prin pierderea pinball medie ca în GEFCom2014 Hong et al. (2016), Hong și Fan (2016)
- Modele: naiv zi, naiv săptămînal, media pe 4 săptămîni; **ARX expert** din Ziel și Weron (2018) pentru fiecare oră
 - ▶ regresori: $y_{d,h}$, $y_{d-1,h}$, $y_{d-6,h}$, minimul și maximul zilei d , ultima oră din d , luni, sîmbătă, duminică; fereastră mobilă de un an
 - ▶ cuantile: prognoza punctuală plus cuantilele empirice ale ultimelor 182 de erori la aceeași oră
- ARX: autoregresie cu variabile exogene (aici variabile calendaristice)

O săptămână de iarnă cu prognoze de consum



- 12–18 ianuarie 2026; prognoza naivă săptămînală copiază săptămîna cu sărbători 5–9 ianuarie (Boboteaza și Sfîntul Ion, 6–7 ianuarie)

Pierdere pinball medie și MCS de 90%



□ Pierderi medii zilnice; MCS cu $T_{\max}$, bootstrap pe blocuri mobile (blocuri de 7 zile), 2000 de replicări; verde: în MCS

Interpretarea comparației pentru consumul de electricitate

Model	Pinball (MW)	MAE (MW)	Acoperire 90%	p MCS
naiv (ziua d)	161	433	89,2%	$< 0,001$
naiv săptămînal	155	417	87,6%	$< 0,001$
media pe 4 săptămîni	161	423	88,7%	$< 0,001$
ARX expert	83	221	88,2%	1,000
ARX + media pe 4 săptămîni	107	285	88,3%	$< 0,001$

- ARX expert înjumătățește pierderile regulilor naive și este singur în MCS; DM–HLN față de combinația ARX + medie: $-10,7$
- Aici combinarea cu o prognoză mult mai slabă strică: ponderile egale ajută doar cînd prognozele au calitate asemănătoare (secțiunea 5)
- Toate intervalele acoperă puțin sub nivelul nominal; cele mai mari pierderi cad în zilele de sărbătoare legală și imediat după ele (8 ianuarie 2026, 25 decembrie 2025, 1 ianuarie 2025): efectele calendaristice sînt următoarea îmbunătățire

Recapitulare: compararea prognozelor

- ▣ DM compară prognoze; pentru modele estimate alegeți West (populație) sau GW (metode, fereastră mobilă)
- ▣ Mai mulți pași, P mic: varianță HAC plus corecția HLN și t_{P-1}
- ▣ Modele imbricate: Clark–West; multe modele: SPA sau MCS, niciodată cel mai mic p-value
- ▣ Inflația din România, inflația din SUA, EUR/RON: reperul simplu se bate greu, iar diferențele sînt rareori semnificative

Bates și Granger (1969)



Clive W. J. Granger (1934–2009),
Premiul Nobel pentru Economie 2003


Foto: Olaf Storbeck (2008); CC BY-SA 2.0;
Wikimedia Commons

- Două prognoze nedeplasate cu varianțele erorilor σ_1^2, σ_2^2 și covarianța σ_{12} ; combinația $w\hat{y}_1 + (1 - w)\hat{y}_2$ **Bates și Granger (1969)**
 - ▶ varianța erorii $w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w)\sigma_{12}$, minimă pentru
 - ▶ $w^* = \frac{\sigma_2^2 - \sigma_{12}}{\sigma_1^2 + \sigma_2^2 - 2\sigma_{12}}, \quad \sigma_c^2 = \frac{\sigma_1^2\sigma_2^2 - \sigma_{12}^2}{\sigma_1^2 + \sigma_2^2 - 2\sigma_{12}} \leq \min(\sigma_1^2, \sigma_2^2)$
 - ▶ σ_c^2 : varianța erorii combinației optime, niciodată peste cea a prognozei mai bune; prognoza mai puțin precisă primește ponderea mai mică
- N prognoze: $w^* = \Sigma^{-1}\iota/(\iota'\Sigma^{-1}\iota)$, cu Σ matricea de covarianță a erorilor și ι un vector de unu; **Granger și Ramanathan (1984)**: regresia lui y pe prognoze, cu sau fără termen liber și restricția ca ponderile să însumeze 1
 - ▶ combinarea diversifică riscul de model, rupturile structurale și informația privată a prognozatorilor **Timmermann (2006)**

Paradoxul combinării prognozelor

- Regularitate empirică: media simplă bate ponderile „optime” estimate [Stock și Watson \(2004\)](#), [Timmermann \(2006\)](#), [Genre et al. \(2013\)](#)
 - ▶ Stock–Watson: în 7 țări și cu mulți predictorai ai creșterii economice, ponderile egale și mediana sînt printre cele mai bune combinații
- **Explicația** [Smith și Wallis \(2009\)](#), [Claeskens et al. \(2016\)](#): ponderile sînt estimate
 - ▶ $\mathbb{E}[\text{MSE}(\hat{w})] = \text{MSE}(w^*) + \mathbb{E}(\hat{w} - w^*)^2 D$, $D = \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}$ (varianța lui $e_1 - e_2$)
 - ▶ $\hat{w}$: ponderea estimată din n erori trecute; MSE: eroarea pătratică medie a combinației
 - ▶ câștigul lui w^* față de $1/2$: $(w^* - 1/2)^2 D$; pierderea din estimare: $\text{Var}(\hat{w})D$, de ordinul $1/n$
 - ▶ ponderile egale câștigă cînd $(w^* - 1/2)^2 < \text{Var}(\hat{w})$: prognoze asemănătoare, eșantioane scurte, erori corelate
- În plus: ponderile se schimbă la rupturi, deci ferestrele lungi sînt deplasate, iar cele scurte zgomotoase

Paradoxul prin simulare



- Erori Normale bivariate cu $\sigma_1^2 = 1$; ponderi estimate din n erori trecute; 4 000 de replicări; punctat: raportul în populație $MSE(w^*)/MSE(1/2)$

Interpretarea simulării paradoxului

- Prognoze asemănătoare ($w^* = 0,55$): ponderea optimă reduce MSE-ul din populație doar la 0,997 din MSE-ul ponderilor egale, iar estimarea ei costă: raport 1,14 la $n = 10$, 1,024 la $n = 40$
- Moderat diferite ($w^* = 0,70$): ponderile estimate au nevoie de aproximativ 20 de erori trecute ca să nu piardă (1,07 la $n = 10$, 0,973 la $n = 40$)
- Foarte diferite ($w^* = 0,89$): estimați ponderile sau renunțați la prognoza slabă; cazul consumului de electricitate din secțiunea 4 este de acest tip


Între ponderi egale și optime: shrinkage și combinări robuste

- ▣ **Shrinkage:** $\hat{w}_\lambda = \lambda \hat{w} + (1 - \lambda)\iota/N$ Diebold și Pauly (1990), Stock și Watson (2004)
 - ▶ $\hat{w}$: ponderile estimate; ι/N : ponderi egale pentru N prognoze; $\lambda \in [0, 1]$: $\lambda = 0$ dă media, $\lambda = 1$ ponderile estimate
 - ▶ un prior bayesian centrat pe ponderile egale; λ scade cu numărul de prognoze și crește cu eșantionul
- ▣ **Ponderi după performanță:** $w_i \propto 1/\text{MSE}_i$ pe o fereastră recentă, ignorând corelațiile; actualizarea dă erorilor recente o pondere mai mare
 - ▶ **cel mai bun anterior:** alegem prognozatorul cu cel mai mic MSE trecut (o pondere egală cu 1)
- ▣ **Robuste:** mediana, media trunchiată: protejează împotriva prognozatorilor extremi
- ▣ Panelurile de experți se schimbă: prognozatorii intră și ies, deci Σ nu este niciodată observată complet Capistrán și Timmermann (2009)
 - ▶ ponderile după performanță cer un istoric minim; o sinteză a 50 de ani de practică: Wang et al. (2023)

Combinarea prognozelor de densitate

- ▣ **Combinarea liniară** (linear pool): $p(y) = \sum_i w_i p_i(y)$, $w_i \geq 0$, $\sum w_i = 1$ Hall și Mitchell (2007)
 - ▶ p_i : prognoza de densitate a modelului i ; w_i : ponderea ei; combinarea este o mixtură de densități
 - ▶ ponderile care minimizează scorul logaritm mediu: **optimal prediction pools** Geweke și Amisano (2011)
 - ▶ ponderi interioare chiar dacă toate modelele sînt greșit specificate: o combinare nu este o medie de modele în sens bayesian
- ▣ Combinarea liniară a unor densități calibrate este **supradispersată** Gneiting și Ranjan (2013)
 - ▶ mixtura adaugă varianța mediilor; remediul: o combinare transformată beta sau medierea cuantilelor (vincentizare)
- ▣ Scorurile proprii (secțiunea 3) sînt criteriile naturale pentru estimarea și compararea combinărilor

Combinări optime pentru densitățile S&P 500



- Scorul logaritmic mediu al $w p_{\text{GARCH-t}} + (1 - w) p_2$ pe 2013–2026; punctele: minimele
- Cu i.i.d. Normal: $w^* = 0,98$, scorul 1,2318 față de 1,2328 pentru GARCH- t singur; cu GARCH-N: $w^* = 1,00$: GARCH- t domină, combinarea nu adaugă aproape nimic

Interpretarea combinărilor optime

- ▣ Combinarea cu i.i.d. Normal pune aproape toată ponderea pe GARCH- t : o mică componentă Normală doar asigură împotriva zilelor extreme
- ▣ Cu GARCH-N optimul este colțul $w = 1$: cele două densități GARCH conțin aceeași informație, cozile t sînt pur și simplu mai bune
- ▣ Ponderile estimate pe eșantionul de evaluare sînt optimiste; în practică estimați-le pe o fereastră trecută și evaluați pe următoarea

Studiu de caz: scheme de combinare față de media simplă




Federal Reserve Bank of Philadelphia, unde se află SPF din 1990

Foto: [Beyond My Ken \(2013\)](#); CC BY-SA 4.0;
[Wikimedia Commons](#)


- [Genre et al. \(2013\)](#) compară scheme de combinare pe Survey of Professional Forecasters al BCE: ponderi egale, mediana, media trunchiată, ponderi după performanță, shrinkage și altele
 - ▶ răspunsul lor: rareori și nu robust în timp
- Aplicăm schemele lor pe SPF din SUA: inflația IPC (anualizată, trimestrială) la patru trimestre după trimestrul anchetei; anchete T1 1990–T2 2025 ($P = 142$, 195 de prognozatori, în medie 36 pe anchetă)
 - ▶ ponderi după performanță: inversul MSE pe ultimele 20 de anchete cu realizare cunoscută, cel puțin 8 prognoze trecute (în medie 25 de prognozatori eligibili); media trunchiată: 10% din fiecare parte

Prognozele individuale SPF și realizarea



- ☐ Fiecare punct: prognoza IPC a unui prognozator pentru trimestrul de peste patru trimestre, plasată la trimestrul-țintă; realizarea este mult mai volatilă decât orice prognoză

Scheme de combinare față de medie



□ RMSE relativ la media cu ponderi egale (RMSE 2,18 puncte procentuale); albastru: cel puțin la fel de bun ca media

Q ATS_ch1_spf_combination

Interpretarea combinării SPF

- Mediana 0,999, media trunchiată 1,000, inversul MSE 1,008, cel mai bun anterior 1,099 (RMSE relativ)
 - ▶ DM–HLN față de medie: mediana p 0,842; inversul MSE p 0,091; cel mai bun anterior HLN 2,76, p 0,007
 - ▶ Răspunsul lui [Genre et al. \(2013\)](#) se confirmă pe datele SUA: nimic nu bate media semnificativ, iar urmărirea câștigătorului trecut pierde
- Totuși 33% dintre cei 76 de prognozatori cu cel puțin 20 de prognoze au RMSE mai mic decât media
 - ▶ sînt cunoscuți doar ex post, pe eșantioane diferite și mai scurte: supraviețuire și noroc, nu abilitate care putea fi selectată
- Mincer–Zarnowitz pentru medie: $\hat{b} = 0,24$ (SE 0,31), $R^2 = 0,005$, $p < 0,001$: inflația IPC trimestrială cu un an înainte este aproape imprevizibilă; prognozele sînt netede, realizările zgomotoase

Lecțiile competițiilor M4 și M5

- **M4** (2018) [Makridakis et al. \(2020\)](#): 100 000 de serii, 61 de metode, prognoze punctuale și intervale de 95%
 - ▶ câștigătorul a fost un hibrid între netezirea exponențială și o rețea neuronală recurentă; locul doi, o combinație de metode statistice cu ponderi învățate de un meta-model
 - ▶ combinațiile au dominat primele locuri; metodele de machine learning pure au avut rezultate slabe; intervalele de predicție au fost prea înguste pentru majoritatea metodelor
- **M5** (2020) [Makridakis et al. \(2022\)](#): 42 840 de serii ierarhice de vânzări Walmart, erori scalate ponderate
 - ▶ arborii cu gradient boosting (LightGBM) antrenați *pe toate* seriile au câștigat; variabilele exogene (prețuri, evenimente) și învățarea între serii au contat
 - ▶ din nou, ansamblurile de multe modele au fost în frunte ([Capitolul 12](#))
- Lecția comună: combinați, evaluați cu scoruri independente de scală (MASE, TSA, [Capitolul 0](#)) și cu scoruri proprii și raportați o incertitudine calibrată



Recapitulare: combinarea

- ▣ Ponderile optime reduc varianța erorii; ponderile estimate adaugă un cost de ordinul $1/n$
- ▣ Paradoxul: când prognozele sînt asemănătoare, cîștigă ponderile egale, mediana și media trunchiată
- ▣ Combinările liniare de densități sînt supradispersate; estimați-le prin scorul logaritmico
- ▣ SPF din SUA: nicio schemă nu bate media semnificativ; alegerea cîștigătorului trecut pierde

Versiuni ale datelor și revizuiți

- Datele macroeconomice se revizuiesc: PIB-ul SUA este publicat prima dată la aproximativ 30 de zile după trimestru și revizuit ani la rând (revizuiți de referință, metode noi)
 - ▶ o **versiune** este setul de date așa cum era disponibil la o anumită dată; setul de date în timp real păstrează toate versiunile [Croushore și Stark \(2001\)](#)
- Surse fără cheie: ALFRED (St. Louis Fed, versiunile seriilor FRED), RTDSM al Philadelphia Fed; BCE păstrează o bază de date în timp real pentru zona euro; INS publică o estimare semnal a PIB și estimări revizuite ulterior
 - ▶ prognozele făcute cu ultima versiune a datelor exagerează ce se putea prezice în timp real [Stark și Croushore \(2002\)](#), [Croushore \(2011\)](#)
- Întrebarea pentru evaluare: ce versiune este „adevărul”? Prima publicare (ținta prognozatorilor) sau ultima (cea mai bună estimare a realității)?

Creșterea PIB real în SUA: prima publicare și ultima versiune



- Creșterea trimestrială anualizată, 1990–2026; revizuirile = ultima versiune minus prima publicare (Philadelphia Fed RTDSM); prima publicare pentru T4 2025 lipsește (închiderea guvernului federal)

ATS_ch1_real_time

Interpretarea revizuirilor

- Revizuirea medie 0,23 pp, abaterea standard 1,54 pp, revizuirea absolută medie 1,21 pp pe 143 de trimestre; corelația prima–ultima 0,939
 - ▶ cele mai mari: T2 2020 (4,9 pp) și T4 2008 (−4,7 pp): revizuirile sînt mari exact la punctele de cotitură
- Nowcast-ul SPF pentru trimestrul curent ($P = 143$): RMSE 1,95 față de prima publicare, 2,36 față de ultima; panta MZ 1,15 și 1,08
- Ierarhia prognozatorilor și a modelelor se poate schimba cu versiunea: precizați alegerea în preînregistrare

Un plan de evaluare preînregistrat

- ▣ Fixați **înainte** de a vedea rezultatele în afara eșantionului
 - ▶ ținta, orizonturile, pierderea sau scorul (secțiunile 1–3), versiunea realizării, perioada de evaluare, schema și fereastra de estimare
 - ▶ reperul (mersul aleator, naiv sezonier, media anchetei) și lista completă a modelelor concurente
 - ▶ testele: DM–HLN sau GW; Clark–West pentru modele imbricate; SPA sau MCS pentru multe modele; o corecție pentru mai multe orizonturi (Holm)
- ▣ Raportați tot ce s-a încercat; un model selectat pe perioada de test are o eroare deplasată
 - ▶ proiectul acestui curs începe exact cu un astfel de plan (propunerea și preînregistrarea, 5%)

Recapitulare: date în timp real

- ▣ Evaluați prognozele cu datele care existau când au fost făcute
- ▣ Revizuirile sînt mari la punctele de cotitură; alegerea versiunii „adevărate” schimbă RMSE și ierarhiile
- ▣ Preînregistrați țintele, pierderile, reperele, testele și versiunea datelor

O întrebare deschisă

- ▣ Rezistă paradoxul combinării când panelul de experți se schimbă în timp, iar distribuția realizărilor se deplasează (2020–2023)?
 - ▶ formal: $H_0: \mathbb{E}[(y - \hat{y}_\lambda)^2 - (y - \bar{y})^2] \geq 0$ pentru orice factor de shrinkage λ fixat dinainte, în fiecare subperioadă
 - ▶ $\hat{y}_\lambda$: combinația shrinkage cu factorul λ ; $\bar{y}$: media tuturor prognozatorilor
 - ▶ infirmată de un λ preînregistrat care bate media cu DM–HLN și p-value $< 0,05$ după o corecție Holm pe subperioade
- ▣ De ce contează: băncile centrale publică media anchetelor; o combinaire mai bună ar schimba așteptările publicate
 - ▶ literatura de pornire: Genre et al. (2013), Capistrán și Timmermann (2009), Smith și Wallis (2009), Claeskens et al. (2016), Wang et al. (2023)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate despre combinarea prognozelor SPF cu intrarea și ieșirea prognozatorilor; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** Propune trei motive pentru care ponderile după inversul MSE ar putea bate media după 2020, fiecare cu un test.
 - ▶ **cod și replicare:** cereți o funcție, apoi reproduceți întâi o cifră cunoscută (RMSE relativ al medianei din acest curs)
 - ▶ **robustețe și critică:** Joacă rolul unui recenzent ostil: enumeră toate felurile în care această evaluare ar putea fi afectată de data snooping.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Fără informație din viitor: ponderile la ancheta s folosesc doar realizări cunoscute la s (aici, prognoze din anchete cu cel puțin cinci trimestre mai vechi, al căror trimestru-țintă s -a încheiat)
- ▣ Numărul de laguri HAC corespunde suprapunerii țăntelor $(h - 1)$; corecția HLN este aplicată
- ▣ λ , subperioadele și istoricul minim sînt fixate înaintea rezultatelor; toate variantele sînt raportate
- ▣ Interpretarea separă „neseemnificativ” de „egal”

Mini-studiu de caz: shrinkage pe subperioade



- RMSE al combinației $\lambda \cdot (\text{ponderi după inversul MSE}) + (1 - \lambda) \cdot (\text{ponderi egale între prognozatorii eligibili})$, relativ la media tuturor prognozatorilor; SPF din SUA, IPC la patru trimestre
- $\lambda = 1$: 1,009 (1990–2007, $P = 72$), 1,007 (2008–2019), 1,007 (2020–2025); eșantionul complet HLN 1,70, p 0,091
- În fiecare subperioadă: cu cât ponderea performanței trecute este mai mare, cu atât rezultatul este mai slab; paradoxul rezistă valului inflaționist din 2020–2023

Idee de proiect

- ▣ **Combinarea prognozelor inflației din România:** modele (AR, curba Phillips cu deviația PIB, ținta BNR), anchete și așteptări din piață
 - ▶ preînregistrați orizonturile de 1–12 luni, pierderea pinball la 5%, 50%, 95% și CRPS, corecția Holm pe orizonturi
 - ▶ replicați întâi: tabelul pentru inflația din România din acest curs (Seminarul 1, C1 îl face pe orizonturi)
 - ▶ extensie: combinarea densităților prin optimal pools; testul GW pentru a vedea dacă șocul din 2022 a schimbat câștigătorul
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Alegeți întâi pierderea sau scorul: ele definesc ce este o prognoză „bună” (medie, mediană, cuantilă, distribuție)
- ▣ Prognozele de densitate: verificați calibrarea cu PIT, ierarhizați cu scoruri proprii; ES are nevoie de VaR pentru a fi evaluat
- ▣ Teste: DM–HLN cu HAC, GW pentru metode, Clark–West pentru modele imbricate, SPA și MCS pentru multe modele
- ▣ Combinați prognozele asemănătoare cu ponderi egale; ponderile estimate merită doar pentru prognoze foarte diferite și istoric lung
- ▣ Evaluați în timp real și preînregistrați planul

Autoevaluare

Întrebări

- ▣ Ce funcțională elicitează pierderea pinball cu $\tau = 0,05$?
- ▣ Ce spune o histogramă PIT în formă de U despre intervale?
- ▣ De ce nu este valid testul DM pentru modele imbricate cu parametri estimați?
- ▣ Când bat ponderile de combinare estimate ponderile egale?
- ▣ De ce nu poate fi ierarhizat ES singur?

Urmează:

- ▣ Rupturi structurale și modele neliniare: teste pentru rupturi, modele cu prag
- ▣ Evaluarea prognozelor sub instabilitate: ferestre mobile, eșecul prognozelor, testul de fluctuație [Giacomini și Rossi \(2010\)](#)

Anexă: consistența pierderii pinball

- $\mathbb{E}\rho_\tau(Y - x) = \tau \int_x^\infty (y - x)dF(y) + (1 - \tau) \int_{-\infty}^x (x - y)dF(y)$
- Derivata (Leibniz): $-\tau(1 - F(x)) + (1 - \tau)F(x) = F(x) - \tau$; nulă în $x = F^{-1}(\tau)$; derivata a doua $f(x) \geq 0$
- Pentru $\tau = 1/2$: $\rho_{1/2}(e) = |e|/2$, deci mediana; pentru x diferit de cuantilă, pierderea suplimentară este $\int_q^x (F(z) - \tau)dz > 0$
- Pierderile liniare pe porțiuni generalizate $(1\{y \leq x\} - \tau)(g(x) - g(y))$, g crescătoare, formează întreaga clasă de pierderi consistente pentru cuantilă [Gneiting \(2011\)](#)

Anexă: forma cu nucleu a CRPS

- ▣ Scriem $(F(z) - 1\{y \leq z\})^2 = F(z)^2 - 2F(z)1\{y \leq z\} + 1\{y \leq z\}$
- ▣ Cu $X, X' \sim F$ i.i.d.: $F(z)^2 = P(X \leq z, X' \leq z)$ și $\mathbb{E}|X - y| = \int [F(z)(1 - 1\{y \leq z\}) + (1 - F(z))1\{y \leq z\}] dz$
- ▣ $\frac{1}{2}\mathbb{E}|X - X'| = \int F(z)(1 - F(z)) dz$; prin scădere obținem $\int (F(z) - 1\{y \leq z\})^2 dz$
- ▣ Proprietatea: $\mathbb{E}_G \text{CRPS}(F, Y) - \mathbb{E}_G \text{CRPS}(G, Y) = \int (F(z) - G(z))^2 dz \geq 0$, zero doar dacă $F = G$

Anexă: corecția Clark–West

- ▣ Sub H_0 coeficienții suplimentari ai modelului mare sînt $\beta_2 = 0$; prognoza lui este aproximativ $\hat{y}_2 = \hat{y}_1 + \hat{\beta}_2' x_2$, cu $\hat{\beta}_2$ zgomot de estimare pur
- ▣ $e_2 = e_1 - (\hat{y}_2 - \hat{y}_1)$, deci $e_1^2 - e_2^2 = 2e_1(\hat{y}_2 - \hat{y}_1) - (\hat{y}_2 - \hat{y}_1)^2$
- ▣ $\mathbb{E}[e_1(\hat{y}_2 - \hat{y}_1)] = 0$ sub H_0 (e_1 este o diferență de martingală), deci $\mathbb{E}(e_1^2 - e_2^2) = -\mathbb{E}(\hat{y}_2 - \hat{y}_1)^2 < 0$
- ▣ Adunarea lui $(\hat{y}_1 - \hat{y}_2)^2$ recentrează diferențialul în zero: $f_t = 2e_{1t}(\hat{y}_{2t} - \hat{y}_{1t})$, statistica de încadrare din [Harvey, Leybourne și Newbold \(1998\)](#) sub altă formă

Bibliografie (1/7)

- ▣ Amisano, G., & Giacomini, R. (2007). Comparing density forecasts via weighted likelihood ratio tests. *Journal of Business & Economic Statistics*, 25(2), 177–190. doi:10.1198/073500106000000332
- ▣ Atkeson, A., & Ohanian, L. E. (2001). Are Phillips curves useful for forecasting inflation? *Federal Reserve Bank of Minneapolis Quarterly Review*, 25(1), 2–11. doi:10.21034/qv.2511
- ▣ Banerjee, A., Guo, X., & Wang, H. (2005). On the optimality of conditional expectation as a Bregman predictor. *IEEE Transactions on Information Theory*, 51(7), 2664–2669. doi:10.1109/TIT.2005.850145
- ▣ Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468. doi:10.1057/jors.1969.103
- ▣ Berkowitz, J. (2001). Testing density forecasts, with applications to risk management. *Journal of Business & Economic Statistics*, 19(4), 465–474. doi:10.1198/07350010152596718
- ▣ Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *The Review of Economics and Statistics*, 69(3), 542–547. doi:10.2307/1925546
- ▣ Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
- ▣ Capistrán, C., & Timmermann, A. (2009). Forecast combination with entry and exit of experts. *Journal of Business & Economic Statistics*, 27(4), 428–440. doi:10.1198/jbes.2009.07211
- ▣ Chong, Y. Y., & Hendry, D. F. (1986). Econometric evaluation of linear macro-economic models. *The Review of Economic Studies*, 53(4), 671–690. doi:10.2307/2297611
- ▣ Christoffersen, P. F., & Diebold, F. X. (1997). Optimal prediction under asymmetric loss. *Econometric Theory*, 13(6), 808–817. doi:10.1017/S0266466600006277
- ▣ Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862. doi:10.2307/2527341

Bibliografie (2/7)

- Claeskens, G., Magnus, J. R., Vasnev, A. L., & Wang, W. (2016). The forecast combination puzzle: A simple theoretical explanation. *International Journal of Forecasting*, 32(3), 754–762. doi:10.1016/j.ijforecast.2015.12.005
- Clark, T. E., & McCracken, M. W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110. doi:10.1016/S0304-4076(01)00071-9
- Clark, T. E., & West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311. doi:10.1016/j.jeconom.2006.05.023
- Croushore, D. (2011). Frontiers of real-time data analysis. *Journal of Economic Literature*, 49(1), 72–100. doi:10.1257/jel.49.1.72
- Croushore, D., & Stark, T. (2001). A real-time data set for macroeconomists. *Journal of Econometrics*, 105(1), 111–130. doi:10.1016/S0304-4076(01)00072-0
- Dawid, A. P. (1984). Statistical theory: The prequential approach. *Journal of the Royal Statistical Society, Series A*, 147(2), 278–292. doi:10.2307/2981683
- Diebold, F. X. (2015). Comparing predictive accuracy, twenty years later: A personal perspective on the use and abuse of Diebold–Mariano tests. *Journal of Business & Economic Statistics*, 33(1), 1. doi:10.1080/07350015.2014.983236
- Diebold, F. X., Gunther, T. A., & Tay, A. S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883. doi:10.2307/2527342
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Diebold, F. X., & Pauly, P. (1990). The use of prior information in forecast combination. *International Journal of Forecasting*, 6(4), 503–508. doi:10.1016/0169-2070(90)90028-A
- Ehm, W., Gneiting, T., Jordan, A., & Krüger, F. (2016). Of quantiles and expectiles: Consistent scoring functions, Choquet representations and forecast rankings. *Journal of the Royal Statistical Society, Series B*, 78(3), 505–562. doi:10.1111/rssb.12154

Bibliografie (3/7)

- Elliott, G., & Timmermann, A. (2008). Economic forecasting. *Journal of Economic Literature*, 46(1), 3–56. doi:10.1257/jel.46.1.3
- Fama, E. F. (1984). Forward and spot exchange rates. *Journal of Monetary Economics*, 14(3), 319–338. doi:10.1016/0304-3932(84)90046-1
- Fissler, T., & Ziegel, J. F. (2016). Higher order elicibility and Osband's principle. *The Annals of Statistics*, 44(4), 1680–1707. doi:10.1214/16-AOS1439
- Genre, V., Kenny, G., Meyler, A., & Timmermann, A. (2013). Combining expert forecasts: Can anything beat the simple average? *International Journal of Forecasting*, 29(1), 108–121. doi:10.1016/j.ijforecast.2012.06.004
- Geweke, J., & Amisano, G. (2011). Optimal prediction pools. *Journal of Econometrics*, 164(1), 130–141. doi:10.1016/j.jeconom.2011.02.017
- Giacomini, R., & Rossi, B. (2010). Forecast comparisons in unstable environments. *Journal of Applied Econometrics*, 25(4), 595–620. doi:10.1002/jae.1177
- Giacomini, R., & White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578. doi:10.1111/j.1468-0262.2006.00718.x
- Gneiting, T., Balabdaoui, F., & Raftery, A. E. (2007). Probabilistic forecasts, calibration and sharpness. *Journal of the Royal Statistical Society, Series B*, 69(2), 243–268. doi:10.1111/j.1467-9868.2007.00587.x
- Gneiting, T., & Katzfuss, M. (2014). Probabilistic forecasting. *Annual Review of Statistics and Its Application*, 1, 125–151. doi:10.1146/annurev-statistics-062713-085831
- Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762. doi:10.1198/jasa.2011.r10138
- Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/016214506000001437

Bibliografie (4/7)

- ▣ Gneiting, T., & Ranjan, R. (2013). Combining predictive distributions. *Electronic Journal of Statistics*, 7, 1747–1782. doi:10.1214/13-EJS823
- ▣ Gneiting, T., & Ranjan, R. (2011). Comparing density forecasts using threshold- and quantile-weighted scoring rules. *Journal of Business & Economic Statistics*, 29(3), 411–422. doi:10.1198/jbes.2010.08110
- ▣ Good, I. J. (1952). Rational decisions. *Journal of the Royal Statistical Society, Series B*, 14(1), 107–114. doi:10.1111/j.2517-6161.1952.tb00104.x
- ▣ Granger, C. W. J., & Ramanathan, R. (1984). Improved methods of combining forecasts. *Journal of Forecasting*, 3(2), 197–204. doi:10.1002/for.3980030207
- ▣ Hall, S. G., & Mitchell, J. (2007). Combining density forecasts. *International Journal of Forecasting*, 23(1), 1–13. doi:10.1016/j.ijforecast.2006.08.001
- ▣ Hamill, T. M. (2001). Interpretation of rank histograms for verifying ensemble forecasts. *Monthly Weather Review*, 129(3), 550–560. doi:10.1175/1520-0493(2001)129<0550:IORHFV>2.0.CO;2
- ▣ Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. doi:10.2307/j.ctv14jx6sm
- ▣ Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. doi:10.1198/073500105000000063
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- ▣ Harvey, D. I., Leybourne, S. J., & Newbold, P. (1998). Tests for forecast encompassing. *Journal of Business & Economic Statistics*, 16(2), 254–259. doi:10.1080/07350015.1998.10524759
- ▣ Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. doi:10.1016/S0169-2070(96)00719-4

Bibliografie (5/7)

- ▣ Hong, T., & Fan, S. (2016). Probabilistic electric load forecasting: A tutorial review. *International Journal of Forecasting*, 32(3), 914–938. doi:10.1016/j.ijforecast.2015.11.011
- ▣ Hong, T., Pinson, P., Fan, S., Zareipour, H., Troccoli, A., & Hyndman, R. J. (2016). Probabilistic energy forecasting: Global Energy Forecasting Competition 2014 and beyond. *International Journal of Forecasting*, 32(3), 896–913. doi:10.1016/j.ijforecast.2016.02.001
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Kilian, L., & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*. Cambridge University Press. doi:10.1017/9781108164818
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. doi:10.1016/j.ijforecast.2021.11.013
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. doi:10.1016/j.ijforecast.2019.04.014
- ▣ Matheson, J. E., & Winkler, R. L. (1976). Scoring rules for continuous probability distributions. *Management Science*, 22(10), 1087–1096. doi:10.1287/mnsc.22.10.1087
- ▣ Meese, R. A., & Rogoff, K. (1983). Empirical exchange rate models of the seventies. *Journal of International Economics*, 14(1–2), 3–24. doi:10.1016/0022-1996(83)90017-X
- ▣ Mincer, J., & Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (Ed.), *Economic Forecasts and Expectations* (pp. 3–46). NBER. nber.org
- ▣ Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. doi:10.2307/1913610

Bibliografie (6/7)

- ▣ Patton, A. J. (2020). Comparing possibly misspecified forecasts. *Journal of Business & Economic Statistics*, 38(4), 796–809. doi:10.1080/07350015.2019.1585256
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., et al. (2022). Forecasting: theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Romano, J. P., & Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282. doi:10.1111/j.1468-0262.2005.00615.x
- ▣ Rossi, B., & Sekhposyan, T. (2019). Alternative tests for correct specification of conditional predictive densities. *Journal of Econometrics*, 208(2), 638–657. doi:10.1016/j.jeconom.2018.07.008
- ▣ Savage, L. J. (1971). Elicitation of personal probabilities and expectations. *Journal of the American Statistical Association*, 66(336), 783–801. doi:10.1080/01621459.1971.10482346
- ▣ Scheuerer, M., & Hamill, T. M. (2015). Variogram-based proper scoring rules for probabilistic forecasts of multivariate quantities. *Monthly Weather Review*, 143(4), 1321–1334. doi:10.1175/MWR-D-14-00269.1
- ▣ Smith, J., & Wallis, K. F. (2009). A simple explanation of the forecast combination puzzle. *Oxford Bulletin of Economics and Statistics*, 71(3), 331–355. doi:10.1111/j.1468-0084.2008.00541.x
- ▣ Stark, T., & Croushore, D. (2002). Forecasting with a real-time data set for macroeconomists. *Journal of Macroeconomics*, 24(4), 507–531. doi:10.1016/S0164-0704(02)00062-9
- ▣ Stock, J. H., & Watson, M. W. (2004). Combination forecasts of output growth in a seven-country data set. *Journal of Forecasting*, 23(6), 405–430. doi:10.1002/for.928
- ▣ Stock, J. H., & Watson, M. W. (1999). Forecasting inflation. *Journal of Monetary Economics*, 44(2), 293–335. doi:10.1016/S0304-3932(99)00027-6

Bibliografie (7/7)

- ▣ Timmermann, A. (2006). Forecast combinations. In G. Elliott, C. W. J. Granger, & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 1, pp. 135–196). Elsevier. doi:10.1016/S1574-0706(05)01004-9
- ▣ Wang, X., Hyndman, R. J., Li, F., & Kang, Y. (2023). Forecast combinations: An over 50-year review. *International Journal of Forecasting*, 39(4), 1518–1547. doi:10.1016/j.ijforecast.2022.11.005
- ▣ Weber, S. (2006). Distribution-invariant risk measures, information, and dynamic consistency. *Mathematical Finance*, 16(2), 419–441. doi:10.1111/j.1467-9965.2006.00277.x
- ▣ Welch, I., & Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *The Review of Financial Studies*, 21(4), 1455–1508. doi:10.1093/rfs/hhm014
- ▣ West, K. D. (1996). Asymptotic inference about predictive ability. *Econometrica*, 64(5), 1067–1084. doi:10.2307/2171956
- ▣ White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126. doi:10.1111/1468-0262.00152
- ▣ Ziel, F., & Weron, R. (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics*, 70, 396–420. doi:10.1016/j.eneco.2017.12.016