



Analiza avansată a seriilor de timp și previziune

Capitolul 5: Modele VAR bayesiene, modele factoriale și nowcasting



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ADL-MIDAS: Autoregressive Distributed Lag MIDAS (regresie MIDAS cu decalaje autoregresive și distribuite)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ BGR: Bańbura–Giannone–Reichlin (large Bayesian VARs, 2010) — modelele VAR bayesiene mari Bańbura–Giannone–Reichlin (2010)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian (Schwarz))
- ▣ BVAR: Bayesian Vector AutoRegression (model vector autoregresiv bayesian)
- ▣ CPI: Consumer Price Index (indicele prețurilor de consum)
- ▣ CUMFNS: Capacity utilisation, manufacturing (FRED series code) — gradul de utilizare a capacităților în industria prelucrătoare (codul seriei în FRED)
- ▣ DFM: Dynamic Factor Model (model factorial dinamic)
- ▣ DI: Diffusion Index (forecast) — prognoză cu indici de difuziune
- ▣ DI-AR: Diffusion Index forecast with AutoRegressive lags (prognoză cu indici de difuziune și decalaje autoregresive)
- ▣ EM: Expectation–Maximisation (algorithm) — algoritmul expectație–maximizare
- ▣ EMPL: employment (total private payrolls) — ocuparea (salariații din sectorul privat)
- ▣ ESI: Economic Sentiment Indicator (European Commission) — indicatorul sentimentului economic (Comisia Europeană)
- ▣ ESS: Effective Sample Size (mărimea efectivă a eșantionului)
- ▣ FAVAR: Factor-Augmented Vector AutoRegression (model VAR augmentat cu factori)
- ▣ FFR: Federal Funds Rate (dobînda federal funds)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ FRED-MD: FRED Monthly Database for macroeconomic research (McCracken–Ng) — baza de date lunară FRED pentru cercetare macroeconomică (McCracken–Ng)
- ▣ GLP: Giannone–Lenza–Primiceri (hierarchical prior selection, 2015) — alegerea ierarhică a distribuției a priori Giannone–Lenza–Primiceri (2015)
- ▣ INS: Institutul Național de Statistică
- ▣ IP: Industrial Production (producția industrială)
- ▣ IPC: Indicele prețurilor de consum
- ▣ LARGE: the large system of BGR (all series observed over the sample) — sistemul mare din BGR (toate seriile observate pe eșantion)
- ▣ LLM: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ MCMC: Markov Chain Monte Carlo (metode Monte Carlo cu lanțuri Markov)

Acronime folosite în acest material (2/2)

- MEDIUM: the 20-variable system of BGR (sistemul cu 20 de variabile din BGR)
- MIDAS: MIXed DATA Sampling (regression) — regresie cu date de frecvențe mixte
- ML: Machine Learning (învățare automată)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MSFE: Mean Squared Forecast Error (eroarea medie pătratică de prognoză)
- NBER: National Bureau of Economic Research (Biroul Național de Cercetări Economice al SUA)
- NIW: Normal-inverse-Wishart (prior) — distribuția a priori Normal-inverse-Wishart
- NLS: Nonlinear Least Squares (cele mai mici pătrate neliniare)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- PCA: Principal Component Analysis (analiza componentelor principale)
- PIB: Produsul intern brut
- RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- SE: Standard Error (eroare standard)
- SMALL: the 3-variable system of BGR (employment, CPI, federal funds rate) — sistemul cu 3 variabile din BGR (ocupare, IPC, dobînda federal funds)
- SUA: Statele Unite ale Americii
- SVAR: Structural Vector AutoRegression (model vector autoregresiv structural)
- TSA: Time Series Analysis (Serii de timp, cursul de licență)
- UNRATE: Unemployment Rate (FRED series code) — rata șomajului (codul seriei în FRED)
- USREC: NBER recession indicator (FRED series code) — indicatorul recesiunilor NBER (codul seriei în FRED)
- VAR: Vector AutoRegression (model vector autoregresiv)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum prognozăm și analizăm o economie descrisă de o sută de serii, unele publicate lunar și cu întârziere, altele trimestrial?
 - ▶ un VAR nerestricționat cu 100 de variabile și 13 laguri are peste 130 000 de coeficienți: datele singure nu îi pot determina
- ▣ **Traseul** capitolului
 - ▶ blestemul dimensionalității; inferența bayesiană la nivelul necesar (conjugare, eşantionarea Gibbs, diagnosticarea MCMC)
 - ▶ distribuțiile a priori Minnesota și Normal-inverse-Wishart, observații fictive, shrinkage ales prin verosimilitatea marginală, modele BVAR mari
 - ▶ modele factoriale: componente principale, numărul de factori, indici de difuziune, FAVAR, modele factoriale dinamice
 - ▶ frecvențe mixte și nowcasting: ecuații punte, MIDAS, filtrul Kalman cu date incomplete la sfârșitul eşantionului, știri; PIB-ul României
- ▣ Pornim de la [TSA, Capitolul 6](#) (VAR), [TSA, Capitolul 10](#) (filtrul Kalman) și [Capitolul 3](#) (VAR structural); Seminarul 5 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Derivați distribuții a posteriori conjugate, rulați un eșantionator Gibbs și judecați convergența cu grafice de traiectorie, mărimea efectivă a eșantionului și $\hat{R}$
- ▣ Scrieți distribuția a priori Minnesota în formă natural conjugată și cu observații fictive și explicați fiecare hiperparametru
- ▣ Alegeți gradul de shrinkage al unui BVAR mare prin verosimilitatea marginală sau prin regula potrivirii în eșantion și evaluați prognozele în afara eșantionului
- ▣ Estimați modele factoriale aproximative prin componente principale, alegeți numărul de factori și construiți prognoze cu indici de difuziune și un FAVAR
- ▣ Realizați nowcasting pentru PIB-ul trimestrial din date lunare cu ecuații punte, MIDAS și un model factorial dinamic și descompuneți fiecare revizuire în știri

Bibliografie, date și instrumente

- Manualul de bază: Kilian și Lütkepohl (2017), cap. 5 (VAR bayesian) și cap. 16 (VAR mari, factori); Karlsson (2013); Stock și Watson (2016)
 - ▶ Fundamente bayesiene: Gelman et al. (2013); spațiul stărilor: Durbin și Koopman (2012); sinteză despre nowcasting: Bańbura, Giannone, Modugno și Reichlin (2013)
- Quantlet-urile Python ale capitolului: Quantlets/Ch_05
 - ▶ BVAR Minnesota și Normal-inverse-Wishart, verosimilitatea marginală, PCA cu EM, Bai-Ng, FAVAR, filtrul Kalman și știrile scrise explicit în `numpy`
 - ▶ pachete de comparație: `statsmodels` (DynamicFactorMQ, estimarea EM a modelului de nowcasting) și `bvar` al Băncii Angliei (hiperparametri GLP)
- Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Utilizare
117 serii lunare SUA în formatul FRED-MD (producție, muncă, locuințe, comenzi, monedă, dobânzi, prețuri), 1960:1–2026:7	FRED (St. Louis Fed), câte un CSV pe serie; codurile de transformare FRED-MD McCracken și Ng (2016)	BVAR, factori, FAVAR
datele recesiunilor NBER; gradul de utilizare a capacităților, rata șomajului din SUA	FRED (USREC, CUMFNS, UNRATE)	grafice, Gibbs
România: IP, comerț cu amănuntul, construcții, șomaj, șase indicatori de încredere (11 serii lunare); IP din zona euro	Eurostat (sts_inpr_m, sts_trtu_m, sts_copr_m, une_rt_m, ei_bssi_m_r2)	nowcasting
PIB-ul real al României, trimestrial, ajustat sezonier și cu numărul de zile lucrătoare	Eurostat (namq_10_gdp)	variabila-țintă

- Toate sursele sînt publice și nu cer cont sau cheie; codurile FRED-MD: 1 nivel, 2 diferență, 4 logaritm, 5 diferența logaritmilor, 6 a doua diferență a logaritmilor
- Octombrie 2025: ancheta în gospodării și IPC din SUA nu au fost colectate (închiderea guvernului federal); luna lipsă izolată este interpolată

Originea shrinkage-ului: Minneapolis



Federal Reserve Bank of Minneapolis, 2010


Foto: Innotata (2010); CC BY-SA 3.0; Wikimedia Commons

- Începutul anilor 1980: Litterman realizează prognoze cu VAR bayesiene la Fed Minneapolis [Litterman \(1986\)](#); distribuția a priori „Minnesota”
 - ▶ Doan, Litterman și Sims (1984): suma coeficienților și proiecții condiționate; Sims (1993), Sims și Zha (1998): observația inițială fictivă
- 1989–2002: indici factoriali dinamici [Stock și Watson \(1989\)](#), factori dinamici generalizați [Forni, Hallin, Lippi și Reichlin \(2000\)](#), indici de difuziune [Stock și Watson \(2002a\)](#)
- 2005–2015: FAVAR [Bernanke, Boivin și Elias \(2005\)](#), nowcasting [Giannone, Reichlin și Small \(2008\)](#), BVAR mari [Bańbura, Giannone și Reichlin \(2010\)](#), distribuții a priori ierarhice [Giannone, Lenza și Primiceri \(2015\)](#)
- O singură idee: când parametrii depășesc observațiile, adăugăm informație (o distribuție a priori) sau reducem dimensiunea (factori)

Numărarea parametrilor

- ▣ VAR(p) cu n variabile: $k = np + 1$ regresori pe ecuație, nk coeficienți și $n(n + 1)/2$ covarianțe
 - ▶ $n = 3, p = 13$: $k = 40$; $n = 20$: $k = 261$; $n = 102$: $k = 1\,327$ pe ecuație
 - ▶ o fereastră de 10 ani are $T = 120$ de luni: cu $k > T$, OLS nu există ($X'X$ este singulară)
- ▣ Chiar cu $k < T$, eroarea de estimare crește cu k/T : MSE la un pas $\approx \sigma^2(1 + k/T)$ pentru o regresie corect specificată
 - ▶ supraajustare: potrivirea în eșantion se îmbunătățește, acuratețea în afara eșantionului se deteriorează
- ▣ Trei remedii: (i) shrinkage (distribuții a priori bayesiene, ridge, LASSO); (ii) reducerea dimensiunii (factori); (iii) selecția variabilelor

Simulare: VAR estimat prin OLS comparat cu un BVAR Minnesota



- Modelul adevărat: VAR(1) staționar $A = 0,5I + (0,3/n)11'$; se estimează un VAR(4), $T = 120$; MSE la un pas al variabilei 1 raportat la modelul adevărat; 200 de replicări

Interpretarea simulării

- OLS: MSE relativ urcă la 6,52 pentru $n = 24$ ($k = 97$ de regresori pentru 116 observații)
- BVAR: 1,25 pentru $n = 24$; gradul de strângere ales prin verosimilitatea marginală scade de la 0,31 ($n = 2$) la 0,14 ($n = 24$)
- Un AR(4) univariat rămîne în jurul valorii 1,08: informația dintre variabile există, dar este mică, iar OLS o irosește pe zgomot
- Cu cît sistemul este mai mare, cu atît distribuția a priori trebuie să fie mai strînsă: tema întregului capitol De Mol, Giannone și Reichlin (2008)

Recapitulare: blestemul dimensionalității

- ▣ Parametrii cresc cu n^2p ; observațiile nu
- ▣ Shrinkage-ul acceptă o deplasare mică în schimbul unei reduceri mari a varianței
- ▣ Factorii rezumă multe serii prin câteva componente comune

Distribuția a priori, verosimilitatea, distribuția a posteriori



Pierre-Simon Laplace, care a dezvoltat
probabilitatea inversă

Portret: Paulin Guérin (1838); domeniu public;
[Wikimedia Commons](#)

- Bayes: $p(\theta | y) = p(y | \theta)p(\theta)/p(y)$, cu $p(y) = \int p(y | \theta)p(\theta) d\theta$
 - ▶ θ : parametrii; y : datele; $p(\theta)$: distribuția **a priori**; $p(y | \theta)$: verosimilitatea; $p(\theta | y)$: distribuția **a posteriori**
 - ▶ $p(y)$: **verosimilitatea marginală**, evidența în favoarea modelului și a distribuției a priori
- Conjugarea: distribuția a priori și cea a posteriori sînt din aceeași familie, deci cea a posteriori are formă închisă
 - ▶ media distribuției Normale cu varianța cunoscută: Normală; coeficienți și varianță în regresie: Normal-inverse-gamma
- Rezumate punctuale: media a posteriori (pierdere pătratică), mediana (pierdere absolută); mulțimi credibile din cuantilele a posteriori

Actualizarea Normală este o medie ponderată cu precizii (1/2)

- Datele: $\hat{\beta} \mid \beta \sim N(\beta, s^2)$ cu $s^2 = \sigma^2 / \sum x_t^2$; distribuția a priori: $\beta \sim N(m_0, v_0)$
 - ▶ $\hat{\beta}$: estimația OLS a pantei β pentru regresorul x_t ; σ^2 : varianța erorii, considerată cunoscută; s^2 : varianța de eșantionare a lui $\hat{\beta}$
 - ▶ m_0, v_0 : media și varianța a priori; precizia = $1/\text{varianța}$
- Completăm pătratul în β : distribuția a posteriori este Normală, $\beta \mid y \sim N(m_1, v_1)$
 - ▶ preciziile se adună: $v_1^{-1} = v_0^{-1} + s^{-2}$
 - ▶ mediile se mediază: $m_1 = w m_0 + (1 - w)\hat{\beta}$, cu ponderea distribuției a priori $w = v_0^{-1} / (v_0^{-1} + s^{-2}) \in (0, 1)$
 - ▶ w este mare când distribuția a priori este strînsă (v_0 mic) sau datele sînt puțin informative (s^2 mare)


Actualizarea Normală este o medie ponderată cu precizii (2/2)

- În forma de regresie:

$$\bar{\beta} = (V_0^{-1} + X'X/\sigma^2)^{-1}(V_0^{-1}m_0 + X'y/\sigma^2)$$

- ▶ y ($T \times 1$), X ($T \times k$): datele; m_0 , V_0 : vectorul mediilor și matricea de covarianță a priori; $\bar{\beta}$: media a posteriori
- ▶ aceeași ponderare: precizia a priori V_0^{-1} plus precizia datelor $X'X/\sigma^2$
- Cu $m_0 = 0$ și $V_0 = \tau^2 I$ aceasta este regresia ridge cu penalizarea σ^2/τ^2
 - ▶ τ^2 : varianța a priori a fiecărui coeficient; un τ^2 mic strânge mai mult spre 0
- Când $T \rightarrow \infty$, $X'X$ crește și ponderea distribuției a priori $w \rightarrow 0$: distribuția a priori contează în eșantioane mici și în modele mari
- Seminarul 5, A1: actualizarea de mînă și alegerea bayesiană empirică a lui τ^2

Actualizarea unui coeficient AR(1)



- Rata șomajului din SUA, lunar, ferestre care se încheie în decembrie 2019; distribuția a priori $N(1, 0.2^2)$ (mers aleator), σ^2 la estimația OLS

Interpretarea actualizării

- ▣ $T = 24$: OLS 0,763 (SE 0,119), media a posteriori 0,825 (abaterea standard 0,102); distribuția a priori are ponderea 26,0%
- ▣ $T = 240$: OLS 0,997, a posteriori 0,997; ponderea distribuției a priori scade la 0,1%
- ▣ Într-un VAR, fiecare ecuație are sute de coeficienți, dar același T : distribuția a priori păstrează ponderea pe care o are aici la $T = 24$

Verosimilitatea marginală și factorii Bayes

- $p(y | M) = \int p(y | \theta, M)p(\theta | M) d\theta$: densitatea datelor *înainte* de a le vedea
 - ▶ M : un model, adică o verosimilitate împreună cu distribuția ei a priori; integrala mediază verosimilitatea după distribuția a priori
 - ▶ descompunerea erorilor de predicție: $\ln p(y) = \sum_t \ln p(y_t | y_{1:t-1})$, o sumă de scoruri logaritmice la un pas ([Capitolul 1](#)); $y_{1:t-1}$: datele până la $t - 1$
 - ▶ penalizează automat complexitatea: o distribuție a priori difuză împrăștie probabilitatea pe date care nu apar
- Factorul Bayes $B_{12} = p(y | M_1)/p(y | M_2)$; $2 \ln B_{12} > 6$ este o evidență „puternică” [Kass și Raftery \(1995\)](#)
 - ▶ este sensibil la distribuția a priori: cu o distribuție a priori improprie nu este definit
- Folosirea ierarhică: tratăm hiperparametrii γ ai distribuției a priori ca parametri și maximizăm $p(y | \gamma)$ (Bayes empiric) sau le dăm o distribuție a priori [Giannone, Lenza și Primiceri \(2015\)](#)

Eșantionarea Gibbs (1/2)

- Când distribuția a posteriori comună nu are formă închisă, dar fiecare **distribuție condiționată completă** are:
extragem $\theta_1 \mid \theta_2, y$, apoi $\theta_2 \mid \theta_1, y$ și repetăm [Geman și Geman \(1984\)](#), [Gelfand și Smith \(1990\)](#)
 - ▶ θ_1, θ_2 : două blocuri de parametri; distribuția condiționată completă: distribuția unui bloc dat fiind celălalt și datele
 - ▶ extragerile formează un lanț Markov a cărui distribuție staționară este cea a posteriori
 - ▶ eliminăm o perioadă inițială (burn-in), apoi mediem funcții ale extragerilor (teorema ergodică)
- În VAR: volatilitatea stochastică, distribuțiile a priori neconjugate și SVAR identificate pe mulțimi ([Capitolul 3](#))
cer pași Gibbs sau Metropolis–Hastings


Eșantionarea Gibbs (2/2): regresia liniară

- ▣ Regresia $y = X\beta + e$ cu distribuții a priori independente $\beta \sim N(b_0, V_0)$, $\sigma^2 \sim IG(a_0, d_0)$
 - ▶ b_0, V_0 : media și covarianța a priori ale lui β ; $IG(a_0, d_0)$: distribuția inverse gamma cu parametrul de formă a_0 și de scală d_0
- ▣ Pasul 1, coeficienții dată fiind varianța: $\beta \mid \sigma^2, y \sim N(\bar{b}, \bar{V})$
 - ▶ $\bar{V} = (V_0^{-1} + X'X/\sigma^2)^{-1}$, $\bar{b} = \bar{V}(V_0^{-1}b_0 + X'y/\sigma^2)$: actualizarea Normală de pe slide-urile anterioare
- ▣ Pasul 2, varianța dată fiind coeficienții: $\sigma^2 \mid \beta, y \sim IG(a_0 + T/2, d_0 + e'e/2)$
 - ▶ $e = y - X\beta$: reziduurile la extragerea curentă a lui β ; datele adaugă $T/2$ la parametrul de formă și jumătate din suma pătratelor reziduurilor la scală

Diagnosticarea MCMC

- ▣ **Mărima efectivă a eșantionului:** $ESS = M / (1 + 2 \sum_{k \geq 1} \rho_k)$: numărul de extrageri independente cu aceeași precizie
 - ▶ M : numărul de extrageri păstrate; ρ_k : autocorelația extragerilor la lagul k
 - ▶ lanț de tip AR(1): $ESS = M(1 - \rho)/(1 + \rho)$; $\rho = 0,9$ păstrează aproximativ 5% din extrageri
- ▣ $\hat{R}$ **Gelman și Rubin (1992)**: mai multe lanțuri din puncte de pornire dispersate; $\hat{R} = \sqrt{\hat{V}/W}$,
 $\hat{V} = \frac{n-1}{n} W + B/n$
 - ▶ n : numărul de extrageri pe lanț; W : varianța în interiorul lanțurilor; B : $n \times$ varianța mediilor lanțurilor; $\hat{V}$: estimăția comună a varianței
 - ▶ $\hat{R} \approx 1$: lanțurile sînt de acord; practica actuală: $\hat{R}$ cu ranguri normalizate și lanțuri divizate $< 1,01$ **Vehtari et al. (2021)**
- ▣ Statistica z **Geweke**: compară media primelor 10% și a ultimelor 50% din lanț, cu varianțe spectrale; $|z| > 2$ semnalează lipsa convergenței
- ▣ Niciuna nu demonstrează convergența; fiecare poate dezvălui un eșec

Eșantionarea Gibbs: o parametrizare ineficientă și una eficientă



- Creșterea lunară a IP din SUA pe gradul de utilizare a capacităților cu lag (media 79,0%, abaterea standard 4,7), 1967–2019, $T = 635$; Gibbs pe câte un parametru, patru lanțuri, 4 000 de extrageri, burn-in 1 000

Interpretarea celor două eșantionatoare

- ▣ Regresorul brut: corelația a posteriori dintre termenul liber și pantă este $-0,998$, deci fiecare pas condiționat se mișcă foarte puțin
 - ▶ autocorelația de ordinul 1 $0,992$; $ESS = 53$ din $12\,000$ de extrageri; $\hat{R} = 1,32$; z Geweke $= -2,27$
- ▣ Regresorul centrat: corelația $-0,001$, $ESS = 11\,529$, $\hat{R} = 1,00$, z Geweke $= 0,01$
 - ▶ același model, aceeași distribuție a posteriori a pantei (media $0,0123$); s-a schimbat doar eșantionatorul
- ▣ Lecția: reparametrizați sau extrageți împreună blocurile corelate; BVAR-urile conjugate evită problema extrăgând B într-un singur bloc

Recapitulare: inferența bayesiană

- ▣ Precizia a posteriori = precizia a priori + precizia datelor; media este o medie ponderată
- ▣ Verosimilitatea marginală evaluează un model împreună cu distribuția lui a priori și poate alege hiperparametri
- ▣ Eșantionarea Gibbs cere distribuțiile condiționate complete; verificați ESS, $\hat{R}$ și Geweke înainte de a avea încredere în extrageri

Distribuția a priori Minnesota

- VAR(p): $y_t = c + A_1 y_{t-1} + \dots + A_p y_{t-p} + u_t$; $(A_l)_{ij}$: efectul variabilei j cu lagul l asupra variabilei i
 - ▶ mediile a priori [Litterman \(1986\)](#): $\mathbb{E}[(A_1)_{ij}] = \delta_i$, toți ceilalți coeficienți 0; $\delta_i = 1$ (mers aleator) pentru serii persistente, 0 (zgomot alb) în rest
 - ▶ varianțele a priori [Bańbura, Giannone și Reichlin \(2010\)](#), ec. (2): $\text{Var}[(A_l)_{ij}] = \lambda^2/l^2$ dacă $j = i$, $\vartheta \lambda^2 \sigma_i^2 / (l^2 \sigma_j^2)$ dacă $j \neq i$
- Hiperparametri: λ gradul general de strângere, $1/l^2$ descreșterea cu lagul, $\vartheta \in (0, 1]$ shrinkage-ul între variabile
 - ▶ σ_i^2 : varianța reziduală a unui AR univariat pentru y_i , astfel încât σ_i^2/σ_j^2 fixează unitățile de măsură
 - ▶ $\lambda = 0$: a posteriori = a priori; $\lambda \rightarrow \infty$: media a posteriori = OLS
- Versiunea originală: Σ diagonală și fixă, fiecare ecuație o regresie separată de tip ridge, cu termen liber difuz

Distribuția a priori natural conjugată (1/2)

- ▣ VAR-ul ca regresie multivariată $Y = XB + U$, liniile lui U i.i.d. $N(0, \Sigma)$
 - ▶ $Y (T \times n)$: observațiile; $X (T \times k)$: constanta și cele p laguri; $B (k \times n)$: coeficienții, câte o coloană pentru fiecare ecuație
- ▣ Distribuția a priori [Kadiyala și Karlsson \(1997\)](#): $\text{vec}(B) \mid \Sigma \sim N(\text{vec}(B_0), \Sigma \otimes \Omega_0)$, $\Sigma \sim IW(\Psi, d)$
 - ▶ vec : așază coloanele una sub alta; $\otimes$: produsul Kronecker; B_0 : media a priori; $\Omega_0 (k \times k)$: covarianța a priori între regresori
 - ▶ $IW(\Psi, d)$: distribuția inverse Wishart cu matricea de scală Ψ și d grade de libertate
- ▣ Distribuția a posteriori: aceleași familii, cu parametri actualizați
 - ▶ $\bar{\Omega}^{-1} = \Omega_0^{-1} + X'X$, $\bar{B} = \bar{\Omega}(\Omega_0^{-1}B_0 + X'Y)$: din nou media ponderată cu precizii
 - ▶ $\Sigma \mid Y \sim IW(\bar{\Psi}, T + d)$, $\bar{\Psi} = \Psi + \hat{U}'\hat{U} + (\bar{B} - B_0)'\Omega_0^{-1}(\bar{B} - B_0)$, $\hat{U} = Y - X\bar{B}$


Distribuția a priori natural conjugată (2/2)

- ▣ Prețul conjugării: structura Kronecker dă fiecărei ecuații același Ω_0 , deci $\vartheta = 1$
 - ▶ momentele Minnesota cu $\Omega_0 = \text{diag}(\lambda^2/(l^2\sigma_j^2))$ și $\mathbb{E}\Sigma = \text{diag}(\sigma_j^2)$ ($d = n + 2$, $\Psi = \text{diag}(\sigma_j^2)$)
- ▣ Câștigul: o singură inversare $k \times k$ pentru toate ecuațiile; extrageri exacte fără MCMC; verosimilitatea marginală în formă închisă (▶ anexă)

Observații fictive

- ▣ Estimarea mixtă Theil: adăugăm T_d linii artificiale (Y_d, X_d) și aplicăm OLS pe $\begin{pmatrix} Y_d \\ Y \end{pmatrix}$, $\begin{pmatrix} X_d \\ X \end{pmatrix}$; fiecare linie exprimă o convingere a priori ca și cum ar fi date
 - ▶ echivalent cu distribuția a priori NIW cu $B_0 = (X_d' X_d)^{-1} X_d' Y_d$, $\Omega_0 = (X_d' X_d)^{-1}$ Bańbura, Giannone și Reichlin (2010), ec. (5)
 - ▶ blocul Minnesota: $Y_d = \text{diag}(\delta_i \sigma_i) / \lambda$, $X_d = J_p \otimes \text{diag}(\sigma_i) / \lambda$, $J_p = \text{diag}(1, \dots, p)$
- ▣ **Suma coeficienților** Doan, Litterman și Sims (1984): $Y_d = \text{diag}(\bar{y}_i) / \mu$, $X_d = (1_p' \otimes \text{diag}(\bar{y}_i) / \mu, 0)$
 - ▶ $\bar{y}_i$: media primelor p observații ale lui y_i ; 1_p : un vector de p unități; $\mu > 0$: gradul de strângere al acestei distribuții
 - ▶ strînge $\Pi = I - \sum_l A_l$ spre 0 („diferențiere inexactă”): $\mu \rightarrow 0$ dă un VAR în diferențe, fără cointegrare
- ▣ **Observația inițială fictivă** Sims (1993), Sims și Zha (1998): o linie $y = \bar{y}' / \phi$, $x = (\bar{y}' / \phi, \dots, \bar{y}' / \phi, 1 / \phi)$
 - ▶ $\bar{y}$: vectorul valorilor $\bar{y}_i$; $\phi > 0$: gradul de strângere; împinge spre rădăcini unitare sau spre un model staționar cu media $\bar{y}$: permite cointegrarea (Capitolul 4)

Cît shrinkage? Potrivirea în eșantion comparată cu acuratețea în afara eșantionului



- Sistemul MEDIUM (20 de variabile, $p = 13$, $k = 261$), distribuția a priori BGR, ferestre mobile de 10 ani; în afara eșantionului: MSFE la un pas pentru ocupare, IPC și dobînda federal funds, 1971–2003, relativ la mersul aleator

Interpretarea compromisului

- Potrivirea în eșantion se îmbunătățește fără limită când λ crește: cu $k = 261$ și $T = 120$, o distribuție a priori largă interpolează datele
- În afara eșantionului: formă de U; minimul 0,66 la $\lambda = 0,10$; 0,93 cu $\lambda = 0,005$ (aproape mersul aleator); 1,87 cu $\lambda = 20$
- Shrinkage-ul trebuie ales fără a privi eșantionul de evaluare: printr-o regulă de potrivire (BGR) sau prin verosimilitatea marginală (GLP)


Recapitulare: distribuțiile a priori Minnesota și NIW

- Minnesota: centrăm fiecare ecuație pe un mers aleator sau pe zgomot alb; strângem mai mult lagurile îndepărtate și celelalte variabile
- Forma natural conjugată păstrează formulele închise cu prețul $\vartheta = 1$
- Observațiile fictive implementează distribuția a priori prin OLS și adaugă convingeri despre suma coeficienților și observația inițială

Giannone, Lenza și Primiceri (2015)

- ▣ Tratăm $\gamma = (\lambda, \mu, \phi)$ ca parametri cu distribuții a priori proprii: $p(\gamma | y) \propto p(y | \gamma)p(\gamma)$ Giannone, Lenza și Primiceri (2015)
 - ▶ $p(y | \gamma)$ este cunoscută în formă închisă pentru distribuția NIW cu observații fictive: datele plus observațiile fictive, minus observațiile fictive singure
 - ▶ distribuții a priori pentru hiperparametri: Gamma cu modul 0,2 și abaterea standard 0,4 pentru λ , modul 1 și abaterea standard 1 pentru μ și ϕ
- ▣ Interpretare: verosimilitatea marginală este un scor în afara eșantionului al densităților predictive la un pas (secțiunea anterioară)
 - ▶ deci echilibrează potrivirea și complexitatea fără un eșantion de evaluare
- ▣ Folosim modul a posteriori al lui γ (ca aici) sau integrăm γ prin Metropolis–Hastings; GLP constată că ambele prognozează cam la fel de bine ca modelele factoriale

Verosimilitatea marginală în funcție de gradul de strângere



- SMALL ($n = 3$), MEDIUM ($n = 20$), LARGE ($n = 102$), $p = 13$, 1960:1–2019:12 ($T = 707$); $\mu = \phi = 1$; log ML minus maximul, împărțit la nT

Interpretarea verosimilității marginale

- ▣ Gradul optim de strângere: 0,382 (SMALL), 0,146 (MEDIUM), 0,133 (LARGE): sistemele mai mari cer o distribuție a priori mai strânsă
- ▣ Valoarea din manuale $\lambda = 0,2$ costă $-46,9$ puncte logaritmice pentru MEDIUM și $-597,2$ pentru LARGE; $\lambda = 1$ costă $-15571,6$ pentru LARGE
- ▣ Modul comun cu distribuțiile hiperparametrilor: SMALL $\mu = 0,20$, $\phi = 0,44$; MEDIUM $\mu = 0,13$, $\phi = 0,44$: datele cer distribuții strânse pentru suma coeficienților și observația inițială

Două reguli pentru un singur hiperparametru

- **Regula potrivirii BGR:** alegem λ astfel încât potrivirea în eșantion la un pas a variabilelor-cheie să fie egală cu cea a unui VAR mic estimat prin OLS [Bańbura, Giannone și Reichlin \(2010\)](#), secțiunea 3
 - ▶ $\text{Fit}(\lambda) = \frac{1}{3} \sum_{i \in I} \text{msfe}_i^{(\lambda)} / \text{msfe}_i^{(0)}$ pe 1960–1969; aici ținta este 0,43
 - ▶ I : cele trei variabile-cheie; $\text{msfe}_i^{(\lambda)}$: eroarea pătratică medie la un pas, în eșantion, a variabilei i cu gradul de strângere λ ; $\lambda = 0$: doar media a priori
 - ▶ valorile noastre: MEDIUM 0,158, LARGE 0,059 (BGR, tabelul 1: 0,108 și 0,035 pe setul lor de date)
- **Verosimilitatea marginală GLP:** reestimată pe fiecare fereastră; pe ferestre de 10 ani modul median este 0,34 (SMALL) și 0,28 (MEDIUM)
 - ▶ intervalul 10%–90% al modului MEDIUM între ferestre: [0,23; 0,33]
- Pachetul Python `bvar` al Băncii Angliei implementează optimizarea GLP pentru modelul conjugat; notebook-ul îl compară cu codul nostru `numpy`


Recapitulare: distribuții a priori ierarhice

- ▣ Verosimilitatea marginală alege shrinkage-ul; acesta scade când sistemul crește
- ▣ Distribuțiile pentru suma coeficienților și observația inițială se aleg la fel
- ▣ O regulă de potrivire este o alternativă transparentă atunci când evaluarea trebuie să reproducă un studiu publicat

Bańbura, Giannone și Reichlin (2010): designul

- Bańbura, Giannone și Reichlin (2010): poate un VAR cu 131 de variabile să prognozeze și să identifice șocuri? Sistemele SMALL (ocupare, IPC, dobînda federal funds), MEDIUM (20), LARGE (toate)
 - ▶ $p = 13$; ferestre mobile de 10 ani; prognoze punctuale din media a posteriori, iterate pînă la $h = 12$; reper: mers aleator cu derivă
 - ▶ distribuția a priori NIW Minnesota plus suma coeficienților cu $\tau = 10\lambda$ (secțiunea 3.3); λ prin regula potrivirii pe 1960–1969
- Datele noastre: panelul în format FRED-MD; LARGE = cele 102 serii observate pe 1960–2026 (agregate și componente)
 - ▶ MEDIUM: lista BGR, cu S&P 500, cursul de schimb efectiv și rezervele neîmprumutate înlocuite de randamentul Baa, dobînda la 3 luni și autorizațiile de construcție (indisponibile pentru 1960–2026 sau negative după 2008)
- Evaluarea: ținte 1971–2003 (lucrarea), 2004–2019 și 2004–2026 (extinderi); 678 de origini ale prognozelor; adăugăm GLP SMALL și MEDIUM

Acuratețea prognozelor, 1971–2003



- MSFE relativ la mersul aleator cu derivă (scară logaritmică; sub 1 = mai bine), ocuparea și IPC în $100 \times$ logaritmul nivelului, dobînda în procente

ATS_ch5_large_bvar

Interpretarea comparației prognozelor

- ▣ $h = 1$, ocuparea: OLS SMALL 1,06, BGR MEDIUM 0,54, LARGE 0,50 (BGR, tabelul 1: 1,14; 0,54; 0,46)
 - ▶ IPC: 0,78; 0,51; 0,48; dobînda federal funds: 1,65; 0,74; 0,78
- ▣ Adăugarea de variabile cu mai mult shrinkage ajută: LARGE este superior lui SMALL pentru fiecare variabilă la $h \leq 6$
- ▣ GLP SMALL este aproape la fel de bun ca sistemele mari pentru ocupare și IPC (0,57; 0,50): mare parte din câștig vine din distribuția a priori, nu doar din variabile
- ▣ Dobînda federal funds după 3 luni este dificilă pentru toate modelele (LARGE 1,20 la $h = 12$)

După 2003: extinderea și martie 2020


Modelul	EMPL, 1	EMPL, 12	CPI, 1	CPI, 12	FFR, 1	FFR, 12
OLS SMALL	0,38	1,08	1,26	2,43	0,98	3,51
BGR MEDIUM	0,20	0,66	0,97	6,49	0,55	1,91
BGR LARGE	0,19	0,67	0,92	3,73	0,45	1,79
GLP SMALL	0,24	0,33	0,93	1,07	0,61	0,67
GLP MEDIUM	0,20	0,28	0,95	2,55	0,57	0,91

- Ținte 2004:1–2019:12, MSFE relativ (mersul aleator cu derivă = 1)
- Incluzînd 2020–2026, MSFE la 12 luni pentru ocupare explodează: BGR MEDIUM 500,06, GLP SMALL 8,64: ferestrele care conțin aprilie 2020 tratează prăbușirea ca dinamică
- Remediul: scalăm varianța reziduală a lunilor pandemiei cu factori estimați [Lenza și Primiceri \(2022\)](#) sau folosim volatilitatea stochastică (secțiunea următoare)

Un șoc de politică monetară într-un VAR mare

- Schema recursivă din [Bańbura, Giannone și Reichlin \(2010\)](#), secțiunea 4: $y_t = (X_t, r_t, Z_t)$, variabile lente X_t (activitate reală, prețuri), dobînda r_t , variabile rapide Z_t (monedă, dobînzii, cursuri de schimb)
 - ▶ contează doar poziția lui r_t ([Capitolul 3](#)): nu este nevoie de nicio ordonare în interiorul blocurilor
- Benzi bayesiene: pentru fiecare extragere (B, Σ) din distribuția a posteriori NIW calculăm coloana de impact Cholesky și răspunsurile; raportăm cuantilele a posteriori
 - ▶ 500 de extrageri, șoc de 100 bp, eșantion 1961–2002, $p = 13$; SMALL cu o distribuție a priori aproape plată
- Acestea sînt benzile a posteriori anunțate în [Capitolul 3](#): intervale credibile punctuale, condiționate de ipoteza de identificare

Răspunsuri la un șoc de 100 bp al dobânzii federal funds



- Mediane a posteriori cu benzi de 68% și 90%; liniile: SMALL, MEDIUM, LARGE; ocuparea și IPC în procente

Q-ATS_ch5_large_bvar

Interpretarea răspunsurilor

- ▣ Ocuparea: minimum $-0,49\%$ (SMALL, luna 28), $-0,39\%$ (LARGE, luna 23); după patru ani LARGE revine la $-0,11\%$ (banda $[-0,39; 0,15]$)
- ▣ IPC: anomalia prețurilor scade de la $0,26\%$ (SMALL) la $0,13\%$ (LARGE); după patru ani LARGE dă $-0,43\%$ (banda $[-0,97; 0,11]$)
- ▣ Ca în BGR: mai multă informație face răspunsul ocupării mai puțin persistent și răspunsul prețurilor mai plauzibil
- ▣ Benzile nu se largesc cu 102 variabile: distribuția a priori compensează coeficienții suplimentari


Recapitulare: modele BVAR mari

- Cu un shrinkage care crește odată cu sistemul, un VAR cu 102 variabile prognozează mai bine decât un VAR cu 3 variabile estimat prin OLS
- Rezultatele BGR pentru 1971–2003 se replică pe datele actuale; după 2020 BVAR-ul homoscedastic eșuează
- Seturile mari de informații reduc anomalia prețurilor din VAR-urile monetare mici

Modele BVAR mari cu volatilitate stochastică

- **Volatilitate comună** [Carriero, Clark și Marcellino \(2016\)](#): $u_t = \sqrt{f_t} \varepsilon_t$, $\varepsilon_t \sim N(0, \Sigma)$, $\ln f_t = \phi \ln f_{t-1} + \nu_t$
 - ▶ u_t : reziduul VAR; $f_t > 0$: un factor de volatilitate comun tuturor ecuațiilor; ϕ : persistența lui; ν_t : șocul lui
 - ▶ dat fiind $f_{1:T}$, modelul este un BVAR conjugat ponderat (liniile împărțite la $\sqrt{f_t}$); f_t se extrage cu un pas Kim–Shephard–Chib
- **Volatilități specifice fiecărei variabile** [Carriero, Clark și Marcellino \(2019\)](#), [Clark \(2011\)](#): $\Sigma_t = A^{-1} H_t A^{-1'}$, H_t diagonală cu volatilități log-AR [Primiceri \(2005\)](#)
 - ▶ A : inferior triunghiulară cu diagonala unu (relațiile contemporane); H_t : varianțele variabile în timp ale șocurilor ortogonalizate
 - ▶ conjugarea se pierde; algoritmul triunghiular extrage ecuațiile una câte una și face posibil $n = 100$
- Cîștigurile: mai ales în prognozele de densitate (intervale calibrate) și în robustețea la valori extreme precum 2020

Un factor comun de volatilitate în reziduurile BVAR



□ BVAR MEDIUM (hiperparametri GLP), 1960–2026: logaritmul mediei transversale a pătratelor reziduurilor standardizate

ATS_ch5_large_bvar

Interpretarea indicatorului de volatilitate

- Mișcări comune: varianța reziduală crește în fiecare recesiune și scade în Marea Moderație (1960–1984 este de 1,28 ori 1985–2007)
- Aprilie 2020 este de 176 ori luna mediană: un BVAR gaussian homoscedastic o tratează ca pe o observație obișnuită
- Acesta este argumentul pentru modelul cu volatilitate comună (o singură stare în plus) înaintea modelului complet cu volatilități specifice; [Capitolul 6](#) dă instrumentele de filtrare

Modelul factorial aproximativ

- $x_{it} = \lambda_i' F_t + e_{it}$, $i = 1, \dots, N$, $t = 1, \dots, T$; F_t : r factori comuni, λ_i : ponderi factoriale (loadings), e_{it} : componente idiosincratice
 - ▶ *aproximativ* Chamberlain și Rothschild (1983): e_{it} pot fi slab corelate între i și în timp, cu condiția ca acea corelație să rămână mărginită când $N \rightarrow \infty$
 - ▶ $\Lambda (N \times r)$: ponderile factoriale așezate pe linii; $X (T \times N)$: panelul; Σ_Λ : o limită pozitiv definită
 - ▶ caracterul general (pervasiveness): $\Lambda' \Lambda / N \rightarrow \Sigma_\Lambda > 0$, fiecare factor afectează multe serii; cele mai mari r valori proprii ale lui XX' cresc cu N , celelalte nu
- Identificarea: $\Lambda F_t = (\Lambda H)(H^{-1} F_t)$ pentru orice H inversabilă: este identificat doar spațiul factorilor
 - ▶ normalizarea pentru PCA: $F' F / T = I_r$ și $\Lambda' \Lambda$ diagonală
- Forma statică a unui model dinamic: lagurile factorilor dinamici sînt așezate în F_t Stock și Watson (2016); modelul dinamic generalizat lucrează în domeniul frecvențelor Forni, Hallin, Lippi și Reichlin (2000)


Componente principale

- Cele mai mici pătrate: $\min_{F, \Lambda} \sum_{i,t} (x_{it} - \lambda'_i F_t)^2$ cu $F'F/T = I$: $\hat{F} = \sqrt{T} \times$ primii r vectori proprii ai lui XX' , $\hat{\Lambda} = X'\hat{F}/T$
 - standardizați întâi fiecare serie: PCA nu este invariantă la scară
- Consistența [Stock și Watson \(2002a\)](#), [Bai \(2003\)](#): $\hat{F}_t \rightarrow HF_t$ când $N, T \rightarrow \infty$, cu viteza $\min(\sqrt{N}, \sqrt{T})$
 - H : o rotație inversabilă de $r \times r$; PCA recuperează factorii pînă la această rotație
 - dacă $\sqrt{T}/N \rightarrow 0$, factorii estimați pot fi folosiți ca regresori ca și cum ar fi observați (fără corecția pentru regresori generați)
- Valori lipsă și date de început diferite: EM [Stock și Watson \(2002b\)](#), [McCracken și Ng \(2016\)](#): completăm cu 0, aplicăm PCA, recompleteăm celulele lipsă cu $\hat{\lambda}'_i \hat{F}_t$, iterăm

Baza de date FRED-MD

- ▣ [McCracken și Ng \(2016\)](#): aproximativ 130 de serii lunare SUA începînd din 1959, actualizate lunar, cu un cod de transformare pentru fiecare serie și cu ediții pentru analize în timp real
 - ▶ opt grupe: producție și venit, piața muncii, locuințe, consum și comenzi, monedă și credit, dobînzii și cursuri de schimb, prețuri, piața de acțiuni
 - ▶ valori extreme: o observație aflată la mai mult de 10 abateri intercuartilice de mediană devine lipsă (3 celule aici)
- ▣ Panelul nostru: 117 serii FRED-MD distribuite de FRED (seriile bursiere nu sînt), 1960:1–2026:7, 4,5% celule lipsă
 - ▶ fișierul oficial (`current.csv` al St. Louis Fed) îl poate înlocui în notebook printr-o singură linie
- ▣ Doar ediția curentă: rezultatele sînt pseudo în afara eșantionului, nu în timp real [Croushore și Stark \(2001\)](#)

Factorii panelului FRED-MD



- Stînga: ponderea varianței panelului standardizat explicată de fiecare componentă principală; dreapta: primul factor (EM, 8 factori), recesiunile NBER marcate


Interpretarea factorilor

- Prima componentă explică 17,6%, a doua 7,9%; cinci explică 44,2%, opt 54,2%
- Primul factor este un indice al activității reale: corelația $-0,58$ cu indicatorul recesiunilor NBER; minimul este în aprilie 2020
- Nicio componentă nu domină: panelurile macro au câțiva factori puternici și o coadă lungă de factori slabi, ceea ce face din numărul de factori o întrebare reală

Cîți factori? Bai și Ng (2002)

- $V(k) = (NT)^{-1} \sum_{i,t} (x_{it} - \hat{\lambda}_i' \hat{F}_t)^2$ după k componente; scade cu k , deci are nevoie de o penalizare Bai și Ng (2002)
 - ▶ $IC_{p1}(k) = \ln V(k) + k \frac{N+T}{NT} \ln \frac{NT}{N+T}$, $IC_{p2}(k) = \ln V(k) + k \frac{N+T}{NT} \ln C_{NT}^2$, $C_{NT}^2 = \min(N, T)$
 - ▶ $IC_{p3}(k) = \ln V(k) + k \ln C_{NT}^2 / C_{NT}^2$; alegem k care minimizează criteriul; penalizarea crește cu k și dispare cînd $N, T \rightarrow \infty$
 - ▶ variantele PC_p : $V(k) + k \hat{\sigma}^2 g(N, T)$ cu $\hat{\sigma}^2 = V(k_{\max})$, $g(N, T)$ aceleași penalizări: depind de $k_{\max}$, cel mai mare k încercat
- Panelul nostru ($k_{\max} = 15$): $IC_{p1} = 8$, $IC_{p2} = 8$, $IC_{p3} = 10$, $PC_{p1} = 13$, $PC_{p2} = 11$
 - ▶ criteriile nu sînt de acord atunci cînd valorile proprii scad lent; raportați alegerea și sensibilitatea ei
- Pentru prognoză, numărul de factori din regresie se alege separat (prin BIC), ca în prognozele cu indici de difuziune

Conținutul economic al factorilor



□ R^2 marginal mediu al regresiei fiecărei serii standardizate pe un singur factor, pe grupe (ca în McCracken și Ng 2016)


Interpretarea R^2 marginal

- Factorul 1 este activitatea reală: R^2 0,43 pentru producție, 0,24 pentru muncă; cea mai bine explicată serie are 0,78
- Factorii 2 și 3 se încarcă pe prețuri (0,22; 0,19) și pe locuințe (0,16; 0,12)
- Dobânzile se încarcă slab pe primii trei factori: informația monetară se află în factori ulteriori sau în dobânzile înseși, motivația pentru FAVAR
- Etichetele sînt o alegere de rotație: este identificat spațiul factorilor, nu fiecare factor

Prognoze cu indici de difuziune: Stock și Watson (2002)

- **Stock și Watson (2002b):** $y_{t+h}^h = \alpha_h + \beta_h' \hat{F}_t + \sum_{j=0}^p \gamma_{hj} z_{t-j} + \varepsilon_{t+h}$ (prognoză directă, o ecuație pentru fiecare h)
 - ▶ y_{t+h}^h : ținta pe următoarele h luni, anualizată; $\hat{F}_t$: factorii estimați; z_t : creșterea curentă a țintei; $\alpha_h, \beta_h, \gamma_{hj}$: coeficienți estimați prin OLS pentru fiecare h
 - ▶ serii reale: $y_{t+h}^h = \frac{1200}{h} \ln(Y_{t+h}/Y_t)$; prețuri: $\frac{1200}{h} \ln(P_{t+h}/P_t) - 1200 \ln(P_t/P_{t-1})$ (Y_t, P_t : nivelurile)
 - ▶ DI: doar factori, $k \in \{1, \dots, 12\}$ prin BIC; DI-AR, Lag: factori și $p \in \{0, \dots, 5\}$ laguri prin BIC; reperul: AR cu laguri alese prin BIC
- Recursiv: factorii sînt reestimați la fiecare origine prin EM pe datele disponibile atunci; originile încep în 1970:1
 - ▶ evaluarea 1970–1998 (lucrarea) și 1999–2019 (extindere), după originea prognozei
- Variabilele-țintă: producția industrială, numărul de salariați, inflația IPC; $h = 1, 6, 12$ luni

Proгноze cu indici de difuziune comparate cu un AR



□ MSE relativ la prognoza AR cu laguri alese prin BIC (sub 1 = mai bine)

Interpretarea indicilor de difuziune

- ▣ 1970–1998: câștiguri mari pentru activitatea reală la $h = 12$: IP 0,58, ocupare 0,62; pentru inflație doar cu lagurile proprii (DI-AR, Lag 0,68)
- ▣ 1999–2019: câștigurile dispar (IP 1,07, ocupare 1,09, inflație 1,35): Marea Moderație a făcut activitatea mai puțin previzibilă din panel
- ▣ BIC alege în mediană 7 factori (10%–90%: 5–12) pentru DI-AR, Lag la $h = 12$
- ▣ Shrinkage-ul bayesian și componentele principale dau prognoze puternic corelate în panelurile mari De Mol, Giannone și Reichlin (2008): două căi pentru aceeași informație

Recapitulare: modele factoriale

- ▣ Cîțiva factori rezumă o sută de serii; PCA estimează consistent spațiul factorilor cînd $N, T \rightarrow \infty$
- ▣ Criteriile Bai–Ng aleg numărul de factori; verificați sensibilitatea lor
- ▣ Indicii de difuziune au ajutat mult înainte de 1999 și mult mai puțin după: evaluați pe mai multe perioade

FAVAR: Bernanke, Boivin și Eliaz (2005)




Ben Bernanke, 2008

Foto: Federal Reserve (2008); domeniu
public; Wikimedia Commons

- Bernanke, Boivin și Eliaz (2005): $\begin{pmatrix} F_t \\ Y_t \end{pmatrix} = \Phi(L) \begin{pmatrix} F_{t-1} \\ Y_{t-1} \end{pmatrix} + v_t$, $X_t = \Lambda^F F_t + \Lambda^Y Y_t + e_t$,
 Y_t = dobînda federal funds
 - ▶ F_t : K factori neobservați; X_t : panelul mare; Λ^F , Λ^Y : ponderile factoriale; $\Phi(L)$: un polinom în operatorul lag; v_t , e_t : erorile
 - ▶ VAR-ul vede informația a 100 de serii prin K factori; răspunsurile sînt disponibile pentru fiecare serie din X_t
- Estimarea în doi pași (secțiunea III): componentele principale $\hat{C}_t$ ale lui X_t ; factorii lenți din seriile lente; eliminăm Y_t : $\hat{F}_t = \hat{C}_t - \hat{b}_Y Y_t$
 - ▶ $K = 3$, VAR(13), 1960:1–2001:8 (la noi: $T = 500$, $N = 102$ serii complete, 76 lente); Cholesky cu Y_t ultimul; șoc de 25 bp
- Prețurile și masa monetară intră ca rate lunare de creștere; răspunsurile se cumulează în niveluri

Răspunsurile FAVAR la un șoc de politică monetară de 25 bp



- Niveluri în procente (dobânzi și șomaj în pp); benzi bootstrap pe reziduuri de 90%, factorii tratați ca date; linia întreruptă: eșantion pînă în 2007:12

Interpretarea FAVAR

- ▣ Activitatea reală scade cu întârziere: IP minim $-0,35\%$ după 13 luni, gradul de utilizare a capacităților $-0,28$ pp, numărul de salariați $-0,12\%$, șomajul crește cu $0,061$ pp
- ▣ Locuințele începute reacționează primele și cel mai puternic ($-1,18\%$ după 9 luni): sectorul sensibil la dobândă
- ▣ Anomalia prețurilor este mică (cel mult $0,046\%$, luna 8); IPC ajunge la $-0,14\%$ după 48 de luni (banda $[-0,32; 0,03]$); până în 2007: $-0,19\%$
- ▣ Seminarul 5, B4: cu $K = 1$ sau $K = 5$ anomalia revine; alegerea lui K este o ipoteză de identificare, nu un detaliu

Modelul factorial dinamic

- Ecuația de măsurare: $x_t = \Lambda f_t + e_t$, $e_t \sim N(0, \Psi)$, Ψ diagonală; ecuația de tranziție:
 $f_t = A_1 f_{t-1} + \dots + A_q f_{t-q} + u_t$, $u_t \sim N(0, Q)$
 - ▶ x_t : cele N serii observate; f_t : cei r factori; Λ : ponderile factoriale; e_t : erorile idiosincratice, cu covarianța diagonală Ψ ; A_j : matricele VAR(q) ale factorilor; Q : covarianța șocurilor factorilor u_t
 - ▶ un model în spațiul stărilor (TSA, Capitolul 10; Capitolul 6): starea $s_t = (f_t', \dots, f_{t-m}')'$, cu $m \geq q - 1$ laguri; filtrul și netezitorul Kalman
- **În doi pași** Doz, Giannone și Reichlin (2011): PCA pentru $\hat{f}_t$, OLS pentru Λ și Ψ , un VAR pe $\hat{f}_t$ pentru A și Q , apoi netezitorul Kalman reestimează f_t
 - ▶ consistent pentru N și T mari, deși Ψ diagonală este o specificare greșită
- **Verosimilitate cvasi-maximă prin EM** Doz, Giannone și Reichlin (2012), Bańbura și Modugno (2014): pasul E = netezitorul Kalman, pasul M = regresii pe momentele netezite; tratează orice structură de date lipsă și componente idiosincratice AR(1)

Datele lipsă nu sînt o problemă pentru filtrul Kalman

- La momentul t păstrăm doar liniile observate: $x_t^o = W_t x_t$, $\Lambda_t = W_t \Lambda$, $\Psi_t = W_t \Psi W_t'$, cu W_t o matrice de selecție
 - ▶ dacă nu se observă nimic, pasul de actualizare se omite și predicția se transmite mai departe
- **Date incomplete la sfîrșitul eșantionului (ragged edge):** fiecare serie se oprește în altă lună (întîrzieri de publicare); filtrul folosește ce există
 - ▶ același mecanism tratează seriile care încep tîrziu (încrederea în servicii din 2002) și seriile trimestriale observate în fiecare a treia lună
- De aceea nowcasting-ul este o problemă de filtrare și de aceea [Capitolul 6](#) dezvoltă filtrul complet

Problema nowcasting-ului



Lucrezia Reichlin, 2013

Foto: Niccolò Caranti (2013); CC BY-SA 3.0;

Wikimedia Commons

- **Nowcasting:** estimarea prezentului și a trecutului recent al unei variabile de frecvență joasă (PIB) din date de frecvență înaltă, publicate mai repede [Giannone, Reichlin și Small \(2008\)](#), [Bańbura, Giannone, Modugno și Reichlin \(2013\)](#)
 - ▶ backcast (trimestrul trecut, încă nepublicat), nowcast (trimestrul curent), forecast (trimestrul următor)
- Trei dificultăți: frecvențe mixte, mulți indicatori, publicări asincrone (ragged edge)
 - ▶ anchetele apar la sfârșitul lunii; producția industrială după mai mult de o lună; PIB-ul la câteva săptămîni după trimestru
- Instrumente: ecuații punte [Baffigi, Golinelli și Parigi \(2004\)](#), MIDAS [Ghysels, Santa-Clara și Valkanov \(2006\)](#), [Ghysels, Sinko și Valkanov \(2007\)](#), DFM cu frecvențe mixte [Mariano și Murasawa \(2003\)](#), [Bańbura și Modugno \(2014\)](#) și VAR cu frecvențe mixte [Schorfheide și Song \(2015\)](#)


Ecuatii punte și MIDAS

- **Punte:** prognoză lunile lipsă ale fiecărui indicator (AR), agregăm la trimestru, regresăm PIB-ul pe agregatele trimestriale [Baffigi, Golinelli și Parigi \(2004\)](#)
 - ▶ simplă și transparentă; eroarea prognozelor AR lunare trece în nowcast
- **MIDAS** [Ghysels, Santa-Clara și Valkanov \(2006\)](#): $y_\tau = \beta_0 + \beta_1 \sum_{j=0}^{K-1} w_j(\theta) x_{m_\tau-j} + \rho y_{\tau-s} + \varepsilon_\tau$, cu ultima valoare lunară disponibilă x_{m_τ}
 - ▶ τ : trimestrul; m_τ : ultima lună disponibilă a lui; x : un indicator lunar cu K laguri; $w_j(\theta)$: ponderi cu suma 1; $y_{\tau-s}$: creșterea PIB cu lag
 - ▶ Almon exponențial: $w_j(\theta) = e^{\theta_1 j + \theta_2 j^2} / \sum_k e^{\theta_1 k + \theta_2 k^2}$; doi parametri pentru K laguri, estimați prin NLS
 - ▶ MIDAS cu valori anticipate [Andreou, Ghysels și Kourtellis \(2013\)](#), [Clements și Galvão \(2008\)](#): o regresie pentru fiecare set de informații; U-MIDAS lasă w_j nerestricționate când K este mic [Forni, Marcellino și Schumacher \(2015\)](#)
- Niciuna nu folosește dinamica comună a indicatorilor; DFM o folosește

Legătura dintre luni și trimestre: Mariano și Murasawa (2003)

- ▣ Fie Y_t^M un nivel lunar latent, iar PIB-ul trimestrial media pe 3 luni, observată în a treia lună
 - ▶ aproximarea prin media geometrică: $\ln Y_t^Q \approx \frac{1}{3}(\ln Y_t^M + \ln Y_{t-1}^M + \ln Y_{t-2}^M)$
 - ▶ creșterea trimestrială $y_t^Q = \ln Y_t^Q - \ln Y_{t-3}^Q = \frac{1}{3}(y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4})$, y_t = creșterea lunară
Mariano și Murasawa (2003)
- ▣ În DFM: $y_t^Q = \lambda_y' \sum_{j=0}^4 w_j f_{t-j} + e_t^Q$, $w = (1, 2, 3, 2, 1)/3$: starea trebuie să conțină cinci laguri ale lui f_t
 - ▶ λ_y : ponderile factoriale ale creșterii PIB; w_j : ponderile Mariano–Murasawa; e_t^Q : eroarea idiosincronică a PIB
 - ▶ PIB-ul este o variabilă lunară observată din trei în trei luni: lipsește în lunile 1 și 2 ale fiecărui trimestru
- ▣ Seminarul 5, A7: ponderile de mînă

Studiu de caz: nowcasting pentru PIB-ul României




Institutul Național de Statistică, București

Foto: Dan Mihai Pitea (2009); CC BY-SA 3.0;

[Wikimedia Commons](#)

- Ținta: creșterea t/t a PIB-ului real (Eurostat), 94 de trimestre până în T2 2026; panelul lunar: 11 serii din 2003 (Eurostat)
 - ▶ date „hard” ca rate lunare de creștere: IP, comerț, construcții, IP din zona euro; variația șomajului; nivelurile a șase solduri de încredere
- Întârzieri stilizate de publicare la sfârșitul fiecărei luni: anchete 0, șomaj 1, date hard 2 luni; PIB-ul la 2 luni după trimestru
 - ▶ datele din ediția curentă: pseudo timp real (fără revizuiți)
- Modelele: AR(1), punte (IP, comerț, ESI), MIDAS (IP, ESI; $K = 6$), DFM cu doi factori (în doi pași și EM)

PIB-ul României și doi indicatori lunari




□ Creșterea trimestrială a PIB-ului (T2 2020: -8,6%, trunchiată); creșterea IP (medie pe 3 luni) și ESI standardizat

Interpretarea datelor pentru România

- ▣ Creșterea trimestrială este volatilă: oscilațiile de ± 5 pp din 2009–2012 și prăbușirea din 2020 domină varianța
- ▣ ESI (medie pe 3 luni) are corelația 0,44 cu creșterea PIB înainte de 2020: informativ, departe de perfect
- ▣ Ultimul trimestru publicat: T2 2026, creștere 0,00%; ținta nowcast-ului este T3 2026

Ponderile MIDAS pentru România



□ ADL-MIDAS cu ponderi Almon exponențiale la sfârșitul lunii a treia a trimestrului, 2003–2026


Interpretarea ponderilor MIDAS

- ▣ IP: ponderi în formă de cocoașă, cu maximul la lagul 2 (0,25): contează lunile trimestrului însuși, cum prezic ponderile Mariano–Murasawa
- ▣ ESI: ponderea 0,92 pe ultima lună: un indicator de nivel rezumă deja trecutul
- ▣ Creșterea PIB cu lag are coeficientul $-0,28$: seria zgomotoasă t/t revine la medie

Evaluarea în pseudo timp real

- ▣ Pentru fiecare trimestru T1 2013–T2 2026, nowcast-uri la sfârșitul lunilor 1, 2, 3 ale trimestrului și la sfârșitul primei luni de după
 - ▶ toți parametrii sînt reestimați pe datele disponibile la acea dată; T2–T3 2020 sînt excluse din RMSE (raportăm și cu ele)
- ▣ Eșantionul de evaluare începe în 2013 pentru că oscilațiile din 2009–2012 sînt mai mari decît orice eroare de model; din 2010 RMSE urcă la aproximativ 2 pp pentru toate modelele
 - ▶ abaterea standard a țintei 2013–2026 (fără T2–T3 2020): 1,33 pp
- ▣ Întrebarea: scade RMSE pe măsură ce trimestrul avansează și cu cît față de un AR?

Acuratețea nowcast-ului în funcție de setul de informații



RMSE al nowcast-urilor pentru creșterea t/t a PIB-ului, T1 2013–T2 2026 fără T2–T3 2020


Interpretarea acurateții nowcast-ului

- ▣ AR: 1,33 pp peste tot; DFM: de la 1,34 (luna 1) la 1,20 (luna 1 de după); MIDAS: de la 1,60 la 1,15
- ▣ Ecuația punte nu este superioară modelului AR (1,39); estimarea EM a DFM este apropiată de AR (1,31 în luna 3)
- ▣ Diebold–Mariano DFM comparat cu AR în luna 3: $t = -0,30$, $p = 0,76$: câștigul nu este semnificativ pe 54 de trimestre
- ▣ Cu 2020: AR 1,90, DFM 1,30 în luna 1 de după: datele lunare surprind prăbușirea, AR nu poate

Știri și revizuirii: Bańbura și Modugno (2014)

- Seturile de informații $\Omega_v \subset \Omega_{v+1}$; noile publicări x_j , $j \in J_{v+1}$; **știrea** este $l_j = x_j - \mathbb{E}[x_j \mid \Omega_v]$, nu x_j
 - ▶ cu parametri ficși, revizuirea nowcast-ului lui y este o sumă ponderată a știrilor:
 $\mathbb{E}[y \mid \Omega_{v+1}] - \mathbb{E}[y \mid \Omega_v] = \mathbb{E}[yI']\mathbb{E}[II']^{-1}I = \sum_j w_j l_j$ Bańbura și Modugno (2014)
 - ▶ I : vectorul știrilor l_j ; w_j : ponderea publicării j
- În DFM: $l_j = \lambda_j'(f_{t_j} - \hat{f}_{t_j|v}) + e_j$, deci $\mathbb{E}[II'] = HP_{|v}H' + \Psi_J$ și $\mathbb{E}[yI'] = z_y'P_{|v}H'$
 - ▶ λ_j : ponderile factoriale ale publicării j ; t_j : luna la care se referă; $\hat{f}_{t_j|v}$: estimația factorului dat fiind Ω_v ; H : vectorii λ_j' așezați pe linii; Ψ_J : varianțele lor idiosincratice; z_y : ponderea factorială a țintei
 - ▶ $P_{|v}$: covarianța stării stivuie dat fiind Ω_v , din filtrul Kalman
- O publicare mare dar așteptată nu schimbă nimic; o surpriză mică într-o serie cu pondere mare schimbă mult; publicările corelate își împart ponderea

Nowcast pentru T3 2026 și sursa revizuirii



- Stînga: nowcast-uri la sfîrșitul lunilor iunie–septembrie 2026; dreapta: descompunerea în știri a nowcast-ului DFM în doi pași între seturile de informații din august și septembrie

Interpretarea știrilor

- Nowcast-ul DFM pentru T3 2026: 0,70% la sfârșitul lui august, 0,19% la sfârșitul lui septembrie; cele 11 publicări noi însumează exact $-0,51$ pp
- Publicarea IP pentru iulie a fost cu $-3,7$ pp sub așteptarea modelului; cu ponderea 0,073 a redus nowcast-ul cu $-0,27$ pp; ESI $-0,13$, IP din zona euro $-0,12$
- Alte modele la sfârșitul lui septembrie: DFM EM 0,08%, punte $-0,64\%$, AR 0,76%: prima estimare oficială pentru T3 2026 le va judeca
- Descompunerea în știri transformă o cifră într-o explicație pe care o bancă centrală o poate verifica publicare cu publicare

Recapitulare: nowcasting

- ▣ Nowcasting = filtrarea unui sistem cu frecvențe mixte și date incomplete la sfârșitul eșantionului
- ▣ Ecuațiile punte, MIDAS și DFM folosesc aceeași legătură Mariano–Murasawa între luni și trimestre
- ▣ Pentru România, datele lunare îmbunătățesc nowcast-ul spre sfârșitul trimestrului; câștigul este modest și nesemnificativ
- ▣ Orice revizuire se descompune exact în știri când parametrii sînt ficși

O întrebare deschisă

- Poate un model de nowcasting să fie semnificativ statistic superior unui AR simplu pentru creșterea PIB-ului României și ce publicări poartă informația?
 - ▶ formal: H_0 : MSE egal pentru nowcast-urile DFM și AR la sfârșitul lunii 3 (Diebold–Mariano, [Capitolul 1](#)), cu eșantionul, modelele și lagurile preînregistrate
 - ▶ infirmată de o respingere pe trimestre pe care modelul nu le-a văzut, cu ediții în timp real ale PIB
- Miza: deciziile fiscale și monetare din 2025–2026 s-au luat cu PIB-ul cunoscut la câteva săptămîni după fiecare trimestru
 - ▶ literatura de pornire: [Giannone, Reichlin și Small \(2008\)](#), [Bańbura și Modugno \(2014\)](#), [Bańbura, Giannone, Modugno și Reichlin \(2013\)](#), [Giannone, Lenza și Primiceri \(2021\)](#), [Schorfheide și Song \(2015\)](#)

Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate care fac nowcasting pentru PIB-ul țărilor din Europa Centrală și de Est cu modele factoriale sau MIDAS; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** Ce publicări lunare din România ar trebui să conțină știri despre PIB și în ce lună a trimestrului?
 - ▶ **cod și replicare:** cereți un filtru Kalman cu date lipsă, apoi reproduceți întâi o cifră cunoscută (suma știrilor din acest curs)
 - ▶ **robustețe și critică:** Joacă rolul unui recenzent ostil al unui articol de nowcasting: enumeră felurile în care designul în pseudo timp real ar putea favoriza artificial modelul.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Setul de informații la fiecare dată conține doar datele publicate pînă atunci; datele din ediția curentă supraestimează acuratețea
- ▣ Hiperparametrii, factorii și lagurile se aleg în interiorul fiecărei ferestre de estimare, niciodată pe eșantionul de evaluare
- ▣ Perioada de evaluare și tratarea anului 2020 sînt fixate înaintea rezultatelor; toate variantele sînt raportate
- ▣ O afirmație despre „nowcast-uri mai bune” se sprijină pe un test, nu doar pe un RMSE mai mic

Mini studiu de caz: cât de robustă este o clasificare?



- RMSE al nowcast-ului DFM relativ la AR la sfârșitul lunii 3, 2013–2026, pentru diferite numere de factori, începuturi ale eșantionului, întârzieri de publicare și tratări ale anului 2020
- Cele 16 variante variază între 0,71 și 1,03; DFM este superior în 14 dintre ele: un rezumat AI care raportează cea mai bună variantă drept „rezultatul” greșește

Idee de proiect

- ▣ **Un model de nowcasting în timp real pentru PIB-ul României:** întâi replicare, apoi extindere
 - ▶ replicați: descompunerea în știri din acest curs (−0,51 pp între august și septembrie 2026) și tabelul BGR pentru 1971–2003
 - ▶ extindeți: datele reale de publicare (calendarul INS), edițiile PIB salvate de acum înainte, blocuri de factori pentru date hard și soft, un BVAR cu frecvențe mixte, nowcast-uri de densitate
 - ▶ preînregistrați: ținta, trimestrele, modelele, seturile de informații, tratarea anului 2020 și testul Diebold–Mariano
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Multe serii și puține observații: strângeți (distribuții a priori) sau comprimați (factori)
- ▣ Distribuția Minnesota în formă conjugată dă distribuții a posteriori închise, extrageri exacte și o verosimilitate marginală care alege shrinkage-ul
- ▣ Sistemele mai mari cer distribuții mai strânse; atunci prognozează mai bine și dau răspunsuri mai plauzibile
- ▣ Componentele principale estimează spațiul factorilor; Bai–Ng îi alege dimensiunea; FAVAR și DFM îl folosesc
- ▣ Nowcasting-ul este filtrare Kalman cu date incomplete la sfârșitul eșantionului; orice revizuire este o sumă de știri

Autoevaluare

Întrebări

- ▣ Ce se întâmplă cu media a posteriori Minnesota când $\lambda \rightarrow 0$?
- ▣ De ce impune distribuția natural conjugată $\vartheta = 1$?
- ▣ Ce distribuție permite cointegrarea: suma coeficienților sau observația inițială?
- ▣ De ce poate identifica PCA doar spațiul factorilor?
- ▣ De ce o publicare mare, dar așteptată, nu este o știre?

Urmează:

- ▣ Modele în spațiul stărilor și filtrare bayesiană
- ▣ Filtrul și netezitorul Kalman complet; EM, filtre de particule, volatilitate stochastică

Anexă: distribuția a posteriori natural conjugată

- ▣ Verosimilitatea: $p(Y | B, \Sigma) \propto |\Sigma|^{-T/2} \exp\{-\frac{1}{2}\text{tr}[\Sigma^{-1}(Y - XB)'(Y - XB)]\}$
- ▣ Distribuția a priori: $|\Sigma|^{-k/2} \exp\{-\frac{1}{2}\text{tr}[\Sigma^{-1}(B - B_0)'\Omega_0^{-1}(B - B_0)]\} \times |\Sigma|^{-(d+n+1)/2} \exp\{-\frac{1}{2}\text{tr}(\Sigma^{-1}\Psi)\}$
- ▣ Completăm pătratul în B :

$$(Y - XB)'(Y - XB) + (B - B_0)'\Omega_0^{-1}(B - B_0) = (B - \bar{B})'\bar{\Omega}^{-1}(B - \bar{B}) + \hat{U}'\hat{U} + (\bar{B} - B_0)'\Omega_0^{-1}(\bar{B} - B_0)$$
- ▣ Deci $B | \Sigma, Y \sim MN(\bar{B}, \bar{\Omega}, \Sigma)$ și $\Sigma | Y \sim IW(\bar{\Psi}, T + d)$: aceleași familii ca distribuția a priori

Anexă: verosimilitatea marginală în formă închisă

- Integrând B și Σ (GLP, anexă): $p(Y) = \pi^{-nT/2} \frac{\Gamma_n(\frac{T+d}{2})}{\Gamma_n(\frac{d}{2})} |\Omega_0|^{-\frac{n}{2}} |X'X + \Omega_0^{-1}|^{-\frac{n}{2}} |\Psi|^{\frac{d}{2}} |\bar{\Psi}|^{-\frac{T+d}{2}}$
- $|\Omega_0| |X'X + \Omega_0^{-1}| = |I + \Omega_0 X'X|$: penalizarea complexității, care crește cu λ
- $|\bar{\Psi}|$: termenul de potrivire, care scade cu λ ; optimul le echilibrează
- Cu observații fictive: $\ln p(Y | \gamma) = \ln p(Y, Y_d | \gamma) - \ln p(Y_d | \gamma)$, fiecare cu formula de mai sus

Bibliografie (1/5)

- ▣ Andreou, E., Ghysels, E., & Kourtellis, A. (2013). Should macroeconomic forecasters use daily financial data and how? *Journal of Business & Economic Statistics*, 31(2), 240–251. doi:10.1080/07350015.2013.767199
- ▣ Aruoba, S. B., Diebold, F. X., & Scotti, C. (2009). Real-time measurement of business conditions. *Journal of Business & Economic Statistics*, 27(4), 417–427. doi:10.1198/jbes.2009.07205
- ▣ Bańbura, M., Giannone, D., Modugno, M., & Reichlin, L. (2013). Now-casting and the real-time data flow. In G. Elliott & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 2A, pp. 195–237). Elsevier. doi:10.1016/B978-0-444-53683-9.00004-9
- ▣ Bańbura, M., Giannone, D., & Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71–92. doi:10.1002/jae.1137
- ▣ Bańbura, M., & Modugno, M. (2014). Maximum likelihood estimation of factor models on datasets with arbitrary pattern of missing data. *Journal of Applied Econometrics*, 29(1), 133–160. doi:10.1002/jae.2306
- ▣ Baffigi, A., Golinelli, R., & Parigi, G. (2004). Bridge models to forecast the euro area GDP. *International Journal of Forecasting*, 20(3), 447–460. doi:10.1016/S0169-2070(03)00067-0
- ▣ Bai, J. (2003). Inferential theory for factor models of large dimensions. *Econometrica*, 71(1), 135–171. doi:10.1111/1468-0262.00392
- ▣ Bai, J., & Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221. doi:10.1111/1468-0262.00273
- ▣ Bernanke, B. S., Boivin, J., & Elias, P. (2005). Measuring the effects of monetary policy: A factor-augmented vector autoregressive (FAVAR) approach. *The Quarterly Journal of Economics*, 120(1), 387–422. doi:10.1162/0033553053327452
- ▣ Carriero, A., Clark, T. E., & Marcellino, M. (2016). Common drifting volatility in large Bayesian VARs. *Journal of Business & Economic Statistics*, 34(3), 375–390. doi:10.1080/07350015.2015.1040116
- ▣ Carriero, A., Clark, T. E., & Marcellino, M. (2019). Large Bayesian vector autoregressions with stochastic volatility and non-conjugate priors. *Journal of Econometrics*, 212(1), 137–154. doi:10.1016/j.jeconom.2019.04.024
- ▣ Chamberlain, G., & Rothschild, M. (1983). Arbitrage, factor structure, and mean-variance analysis on large asset markets. *Econometrica*, 51(5), 1281–1304. doi:10.2307/1912275

Bibliografie (2/5)

- ▣ Chan, J. C. C. (2020). Large Bayesian vector autoregressions. In P. Fuleky (Ed.), *Macroeconomic Forecasting in the Era of Big Data* (pp. 95–125). Springer. doi:10.1007/978-3-030-31150-6_4
- ▣ Clark, T. E. (2011). Real-time density forecasts from Bayesian vector autoregressions with stochastic volatility. *Journal of Business & Economic Statistics*, 29(3), 327–341. doi:10.1198/jbes.2010.09248
- ▣ Clements, M. P., & Galvão, A. B. (2008). Macroeconomic forecasting with mixed-frequency data: Forecasting output growth in the United States. *Journal of Business & Economic Statistics*, 26(4), 546–554. doi:10.1198/073500108000000015
- ▣ Croushore, D., & Stark, T. (2001). A real-time data set for macroeconomists. *Journal of Econometrics*, 105(1), 111–130. doi:10.1016/S0304-4076(01)00072-0
- ▣ De Mol, C., Giannone, D., & Reichlin, L. (2008). Forecasting using a large number of predictors: Is Bayesian shrinkage a valid alternative to principal components? *Journal of Econometrics*, 146(2), 318–328. doi:10.1016/j.jeconom.2008.08.011
- ▣ Doan, T., Litterman, R., & Sims, C. (1984). Forecasting and conditional projection using realistic prior distributions. *Econometric Reviews*, 3(1), 1–100. doi:10.1080/07474938408800053
- ▣ Doz, C., Giannone, D., & Reichlin, L. (2012). A quasi-maximum likelihood approach for large, approximate dynamic factor models. *The Review of Economics and Statistics*, 94(4), 1014–1024. doi:10.1162/REST_a_00225
- ▣ Doz, C., Giannone, D., & Reichlin, L. (2011). A two-step estimator for large approximate dynamic factor models based on Kalman filtering. *Journal of Econometrics*, 164(1), 188–205. doi:10.1016/j.jeconom.2011.02.012
- ▣ Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press. doi:10.1093/acprof:oso/9780199641178.001.0001
- ▣ Forni, M., Hallin, M., Lippi, M., & Reichlin, L. (2000). The generalized dynamic-factor model: Identification and estimation. *The Review of Economics and Statistics*, 82(4), 540–554. doi:10.1162/003465300559037
- ▣ Forni, C., Marcellino, M., & Schumacher, C. (2015). Unrestricted mixed data sampling (MIDAS): MIDAS regressions with unrestricted lag polynomials. *Journal of the Royal Statistical Society: Series A*, 178(1), 57–82. doi:10.1111/rssa.12043
- ▣ Gelfand, A. E., & Smith, A. F. M. (1990). Sampling-based approaches to calculating marginal densities. *Journal of the American Statistical Association*, 85(410), 398–409. doi:10.1080/01621459.1990.10476213

Bibliografie (3/5)

- ▣ Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3rd ed.). Chapman and Hall/CRC. doi:10.1201/b16018
- ▣ Gelman, A., & Rubin, D. B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4), 457–472. doi:10.1214/ss/1177011136
- ▣ Geman, S., & Geman, D. (1984). Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-6(6), 721–741. doi:10.1109/TPAMI.1984.4767596
- ▣ Ghysels, E. (2016). Macroeconomics and the reality of mixed frequency data. *Journal of Econometrics*, 193(2), 294–314. doi:10.1016/j.jeconom.2016.04.008
- ▣ Ghysels, E., Santa-Clara, P., & Valkanov, R. (2006). Predicting volatility: Getting the most out of return data sampled at different frequencies. *Journal of Econometrics*, 131(1–2), 59–95. doi:10.1016/j.jeconom.2005.01.004
- ▣ Ghysels, E., Sinko, A., & Valkanov, R. (2007). MIDAS regressions: Further results and new directions. *Econometric Reviews*, 26(1), 53–90. doi:10.1080/07474930600972467
- ▣ Giannone, D., Lenza, M., & Primiceri, G. E. (2021). Economic predictions with big data: The illusion of sparsity. *Econometrica*, 89(5), 2409–2437. doi:10.3982/ECTA17842
- ▣ Giannone, D., Lenza, M., & Primiceri, G. E. (2015). Prior selection for vector autoregressions. *The Review of Economics and Statistics*, 97(2), 436–451. doi:10.1162/REST_a_00483
- ▣ Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676. doi:10.1016/j.jmoneco.2008.05.010
- ▣ Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. doi:10.2307/j.ctv14jx6sm
- ▣ Kadiyala, K. R., & Karlsson, S. (1997). Numerical methods for estimation and inference in Bayesian VAR-models. *Journal of Applied Econometrics*, 12(2), 99–132. doi:10.1002/(SICI)1099-1255(199703)12:2<99::AID-JAE429>3.0.CO;2-A
- ▣ Karlsson, S. (2013). Forecasting with Bayesian vector autoregression. In G. Elliott & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 2B, pp. 791–897). Elsevier. doi:10.1016/B978-0-444-62731-5.00015-4

Bibliografie (4/5)

- ▣ Kass, R. E., & Raftery, A. E. (1995). Bayes factors. *Journal of the American Statistical Association*, 90(430), 773–795. doi:10.1080/01621459.1995.10476572
- ▣ Kilian, L., & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*. Cambridge University Press. doi:10.1017/9781108164818
- ▣ Koop, G. (2013). Forecasting with medium and large Bayesian VARs. *Journal of Applied Econometrics*, 28(2), 177–203. doi:10.1002/jae.1270
- ▣ Koop, G., & Korobilis, D. (2010). Bayesian multivariate time series methods for empirical macroeconomics. *Foundations and Trends in Econometrics*, 3(4), 267–358. doi:10.1561/08000000013
- ▣ Lenza, M., & Primiceri, G. E. (2022). How to estimate a vector autoregression after March 2020. *Journal of Applied Econometrics*, 37(4), 688–699. doi:10.1002/jae.2895
- ▣ Litterman, R. B. (1986). Forecasting with Bayesian vector autoregressions: Five years of experience. *Journal of Business & Economic Statistics*, 4(1), 25–38. doi:10.1080/07350015.1986.10509491
- ▣ Mariano, R. S., & Murasawa, Y. (2003). A new coincident index of business cycles based on monthly and quarterly series. *Journal of Applied Econometrics*, 18(4), 427–443. doi:10.1002/jae.695
- ▣ McCracken, M. W., & Ng, S. (2016). FRED-MD: A monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, 34(4), 574–589. doi:10.1080/07350015.2015.1086655
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Primiceri, G. E. (2005). Time varying structural vector autoregressions and monetary policy. *The Review of Economic Studies*, 72(3), 821–852. doi:10.1111/j.1467-937X.2005.00353.x
- ▣ Schorfheide, F., & Song, D. (2015). Real-time forecasting with a mixed-frequency VAR. *Journal of Business & Economic Statistics*, 33(3), 366–380. doi:10.1080/07350015.2014.954707
- ▣ Sims, C. A. (1993). A nine-variable probabilistic macroeconomic forecasting model. In J. H. Stock & M. W. Watson (Eds.), *Business Cycles, Indicators and Forecasting* (pp. 179–212). University of Chicago Press. nber.org

Bibliografie (5/5)

- ▣ Sims, C. A., & Zha, T. (1998). Bayesian methods for dynamic multivariate models. *International Economic Review*, 39(4), 949–968. doi:[10.2307/2527347](https://doi.org/10.2307/2527347)
- ▣ Stock, J. H., & Watson, M. W. (2002a). Forecasting using principal components from a large number of predictors. *Journal of the American Statistical Association*, 97(460), 1167–1179. doi:[10.1198/016214502388618960](https://doi.org/10.1198/016214502388618960)
- ▣ Stock, J. H., & Watson, M. W. (2002b). Macroeconomic forecasting using diffusion indexes. *Journal of Business & Economic Statistics*, 20(2), 147–162. doi:[10.1198/073500102317351921](https://doi.org/10.1198/073500102317351921)
- ▣ Stock, J. H., & Watson, M. W. (2016). Dynamic factor models, factor-augmented vector autoregressions, and structural vector autoregressions in macroeconomics. In J. B. Taylor & H. Uhlig (Eds.), *Handbook of Macroeconomics* (Vol. 2A, pp. 415–525). Elsevier. doi:[10.1016/bs.hesmac.2016.04.002](https://doi.org/10.1016/bs.hesmac.2016.04.002)
- ▣ Stock, J. H., & Watson, M. W. (1989). New indexes of coincident and leading economic indicators. *NBER Macroeconomics Annual*, 4, 351–394. doi:[10.1086/654119](https://doi.org/10.1086/654119)
- ▣ Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, 16(2), 667–718. doi:[10.1214/20-BA1221](https://doi.org/10.1214/20-BA1221)