



Analiza avansată a seriilor de timp și previziune

Capitolul 6: Modele în spațiul stărilor și filtrare bayesiană



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **APF:** Auxiliary Particle Filter (filtrul de particule auxiliar)
- ▣ **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARCH:** AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARIMA:** AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ▣ **ARMA:** AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BN:** Beveridge–Nelson (decomposition) — descompunerea Beveridge–Nelson
- ▣ **BNR:** Banca Națională a României
- ▣ **BSTS:** Bayesian Structural Time Series (serii de timp structurale bayesiene)
- ▣ **BVAR:** Bayesian Vector AutoRegression (model vector autoregresiv bayesian)
- ▣ **DFM:** Dynamic Factor Model (model factorial dinamic)
- ▣ **DK:** Durbin–Koopman (simulation smoother, 2002) — algoritmul Durbin–Koopman (2002) de simulare a stărilor netezite
- ▣ **DSGE:** Dynamic Stochastic General Equilibrium (model) — model dinamic stochastic de echilibru general
- ▣ **EKF:** Extended Kalman Filter (filtrul Kalman extins)
- ▣ **EM:** Expectation–Maximisation (algorithm) — algoritmul expectație–maximizare
- ▣ **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **ETS:** Error, Trend, Seasonality (exponential smoothing state space models) — eroare, trend, sezonabilitate (modele de netezire exponențială)

Acronime folosite în acest material (2/3)

- ▣ **FERMIAC**: mechanical Monte Carlo device of Enrico Fermi (Los Alamos, 1947) — dispozitiv mecanic Monte Carlo al lui Enrico Fermi (Los Alamos, 1947)
- ▣ **FFBS**: Forward Filtering, Backward Sampling (filtrare înainte, eşantionare înapoi)
- ▣ **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **HICP**: Harmonised Index of Consumer Prices (indicele armonizat al prețurilor de consum (IAPC))
- ▣ **HP**: Hodrick–Prescott (filter) — filtrul Hodrick–Prescott
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **IG**: inverse gamma (distribution) — distribuția gamma inversă
- ▣ **IMA**: Integrated Moving Average (model) — model integrat de medie mobilă
- ▣ **KSC**: Kim–Shephard–Chib (1998), mixture sampler for stochastic volatility (Kim–Shephard–Chib (1998), eşantionatorul cu mixtură pentru volatilitatea stohastică)
- ▣ **LLM**: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MCMC**: Markov Chain Monte Carlo (metode Monte Carlo cu lanțuri Markov)
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **MNZ**: Morley–Nelson–Zivot (2003) — Morley–Nelson–Zivot (2003)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **PIB**: Produsul intern brut

Acronime folosite în acest material (3/3)

- ▣ **PMMH**: Particle Marginal Metropolis–Hastings (algoritmul Metropolis–Hastings marginal cu filtru de particule)
- ▣ **QML**: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- ▣ **SMC**: Sequential Monte Carlo (metode Monte Carlo secvențiale)
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **SV**: Stochastic Volatility (volatilitate stochastică)
- ▣ **TSA**: Time Series Analysis (Serii de timp, cursul de licență)
- ▣ **TVA**: Taxa pe valoarea adăugată
- ▣ **TVP**: Time-Varying Parameter(s) — parametri variabili în timp
- ▣ **TVP-VAR**: Time-Varying-Parameter Vector AutoRegression (model VAR cu parametri variabili în timp)
- ▣ **TVP-VAR-SV**: TVP-VAR with Stochastic Volatility (model VAR cu parametri variabili în timp și volatilitate stochastică)
- ▣ **UC**: Unobserved Components (model) — model cu componente neobservate
- ▣ **UC-SV**: Unobserved Components model with Stochastic Volatility (Stock–Watson 2007) — model cu componente neobservate și volatilitate stochastică (Stock–Watson 2007)
- ▣ **UC-UR**: UC model with correlated trend and cycle shocks (Morley–Nelson–Zivot 2003) — model UC cu șocuri corelate ale trendului și ciclului (Morley–Nelson–Zivot 2003)
- ▣ **UC0**: UC model with uncorrelated trend and cycle shocks (Clark 1987) — model UC cu șocuri necorelate ale trendului și ciclului (Clark 1987)
- ▣ **UKF**: Unscented Kalman Filter (filtrul Kalman unscented)
- ▣ **VAR**: Vector AutoRegression (model vector autoregresiv)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum învățăm despre mărimi pe care nu le observăm niciodată (inflația de trend, output gap-ul, volatilitatea, coeficienți variabili în timp) și cât ne putem baza pe ce aflăm?
 - ▶ un singur cadru: o ecuație de stare pentru mărimea ascunsă, o ecuație de măsurare pentru date și un filtru care actualizează convingerile pe măsură ce sosesc datele
- ▣ **Traseul** capitolului
 - ▶ modelul liniar gaussian general, inițializarea difuză exactă, verosimilitatea exactă și inferența la frontieră
 - ▶ spațiul stărilor bayesian: simulation smoothers și eşantionare Gibbs; volatilitatea stochastică
 - ▶ filtre neliniare: filtrul Kalman extins și unscented, filtre de particule, particle MCMC
 - ▶ parametri variabili în timp, factori dinamici, descompuneri trend–ciclu și inflația de trend cu volatilitate stochastică
- ▣ Pornim de la [TSA, Capitolul 10](#) (forma în spațiul stărilor, filtrul Kalman de mînă, netezirea, modelele local level și local trend, output gap-ul UC, bazele modelelor Markov switching); Seminarul 6 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Derivați filtrul și netezitorul Kalman pentru modelul liniar gaussian general, cu inițializare difuză exactă, și scrieți-le în `numpy`
- ▣ Maximizați verosimilitatea exactă și evaluați inferența asupra varianțelor care pot ajunge pe frontieră (pile-up, teste LR bootstrap)
- ▣ Eșantionați stările cu metodele Carter–Kohn, Durbin–Koopman și cu eșantionarea pe baza matricei de precizie, într-un eșantionator Gibbs; estimați volatilitatea stochastică prin mixtura KSC
- ▣ Aplicați filtrele Kalman extins, unscented și de particule; folosiți verosimilitatea din filtrul de particule în PMMH și alegeți numărul de particule
- ▣ Estimați regresii TVP, modele UC cu șocuri corelate și inflația de trend UC-SV și raportați cât de fragile sînt estimațiile componentelor latente

Bibliografie, date și instrumente

- ▣ Bibliografia de bază: Durbin și Koopman (2012), cap. 2–9 și 11–14; Harvey (1990); Kim și Nelson (1999); Hamilton (1994), cap. 13; Chopin și Papaspiliopoulos (2020)
 - ▶ lucrările originale: Kalman (1960), Koopman (1997), Carter și Kohn (1994), Durbin și Koopman (2002), Kim, Shephard și Chib (1998), Gordon, Salmond și Smith (1993), Pitt și Shephard (1999), Andrieu, Doucet și Holenstein (2010), Primiceri (2005), Morley, Nelson și Zivot (2003), Stock și Watson (2007)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_06](#)
 - ▶ filtrul și netezitorul Kalman cu inițializare difuză exactă, simulation smoothers, eșantionatorul Gibbs KSC, filtrele de particule bootstrap și auxiliar, PMMH și UC-SV scrise explicit în `numpy`; verificate cu `statsmodels`
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Utilizare
deflatorul PIB și PIB-ul real al SUA (trimestrial)	FRED (GDPDEF, GDPC1)	verosimilitate, MNZ, UC-SV
S&P 500 și BET, închideri zilnice	EODHD	volatilitate stochastică
IAPC pentru România și zona euro (indice lunar, 2025 = 100)	Eurostat prc_hicp_minr	TVP, UC-SV
PIB-ul real al României, ajustat sezonier și cu numărul de zile lucrătoare	Eurostat namq_10_gdp	output gap-ul
producția industrială, numărul de salariați, venitul real fără transferuri, vânzările reale ale SUA (lunar)	FRED (INDPRO, PAYEMS, W875RX1, CMRMTSPL)	DFM

- Toate sursele sînt publice și nu cer cont sau cheie; seriile trimestriale pînă în T2 2026, cele lunare pînă în august sau septembrie 2026, datele zilnice pînă la 18 septembrie 2026
- IAPC (HICP): indicele armonizat al prețurilor de consum; DFM: model cu factori dinamici

De la navigația Apollo la inflația de trend



Rudolf E. Kálmán, 2007

Foto: ETH-Bibliothek Zürich, Bildarchiv (2007); CC

BY-SA 4.0; Wikimedia Commons

- 1960: Kalman (1960) dă filtrul liniar recursiv; în mai puțin de un deceniu, el ghidează misiunile Apollo
- 1982–1997: algoritmul EM pentru modele în spațiul stărilor Shumway și Stoffer (1982); serii de timp structurale Harvey (1990); filtrarea difuză exactă Koopman (1997)
- 1993–1999: filtre de particule Gordon, Salmond și Smith (1993), Pitt și Shephard (1999); eșantionarea Gibbs a stărilor Carter și Kohn (1994), Frühwirth-Schnatter (1994); volatilitate stochastică Kim, Shephard și Chib (1998)
- 2002–2010: simulation smoother-ul Durbin și Koopman (2002); TVP-VAR cu volatilitate stochastică Primiceri (2005), Cogley și Sargent (2005); particule MCMC Andrieu, Doucet și Holenstein (2010)
- Astăzi: băncile centrale urmăresc inflația de trend și output gap-ul cu aceste instrumente Stock și Watson (2007), Morley, Nelson și Zivot (2003)

De la TSA la acest capitol

- ▣ Cunoscut ([TSA](#), [Capitolul 10](#)): forma în spațiul stărilor, filtrul Kalman pentru modelul local level de mînă, netezirea, verosimilitatea maximă prin descompunerea erorilor de predicție, filtrul HP ca netezitor, Hamilton (2018), modelele Markov switching
- ▣ Nou aici
 - ▶ filtrul și netezitorul pentru orice model liniar gaussian, cu stări nestacionare inițializate exact (nu cu o varianță mare)
 - ▶ inferența cînd o varianță poate fi zero; eșantionarea bayesiană a traiectoriilor întregi ale stărilor
 - ▶ modele neliniare și negausiene: volatilitate stochastică, filtre de particule, particule MCMC
 - ▶ aplicații la nivel de cercetare: MNZ, UC-SV, regresii TVP, ragged edge într-un DFM
- ▣ Modelele Markov switching în detaliu: [Capitolul 7](#); nowcasting cu factori: [Capitolul 5](#)

Forma generală în spațiul stărilor (1/2)

- Două ecuații: datele sînt o funcție liniară cu zgomot a unei stări neobservate, iar starea urmează o dinamică liniară de ordinul întâi

$$y_t = Z_t \alpha_t + \varepsilon_t, \quad \alpha_{t+1} = c_t + T_t \alpha_t + R_t \eta_t, \quad t = 1, \dots, n$$

- Notățiile

- ▶ y_t ($p \times 1$): observațiile; α_t ($m \times 1$): starea; n : lungimea eșantionului
- ▶ Z_t ($p \times m$): matricea de măsurare; T_t ($m \times m$): matricea de tranziție; c_t : un termen liber cunoscut
- ▶ $\varepsilon_t \sim N(0, H_t)$: zgomotul de măsurare; $\eta_t \sim N(0, Q_t)$: șocurile stării; R_t ($m \times r$) alege stările care primesc șocuri
- ▶ ε_t și η_s sînt independente între ele și în timp

- Starea inițială $\alpha_1 \sim N(a_1, P_1)$

- ▶ elementele nestaționare sau fixe necunoscute: $P_1 = \kappa P_\infty + P_*$, $\kappa \rightarrow \infty$; P_∞ marchează elementele difuze, P_* este covarianța celorlalte

Forma generală în spațiul stărilor (2/2)

- Matricele sistemului Z_t, T_t, R_t, H_t, Q_t depind de parametrii ψ ; variația în timp a lui Z_t dă regresii cu coeficienți variabili în timp
 - ▶ ARMA, UC, regresii TVP, DFM, VAR cu date lipsă, ETS: toate sînt cazuri particulare [Durbin și Koopman \(2012\)](#)
- Notățiile pentru estimatii
 - ▶ $Y_t = (y_1, \dots, y_t)$: datele pînă la t
 - ▶ starea prezisă: $a_t = \mathbb{E}(\alpha_t | Y_{t-1})$, $P_t = \text{Var}(\alpha_t | Y_{t-1})$; filtrată: $a_{t|t}$, $P_{t|t}$ (după y_t)
 - ▶ netezită: $\hat{\alpha}_t = \mathbb{E}(\alpha_t | Y_n)$, $V_t = \text{Var}(\alpha_t | Y_n)$ (toate datele)

Filtrul Kalman dintr-o singură leamnă

- Lema (condiționarea vectorilor normali comuni): dacă (x, y) este gaussian, $\mathbb{E}(x|y) = \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$, $\text{Var}(x|y) = \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}$
 - ▶ μ_x, μ_y : mediile; $\Sigma_{xy} = \text{Cov}(x, y)$, $\Sigma_{yy} = \text{Var}(y)$: blocurile de covarianță
 - ▶ o aplicăm pentru $x = \alpha_t$ și $y = y_t$, condiționat de Y_{t-1} : $v_t = y_t - Z_t a_t$ este informația nouă (eroarea de predicție)
- Varianța erorii de predicție $\text{Var}(v_t|Y_{t-1}) = F_t = Z_t P_t Z_t' + H_t$; $\text{Cov}(\alpha_t, v_t|Y_{t-1}) = P_t Z_t'$; v_t este independent de Y_{t-1}
- Actualizarea: $a_{t|t} = a_t + P_t Z_t' F_t^{-1} v_t$, $P_{t|t} = P_t - P_t Z_t' F_t^{-1} Z_t P_t$
- Predicția: $a_{t+1} = c_t + T_t a_{t|t}$, $P_{t+1} = T_t P_{t|t} T_t' + R_t Q_t R_t'$
- Fără normalitate, aceleași recursii dau cel mai bun predictor *liniar* (eroare pătratică medie minimă printre funcțiile liniare de Y_t)

Filtrul într-o singură trecere

- ▣ Cu v_t și F_t de pe slide-ul anterior: $K_t = T_t P_t Z_t' F_t^{-1}$ (cîștigul Kalman), $L_t = T_t - K_t Z_t$
- ▣ $a_{t+1} = c_t + T_t a_t + K_t v_t$, $P_{t+1} = T_t P_t L_t' + R_t Q_t R_t'$
- ▣ Costul: $O(n(m^3 + p^3))$; cu matrice constante, P_t converge către starea staționară a ecuației Riccati
 - ▶ P_t și K_t nu depind de y : se pot calcula înainte de sosirea datelor
- ▣ y_t lipsă: punem $Z_t = 0$ (sau eliminăm rîndurile lipsă): v_t și K_t dispar, iar filtrul doar prezice
 - ▶ frecvențele mixte și ragged edge al datelor în timp real se tratează deci fără cost suplimentar (Capitolul 5)
- ▣ y_t multivariat cu H_t diagonală: prelucrăm cele p elemente pe rînd (tratarea univariată Koopman și Durbin (2000)): fără inversarea unei matrice $p \times p$

Netezirea: recursii înapoi

- ▣ Netezitorul stărilor **Durbin și Koopman (2012)**: $r_{t-1} = Z_t' F_t^{-1} v_t + L_t' r_t$, $N_{t-1} = Z_t' F_t^{-1} Z_t + L_t' N_t L_t$, $r_n = 0$, $N_n = 0$
- ▣ Starea netezită: $\hat{\alpha}_t = a_t + P_t r_{t-1}$, $V_t = P_t - P_t N_{t-1} P_t$
 - ▶ r_{t-1} : o sumă ponderată a inovațiilor de la t încolo; $N_{t-1} = \text{Var}(r_{t-1})$
 - ▶ $\hat{\alpha}_t$ corectează a_t cu tot ce aflăm de la momentul t încolo
- ▣ Netezitorul perturbațiilor: $\hat{\varepsilon}_t = H_t(F_t^{-1} v_t - K_t' r_t)$, $\hat{\eta}_t = Q_t R_t' r_t$: reziduuri auxiliare pentru valori extreme și rupturi și scorul verosimilității
- ▣ Derivarea folosește aceeași leamnă, acum condiționând pe $v_t, \dots, v_n$, care sînt independente ([▶ Anexa](#))

Inițializarea difuză (1/2)

- Mersurile aleatoare, trendurile și coeficienții de regresie nu au distribuție staționară: $P_1 = \kappa P_\infty + P_*$, $\kappa \rightarrow \infty$
 - ▶ „big kappa” ($\kappa = 10^6$ – 10^7) este o aproximare cu două defecte: verosimilitatea conține termeni $-\frac{1}{2} \ln \kappa$, iar erorile de rotunjire cresc cu κ
- Filtrul difuz exact [Koopman \(1997\)](#), [Ansley și Kohn \(1985\)](#), [de Jong \(1991\)](#)
 - ▶ dezvoltăm $P_t = \kappa P_{\infty,t} + P_{*,t} + O(\kappa^{-1})$ și păstrăm ambele părți cît timp $P_{\infty,t} \neq 0$
 - ▶ $P_{\infty,t}$ ajunge la zero după d pași (d = numărul elementelor difuze, dacă sînt identificate)
 - ▶ apoi preia filtrul obișnuit


Inițializarea difuză (2/2)

□ Recursiile difuze exacte

- ▶ $F_{\infty,t}$, $F_{*,t}$: părțile difuză și finită ale lui F_t ; $K_t^{(0)}$, $K_t^{(1)}$: câștigurile corespunzătoare; $L_t^{(0)} = T_t - K_t^{(0)} Z_t$, $L_t^{(1)} = -K_t^{(1)} Z_t$
- ▶ y_t univariat, $F_{\infty,t} = Z_t P_{\infty,t} Z_t' > 0$: $K_t^{(0)} = T_t P_{\infty,t} Z_t' / F_{\infty,t}$, $K_t^{(1)} = T_t (P_{*,t} Z_t' - P_{\infty,t} Z_t' F_{*,t} / F_{\infty,t}) / F_{\infty,t}$
- ▶ $a_{t+1} = c_t + T_t a_t + K_t^{(0)} v_t$; $P_{\infty,t+1} = T_t P_{\infty,t} L_t^{(0)'} + T_t P_{*,t} L_t^{(1)'} + R_t Q_t R_t'$

- Netezitorul are recursii difuze corespunzătoare pentru $r^{(0)}$, $r^{(1)}$, $N^{(0)}$, $N^{(1)}$, $N^{(2)}$ [Durbin și Koopman \(2012\)](#), secțiunea 5.3; în Quantlet ambele sînt comparate cu statsmodels

Inițializarea difuză exactă față de big kappa



□ Stînga: modelul local level pentru inflația deflatorului PIB din SUA, la varianțele ML; dreapta: local linear trend pentru $100 \times \log$ PIB real al României, $T = 106$; ambele comparate cu filtrul difuz exact

Interpretarea inițializării difuze

- Cu toți termenii, log-verosimilitatea big kappa scade cu $\frac{1}{2} \ln 10$ la fiecare ordin de mărime al lui κ : $-460,72$ la $\kappa = 10^7$, $-468,78$ la 10^{14} ; valoarea exactă este $-452,66$
- Înlocuirea primului termen cu limita lui difuză repară nivelul ($-452,66$ la 10^7), dar doar pentru că știm că $d = 1$; estimarea ML după ψ nu este afectată, compararea modelelor cu d diferit este
- Varianțele netezite: eroarea este $0,000012$ la $\kappa = 10^4$, $0,06$ la 10^8 și 10^{15} la 10^{16} : niciun κ nu este sigur simultan pentru stări și pentru varianțe
- Regula practică: folosiți filtrul difuz exact ori de câte ori modelul are stări nestaționare sau fixe necunoscute

Descompunerea erorilor de predicție, cazul difuz


- $p(y_1, \dots, y_n) = \prod_t p(y_t | Y_{t-1})$, iar $y_t | Y_{t-1} \sim N(Z_t a_t, F_t)$: verosimilitatea este un produs secundar al filtrului
- Log-verosimilitatea difuză [Durbin și Koopman \(2012\)](#), ec. (7.4):

$$\ln L_d = -\frac{np}{2} \ln 2\pi - \frac{1}{2} \sum_{t=1}^d w_t - \frac{1}{2} \sum_{t=d+1}^n (\ln |F_t| + v_t' F_t^{-1} v_t)$$
- $w_t = \ln F_{\infty, t}$ dacă $F_{\infty, t} > 0$, altfel $w_t = \ln F_{*, t} + v_t^2 / F_{*, t}$: primele d observații doar fixează stările difuze
 - echivalentă cu verosimilitatea marginală din [de Jong \(1991\)](#) și cu tratarea stărilor difuze ca parametri ficși, eliminați prin concentrare
- Scala: scriem $H_t = \sigma^2 H_t^*$, $Q_t = \sigma^2 Q_t^*$; atunci $F_t = \sigma^2 F_t^*$ și $\hat{\sigma}^2 = \frac{1}{p(n-d)} \sum_{t>d} v_t' F_t^{*-1} v_t$: un parametru mai puțin în căutarea numerică

Maximizarea verosimilității

- ▣ Parametrizăm varianțele prin $\exp(\cdot)$, corelațiile prin $\tanh(\cdot)$, coeficienții AR prin autocorelațiile parțiale: căutare fără restricții, doar modele staționare
 - mai multe puncte de pornire: verosimilitățile UC sînt adesea multimodale (MNZ, mai jos)
- ▣ Scorul într-o singură trecere filtru–netezitor: $\partial \ln L / \partial \psi = \frac{1}{2} \sum_t \text{tr}\{(\hat{\varepsilon}_t \hat{\varepsilon}_t' + \text{Var}(\varepsilon_t | Y_n) - H_t) H_t^{-1} \frac{\partial H_t}{\partial \psi} H_t^{-1}\} + \dots$
Durbin și Koopman (2012), secțiunea 7.3
- ▣ Algoritmul EM Shumway și Stoffer (1982): pasul E este netezitorul, pasul M are formule explicite pentru H și Q ; lent lîngă optim, dar robust la puncte de pornire slabe (DFM mari)
- ▣ Erorile standard: inversa hessiane în $\hat{\psi}$ (numerică); valabile doar pentru puncte interioare; le raportăm pe scala transformată
- ▣ Identificarea: unele modele UC sînt echivalente observațional cu modele ARIMA cu mai puțini parametri; verificați forma redusă înainte de a interpreta componentele

Local level pentru inflația din SUA: numpy față de statsmodels



- Inflația deflatorului PIB, T1 1953–T2 2026, $T = 294$; ML difuz exact; nivelul netezit cu o bandă de 90% și nivelul unilateral (filtrat)


Interpretarea estimațiilor local level

- ▣ numpy: $\hat{\sigma}_\varepsilon^2 = 0,517$, $\hat{\sigma}_\eta^2 = 0,453$, $\hat{q} = 0,877$; statsmodels: 0,517 și 0,453: același optim
- ▣ Log-verosimilitățile $-452,66$ și $-451,74$: diferă exact cu $\frac{1}{2} \ln 2\pi = 0,919$, constanta pe care statsmodels o omite pentru observația difuză ($d = 1$)
- ▣ Câștigul în starea staționară este 0,596: fiecare trimestru nou mută estimația nivelului cu 60% din surpriză; inflația este mai aproape de un mers aleator decât de un zgomot alb în jurul unei medii
- ▣ Ultimul nivel netezit este 4,83% (abatere standard 0,55): la finalul eșantionului estimațiile netezite și filtrate coincid, la fel și incertitudinea lor
- ▣ O singură varianță constantă pentru 1953–2026 este neplauzibilă (Marea Inflație, Marea Moderație): de aici modelul UC-SV din ultima secțiune

Inferența la frontieră: problema pile-up

- ▣ Modelul local level cu $q = \sigma_{\eta}^2 / \sigma_{\varepsilon}^2$: estimația ML este exact zero cu probabilitate pozitivă chiar dacă $q > 0$
Shephard și Harvey (1990)
 - ▶ scorul în $q = 0$ este adesea negativ, pentru că un trend neted se potrivește datelor mai bine decât unul care rătăcește puțin
- ▣ Consecințele
 - ▶ intervalul de încredere calculat din hessiană nu este valid
 - ▶ testul LR pentru $q = 0$ nu este χ_1^2 , nici măcar $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$: modelul sub alternativă este nestaționar
 - ▶ remedii: estimarea median-nedeplasată a varianței coeficienților Stock și Watson (1998); bootstrap parametric pentru statistica LR (secțiunea TVP); distribuții a priori care țin q departe de zero
- ▣ Aceeași problemă apare în regresii TVP (este coeficientul constant?) și în modelele UC (este trendul determinist?)

Cît de des este varianța estimată a nivelului exact zero?



- Cîte 4 000 de serii local level simulate de lungime $T = 100$ pentru fiecare q adevărat; ML pentru q pe o grilă fină, cu σ_ϵ^2 eliminat prin concentrare

Interpretarea simulării pile-up

- ▣ Pentru $q = 0$ adevărat: 64% dintre estimări sînt exact zero; restul se împrăștie pe mai multe ordine de mărime
- ▣ Pentru $q = 0,01$: tot 14% zerouri; mediana estimațiilor este 0,0077; pentru $q = 0,05$: 2% zerouri
- ▣ Un $\hat{\sigma}_\eta^2 = 0$ raportat nu este deci o dovadă a unui nivel constant; o valoare pozitivă mică este compatibilă cu un nivel determinist
- ▣ Raportați verosimilitatea profil sau distribuția a posteriori a lui q , nu o estimatie punctuală cu o eroare standard din hessiană

Eşantionarea stărilor



Portret identificat tradițional cu Thomas
Bayes (identificare incertă)

Portret: autor necunoscut; domeniu public;

[Wikimedia Commons](#)

- Ținta: $p(\alpha_1, \dots, \alpha_n, \psi | Y_n)$; filtrul dă $p(\alpha_t | Y_t, \psi)$ doar pentru un t și un ψ
- Eşantionatorul Gibbs: alternăm $\alpha_{1:n} \sim p(\alpha_{1:n} | \psi, Y_n)$ și $\psi \sim p(\psi | \alpha_{1:n}, Y_n)$; dată fiind starea, ψ este adesea o problemă de regresie conjugată
- Incertitudinea despre ψ intră în benzile stărilor (benzile ML o ignoră)
- Funcțiile de traiectorii întregi devin ușor de calculat: data unui maxim, probabilitatea ca un trend să rămână într-o bandă-țintă
- Eşantionarea întregii traiectorii într-un singur bloc (nu câte un α_t) asigură o bună amestecare (mixing) a eşantionatorului

Filtrare înainte, eşantionare înapoi

- Factorizarea: $p(\alpha_{1:n}|Y_n) = p(\alpha_n|Y_n) \prod_{t=1}^{n-1} p(\alpha_t|\alpha_{t+1}, Y_t)$ (proprietatea Markov a stării)
- Înainte: rulăm filtrul și păstrăm $a_{t|t}, P_{t|t}$; extragem $\alpha_n \sim N(a_{n|n}, P_{n|n})$ [Carter și Kohn \(1994\)](#), [Frühwirth-Schnatter \(1994\)](#)
- Înapoi: $\alpha_t|\alpha_{t+1}, Y_t \sim N(m_t, S_t)$ din leamnă, cu câștigul de netezire $G_t = P_{t|t} T_t' P_{t+1}^{-1}$ (m_t, S_t : media și varianța condiționate):
 - $m_t = a_{t|t} + G_t(\alpha_{t+1} - c_t - T_t a_{t|t}), \quad S_t = P_{t|t} - G_t T_t P_{t|t}$
- Probleme: P_{t+1} este singulară când $R_t Q_t R_t'$ este singulară (laguri în stare): folosim doar rîndurile cu șocuri; n extrageri de dimensiune m
- Același rezultat ca pasul Gibbs din eşantionatoarele BVAR și DFM din [Capitolul 5](#)


Simulation smoother-ul Durbin–Koopman

- ▣ Ideea [Durbin și Koopman \(2002\)](#): $\alpha - \hat{\alpha}(y)$ are aceeași distribuție condiționată pentru orice y (modelul gaussian): o simulăm o singură dată din model
- ▣ Algoritmul (corecția mediei):
 - ▶ 1. extragem $\alpha_{1:n}^+, y_{1:n}^+$ din model (șocuri și stare inițială); păstrăm structura valorilor lipsă din y
 - ▶ 2. rulăm o singură dată netezitorul stărilor pe $y - y^+$ (termeni liberi nuli): $\hat{\alpha}(y - y^+) = \hat{\alpha}(y) - \hat{\alpha}(y^+)$
 - ▶ 3. $\tilde{\alpha} = \alpha^+ + \hat{\alpha}(y) - \hat{\alpha}(y^+)$ este o extragere din $p(\alpha|Y_n)$
- ▣ Este nevoie doar de netezitorul mediei: fără inversarea lui $P_{t|t}$, fără probleme de singularitate, stările difuze sînt tratate de netezitorul difuz exact (demonstrația: [▶ Anexa](#))
- ▣ Precursor: simulation smoother-ul perturbațiilor din [de Jong și Shephard \(1995\)](#); aceeași idee pentru perturbațiile ε_t, η_t

Eşantionarea pe baza matricei de precizie

- ▣ Scriem modelul matriceal [Chan și Jeliaskov \(2009\)](#): $y = X\alpha + \varepsilon$, $D\alpha = \eta$
 - ▶ D : o matrice de diferențe în bandă (diferențe de ordinul întâi pentru un mers aleator)
 - ▶ atunci $\alpha|y \sim N(\hat{\alpha}, K^{-1})$, cu $K = D'\Sigma_\eta^{-1}D + X'\Sigma_\varepsilon^{-1}X$
- ▣ K este în bandă (tridiagonală pentru un mers aleator): un singur factor Cholesky în bandă $K = U'U$ costă $O(n)$
 - ▶ α , y : toate stările și observațiile așezate una sub alta; X : matricea bloc-diagonală a lui Z_t ; Σ_ε , Σ_η : covarianțele zgomotelor; K : precizia a posteriori (inversa covarianței)
 - ▶ $\hat{\alpha}$ rezolvă $K\hat{\alpha} = X'\Sigma_\varepsilon^{-1}y$; o extragere este $\hat{\alpha} + U^{-1}z$, $z \sim N(0, I)$
- ▣ Varianțele variabile în timp (volatilitatea stochastică) schimbă doar ponderile de pe diagonală: ideal în eşantionatoarele Gibbs pentru UC-SV și SV
- ▣ Trei eşantionatoare, o singură țintă: FFBS, DK și eşantionarea pe baza preciziei extrag din aceeași $p(\alpha|Y_n, \psi)$; diferă prin cost și generalitate

Trei eșantionatoare pentru aceeași distribuție a posteriori



- Local level pentru inflația din SUA la varianțele ML, a priori propriu $\mu_1 \sim N(y_1, 100)$; stînga: abaterea standard a 2000 de extrageri față de netezitorul exact; dreapta: timpul pe extragere pentru eșantioane simulate


Interpretarea celor trei eșantionatoare

- ▣ Rapoartele dintre abaterea standard a extragerilor și cea exactă se află în $[0,94; 1,05]$ (FFBS), $[0,96; 1,05]$ (DK) și $[0,95; 1,04]$ (precizie): doar zgomot Monte Carlo
- ▣ Cea mai mare eroare a mediilor extragerilor: 0,031; 0,027; 0,039, de ordinul erorii standard Monte Carlo
- ▣ Pentru $T = 4000$: 89,2 ms (FFBS), 68,8 ms (DK), 0,19 ms (precizie) pe extragere; toate sînt liniare în T , rezolvarea în bandă nu are buclă Python
- ▣ Alegeți DK pentru modele generale cu stări difuze și eșantionarea pe baza preciziei pentru mersuri aleatoare cu varianțe variabile în timp

Un eşantionator Gibbs pentru modelul local level

- ▣ Modelul: $y_t = \mu_t + \varepsilon_t$, $\mu_{t+1} = \mu_t + \eta_t$; μ_t : nivelul; $IG(a_0, b_0)$: distribuția a priori inverse gamma cu formă a_0 și scală b_0 ; $q = \sigma_\eta^2 / \sigma_\varepsilon^2$
- ▣ Blocul 1: $\mu_{1:n} | \sigma_\varepsilon^2, \sigma_\eta^2, Y_n$ prin simulation smoother-ul DK (cu μ_1 difuz exact)
- ▣ Blocul 2: $\sigma_\varepsilon^2 | \mu, Y_n \sim IG(a_0 + \frac{n}{2}, b_0 + \frac{1}{2} \sum_t (y_t - \mu_t)^2)$; $\sigma_\eta^2 | \mu \sim IG(a_0 + \frac{n-1}{2}, b_0 + \frac{1}{2} \sum_t (\Delta \mu_t)^2)$
- ▣ A priori $IG(2,5; 0,25)$ pentru ambele: propriu, slab și exclude exact $\sigma_\eta^2 = 0$
 - distribuția a priori nu este neutră lângă frontieră: un IG conjugat împinge în sus varianțele mici; parametrizarea necentrată din [Frühwirth-Schnatter și Wagner \(2010\)](#) permite în schimb o distribuție a priori Normală pentru $\pm \sigma_\eta$
- ▣ Convergența: grafice ale traiectoriilor, mai multe lanțuri, factorul de ineficiență $1 + 2 \sum_k \rho_k$ (ponderi Parzen): numărul de extrageri care valorează cât o extragere independentă [Kim, Shephard și Chib \(1998\)](#)

Distribuția a posteriori Gibbs a raportului semnal-zgomot



- Inflația din SUA, local level, 5 000 de extrageri după perioada de ardere; stînga: distribuția a posteriori a lui $\log_{10} q$ și valoarea ML; dreapta: traiectoriile celor două varianțe

Interpretarea rezultatelor Gibbs

- ▣ Mediana a posteriori a lui q : 0,84, intervalul de credibilitate de 90% [0,52; 1,42]; ML: 0,88
- ▣ Mediile a posteriori 0,515 și 0,441 față de ML 0,517 și 0,453: cu $n = 294$, a priori contează foarte puțin departe de frontieră
- ▣ Factorii de ineficiență 9,9 și 11,3: extragerile varianțelor moștenesc autocorelația extragerilor stărilor
- ▣ Intervalul pentru q exclude zero: trendul inflației din SUA se mișcă, dar capătul superior al intervalului este de 2,7 ori mai mare decât cel inferior

Modelul de volatilitate stocastică



Neil Shephard, 2004

Foto: Renate Schmid (2004), MFO; CC

BY-SA 2.0 de; Wikimedia Commons

- $y_t = \exp(h_t/2) \epsilon_t$, $h_{t+1} = \mu + \phi(h_t - \mu) + \sigma_\eta \eta_t$, $\epsilon_t, \eta_t \sim \text{i.i.d. } N(0, 1)$ Taylor (1994)
- h_t : logaritmul varianței, o stare latentă AR(1); ϕ : persistența; σ_η : volatilitatea volatilității; $\exp(\mu/2)$: volatilitatea tipică
- Un model în spațiul stărilor cu ecuația de măsurare neliniară: filtrul Kalman nu se aplică direct
- Corespondentul în timp continuu: logaritmul varianței ca proces Ornstein–Uhlenbeck (evaluarea opțiunilor, măsurile realizate din Capitolul 8)

Volatilitatea stochastică nu este GARCH (1/2)

- GARCH [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha y_{t-1}^2 + \beta \sigma_{t-1}^2$, $\omega > 0$, $\alpha, \beta \geq 0$
 - ▶ σ_t^2 este cunoscută la $t - 1$ (o funcție de randamentele trecute): o singură sursă de aleatoriu
 - ▶ verosimilitatea este un produs de densități cunoscute: o singură trecere, ML exact
- SV: h_t are propriul șoc η_t ; chiar cu toate randamentele trecute, varianța de azi este incertă
 - ▶ $p(y_{1:n}|\psi) = \int \prod_t N(y_t; 0, e^{h_t}) p(h_{1:n}|\psi) dh_{1:n}$: o integrală n -dimensională fără formă închisă
- Compararea pe scala verosimilității este posibilă doar după calculul integralei: filtrul de particule (secțiunea următoare) sau eșantionarea prin importanță [Kim, Shephard și Chib \(1998\)](#)

Volatilitatea stocastică nu este GARCH (2/2)

- Momentele, cu $\sigma_h^2 = \sigma_\eta^2 / (1 - \phi^2)$ varianța necondiționată a lui h_t
 - ▶ kurtosis-ul lui y_t : $3 \exp(\sigma_h^2) > 3$ chiar cu ϵ_t gaussian: cozile groase provin din varianța aleatoare
 - ▶ $\text{Corr}(y_t^2, y_{t-k}^2) = (e^{\sigma_h^2 \phi^k} - 1) / (3e^{\sigma_h^2} - 1)$: volatility clustering care scade odată cu ϕ^k
- Efectul de levier intră prin $\text{Corr}(\epsilon_t, \eta_t) = \rho < 0$ [Omori, Chib, Shephard și Nakajima \(2007\)](#); GARCH are nevoie de un termen asimetric pentru același efect

O formă liniară în spațiul stărilor: logaritmul pătratelor randamentelor

- ▣ $y_t^* = \ln y_t^2 = h_t + \xi_t$, $\xi_t = \ln \epsilon_t^2$: liniar în h_t , dar ξ_t are o lege $\ln \chi_1^2$ cu media $-1,2704$ și varianța $\pi^2/2 \approx 4,93$
- ▣ QML [Harvey, Ruiz și Shephard \(1994\)](#): rulăm filtrul Kalman ca și cum ξ_t ar fi $N(-1,2704; \pi^2/2)$; consistent, dar ineficient
 - ▶ y_t^* este ARMA(1,1): $\text{Corr}(y_t^*, y_{t-k}^*) = \phi^k \sigma_h^2 / (\sigma_h^2 + \pi^2/2)$, mică pentru că zgomotul domină semnalul
- ▣ Randamentele nule: $\ln 0 = -\infty$; folosim $y_t^* = \ln(y_t^2 + c)$ cu o constantă mică c (aici $c = 10^{-3} \text{Var}(y)$, scalată la serie)
- ▣ Extensia multivariată a aceleiași idei: modele SV factoriale [Harvey, Ruiz și Shephard \(1994\)](#)


Mixtura KSC: un model condiționat gaussian

- Kim, Shephard și Chib (1998): aproximăm $\ln \chi_1^2$ printr-o mixtură de șapte distribuții Normale; dată componenta s_t , modelul este liniar și gaussian
- $y_t^* = h_t + m_{s_t} - 1,2704 + \sqrt{v_{s_t}} u_t$, $u_t \sim N(0, 1)$, $P(s_t = i) = p_i$; $s_t \in \{1, \dots, 7\}$: componenta; p_i , m_i , v_i : probabilitatea, media și varianța ei (tabelul)
- Media mixturii $-1,2704$ și varianța $4,935$, față de $-1,2704$ și $4,935$ pentru legea exactă
- Eroarea de aproximare rămasă se poate elimina prin reponderarea extragerilor (ponderi de importanță) Kim, Shephard și Chib (1998); mixturi mai fine cu 10 componente Omori, Chib, Shephard și Nakajima (2007)

i	p_i	m_i	v_i
1	0,00730	-10,12999	5,79596
2	0,10556	-3,97281	2,61369
3	0,00002	-8,56686	5,17950
4	0,04395	2,77786	0,16735
5	0,34001	0,61942	0,64009
6	0,24566	1,79518	0,34023
7	0,25750	-1,08819	1,26261

- Sursa: Kim, Shephard și Chib (1998), tabelul 4

Legea log chi-pătrat și aproximările ei



- Stînga: densitatea lui $\ln \epsilon^2$ (exactă), mixtura KSC și distribuția Normală cu aceleași două momente folosită de QML; dreapta: cele două erori de aproximare


Interpretarea aproximării prin mixtură

- Legea are o asimetrie puternică la stînga: randamentele mici produc valori foarte negative pentru $\ln y_t^2$; aproximarea prin distribuția Normală ratează atît asimetria, cît și vîrfurile
- Cea mai mare eroare a densității: 0,010 pentru mixtură, 0,096 pentru distribuția Normală (QML)
- QML tratează un zgomot asimetric ca pe unul simetric: filtrul reacționează excesiv la randamentele apropiate de zero; mixtura corectează acest lucru cu prețul unui bloc Gibbs suplimentar

Eșantionarea Gibbs a modelului SV

- Blocul 1: $s_t | y_t^*, h_t$ independent, $P(s_t = i) \propto p_i N(y_t^* - h_t; m_i - 1,2704, v_i)$
- Blocul 2: $h_{1:n} | s, \psi, y^*$ într-o singură extragere: un model liniar gaussian cu varianțe de măsurare cunoscute și variabile în timp v_{s_t} (precizie sau DK)
- Blocul 3: $\sigma_\eta^2 | h, \mu, \phi$ invers gamma; ϕ prin Metropolis–Hastings, cu regresia AR(1) ca propunere; μ din distribuția Normală
- Distribuțiile a priori [Kim, Shephard și Chib \(1998\)](#): $(\phi + 1)/2 \sim \text{Beta}(20; 1,5)$, $\sigma_\eta^2 \sim \text{IG}(2,5; 0,025)$, $\mu \sim N(0, 10)$
- Eșantionatoarele cu o singură mișcare (cîte un h_t , [Jacquier, Polson și Rossi \(1994\)](#)) au o amestecare (mixing) foarte lentă, pentru că valorile consecutive h_t sînt puternic corelate: eșantionați traiectoria ca bloc

Volatilitatea stocastică pentru S&P 500 și BET



- Randamente logaritmice zilnice în %, centrate, 2016–2026 ($T = 2692$ și 2675); eşantionatorul Gibbs KSC, 20 000 de extrageri; GARCH(1,1) prin ML pe aceleași date

Interpretarea estimațiilor SV

Indice	ϕ	σ_η	μ	inef. ϕ, σ_η	GARCH $\alpha + \beta$	corel. vol.
S&P 500	0,963	0,289	-0,465	49 / 98	0,967	0,91
BET	0,914	0,393	-0,624	58 / 87	0,952	0,84

- Intervalele de 90% pentru ϕ : [0,950; 0,975] (S&P 500), [0,888; 0,938] (BET): logaritmul varianței este foarte persistent, ca în Kim, Shephard și Chib (1998)
- Cele două traiectorii ale volatilității sînt apropiate (corelația din ultima coloană), dar SV reacționează mai puțin decît GARCH la un singur randament mare, la care varianța GARCH sare cu αy_{t-1}^2
- Factorii de ineficiență mari pentru σ_η sînt tipici: σ_η și traiectoria $h_{1:n}$ sînt puternic dependente; sînt necesare lanțuri lungi sau tehnici de interweaving
- Kurtosis-ul randamentelor: 19,5 (S&P 500) și 20,8 (BET); cu ϵ_t gaussian, SV explică doar o parte (extensia uzuală: erori SV- t)

Filtrul Bayes

- ▣ Modelul general: $y_t \sim g(y_t|x_t, \psi)$, $x_t \sim f(x_t|x_{t-1}, \psi)$; g : densitatea de măsurare, f : densitatea de tranziție, x_t : starea; ținta: $p(x_t|Y_t)$ și $p(y_t|Y_{t-1})$
- ▣ Predicția: $p(x_t|Y_{t-1}) = \int f(x_t|x_{t-1}) p(x_{t-1}|Y_{t-1}) dx_{t-1}$
- ▣ Actualizarea: $p(x_t|Y_t) = g(y_t|x_t) p(x_t|Y_{t-1})/p(y_t|Y_{t-1})$, $p(y_t|Y_{t-1}) = \int g(y_t|x_t) p(x_t|Y_{t-1}) dx_t$
- ▣ Formă închisă doar în două cazuri: liniar gaussian (Kalman) și spații finite de stări (filtrul Hamilton al modelelor Markov switching, [Capitolul 7](#))
 - ▶ altfel: aproximăm modelul (EKF), aproximăm densitățile prin puncte (UKF) sau prin eșantioane ponderate (filtre de particule)


Filtrul Kalman extins

- Modelul neliniar $y_t = Z(x_t) + \varepsilon_t$, $x_{t+1} = T(x_t) + R\eta_t$: liniarizăm în jurul estimațiilor curente, $\dot{Z}_t = \partial Z / \partial x|_{a_t}$, $\dot{T}_t = \partial T / \partial x|_{a_t|_t}$
- Rulăm recursiile Kalman cu $\dot{Z}_t$, $\dot{T}_t$ pentru varianțe și cu funcțiile exacte pentru medii [Durbin și Koopman \(2012\)](#), secțiunea 10.2
- Un eșec instructiv: în SV, $\mathbb{E}(y_t|h_t) = 0$ pentru orice h_t , deci $\partial \mathbb{E}(y_t|h_t) / \partial h_t = 0$: câștigul EKF este zero, iar filtrul nu învață niciodată h_t
 - informația despre h_t se află în y_t^2 , un moment de ordinul doi; liniarizarea păstrează doar momentele de ordinul întâi
- Regula: transformăm întâi modelul ($\ln y_t^2$) sau folosim o metodă care propagă întreaga distribuție

Filtrul Kalman unscented

- ▣ Transformarea unscented [Julier și Uhlmann \(2004\)](#): $N(m, P)$ în n dimensiuni este reprezentată prin $2n + 1$ puncte sigma
 - ▶ $\mathcal{X}_0 = m$, $\mathcal{X}_{\pm i} = m \pm (\sqrt{(n + \lambda)P})_i; (\sqrt{A})_i$: coloana i a unei rădăcini pătrate a matricei
 - ▶ ponderile $w_0 = \lambda/(n + \lambda)$, $w_{\pm i} = 1/(2(n + \lambda))$; λ : un parametru de împrăștiere
 - ▶ trecem fiecare punct prin g și calculăm medii și covarianțe ponderate
- ▣ Exactă pentru medie pînă la ordinul doi al dezvoltării Taylor a lui g (EKF: ordinul întâi); nu sînt necesari iacobieni
- ▣ UKF: aplicăm transformarea în pasul de predicție și în cel de actualizare; cost similar cu EKF
- ▣ Rămîne gaussian la fiecare pas: densitățile de filtrare multimodale sau cu cozi groase cer particule

Liniaizarea față de transformarea unscented



- Volatilitatea din logaritmul varianței: media și abaterea standard a lui $\exp(h/2)$ pentru $h \sim N(0, s^2)$; momentele lognormale exacte, liniaizarea de ordinul întâi (EKF) și transformarea unscented cu trei puncte sigma

Interpretarea transformării unscented

- Pentru $s = 1$: media exactă 1,131, liniarizarea 1,000, unscented 1,131; abaterea standard exactă 0,598, liniarizarea 0,496, unscented 0,618
- Liniarizarea ignoră convexitatea funcției exp: subestimează volatilitatea așteptată, cu atât mai mult cu cât h este mai incert
- Trei puncte sigma surprind convexitatea aproape exact pentru medie; varianța se abate pentru valori mari ale lui s
- Aceeași deplasare apare în practică: o prognoză EKF a volatilității sau a prețului unei opțiuni este prea mică atunci când starea este incertă

Filtre de particule



Stanisław Ulam cu FERMIAC, un dispozitiv Monte Carlo


Foto: Los Alamos National Laboratory
(LA-UR-00-2532); public domain; Wikimedia
Commons

- Reprezentăm $p(x_t|Y_t)$ prin particule $x_t^{(i)}$ cu ponderi $W_t^{(i)}$, $i = 1, \dots, N$; metoda Monte Carlo provine de la Ulam și Metropolis (1949)
- Filtrul bootstrap Gordon, Salmond și Smith (1993), Kitagawa (1996)
 - ▶ propagăm: $x_t^{(i)} \sim f(\cdot|x_{t-1}^{(i)})$
 - ▶ ponderăm: $w_t^{(i)} = g(y_t|x_t^{(i)})$
 - ▶ reeșantionăm N particule cu probabilitățile $W_t^{(i)} \propto w_t^{(i)}$
- Fără reeșantionare ponderile degenerază (o singură particulă preia toată ponderea); mărimea efectivă a eșantionului $ESS_t = 1 / \sum_i (W_t^{(i)})^2$
- Reeșantionarea sistematică: o singură variabilă uniformă U , punctele $(U + i - 1)/N$ pe ponderile cumulate: varianță mai mică decât reeșantionarea multinomială

Verosimilitatea din filtrul de particule

- ▣ $\hat{p}(y_t|Y_{t-1}) = \frac{1}{N} \sum_i w_t^{(i)}$ și $\hat{L}(\psi) = \prod_t \hat{p}(y_t|Y_{t-1})$
- ▣ $\mathbb{E} \hat{L}(\psi) = L(\psi)$ exact, pentru orice $N \geq 1$ Del Moral (2004) (▶ Anexa)
 - ▶ $\hat{L}$ este nedeplasat pe scala nivelului
 - ▶ nu și pe scala logaritmică: dacă $\ln \hat{L} \approx N(\ln L - \tau^2/2, \tau^2)$, atunci $\mathbb{E} \ln \hat{L} = \ln L - \tau^2/2$; $\tau^2 = \text{Var} \ln \hat{L}$
- ▣ $\text{Var} \ln \hat{L}$ crește aproximativ liniar în n și scade ca $1/N$: un eșantion de două ori mai lung cere de două ori mai multe particule
- ▣ $\hat{L}(\psi)$ nu este netedă în ψ (reeșantionarea este discontinuă): nu o maximizați prin metode de gradient; folosiți-o într-un MCMC

Filtrul de particule pentru modelul SV al S&P 500



- Stînga: volatilitatea filtrată $E[\exp(h_t/2) | Y_t]$ (filtrul bootstrap, $N = 20\,000$, media a posteriori Gibbs pentru ψ) față de GARCH(1,1) și traiectoria SV netezită, ultimii doi ani; dreapta: estimații ale log-verosimilității, cîte 100 de rulări pentru fiecare N


Interpretarea filtrului de particule

- ▣ Abaterea standard Monte Carlo a lui $\ln \hat{L}$: 4,19 ($N = 100$), 2,38 ($N = 500$), 1,14 ($N = 2000$); un N mic deplasează și $\ln \hat{L}$ în jos
- ▣ Log-verosimilitatea SV $-3378,8$ față de maximul GARCH(1,1) $-3467,3$: o diferență de 88,5 cu același număr de parametri
- ▣ Comparăția favorizează SV chiar și la media a posteriori (nu la maximul) verosimilității sale; Kim, Shephard și Chib (1998) compară SV cu modelele ARCH pe aceeași scală a verosimilității
- ▣ Volatilitatea SV filtrată este o estimăție unilaterală, ca GARCH: corelația 0,96; traiectoria netezită anticipează punctele de întoarcere pentru că folosește date viitoare
- ▣ Mărimea efectivă a eșantionului pe parcursul eșantionului: minimum 150, mediana 18719 din 20 000 de particule

Filtrul de particule auxiliar

- ▣ Slăbiciunea filtrului bootstrap: particulele sînt propagate fără a ține cont de y_t ; o valoare extremă lasă puține particule cu pondere
- ▣ APF Pitt și Shephard (1999): privim înainte de propagare
 - ▶ prima etapă: reeșantionăm $x_{t-1}^{(i)}$ cu ponderi $\propto W_{t-1}^{(i)} g(y_t | \mu_t^{(i)})$, $\mu_t^{(i)} = \mathbb{E}(x_t | x_{t-1}^{(i)})$
 - ▶ a doua etapă: propagăm, apoi ponderăm cu $g(y_t | x_t^{(i)}) / g(y_t | \mu_t^{(k_i)})$ pentru a corecta privirea înainte
 - ▶ k_i : indicele particulei alese în prima etapă
- ▣ Cazul complet adaptat: ponderi în prima etapă $p(y_t | x_{t-1})$ și propunerea $p(x_t | x_{t-1}, y_t)$: ponderile din etapa a doua sînt egale (optim local)
- ▣ Estimația verosimilității rămîne nedeplasată: $\hat{p}(y_t | Y_{t-1}) = (\sum_i W_{t-1}^{(i)} g(y_t | \mu_t^{(i)})) \cdot \frac{1}{N} \sum_i \omega_t^{(i)}$; $\omega_t^{(i)}$: ponderile din etapa a doua

Verosimilitățile din filtrele de particule față de verosimilitatea Kalman exactă



- Modelul local level pentru inflația din SUA, la varianțele ML: eroarea lui $\ln \hat{L}$ (condiționat de y_1) pentru filtrul bootstrap și pentru cel auxiliar, câte 200 de rulări pentru fiecare N


Interpretarea verificării filtrelor de particule

- ▣ Eroarea medie a lui $\ln \hat{L}$: $-14,37$; $-4,48$; $-1,30$ (bootstrap, $N = 50, 200, 1000$) și $-9,37$; $-2,87$; $-0,88$ (auxiliar)
- ▣ Abaterile standard: $1,46$ (bootstrap) și $1,17$ (auxiliar) pentru $N = 1000$: privirea înainte crește precizia, pentru că raportul semnal-zgomot este mare
- ▣ Media negativă este deplasarea Jensen a logaritmului unui estimator nedeplasat: scade ca $\text{Var}(\ln \hat{L})/2$
- ▣ Testați întotdeauna un filtru de particule pe un model cu verosimilitate cunoscută înainte de a-l folosi acolo unde aceasta nu este disponibilă

Particle MCMC

- ▣ Ideea pseudo-marginală [Andrieu și Roberts \(2009\)](#): rulăm Metropolis–Hastings cu o estimatie nedeplasată și pozitivă $\hat{L}(\psi)$ în locul lui $L(\psi)$; lanțul are ca țintă tot distribuția a posteriori exactă $p(\psi|Y_n)$
- ▣ PMMH [Andrieu, Doucet și Holenstein \(2010\)](#)
 - ▶ propunem ψ' din densitatea de propunere $q(\cdot|\psi)$; rulăm un filtru de particule pentru $\hat{L}(\psi')$
 - ▶ acceptăm cu probabilitatea $\min\{1, \hat{L}(\psi')p(\psi')q(\psi|\psi')/[\hat{L}(\psi)p(\psi)q(\psi'|\psi)]\}$; $p(\cdot)$: distribuția a priori
 - ▶ păstrăm $\hat{L}$ al punctului curent (nu îl recalculăm)
- ▣ Alegerea lui N [Pitt, Silva, Giordani și Kohn \(2012\)](#), [Doucet, Pitt, Deligiannidis și Kohn \(2015\)](#)
 - ▶ prea puține particule blochează lanțul; prea multe iroiesc timpul
 - ▶ ținta: $\text{Var}(\ln \hat{L}) \approx 1\text{--}2$ la media a posteriori
 - ▶ particle Gibbs (SMC condiționat) eșantionează și traiectoria stării; util atunci când nu există o structură condiționat gaussiană
- ▣ Funcționează pentru orice model pe care îl puteți simula și a cărei densitate de măsurare o puteți evalua: SV cu salturi, modele DSGE, modele UC neliniare

PMMH față de eșantionatorul Gibbs KSC



- Ultimele 1000 de randamente S&P 500; PMMH cu un filtru bootstrap de $N = 600$ particule, 10 000 de iterații, mers aleator pe $(\mu, \tanh \phi, \ln \sigma_{\eta})$; Gibbs cu mixtura KSC


Interpretarea rulării PMMH

- ▣ Mediile a posteriori ale lui ϕ : 0,955 (Gibbs) și 0,955 (PMMH); ale lui σ_η : 0,219 și 0,216; abaterile standard a posteriori 0,037 și 0,039
- ▣ Doi algoritmi exacti, aceeași distribuție a posteriori: aproximarea prin mixtura KSC nu are aici un efect vizibil
- ▣ $N = 600$ dă o abatere standard a lui $\ln \hat{L}$ de 1,19 la media a posteriori, în intervalul recomandat; rata de acceptare este 13%
- ▣ Costul: 3,6 minute pentru PMMH, față de cîteva secunde pentru Gibbs: folosiți PMMH cînd nu există o reprezentare condiționat gaussiană

O regresie TVP în forma în spațiul stărilor

- $y_t = c_t + b_t x_t + D_t' \gamma + \varepsilon_t$, $c_{t+1} = c_t + \eta_{c,t}$, $b_{t+1} = b_t + \eta_{b,t}$
 - ▶ c_t, b_t : termenul liber și panta, mersuri aleatoare cu varianțele σ_c^2, σ_b^2 ; D_t : variabile dummy cu γ fix
 - ▶ starea $\alpha_t = (c_t, b_t, \gamma')'$; $Z_t = (1, x_t, D_t')$
- Coeficienții ficși (γ , aici variabile dummy sezoniere trimestriale) sînt stări cu varianță zero și start difuz: $d =$ numărul stărilor = 5
 - ▶ cu $\sigma_c^2 = \sigma_b^2 = 0$, netezitorul dă estimațiile OLS (cele mai mici pătrate recursive)
- Întrebarea: s-a schimbat co-mișcarea inflației din România cu inflația din zona euro de la introducerea țintirii inflației (2005)?
- y_t : inflația IAPC din România, trimestrial, % anualizat, neajustată sezonier; x_t : inflația IAPC din zona euro fără componenta sezonieră; T4 2005–T2 2026, $T = 83$
- Testul pantei constante: $H_0: \sigma_b^2 = 0$ pe frontieră; bootstrap parametric pentru statistica LR din modelul restricționat (199 de eșantioane)

Inflația din România și inflația din zona euro: o pantă variabilă în timp?



- Sus: cele două rate ale inflației; jos: b_t netezit cu o bandă de 90% (ML difuz exact) și panta unei regresii mobile pe 12 trimestre cu aceleași variabile dummy

Interpretarea regresiei TVP

- ▣ ML: $\hat{\sigma}_c^2 = 0,332$, $\hat{\sigma}_b^2 = 0,0011$, $\hat{\sigma}_\varepsilon^2 = 7,21$; log-verosimilitățile numpy și statsmodels sînt $-209,93$ și $-209,93$
- ▣ b_t se deplasează de la 0,76 (eroare standard 0,23) în T3 2008 la 0,89 (eroare standard 0,17) în T4 2022: o pantă apropiată de unu, dar fără o schimbare semnificativă
- ▣ LR = 0,066; p-value-ul bootstrap = 0,265 (cuantila de 95% este 1,91; 66% dintre statisticile bootstrap sînt exact zero: din nou pile-up); regula $\frac{1}{2}\chi_1^2$ dă $p = 0,399$
- ▣ Regresia mobilă oscilează între valori negative și 1,5: acesta este zgomotul de eșantionare al ferestrelor de 12 trimestre, nu variație în timp; modelul în spațiul stărilor îl mediază printr-o varianță explicită

TVP-VAR cu volatilitate stocastică



Thomas J. Sargent, 2011

Foto: Holger Motzkau (2011); CC BY-SA
3.0; Wikimedia Commons

- Cogley și Sargent (2001), Cogley și Sargent (2005), Primiceri (2005):
$$y_t = X_t' \beta_t + A_t^{-1} \Sigma_t \epsilon_t$$
 - ▶ X_t : lagurile; β_t : coeficienții; $\epsilon_t \sim N(0, I)$
 - ▶ A_t : inferior triunghiulară, cu elementele libere a_t ; $\Sigma_t = \text{diag}(\sigma_{j,t})$
 - ▶ β_t , a_t și $\ln \sigma_{j,t}$ urmează mersuri aleatoare
- Întrebarea: s-a schimbat politica monetară a SUA (coeficienți care derivă) sau s-au micșorat șocurile (volatilități în scădere) după 1980?
- Răspunsul din Primiceri (2005): reacția sistematică a politicii monetare s-a schimbat, dar aceste schimbări explică puțin din anii 1970; varianța șocurilor care nu țin de politica monetară contează mai mult
- Fără volatilitate stocastică, scăderea varianțelor șocurilor este atribuită greșit schimbării coeficienților

Estimarea unui TVP-VAR-SV

- Blocurile Gibbs, fiecare fiind unul dintre eșantionatoarele din acest capitol:
 - ▶ $\beta_{1:n}$ | rest: simulation smoother pentru un model liniar gaussian cu covarianțe cunoscute, variabile în timp
 - ▶ $a_{1:n}$ | rest: ecuație cu ecuație, același netezitor
 - ▶ $\ln \sigma_{j,1:n}$ | rest: mixtura KSC cu indicatorii ei
 - ▶ covarianțele măsurilor aleatoare: invers Wishart
- Ordinea pașilor Gibbs contează: algoritmul inițial extrăgea indicatorii mixturii într-un punct greșit al ciclului; [Del Negro și Primiceri \(2015\)](#) dau ordinea corectă, iar rezultatele de fond se schimbă puțin
- Distribuții a priori dintr-un eșantion de antrenare de la începutul datelor, ca în [Primiceri \(2005\)](#), cu scale mici pentru covarianțele măsurilor aleatoare: a priori decide câtă variație este permisă
- Supraparametrizarea: cu k coeficienți pe ecuație, aplicăm shrinkage varianțelor sau selectăm coeficienții care variază (parametrizarea necentrată, [Frühwirth-Schnatter și Wagner \(2010\)](#))

DFM ca model în spațiul stărilor (1/2)

- $x_{it} = \lambda_i' f_t + e_{it}, \quad f_t = \Phi f_{t-1} + u_t, \quad e_{it} = \rho_i e_{i,t-1} + \nu_{it}$
 - ▶ f_t : factorii, un VAR(1) cu matricea Φ ; λ_i : ponderile factoriale ale seriei i , așezate în Λ
 - ▶ e_{it} : erori idiosincratice AR(1) cu coeficienții ρ_i ; u_t, ν_{it} : șocurile
 - ▶ starea $(f_t', f_{t-1}', e_t')'$; matricea de măsurare $Z = (\Lambda, 0, I)$
- Frecvențele mixte [Mariano și Murasawa \(2003\)](#)
 - ▶ o rată de creștere trimestrială este o sumă ponderată a stărilor lunare
 - ▶ filtrul sare pur și simplu peste lunile lipsă


DFM ca model în spațiul stărilor (2/2)

▣ Estimarea

- ▶ în doi pași [Doz, Giannone și Reichlin \(2011\)](#): componentele principale dau Λ , Φ , Σ_e ; apoi netezitorul Kalman reestimează f_t pe panelul complet; consistent când $N, T \rightarrow \infty$
- ▶ ML prin EM [Shumway și Stoffer \(1982\)](#), [Bańbura și Modugno \(2014\)](#): pasul E este netezitorul, sînt permise structuri arbitrare de date lipsă
- ▶ N mare: comprimăm cele N observații într-un vector de dimensiune r înainte de filtrare [Jungbacker și Koopman \(2015\)](#); costul nu mai crește ca N^3

- ### ▣ Nowcasting [Giannone, Reichlin și Small \(2008\)](#): ragged edge, descompunerea pe știri și evaluarea în timp real se află în [Capitolul 5](#); această secțiune arată mecanismul în spațiul stărilor

Un model cu un factor pentru indicatorii coincidenți ai SUA



- Creșterea lunară a producției industriale, a numărului de salariați, a venitului real fără transferuri și a vânzărilor reale (FRED), standardizate, ianuarie 1990–septembrie 2026; estimatorul în doi pași, tratarea univariată a vectorului de observații; ultimele 36 de luni

Interpretarea datelor incomplete la sfârșitul eșantionului (ragged edge)

- ▣ Încărcările factoriale 0,90; 0,89; 0,68; 0,84; coeficientul AR al factorului 0,12: ratele lunare de creștere sînt puțin persistente, deci factorul este în principal o medie ponderată a lunii
- ▣ Ultima lună completă este iulie 2026: abaterea standard a factorului este 0,28; în septembrie 2026, cu o singură serie din patru disponibilă, crește la 0,46
- ▣ Filtrul ponderează fiecare serie după raportul ei semnal–zgomot; nicio serie nu este eliminată, niciun gol nu este completat de mîină
- ▣ Prognoza factorului dincolo de date este aceeași recursie, cu toate observațiile lipsă

Trei definiții ale ciclului

- Beveridge–Nelson [Beveridge și Nelson \(1981\)](#): trendul = prognoza pe orizont lung fără drift
 - ▶ $\tau_t^{BN} = y_t + \sum_{j \geq 1} \mathbb{E}_t(\Delta y_{t+j} - \mu)$; ciclul $c_t^{BN} = y_t - \tau_t^{BN}$
 - ▶ $\mathbb{E}_t$: speranța condiționată de datele pînă la t ; μ : creșterea medie; trendul este nivelul la care se așteaptă să ajungă y după ce creșterea previzibilă s-a stins
 - ▶ pentru un AR(1) în creștere: $c_t^{BN} = -\frac{\phi}{1-\phi}(\Delta y_t - \mu)$; unilateral, depinde de modelul ARMA ales; versiuni fiabile: [Kamber, Morley și Wong \(2018\)](#)
- Componente neobservate [Clark \(1987\)](#), [Watson \(1986\)](#), [Harvey și Jaeger \(1993\)](#): $y_t = \tau_t + c_t$, cu trend mers aleator (sau neted) și ciclu AR(2); bilateral după netezire
- Hamilton [Hamilton \(2018\)](#): c_{t+h} = reziduul regresiei lui y_{t+h} pe $(1, y_t, \dots, y_{t-3})$, $h = 8$ trimestre; fără model și unilateral ([TSA, Capitolul 10](#))
- Pentru PIB-ul SUA ciclul BN este mic și zgomotos, ciclul UC mare și neted: aceleași date, două povești. De ce?

Componente neobservate cu șocuri corelate

▣ Morley, Nelson și Zivot (2003), modelul UC-UR

- ▶ $y_t = \tau_t + c_t$, $\tau_t = \mu + \tau_{t-1} + \eta_t$, $c_t = \phi_1 c_{t-1} + \phi_2 c_{t-2} + \varepsilon_t$, $\text{Corr}(\eta_t, \varepsilon_t) = \rho$
- ▶ τ_t : trendul stochastic cu driftul μ și șocurile η_t (abaterea standard σ_η); c_t : un ciclu AR(2) cu șocurile ε_t (abaterea standard σ_ε); ρ : corelația celor două șocuri


▣ Modelul UC0 al lui Clark impune $\rho = 0$; cu un ciclu AR(2), ρ este identificat: forma redusă este un ARIMA(2,1,2), cu tot atîția parametri cît UC-UR

- ▶ cu un ciclu AR(1), ρ nu este identificat

▣ Rezultatul: dacă ρ este liber, ciclul UC filtrat coincide cu ciclul BN al modelului ARIMA(2,1,2): diferența dintre BN și UC era restricția $\rho = 0$

▣ Starea (τ_t, c_t, c_{t-1}) : τ difuz, blocul ciclului staționar (inițializare mixtă); studiul de caz de mai jos: eșantionul lor, T1 1947–T2 1998, datele din ediția actuală

Replicarea Morley, Nelson și Zivot (2003)




- $100 \times \log$ PIB real al SUA (FRED GDPC1), $T = 206$; UC0 și UC-UR prin ML difuz exact; ciclul BN dintr-un ARIMA(2,1,2); ciclul Hamilton (2018) pentru comparație

Interpretarea replicării MNZ

Model	μ	ϕ_1	ϕ_2	σ_η	σ_ε	ρ	$\ln L$
UC0	0,858	1,501	-0,571	0,612	0,665	0	-280,81
UC-UR	0,859	1,334	-0,738	1,185	0,669	-0,927	-279,35

- ▣ $\hat{\rho} = -0,927$: șocurile trendului și ale ciclului sînt corelate negativ aproape perfect; șocurile trendului sînt mai mari decît cele ale ciclului ($\hat{\sigma}_\eta > \hat{\sigma}_\varepsilon$)
- ▣ Corelația ciclului UC-UR filtrat cu ciclul BN (coeficienții AR ai ARIMA 1,334; -0,738, ca în UC-UR): 0,999; abaterile standard ale ciclurilor: UC0 2,20, UC-UR 0,52, BN 0,52, Hamilton 3,50
- ▣ Testul LR pentru $\rho = 0$: 2,92, $p = 0,088$ (χ_1^2); ciclul UC0 este mare pentru că este presupus ortogonal pe trend, nu pentru că datele o cer
- ▣ Cifrele noastre folosesc ediția actuală a datelor PIB; estimațiile din lucrare diferă la zecimale, nu în concluzie

România: ciclul este trendul




Palatul BNR, București

Foto: Ștefan Jurcă (2015); CC BY 2.0;

[Wikimedia Commons](#)

- Economii emergente au șocuri de trend volatile [Aguiar și Gopinath \(2007\)](#): un trend de tip mers aleator absoarbe cea mai mare parte a mișcării PIB
- UC0 pentru România, T1 2000–T2 2026 (T2–T4 2020 tratate ca lipsă):
 $\hat{\sigma}_\eta = 1,897$, $\hat{\sigma}_\varepsilon = 0,950$, $\hat{\phi}_1 = 0,280$, $\hat{\phi}_2 = -0,261$: un ciclu scurt și slab
- UC-UR: $\hat{\rho} = 1,00$ la frontieră, LR = 2,92: în 106 trimestre corelația este slab determinată
- Alternativa: un trend neted (mers aleator integrat, modelul HP [Harvey și Jaeger \(1993\)](#)) cu un ciclu AR(2): $\hat{\sigma}_\zeta^2 = 0,0046$, $\hat{\sigma}_\varepsilon^2 = 4,95$, $\hat{\phi} = (0,87; 0,09)$

Output gap-ul României



- 100×log PIB real, Eurostat, ajustat sezonier și cu numărul de zile lucrătoare; UC cu trend neted (netezit, cu bandă de 90%, și filtrat), UC0 cu trend mers aleator, Hamilton (2018) pe seria completă


Interpretarea output gap-ului României

- Output gap-ul cu trend neted: 16,0% în T3 2008 (abatere standard 5,9), -5,0% în T3 2010, 5,9% în T4 2019; ultimul trimestru -2,6% (abatere standard 7,4)
- În timp real situația este alta: output gap-ul filtrat era doar 1,4% în T3 2008 și 0,3% în T4 2019; abaterea standard a revizuirilor (netezit minus filtrat): 3,8 pp [Orphanides și van Norden \(2002\)](#)
- Alegerea modelului domină: abaterea standard a output gap-ului este 4,5 (trend neted), 0,53 (UC0), 5,4 (Hamilton); corelația trend neted-Hamilton 0,65
- Un output gap pentru România fără banda lui și fără modelul din spatele lui nu este o informație

Modelul UC-SV al lui Stock și Watson (2007)

- $\pi_t = \tau_t + \sigma_{\eta,t}\eta_t$, $\tau_t = \tau_{t-1} + \sigma_{\varepsilon,t}\varepsilon_t$, $\ln \sigma_{j,t}^2 = \ln \sigma_{j,t-1}^2 + \nu_{j,t}$, $\nu_{j,t} \sim N(0, \gamma)$ **Stock și Watson (2007)**
 - ▶ π_t : inflația; τ_t : inflația de trend (un mers aleator); $\sigma_{\eta,t}$, $\sigma_{\varepsilon,t}$: abaterile standard variabile în timp ale șocurilor tranzitorii și de trend ($j \in \{\eta, \varepsilon\}$); $\eta_t, \varepsilon_t \sim N(0, 1)$
- $\gamma = 0,2$ este fixat, nu estimat: singurul parametru de calibrare; el guvernează cât de repede se pot mișca volatilitățile
 - ▶ forma redusă: IMA(1,1) cu un coeficient MA variabil în timp θ_t , funcție de $\sigma_{\varepsilon,t}/\sigma_{\eta,t}$
- Gibbs: $\tau_{1:n}$ prin eșantionarea pe baza preciziei (ponderi variabile în timp); fiecare $\ln \sigma_{j,1:n}^2$ prin mixtura KSC pe $\ln(\hat{\eta}_t^2 + c)$ și $\ln(\Delta\tau_t^2 + c)$
 - ▶ pentru România: trei coeficienți sezonieri trimestriali ca bloc Gibbs suplimentar (regresie ponderată); IAPC nu este ajustat sezonier
- Miza: ponderea șocurilor de trend decide cât dintr-un salt al inflației este permanent și cât ar trebui să extrapoleze cel care face prognoze

Inflația de trend în SUA, 1953–2026




□ Inflația deflatorului PIB, $T = 294$ trimestre; UC-SV cu $\gamma = 0,2$, eșantionator Gibbs; sus: trendul cu bandă de 68%; jos: mediile a posteriori ale lui $\sigma_{\varepsilon,t}$ (trend) și $\sigma_{\eta,t}$ (tranzitoriu)

Interpretarea inflației de trend din SUA

- Trendul: 8,9% în T1 1975, 2,1% în T1 1995, 1,4% în T4 2019, 8,0% [6,6; 8,9] în T2 2022, 5,2% [3,8; 6,0] în T2 2026
- Șocurile de trend: abaterea standard 1,60 în 1975, 0,19 în 1995, 1,42 în 2022; șocurile tranzitorii: 0,88; 0,20; 0,90
- Coeficientul MA implicit θ_t : $-0,20$ (1975), $-0,39$ (1995), $-0,37$ (2019), $-0,24$ (2022): inflația a devenit din nou mai apropiată de un mers aleator în 2021–2022
- Aceasta este lecția de prognoză din [Stock și Watson \(2007\)](#): în perioade calme netezim puternic; când volatilitatea trendului crește, un model cu coeficienți fiși reacționează prea lent

Inflația de trend din România și ținta BNR



- Inflația IAPC trimestrială (medii trimestriale ale indicelui lunar), $T = 102$, T1 2001–T2 2026; UC-SV cu $\gamma = 0,2$ și variabile dummy sezoniere trimestriale; banda-țintă a BNR din 2013

Interpretarea inflației de trend din România

- ▣ Trendul: 8,4% la începutul țintirii inflației (T3 2005), -0,8% în T3 2015, 2,5% în T4 2019, 8,1% în T1 2023
- ▣ Ultimul trimestru: 7,3% [5,5; 9,0]; probabilitatea a posteriori ca trendul să se afle în intervalul 1,5–3,5%: 2%
- ▣ Din 2013, trendul s-a aflat în bandă doar o parte din timp: sub ea în 2015–2016 (reducerile de TVA), peste ea din 2021
- ▣ Rezerve: prețurile administrate (plafonările la energie, modificările TVA) intră ca șocuri de trend într-un model univariat; un proiect le poate adăuga ca regresori sau ca o componentă separată

Mai departe: BSTS și modele cu schimbare de regim

- ▣ Serii de timp structurale bayesiene [Scott și Varian \(2014\)](#): local linear trend + componentă sezonieră + regresie cu a priori spike-and-slab pe mulți regresori (Google Trends)
 - ▶ același simulation smoother într-un eșantionator Gibbs; selecția variabilelor pe blocul de regresie
 - ▶ contrafactuali pentru evaluarea politicilor (CausallImpact, [Brodersen et al. \(2015\)](#)): [Capitolul 14](#)
- ▣ Stări discrete: $s_t \in \{1, \dots, K\}$ cu un lanț Markov; filtrul Hamilton este filtrul Bayes cu sume în loc de integrale
 - ▶ modele în spațiul stărilor cu schimbare de regim (filtrul Kim, eșantionare Gibbs) [Kim și Nelson \(1999\)](#): [Capitolul 7](#)
- ▣ Evaluarea prognozelor tuturor acestor modele (prognoze de densitate, reguli de scor): [Capitolul 1](#)

O întrebare deschisă

- Cît din saltul inflației din 2021–2023 a fost o deplasare a inflației de trend, în SUA și în România, și s-a inversat aceasta?
 - ▶ formal: distribuția a posteriori a lui τ_t și a raportului $\sigma_{\varepsilon,t}/\sigma_{\eta,t}$ în UC-SV; infirmată dacă trendul a revenit la nivelul din 2019 cu probabilitate a posteriori mare sub orice specificare preînregistrată
 - ▶ răspunsul univariat depinde de un parametru fixat, γ : mini studiul de caz de mai jos
- Miza: o bancă centrală reacționează diferit la un salt tranzitoriu și la unul persistent; ancorarea este o afirmație despre trend, nu despre inflația totală
 - ▶ literatura de pornire: Stock și Watson (2007), Cogley și Sargent (2005), Primiceri (2005), Morley, Nelson și Zivot (2003)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează lucrări recenzate care estimează inflația de trend cu volatilitate stochastică pentru țări europene după 2021; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** Propune trei implicații observabile care deosebesc o deplasare a trendului de o succesiune de șocuri tranzitorii mari.
 - ▶ **cod și replicare:** cereți un eșantionator Gibbs pentru UC-SV, apoi reproduceți întâi o cifră cunoscută (trendul pentru SUA din acest curs)
 - ▶ **robustețe și critică:** Joacă rolul unui recenzent ostil: ce alegeri fixate ale unui model UC-SV ar putea schimba concluzia despre 2022?
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Eșantionatorul are ca țintă distribuția a posteriori declarată: testați-l pe un model cu răspuns cunoscut (netezitorul Kalman, ca în verificarea celor trei eșantionatoare)
- ▣ Convergența este raportată: mai multe lanțuri, factori de ineficiență, efectul dublării numărului de extrageri
- ▣ Alegerile fixate (γ , constanta KSC, distribuțiile a priori, tratarea sezonality, data de început) sînt enumerate și variate înaintea concluziilor
- ▣ Estimațiile de la finalul eșantionului sînt raportate ca valori filtrate, cu benzile lor, nu ca estimații punctuale netezite

Mini studiu de caz: un parametru fixat, patru trenduri



- Trendul UC-SV pentru SUA din 2015, pentru $\gamma \in \{0,05; 0,1; 0,2; 0,4\}$: trendul în T2 2022 7,6; 7,8; 8,0; 8,3% (inflația 9,0%); în ultimul trimestru 5,1; 5,2; 5,2; 5,1%
- Ordinea este stabilă, dar nivelul trendului din 2022 nu este: un rezumat AI care raportează „inflația de trend a atins un maxim de X%” fără γ ascunde o alegere de modelare

Idee de proiect

- ▣ **Inflația de trend și ancorarea în Europa Centrală și de Est:** întîi replicare, apoi extindere
 - ▶ replicați: trendul UC-SV pentru SUA din acest curs (T2 2022: 8,0%) și trendul pentru România (7,3% în T2 2026)
 - ▶ extindeți: România, Ungaria, Polonia și Cehia; un UC-SV multivariat cu un trend comun al zonei euro; prețurile administrate ca o componentă separată; γ estimat cu o distribuție a priori în loc să fie fixat
 - ▶ preînregistrați: datele, eșantionul, distribuțiile a priori, statistica de ancorare (probabilitatea a posteriori de a fi în banda-țintă), exercițiul în timp real și grila de robustețe
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Filtrul Kalman este condiționarea gaussiană aplicată recursiv; netezitorul, verosimilitatea și simulation smoother-ul decurg din ea
- ▣ Inițializați exact stările nestaționare; tratați varianțele nule ca probleme de frontieră
- ▣ Spațiul stărilor bayesian: eşantionați traiectorii întregi; FFBS, DK și eşantionarea pe baza preciziei sînt interschimbabile
- ▣ Volatilitatea stochastică nu este GARCH; mixtura KSC și filtrele de particule o fac tratabilă
- ▣ Mărimile latente (output gap-uri, trenduri, pante variabile în timp) au o incertitudine care depinde de model: raportați benzi, valori filtrate și alternative

Autoevaluare

Întrebări

- ▣ De ce scade nelimitat log-verosimilitatea big kappa când κ crește?
- ▣ Ce vă spune o estimatie ML $\hat{\sigma}_\eta^2 = 0$ despre un model local level?
- ▣ De ce are nevoie simulation smoother-ul DK doar de netezitorul mediei?
- ▣ De ce este zero câștigul EKF în modelul SV?
- ▣ De ce este $\ln \hat{L}$ deplasat, deși $\hat{L}$ este nedeplasat?
- ▣ Ce restricție face ca ciclul UC să difere de ciclul BN?

Urmează:

- ▣ Modele cu schimbare de regim
- ▣ Stări ascunse discrete: filtrul Hamilton, netezitorul Kim, EM și Gibbs pentru modelele Markov switching și modele în spațiul stărilor cu regimuri

Anexă: netezitorul din leamnă

- ▣ $Y_n = (Y_{t-1}, v_t, \dots, v_n)$, iar $v_t, \dots, v_n$ sînt independente între ele și de Y_{t-1} : lema se aplică separat fiecărui v_j
- ▣ Netezitorul: $\hat{\alpha}_t = a_t + \sum_{j=t}^n \text{Cov}(\alpha_t, v_j) F_j^{-1} v_j$, cu $\text{Cov}(\alpha_t, v_j) = P_t L_t' \cdots L_{j-1}' Z_j'$
- ▣ Rezultă $\hat{\alpha}_t = a_t + P_t r_{t-1}$, cu $r_{t-1} = \sum_{j=t}^n L_t' \cdots L_{j-1}' Z_j' F_j^{-1} v_j$ (produs vid pentru $j = t$), care satisface recursia
înapoi $r_{t-1} = Z_t' F_t^{-1} v_t + L_t' r_t$
- ▣ Pașii de filtrare (actualizarea și predicția) rezultă din aceeași leamnă numai cu $j = t$: slide-ul [Filtrul Kalman dintr-o singură leamnă](#)

Anexă: exactitatea simulation smoother-ului Durbin–Koopman

- ▣ Modelul gaussian: $\alpha|y \sim N(\hat{\alpha}(y), V)$, cu V independent de y , iar $\hat{\alpha}(y)$ liniar în y (afin, cu termenii liberi)
- ▣ Pentru o extragere (α^+, y^+) din legea comună, $\alpha^+ - \hat{\alpha}(y^+) \sim N(0, V)$ și este independentă de y^+ (și de y)
- ▣ Deci $\tilde{\alpha} = \hat{\alpha}(y) + \alpha^+ - \hat{\alpha}(y^+) \sim N(\hat{\alpha}(y), V)$; liniaritatea dă $\hat{\alpha}(y) - \hat{\alpha}(y^+) = \hat{\alpha}_0(y - y^+)$, o singură trecere a netezitorului cu termeni liberi nuli
- ▣ Stările difuze: netezitorul difuz exact este invariant la partea difuză a lui α_1^+ , deci aceasta poate fi fixată la a_1

Anexă: nedeplasarea verosimilității din filtrul de particule

- Filtrul bootstrap, un pas: $\mathbb{E}[\frac{1}{N} \sum_i w_t^{(i)} | \mathcal{F}_{t-1}] = \int g(y_t|x) \hat{p}_N(x|Y_{t-1}) dx$, unde $\hat{p}_N$ este legea predictivă empirică a particulelor
- Aplicînd succesiv proprietatea speranțelor condiționate iterate pentru $t = n, n-1, \dots, 1$ (la fiecare pas, speranța ultimului factor condiționată de $\mathcal{F}_{t-1}$ se înlocuiește cu formula de mai sus), cu reeșantionare multinomială sau sistematică, obținem $\mathbb{E} \prod_t \hat{p}(y_t|Y_{t-1}) = p(y_{1:n})$ [Del Moral \(2004\)](#)
- Fiecare factor este o estimatie de tip raport, dar produsul este nedeplasat, pentru că reeșantionarea păstrează ponderile așteptate; mărimile normalizate (mediile filtrate) sînt doar consistente

Bibliografie (1/5)

- ▣ Aguiar, M., & Gopinath, G. (2007). Emerging market business cycles: The cycle is the trend. *Journal of Political Economy*, 115(1), 69–102. doi:10.1086/511283
- ▣ Andrieu, C., Doucet, A., & Holenstein, R. (2010). Particle Markov chain Monte Carlo methods. *Journal of the Royal Statistical Society: Series B*, 72(3), 269–342. doi:10.1111/j.1467-9868.2009.00736.x
- ▣ Andrieu, C., & Roberts, G. O. (2009). The pseudo-marginal approach for efficient Monte Carlo computations. *The Annals of Statistics*, 37(2), 697–725. doi:10.1214/07-AOS574
- ▣ Ansley, C. F., & Kohn, R. (1985). Estimation, filtering, and smoothing in state space models with incompletely specified initial conditions. *The Annals of Statistics*, 13(4), 1286–1316. doi:10.1214/aos/1176349739
- ▣ Bańbura, M., & Modugno, M. (2014). Maximum likelihood estimation of factor models on datasets with arbitrary pattern of missing data. *Journal of Applied Econometrics*, 29(1), 133–160. doi:10.1002/jae.2306
- ▣ Beveridge, S., & Nelson, C. R. (1981). A new approach to decomposition of economic time series into permanent and transitory components with particular attention to measurement of the 'business cycle'. *Journal of Monetary Economics*, 7(2), 151–174. doi:10.1016/0304-3932(81)90040-4
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- ▣ Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., & Scott, S. L. (2015). Inferring causal impact using Bayesian structural time-series models. *The Annals of Applied Statistics*, 9(1), 247–274. doi:10.1214/14-AOAS788
- ▣ Carter, C. K., & Kohn, R. (1994). On Gibbs sampling for state space models. *Biometrika*, 81(3), 541–553. doi:10.1093/biomet/81.3.541
- ▣ Chan, J. C. C., & Jeliazkov, I. (2009). Efficient simulation and integrated likelihood estimation in state space models. *International Journal of Mathematical Modelling and Numerical Optimisation*, 1(1/2), 101–120. doi:10.1504/IJMMNO.2009.030090
- ▣ Chopin, N., & Papaspiliopoulos, O. (2020). *An Introduction to Sequential Monte Carlo*. Springer. doi:10.1007/978-3-030-47845-2
- ▣ Clark, P. K. (1987). The cyclical component of U.S. economic activity. *The Quarterly Journal of Economics*, 102(4), 797–814. doi:10.2307/1884282

Bibliografie (2/5)

- Cogley, T., & Sargent, T. J. (2001). Evolving post-World War II U.S. inflation dynamics. *NBER Macroeconomics Annual*, 16, 331–373. doi:10.1086/654451
- Cogley, T., & Sargent, T. J. (2005). Drifts and volatilities: Monetary policies and outcomes in the post WWII US. *Review of Economic Dynamics*, 8(2), 262–302. doi:10.1016/j.red.2004.10.009
- de Jong, P. (1991). The diffuse Kalman filter. *The Annals of Statistics*, 19(2), 1073–1083. doi:10.1214/aos/1176348139
- de Jong, P., & Shephard, N. (1995). The simulation smoother for time series models. *Biometrika*, 82(2), 339–350. doi:10.1093/biomet/82.2.339
- Del Moral, P. (2004). *Feynman–Kac Formulae: Genealogical and Interacting Particle Systems with Applications*. Springer. doi:10.1007/978-1-4684-9393-1
- Del Negro, M., & Primiceri, G. E. (2015). Time varying structural vector autoregressions and monetary policy: A corrigendum. *The Review of Economic Studies*, 82(4), 1342–1345. doi:10.1093/restud/rdv024
- Doucet, A., Pitt, M. K., Deligiannidis, G., & Kohn, R. (2015). Efficient implementation of Markov chain Monte Carlo when using an unbiased likelihood estimator. *Biometrika*, 102(2), 295–313. doi:10.1093/biomet/asu075
- Doz, C., Giannone, D., & Reichlin, L. (2011). A two-step estimator for large approximate dynamic factor models based on Kalman filtering. *Journal of Econometrics*, 164(1), 188–205. doi:10.1016/j.jeconom.2011.02.012
- Durbin, J., & Koopman, S. J. (2002). A simple and efficient simulation smoother for state space time series analysis. *Biometrika*, 89(3), 603–616. doi:10.1093/biomet/89.3.603
- Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press. doi:10.1093/acprof:oso/9780199641178.001.0001
- Frühwirth-Schnatter, S. (1994). Data augmentation and dynamic linear models. *Journal of Time Series Analysis*, 15(2), 183–202. doi:10.1111/j.1467-9892.1994.tb00184.x
- Frühwirth-Schnatter, S., & Wagner, H. (2010). Stochastic model specification search for Gaussian and partial non-Gaussian state space models. *Journal of Econometrics*, 154(1), 85–100. doi:10.1016/j.jeconom.2009.07.003

Bibliografie (3/5)

- ▣ Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676. doi:10.1016/j.jmoneco.2008.05.010
- ▣ Gordon, N. J., Salmond, D. J., & Smith, A. F. M. (1993). Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEE Proceedings F (Radar and Signal Processing)*, 140(2), 107–113. doi:10.1049/ip-f-2.1993.0015
- ▣ Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. doi:10.2307/j.ctv14jx6sm
- ▣ Hamilton, J. D. (2018). Why you should never use the Hodrick–Prescott filter. *The Review of Economics and Statistics*, 100(5), 831–843. doi:10.1162/rest_a_00706
- ▣ Harvey, A. C. (1990). *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press. doi:10.1017/CBO9781107049994
- ▣ Harvey, A. C., & Jaeger, A. (1993). Detrending, stylized facts and the business cycle. *Journal of Applied Econometrics*, 8(3), 231–247. doi:10.1002/jae.3950080302
- ▣ Harvey, A., Ruiz, E., & Shephard, N. (1994). Multivariate stochastic variance models. *The Review of Economic Studies*, 61(2), 247–264. doi:10.2307/2297980
- ▣ Jacquier, E., Polson, N. G., & Rossi, P. E. (1994). Bayesian analysis of stochastic volatility models. *Journal of Business & Economic Statistics*, 12(4), 371–389. doi:10.1080/07350015.1994.10524553
- ▣ Julier, S. J., & Uhlmann, J. K. (2004). Unscented filtering and nonlinear estimation. *Proceedings of the IEEE*, 92(3), 401–422. doi:10.1109/JPROC.2003.823141
- ▣ Jungbacker, B., & Koopman, S. J. (2015). Likelihood-based dynamic factor analysis for measurement and forecasting. *The Econometrics Journal*, 18(2), C1–C21. doi:10.1111/ectj.12029
- ▣ Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45. doi:10.1115/1.3662552
- ▣ Kamber, G., Morley, J., & Wong, B. (2018). Intuitive and reliable estimates of the output gap from a Beveridge–Nelson filter. *The Review of Economics and Statistics*, 100(3), 550–566. doi:10.1162/REST_a_00691

Bibliografie (4/5)

- ▣ Kim, C.-J., & Nelson, C. R. (1999). *State-Space Models with Regime Switching: Classical and Gibbs-Sampling Approaches with Applications*. MIT Press. doi:10.7551/mitpress/6444.001.0001
- ▣ Kim, S., Shephard, N., & Chib, S. (1998). Stochastic volatility: Likelihood inference and comparison with ARCH models. *The Review of Economic Studies*, 65(3), 361–393. doi:10.1111/1467-937X.00050
- ▣ Kitagawa, G. (1996). Monte Carlo filter and smoother for non-Gaussian nonlinear state space models. *Journal of Computational and Graphical Statistics*, 5(1), 1–25. doi:10.1080/10618600.1996.10474692
- ▣ Koopman, S. J. (1997). Exact initial Kalman filtering and smoothing for nonstationary time series models. *Journal of the American Statistical Association*, 92(440), 1630–1638. doi:10.1080/01621459.1997.10473685
- ▣ Koopman, S. J., & Durbin, J. (2000). Fast filtering and smoothing for multivariate state space models. *Journal of Time Series Analysis*, 21(3), 281–296. doi:10.1111/1467-9892.00186
- ▣ Mariano, R. S., & Murasawa, Y. (2003). A new coincident index of business cycles based on monthly and quarterly series. *Journal of Applied Econometrics*, 18(4), 427–443. doi:10.1002/jae.695
- ▣ Morley, J. C., Nelson, C. R., & Zivot, E. (2003). Why are the Beveridge–Nelson and unobserved-components decompositions of GDP so different? *The Review of Economics and Statistics*, 85(2), 235–243. doi:10.1162/003465303765299765
- ▣ Omori, Y., Chib, S., Shephard, N., & Nakajima, J. (2007). Stochastic volatility with leverage: Fast and efficient likelihood inference. *Journal of Econometrics*, 140(2), 425–449. doi:10.1016/j.jeconom.2006.07.008
- ▣ Orphanides, A., & van Norden, S. (2002). The unreliability of output-gap estimates in real time. *The Review of Economics and Statistics*, 84(4), 569–583. doi:10.1162/003465302760556422
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Pitt, M. K., & Shephard, N. (1999). Filtering via simulation: Auxiliary particle filters. *Journal of the American Statistical Association*, 94(446), 590–599. doi:10.1080/01621459.1999.10474153
- ▣ Pitt, M. K., Silva, R. d. S., Giordani, P., & Kohn, R. (2012). On some properties of Markov chain Monte Carlo simulation methods based on the particle filter. *Journal of Econometrics*, 171(2), 134–151. doi:10.1016/j.jeconom.2012.06.004

Bibliografie (5/5)

- ▣ Primiceri, G. E. (2005). Time varying structural vector autoregressions and monetary policy. *The Review of Economic Studies*, 72(3), 821–852. doi:10.1111/j.1467-937X.2005.00353.x
- ▣ Scott, S. L., & Varian, H. R. (2014). Predicting the present with Bayesian structural time series. *International Journal of Mathematical Modelling and Numerical Optimisation*, 5(1/2), 4–23. doi:10.1504/IJMMNO.2014.059942
- ▣ Shephard, N., & Harvey, A. C. (1990). On the probability of estimating a deterministic component in the local level model. *Journal of Time Series Analysis*, 11(4), 339–347. doi:10.1111/j.1467-9892.1990.tb00062.x
- ▣ Shumway, R. H., & Stoffer, D. S. (1982). An approach to time series smoothing and forecasting using the EM algorithm. *Journal of Time Series Analysis*, 3(4), 253–264. doi:10.1111/j.1467-9892.1982.tb00349.x
- ▣ Stock, J. H., & Watson, M. W. (1998). Median unbiased estimation of coefficient variance in a time-varying parameter model. *Journal of the American Statistical Association*, 93(441), 349–358. doi:10.1080/01621459.1998.10474116
- ▣ Stock, J. H., & Watson, M. W. (2007). Why has U.S. inflation become harder to forecast? *Journal of Money, Credit and Banking*, 39(s1), 3–33. doi:10.1111/j.1538-4616.2007.00014.x
- ▣ Taylor, S. J. (1994). Modeling stochastic volatility: A review and comparative study. *Mathematical Finance*, 4(2), 183–204. doi:10.1111/j.1467-9965.1994.tb00057.x
- ▣ Watson, M. W. (1986). Univariate detrending methods with stochastic trends. *Journal of Monetary Economics*, 18(1), 49–75. doi:10.1016/0304-3932(86)90054-1