



Analiza avansată a seriilor de timp și previziune

Capitolul 7: Modele cu schimbare de regim



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/4)

- **AI:** Artificial Intelligence (inteligență artificială)
- **AIC:** Akaike Information Criterion (criteriul informațional Akaike)
- **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- **ARCH:** AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- **BCE:** Banca Centrală Europeană
- **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- **BFGS:** Broyden–Fletcher–Goldfarb–Shanno (quasi-Newton optimiser) — algoritmul de optimizare cvasi-Newton Broyden–Fletcher–Goldfarb–Shanno
- **BIC:** Bayesian Information Criterion (criteriul informațional bayesian (Schwarz))
- **BNR:** Banca Națională a României
- **CHP:** Carrasco–Hu–Ploberger (test, 2014) — testul Carrasco–Hu–Ploberger (2014)
- **CRPS:** Continuous Ranked Probability Score (scorul probabilistic continuu)
- **DLW:** Diebold–Lee–Weinbach (TVTP model, 1994) — modelul TVTP Diebold–Lee–Weinbach (1994)
- **ECM:** Error Correction Model (model cu corecția erorii)
- **EM:** Expectation–Maximisation (algorithm) — algoritmul expectație–maximizare

Acronime folosite în acest material (2/4)

- **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- **ES**: Expected Shortfall (pierderea așteptată în coadă)
- **ESI**: Economic Sentiment Indicator (European Commission) — indicatorul sentimentului economic (Comisia Europeană)
- **FFBS**: Forward Filtering, Backward Sampling (filtrare înainte, eşantionare înapoi)
- **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- **GPH**: Geweke–Porter–Hudak (estimator) — estimatorul Geweke–Porter–Hudak al parametrului de memorie lungă
- **HAR**: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- **HMP**: Haas–Mittnik–Paolella (MS-GARCH, 2004) — modelul MS-GARCH Haas–Mittnik–Paolella (2004)
- **HQ**: Hannan–Quinn (information criterion) — criteriul informațional Hannan–Quinn
- **IAPC**: Indicele armonizat al prețurilor de consum
- **KS**: Kolmogorov–Smirnov (test) — testul Kolmogorov–Smirnov
- **LLM**: Large Language Model (model lingvistic de mari dimensiuni)

Acronime folosite în acest material (3/4)

- **LR:** Likelihood Ratio (test) — testul raportului de verosimilitate
- **MCMC:** Markov Chain Monte Carlo (metode Monte Carlo cu lanțuri Markov)
- **MFM:** Modelling Financial Markets (Modelarea piețelor financiare, cursul de master)
- **MS:** Markov Switching (schimbare de regim de tip Markov)
- **MS-GARCH:** Markov-Switching GARCH (model GARCH cu schimbare de regim de tip Markov)
- **MS-VAR:** Markov-Switching Vector AutoRegression (model VAR cu schimbare de regim de tip Markov)
- **MSI:** Markov-Switching Intercept (termen liber cu schimbare de regim)
- **MSI-AR:** Markov-Switching Intercept AutoRegression (model autoregresiv cu termen liber care comută)
- **MSIAH:** Markov-Switching Intercept, Autoregressive parameters and Heteroskedasticity (termen liber, coeficienți autoregresivi și varianță cu schimbare de regim)
- **MSIH:** Markov-Switching Intercept and Heteroskedasticity (termen liber și varianță cu schimbare de regim)
- **MSIH-AR:** Markov-Switching Intercept and Heteroskedasticity AutoRegression (model autoregresiv cu termen liber și varianță care comută)
- **MSM:** Markov-Switching Mean (Krolzig notation) — medie cu schimbare de regim (notația Krolzig)

Acronime folosite în acest material (4/4)

- ▣ **MSM-AR**: Markov-Switching Mean AutoRegression (model autoregresiv cu medie care comută)
- ▣ **NBER**: National Bureau of Economic Research (Biroul Național de Cercetări Economice al SUA)
- ▣ **PIB**: Produsul intern brut
- ▣ **PIT**: Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ **PNB**: Produsul național brut
- ▣ **QPS**: Quadratic Probability Score (scorul pătratic al probabilităților)
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **ROL**: Romanian old leu (ISO 4217 code, until 2005) — leul vechi (cod ISO 4217, pînă în 2005)
- ▣ **STAR**: Smooth Transition AutoRegression (autoregresie cu tranziție netedă)
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **SWARCH**: Switching ARCH (Hamilton–Susmel) — model ARCH cu schimbare de regim (Hamilton–Susmel)
- ▣ **TAR**: Threshold AutoRegression (autoregresie cu prag)
- ▣ **TSA**: Time Series Analysis (Serii de timp, cursul de licență)
- ▣ **TVA**: Taxa pe valoarea adăugată
- ▣ **TVTP**: Time-Varying Transition Probabilities (probabilități de tranziție variabile în timp)
- ▣ **VAR**: Vector AutoRegression (model vector autoregresiv)

Întrebarea de azi și traseul

- **Întrebarea:** când procesul generator al datelor se schimbă el însuși (recesiune și expansiune, calm și panică, curs fix și curs floating), cum deducem regimul, estimăm modelul, îl testăm și prognozăm cu el?
 - ▶ regimul nu este observat niciodată: totul se sprijină pe probabilitatea lui condiționată de date
- **Traseul** capitolului
 - ▶ filtrul Hamilton și netezitorul Kim derivate; EM și verosimilitatea maximă numerică; identificare și schimbarea etichetelor
 - ▶ testarea numărului de regimuri; probabilități de tranziție variabile în timp; VAR cu schimbare de regim; GARCH cu schimbare de regim
 - ▶ estimarea bayesiană prin eșantionare Gibbs; regimuri, memorie lungă și rupturi; prognoza și evaluarea ei
 - ▶ aplicații: ciclul economic din SUA, inflația și PIB-ul României, S&P 500 și BET, EUR/RON
- Pornim de la [TSA](#), [Capitolul 10](#) (modelul lui Hamilton cu statsmodels), [Capitolul 2](#) (modele cu prag, rupturi) și [Capitolul 6](#) (spațiul stărilor, filtrare bayesiană); Seminarul 7 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Derivați filtrul Hamilton, verosimilitatea și netezitorul Kim și scrieți-le în numpy cu o recursie stabilă numeric
- ▣ Estimați regresii, modele autoregresive și VAR cu schimbare de regim prin EM și prin verosimilitate maximă numerică și diagnosticați maximele locale și degenerate
- ▣ Explicați de ce testul raportului de verosimilitate pentru numărul de regimuri este nestandard și testați prin bootstrap și prin criterii informaționale
- ▣ Specificați probabilități de tranziție variabile în timp, răspunsuri la impuls dependente de regim și modele MS-GARCH fără dependență de traiectorie
- ▣ Estimați un model cu schimbare de regim prin eșantionare Gibbs, tratați schimbarea etichetelor și evaluați prognozele cu reguli de scor și scoruri ale probabilităților

Bibliografie, date și instrumente

- ▣ Manualele de bază: [Hamilton \(1994\)](#), cap. 22; [Kim și Nelson \(1999\)](#); [Krolzig \(1997\)](#); [Frühwirth-Schnatter \(2006\)](#)
 - ▶ Sinteze: [Hamilton \(2016\)](#); [Ang și Timmermann \(2012\)](#)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_07](#)
 - ▶ filtrul Hamilton, netezitorul Kim, EM, verosimilitatea maximă pe starea extinsă, TVTP, MS-VAR, MS-GARCH și eșantionatorul Gibbs scrise în `numpy`
 - ▶ comparație: `statsmodels` `MarkovRegression` și `MarkovAutoregression`
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Utilizare
creșterea PNB real al SUA, T2 1951–T4 1984 (datele lui Hamilton); producția industrială și indicatorul avansat din SUA, 1948–1991 (datele lui Filardo)	seturi de date distribuite cu statsmodels	replicare
PIB-ul real și rata șomajului din SUA, trimestrele de recesiune NBER	FRED (GDPC1, UNRATE, USRECQ)	date, MS-VAR, prognoze
PIB-ul real (trimestrial) și IAPC (lunar) ale României	Eurostat (namq_10_gdp, prc_hicp_minr)	Gibbs, regimuri ale inflației
S&P 500, BET: închideri zilnice	EŌDHD (data/market)	MS-GARCH, bull/bear
EUR/RON	cursul de referință BCE pînă în iunie 2005, cursul de referință BNR din iulie 2005	regimuri de volatilitate

□ Toate sursele sînt publice și nu cer cont sau cheie

De la Markov la Hamilton



Andrei Markov (1856–1922), în jurul anului
1886

Foto: autor necunoscut (1886); domeniu public;
[Wikimedia Commons](#)

- 1906–1913: lanțurile Markov, o dependență care cere doar starea prezentă
- 1970: [Baum et al. \(1970\)](#): verosimilitatea maximă pentru modele Markov ascunse (algoritmul Baum–Welch, un EM înainte de EM); recunoașterea vorbirii [Rabiner \(1989\)](#)
- 1973: [Goldfeld și Quandt \(1973\)](#): regresii cu schimbare de regim în econometrie
- 1989–1990: [Hamilton \(1989\)](#) datează recesiunile din SUA doar din PNB; [Hamilton \(1990\)](#) dă algoritmul EM; [Kim \(1994\)](#) netezitorul
- 1993–2006: estimarea bayesiană [Albert și Chib \(1993\)](#), [Chib \(1996\)](#), [Frühwirth-Schnatter \(2001\)](#); MS-VAR [Krolzig \(1997\)](#); MS-GARCH [Gray \(1996\)](#), [Haas, Mittnik și Paoletta \(2004\)](#)

Cunoscut din TSA și elemente noi

- ▣ Cunoscut (TSA, Capitolul 10): $y_t = \mu_{S_t} + \varepsilon_t$, matricea de tranziție, duratele așteptate, probabilitățile ergodice, probabilitățile filtrate și netezite din statsmodels
 - ▶ recesiunile din SUA din PIB, regimurile creșterii din România, efectul anului 2020
- ▣ Nou: fiecare pas derivat și scris în cod; estimarea ca problemă de optimizare cu capcane; inferența asupra numărului de regimuri
 - ▶ extensii: tranziții care depind de covariabile, sisteme (MS-VAR), dinamica volatilității (MS-GARCH), estimare bayesiană
- ▣ Capitolul 2 a împărțit eșantionul după un prag observat (TAR, STAR) sau după o dată (rupturi); aici comutarea este un lanț Markov latent


Familia de modele (notația Krolzig)

- MS(K)-AR(p): $y_t = \nu_{S_t} + \sum_{k=1}^p \phi_{k,S_t} y_{t-k} + \sigma_{S_t} \varepsilon_t$, $\varepsilon_t \sim \text{i.i.d. } N(0, 1)$, $S_t \in \{1, \dots, K\}$
 - ▶ S_t : regimul la momentul t , una dintre K valori; ν_{S_t} , ϕ_{k,S_t} , σ_{S_t} : termenul liber, coeficienții AR(p) și abaterea standard a șocului în regimul curent
 - ▶ S_t un lanț Markov omogen, $p_{ij} = \Pr(S_t = j \mid S_{t-1} = i)$, independent de ε Krolzig (1997); $P = (p_{ij})$: matricea de tranziție, cu suma pe fiecare rând egală cu 1
- Parametrii care comută dau numele:
 - ▶ **MSI**: termenul liber ν ; **MSIH**: termenul liber și varianța; **MSIAH**: termenul liber, coeficienții AR și varianța
 - ▶ **MSM** (Hamilton 1989): comută *media* μ_{S_t} , $y_t - \mu_{S_t} = \sum_k \phi_k (y_{t-k} - \mu_{S_{t-k}}) + \sigma \varepsilon_t$
- MSI: după o comutare media se ajustează treptat; MSM: sare imediat; MSM cere regimurile a $p + 1$ perioade
- Cazuri particulare: $p_{ij} = \pi_j$ pentru orice i dă un amestec i.i.d.; o matrice P superior triunghiulară dă un model cu puncte de schimbare Chib (1998)

Lanțul: ergodicitate, durate, persistență

- Probabilitățile ergodice: $\pi'P = \pi'$, $1'\pi = 1$; pentru $K = 2$, $\pi_1 = (1 - p_{22})/(2 - p_{11} - p_{22})$
 - ▶ π : proporția pe termen lung a timpului petrecut în fiecare regim; 1 : un vector de unități
 - ▶ duratele sînt geometrice: $\Pr(D_i = d) = p_{ii}^{d-1}(1 - p_{ii})$, $\mathbb{E}D_i = 1/(1 - p_{ii})$ (fără memorie); D_i : numărul de perioade cît durează o vizită în regimul i
- Reprezentarea AR(1) [Hamilton \(1994\)](#), §22.2: $\xi_t = 1\{S_t = 1\}$ verifică $\xi_t = (1 - p_{22}) + \lambda\xi_{t-1} + v_t$, $\lambda = p_{11} + p_{22} - 1$
 - ▶ $1\{\cdot\}$: indicatorul (1 dacă este adevărat, 0 altfel); v_t : inovația; este o diferență de martingală, dar nu este independentă de trecut (varianța ei depinde de S_{t-1})
 - ▶ $\Pr(S_{t+h} = 1 \mid S_t) \rightarrow \pi_1$ cu viteza λ^h : λ este persistența procesului de regim
- Dependența de durată (recesiuni care se încheie mai probabil cu cît durează mai mult) cere o stare extinsă sau un lanț semi-Markov [Maheu și McCurdy \(2000\)](#)

Duratele și viteza de amestecare



□ $p_{11} = 0,9$, $p_{22} = 0,75$: durate așteptate de 10 și 4 perioade; $\pi_1 = 0,714$; $\lambda = 0,65$

□ Distanța față de probabilitatea ergodică scade cu factorul λ în fiecare perioadă: după 10 perioade regimul de pornire este aproape uitat

Filtrul Hamilton, derivat

- ▣ Notăție: $Y_t = (y_1, \dots, y_t)$, $\hat{\xi}_{t|s}$ vectorul $\Pr(S_t = j \mid Y_s)$ de dimensiune K , η_t vectorul densităților $f(y_t \mid S_t = j, Y_{t-1})$
 - ▶ **predicția** (probabilitatea totală, proprietatea Markov): $\hat{\xi}_{t|t-1} = P' \hat{\xi}_{t-1|t-1}$
 - ▶ **actualizarea** (Bayes): $\hat{\xi}_{t|t} = \frac{\hat{\xi}_{t|t-1} \odot \eta_t}{1'(\hat{\xi}_{t|t-1} \odot \eta_t)}$
 - ▶ **verosimilitatea**: $f(y_t \mid Y_{t-1}) = 1'(\hat{\xi}_{t|t-1} \odot \eta_t)$, deci $\ln L = \sum_t \ln f(y_t \mid Y_{t-1})$
- ▣ Pornire: $\hat{\xi}_{1|0} = \pi$ (ergodic) sau un parametru liber; $\odot$ este produsul element cu element
- ▣ Aceeași structură ca filtrul Kalman ([Capitolul 6](#)): predicție, actualizare, descompunerea erorilor de predicție; aici starea este discretă, iar actualizarea este exactă

Aspecte numerice și cost

- ▣ Densitățile ajung sub limita reprezentabilă (de exemplu 10^{-300} după o valoare extremă): lucrăm cu $\ln \eta_t$ și scădem $m_t = \max_j \ln \eta_{jt}$
 - ▶ $\ln f(y_t | Y_{t-1}) = m_t + \ln \sum_j \hat{\xi}_{j,t|t-1} e^{\ln \eta_{jt} - m_t}$ (log-sum-exp); vectorul filtrat nu se schimbă
- ▣ Cost: $O(TK^2)$; la MSM-AR(p) starea este $(S_t, \dots, S_{t-p})$, $M = K^{p+1}$ (32 pentru $K = 2$, $p = 4$ ale lui Hamilton)
 - ▶ matricea de tranziție extinsă este rară: din $(i_0, \dots, i_p)$ se trece doar în $(j, i_0, \dots, i_{p-1})$, cu probabilitatea $p_{i_0 j}$
 - ▶ MSI-AR(p) cere doar K stări: valorile cu lag ale lui y intră ca regresori
- ▣ Filtrul nostru numpy și statsmodels dau aceeași log-verosimilitate, la precizia mașinii, când distribuția inițială este aceeași

Netezitorul Kim, derivat

- Scopul: $\hat{\xi}_{t|T}$, probabilitățile regimurilor date fiind toate datele [Kim \(1994\)](#)
 - ▶ pasul-cheie: $\Pr(S_t = i \mid S_{t+1} = j, Y_T) = \Pr(S_t = i \mid S_{t+1} = j, Y_t)$: dat fiind S_{t+1} , valorile viitoare ale lui y nu aduc informație suplimentară despre S_t
 - ▶ exact pentru MSI/MSIH/MSM pe starea extinsă; aproximare doar cînd starea are și o parte continuă (Kim 1994, [Capitolul 6](#))
 - ▶ demonstrația pasului-cheie: [▶ Anexa](#)
- Bayes pentru pereche: $\Pr(S_t = i, S_{t+1} = j \mid Y_T) = \frac{\hat{\xi}_{i,t|t} p_{ij}}{\hat{\xi}_{j,t+1|t}} \hat{\xi}_{j,t+1|T}$
 - ▶ sumăm după j : $\hat{\xi}_{t|T} = \hat{\xi}_{t|t} \odot \left[P(\hat{\xi}_{t+1|T} \oslash \hat{\xi}_{t+1|t}) \right]$, înapoi de la $\hat{\xi}_{T|T}$; $\odot$: împărțirea element cu element
- Probabilitățile comune ale perechii (S_t, S_{t+1}) sînt pasul E al algoritmului EM; eșantionarea în locul sumării dă FFBS (secțiunea [Estimarea bayesiană](#))

Trei probabilități, trei întrebări

- ▣ Probabilitatea **prezisă** $\hat{\xi}_{t+1|t}$: ce așteaptă un prognozator pentru perioada următoare; intră în densitatea de prognoză
- ▣ Probabilitatea **filtrată** $\hat{\xi}_{t|t}$: ce se putea ști la t ; semnalul în timp real (Chauvet și Piger 2008)
 - ▶ datarea în timp real se evaluează cu probabilități filtrate și cu edițiile datelor, niciodată cu cele netezite
- ▣ Probabilitatea **netezită** $\hat{\xi}_{t|T}$: răspunsul istoricului; folosește viitorul și se revizuieste pe măsură ce sosesc date
 - ▶ datarea regimurilor trecute și ponderile pasului M
- ▣ Confuzia lor este cea mai frecventă eroare în lucrările aplicate: o probabilitate netezită nu este o prognoză

EM: verosimilitatea datelor complete

- Dacă $S_1, \dots, S_T$ ar fi observate, log-verosimilitatea s-ar separa [Dempster, Laird și Rubin \(1977\)](#), [Hamilton \(1990\)](#):
 - ▶ $\ln L_c = \sum_j 1\{S_1 = j\} \ln \rho_j + \sum_{t \geq 2} \sum_{i,j} 1\{S_{t-1} = i, S_t = j\} \ln p_{ij} + \sum_t \sum_j 1\{S_t = j\} \ln \eta_{jt}(\theta_j)$
 - ▶ $\rho_j = \Pr(S_1 = j)$: probabilitățile inițiale; $\eta_{jt}(\theta_j)$: densitatea lui y_t în regimul j , cu parametrii θ_j
 - ▶ numărarea tranzițiilor și regresii regim cu regim: forme închise
- **Pasul E:** înlocuim indicatorii cu speranțele lor condiționate de Y_T și de $\theta^{(m)}$ curent (m : iterația)
 - ▶ $\hat{\xi}_{j,t|T}$ și $\hat{\xi}_{ij,t|T} = \Pr(S_{t-1} = i, S_t = j \mid Y_T)$: exact ieșirea netezitorului Kim
- Baum et al. (1970) au derivat aceeași recursie pentru modelele Markov ascunse (algoritmul forward–backward)


EM: pasul M în formă închisă

- Tranzițiile: $p_{ij}^{(m+1)} = \frac{\sum_{t=2}^T \hat{\xi}_{ij,t|T}}{\sum_{t=2}^T \hat{\xi}_{i,t-1|T}}$ (tranziții așteptate raportate la vizite așteptate); $\rho^{(m+1)} = \hat{\xi}_{1|T}$
- Coeficienți care comută (MSIAH): cele mai mici pătrate ponderate $\beta_j^{(m+1)} = (X' W_j X)^{-1} X' W_j y$,
 $W_j = \text{diag}(\hat{\xi}_{j,t|T})$; X : liniile x'_t (constanta și lagurile), y : observațiile; fiecare dată contează cu probabilitatea de a fi în regimul j
- Varianțele: $\sigma_j^{2(m+1)} = \sum_t \hat{\xi}_{j,t|T} (y_t - x'_t \beta_j)^2 / \sum_t \hat{\xi}_{j,t|T}$; MS-VAR: același lucru cu matrice
- Coeficienți comuni (MSIH-AR): o singură regresie ponderată stivuită, cu ponderile $\hat{\xi}_{j,t|T} / \sigma_j^2$ (un pas M condiționat, ECM)
- MSM-AR: μ și ϕ apar ca produse, deci nu există formă închisă: maximizare numerică (sau EM cu un pas M numeric)
- Derivarea pasului M pentru P și a monotoniei EM: [▶ Anexa](#)

EM și verosimilitatea maximă numerică în practică

- EM nu scade niciodată verosimilitatea, este robust departe de optim, dar lent în apropierea lui (convergență liniară)
 - ▶ monotonia cere ca ρ să fie un parametru liber; cu $\rho = \pi(P)$ pasul M pentru P este doar aproximativ
- Verosimilitatea maximă numerică: BFGS pe parametri fără restricții ($\ln \sigma_j^2$, logit-urile lui p_{ij}); erorile standard din hessiană prin metoda delta
 - ▶ în practică: EM din multe puncte de pornire, apoi o rafinare de tip Newton și hessiana
- Verosimilitatea este nemărginită: $\sigma_j \rightarrow 0$ în jurul unei observații, cu $p_{jj} \rightarrow 0$, dă $\ln L \rightarrow \infty$
 - ▶ remedii: o limită inferioară pentru σ_j/σ_k [Hathaway \(1985\)](#), distribuții a priori (secțiunea [Estimarea bayesiană](#)) sau respingerea regimurilor care durează o singură perioadă
- Erorile standard lângă frontieră ($p_{ij} \approx 1$) nu sînt de încredere: raportați verosimilitatea de profil sau intervale bootstrap

EM din 30 de puncte de pornire



- MSIH(2)-AR(1) pe datele PNB ale lui Hamilton: termen liber și varianță care comută, coeficient AR(1) comun; puncte de pornire aleatoare; scară logaritmică pentru iterații

Interpretarea traiectoriilor EM

- ▣ 2 limite (log-verosimilitatea, numărul de puncte de pornire): $-186,48$ (20); $-183,76$ (10); în mediană 159 de iterații, cel mult 216
- ▣ Cea mai înaltă ($-183,76$) este **degenerată**: un regim cu $\sigma^2 = 0,049$, $p_{11} < 10^{-9}$ și media 1,11, folosit de 29 de trimestre izolate
- ▣ `statsmodels` (20 de căutări aleatoare) raportează $-185,73$, un al treilea maxim local, pe care niciunul dintre punctele noastre de pornire nu l-a atins
- ▣ Lecția: raportați schema punctelor de pornire, toate maximele locale și motivul pentru care cel ales are sens economic

Identificare și schimbarea etichetelor

- Verosimilitatea este invariantă la cele $K!$ permutări ale etichetelor: (θ_1, θ_2, P) și $(\theta_2, \theta_1, \sim P \sim')$ se potrivesc la fel de bine
 - ▶ pentru verosimilitatea maximă este inofensiv: alegem un mod și numim regimurile după o ordonare ($\mu_1 < \mu_2$ sau $\sigma_1 < \sigma_2$)
 - ▶ pentru MCMC nu este: eșantionatorul sare între moduri, iar media a posteriori a lui μ_1 amestecă regimurile [Celeux, Hurn și Robert \(2000\)](#), [Stephens \(2000\)](#)
- Identificarea eșuează și local: K regimuri cu $\theta_i = \theta_j$ sau un regim nevizitat lasă P neidentificat
 - ▶ aceasta este rădăcina problemei de testare din secțiunea următoare
- Regimurile statistice nu sînt neapărat regimuri economice: aceleași date de PIB dau recesiuni (MSM), ere de volatilitate (MSIH) sau valori extreme izolate


Testul LR nestandard

- H_0 : un singur regim ($\mu_1 = \mu_2, \sigma_1 = \sigma_2$) față de H_1 : două regimuri
 - ▶ (i) sub H_0 , p_{11} și p_{22} **nu sînt identificați**: parametri de perturbare prezenți doar sub H_1 , problema Davies din Capitolul 2 Davies (1987)
 - ▶ (ii) ipoteza nulă se poate scrie $p_{11} = 1$: un parametru pe **frontieră**
 - ▶ (iii) scorul în raport cu $\mu_2 - \mu_1$ este **identic zero** sub H_0 : matricea informațională este singulară
- Fiecare dintre cele trei încalcă una dintre condițiile pentru $2 \ln \Lambda \rightarrow \chi_q^2$ (Λ : raportul de verosimilitate; q : numărul de restricții): numărarea parametrilor nu dă valoarea critică
- Aceeași structură ca testarea liniarității față de TAR sau STAR (Capitolul 2), cu o comutare latentă în locul uneia observate

Soluțiile din literatură

- ▣ Hansen (1992): tratează verosimilitatea ca un proces empiric în parametrii de perturbare și mărginește LR standardizat; conservator, greu de calculat
 - ▶ aplicat modelului PNB al lui Hamilton: nicio dovadă împotriva unui singur regim la nivelurile uzuale
- ▣ Garcia (1998): distribuția asimptotică sub H_0 a statisticii sup-LR pentru modele cu medie (și varianță) care comută, cu valori critice tabelate
- ▣ Cho și White (2007): quasi-LR față de un amestec cu două componente (o comutare i.i.d. are același comportament sub H_0)
- ▣ Carrasco, Hu și Ploberger (2014): un test optim de tip scor față de schimbarea de regim de tip Markov, care cere doar modelul nul
- ▣ În practică: **bootstrap parametric** al LR
 - ▶ simulăm din modelul nul estimat; reestimăm ambele modele (cu mai multe puncte de pornire) pe fiecare eșantion
 - ▶ $p = (1 + \#\{LR^* \geq LR\})/(B + 1)$; LR^* : cele B statistici bootstrap; $\#$: numărul celor mai mari decât LR
- ▣ Selecție în loc de testare: AIC, BIC, HQ sau factori Bayes prin verosimilitatea marginală Chib (1995)

Distribuția bootstrap a statisticii LR sub ipoteza nulă



- Creșterea PIB-ului SUA, T2 1947–T4 2019 ($T = 290$): H_0 AR(1) Gaussian, H_1 MSIH(2)-AR(1); 199 de eșantioane simulate din AR(1) estimat, ambele modele reestimate, EM cu 4 puncte de pornire

Interpretarea testului

- ▣ Cuantila bootstrap de 95% este 12,32, față de 5,99 (χ_2^2) și 9,49 (χ_4^2); media extragerilor sub H_0 5,79: numărarea parametrilor dă o valoare critică greșită
- ▣ LR observat = 71,7, p-value-ul bootstrap 0,005 (cea mai mică posibilă cu $B = 199$): două regimuri
- ▣ Dar ce regimuri? Abaterile standard 0,46 și 1,11 pp, $p_{ii} = 0,990$ și 0,985: ere de volatilitate (Marea Moderație), nu recesiuni
- ▣ BIC: 755,5 ($K = 1$), 706,4 ($K = 2$), 734,7 ($K = 3$); AIC: 744,5; 680,8; 687,0

Lucrarea



Chicago, februarie 1931: regimul de care se teme
orice prognozator

Foto: [US National Archives \(1931\)](#); domeniu public;
[Wikimedia Commons](#)


- [Hamilton \(1989\)](#), secțiunea 4: PNB real al SUA, $100 \times$ variația logaritmului, T2 1951–T4 1984, MSM(2)-AR(4)
- Ecuația (4.3): $y_t - \mu_{S_t} = \sum_{k=1}^4 \phi_k (y_{t-k} - \mu_{S_{t-k}}) + \sigma \varepsilon_t$; estimațiile în Tabelul I
- Afirmația: datele în care regimul de creștere scăzută este probabil coincid cu recesiunile NBER, deși datele NBER nu au fost folosite
- Replicăm pe setul lui de date, comparăm numpy cu statsmodels, apoi reestimăm pe PIB-ul de azi

Replicare: datele lui Hamilton, două implementări

Estimarea	μ_0	μ_1	ϕ_1	ϕ_2	ϕ_3	ϕ_4	σ	$\ln L$
numpy (eroarea standard)	-0,359 (0,265)	1,164 (0,075)	0,013 (0,120)	-0,058 (0,138)	-0,247 (0,107)	-0,213 (0,111)	0,769	-181,26
statsmodels	1,164	-0,359	0,013	-0,058	-0,247	-0,213	0,769	-181,26

- Tranziții: $p_{00} = 0,755$ (rămînerea în regimul scăzut), $p_{11} = 0,904$; durate așteptate de 4,1 și 10,4 trimestre; $T = 131$ după 4 laguri
- Cea mai mare diferență între cele două traiectorii ale probabilităților netezite: $< 10^{-4}$
- Estimarea: BFGS pe starea extinsă de 32 de combinații de regimuri, 8 puncte de pornire aleatoare; erorile standard din hessiana numerică

Regimurile lui Hamilton atunci și acum




- Stînga: probabilitatea netezită a regimului de creștere scăzută pe datele lui Hamilton. Dreapta: aceeași specificație pe GDPC1 de azi, estimată pe T2 1953–T4 2019 ($T = 267$), probabilități pînă în T2 2026 cu aceiași parametri

Interpretarea replicării

- ▣ Pe datele lui, regimul urmărește datele NBER: QPS 0,179 și concordanță de 89% (probabilitate peste 0,5 comparată cu trimestrele NBER) [Diebold și Rudebusch \(1989\)](#), [Harding și Pagan \(2002\)](#)
- ▣ Pe datele de azi, regimul scăzut își schimbă natura: media $-1,22\%$, $p_{00} = 0,26$ (durata 1,4 trimestre): căderi bruște izolate, nu recesiuni
- ▣ Prinde T4 2008 (0,95) și T2 2020 (1,00), dar nu 2001 (cel mult 0,01); QPS 0,229 pe 37 de trimestre NBER
- ▣ După 1984 recesiunile sînt mai rare și mai blînde (Marea Moderație): un model fix cu două medii își pierde puterea; de aici TVTP, MSIH și trei regimuri

Datarea în pseudo timp real



- Modelul lui Hamilton reestimat în fiecare an pe datele disponibile atunci (ediția curentă, fără revizuirile datelor); probabilitatea filtrată a fiecărui trimestru cu informația de până la acel trimestru, 1990–2026

Interpretarea datării în timp real

- ▣ Primul trimestru peste 0,5: 1990–91 niciunul (maximum 0,32), 2001 niciunul (maximum 0,05), 2008 T4 2008, 2020 T1 2020
- ▣ QPS înainte de 2020: 0,127 în timp real față de 0,152 netezit; 0 semnale false peste 0,5
- ▣ [Chauvet și Piger \(2008\)](#): cu ediții în timp real, modelele MS semnalează începutul recesiunilor mai repede decât anunțul NBER, dar recesiunile ușoare sînt ratate
- ▣ Exercițiul nostru avantajează modelul: PIB-ul revizuit de azi nu era disponibil în 2001

Lanțul dependent de variabile observate


- Diebold, Lee și Weinbach (1994), Filardo (1994): $p_{ii,t} = \Pr(S_t = i \mid S_{t-1} = i, z_{t-1}) = \frac{\exp(z'_{t-1}\gamma_i)}{1 + \exp(z'_{t-1}\gamma_i)}$
 - ▶ z_{t-1} : variabile observate cunoscute la $t - 1$ (cu o constantă); γ_i : coeficienții lor; funcția logistică menține $p_{ii,t}$ în $(0, 1)$
 - ▶ un indicator avansat, panta curbei randamentelor sau dobînda de politică pot face mai probabil sau mai puțin probabil începutul sau sfîrșitul unei recesiuni
 - ▶ duratele așteptate variază acum în timp; lanțul nu mai este omogen
- Filtrul și netezitorul rămîn neschimbate, cu P_t în locul lui P ; EM: pasul M pentru γ_i este un logit ponderat (DLW)
 - ▶ z_{t-1} trebuie să fie predeterminat și să nu depindă de S_t ; dacă z reacționează la regim, modelul este greșit specificat (comutare endogenă)
- Testul tranzițiilor constante: H_0 : pantele lui γ_i sînt zero este un test LR standard, deoarece regimurile există sub ambele ipoteze

Replicare: Filardo (1994)

Modelul	μ_0	μ_1	γ_0	γ_1	$\ln L$	statsmodels
TVTP, numpy (eroarea standard)	-0,87	0,50	(1,49; -1,09) (0,48; 0,62)	(4,33; 1,75) (0,76; 0,52)	-586,20	-586,20
tranziții constante		2,77	$p_{00} = 0,983$	$p_{11} = 0,14$	-590,67	

- Creșterea producției industriale din SUA, lunar, $T = 513$ (datele lui Filardo); MSM(2)-AR(4); $z_{t-1} = (1, \text{creșterea indicatorului compozit avansat})$
- LR pentru TVTP față de tranziții constante: 8,94 ($p = 0,011$, 2 restricții)
- Maximul cu tranziții constante nu este un ciclu economic: un regim cu medie mare (2,77% pe lună) care durează aproximativ o lună

Probabilități de tranziție determinate de indicatorul avansat



□ Sus: probabilitatea netezită a regimului de creștere scăzută; jos: probabilitățile de rămânere în fiecare regim, lună de lună


Interpretarea TVTP

- ▣ Rămînerea în expansiune: mediana 0,988, dar coboară pînă la 0,10 cînd indicatorul avansat scade puternic: expansiunile se încheie cînd indicatorul se întoarce
- ▣ Rămînerea în recesiune scade cînd indicatorul crește (panta $\gamma - 1,09$): revenirile sînt anunțate de indicator
- ▣ QPS față de lunile NBER 0,197, concordanță 88%
- ▣ Atenție: indicatorul avansat a fost construit cunoscînd datele NBER; un test în timp real cere edițiile lui

MS-VAR și răspunsuri dependente de regim

- MSIAH(K)-VAR(p): $y_t = \nu_{S_t} + \sum_{k=1}^p A_{k,S_t} y_{t-k} + \Sigma_{S_t}^{1/2} \varepsilon_t$, $y_t \in \mathbb{R}^n$ Krolzig (1997)
 - ▶ ν_{S_t} , A_{k,S_t} , Σ_{S_t} : vectorul termenilor liberi, matricele lagurilor și covarianța erorilor în regimul curent; $\varepsilon_t \sim N(0, I_n)$
 - ▶ EM: pasul M este o regresie multivariată ponderată pe fiecare regim; $\Sigma_j = \sum_t \hat{\xi}_{j,t|T} \hat{u}_{jt} \hat{u}_{jt}' / \sum_t \hat{\xi}_{j,t|T}$ ($\hat{u}_{jt}$: reziduurile regimului j)
 - ▶ parametrii cresc ca $K(n + n^2 p + n(n + 1)/2)$: shrinkage sau comutare restrînsă (MSIH) în sistemele mai mari (Capitolul 5)
- **Răspunsuri la impuls dependente de regim** Ehrmann, Ellison și Valla (2003): $\partial y_{t+h} / \partial \varepsilon_t$ calculat cu (A_j, Σ_j) , presupunînd că regimul j persistă pe orizont
 - ▶ răspunsul complet face media pe traiectoriile viitoare ale regimurilor și depinde de probabilitățile curente ale regimurilor; se obține prin simulare
- Comutarea doar în Σ identifică șocurile structurale prin heteroscedasticitate (Capitolul 3); Sims și Zha (2006) întreabă dacă politica monetară a SUA a comutat și găsesc mai ales comutări de varianță

Un VAR cu două regimuri pentru producție și șomaj



- MSIAH(2)-VAR(1) pentru creșterea PIB-ului SUA și variația ratei șomajului, T1 1960–T4 2019 ($T = 239$, 20 de parametri), EM din 12 puncte de pornire; ordinea Cholesky: producția prima; răspunsuri scalate la un șoc de producție de 1 pp

Interpretarea modelului MS-VAR

- Regimurile sînt calm și volatil
 - ▶ abaterea standard a șocului de producție 0,42 față de 1,02 pp; durate de 21,8 și 14,3 trimestre
 - ▶ regimul volatil acoperă 83% din trimestre înainte de 1984, 17% după și 100% din trimestrele NBER
- Șomajul la 12 trimestre după un șoc de producție de 1 pp: $-0,06$ pp (calm), $-0,83$ pp (volatil), $-0,65$ pp (VAR liniar)
- Legea lui Okun depinde de regim
 - ▶ în regimul calm surprizele de producție aproape nu mișcă șomajul (corelația șocurilor $-0,15$, față de $-0,69$)
 - ▶ un VAR liniar face media a două transmisii
- În L : $-166,8$ (MS-VAR) față de $-222,0$ (VAR liniar); răspunsurile dependente de regim presupun că regimul persistă pe orizont

Regimuri în volatilitate



Lehman Brothers, Times Square, 2007:
un regim calm aproape de sfârșit

Foto: David Shankbone (2007); CC BY-SA
3.0; Wikimedia Commons

- Lamoureux și Lastrapes (1990): schimbările structurale ale varianței deplasează persistența GARCH $\alpha + \beta$ spre 1
- Hamilton și Susmel (1994): SWARCH, un ARCH a cărui scală comută după un lanț Markov; mare parte din persistență trece în lanț
- MSIH pe randamente: cel mai simplu model cu regimuri de volatilitate, deja un reper util pentru GARCH Bollerslev (1986)
- Capitolul 8 dezvoltă măsurile realizate și GARCH multivariat; aici: ce fac regimurile cu GARCH

Problema dependenței de traiectorie


- MS-GARCH naiv: $h_t = \omega_{S_t} + \alpha_{S_t} \varepsilon_{t-1}^2 + \beta_{S_t} h_{t-1}$
 - ▶ h_t : varianța condiționată; ε_{t-1} : ultimul șoc al randamentului; ω, α, β : parametrii GARCH ai regimului
 - ▶ h_{t-1} depinde la rîndul lui de regim
 - ▶ h_t depinde de întreaga traiectorie $(S_1, \dots, S_t)$: K^t istorii, deci filtrul Hamilton nu se poate aplica ($2^{100} \approx 10^{30}$)
- Gray (1996): comprimă trecutul în $h_{t-1} = \mathbb{E}[\varepsilon_{t-1}^2 \mid Y_{t-2}]$, varianța amestecului: $h_{j,t} = \omega_j + \alpha_j \varepsilon_{t-1}^2 + \beta_j h_{t-1}$
 - ▶ Klaassen (2002): condiționează și pe S_t , folosind $\Pr(S_{t-1} \mid S_t, Y_{t-1})$
- Haas, Mittnik și Paoletta (2004): K procese GARCH rulează în paralel, $h_{j,t} = \omega_j + \alpha_j \varepsilon_{t-1}^2 + \beta_j h_{j,t-1}$; lanțul îl alege pe unul
 - ▶ fără dependență de traiectorie, verosimilitate exactă, condiții explicite de staționaritate; asimptotica în Bauwens, Preminger și Rombouts (2010)

S&P 500: GARCH comparat cu MS-GARCH

Modelul	$\alpha + \beta$, regimul 1	$\alpha + \beta$, regimul 2	p_{ij}	$\ln L$	BIC
GARCH(1,1)	0,981			-9219,9	18475,0
MS-GARCH (HMP)	0,964	0,998	0,959; 0,925	-9119,1	18317,5
MS-GARCH (Gray)	1,000	0,921	0,981; 0,956	-9207,4	18494,1

- Randamente logaritmice zilnice (%), ianuarie 2000 – septembrie 2026, $T = 6\,714$; inovații Normale, medie comună; verosimilitate maximă numerică în numpy din mai multe puncte de pornire
- Regimurile HMP: volatilitatea condiționată medie cît timp regimul este activ 13,1% și 27,6% pe an; durate așteptate de 24 și 13 zile

Volatilitatea condiționată și regimul de volatilitate ridicată



- ☐ Sus: volatilitatea condiționată anualizată, GARCH(1,1) și MS-GARCH (HMP, varianța amestecului); jos: probabilitatea filtrată a regimului de volatilitate ridicată

Interpretarea modelului MS-GARCH

- BIC preferă HMP (18317,5) față de GARCH (18475,0); regimul de volatilitate ridicată este activ în 21% din zile
- Persistența cu un singur regim 0,981; în interiorul regimurilor 0,964 (calm) și 0,998 (volatilitate ridicată): regimurile nu elimină automat persistența, ci o mută acolo unde îi este locul
- Comprimarea lui Gray se potrivește mai slab aici (−9207,4): aproximarea nu este inofensivă
- Maximele locale sînt frecvente: puncte de pornire diferite dau împărțiri diferite în regimuri (raportați întotdeauna schema punctelor de pornire)

Regimuri pe piața de acțiuni: S&P 500 și BET




Bursa de Valori București, 2024

Foto: Corina Chitu (2024); CC BY-SA 4.0; Wikimedia

[Commons](#)

- Randamente logaritmice săptămânale, 2000–2026, MSIH(2):
 $r_t = \mu_{S_t} + \sigma_{S_t} \varepsilon_t$ Maheu și McCurdy (2000), Ang și Timmermann (2012)
- S&P 500 (anualizat): calm, media 16,6%, volatilitatea 10,9%; agitat –20,6%, 28,3%
- BET: calm 20,1%, 13,6%; agitat 3,2%, 39,9%
- Durate (săptămîni), calm și agitat: S&P 500 37 și 14; BET 33 și 12

Regimuri agitate pe două piețe



- Nivelurile indicilor pe scară logaritmică (prima săptămână = 100); hașurat: probabilitatea netezită a regimului agitat peste 0,5; EM din 15 puncte de pornire și rafinare numerică (statsmodels: același $\ln L$)

Interpretarea regimurilor pieței de acțiuni

- ▣ Ponderea regimului agitat: S&P 500 26%, BET 25%; corelația celor două probabilități 0,48; ambele agitate în 15% din săptămîni
- ▣ Regimurile sînt mai ales regimuri de volatilitate: media regimului agitat este mai mică, dar estimată cu eroare mare
- ▣ In L : S&P 500 $-3019,3$ (numpy) și $-3019,3$ (statsmodels); BET $-3339,9$ și $-3339,9$
- ▣ BET are episoade agitate proprii (politică internă, prăbușirea din 2007–2009), nu doar importate

Regimuri și alocarea activelor, pe scurt

- ▣ Ang și Bekaert (2002)
 - ▶ cu schimbare de regim, portofoliile optime depind de probabilitățile curente ale regimurilor
 - ▶ preferința pentru piața internă și valoarea diversificării internaționale se schimbă de la un regim la altul
- ▣ Ponderea acțiunilor față de numerar în portofoliul medie–varianță, cu aversiunea la risc $\gamma = 5$: $w = \mu/(\gamma\sigma^2)$; μ , σ^2 : media și varianța săptămânale ale randamentului în regim
 - ▶ S&P 500: 2,79 în regimul calm, -0,51 în cel agitat, 0,39 cu momente constante
 - ▶ cu momentele amestecului la un pas, ponderea se mișcă între -0,47 și 2,02
- ▣ Rezerve: eroarea de estimare a mediilor pe regimuri este mare; câștigurile în afara eșantionului trebuie testate (Capitolul 1), iar costurile de tranzacționare incluse
- ▣ Aplicațiile de risc de piață (VaR și ES cu regimuri) sînt în MFM, Capitolul 7

Eșantionarea Gibbs cu augmentarea datelor

- Tratăm $S = (S_1, \dots, S_T)$ ca parametri [Albert și Chib \(1993\)](#): dat fiind S , modelul este un set de regresii; dat fiind θ , S este un lanț Markov ascuns
 - ▶ 1. $S \mid \theta, Y$; 2. $P \mid S$: rîndurile $\sim \text{Dirichlet}(a_{i\cdot} + n_{i\cdot})$, n_{ij} numărul de tranziții, a_{ij} parametrii Dirichlet a priori
 - ▶ 3. $\mu_j \mid \sigma_j^2, S, Y \sim \text{Normală}$ și $\sigma_j^2 \mid \mu_j, S, Y \sim \text{inverse gamma}$: actualizări conjugate pe observațiile regimului j ([Capitolul 5](#))
- **FFBS** [Chib \(1996\)](#): extragem toată traiectoria odată: $S_T \sim \hat{\xi}_{T|T}$, apoi înapoi


$\Pr(S_t = i \mid S_{t+1} = j, Y_t) \propto \hat{\xi}_{i,t|t} p_{ij}$

 - ▶ eșantionarea cîte un S_t , dat fiind S_{t-1} și S_{t+1} , are o amestecare (mixing) foarte lentă cînd regimurile sînt persistente
 - ▶ analogul discret al simulation smoother-ului din [Capitolul 6 Carter și Kohn \(1994\)](#)
- Distribuțiile a priori țin σ_j departe de 0 și p_{ii} departe de frontieră: maximele degenerate ale verosimilității dispar

Schimbarea etichetelor în MCMC și alegerea lui K

- **Eșantionatorul cu permutări aleatoare** [Frühwirth-Schnatter \(2001\)](#): permutăm aleator etichetele după fiecare iterație; eşantionatorul vizitează astfel toate cele $K!$ moduri
 - ▶ rezultatul nerestricționat arată ce parametri separă regimurile; identificăm apoi prin restricția care le separă
 - ▶ o restricție nepotrivită (de exemplu pe parametri aproape egali) taie un mod în două și deplasează ambele regimuri [Celeux, Hurn și Robert \(2000\)](#)
- Alegerea lui K : verosimilitatea marginală $p(Y | K)$ din rezultatele Gibbs [Chib \(1995\)](#),
 $\ln p(Y) = \ln f(Y | \theta^*) + \ln p(\theta^*) - \ln p(\theta^* | Y)$
 - ▶ ordonata verosimilității vine din filtrul Hamilton; ordonata a posteriori din rulări Gibbs reduse
- Modelele cu puncte de schimbare ([Chib 1998](#)) folosesc același eşantionator cu o matrice P superior triunghiulară

Creșterea PIB-ului României: două regimuri prin eșantionare Gibbs




- Creșterea trimestrială, T2 1995–T2 2026 ($T = 125$), MSIH(2) fără termen AR; 5 000 de extrageri după burn-in; stînga: eșantionatorul cu permutări, dreapta: eșantionatorul identificat prin $\mu_1 < \mu_2$

Interpretarea distribuției a posteriori

- Eșantionatorul cu permutări: eticheta 1 are media mai mare în 49% din extrageri: histograma bimodală reprezintă cele două regimuri, nu două răspunsuri
- Identificat: $\mu_1 -0,11 [-1,26; 0,87]$, $\sigma_1 3,80$; $\mu_2 1,08 [0,76; 1,41]$, $\sigma_2 1,57$ (intervale credibile de 90%)
- $p_{11} 0,85 [0,73; 0,94]$, $p_{22} 0,91$; EM: $\mu = 0,03$ și $1,04$, $p_{ii} = 0,90$ și $0,94$
- Mediile se suprapun, abaterile standard nu: regimurile sînt o eră volatilă (1995–2000, 2009–2012, 2020) și una stabilă; varianța este restricția de identificare mai bună
- Probabilitățile regimurilor a posteriori și cele din EM au corelația 0,99; distribuția a posteriori include și incertitudinea parametrilor, pe care traiectoria EM o ignoră

Comutările rare arată ca memoria lungă

- ▣ Diebold și Inoue (2001): $y_t = \mu_{S_t} + \varepsilon_t$ cu $p_{ij} = 1 - c/T^\delta$
 - ▶ $c, \delta > 0$: comutările devin mai rare când T crește
 - ▶ varianța sumelor parțiale crește ca la un proces $I(d)$, $d > 0$
 - ▶ autocorelațiile $\propto \lambda^k$, cu $\lambda \rightarrow 1$, scad atît de lent încît, în orice eșantion finit, par hiperbolice
- ▣ Consecințe
 - ▶ o estimatie GPH sau Whittle locală semnificativă ([Capitolul 10](#)) nu deosebește integrarea fracționară de rupturile ocazionale sau de regimuri
 - ▶ același lucru este valabil pentru persistența GARCH (secțiunea [Regimuri de volatilitate și MS-GARCH](#)) și pentru testele de rădăcină unitară cu rupturi ([Capitolul 2](#))
- ▣ Care descriere este „adevărată” contează mai puțin decît care prognozează mai bine în afara eșantionului

Simulare: estimații GPH ale lui d cu schimbare de regim

□ $y_t = \mu_{S_t} + \varepsilon_t$, $\mu \in \{0, 1\}$, $\sigma = 1$; media estimațiilor GPH ($m = T^{0.5}$) pe 200 de replicări, ± 2 erori standard


Interpretarea simulării

- ▣ Comutări rare ($p = 1 - 5/T$): media $\hat{d} = 0,43; 0,51; 0,60; 0,63$ pentru $T = 250; 1\,000; 4\,000; 16\,000$: nu dispăre când T crește
- ▣ $p = 0,95$ fix: $0,30; 0,18; 0,08; 0,01$: memorie scurtă, $\hat{d} \rightarrow 0$ pe măsură ce frecvențele folosite se apropie de zero
- ▣ Traectoria din stînga are 6 comutări în 4000 de observații; autocorelația ei este 0,12 la lagul 50 și 0,06 la lagul 200

Regimuri sau rupturi?

- O ruptură ([Capitolul 2](#)) este un regim care nu revine niciodată: P superior bidiagonală, $S_1 = 1$ [Chib \(1998\)](#)
 - ▶ filtrul Hamilton și EM se aplică neschimbate; masca tranzițiilor ține tranzițiile interzise la zero
- Regimurile recurente pun în comun informația din episoade: al doilea episod de inflație ridicată folosește parametrii primului
 - ▶ rupturile cer un nou set de parametri pentru fiecare episod și nu spun nimic despre viitor
- Comparăm cele două prin BIC sau verosimilitatea marginală; [Garcia și Perron \(1996\)](#): rata reală a dobânzii din SUA este descrisă mai bine prin trei regimuri recurente decât printr-un proces stabil

Regimurile inflației din România din 1997



- Inflația anuală IAPC, $100 \ln(P_t/P_{t-12})$, din februarie 1997 ($T = 355$); MSIH(3)-AR(1), EM din 25 de puncte de pornire; linii întrerupte: punctele de schimbare ale modelului cu 4 regimuri; scară logaritmică simetrică

Interpretarea regimurilor inflației

- ▣ Nivelurile regimurilor $\nu_j/(1 - \phi)$: 68,7%, 17,8% și 2,9%; abaterea standard a șocurilor 10,58; 1,70 și 0,45 pp; $\phi = 0,971$: după 2001 cele două regimuri inferioare diferă mai ales prin volatilitate
- ▣ Regimul volatil revine la creșterea TVA din 2010, în 2022 și în 2025; probabilitățile filtrate în august 2026 (inflația 6,1%): 0,00; 0,93; 0,07
- ▣ BIC preferă punctele de schimbare: 3 segmente 887,0, 4 segmente 897,5, schimbare de regim 934,1; punctele de schimbare ale modelului cu 4 segmente: aprilie 1998, martie 1999, septembrie 2000
- ▣ Interpretare: dezinflația a fost un proces într-un singur sens
 - ▶ după 2000 un singur segment, foarte persistent, absoarbe creșterile din 2022 și 2025 ca șocuri
 - ▶ dacă ele sînt un regim recurent se decide în afara eșantionului

Regimurile cursului de schimb din România




Banca Națională a României, București, 2014

Foto: Crislia (2014); CC BY-SA 4.0; Wikimedia

[Commons](#)

- 1999–2005: depreciere graduală a leului vechi într-un regim de managed float
- Iulie 2005: denominarea ($10\,000\text{ ROL} = 1\text{ RON}$); august 2005: țintirea inflației, cu un regim de managed float; contul de capital complet liberalizat în 2006
- Episoade: octombrie 2008, 2011–2012, martie 2020, mai 2025 (alegerile prezidențiale și tensiunile fiscale)
- Modelul: variații logaritmice săptămânale, $\text{MSIH}(3)$ ordonat după volatilitate; regimurile sînt rezultate ale politicii, nu regimul anunțat

Regimurile de volatilitate ale EUR/RON, 1999–2026



- ☐ Sus: EUR/RON (cursul de referință BCE până în iunie 2005, BNR din iulie 2005); jos: probabilitățile netezite ale regimurilor calm, intermediar și agitat; $T = 1\,445$ de săptămâni


Interpretarea regimurilor EUR/RON

- ▣ Abaterea standard săptămînală pe regim: 0,07; 0,39 și 1,51%; durate așteptate de 16; 17 și 20 de săptămîni
- ▣ Înainte de iulie 2005 regimul agitat cuprinde 87% din săptămîni (deprecierea continuă a leului vechi, media 0,25% pe săptămîină), după aceea 18%; regimul calm trece de la 2% la 25%
- ▣ Probabilitatea regimului agitat atinge 1,00 în octombrie 2008–martie 2009 și 1,00 în primăvara lui 2025; cea mai mare variație săptămînală din 2025, 2,76%, în săptămîina încheiată la 9 mai 2025
- ▣ EUR/RON a avut media 4,9773 în aprilie 2025 și era 5,2644 la sfîrșitul eșantionului: o schimbare de nivel urmată de revenirea la calm, cum prevede un regim de managed float

Proгноzele unui model cu schimbare de regim

- Proгноza regimului: $\hat{\xi}_{T+h|T} = (P')^h \hat{\xi}_{T|T}$, care converge spre π cu viteza λ^h
 - la un pas: $f(y_{T+1} | Y_T) = \sum_j \hat{\xi}_{j,T+1|T} N(x'_{T+1} \beta_j, \sigma_j^2)$, un **amestec**: asimetric, cu cozi groase, posibil bimodal
- La mai mulți pași, cu termeni AR: media nu este liniară în regimurile trecute (MSM) sau cere traiectoria regimurilor; simulăm traiectorii ale perechii (S, y)
- Evaluarea ([Capitolul 1](#)): prognozele punctuale prin RMSE și Diebold–Mariano; densitățile prin scorul logaritmic, PIT și CRPS; probabilitățile regimurilor prin QPS
 - $QPS = \frac{2}{T} \sum_t (\hat{p}_t - d_t)^2$ [Diebold și Rudebusch \(1989\)](#): scorul Brier al unei probabilități de recesiune $\hat{p}_t$ față de indicatorul NBER d_t (1 în recesiune); 0 este perfect, 2 cel mai slab
- [Clements și Krolzig \(1998\)](#): modelele MS sînt rareori superioare modelelor AR liniare în prognozele punctuale ale PIB; valoarea lor stă în densități și în probabilitățile punctelor de întoarcere

PIB-ul SUA: prognoze de densitate la un pas, 1990–2019



- Fereastră extinsă din T2 1947, 120 de trimestre, AR(1) reestimat în fiecare trimestru, MSIH(2)-AR(1) la fiecare 4 trimestre (EM, pornind de la soluția anterioară); stînga: diferența cumulată a scorurilor logaritmice; dreapta: histogramele PIT (linia întreruptă: uniformă)

Interpretarea comparației prognozelor

- RMSE: AR(1) 0,554, MSIH(2)-AR(1) 0,558: prognozele punctuale sînt aproape identice, cum au găsit Clements și Krolzig
- Scorul logaritmice mediu: $-1,028$ față de $-0,890$; Diebold–Mariano pe diferență 1,16 ($p = 0,24$)
- Câștigul vine din regimul de varianță: densitatea AR(1) este prea largă după 1984 (PIT concentrat la mijloc, KS $p < 0,001$); densitatea MS este mai aproape de uniformă, dar nici ea nu este calibrată (KS $p = 0,01$)
- Câștigul cumulat de scor logaritmice înainte de 2008: 17,72; din 2008: $-1,10$: modelul cu regimuri câștigă în perioadele calme și pierde în criză

O întrebare deschisă

- Poate un model cu schimbare de regim să dateze în timp real recesiunile și regimurile inflației din România mai bine decât regulile simple și este episodul din 2025 un regim nou?
 - ▶ formal: H_0 : QPS egal pentru probabilitatea filtrată a regimului și pentru regula celor două trimestre negative, față de o cronologie de referință, pe trimestre preînregistrate
 - ▶ infirmată de o diferență semnificativă pe trimestre pe care modelul nu le-a văzut, cu ediții ale PIB
- Miza: România nu are un comitet oficial de datare a ciclului economic; politica reacționează la regimuri pe care le vede doar cu întârziere
 - ▶ literatura de pornire: [Hamilton \(1989\)](#), [Chauvet și Piger \(2008\)](#), [Clements și Krolzig \(1998\)](#), [Hamilton \(2016\)](#)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate care datează ciclurile economice ale țărilor din Europa Centrală și de Est cu modele Markov switching; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** Ce specificație (MSM, MSIH, TVTP cu ce indicator avansat) ar trebui să separe recesiunile de erele de volatilitate în PIB-ul României?
 - ▶ **cod și replicare:** cereți un filtru Hamilton, apoi reproduceți întâi o cifră cunoscută (log-verosimilitatea lui Hamilton –181,26)
 - ▶ **robustețe și critică:** Joacă rolul unui recenzent ostil: enumeră felurile în care o datare a regimurilor poate fi un artefact al specificației sau al punctelor de pornire.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Verosimilitatea este maximul global dintre multe puncte de pornire, iar regimul ales nu este degenerat
- ▣ Afirmațiile despre timpul real folosesc probabilități filtrate și ediții ale datelor, niciodată probabilități netezite
- ▣ Numărul de regimuri se testează prin bootstrap sau se alege printr-un criteriu fixat dinainte, nu prin numărarea gradelor de libertate ale unui χ^2
- ▣ Semnificația fiecărui regim se verifică față de evenimente externe, nu se presupune din eticheta lui

Mini studiu de caz: cât de robustă este o datare a recesiunilor?



- Creșterea PIB-ului SUA: patru specificații × trei începuturi ale eșantionului, toate pînă în T4 2019; QPS al probabilității netezite a regimului cu media scăzută față de trimestrele NBER, 1985–2019
- QPS între 0,034 și 1,846 (o probabilitate constantă are scorul 0,145)
 - ▶ 4 variante semnalează majoritatea trimestrelor: regimul lor cu media scăzută este Marea Moderație
 - ▶ 1 din 12 datează atît 2001, cît și 2008 fără alarme false: un rezumat AI care raportează o singură variantă drept „datarea” greșește

Idee de proiect

- ▣ **O cronologie a ciclului economic din România pe baza regimurilor:** întâi replicare, apoi extindere
 - ▶ replicați: Tabelul I al lui Hamilton pe datele lui (log-verosimilitatea $-181,26$) și modelul TVTP al lui Filardo ($-586,20$)
 - ▶ extindeți: PIB-ul și producția industrială ale României, MSM față de MSIH, TVTP cu ESI drept indicator avansat, alegerea bayesiană a lui K , probabilități filtrate în timp real
 - ▶ preînregistrați: eșantionul, specificațiile, schema punctelor de pornire, cronologia de referință și comparația QPS
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Filtrul Hamilton și netezitorul Kim sînt recursii bayesiene exacte pentru o stare latentă discretă
- ▣ EM și verosimilitatea maximă numerică găsesc maxime locale și degenerate: multe puncte de pornire, apoi judecată
- ▣ Numărul de regimuri este o problemă de testare nestandard: bootstrap, Garcia, CHP sau criterii informaționale
- ▣ TVTP, MS-VAR și MS-GARCH dau regimurilor un conținut economic; eşantionarea Gibbs face vizibilă incertitudinea
- ▣ Regimurile, rupturile și memoria lungă sînt apropiate observațional; prognozele decid

Autoevaluare

Întrebări

- ▣ De ce are nevoie netezitorul Kim de $\hat{\xi}_{t+1|t}$ la numitor?
- ▣ De ce are nevoie modelul MSM-AR(4) al lui Hamilton de 32 de stări?
- ▣ Ce trei condiții ale asimptoticii LR nu sînt îndeplinite la testarea unui regim față de două?
- ▣ De ce depinde de traiectorie verosimilitatea modelului MS-GARCH naiv?
- ▣ De ce poate o medie cu schimbare de regim să producă o estimatie GPH pozitivă?

Urmează:

- ▣ Modelarea avansată a volatilității
- ▣ Măsuri realizate, HAR și GARCH multivariat

Anexă: EM pentru lanțul Markov, pas cu pas

- Log-verosimilitatea așteptată a datelor complete:

$$Q(\theta \mid \theta^{(m)}) = \sum_j \hat{\xi}_{j,1|T} \ln \rho_j + \sum_{t \geq 2} \sum_{i,j} \hat{\xi}_{ij,t|T} \ln p_{ij} + \sum_t \sum_j \hat{\xi}_{j,t|T} \ln \eta_{jt}$$

- Maximizăm $\sum_{t,j} \hat{\xi}_{ij,t|T} \ln p_{ij}$ cu $\sum_j p_{ij} = 1$: lagrangianul $\Rightarrow p_{ij} = \sum_t \hat{\xi}_{ij,t|T} / \sum_t \sum_k \hat{\xi}_{ik,t|T}$

- iar $\sum_k \hat{\xi}_{ik,t|T} = \hat{\xi}_{i,t-1|T}$; partea Gaussiană dă cele mai mici pătrate ponderate

- Monotonia: $\ln L(\theta) = Q(\theta \mid \theta^{(m)}) - H(\theta \mid \theta^{(m)})$, iar H este maxim în $\theta^{(m)}$ (inegalitatea Gibbs) [Dempster, Laird și Rubin \(1977\)](#)

Anexă: netezitorul Kim, pasul Markov

- $\Pr(S_t = i \mid S_{t+1} = j, Y_T) = \frac{f(y_{t+1:T} \mid S_t = i, S_{t+1} = j, Y_t) \Pr(S_t = i \mid S_{t+1} = j, Y_t)}{f(y_{t+1:T} \mid S_{t+1} = j, Y_t)}$
- Dacă $y_{t+1:T}$ depinde de S_t doar prin S_{t+1} (adevărat pe starea extinsă), raportul densităților este 1
- Atunci $\Pr(S_t = i \mid S_{t+1} = j, Y_t) = \hat{\xi}_{i,t|t} p_{ij} / \hat{\xi}_{j,t+1|t}$; înmulțim cu $\hat{\xi}_{j,t+1|T}$ și sumăm după j
- Cu o stare continuă (spațiul stărilor cu schimbare de regim, [Capitolul 6](#)) raportul nu este 1: netezitorul Kim devine o aproximare

Bibliografie (1/4)

- ▣ Albert, J. H., & Chib, S. (1993). Bayes inference via Gibbs sampling of autoregressive time series subject to Markov mean and variance shifts. *Journal of Business & Economic Statistics*, 11(1), 1–15. doi:10.1080/07350015.1993.10509929
- ▣ Ang, A., & Bekaert, G. (2002). International asset allocation with regime shifts. *The Review of Financial Studies*, 15(4), 1137–1187. doi:10.1093/rfs/15.4.1137
- ▣ Ang, A., & Timmermann, A. (2012). Regime changes and financial markets. *Annual Review of Financial Economics*, 4, 313–337. doi:10.1146/annurev-financial-110311-101808
- ▣ Baum, L. E., Petrie, T., Soules, G., & Weiss, N. (1970). A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. *The Annals of Mathematical Statistics*, 41(1), 164–171. doi:10.1214/aoms/1177697196
- ▣ Bauwens, L., Preminger, A., & Rombouts, J. V. K. (2010). Theory and inference for a Markov switching GARCH model. *The Econometrics Journal*, 13(2), 218–244. doi:10.1111/j.1368-423X.2009.00307.x
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- ▣ Carrasco, M., Hu, L., & Ploberger, W. (2014). Optimal test for Markov switching parameters. *Econometrica*, 82(2), 765–784. doi:10.3982/ECTA8609
- ▣ Carter, C. K., & Kohn, R. (1994). On Gibbs sampling for state space models. *Biometrika*, 81(3), 541–553. doi:10.1093/biomet/81.3.541
- ▣ Celeux, G., Hurn, M., & Robert, C. P. (2000). Computational and inferential difficulties with mixture posterior distributions. *Journal of the American Statistical Association*, 95(451), 957–970. doi:10.1080/01621459.2000.10474285
- ▣ Chauvet, M., & Piger, J. (2008). A comparison of the real-time performance of business cycle dating methods. *Journal of Business & Economic Statistics*, 26(1), 42–49. doi:10.1198/073500107000000296
- ▣ Chib, S. (1996). Calculating posterior distributions and modal estimates in Markov mixture models. *Journal of Econometrics*, 75(1), 79–97. doi:10.1016/0304-4076(95)01770-4
- ▣ Chib, S. (1998). Estimation and comparison of multiple change-point models. *Journal of Econometrics*, 86(2), 221–241. doi:10.1016/S0304-4076(97)00115-2

Bibliografie (2/4)

- ▣ Chib, S. (1995). Marginal likelihood from the Gibbs output. *Journal of the American Statistical Association*, 90(432), 1313–1321. doi:10.1080/01621459.1995.10476635
- ▣ Cho, J. S., & White, H. (2007). Testing for regime switching. *Econometrica*, 75(6), 1671–1720. doi:10.1111/j.1468-0262.2007.00809.x
- ▣ Clements, M. P., & Krolzig, H.-M. (1998). A comparison of the forecast performance of Markov-switching and threshold autoregressive models of US GNP. *The Econometrics Journal*, 1(1), C47–C75. doi:10.1111/1368-423X.11004
- ▣ Davies, R. B. (1987). Hypothesis testing when a nuisance parameter is present only under the alternative. *Biometrika*, 74(1), 33–43. doi:10.1093/biomet/74.1.33
- ▣ Dempster, A. P., Laird, N. M., & Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B*, 39(1), 1–22. doi:10.1111/j.2517-6161.1977.tb01600.x
- ▣ Diebold, F. X., & Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159. doi:10.1016/S0304-4076(01)00073-2
- ▣ Diebold, F. X., Lee, J.-H., & Weinbach, G. C. (1994). Regime switching with time-varying transition probabilities. In C. P. Hargreaves (Ed.), *Nonstationary Time Series Analysis and Cointegration* (pp. 283–302). Oxford University Press. doi:10.1093/oso/9780198773917.003.0010
- ▣ Diebold, F. X., & Rudebusch, G. D. (1989). Scoring the leading indicators. *The Journal of Business*, 62(3), 369–391. doi:10.1086/296467
- ▣ Ehrmann, M., Ellison, M., & Valla, N. (2003). Regime-dependent impulse response functions in a Markov-switching vector autoregression model. *Economics Letters*, 78(3), 295–299. doi:10.1016/S0165-1765(02)00256-2
- ▣ Filardo, A. J. (1994). Business-cycle phases and their transitional dynamics. *Journal of Business & Economic Statistics*, 12(3), 299–308. doi:10.1080/07350015.1994.10524545
- ▣ Frühwirth-Schnatter, S. (2001). Markov chain Monte Carlo estimation of classical and dynamic switching and mixture models. *Journal of the American Statistical Association*, 96(453), 194–209. doi:10.1198/016214501750333063
- ▣ Frühwirth-Schnatter, S. (2006). *Finite Mixture and Markov Switching Models*. Springer. doi:10.1007/978-0-387-35768-3

Bibliografie (3/4)

- ▣ Garcia, R. (1998). Asymptotic null distribution of the likelihood ratio test in Markov switching models. *International Economic Review*, 39(3), 763–788. doi:10.2307/2527399
- ▣ Garcia, R., & Perron, P. (1996). An analysis of the real interest rate under regime shifts. *The Review of Economics and Statistics*, 78(1), 111–125. doi:10.2307/2109851
- ▣ Goldfeld, S. M., & Quandt, R. E. (1973). A Markov model for switching regressions. *Journal of Econometrics*, 1(1), 3–15. doi:10.1016/0304-4076(73)90002-X
- ▣ Gray, S. F. (1996). Modeling the conditional distribution of interest rates as a regime-switching process. *Journal of Financial Economics*, 42(1), 27–62. doi:10.1016/0304-405X(96)00875-6
- ▣ Haas, M., Mittnik, S., & Paoletta, M. S. (2004). A new approach to Markov-switching GARCH models. *Journal of Financial Econometrics*, 2(4), 493–530. doi:10.1093/jjfinec/nbh020
- ▣ Hamilton, J. D. (1990). Analysis of time series subject to changes in regime. *Journal of Econometrics*, 45(1–2), 39–70. doi:10.1016/0304-4076(90)90093-9
- ▣ Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384. doi:10.2307/1912559
- ▣ Hamilton, J. D. (2016). Macroeconomic regimes and regime shifts. In J. B. Taylor & H. Uhlig (Eds.), *Handbook of Macroeconomics* (Vol. 2A, pp. 163–201). Elsevier. doi:10.1016/bs.hesmac.2016.03.004
- ▣ Hamilton, J. D., & Susmel, R. (1994). Autoregressive conditional heteroskedasticity and changes in regime. *Journal of Econometrics*, 64(1–2), 307–333. doi:10.1016/0304-4076(94)90067-1
- ▣ Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. doi:10.2307/j.ctv14jx6sm
- ▣ Hansen, B. E. (1992). The likelihood ratio test under nonstandard conditions: Testing the Markov switching model of GNP. *Journal of Applied Econometrics*, 7(S1), S61–S82. doi:10.1002/jae.3950070506
- ▣ Harding, D., & Pagan, A. (2002). Dissecting the cycle: A methodological investigation. *Journal of Monetary Economics*, 49(2), 365–381. doi:10.1016/S0304-3932(01)00108-8

Bibliografie (4/4)

- ▣ Hathaway, R. J. (1985). A constrained formulation of maximum-likelihood estimation for normal mixture distributions. *The Annals of Statistics*, 13(2), 795–800. doi:10.1214/aos/1176349557
- ▣ Kim, C.-J. (1994). Dynamic linear models with Markov-switching. *Journal of Econometrics*, 60(1–2), 1–22. doi:10.1016/0304-4076(94)90036-1
- ▣ Kim, C.-J., & Nelson, C. R. (1999). *State-Space Models with Regime Switching: Classical and Gibbs-Sampling Approaches with Applications*. MIT Press. doi:10.7551/mitpress/6444.001.0001
- ▣ Klaassen, F. (2002). Improving GARCH volatility forecasts with regime-switching GARCH. *Empirical Economics*, 27(2), 363–394. doi:10.1007/s001810100100
- ▣ Krolzig, H.-M. (1997). *Markov-Switching Vector Autoregressions: Modelling, Statistical Inference, and Application to Business Cycle Analysis*. Springer. doi:10.1007/978-3-642-51684-9
- ▣ Lamoureux, C. G., & Lastrapes, W. D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234. doi:10.1080/07350015.1990.10509794
- ▣ Maheu, J. M., & McCurdy, T. H. (2000). Identifying bull and bear markets in stock returns. *Journal of Business & Economic Statistics*, 18(1), 100–112. doi:10.1080/07350015.2000.10524851
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2), 257–286. doi:10.1109/5.18626
- ▣ Sims, C. A., & Zha, T. (2006). Were there regime switches in U.S. monetary policy? *American Economic Review*, 96(1), 54–81. doi:10.1257/000282806776157678
- ▣ Stephens, M. (2000). Dealing with label switching in mixture models. *Journal of the Royal Statistical Society: Series B*, 62(4), 795–809. doi:10.1111/1467-9868.00265