



Analiza avansată a seriilor de timp și previziune

Capitolul 8: Modelarea avansată a volatilității: măsuri realizate, HAR și GARCH multivariat



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/4)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARCH:** AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARMA:** AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BEKK:** Baba–Engle–Kraft–Kroner (multivariate GARCH model) — modelul GARCH multivariat Baba–Engle–Kraft–Kroner
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC:** Bayesian Information Criterion (criteriul informațional bayesian (Schwarz))
- ▣ **BNHLS:** Barndorff–Nielsen–Hansen–Lunde–Shephard (Barndorff–Nielsen–Hansen–Lunde–Shephard)
- ▣ **BNR:** Banca Națională a României
- ▣ **BV:** Bipower Variation (variația bipower)
- ▣ **CAC:** Cotation Assistée en Continu (CAC 40 index, Paris) — indicele CAC 40 al bursei din Paris
- ▣ **CCC:** Constant Conditional Correlation (model) — model cu corelație condiționată constantă
- ▣ **DCC:** Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ **DCC-NL:** DCC with Nonlinear shrinkage of the target (Engle–Ledoit–Wolf 2019) — DCC cu shrinkage neliniar al țintei (Engle–Ledoit–Wolf 2019)
- ▣ **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EGARCH:** Exponential GARCH (GARCH exponențial)

Acronime folosite în acest material (2/4)

- **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- **ES**: Expected Shortfall (pierderea așteptată în coadă)
- **ETF**: Exchange-Traded Fund (fond tranzacționat la bursă)
- **FDR**: False Discovery Rate (rata descoperirilor false)
- **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — furnizorul de indici FTSE Russell
- **FWER**: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- **GARCH-MIDAS**: GARCH with a Mixed Data Sampling long-run component (Engle–Ghysels–Sohn 2013) — GARCH cu o componentă de termen lung MIDAS (Engle–Ghysels–Sohn 2013)
- **GARCH-X**: GARCH with eXogenous variables (GARCH cu variabile exogene)
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- **GMM**: Generalized Method of Moments (metoda generalizată a momentelor)
- **GMV**: Global Minimum-Variance (portfolio) — portofoliul de varianță minimă globală
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- **HAR**: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen

Acronime folosite în acest material (3/4)

- ▣ **HAR-CJ**: HAR with Continuous and Jump components (HAR cu componente continuă și de salt)
- ▣ **HARQ**: HAR with realised Quarticity (HAR cu cuarticitatea realizată)
- ▣ **HEAVY**: High-frEQUENCY-bAsed VolatilitY (models) — modele de volatilitate pe baza datelor de înaltă frecvență
- ▣ **IGARCH**: Integrated GARCH (GARCH integrat)
- ▣ **IPP**: Indicele Prețurilor Producției
- ▣ **IQ**: Integrated Quarticity (cuarticitatea integrată)
- ▣ **LLM**: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MCS**: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ **MFM**: Modelling Financial Markets (Modelarea piețelor financiare, cursul de master)
- ▣ **MIDAS**: MlXed DAta Sampling (regression) — regresie cu date de frecvențe mixte
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **MSTR**: MicroStrategy (Strategy Inc.), NASDAQ ticker (MicroStrategy (Strategy Inc.), simbolul bursier NASDAQ)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **OPG**: Outer Product of the Gradient (scores) — produsul exterior al scorurilor
- ▣ **PPI**: Producer Price Index (indicele prețurilor producției (IPP))
- ▣ **QLIKE**: Quasi-LIKElihood loss (pierderea de tip cvasi-verosimilitate)

Acronime folosite în acest material (4/4)

- ▣ **QML**: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- ▣ **QMLE**: Quasi-Maximum Likelihood Estimator (estimatorul de verosimilitate cvasi-maximă)
- ▣ **QV**: Quadratic Variation (variația pătratică)
- ▣ **RGARCH**: Realized GARCH (model GARCH cu măsură realizată)
- ▣ **RK**: Realised Kernel (estimator cu nucleu al varianței integrate, robust la zgometul de microstructură)
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **RQ**: Realised Quarticity (cuarticitatea realizată)
- ▣ **RV**: Realised Variance (varianța realizată)
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **SV**: Stochastic Volatility (volatilitate stohastică)
- ▣ **TLC**: Teorema Limită Centrală
- ▣ **TQ**: Tripower Quarticity (cuarticitatea tripower)
- ▣ **TSA**: Time Series Analysis (Serii de timp, cursul de licență)
- ▣ **TSLA**: Tesla Inc., NASDAQ ticker (Tesla Inc., simbolul bursier NASDAQ)
- ▣ **TSRV**: Two-Scales Realised Variance (varianța realizată cu două scale de timp)
- ▣ **UTC**: Coordinated Universal Time (Temps Universel Coordonné) — timpul universal coordonat
- ▣ **VEC**: VEC multivariate GARCH (half-vectorised covariance) — GARCH multivariat VEC (covarianța semivectorizată)
- ▣ **VIX**: CBOE Volatility Index (indicele de volatilitate CBOE)
- ▣ **VR**: Variance Ratio (raportul varianțelor)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cât de precis putem măsura, modela și prognoza o varianță care nu se observă niciodată?
 - ▶ și care dintre instrumentele noastre funcționează în continuare când datele sînt zgomotoase, au salturi sau au multe dimensiuni?
 - ▶ două căi către volatilitate: un filtru parametric al randamentelor zilnice (GARCH) și o măsurare neparametrică din prețurile intraday (măsurile realizate); cercetarea actuală le combină
- ▣ **Traseul** capitolului
 - ▶ verosimilitatea cvasi-maximă pentru GARCH și inferența robustă; componente de termen lung: component GARCH și GARCH-MIDAS cu factori macroeconomici
 - ▶ măsuri realizate: asimptotica varianței realizate, zgomotul de microstructură, realised kernels, variația bipower și testele de salt
 - ▶ prognoza cu măsuri realizate: HAR, HARQ, Realized GARCH, HEAVY; funcții de pierdere robuste
 - ▶ cazul multivariat: BEKK, DCC și cDCC, blestemul dimensionalității și DCC-NL, covarianța realizată
- ▣ Pornim de la [TSA, Capitolul 5](#) (GARCH, GJR, EGARCH, curba de impact a știrilor, QLIKE) și [TSA, Capitolul 14](#) (bazele DCC)
 - ▶ MFM, Capitolele 5–9 aplică aceste instrumente riscului de piață; Seminarul 8 are loc înaintea acestui curs

Rezultatele învățării

- Enunțați condițiile în care QML gaussian pentru GARCH este consistent și asimptotic normal și calculați erorile standard Bollerslev–Wooldridge
- Separați volatilitatea de termen scurt de cea de termen lung cu component GARCH și GARCH-MIDAS și evaluați dacă un factor macroeconomic contează
- Derivați teoria asimptotică a varianței realizate, explicați efectul zgomotului și al salturilor și alegeți între RV, realised kernels și variația bipower
- Prognozați volatilitatea cu HAR, HARQ și Realized GARCH și comparați prognozele cu funcții de pierdere robuste la un proxy zgomotos
- Estimați modele DCC și cDCC, explicați de ce matricele de covarianță mari au nevoie de shrinkage și măsurați corelația din date intraday

Bibliografie, date și instrumente

- ▣ Bibliografia de bază: Francq și Zakoïan (2019); Andersen, Bollerslev, Diebold și Labys (2003); Barndorff-Nielsen și Shephard (2002); Barndorff-Nielsen, Hansen, Lunde și Shephard (2008)
 - ▶ prognoza și cazul multivariat: Corsi (2009); Hansen, Huang și Shek (2012); Engle (2002); Patton (2011)
 - ▶ studii de caz: Engle, Ghysels și Sohn (2013) (GARCH-MIDAS), Bollerslev, Patton și Quaadvlieg (2016) (HARQ), Hansen, Huang și Shek (2012) (Realized GARCH), Engle, Ledoit și Wolf (2019) (DCC-NL)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_08](#)
 - ▶ QML cu erori standard sandwich, component GARCH, GARCH-MIDAS, realised kernels, teste de salt, HAR/HARQ, Realized GARCH, DCC/cDCC și shrinkage neliniar scrise explicit în `numpy`
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Utilizare
Măsurile realizate zilnice pentru șase indici bursieri (RV la 5 minute, BV, realised kernel, randamentul deschidere-închidere), 2000–2022	Heber, Lunde, Shephard și Sheppard (2009), v0.3	HAR, RGARCH
Bitcoin și Ether: prețuri la un minut 2018–2026, prețuri la o secundă în august 2026	datele publice Binance (data.binance.vision); măsurile calculate de noi	zgomot, salturi, HARQ
S&P 500, DAX, BET, Bitcoin, 14 acțiuni și 3 ETF-uri pe acțiuni din SUA, zilnic	EODHD	QML, MIDAS, DCC
cursul de referință EUR/RON	BNR	QML
producția industrială și IPP pentru bunuri finite ale SUA (lunar)	FRED (INDPRO, WPSFD49207)	GARCH-MIDAS

- Biblioteca Oxford-Man nu mai este actualizată din februarie 2022 (copie arhivată, citată conform condițiilor ei); datele Binance la un minut extind măsurile realizate pînă la 18 septembrie 2026; o simulare calibrată oferă teoriei un adevăr cunoscut
- RV: varianța realizată; BV: variația bipower; IPP (PPI): indicele prețurilor producției

De la sala de tranzacționare la fiecare tranzacție



Bursa din New York, 1908

Foto: Helen D. Van Eaton, *Leslie's Monthly Magazine* (1908);
public domain; Wikimedia Commons

- 1982–1986: ARCH și GARCH Engle (1982), Bollerslev (1986): volatilitatea ca varianță condiționată filtrată a randamentelor zilnice
- 1992–2004: teoria QML Bollerslev și Wooldridge (1992), Lee și Hansen (1994), Lumsdaine (1996), Francq și Zakoïan (2004); componente Engle și Lee (1999); DCC Engle (2002)
- 1998–2008: varianța realizată Andersen și Bollerslev (1998), Andersen, Bollerslev, Diebold și Labys (2003), Barndorff-Nielsen și Shephard (2002); variația bipower Barndorff-Nielsen și Shephard (2004); zgomot și kernel-uri Zhang, Mykland și Aït-Sahalia (2005), Barndorff-Nielsen, Hansen, Lunde și Shephard (2008)
- 2009–2019: HAR Corsi (2009), Realized GARCH Hansen, Huang și Shek (2012), GARCH-MIDAS Engle, Ghysels și Sohn (2013), HARQ Bollerslev, Patton și Quaadvlieg (2016), DCC-NL Engle, Ledoit și Wolf (2019)
- Astăzi: datele de înaltă frecvență sînt ieftine; întrebările sînt statistice (zgomot, salturi, dimensiune, evaluare)

De la TSA la acest capitol

- ▣ Cunoscut (TSA, Capitolul 5): GARCH(1,1), GJR, EGARCH, curba de impact a știrilor, ML cu erori gaussiene și Student- t , QLIKE; (TSA, Capitolul 14): CCC și DCC
- ▣ Nou aici
 - ▶ de ce ML gaussian funcționează și când randamentele nu sînt gaussiene și ce erori standard sînt atunci valide
 - ▶ volatilitate cu o componentă lentă, determinată de factori macroeconomici; volatilitate măsurată din prețurile intraday, cu propria eroare de eșantionare
 - ▶ modele care folosesc măsuri realizate; evaluarea față de o țintă zgomotoasă; matrice de covarianță cu multe active
- ▣ Volatilitatea stochastică (un logaritm al varianței latent, cu propriul șoc): Capitolul 6; GARCH cu schimbare de regim: Capitolul 7; backtesting pentru VaR și ES: Capitolul 9; rough volatility: Capitolul 10

Cvasi-verosimilitatea gaussiană (1/2): modelul

- Șocul randamentului este produsul dintre volatilitate și un șoc standardizat; varianța urmează recursia GARCH(1,1)

$$\varepsilon_t = \sigma_t(\theta_0) \eta_t, \quad \sigma_t^2(\theta) = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2(\theta)$$

- Notățiile

- ▶ ε_t : randamentul centrat al zilei t ; $\sigma_t^2(\theta)$: varianța lui condiționată de trecutul $\mathcal{F}_{t-1}$ (informația pînă în ziua $t - 1$)
- ▶ η_t : șoc standardizat i.i.d., $\mathbb{E}\eta_t = 0$, $\mathbb{E}\eta_t^2 = 1$; legea lui (distribuția Normală, Student- t , asimetrică) este necunoscută
- ▶ $\theta = (\omega, \alpha, \beta)$, cu valoarea adevărată θ_0 : $\omega > 0$ fixează nivelul, $\alpha \geq 0$ reacția la pătratul șocului de ieri, $\beta \geq 0$ persistența varianței de ieri

- Recursia pornește de la un σ_1^2 arbitrar; efectul valorii de start dispare geometric cînd $\beta < 1$

Cvasi-verosimilitatea gaussiană (2/2): estimatorul și scorul

- QMLE: se maximizează log-verosimilitatea gaussiană, folosită ca ecuație de estimare chiar dacă η_t nu este gaussian

$$\hat{\theta} = \arg \max_{\theta} \sum_{t=1}^T \ell_t(\theta), \quad \ell_t(\theta) = -\frac{1}{2} \left(\ln \sigma_t^2(\theta) + \frac{\varepsilon_t^2}{\sigma_t^2(\theta)} \right)$$

- ▶ ℓ_t : log-densitatea gaussiană a zilei t , fără constantă; T : numărul de zile; $\hat{\theta}$: valoarea estimată
- Scorul, adică gradientul lui ℓ_t , are media condiționată zero în valoarea adevărată

$$s_t(\theta) = \frac{\partial \ell_t}{\partial \theta} = \frac{1}{2} \left(\frac{\varepsilon_t^2}{\sigma_t^2} - 1 \right) \frac{1}{\sigma_t^2} \frac{\partial \sigma_t^2}{\partial \theta}$$

- ▶ în θ_0 , $\varepsilon_t^2/\sigma_t^2 = \eta_t^2$, deci $\mathbb{E}(s_t|\mathcal{F}_{t-1}) = 0$, pentru că $\mathbb{E}\eta_t^2 = 1$
- ▶ doar varianța condiționată trebuie să fie corect specificată; forma legii lui η_t nu se folosește niciodată
- Scorul este o diferență de martingal (media condiționată de trecut este zero)
 - ▶ o TLC pentru martingale dă normalitatea asimptotică fără independența lui ε_t

Consistența și normalitatea asimptotică (1/2): staționaritatea și consistența

- GARCH(1,1) este strict staționar dacă și numai dacă logaritmul multiplicatorului zilnic al varianței are media negativă

$$\mathbb{E} \ln(\alpha_0 \eta_t^2 + \beta_0) < 0$$

- ▶ $\alpha_0 \eta_t^2 + \beta_0$: factorul cu care un șoc al varianței este transmis de la o zi la următoarea; α_0, β_0 : valorile adevărate
- ▶ prin inegalitatea lui Jensen, condiția este mai slabă decât $\alpha_0 + \beta_0 < 1$ (varianță finită): IGARCH ($\alpha_0 + \beta_0 = 1$) este strict staționar, iar $\mathbb{E} \varepsilon_t^2$ poate fi infinită
- ▶ Lee și Hansen (1994), Lumsdaine (1996): GARCH(1,1), inclusiv IGARCH; Berkes, Horváth și Kokoszka (2003), Francq și Zakoïan (2004): GARCH(p, q) sub staționaritate strictă
- Consistența lui $\hat{\theta}$ Francq și Zakoïan (2004)
 - ▶ condiții: staționaritate strictă, θ_0 într-o mulțime compactă de parametri, identificabilitate (η_t^2 nu este o constantă)
 - ▶ nu este nevoie de niciun moment al lui ε_t
- Chiar și pentru GARCH exploziv ($\mathbb{E} \ln(\alpha_0 \eta^2 + \beta_0) > 0$), $(\hat{\alpha}, \hat{\beta})$ rămân consistenți și asimptotic normali, iar ω nu este identificat Jensen și Rahbek (2004)

Consistența și normalitatea asimptotică (2/2): legea limită

- Dacă θ_0 este interior mulțimii parametrilor și η_t are momentul de ordinul patru finit, estimatorul este asimptotic normal

$$\sqrt{T}(\hat{\theta} - \theta_0) \rightarrow N(0, (\kappa_\eta - 1)J^{-1}), \quad J = \mathbb{E} \left[\frac{1}{\sigma_t^4} \frac{\partial \sigma_t^2}{\partial \theta} \frac{\partial \sigma_t^2}{\partial \theta'} \right]$$

- ▶ $\kappa_\eta = \mathbb{E}\eta_t^4$: kurtosis-ul șocului (3 pentru distribuția Normală); $\kappa_\eta - 1 = \text{Var}(\eta_t^2)$
- ▶ J : o matrice 3×3 , media produsului exterior al sensibilităților relative $\sigma_t^{-2} \partial \sigma_t^2 / \partial \theta$; $\rightarrow$: convergența în distribuție când $T \rightarrow \infty$
- ▶ interpretare: varianța de eșantionare a lui $\hat{\theta}$ crește liniar cu kurtosis-ul șocurilor
- Frontiera: dacă $\alpha_0 = 0$, θ_0 nu este interior, iar limita este proiecția unui vector normal pe un con
 - ▶ de aceea [TSA](#), [Capitolul 5](#) testează efectele ARCH unilateral

Sandwich-ul și erorile standard Bollerslev–Wooldridge (1/2)

- Rezultatul general QML: varianța asimptotică este un „sandwich” format din două matrice

$$\sqrt{T}(\hat{\theta} - \theta_0) \rightarrow N(0, A^{-1} B A^{-1}), \quad A = -\mathbb{E} \frac{\partial^2 \ell_t}{\partial \theta \partial \theta'}, \quad B = \mathbb{E} s_t s_t'$$

- A : hessiana negativă așteptată (curbura log-verosimilității); B : varianța scorului s_t
- dacă verosimilitatea este cea adevărată, $A = B$ (egalitatea informațională), iar varianța devine A^{-1} ; sub QML, $A \neq B$

- Pentru GARCH, ambele matrice sînt proporționale cu J ([► Anexa](#))

$$A = \frac{1}{2} J, \quad B = \frac{\kappa_\eta - 1}{4} J, \quad A^{-1} B A^{-1} = (\kappa_\eta - 1) J^{-1}$$

- sandwich-ul regăsește legea limită de pe slide-ul anterior, pentru orice lege a lui η_t cu $\kappa_\eta < \infty$

Sandwich-ul și erorile standard Bollerslev–Wooldridge (2/2)

▣ Trei moduri de a calcula erorile standard

- ▶ doar din hessiană: $A^{-1} = 2J^{-1}$, corect doar dacă $\kappa_\eta = 3$; prea mici cu factorul $\sqrt{(\kappa_\eta - 1)/2}$ când $\kappa_\eta > 3$
- ▶ din produsul exterior al scorurilor (OPG): $B^{-1} = \frac{4}{\kappa_\eta - 1} J^{-1}$, și mai mici când $\kappa_\eta > 3$
- ▶ sandwich Bollerslev și Wooldridge (1992): $\hat{A}^{-1} \hat{B} \hat{A}^{-1}$, valabil oricare ar fi legea lui η_t (cu $\kappa_\eta < \infty$)


▣ Estimațiile folosite de Bollerslev și Wooldridge

- ▶ $\hat{A}$: hessiana observată a lui $-\frac{1}{T} \sum_t \ell_t$ în $\hat{\theta}$; $\hat{B} = \frac{1}{T} \sum_t \hat{s}_t \hat{s}_t'$, cu $\hat{s}_t = s_t(\hat{\theta})$ scorul estimat

▣ Testele Wald și de tip scor robuste folosesc sandwich-ul

- ▶ statistica raportului de cvasi-verosimilitate (cvasi-LR) nu mai are distribuția χ^2 , ci este o sumă ponderată de variabile χ_1^2 (hi-pătrat cu un grad de libertate)

Hessiana față de sandwich: un experiment Monte Carlo




- GARCH(1,1) cu $(\omega, \alpha, \beta) = (0,05, 0,08, 0,90)$, $T = 2\,000$, 300 de replicări; QML gaussian în fiecare; histograma lui $(\hat{\alpha} - \alpha_0)/\hat{s.e.}$

Interpretarea experimentului Monte Carlo

- ▣ η gaussian: acoperirea intervalelor de 95% pentru α este 95,0% (hessiană) și 94,3% (sandwich): ambele corecte
- ▣ Student- $t(5)$, $\kappa_\eta = 9$: intervalele din hessiană acoperă 73,0% pentru α și 74,7% pentru β ; intervalele sandwich 91,7% și 92,3%
- ▣ Teoria prezice factorul $\sqrt{(9-1)/2} = 2$ între cele două erori standard; estimațiile punctuale sînt aceleași
- ▣ Cu cozi groase, un test t pentru α construit cu erorile standard din hessiană respinge mult prea des: raportați implicit erorile standard sandwich

Erori standard robuste și naive pe cinci piețe



- QML gaussian pentru GARCH(1,1), randamente zilnice 2010–2026; bare: eroarea standard sandwich împărțită la eroarea standard din hessiană; etichete: kurtosis-ul $\hat{\kappa}_\eta$ al reziduurilor standardizate

Interpretarea celor cinci piețe

- S&P 500: $\hat{\alpha} = 0,154$, cu eroarea standard 0,013 (hessiană) față de 0,018 (sandwich); $\hat{\kappa}_{\eta} = 5,0$, factorul teoretic 1,42
- BET: $\hat{\kappa}_{\eta} = 12,2$, eroarea standard sandwich a lui $\hat{\alpha}$ este de 3,36 ori mai mare; EUR/RON (managed float): de 2,71 ori, $\hat{\kappa}_{\eta} = 61,8$
- Rapoartele urmează doar aproximativ $\sqrt{(\hat{\kappa}_{\eta} - 1)/2}$: în date, η_t nu este i.i.d., iar sandwich-ul nu are nevoie de această ipoteză
- ML Student- t crește log-verosimilitatea cu 124,4 (S&P 500) și 233,0 (BET), dar este consistent doar dacă forma t este corectă; QML are nevoie doar de ecuația varianței

Recapitulare: QML pentru GARCH

- ▣ QML gaussian este consistent dacă ecuația varianței este corectă, oricare ar fi forma inovațiilor
- ▣ Teoria are nevoie de staționaritate strictă, nu de varianță finită; IGARCH și chiar GARCH exploziv sînt acoperite
- ▣ Cu cozi groase, erorile standard din hessiană sînt prea mici cu factorul $\sqrt{(\kappa_\eta - 1)/2}$; folosiți Bollerslev–Wooldridge

GARCH cu variabile exogene

- GARCH-X: valoarea de ieri a unei variabile observate intră în ecuația varianței

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \pi' x_{t-1}$$

- ▶ x_{t-1} : vectorul variabilelor exogene cunoscute la sfârșitul zilei $t - 1$; π : coeficienții lor ($\pi'x$: suma ponderată)
- ▶ pozitivitatea lui σ_t^2 : $x_{t-1} \geq 0$ și $\pi \geq 0$ sau o specificare în logaritmi
- Candidați pentru x_t : o măsură realizată (duce la HEAVY și Realized GARCH, mai jos), VIX, un indice macroeconomic sau de incertitudine a politicilor, volumul tranzacțiilor
- ▶ teoria QML se păstrează dacă x_t este staționar și ergodic; dinamica lui nu trebuie modelată pentru prognoze cu un pas
- ▶ prognozele cu mai mulți pași au nevoie de un model pentru x_t : exact acest lucru adaugă Realized GARCH și HEAVY
- O variabilă lentă (o serie macroeconomică lunară) nu poate intra în recursia zilnică la frecvența ei: este nevoie de o structură pe componente (slide-urile următoare)

Component GARCH al lui Engle și Lee (1/2): modelul

- Engle și Lee (1999): varianța este suma dintre un nivel de termen lung q_t , care se mișcă lent, și o abatere tranzitorie de la acest nivel

$$\sigma_t^2 = q_t + \alpha(\varepsilon_{t-1}^2 - q_{t-1}) + \beta(\sigma_{t-1}^2 - q_{t-1})$$

$$q_t = \omega + \rho q_{t-1} + \phi(\varepsilon_{t-1}^2 - \sigma_{t-1}^2)$$

- ▶ q_t : componenta de termen lung (permanentă); ρ : persistența ei, apropiată de 1; ω : termenul ei liber
 - ▶ $\sigma_t^2 - q_t$: componenta tranzitorie; α, β : reacția și persistența ei, cu $\alpha + \beta < \rho$
 - ▶ $\varepsilon_{t-1}^2 - \sigma_{t-1}^2$: surpriza de varianță de ieri (cu media zero); ϕ : cât din această surpriză mută nivelul de termen lung
- Ambele componente sînt determinate de același șoc: modelul este un GARCH(2,2) restricționat


Component GARCH al lui Engle și Lee (2/2): două viteze

- Timpul de înjumătățire: numărul de zile după care jumătate dintr-un șoc al unei componente a dispărut

$$HL_q = \frac{\ln(1/2)}{\ln \rho}, \quad HL_{\sigma-q} = \frac{\ln(1/2)}{\ln(\alpha + \beta)}$$

- ▶ HL_q : timpul de înjumătățire al componentei de termen lung; $HL_{\sigma-q}$: al componentei tranzitorii
- ▶ o persistență $\rho = 0,99$ dă aproximativ 69 de zile; $\alpha + \beta = 0,9$ dă aproximativ 6,6 zile
- ▶ GARCH(1,1) impune un singur timp de înjumătățire, $\ln 0,5 / \ln(\alpha + \beta)$
- Două exponențiale aproximează, pe un interval finit de laguri, o autocorelație a pătratelor randamentelor care scade lent (hiperbolic)
 - ▶ memoria lungă propriu-zisă: [Capitolul 10](#)

Component GARCH pentru S&P 500



- Randamente zilnice din 1990, $T = 9\,240$; QML gaussian; volatilitatea totală anualizată $\sqrt{252\sigma_t^2}$ și componenta de termen lung $\sqrt{252q_t}$

Interpretarea modelului cu componente

- ▣ $\hat{\rho} = 0,995$, $\hat{\phi} = 0,026$; partea tranzitorie $\hat{\alpha} + \hat{\beta} = 0,950$: timpi de înjumătățire de 150 de zile (termen lung) și 13,6 zile (termen scurt)
- ▣ GARCH(1,1) pe aceleași date: persistența 0,983, un singur timp de înjumătățire de 41 de zile, un compromis între cele două
- ▣ Statistica cvasi-LR față de GARCH(1,1): 44,1; sub ipoteza nulă $\phi = 0$ parametrul ρ nu este identificat (problema Davies), deci referința χ^2_2 este doar orientativă
- ▣ După 2008, 2020 și 2025, nivelul de termen lung rămîne ridicat luni de zile, deși volatilitatea zilnică a scăzut deja: acest lucru contează pentru orizonturi de peste cîteva săptămîni

GARCH-MIDAS (1/3): o componentă de termen lung determinată macroeconomic



Eric Ghysels, 2019

Foto: Eghysels (2019); CC BY-SA 4.0;

Wikimedia Commons

- Engle, Ghysels și Sohn (2013): varianța zilnică este produsul dintre un nivel lunar τ_t și un factor zilnic $g_{i,t}$

$$r_{i,t} = \mu + \sqrt{\tau_t g_{i,t}} \eta_{i,t}$$

- ▶ $r_{i,t}$: randamentul zilei i din luna t ; μ : randamentul mediu; $\eta_{i,t}$: șoc i.i.d. cu media 0 și varianța 1

- Termenul scurt: un GARCH(1,1) cu media 1, rescalat cu τ_t

$$g_{i,t} = (1 - \alpha - \beta) + \alpha \frac{(r_{i-1,t} - \mu)^2}{\tau_t} + \beta g_{i-1,t}$$

- ▶ α, β : reacția și persistența componentei zilnice, ca în GARCH(1,1)

GARCH-MIDAS (2/3): componenta de termen lung

- Termenul lung: o regresie MIDAS (mixed-data sampling, eșantionare cu frecvențe mixte) a lui $\ln \tau_t$ pe K laguri ale unei variabile lunare

$$\ln \tau_t = m + \theta \sum_{k=1}^K \varphi_k(w) X_{t-k}, \quad \varphi_k(w) \propto (1 - k/K)^{w-1}$$

- ▶ X_{t-k} : factorul lunar de acum k luni; m : termenul liber; θ : efectul factorului (semnul arată dacă este prociclic sau anticiclic)
- ▶ $\varphi_k(w)$: ponderi beta pe laguri, normalizate să însumeze 1 și restricționate să scadă Ghysels, Santa-Clara și Valkanov (2006); $w \geq 1$: cu cât w este mai mare, cu atât scad mai repede; $w = 1$: ponderi egale
- Alegeri pentru X
 - ▶ varianța realizată din lunile anterioare, în nivel: $\tau_t = m + \theta \sum_k \varphi_k(w) \text{RV}_{t-k}$, cu RV_{t-k} suma pătratelor randamentelor zilnice din luna $t - k$
 - ▶ date macroeconomice: creșterea producției industriale, inflația IPP

GARCH-MIDAS (3/3): identificare, estimare și raportul de varianță

- ▣ τ_t este constant în cadrul lunii, iar $\mathbb{E}g_{i,t} = 1$: descompunerea este identificată prin frecvențele diferite, fără un filtru pentru o variabilă latentă
 - ▶ QML gaussian pentru toți parametrii $(\mu, \alpha, \beta, m, \theta, w)$ într-un singur pas; erori standard sandwich
- ▣ Raportul de varianță: ponderea variației logaritmului volatilității explicată de componenta de termen lung


$$VR = \frac{\text{Var}(\ln \tau_t)}{\text{Var}(\ln(\tau_t g_{i,t}))} \in [0, 1]$$

- ▶ VR apropiat de 0: componenta de termen lung este aproape constantă; apropiat de 1: ea preia cea mai mare parte a variației
- ▶ o variabilă macroeconomică poate fi semnificativă ($\hat{\theta} \neq 0$) și totuși să explice puțin din volatilitatea zilnică (VR mic)
- ▣ Inferența asupra lui w este nestandard când $\theta = 0$ (w nu este atunci identificat) și la frontiera $w = 1$
- ▣ Extensii: ponderi nerestricționate, mai mulți regresori, o a doua componentă (zilnică) [Conrad și Kleen \(2020\)](#); prognozele de peste o lună folosesc doar partea de termen lung

Studiu de caz: Engle, Ghysels și Sohn (2013) pe datele noastre

- ▣ **Întrebarea** din Engle, Ghysels și Sohn (2013): se mișcă volatilitatea de termen lung a pieței de acțiuni împreună cu fundamentele macroeconomice (creșterea producției, inflația)?
 - ▶ eșantionul lor de randamente ale acțiunilor din SUA este mult mai lung decât al nostru; componenta lor de termen lung de referință este o varianță realizată pe ferestre fixe
- ▣ **Replicarea noastră:** randamentele zilnice ale S&P 500, eșantion comun din 04.01.1993, $T = 8\,482$; $K = 36$ laguri lunare; ponderi beta restricționate
 - ▶ trei factori de termen lung: varianța realizată lunară (suma pătratelor randamentelor zilnice), creșterea producției industriale (FRED INDPRO), inflația IPP (FRED WPSFD49207)
 - ▶ toate modelele comparate cu GARCH(1,1) pe aceleași zile; QML cu erori standard sandwich
- ▣ Extindere pentru un proiect: producția industrială a României și BET (Seminarul 8, B5); edițiile în timp real ale datelor macroeconomice

GARCH-MIDAS pentru S&P 500



□ $\sqrt{252\tau_t g_{i,t}}$ anualizat pentru modelul cu producția industrială și componentele de termen lung $\sqrt{252\tau_t}$ ale celor trei modele

Estimațiile GARCH-MIDAS

Factorul de termen lung	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\theta}$ (s.e.)	$\hat{w}$	VR (%)	BIC
varianța realizată (nivel)	0,119	0,841	0,0225 (0,0058)	5,939	25,1	22710,0
creșterea producției industriale	0,110	0,870	-0,551 (0,353)	3,692	4,5	22732,5
inflația IPP	0,108	0,873	0,753 (1,260)	1,000	2,2	22733,3
GARCH(1,1)						22721,9

- Aceleași zile pentru toate modelele; $BIC = -2 \ln L + k \ln T$ (mai mic este mai bine); erori standard: Bollerslev–Wooldridge

Interpretarea modelului GARCH-MIDAS

- ▣ Varianța realizată ca factor lent: $\hat{\theta} = 0,0225$ ($t = 3,86$), $VR = 25,1\%$, BIC sub GARCH(1,1): o componentă de termen lung există
- ▣ Producția industrială: $\hat{\theta} = -0,551$ ($t = -1,56$), semnul anticiclic din [Engle, Ghysels și Sohn \(2013\)](#), dar VR doar 4,5% și un BIC mai mare decât GARCH(1,1)
- ▣ Inflația IPP: $\hat{w}$ la frontiera 1 (ponderi egale) și $\hat{\theta}$ imprecis: nicio dovadă în 1993–2026
- ▣ Verdictul replicării: semnul calitativ se păstrează, intensitatea nu; efectele macroeconomice au nevoie de eșantioane lungi, cu recesiuni adânci, motiv pentru care studiul original folosește o istorie mult mai lungă

Recapitulare: componentele de termen lung

- ▣ Volatilitatea are cel puțin două viteze; o singură persistență GARCH le face media
- ▣ GARCH-MIDAS permite unei variabile lunare să determine nivelul de termen lung; identificarea vine din frecvențele mixte
- ▣ Raportați VR și BIC alături de $\hat{\theta}$: semnificația statistică nu înseamnă importanță

Prețurile ca semimartingale Itô (1/2): modelul

- În cursul zilei t , logaritmul prețului se modifică printr-un drift, o componentă browniană scalată cu volatilitatea instantanee și salturi

$$dX_s = \mu_s ds + \sigma_s dW_s + dJ_s, \quad s \in [0, 1]$$

- X_s : logaritmul prețului la momentul intraday s (ziua este rescalată la $[0, 1]$); μ_s : drift-ul; W_s : mișcarea browniană standard
- σ_s : volatilitatea instantanee (spot), stochastică; J_s : un proces de salturi cu un număr finit de salturi pe zi, ΔJ_s : saltul din momentul s

- Variația pătratică a zilei: partea de difuzie plus pătratele salturilor

$$QV_t = IV_t + \sum_{s \leq 1} (\Delta J_s)^2, \quad IV_t = \int_0^1 \sigma_s^2 ds$$

- IV_t : varianța integrată, media varianței instantanee pe parcursul zilei
- fără salturi și cu σ independent de W : $r_t | IV_t \sim N(\int_0^1 \mu_s ds, IV_t)$, deci IV este varianța relevantă pentru randamentul zilnic r_t

Prețurile ca semimartingale Itô (2/2): varianța realizată

- ▣ Varianța realizată: suma pătratelor celor n randamente intraday ale zilei

$$RV_t = \sum_{i=1}^n r_{t,i}^2, \quad r_{t,i} = X_{i/n} - X_{(i-1)/n}$$

- ▶ n : numărul intervalelor intraday (78 de randamente la 5 minute într-o ședință de 6,5 ore); $r_{t,i}$: randamentul logaritm din intervalul i
- ▶ $RV_t \rightarrow QV_t$ în probabilitate când $n \rightarrow \infty$: RV măsoară variația totală (difuzie plus salturi)
- ▣ Drift-ul nu contează la limită: este $O(1/n)$ pe interval, în timp ce partea browniană este $O(n^{-1/2})$
 - ▶ volatilitatea devine observabilă *ex post*, fără model Andersen, Bollerslev, Diebold și Labys (2003), Barndorff-Nielsen și Shephard (2002)

Teorema limită centrală pentru varianța realizată (1/2)

- ▣ Barndorff-Nielsen și Shephard (2002): fără salturi, eroarea lui RV scade cu rata $\sqrt{n}$ și este mixt normală

$$\sqrt{n}(RV_t - IV_t) \rightarrow MN(0, 2IQ_t), \quad IQ_t = \int_0^1 \sigma_s^4 ds$$

- ▶ IQ_t : cuarticitatea integrată, media zilnică a lui σ_s^4 ; ea stabilește mărimea erorii
 - ▶ MN (mixt normală): normală condiționat de traiectoria lui σ , cu o varianță aleatoare $2IQ_t$
 - ▶ convergența este *stabilă* în lege: putem împărți la $\sqrt{IQ_t}$, aleator și estimat consistent, fără a schimba limita
- ▣ Rata $\sqrt{n}$: cu $n = 78$ și volatilitate constantă în cursul zilei, eroarea relativă este de aproximativ $\sqrt{2/78} \approx 16\%$
- ▶ eroarea de măsurare $RV_t - IV_t$ este heteroscedastică (crește cu IQ_t): pe acest fapt se bazează HARQ, mai jos

Teorema limită centrală pentru varianța realizată (2/2): intervale fezabile

- ▣ Varianta fezabilă: estimăm IQ prin cuarticitatea realizată RQ, apoi studentizăm

$$\widehat{IQ}_t = RQ_t = \frac{n}{3} \sum_{i=1}^n r_{t,i}^4, \quad \frac{RV_t - IV_t}{\sqrt{\frac{2}{3} \sum_i r_{t,i}^4}} \rightarrow N(0, 1)$$

- ▶ factorul $\frac{n}{3}$ face RQ nedeplasat la volatilitate constantă, deoarece $\mathbb{E}Z^4 = 3$ pentru $Z \sim N(0, 1)$
- ▶ interval de 95% pentru IV_t : $RV_t \pm 1,96 \sqrt{\frac{2}{3} \sum_i r_{t,i}^4}$; poate conține valori negative

- ▣ Versiunea în logaritmi (metoda delta): un interval pentru $\ln IV_t$

$$\ln RV_t \pm 1,96 \frac{\sqrt{\frac{2}{3} \sum_i r_{t,i}^4}}{RV_t}$$

- ▶ după exponențiere nu conține niciodată valori negative și are o acoperire mai bună în eșantioane finite


O piață simulată cu adevărul cunoscut

- Grilă la o secundă, $n = 23\,400$ de secunde pe zi; logaritmul varianței instantanee este suma a doi factori AR(1) gaussieni

$$\ln \sigma_s^2 = c + f_s^{(1)} + f_s^{(2)}$$

- c : constanta care fixează media; $f^{(1)}$: factorul lent (timp de înjumătățire de 60 de zile, abaterea standard staționară 0,75); $f^{(2)}$: factorul rapid (2 zile, abaterea standard 0,45)
 - media IV = 1 (%² pe zi), media realised kernel-ului pentru S&P 500 în 2000–2022; efectul de levier: corelația –0,6 între șocurile prețului și șocurile factorului rapid
- Salturi: proces Poisson cu 0,08 salturi pe zi, mărimi $N(0, 0,8^2)$ (%): salturile reprezintă aproximativ 5,6% din variația pătratică
- Zgomot: observăm $Y_s = X_s + u_s$, cu u_s i.i.d. $N(0, \omega^2)$ și $\omega = 0,004\%$
 - Y_s : logaritmul prețului observat; X_s : logaritmul prețului eficient; u_s : zgomotul de microstructură, cu abaterea standard ω ; la o secundă, $2n\omega^2 = 0,75$ (slide-urile următoare)
- Fiecare estimator de mai jos este comparat cu IV sau QV adevărate din aceeași zi simulată

Acoperirea TLC fezabile



- 400 de zile simulate fără salturi; intervale de 95% pentru IV_t (în nivel și în logaritmi) din randamente eşantionate la 30 de minute până la 5 secunde, fără și cu zgomot

Interpretarea acoperirii TLC

- Fără zgomot, acoperirea se apropie de 95% când n crește: intervalul în nivel are 90,0% la $n = 13$ și 95,0% la $n = 390$; intervalul în logaritmi este mai aproape pentru n mic (92,0%)
- Cu zgomot, acoperirea se prăbușește când eșantionarea este prea fină: 37,0% la 15 secunde și 0,0% la 5 secunde; la un minut este încă 94,2%
- Intervalul se îngustează ca $n^{-1/2}$, iar deplasarea din zgomot crește ca n : TLC este o afirmație despre prețul eficient, nu despre cel observat
- Regula practică: randamente la 5 minute pentru active lichide, cu excepția cazului în care se folosește un estimator robust la zgomot

Sursa măsurilor realizate




Ole E. Barndorff-Nielsen, 2007

Foto: Thomas Steiner (2007); CC BY-SA 2.5;

[Wikimedia Commons](#)

- Heber, Lunde, Shephard și Sheppard (2009), versiunea 0.3: RV, BV, realised kernels și randamente deschidere–închidere zilnice pentru 31 de indici, din 2000 până la 25 februarie 2022, construite din date tick curățate
- condițiile ei: utilizare liberă dacă biblioteca și versiunea ei sînt citate; copia arhivată păstrează fișierul din 2022 disponibil după închidere
- Bitcoin și Ether se tranzacționează 24/7, iar Binance publică toate prețurile la un minut și la o secundă: calculăm RV, BV, RQ, cuarticitatea tripower și un realised kernel pentru fiecare zi UTC, 2018–2026
- Nicio sursă gratuită nu acoperă datele intraday pentru acțiuni după 2022: un proiect le poate reconstrui dintr-o sursă cu licență

Volatilitatea realizată pe mai multe piețe



- Realised kernel anualizat, medii pe 5 zile: S&P 500, DAX și Nikkei 225 (Oxford-Man, 2000–2022); Bitcoin (prețuri Binance la un minut, 2018–2026, 365 de zile pe an)

Interpretarea volatilităților realizate

- ▣ Volatilitatea anualizată medie din kernel: S&P 500 16,2%, DAX 19,5%, Nikkei 16,6%, Bitcoin 68,4%
- ▣ Seriile de acțiuni se mișcă împreună (2002, 2008, 2011, 2020): un factor comun de termen lung, tema multivariată din ultima secțiune
- ▣ Măsurile deschidere–închidere omit randamentul de peste noapte: pentru riscul zilnic se adaugă pătratul randamentului de peste noapte sau se scalează măsura
- ▣ Bitcoin nu are perioade fără tranzacționare, dar volatilitatea lui zilnică este de trei pînă la patru ori mai mare și scade după 2023

Zgomotul de microstructură (1/2): deplasarea lui RV

- Logaritmul prețului observat este prețul eficient plus un termen de zgomot

$$Y_{i/n} = X_{i/n} + u_i$$

- u_i : zgomot i.i.d. cu varianța ω^2 , independent de X ; surse: oscilația între bid și ask, discretizarea prețului, cotațiile stale (neactualizate)

- RV calculat din prețurile observate la n intervale, $RV_t^{(n)}$, este deplasat în sus, iar deplasarea crește cu n

$$\mathbb{E}(RV_t^{(n)}|X) = IV_t + 2n\omega^2, \quad \text{Var}(RV_t^{(n)}|X) \approx 4n\mathbb{E}u^4$$

- fiecare randament observat conține $u_i - u_{i-1}$, cu varianța $2\omega^2$; însumat pe n randamente, aceasta dă $2n\omega^2$
- RV diverge când $n \rightarrow \infty$: eșantionarea cât mai deasă nu este optimă
- derivarea deplasării și a varianței: [▶ Anexa](#)

Zgomotul de microstructură (2/2): diagnostice

- Două consecințe ale zgomotului i.i.d.
 - ▶ $\hat{\omega}^2 = RV_t^{(n)} / (2n)$, la frecvența cea mai mare, estimează varianța zgomotului, deoarece acolo $2n\omega^2$ domină IV
 - ▶ randamentele prețului observat au autocovarianța de ordinul întâi $-\omega^2$: autocorelația negativă este amprenta zgomotului i.i.d.
- Signature plot: media $RV^{(n)}$ în funcție de intervalul de eșantionare
 - ▶ o zonă plată arată intervalele la care zgomotul nu mai contează
- Zgomotul real nu este i.i.d.: este autocorelat și corelat cu prețul eficient, mai ales în datele de cotații [Hansen și Lunde \(2006b\)](#)

Eșantionarea rară optimă

- Eroarea pătratică medie (MSE) a lui $RV^{(n)}$ ca estimator al lui IV: varianța de eșantionare scade, deplasarea din zgomot crește cu n

$$MSE(n) \approx \underbrace{\frac{2IQ}{n}}_{\text{varianța}} + \underbrace{(2n\omega^2)^2}_{\text{deplasarea}^2} + 4n\mathbb{E}u^4 + \dots$$

- Minimizarea primilor doi termeni dă numărul optim de intervale [Bandi și Russell \(2008\)](#)

$$n^* \approx \left(\frac{IQ}{4\omega^4} \right)^{1/3}$$

- ▶ grila optimă este mai rară când zgomotul (ω^2) este mare față de volatilitate (IQ)
- ▶ exemplu (Seminarul 8, A3): $IV = IQ = 1$, $\omega^2 = 1,6 \times 10^{-5}$ dă $n^* \approx 990$, un randament la fiecare 24 de secunde
- Cel mai bun RV rar converge doar cu rata $n^{1/6}$ și renunță la majoritatea datelor: de aici estimatorii care folosesc toate observațiile
- Subeșantionarea: media RV pe cele K grile decalate (cu start în secunda $0, 1, \dots, K-1$); aceeași deplasare, varianță mai mică

Două scale de timp și realised kernels (1/2)

- RV cu două scale [Zhang, Mykland și Aït-Sahalia \(2005\)](#): scala rapidă estimează deplasarea din zgomot a celei lente și o elimină

$$\text{TSRV} = \overline{\text{RV}}^{(K)} - \frac{\bar{n}}{n} \text{RV}^{(n)}, \quad \bar{n} = \frac{n - K + 1}{K}$$

- ▶ $\overline{\text{RV}}^{(K)}$: RV subeșantionat pe K grile rare decalate (scala lentă), fiecare cu aproximativ $\bar{n}$ randamente; $\text{RV}^{(n)}$: RV pe toate cele n randamente (scala rapidă)
- ▶ deplasarea scalei lente este $2\bar{n}\omega^2 = \frac{\bar{n}}{n} \cdot 2n\omega^2$: corecția o scade; rata $n^{1/6}$
- Pre-averaging [Jacod et al. \(2009\)](#): mediem randamentele pe blocuri înainte de ridicarea la pătrat
- ▶ rata $n^{1/4}$, cea optimă în prezența zgomotului; în practică, apropiat de realised kernel

Două scale de timp și realised kernels (2/2): realised kernel-ul

- Realised kernel [Barndorff-Nielsen, Hansen, Lunde și Shephard \(2008\)](#): RV plus autocovarianțele realizate, ponderate


$$RK_t = \gamma_0 + \sum_{h=1}^H k\left(\frac{h}{H+1}\right)(\gamma_h + \gamma_{-h}), \quad \gamma_h = \sum_i r_{t,i} r_{t,i-h}$$

- γ_h : autocovarianța realizată la lagul h ($\gamma_0 = RV$); H : lățimea de bandă, numărul de laguri folosite; $k(\cdot)$: funcția de ponderare, cu $k(0) = 1$, $k(1) = 0$
- ponderile Parzen: $k(x) = 1 - 6x^2 + 6x^3$ pentru $x \leq \frac{1}{2}$ și $2(1-x)^3$ pentru $\frac{1}{2} < x \leq 1$
- γ_1 negativ creat de zgomot anulează deplasarea $2n\omega^2$: aceeași idee ca la estimarea HAC a varianței ([Capitolul 0](#))

- Proprietăți

- nenegativ prin construcție; rata $n^{1/5}$ cu $H = c^* \xi^{4/5} n^{3/5}$, unde $\xi^2 = \omega^2 / \sqrt{IQ}$ este raportul zgomot/semnal, iar $c^* = 3,51$ pentru Parzen [Barndorff-Nielsen et al. \(2009\)](#)
- corectează și zgomotul cu dependență serială pe distanțe scurte, de orice semn

Estimatorii comparați cu variația pătratică adevărată




- 300 de zile simulate cu salturi și zgomot; deplasarea și rădăcina erorii pătratice medii, relativ la media QV; TSRV cu $K = 300$ de secunde; RK cu lățimea de bandă BNHLS (mediana $H = 31$)

Interpretarea comparației estimatorilor

- ▣ RV la o secundă este dominat de zgomot: deplasarea este 117,8% din QV; la un minut deplasarea este 1,2%, iar RMSE 8,9%
- ▣ RV la cinci minute este nedeplasat, dar zgomotos (RMSE 21,6%); subeșantionarea și TSRV îl reduc la 15,4% și 15,6%
- ▣ Realised kernel-ul folosește toate cele 23 400 de randamente: deplasarea 0,5%, RMSE 4,4%, cel mai bun dintre cei șase
- ▣ Toți estimatorii de aici au ca țintă QV, inclusiv salturile; separarea salturilor cere secțiunea următoare

Signature plot și efectul Epps: Bitcoin și Ether



- Prețuri Binance la o secundă, august 2026 (31 de zile); RV zilnic mediu în funcție de intervalul de eșantionare (subeșantionat); corelația realizată a celor două monede în funcție de interval

Interpretarea signature plot-ului

- Bitcoin: RV este 2,24 la o secundă, 3,65 la un minut, 3,59 la cinci minute: signature plot-ul *crește*, opusul predicției pentru zgomot i.i.d.
- Motivul: 52% dintre randamentele la o secundă sînt zero (nicio tranzacție sau același preț), iar prețurile se ajustează treptat, deci randamentele la o secundă sînt autocorelate pozitiv
- Realised kernel-ul pe date la o secundă (3,46, mediana $H = 22$) adaugă înapoi autocovarianțele pozitive și ajunge în zona plată de 1–30 de minute
- Efectul Epps [Epps \(1979\)](#): corelația realizată 0,64 la o secundă față de 0,82 la cinci minute; tranzacționarea asincronă deplasează covarianțele spre zero la frecvență înaltă

Recapitulare: măsurile realizate

- ▣ RV estimează QV cu eroarea $\sqrt{2IQ/n}$; intervalul în logaritmi se comportă mai bine; convergența stabilă face validă studentizarea
- ▣ Zgomotul deplasează RV la frecvență înaltă; semnul și mărimea acestui efect sînt empirice: priviți întîi signature plot-ul
- ▣ Realised kernels folosesc toate datele și corectează zgomotul cu dependență pe distanțe scurte; RV la 5 minute rămîne un reper robust

Variația bipower (1/2)

- ▣ Barndorff-Nielsen și Shephard (2004): suma produselor valorilor absolute ale randamentelor adiacente, rescalată

$$BV_t = \mu_1^{-2} \frac{n}{n-1} \sum_{i=2}^n |r_{t,i}| |r_{t,i-1}|, \quad \mu_1 = \mathbb{E}|Z| = \sqrt{2/\pi}$$

- ▶ $Z \sim N(0, 1)$; μ_1^{-2} face BV_t consistent pentru IV_t ; $\frac{n}{n-1}$ corectează pentru cele $n-1$ produse
 - ▶ $BV_t \rightarrow IV_t$ chiar și cu salturi (cu activitate finită): un salt intră doar în două produse, fiecare înmulțit cu un randament de ordinul $n^{-1/2}$
- ▣ Deci $RV_t - BV_t \rightarrow \sum_{s \leq 1} (\Delta J_s)^2$: o estimatie neparametrică a variației din salturi a zilei

Variația bipower (2/2): estimatori înrudiți

- ▣ Cuarticitatea robustă la salturi: cuarticitatea tripower

$$\text{TQ}_t = n \mu_{4/3}^{-3} \frac{n}{n-2} \sum_{i=3}^n \prod_{j=0}^2 |r_{t,i-j}|^{4/3}, \quad \mu_{4/3} = \mathbb{E}|Z|^{4/3}$$

- ▶ produse a trei valori absolute ale randamentelor adiacente, fiecare la puterea $4/3$; $\text{TQ}_t \rightarrow \text{IQ}_t$ chiar și cu salturi (RQ, nu)
- ▣ Trunchierea prin vecinii cei mai apropiați (MedRV, MinRV) Andersen, Dobrev și Schaumburg (2012): deplasare mai mică în eșantioane finite din cauza unui salt și a randamentelor nule
- ▣ RV cu prag (trunchiat): se elimină randamentele peste $c n^{-\varpi}$
 - ▶ $c > 0$: o constantă (un multiplu al volatilității locale); $\varpi \in (0, \frac{1}{2})$: pragul scade mai lent decât un randament de difuzie, deci sînt eliminate doar salturile

Testarea salturilor (1/2): statistica raport

- Barndorff-Nielsen și Shephard (2006): fără salturi, diferența $RV - BV$ este și ea mixt normală

$$\sqrt{n}(RV_t - BV_t) \rightarrow MN(0, \vartheta IQ_t), \quad \vartheta = \mu_1^{-4} + 2\mu_1^{-2} - 5 = \frac{\pi^2}{4} + \pi - 5 \approx 0,609$$

- ▶ ϑ : o constantă care măsoară cu cât este BV mai puțin eficient decât RV
- Statistica raport Huang și Tauchen (2005): contribuția relativă a salturilor, studentizată

$$z_t = \frac{(RV_t - BV_t)/RV_t}{\sqrt{\frac{\vartheta}{n} \max(1, TQ_t/BV_t^2)}} \rightarrow N(0, 1)$$

- ▶ test unilateral: respingem ipoteza „niciun salt în ziua t ” pentru z_t mare
- ▶ forma de raport și ajustarea prin max dau cea mai bună mărime a testului în simulările lor; $TQ_t/BV_t^2 \geq 1$ prin Jensen când volatilitatea variază în cursul zilei


Testarea salturilor (2/2): aplicarea practică

- Un test zilnic răspunde la întrebarea „a existat un salt azi?”; localizarea lui în cursul zilei cere un test pe fiecare randament standardizat cu BV local [Lee și Mykland \(2008\)](#)
- Testare multiplă: la nivelul α , pe T zile ne așteptăm la αT zile cu salturi false
 - ▶ folosiți un α mic (0,1%) sau o corecție de tip FWER sau FDR ([Capitolul 1](#))
- Separarea părților continuă și de salt ale lui RV [Andersen, Bollerslev și Diebold \(2007\)](#)

$$J_t = \mathbb{I}(z_t > z_{1-\alpha})(RV_t - BV_t), \quad C_t = RV_t - J_t$$

- ▶ $\mathbb{I}(\cdot)$: indicatorul, 1 dacă testul respinge și 0 altfel; $z_{1-\alpha}$: cuantila $1 - \alpha$ a distribuției $N(0, 1)$
- ▶ J_t : partea de salt, nenulă doar în zilele semnificative; C_t : partea continuă

Mărimea și puterea testului raport




- 2000 de zile simulate (SV cu doi factori, fără salturi), apoi un salt de mărime $c\sqrt{IV_t}$ la un moment aleator; test unilateral la 0,1% cu randamente la 5 minute și la 1 minut

Interpretarea mărimii și puterii

- ▣ Mărimea fără salturi: 0,0% (5 minute) și 0,2% (1 minut) față de 0,1% nominal; cu zgomot i.i.d. de mărimea calibrată, tot 0,1% la 1 minut
- ▣ Puterea pentru un salt de o jumătate de abatere standard zilnică: 5% cu randamente la 5 minute, 68% cu randamente la 1 minut; pentru o abatere standard 74% și 100%
- ▣ Puterea depinde de $c\sqrt{n}$: salturile mici sînt absorbite în difuzie la o eșantionare rară (Seminarul 8, A6 dă pragul de detectare)
- ▣ Compromisul cu zgomotul este același ca pentru RV: o eșantionare mai fină crește puterea pînă cînd zgomotul și randamentele nule distorsionează statistica

Zilele cu salturi pentru Bitcoin și Ether



- Testul Huang–Tauchen cu randamente la 5 minute ($n = 288$ pe zi UTC), 2018–2026, $T = 3165$ de zile; stînga: ponderea zilelor cu salturi la 0,1% pe an; dreapta: distribuția lui z_t față de $N(0, 1)$

Interpretarea testelor de salt pentru criptomonede

- ▣ Bitcoin: 362 de zile cu salturi (11,4%), unde ne așteptăm la aproximativ 3,2 respingeri false; Ether: 355 de zile (11,2%)
- ▣ Totuși, salturile sînt mici: reprezintă 3,0% (Bitcoin) și 2,3% (Ether) din variația totală; restul este continuu
- ▣ Întreaga distribuție a lui z_t este deplasată (media 1,16, nu 0): pe lângă salturi, sezonalitatea intraday pe 24 de ore, randamentele nule și mișcările bruște încalcă ipotezele nulei
- ▣ Înainte de a declara o zi drept zi cu salt: standardizați randamentele cu un profil al volatilității intraday, verificați randamentele nule și controlați numărul de teste

Recapitulare: salturile

- BV estimează partea continuă; $RV - BV$ partea de salt; TQ face testul robust la salturi în cuarticitate
- Testul raport are o mărime bună în simulări; puterea lui crește cu $c\sqrt{n}$
- În datele reale, ipoteza nulă este fragilă: multe respingeri, puțină variație din salturi; tratați numărul de salturi ca dependent de model

Modelul HAR al lui Corsi (1/2): regresia

- ▣ Corsi (2009): RV de mâine este o funcție liniară de mediile zilnică, săptămînală și lunară ale RV din trecut

$$RV_{t+1} = \beta_0 + \beta_d RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + u_{t+1}$$


$$RV_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 RV_{t-j}, \quad RV_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} RV_{t-j}$$

- ▶ $RV_t^{(w)}, RV_t^{(m)}$: mediile pe ultimele 5 zile de tranzacționare (o săptămîină) și pe ultimele 22 (o lună)
 - ▶ $\beta_d, \beta_w, \beta_m \geq 0$: ponderile celor trei orizonturi; β_0 : termenul liber; u_{t+1} : eroarea de prognoză, cu media zero
 - ▶ $\beta_d + \beta_w + \beta_m$: persistența; cu cît este mai aproape de 1, cu atît volatilitatea revine mai lent la medie
- ▣ Ipoteza pieței eterogene: participanții cu orizont zilnic, săptămînal și lunar reacționează la volatilitate la propriul orizont
- ▶ cascada produce autocorelații care scad lent

Modelul HAR al lui Corsi (2/2): estimare și variante

- ▣ Statistic, HAR este un AR(22) cu 19 restricții liniare (coeficienți în trepte)
 - ▶ memorie scurtă, dar imită memoria lungă pe orizontul unei luni
- ▣ OLS este consistent; erorile sînt heteroscedastice și, pentru ținte pe mai multe zile, suprapuse
 - ▶ folosiți erorile standard Newey–West [Newey și West \(1987\)](#) (HAC)
- ▣ Variante
 - ▶ log-HAR: aceeași regresie pe $\ln RV$, cu erori aproape gaussiene; prognoza lui RV este $\exp(\hat{\mu} + \frac{1}{2}\hat{\sigma}_u^2)$, cu $\hat{\mu}$ valoarea ajustată în logaritmi și $\hat{\sigma}_u^2$ varianța reziduurilor
 - ▶ HAR pe $\sqrt{RV}$; ținte pe h zile (RV mediu pe următoarele h zile)
- ▣ Extensii: părțile continuă și de salt, HAR-CJ [Andersen, Bollerslev și Diebold \(2007\)](#); semivarianțele pozitivă și negativă [Patton și Sheppard \(2015\)](#); volatilitatea implicită; termeni de levier

HAR ca AR(22) restricționat



- S&P 500 (Oxford-Man, RV la 5 minute, 2000–2022, $T = 5\,530$): coeficienții unui AR(22) nerestricționat estimat prin OLS și ponderile în trepte implicate de estimațiile HAR

Interpretarea estimațiilor HAR

- ▣ HAR: $\hat{\beta}_d = 0,275$ (0,104), $\hat{\beta}_w = 0,522$ (0,140), $\hat{\beta}_m = 0,094$ (0,078), erori standard Newey–West; $R^2 = 0,560$; persistența $\sum \hat{\beta} = 0,891$
- ▣ AR(22) cu 23 de coeficienți ajunge la $R^2 = 0,596$ în eșantion, cu coeficienți neregulați; HAR surprinde forma cu 4
- ▣ Log-HAR: $\hat{\beta}_d = 0,393$, $\hat{\beta}_w = 0,399$, $\hat{\beta}_m = 0,153$, $R^2 = 0,719$ pe $\ln RV$; în logaritmi, componenta lunară contează mai mult
- ▣ În nivel, câteva zile de criză domină OLS: erori standard mari pentru β_d și β_m ; metoda celor mai mici pătrate ponderate sau logaritmii dau estimații mai stabile


Schema de prognoză

- ▣ Un pas înainte, fereastră mobilă de 1 000 de zile, reestimare zilnică; ținta RV_{t+1}
- ▣ Funcțiile de pierdere: $MSE = (RV - f)^2$ și QLIKE, ambele robuste la zgomotul din RV (vezi mai jos)

$$QLIKE = \frac{RV}{f} - \ln \frac{RV}{f} - 1 \geq 0$$

- ▶ f : prognoza varianței; QLIKE este 0 când $f = RV$ și penalizează subestimarea mai mult decât supraestimarea
- ▣ Filtrul de plauzibilitate („insanity filter”) [Bollerslev, Patton și Quaadvlieg \(2016\)](#): o prognoză din afara intervalului RV din eșantionul de estimare este înlocuită cu media din eșantion
 - ▶ prognozele liniare de tip HAR pot fi negative după un vîrf; QLIKE nu mai este atunci definită
 - ▶ filtrul face parte din metodă și trebuie raportat
- ▣ Statistica t Diebold–Mariano [Diebold și Mariano \(1995\)](#) pentru diferența pierderilor față de HAR
 - ▶ varianță Newey–West; negativă = mai bun decât HAR, sub $-1,96$ semnificativ la 5%; mai multe modele: setul de modele de încredere [Hansen, Lunde și Nason \(2011\)](#), Capitolul 1
- ▣ Modele: HAR, HAR-CJ (partea continuă și partea de salt, din BV), log-HAR; pentru Bitcoin și Ether și HARQ

Extensiile HAR în afara eșantionului



- QLIKE mediu relativ la HAR (sub 1 = mai bun), șase indici Oxford-Man (2004–2022) și două criptomonede (din 01.11.2020); fereastră mobilă de 1 000 de zile

Interpretarea comparației HAR în afara eșantionului

- Log-HAR este mai bun decît HAR după QLIKE pentru 6 din 6 indici: S&P 500 0,764 (DM $-2,07$), CAC 40 0,709 (DM $-1,73$), FTSE 0,874 (DM $-5,08$)
- HAR-CJ ajută pentru 4 din 6 indici, dar nu pentru S&P 500 (1,110): separarea salturilor adaugă zgomot de estimare cînd salturile sînt mici
- Ordinea depinde de funcția de pierdere: după MSE, cîștigurile log-HAR sînt mai mici (S&P 500: 0,837); MSE pune cea mai mare pondere pe zilele de criză
- Șase indici de la un singur furnizor de date și o singură perioadă: raportați-i pe toți, nu doar pe cel mai bun (data snooping, [Capitolul 1](#))

HARQ (1/2): eroarea de măsurare a lui RV

- RV este IV latent plus o eroare de măsurare a cărei varianță se schimbă în fiecare zi

$$RV_t = IV_t + e_t, \quad \text{Var}(e_t|IQ_t) \approx \frac{2 IQ_t}{n}$$

- ▶ e_t : eroarea de măsurare din ziua t ; în zilele volatile (IQ_t mare), RV este mai puțin precis

- Erori în variabile: într-un AR(1) pentru IV cu coeficientul ϕ , panta OLS pe RV este atenuată (▶ Anexa)

$$\text{plim } \hat{\phi} = \phi\lambda, \quad \lambda = \frac{\text{Var}(IV)}{\text{Var}(IV) + \mathbb{E}\text{Var}(e)} \in (0, 1)$$

- ▶ λ : raportul de fiabilitate, ponderea semnalului în varianța lui RV
- ▶ un singur β_d constant este un compromis: prea mare în zilele zgomotoase, prea mic în zilele precise


HARQ (2/2): o pondere care depinde de precizie

- Bollerslev, Patton și Quaadvlieg (2016): ponderea RV de ieri variază cu precizia lui estimată

$$RV_{t+1} = \beta_0 + (\beta_d + \beta_{dQ}\sqrt{RQ_t})RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + u_{t+1}$$

- ▶ RQ_t : cuarticitatea realizată, estimația lui IQ_t ; $\sqrt{RQ_t}$ este proporțional cu abaterea standard a lui e_t
- ▶ ne așteptăm la $\beta_{dQ} < 0$: cu cât RV de ieri este mai puțin precis, cu atât ponderea lui este mai mică
- ▶ $\sqrt{RQ_t}$ este centrat, astfel încât β_d este ponderea unei zile cu precizie medie
- Un singur parametru în plus, tot OLS
- Lucrarea originală: futures pe S&P 500 și 27 de acțiuni din Dow Jones, câștiguri față de HAR în eșantion și în afara lui
 - ▶ replicarea noastră o extinde la Bitcoin și Ether, 2018–2026, unde RQ este disponibil din datele noastre la un minut

HARQ pentru Bitcoin: o pondere care se schimbă cu precizia



- HARQ pe tot eșantionul, pentru RV și RQ la 5 minute ale Bitcoin: ponderea zilnică $\hat{\beta}_d + \hat{\beta}_{dQ}(\sqrt{RQ_t} - \overline{\sqrt{RQ}})$ față de ponderea constantă din HAR

Interpretarea modelului HARQ

- ▣ $\hat{\beta}_{dQ} = -0,00021$ ($t = -2,7$, Newey–West): negativ, cum prezice teoria; ponderea zilnică la precizie medie este 0,752, față de 0,334 în HAR
- ▣ În majoritatea zilelor ponderea este în jur de 0,76; în zilele cele mai zgomotoase scade (cuantila de 1% 0,71, minimul 0,13): RV de ieri primește încredere doar când este precis
- ▣ În afara eșantionului, QLIKE relativ la HAR: Bitcoin 0,946 (DM $-2,44$), Ether 0,921 (DM $-4,50$): câștigul din studiul original se regăsește la criptomonede
- ▣ După MSE imaginea diferă (Bitcoin 1,163): MSE este dominat de câteva zile extreme, unde HARQ micșorează cel mai mult ponderea; mini studiul de caz AI verifică cât de fragil este câștigul

Recapitulare: HAR și HARQ

- HAR este un AR(22) restricționat și parcimonios, estimat prin OLS; logaritmi îl stabilizează
- Câștigurile în afara eșantionului depind de funcția de pierdere și de piață: raportați toate seriile, filtrul și testele DM
- HARQ lasă eroarea de măsurare a RV să stabilească ponderea zilei de ieri: un parametru, un câștig robust după QLIKE

Realized GARCH (1/2): cele trei ecuații

- Hansen, Huang și Shek (2012), forma log-liniară: o ecuație a randamentului, o ecuație GARCH determinată de măsura realizată și o ecuație de măsurare

$$\begin{aligned} r_t &= \sqrt{h_t} z_t, & \ln h_t &= \omega + \beta \ln h_{t-1} + \gamma \ln x_{t-1} \\ \ln x_t &= \xi + \varphi \ln h_t + \tau(z_t) + u_t \end{aligned}$$

- ▶ h_t : varianța condiționată a randamentului r_t ; z_t : șoc standardizat i.i.d.; x_t : măsura realizată din ziua t (aici realised kernel-ul RK)
- ▶ β : persistența lui $\ln h_t$; γ : ponderea măsurii realizate de ieri (variabila de știri care înlocuiește ε_{t-1}^2)
- ▶ u_t : eroarea de măsurare, i.i.d. $N(0, \sigma_u^2)$, independentă de z_t
- Ecuația de măsurare: x_t este un semnal zgomotos, posibil deplasat, al lui h_t
 - ▶ $\varphi = 1$: x_t proporțional cu h_t ; ξ preia diferența de scală (măsura deschidere–închidere față de varianța închidere–închidere)
 - ▶ funcția de levier $\tau(z) = \tau_1 z + \tau_2 (z^2 - 1)$: cu $\tau_1 < 0$, randamentele negative cresc următoarea măsură realizată (impactul știrilor, TSA, Capitolul 5)

Realized GARCH (2/2): forma redusă și estimarea

- ▣ Înlocuind ecuația de măsurare în ecuația GARCH: $\ln h_t$ este un AR(1)

$$\ln h_t = (\omega + \gamma\xi) + \pi \ln h_{t-1} + \gamma(\tau(z_{t-1}) + u_{t-1}), \quad \pi = \beta + \varphi\gamma$$

- ▶ π : persistența logaritmului varianței; prognozele cu mai mulți pași decurg din ea, pentru că x_t are propria ecuație
- ▣ QML comun: log-verosimilitatea însumează o parte pentru randamente și o parte pentru măsurare

$$\ell = -\frac{1}{2} \sum_t \left[\underbrace{\ln h_t + z_t^2}_{r_t} + \underbrace{\ln \sigma_u^2 + u_t^2 / \sigma_u^2}_{x_t} \right]$$

- ▶ comparația cu GARCH se face doar prin verosimilitatea parțială a lui r_t (prima parte), deoarece GARCH nu modelează x_t


HEAVY și familia modelelor cu măsuri realizate

- HEAVY Shephard și Sheppard (2010): două ecuații de tip GARCH, una pentru varianța randamentului și una pentru media măsurii realizate

$$h_t = \text{Var}(r_t | \mathcal{F}_{t-1}) = \omega + \alpha \text{RM}_{t-1} + \beta h_{t-1}$$
$$\mu_t = \mathbb{E}(\text{RM}_t | \mathcal{F}_{t-1}) = \omega_R + \alpha_R \text{RM}_{t-1} + \beta_R \mu_{t-1}$$

- ▶ RM_t : măsura realizată din ziua t ; (ω, α, β) și $(\omega_R, \alpha_R, \beta_R)$: parametrii celor două ecuații
 - ▶ fiecare ecuație se estimează separat prin QML; „momentum”: după un șoc, h_t continuă să crească pînă cînd μ_t îl ajunge din urmă
 - ▶ cînd măsura realizată intră în ecuația varianței, pătratul randamentului de obicei nu mai adaugă nimic (ε_{t-1}^2 primește coeficientul zero)
- Realized EGARCH Hansen și Huang (2016): mai multe măsuri realizate și un efect de levier mai bogat; există versiuni de tip score-driven pentru cozi groase
 - Comparativ cu HAR: randamentele și măsurile realizate sînt modelate împreună, deci sînt disponibile prognoze de densitate și de VaR/ES (Capitolul 9)

Studiu de caz: Realized GARCH pentru S&P 500



- Randamente deschidere-închidere și realised kernel-ul Parzen (Oxford-Man), 2000–2022, $T = 5\,552$, ca în [Hansen, Huang și Shek \(2012\)](#); stînga: criza din 2008; dreapta: funcția de levier estimată

Estimațiile Realized GARCH

ω	β	γ	ξ	φ	τ_1	τ_2	σ_u
0,119 (0,010)	0,678 (0,018)	0,287 (0,016)	-0,456 (0,021)	1,012 (0,026)	-0,073 (0,008)	0,197 (0,010)	0,671 (0,008)

- Erori standard Bollerslev–Wooldridge în paranteze; persistența $\hat{\pi} = \hat{\beta} + \hat{\varphi}\hat{\gamma} = 0,968$ (GARCH(1,1) pe aceleași randamente: 0,989)
- Log-verosimilitatea parțială a randamentelor: Realized GARCH -6899,7, HEAVY -6902,8, GJR -6998,8, GARCH(1,1) -7099,0
- Ecuația varianței HEAVY: $\hat{\alpha} = 0,377$ pentru RK_{t-1} , $\hat{\beta} = 0,691$

Interpretarea modelului Realized GARCH

- ▣ $\hat{\phi} = 1,012$: kernel-ul este proporțional cu varianța condiționată; $\hat{\xi} = -0,456$, cu $\hat{\sigma}_u = 0,671$: în medie, kernel-ul se află sub varianța condiționată a randamentului deschidere–închidere
- ▣ $\hat{\gamma} = 0,287$ este mare, iar $\hat{\beta} = 0,678$ mai mic decât în GARCH: măsura realizată aduce informația mai repede decât pătratele randamentelor (panoul din stînga, toamna lui 2008)
- ▣ Levierul: $\hat{\tau}_1 = -0,073$, $\hat{\tau}_2 = 0,197$: o parabolă asimetrică, mai mare pentru z negativ
- ▣ Cîștigul în verosimilitatea parțială față de GARCH(1,1), egal cu 199,3, are direcția din lucrarea originală; HEAVY este aproape la fel de bun, cu trei parametri

Recapitulare: modelele GARCH cu măsuri realizate

- ▣ O măsură realizată în ecuația varianței este o variabilă de știri mai bună decât pătratul randamentului
- ▣ Realized GARCH adaugă o ecuație de măsurare: prognoze cu mai mulți pași, levier și o verosimilitate comună
- ▣ Comparația cu GARCH se face doar pe verosimilitatea parțială a randamentelor

Problema proxy-ului și funcțiile de pierdere robuste (1/2)

- Nu observăm niciodată σ_t^2 : o prognoză h_t este comparată cu un proxy $\hat{\sigma}_t^2$ (pătratul randamentului, RV, RK)
 - ▶ proxy-ul este nedeplasat condiționat, $\mathbb{E}(\hat{\sigma}_t^2 | \mathcal{F}_{t-1}) = \sigma_t^2$, dar zgomotos
- O funcție de pierdere L este *robustă* Patton (2011) dacă ordinea prognozelor după $\mathbb{E}L(\hat{\sigma}_t^2, h_t)$ coincide cu ordinea după $\mathbb{E}L(\sigma_t^2, h_t)$, pentru orice proxy nedeplasat Hansen și Lunde (2006a)
- Condiția necesară și suficientă: o formă Bregman (Capitolul 1, funcții de scor consistente pentru medie)

$$L(\hat{\sigma}^2, h) = \tilde{C}(h) + B(\hat{\sigma}^2) + C(h)(\hat{\sigma}^2 - h), \quad C'(h) < 0$$

- ▶ C : o funcție descrescătoare de prognoză; $\tilde{C}$: primitiva ei, $\tilde{C}' = C$; B : orice funcție doar de proxy (nu influențează ordinea)


Problema proxy-ului și funcțiile de pierdere robuste (2/2)

- ▣ Robuste: MSE și QLIKE, membrii de grad 2 și de grad 0 ai familiei omogene robuste

$$\text{MSE} = (\hat{\sigma}^2 - h)^2, \quad \text{QLIKE} = \frac{\hat{\sigma}^2}{h} - \ln \frac{\hat{\sigma}^2}{h} - 1$$

- ▶ gradul: cum se scalează pierderea când proxy-ul și prognoza sînt înmulțite cu aceeași constantă; QLIKE (grad 0) nu depinde de scală și penalizează mai mult subestimarea
- ▣ Nerobuste: $\text{MAE} = |\hat{\sigma}^2 - h|$, MSE pe logaritmi $(\ln \hat{\sigma}^2 - \ln h)^2$, MSE pe abateri standard
 - ▶ cu un proxy zgomotos, ele recompensează prognozele deplasate în jos
- ▣ Exemplu: cu $\hat{\sigma}^2 = r^2$, optimul MSE-log este $h^* = \exp(\mathbb{E} \ln r^2) = 0,28 \sigma^2$
 - ▶ pentru că $r^2 = \sigma^2 \chi_1^2$ pentru un randament gaussian, iar $\mathbb{E} \ln \chi_1^2 = -1,27$: MSE-log preferă o prognoză mult sub valoarea adevărată

Funcții de pierdere robuste și nerobuste




- Variația adevărată față de o prognoză deplasată în jos cu factorul 0,6; proxy = RV din n randamente intraday ($n = 1$: pătratul randamentului zilnic); diferența relativă a pierderilor așteptate, peste zero = câștigă varianța adevărată

Interpretarea experimentului de robustețe

- ▣ Cu pătratul randamentului ca proxy, MAE preferă prognoza deplasată (diferența $-10,7\%$) la fel ca MSE-log ($-15,8\%$); MSE ($7,9\%$) și QLIKE ($12,5\%$) nu
- ▣ Cu $n = 5$ randamente intraday, toate cele patru funcții ordonează corect: un proxy precis face funcțiile nerobuste „aproape” robuste [Hansen și Lunde \(2006a\)](#)
- ▣ Pericolul este cel mai mare exact acolo unde nu există măsuri realizate: date zilnice, piețe emergente, istorii lungi
- ▣ Regula: evaluați prognozele de volatilitate cu QLIKE (și MSE), față de cel mai bun proxy disponibil

Șapte prognoze ale volatilității S&P 500



- Variația deschidere-închidere, un pas înainte, 2016–2022 (1 537 zile); fereastră extinsă din 2000, parametrii reestimați la fiecare 250 de zile; proxy: realised kernel

Interpretarea comparației prognozelor

- QLIKE: HAR 0,328, log-HAR 0,324, Realized GARCH 0,337, HEAVY 0,339, GARCH- t 0,396, GJR 0,398, GARCH 0,407
- DM față de HAR (QLIKE): GARCH 8,62, GJR 6,27, Realized GARCH 1,42, log-HAR $-0,37$: modelele cu măsuri realizate sînt clar mai bune decît cele doar cu randamente; între ele diferențele sînt mici
- După MSE, HAR (1,60) conduce, iar statisticile DM sînt mai mici: crahul din 2020 domină erorile pătratice
- Un singur proxy (RK) pentru toate modelele: familia HAR este estimată pe aceeași măsură, ceea ce o avantajează; o comparație corectă încearcă și alt proxy (RV, BV)

Recapitulare: evaluarea

- Doar funcțiile din clasa Patton păstrează ordinea cu un proxy nedeplasat zgomotos: MSE și QLIKE
- La un pas, modelele cu măsuri realizate depășesc modelele GARCH care folosesc doar randamentele; DM și MCS din [Capitolul 1](#) cuantifică diferența
- Precizați proxy-ul, funcția de pierdere, fereastra și filtrul: fiecare poate schimba ordinea

De la o varianță la o matrice de covarianță (1/2)

- Vectorul celor N șocuri ale randamentelor este produsul dintre o rădăcină pătrată matriceală a covarianței condiționate și un vector standardizat

$$\varepsilon_t = H_t^{1/2} \eta_t, \quad \eta_t \text{ i.i.d. } (0, I_N)$$

- ▶ $H_t = \text{Var}(\varepsilon_t | \mathcal{F}_{t-1})$: matricea de covarianță condiționată, $N \times N$; I_N : matricea identitate
- ▶ H_t trebuie să fie simetrică și pozitiv definită pentru orice t și orice valoare a parametrilor
- VEC: fiecare element al lui H_t depinde de toate pătratele și produsele încrucișate din trecut
$$\text{vech}(H_t) = c + A \text{vech}(\varepsilon_{t-1} \varepsilon_{t-1}') + B \text{vech}(H_{t-1})$$
- ▶ vech: așază într-un vector cele $N(N+1)/2$ elemente distincte ale unei matrice simetrice; c : vector, A, B : matrice pătrate de această dimensiune
- ▶ general, dar pozitivitatea este greu de impus

De la o varianță la o matrice de covarianță (2/2): BEKK, CCC și DCC

- ▣ BEKK Engle și Kroner (1995): formule pătratice garantează caracterul pozitiv definit

$$H_t = CC' + A'\varepsilon_{t-1}\varepsilon'_{t-1}A + B'H_{t-1}B$$

- ▶ C : matrice inferior triunghiulară $N \times N$; A, B : matrice $N \times N$; versiunile diagonală și scalară restricționează A, B
- ▶ identificarea: (A, B) și $(-A, -B)$ dau aceeași H_t ; se fixează semnul unui element

- ▣ CCC Bollerslev (1990) și DCC Engle (2002): varianțele din GARCH univariate, corelațiile modelate separat

$$H_t = D_t R D_t \quad (\text{CCC}), \quad H_t = D_t R_t D_t \quad (\text{DCC}), \quad D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{Nt})$$

- ▶ σ_{it} : abaterea standard condiționată a activului i , din propriul GARCH; R : matricea de corelație constantă; R_t : matricea de corelație variabilă în timp

Blestemul dimensionalității în cifre


N	VEC	BEKK	BEKK diagonal	BEKK scalar	DCC
2	21	11	7	5	9
5	465	65	25	17	27
10	6 105	255	75	57	77
25	211 575	1 575	375	327	377
50	3 252 525	6 275	1 375	1 277	1 377
100	51 010 050	25 050	5 250	5 052	5 252

- Numărul parametrilor liberi ai versiunilor (1,1); DCC: $3N$ parametri GARCH univariați, 2 parametri ai corelației și cele $N(N-1)/2$ elemente ale țintei
- Ținta DCC este estimată prin momente (correlation targeting), deci căutarea numerică are doar 2 parametri pentru orice N ; prețul: $N(N-1)/2$ corelații estimate

Teoria asimptotică pentru GARCH multivariat

- ▣ QML gaussian este estimatorul standard; consistența și normalitatea asimptotică: VEC și BEKK [Comte și Lieberman \(2003\)](#), [Hafner și Preminger \(2009\)](#); CCC cu medii ARMA [Ling și McAleer \(2003\)](#)
- ▣ Condițiile sînt mai puternice decît în cazul univariat (momente de ordinul 6 sau 8 pentru BEKK în primele rezultate); sandwich-ul din secțiunea univariată se păstrează
- ▣ DCC se estimează în doi pași [Engle și Sheppard \(2001\)](#): (1) GARCH univariat pentru fiecare serie; (2) QML pentru partea de corelație, condiționat de reziduurile standardizate $z_t = D_t^{-1} \varepsilon_t$
 - ▶ erorile standard din pasul al doilea trebuie să țină seama de primul pas (o corecție de tip GMM); erorile standard naive din pasul al doilea sînt prea mici
- ▣ N mare: verosimilitatea completă cere R_t^{-1} și $|R_t|$ la fiecare t ($O(N^3)$), iar scorul este dominat de zgomot; verosimilitatea compusă pe perechi [Pakel, Shephard, Sheppard și Engle \(2021\)](#) le evită pe amîndouă

DCC și versiunea corectată cDCC (1/2): DCC



Robert F. Engle, 2017

Foto: Econterms (2017); CC BY-SA 4.0;

Wikimedia Commons

- DCC: o recursie de tip GARCH(1,1) pentru o matrice de cvasi-corelație Q_t , rescalată apoi într-o matrice de corelație

$$Q_t = (1 - a - b)S + a z_{t-1} z'_{t-1} + b Q_{t-1}$$

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$$

- ▶ $z_t = D_t^{-1} \varepsilon_t$: reziduurile standardizate ale modelelor GARCH univariate; S : matricea lor de corelație de eşantion (ținta)
- ▶ $a \geq 0$: reacția corelațiilor la co-mișcarea de ieri; $b \geq 0$: persistența; $a + b < 1$
- ▶ $\text{diag}(Q_t)$: matricea diagonală formată din elementele de pe diagonala lui Q_t ; rescalarea pune valoarea 1 pe diagonala lui R_t


DCC și versiunea corectată cDCC (2/2): cDCC

- ▣ Aielli (2013): ținta DCC este estimată inconsistent
 - ▶ $\mathbb{E}(z_t z_t' | \mathcal{F}_{t-1}) = R_t \neq Q_t$, deci în general $\mathbb{E}Q_t \neq \mathbb{E}z_t z_t'$
 - ▶ estimatorul prin momente al lui S este inconsistent, la fel și $(\hat{a}, \hat{b})$
- ▣ cDCC: reziduurile sînt rescalate cu diagonală lui Q_{t-1} înainte de a intra în recursie

$$z_{t-1}^* = \text{diag}(Q_{t-1})^{1/2} z_{t-1}, \quad Q_t = (1 - a - b)S + a z_{t-1}^* z_{t-1}^{*'} + b Q_{t-1}$$

- ▶ atunci $\mathbb{E}(z_t^* z_t^{*'} | \mathcal{F}_{t-1}) = Q_t$, iar $S = \mathbb{E}z_t^* z_t^{*'}$ este o țintă validă
- ▶ ținta cDCC depinde de (a, b) : se estimează iterativ, în interiorul verosimilității

DCC față de cDCC: o simulare



- Proces cDCC bivariat cu $a = 0,05$, $b = 0,93$, corelația-țintă 0,5, varianțe unitare; $T = 2\,000$, 100 de replicări; ambii estimatori pe fiecare eșantion

Interpretarea simulării DCC

- ▣ Estimațiile medii: DCC $\hat{a} = 0,0478$, $\hat{b} = 0,9307$; cDCC $\hat{a} = 0,0486$, $\hat{b} = 0,9288$ (valorile adevărate 0,05 și 0,93)
- ▣ RMSE pentru $\hat{a}$: 0,0090 (DCC) și 0,0086 (cDCC); pentru $\hat{b}$: 0,0135 și 0,0129: inconsistența este reală, dar mică la aceste niveluri de persistență
- ▣ Eroarea de eșantionare domină deplasarea la două mii de observații; diferența contează mai mult pentru țintă în sisteme mari și pentru inferența asupra lui (a, b)
- ▣ O demonstrație a inconsistenței nu spune cât de mare este deplasarea: simulați-o în propria configurație înainte de a alege estimatorul

Matrice de covarianță mari: shrinkage și DCC-NL (1/2)

- Când N/T nu este mic, valorile proprii ale unei covarianțe de eșantion S sînt prea dispersate
 - ▶ N : numărul de active; T : numărul de observații; cele mai mari valori proprii sînt prea mari, cele mai mici, prea mici; inversa S^{-1} amplifică eroarea
- Portofoliul de varianță minimă globală (GMV): ponderile cu cea mai mică varianță care însumează 1

$$w = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}' \Sigma^{-1} \mathbf{1}}$$

- ▶ Σ : matricea de covarianță a randamentelor; $\mathbf{1}$: vectorul cu toate elementele egale cu 1
- ▶ pune ponderi mari pe direcțiile cu valorile proprii cele mai mici, cel mai mult subestimate
- ▶ depinde doar de Σ , deci riscul lui realizat măsoară calitatea prognozei covarianței fără zgomotul randamentelor așteptate


Matrice de covarianță mari: shrinkage și DCC-NL (2/2)

- ▣ Shrinkage liniar [Ledoit și Wolf \(2004\)](#): o medie ponderată între S și o matrice identitate scalată

$$\hat{\Sigma} = \delta \mu I + (1 - \delta) S$$

- ▶ μ : media valorilor proprii ale lui S ; $\delta \in [0, 1]$: intensitatea shrinkage-ului, estimată din date (mai mare când N/T este mai mare)
- ▣ Shrinkage neliniar [Ledoit și Wolf \(2020\)](#): se păstrează vectorii proprii ai lui S și se înlocuiește fiecare valoare proprie λ_i cu $d(\lambda_i)$
 - ▶ $d(\cdot)$: o formulă analitică de tip kernel care ridică valorile proprii mici și le coboară pe cele mari, cu intensități diferite
- ▣ DCC-NL [Engle, Ledoit și Wolf \(2019\)](#): în DCC, ținta S a reziduurilor standardizate este ea însăși o covarianță de eșantion mare: o înlocuim cu versiunea ei cu shrinkage neliniar
 - ▶ verosimilitate compusă pentru (a, b) , GARCH univariat pentru varianțe; evaluat prin abaterea standard în afara eșantionului a portofoliilor GMV

Studiu de caz: Engle, Ledoit și Wolf (2019) pe acțiuni din SUA



- 17 active: 14 acțiuni din SUA și trei ETF-uri pe acțiuni (SPY, QQQ, RSP), care sînt ele însele portofolii de acțiuni; ponderi GMV rebalansate la fiecare 21 de zile din 23.05.2017 (112 rebalansări); fereastra de 1250 de zile, respectiv 250 de zile pentru ultimele două bare; abaterea standard anualizată în afara eșantionului

Interpretarea comparației GMV (1/2)

- ▣ Abaterea standard în afara eșantionului (% anual): 1/N 25,05, eșantion 15,83, shrinkage liniar 15,99, shrinkage neliniar 15,81, DCC 18,35, DCC-NL 18,33
- ▣ Cu $N/T = 17/1250$, covarianța de eșantion este deja precisă
 - ▶ shrinkage-ul neliniar schimbă puțin (15,81 față de 15,83); DCC-NL nu este mai bun decât DCC
- ▣ Aici dinamica dăunează: DCC dă 18,35 față de 15,83
 - ▶ DCC folosește varianțe GARCH, cu prognoze mediate pe perioada de deținere de 21 de zile
 - ▶ prognozele de varianță pe o lună pentru acțiuni individuale precum MSTR și TSLA sînt zgomotoase, iar GMV le amplifică erorile

Interpretarea comparației GMV (2/2)

- ▣ O fereastră de 250 de zile face N/T de cinci ori mai mare
 - ▶ abaterea standard a portofoliului GMV din eșantion este 15,24, cu shrinkage neliniar 15,21: doar cu 0,2% mai mică
 - ▶ deși ETF-urile fac matricea de corelație aproape singulară (numărul de condiționare median 1146)
 - ▶ fereastra mai scurtă reduce ea însăși riscul: o formă rudimentară de variație în timp
- ▣ Studiul original folosește sute de acțiuni, unde N/T este mare
 - ▶ acolo câștigurile DCC-NL sînt substanțiale
 - ▶ cu N -ul nostru, lecția este cînd contează shrinkage-ul, nu cît câștigă

Covarianța realizată

- RV multivariat: suma produselor exterioare ale vectorilor de randamente intraday

$$\text{RCov}_t = \sum_{i=1}^n r_{t,i} r'_{t,i} \rightarrow \int_0^1 \Sigma_s ds$$

- ▶ $r_{t,i}$: vectorul $N \times 1$ al randamentelor intraday; Σ_s : matricea de covarianță instantanee; la limită se adaugă salturile comune; cu prețuri sincrone și fără zgomot, moștenește TLC a lui RV
- Tranzacționarea asincronă: prețurile „previous-tick” creează randamente nule pentru activul care nu a fost tranzacționat; covarianțele se apropie de zero când intervalul scade (efectul Epps)
 - ▶ eșantionarea la timpul de reîmprospătare (toate activele au fost tranzacționate) și realised kernel-ul multivariat [Barndorff-Nielsen et al. \(2011\)](#): consistent și pozitiv semidefinit
- Prognoza: HAR pe elementele factorului Cholesky al lui RCov_t păstrează prognozele pozitiv definite [Chiriac și Voev \(2011\)](#); HEAVY și Realized GARCH au versiuni multivariate
- Evaluarea prognozelor de covarianță H_t față de un proxy matriceal Σ_t : funcții de pierdere robuste [Laurent, Rombouts și Violante \(2012\)](#)
 - ▶ QLIKE matriceal $\ln |H_t| + \text{tr}(H_t^{-1} \Sigma_t)$, cu $|\cdot|$ determinantul și tr urma; MSE Frobenius, suma pătratelor erorilor pe elemente

Bitcoin și Ether: corelația realizată și corelația DCC



- Corelația realizată zilnică din randamente la 5 minute (medii pe 5 zile) și corelația DCC a randamentelor zilnice închidere–închidere (UTC), 2018–2026

Interpretarea corelațiilor

- ▣ Corelația realizată medie 0,83, corelația DCC medie 0,83; corelația dintre cele două serii 0,26
- ▣ DCC folosește o observație pe zi ($\hat{a} = 0,051$, $\hat{b} = 0,928$): netezește și reacționează cu întârziere; măsura realizată se mișcă zilnic și scade repede în episoadele specifice unei monede (cuantila de 5% 0,68)
- ▣ Combinarea lor (o măsură realizată în ecuația corelației) este analogul multivariat al Realized GARCH
- ▣ Eșantionarea la cinci minute se află pe partea plată a curbei Epps pentru aceste două monede (slide-ul cu signature plot): corelația realizată nu este deplasată spre zero

Recapitulare: cazul multivariat

- ▣ BEKK garantează pozitivitatea cu un cost pătratic în parametri; DCC separă varianțele de corelații și funcționează pentru N mare
- ▣ cDCC corectează inconsistența țintei DCC; în configurații moderate, diferența este mică
- ▣ În dimensiune mare, ținta are nevoie de shrinkage (DCC-NL); evaluați prin riscul GMV sau prin funcții de pierdere matriceale robuste

O întrebare deschisă

- Îmbunătățește exploatarea erorii de măsurare a varianței realizate (HARQ) prognozele de volatilitate în mod robust sau doar pentru anumite alegeri de specificare?
 - ▶ formal: raportul $QLIKE\ HARQ/HAR$ și statistica DM pe o grilă preînregistrată (fereastră, filtru, măsură realizată, activ); infirmată dacă raportul depășește 1 sau testul DM este nesemnificativ în majoritatea celulelor
 - ▶ măsura preciziei (RQ) este ea însăși zgomotoasă și cu cozi groase, deci câștigul poate fi fragil
- Miza: sistemele de risc folosesc zilnic prognoze de volatilitate pe o zi; un câștig mic, dar robust valorează mai mult decât unul mare și fragil
 - ▶ literatura de pornire: Bollerslev, Patton și Quaadvlieg (2016), Corsi (2009), Patton (2011), Hansen și Lunde (2006a), Hansen, Lunde și Nason (2011)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează lucrări recenzate din 2016 încoace care testează în afara eșantionului modele de tip HARQ pe alte active decât acțiunile din SUA; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** În ce condiții ale datelor (tranzacționare 24/7, salturi, randamente nule) ar trebui să scadă sau să crească câștigul HARQ? Dă predicții testabile.
 - ▶ **cod și replicare:** cereți prognoze HAR și HARQ pe fereastră mobilă, apoi reproduceți întâi o cifră cunoscută (raportul QLIKE pentru Bitcoin din acest curs)
 - ▶ **robustețe și critică:** Joacă rolul unui recenzent ostil: ce alegeri dintr-o comparație a prognozelor HARQ ar putea produce un câștig fals?
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Prognoza din t folosește doar date pînă la t : ferestrele, centrarea lui RQ, filtrul de plauzibilitate și corecția deplasării prognozelor în logaritmi sînt calculate în fereastra de estimare
- ▣ Funcția de pierdere este robustă (QLIKE, MSE), iar proxy-ul este precizat; statisticile DM folosesc varianțe HAC
- ▣ Toate celulele grilei sînt raportate, nu doar cea mai bună; numărul comparațiilor este precizat
- ▣ Măsurile realizate sînt recalculat din prețurile brute și concordă cu o sursă independentă pentru activele și datele comune

Mini studiu de caz: douăsprezece alegeri, o singură concluzie?



- Raportul QLIKE HARQ/HAR pentru Bitcoin și Ether: fereastră de 500, 1 000 sau 1 500 de zile; filtrul de plauzibilitate sau o limită inferioară egală cu cel mai mic RV din eșantion; ținta RV la 5 minute sau realised kernel
- Rapoarte între 0,865 și 2,844; HARQ mai bun în 58% dintre cele 24 de celule, semnificativ mai bun ($DM < -1,96$) în 50%, semnificativ mai slab în 12%: un rezumat AI care raportează o singură celulă ar ascunde cea mai mare parte din acest tablou

Idee de proiect

- ▣ **Volatilitatea realizată a criptoactivelor: se transferă instrumentele de la acțiuni?:** întâi replicare, apoi extindere
 - ▶ replicați: HAR și HARQ din acest curs pentru Bitcoin (raportul QLIKE 0,946) și Realized GARCH pentru S&P 500 (persistența 0,968)
 - ▶ extindeți: zece monede din arhiva Binance; măsuri robuste la zgomot din date la o secundă
 - ▶ extindeți testele: o corecție a sezonality intraday înaintea testelor de salt; Realized GARCH cu realised kernel
 - ▶ folosiți data ETF-urilor spot (ianuarie 2024) ca ruptură naturală
 - ▶ preînregistrați: activele, eşantionul, măsurile, modelele, ferestrele, funcțiile de pierdere, testele DM/MCS și grila de robustețe
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ QML gaussian are nevoie doar de ecuația varianței; cu cozi groase, folosiți erorile standard sandwich
- ▣ Volatilitatea are componente rapide și lente; factorii macroeconomici ai celei lente au nevoie de eșantioane lungi și de rapoarte de varianță raportate fără selecție
- ▣ Măsurile realizate fac volatilitatea observabilă, cu o eroare cunoscută; zgomotul și salturile decid estimatorul
- ▣ La un pas, HAR, HARQ și Realized GARCH depășesc modelele care folosesc doar randamentele; evaluați cu QLIKE sau MSE
- ▣ În multe dimensiuni, ținta de corelație are nevoie de shrinkage (DCC-NL); dacă dinamica ajută trebuie verificat în afara eșantionului

Autoevaluare

Întrebări

- ▣ De ce sînt prea mici erorile standard din hessiană pentru GARCH cînd $\kappa_\eta > 3$?
- ▣ Ce măsoară raportul de varianță din GARCH-MIDAS?
- ▣ De ce contează convergența stabilă pentru TLC a lui RV?
- ▣ De ce poate crește un signature plot la frecvență înaltă?
- ▣ De ce ne așteptăm ca β_{dQ} să fie negativ în HARQ?
- ▣ Ce funcții de pierdere păstrează ordinea cu un proxy zgomotos?

Urmează:

- ▣ VaR, ES și backtesting: elicitabilitate, funcții de scor și riscul de model
- ▣ De la prognozele de volatilitate la prognozele de coadă: VaR 1% și ES 2,5%, funcțiile lor de scor și backtesting-ul

Anexă: sandwich-ul GARCH

- $\ell_t = -\frac{1}{2}(\ln \sigma_t^2 + \varepsilon_t^2/\sigma_t^2)$, $d_t = \sigma_t^{-2} \partial \sigma_t^2 / \partial \theta$: $s_t = \frac{1}{2}(\eta_t^2 - 1)d_t$ în θ_0
- $B = \mathbb{E} s_t s_t' = \frac{1}{4} \mathbb{E}(\eta_t^2 - 1)^2 \mathbb{E} d_t d_t' = \frac{\kappa_\eta - 1}{4} J$, deoarece η_t este independent de $d_t \in \mathcal{F}_{t-1}$
- $\partial s_t / \partial \theta' = -\frac{1}{2} \eta_t^2 d_t d_t' + \frac{1}{2}(\eta_t^2 - 1) \partial d_t / \partial \theta'$; al doilea termen are media zero, deci $A = \frac{1}{2} J$
- $A^{-1} B A^{-1} = 4J^{-1} \cdot \frac{\kappa_\eta - 1}{4} J \cdot J^{-1} = (\kappa_\eta - 1)J^{-1}$; doar hessiana: $A^{-1} = 2J^{-1}$; OPG: $B^{-1} = \frac{4}{\kappa_\eta - 1} J^{-1}$

Anexă: deplasarea din zgomot a varianței realizate

- ▣ $\tilde{r}_i = Y_{i/n} - Y_{(i-1)/n} = r_i + u_i - u_{i-1}$, cu u i.i.d. $(0, \omega^2)$, independent de X
- ▣ $\sum_i \tilde{r}_i^2 = \sum_i r_i^2 + 2 \sum_i r_i(u_i - u_{i-1}) + \sum_i (u_i - u_{i-1})^2$; termenul mixt are media zero, ultimul are media $2n\omega^2$
- ▣ $\text{Cov}(\tilde{r}_i, \tilde{r}_{i-1}) = -\omega^2$: autocorelație negativă de ordinul întâi; realised kernel-ul adaugă $2\gamma_1 \approx -2n\omega^2$ și elimină deplasarea
- ▣ Randamentele autocorelate pozitiv (ajustarea treptată a prețului, prețuri stale (neactualizate)) dau $\gamma_1 > 0$ și un signature plot care crește cu intervalul; kernel-ul corectează ambele semne

Anexă: atenuarea și HARQ

- ▣ $IV_{t+1} = c + \phi IV_t + v_{t+1}$, observăm $RV_t = IV_t + e_t$, e_t necorelat cu IV_t și v_{t+1}
- ▣ OLS pentru RV_{t+1} pe RV_t : $\text{plim } \hat{\phi} = \frac{\text{Cov}(IV_{t+1}, IV_t)}{\text{Var}(IV_t) + \text{Var}(e_t)} = \phi\lambda$, $\lambda = \frac{\text{Var}(IV)}{\text{Var}(IV) + \mathbb{E}\text{Var}(e_t)}$
- ▣ Cel mai bun predictor liniar, dată precizia de azi, folosește $\phi\lambda_t$, $\lambda_t = \frac{\text{Var}(IV)}{\text{Var}(IV) + 2IQ_t/n}$: descrescător în IQ_t
- ▣ O dezvoltare de ordinul întâi în $\sqrt{IQ_t}$ dă $\beta_d + \beta_{dQ}\sqrt{RQ_t}$, cu $\beta_{dQ} < 0$: specificarea HARQ [Bollerslev, Patton și Quaedvlieg \(2016\)](#)

Bibliografie (1/5)

- ▣ Aielli, G. P. (2013). Dynamic conditional correlation: On properties and estimation. *Journal of Business & Economic Statistics*, 31(3), 282–299. doi:10.1080/07350015.2013.771027
- ▣ Andersen, T. G., & Bollerslev, T. (1998). Answering the skeptics: Yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905. doi:10.2307/2527343
- ▣ Andersen, T. G., Bollerslev, T., & Diebold, F. X. (2007). Roughing it up: Including jump components in the measurement, modeling, and forecasting of return volatility. *The Review of Economics and Statistics*, 89(4), 701–720. doi:10.1162/rest.89.4.701
- ▣ Andersen, T. G., Bollerslev, T., Diebold, F. X., & Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2), 579–625. doi:10.1111/1468-0262.00418
- ▣ Andersen, T. G., Dobrev, D., & Schaumburg, E. (2012). Jump-robust volatility estimation using nearest neighbor truncation. *Journal of Econometrics*, 169(1), 75–93. doi:10.1016/j.jeconom.2012.01.011
- ▣ Bandi, F. M., & Russell, J. R. (2008). Microstructure noise, realized variance, and optimal sampling. *The Review of Economic Studies*, 75(2), 339–369. doi:10.1111/j.1467-937X.2008.00474.x
- ▣ Barndorff-Nielsen, O. E., Hansen, P. R., Lunde, A., & Shephard, N. (2008). Designing realized kernels to measure the ex post variation of equity prices in the presence of noise. *Econometrica*, 76(6), 1481–1536. doi:10.3982/ECTA6495
- ▣ Barndorff-Nielsen, O. E., Hansen, P. R., Lunde, A., & Shephard, N. (2009). Realized kernels in practice: Trades and quotes. *The Econometrics Journal*, 12(3), C1–C32. doi:10.1111/j.1368-423X.2008.00275.x
- ▣ Barndorff-Nielsen, O. E., Hansen, P. R., Lunde, A., & Shephard, N. (2011). Multivariate realised kernels: Consistent positive semi-definite estimators of the covariation of equity prices with noise and non-synchronous trading. *Journal of Econometrics*, 162(2), 149–169. doi:10.1016/j.jeconom.2010.07.009
- ▣ Barndorff-Nielsen, O. E., & Shephard, N. (2002). Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society: Series B*, 64(2), 253–280. doi:10.1111/1467-9868.00336
- ▣ Barndorff-Nielsen, O. E., & Shephard, N. (2004). Power and bipower variation with stochastic volatility and jumps. *Journal of Financial Econometrics*, 2(1), 1–37. doi:10.1093/jjfinec/nbh001
- ▣ Barndorff-Nielsen, O. E., & Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1), 1–30. doi:10.1093/jjfinec/nbi022

Bibliografie (2/5)

- ▣ Berkes, I., Horváth, L., & Kokoszka, P. (2003). GARCH processes: Structure and estimation. *Bernoulli*, 9(2), 201–227. doi:10.3150/bj/1068128975
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- ▣ Bollerslev, T. (1990). Modelling the coherence in short-run nominal exchange rates: A multivariate generalized ARCH model. *The Review of Economics and Statistics*, 72(3), 498–505. doi:10.2307/2109358
- ▣ Bollerslev, T., Patton, A. J., & Quaedvlieg, R. (2016). Exploiting the errors: A simple approach for improved volatility forecasting. *Journal of Econometrics*, 192(1), 1–18. doi:10.1016/j.jeconom.2015.10.007
- ▣ Bollerslev, T., & Wooldridge, J. M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172. doi:10.1080/07474939208800229
- ▣ Chiriac, R., & Voev, V. (2011). Modelling and forecasting multivariate realized volatility. *Journal of Applied Econometrics*, 26(6), 922–947. doi:10.1002/jae.1152
- ▣ Comte, F., & Lieberman, O. (2003). Asymptotic theory for multivariate GARCH processes. *Journal of Multivariate Analysis*, 84(1), 61–84. doi:10.1016/S0047-259X(02)00009-X
- ▣ Conrad, C., & Kleen, O. (2020). Two are better than one: Volatility forecasting using multiplicative component GARCH-MIDAS models. *Journal of Applied Econometrics*, 35(1), 19–45. doi:10.1002/jae.2742
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jjfinec/nbp001
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Engle, R. (2002). Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350. doi:10.1198/073500102288618487
- ▣ Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007. doi:10.2307/1912773

Bibliografie (3/5)

- ▣ Engle, R. F., Ghysels, E., & Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *The Review of Economics and Statistics*, 95(3), 776–797. doi:10.1162/REST_a_00300
- ▣ Engle, R. F., & Kroner, K. F. (1995). Multivariate simultaneous generalized ARCH. *Econometric Theory*, 11(1), 122–150. doi:10.1017/S0266466600009063
- ▣ Engle, R. F., Ledoit, O., & Wolf, M. (2019). Large dynamic covariance matrices. *Journal of Business & Economic Statistics*, 37(2), 363–375. doi:10.1080/07350015.2017.1345683
- ▣ Engle, R. F., & Lee, G. G. J. (1999). A long-run and short-run component model of stock return volatility. In R. F. Engle & H. White (Eds.), *Cointegration, Causality, and Forecasting: A Festschrift in Honour of Clive W. J. Granger* (pp. 475–497). Oxford University Press. doi:10.1093/oso/9780198296836.003.0020
- ▣ Engle, R. F., & Sheppard, K. (2001). Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH. *NBER Working Paper* 8554. doi:10.3386/w8554
- ▣ Epps, T. W. (1979). Comovements in stock prices in the very short run. *Journal of the American Statistical Association*, 74(366), 291–298. doi:10.1080/01621459.1979.10482508
- ▣ Francq, C., & Zakořan, J.-M. (2004). Maximum likelihood estimation of pure GARCH and ARMA-GARCH processes. *Bernoulli*, 10(4), 605–637. doi:10.3150/bj/1093265632
- ▣ Francq, C., & Zakořan, J.-M. (2019). *GARCH Models: Structure, Statistical Inference and Financial Applications* (2nd ed.). Wiley. doi:10.1002/9781119313472
- ▣ Ghysels, E., Santa-Clara, P., & Valkanov, R. (2006). Predicting volatility: Getting the most out of return data sampled at different frequencies. *Journal of Econometrics*, 131(1–2), 59–95. doi:10.1016/j.jeconom.2005.01.004
- ▣ Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779–1801. doi:10.1111/j.1540-6261.1993.tb05128.x
- ▣ Hafner, C. M., & Preminger, A. (2009). On asymptotic theory for multivariate GARCH models. *Journal of Multivariate Analysis*, 100(9), 2044–2054. doi:10.1016/j.jmva.2009.03.011
- ▣ Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. doi:10.2307/j.ctv14jx6sm

Bibliografie (4/5)

- ▣ Hansen, P. R., & Huang, Z. (2016). Exponential GARCH modeling with realized measures of volatility. *Journal of Business & Economic Statistics*, 34(2), 269–287. doi:10.1080/07350015.2015.1038543
- ▣ Hansen, P. R., Huang, Z., & Shek, H. H. (2012). Realized GARCH: A joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906. doi:10.1002/jae.1234
- ▣ Hansen, P. R., & Lunde, A. (2005). A forecast comparison of volatility models: Does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889. doi:10.1002/jae.800
- ▣ Hansen, P. R., & Lunde, A. (2006a). Consistent ranking of volatility models. *Journal of Econometrics*, 131(1–2), 97–121. doi:10.1016/j.jeconom.2005.01.005
- ▣ Hansen, P. R., & Lunde, A. (2006b). Realized variance and market microstructure noise. *Journal of Business & Economic Statistics*, 24(2), 127–161. doi:10.1198/0735001060000000071
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- ▣ Heber, G., Lunde, A., Shephard, N., & Sheppard, K. (2009). *Oxford-Man Institute's realized library*, version 0.3. Oxford-Man Institute, University of Oxford (discontinued in 2022; copy of 28 February 2022 preserved by the Internet Archive). web.archive.org
- ▣ Huang, X., & Tauchen, G. (2005). The relative contribution of jumps to total price variance. *Journal of Financial Econometrics*, 3(4), 456–499. doi:10.1093/jfinec/nbi025
- ▣ Jacod, J., Li, Y., Mykland, P. A., Podolskij, M., & Vetter, M. (2009). Microstructure noise in the continuous case: The pre-averaging approach. *Stochastic Processes and their Applications*, 119(7), 2249–2276. doi:10.1016/j.spa.2008.11.004
- ▣ Jensen, S. T., & Rahbek, A. (2004). Asymptotic inference for nonstationary GARCH. *Econometric Theory*, 20(6), 1203–1226. doi:10.1017/S0266466604206065
- ▣ Laurent, S., Rombouts, J. V. K., & Violante, F. (2012). On the forecasting accuracy of multivariate GARCH models. *Journal of Applied Econometrics*, 27(6), 934–955. doi:10.1002/jae.1248
- ▣ Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. doi:10.1016/S0047-259X(03)00096-4

Bibliografie (5/5)

- ▣ Ledoit, O., & Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *The Annals of Statistics*, 48(5), 3043–3065. doi:10.1214/19-AOS1921
- ▣ Lee, S. S., & Mykland, P. A. (2008). Jumps in financial markets: A new nonparametric test and jump dynamics. *The Review of Financial Studies*, 21(6), 2535–2563. doi:10.1093/rfs/hhm056
- ▣ Lee, S.-W., & Hansen, B. E. (1994). Asymptotic theory for the GARCH(1,1) quasi-maximum likelihood estimator. *Econometric Theory*, 10(1), 29–52. doi:10.1017/S0266466600008215
- ▣ Ling, S., & McAleer, M. (2003). Asymptotic theory for a vector ARMA-GARCH model. *Econometric Theory*, 19(2), 280–310. doi:10.1017/S0266466603192092
- ▣ Lumsdaine, R. L. (1996). Consistency and asymptotic normality of the quasi-maximum likelihood estimator in IGARCH(1,1) and covariance stationary GARCH(1,1) models. *Econometrica*, 64(3), 575–596. doi:10.2307/2171862
- ▣ Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. doi:10.2307/1913610
- ▣ Pakel, C., Shephard, N., Sheppard, K., & Engle, R. F. (2021). Fitting vast dimensional time-varying covariance models. *Journal of Business & Economic Statistics*, 39(3), 652–668. doi:10.1080/07350015.2020.1713795
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Patton, A. J., & Sheppard, K. (2015). Good volatility, bad volatility: Signed jumps and the persistence of volatility. *The Review of Economics and Statistics*, 97(3), 683–697. doi:10.1162/REST_a_00503
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Shephard, N., & Sheppard, K. (2010). Realising the future: Forecasting with high-frequency-based volatility (HEAVY) models. *Journal of Applied Econometrics*, 25(2), 197–231. doi:10.1002/jae.1158
- ▣ Zhang, L., Mykland, P. A., & Aït-Sahalia, Y. (2005). A tale of two time scales: Determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472), 1394–1411. doi:10.1198/016214505000000169