



Analiza avansată a seriilor de timp și previziune



Capitolul 9: VaR, ES și backtesting: elicitalitate, funcții de scor și riscul de model

Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- ADAPT: Adaptive (CAViaR specification) — specificația CAViaR adaptivă
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); în event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARFIMA: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv fracționar integrat cu medie mobilă
- ARMA: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ARMA-GARCH: ARMA mean with GARCH variance (medie ARMA cu varianță GARCH)
- AS: Asymmetric Slope (CAViaR specification) — specificația CAViaR cu pantă asimetrică
- BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- BIC: Bayesian Information Criterion (criteriul informațional bayesian (Schwarz))
- BNR: Banca Națională a României
- BUX: Budapesti Értéktőzsde index (indicele Bursei din Budapesta)
- DM: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- DQ: Dynamic Quantile (test of Engle and Manganelli) — testul dinamic pe cuantile al lui Engle și Manganelli
- EDF: Empirical Distribution Function (funcția de repartiție empirică)
- EM: Engle and Manganelli (2004), CAViaR (Engle și Manganelli (2004), CAViaR)
- EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață
- ES: Expected Shortfall (pierdere așteptată în coadă)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FZ: Fissler–Ziegel (class of scoring functions for VaR and ES) — clasa Fissler–Ziegel de funcții de scor pentru VaR și ES
- FZ-1F: One-factor GAS model for VaR and ES (label of Patton, Ziegel and Chen) — model GAS cu un factor pentru VaR și ES (eticheta lui Patton, Ziegel și Chen)
- FZ-2F: Two-factor GAS model for VaR and ES (label of Patton, Ziegel and Chen) — model GAS cu doi factori pentru VaR și ES (eticheta lui Patton, Ziegel și Chen)
- FZ0: Zero-homogeneous Fissler–Ziegel loss (Patton, Ziegel and Chen) — pierdere Fissler–Ziegel omogenă de grad zero (Patton, Ziegel și Chen)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)

Acronime folosite în acest material (2/3)

- GARCH-EDF: GARCH with innovations from the empirical distribution function (GARCH cu inovații din funcția de repartiție empirică)
- GARCH-FZ: GARCH model estimated by FZ0 minimisation (model GARCH estimat prin minimizarea pierderii FZ0)
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații din distribuția Normală)
- GAS: Generalised Autoregressive Score (model) — model autoregresiv determinat de scor
- GAS-1F: One-factor GAS model for VaR and ES (model GAS cu un factor pentru VaR și ES)
- GAS-2F: Two-factor GAS model for VaR and ES (model GAS cu doi factori pentru VaR și ES)
- GAS-FZ: GAS models for VaR and ES driven by the FZ0 loss (modele GAS pentru VaR și ES determinate de pierderea FZ0)
- GCH: GARCH (short label in tables) — GARCH (etichetă scurtă în tabele)
- GCH-EDF: ARMA-GARCH with innovations from the empirical distribution function (ARMA-GARCH cu inovații din funcția de repartiție empirică)
- GCH-FZ: GARCH model estimated by FZ0 minimisation (table label) — model GARCH estimat prin minimizarea pierderii FZ0 (etichetă de tabel)
- GCH-N: ARMA-GARCH with Normal innovations (ARMA-GARCH cu inovații din distribuția Normală)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- GM: General Motors (stock) — acțiunea General Motors
- GPL: Generalised Piecewise Linear (scoring function) — funcție de scor liniară pe porțiuni generalizată
- GW: Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- HC0: Heteroskedasticity-Consistent covariance of White (type 0) — covarianța White robustă la heteroscedasticitate (tipul 0)
- HS: Historical Simulation (simulare istorică)
- IBM: International Business Machines (stock) — acțiunea International Business Machines
- IG: Indirect GARCH (CAViaR specification) — specificația CAViaR GARCH indirect
- LLM: Large Language Model (model lingvistic de mari dimensiuni)
- LR: Likelihood Ratio (test) — testul raportului de verosimilitate
- MA: Moving Average (medie mobilă)
- MAR33: Basel Framework, chapter MAR33 (internal models, capital requirements) — Cadrul Basel, capitolul MAR33 (modele interne, cerințe de capital)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)

Acronime folosite în acest material (3/3)

- MFM: Modelling Financial Markets (Modelarea piețelor financiare, cursul de master)
- MSE: Mean Squared Error (eroarea pătratică medie)
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- PX: Prague Stock Exchange index (index Burzy cenných papírů Praha) — indicele Bursei din Praga
- PZC: Patton, Ziegel and Chen (2019) — Patton, Ziegel și Chen (2019)
- QLIKE: Quasi-LIKelihood loss (pierderea de tip cvasi-verosimilitate)
- QML: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- RQ: Regression Quantile (criterion of Engle and Manganelli) — criteriul de regresie cuantică al lui Engle și Manganelli
- RW: Random Walk (mers aleator)
- RW-125: Rolling Window of 125 days (historical simulation) — fereastră mobilă de 125 de zile (simulare istorică)
- RW-250: Rolling Window of 250 days (historical simulation) — fereastră mobilă de 250 de zile (simulare istorică)
- RW-500: Rolling Window of 500 days (historical simulation) — fereastră mobilă de 500 de zile (simulare istorică)
- SAV: Symmetric Absolute Value (CAViaR specification) — specificația CAViaR cu valoare absolută simetrică
- TSA: Time Series Analysis (Serii de timp, cursul de licență)
- VAR: Vector AutoRegression (model vector autoregresiv)
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- WIG20: Warszawski Indeks Giełdowy 20 (indicele celor mai mari 20 de companii de la Bursa din Varșovia)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** o prognoză VaR sau ES este o prognoză punctuală a unei funcționale de coadă; cum estimăm modele dinamice pentru ea, cum testăm dacă este calibrată și cum decidem care prognoză este mai bună?
 - ▶ coada se observă rar: o prognoză se judecă cu o pierdere consistentă pentru ținta ei, pe puține zile informative
- ▣ **Traseul** capitolului
 - ▶ măsurile de risc ca funcționale; elicitabilitate, clasa Fissler–Ziegel, FZ0 și diagramele Murphy
 - ▶ regresia cuantică și CAViaR; modele semiparametrice pentru perechea (VaR, ES) și regresia comună
 - ▶ backtesting ca test de calibrare condiționată; riscul de estimare în backtesting; comparația prin MCS în perioadele de criză
 - ▶ orizontul (regula rădăcinii pătrate a timpului), riscul de model, extremele sub dependență, calibrarea conformală
- ▣ Pornim de la [Capitolul 1](#) (reguli de scor, elicitabilitate, DM, MCS), [Capitolul 0](#) (HAC, bootstrap), [Capitolul 8](#) (volatilitate) și [TSA](#), [Capitolul 5](#) (GARCH); Seminarul 9 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Caracterizați funcțiile de scor consistente pentru cuantile și pentru perechea (VaR, ES) și demonstrați că ES singur nu este elicibil
- ▣ Estimați modele CAViaR cu procedura Engle–Manganelli, calculați erorile lor standard și aplicați testul DQ
- ▣ Estimați modele dinamice semiparametrice pentru (VaR, ES) prin minimizarea pierderii FZ0 și replicați comparația în afara eșantionului a lui Patton, Ziegel și Chen
- ▣ Testați calibrarea condiționată cu funcții de identificare, țineți cont de riscul de estimare și comparați modelele de risc prin teste DM, diagrame Murphy și MCS
- ▣ Cuantificați riscul de orizont, de model și de estimare și corectați un VaR necalibrat prin inferență conformală adaptivă

Bibliografie, date și instrumente


- ▣ Teorie: [Gneiting \(2011\)](#); [Fissler și Ziegel \(2016\)](#); [Ehm et al. \(2016\)](#); [Nolde și Ziegel \(2017\)](#)
 - ▶ Modele: [Koenker și Bassett \(1978\)](#); [Engle și Manganelli \(2004\)](#); [Patton, Ziegel și Chen \(2019\)](#); [Dimitriadis și Bayer \(2019\)](#)
 - ▶ Sinteză despre practica prognozei: [Petropoulos et al. \(2022\)](#)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_09](#)
 - ▶ CAViaR, modelele GAS-FZ, regresia comună, testele de backtesting, DM și MCS scrise în `numpy/scipy`; `numba` doar accelerează recursiile
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa, eşantionul	În eşantion / în afara eşantionului
S&P 500, DAX	închideri zilnice EODHD, ianuarie 1990 – septembrie 2026	1990–1999 / 2000–2026
BET EUR/RON	EODHD, închideri oficiale, 2000–2026 cursul de referință BNR, iulie 2005 – septembrie 2026	2000–2009 / 2010–2026 pînă în iunie 2015 / din iulie 2015
Bitcoin	EODHD, 7 zile pe săptămînă, septembrie 2014 – septembrie 2026	2014–2019 / 2020–2026
VIX	închideri zilnice EODHD	regresor în regresia comună (VaR, ES)

- Randamente logaritmice zilnice în %; zece ani în eşantion, ca la Patton, Ziegel și Chen (2019), cinci pentru Bitcoin; perioade de criză: septembrie 2008 – martie 2009, februarie – iunie 2020, 2022, martie – iunie 2025

De la un crah la o funcțională de reglementare



S&P 500 în jurul datei de 19 octombrie 1987

Figură: Mark Carlson, Federal Reserve Board (2006); domeniu public; Wikimedia Commons

- 1987: o cădere de circa 20% într-o singură zi pe piața acțiunilor din SUA arată că solvabilitatea o decide coada, nu varianța
- 1996: Comitetul de la Basel adoptă VaR pentru riscul de piață și un backtest de tip semafor pentru depășiri [Comitetul de la Basel \(1996\)](#)
- 1999–2002: VaR nu este coerent; ES este coerent [Artzner et al. \(1999\)](#), [Acerbi și Tasche \(2002\)](#)
- 2011–2016: ES nu este elicitable [Gneiting \(2011\)](#), dar perechea (VaR, ES) este elicitable împreună [Fissler și Ziegel \(2016\)](#)
- FRTB: capitalul pe baza ES 2,5%, backtesting pe VaR 1% și VaR 2,5% [Comitetul de la Basel \(MAR33\)](#)

Basel: prognozatorul și arbitrul



- O bancă emite zilnic o prognoză a propriei cozi; supraveghetorul o verifică ulterior
- Două întrebări pe care statistica le separă: este prognoza **calibrată** (backtesting) și este ea **mai bună** decât alta (comparație)?
- Elicitabilitatea decide care prognoze pot fi comparate [Nolde și Ziegel \(2017\)](#)
- Contează stimulentele: o regulă de scor răsplătește raportarea onestă doar dacă este strict consistentă pentru țintă

Banca Reglementelor Internaționale, Basel, 2018

Foto: [Michał Pleskiewicz \(2018\)](#); CC BY-SA 4.0;

[Wikimedia Commons](#)

Cunoscut din TSA și MFM și elemente noi

- ▣ Cunoscut: VaR și ES prin simulare istorică, metode parametrice, FHS și EVT; testele Kupiec și Christoffersen; semaforul Basel (TSA, Capitolul 5; MFM, Capitolele 7–8)
- ▣ Nou: perspectiva prognozei
 - ▶ ce pierderi sînt consistente pentru o cuantilă și pentru perechea (VaR, ES); ce aduce elicitabilitatea și ce nu aduce
 - ▶ M-estimarea modelelor dinamice de cuantilă și de ES: identificare, asimptotică, funcții obiectiv nenetede
 - ▶ backtesting ca teste de momente ale calibrării condiționate, cu risc de estimare; comparații valide sub testare multiplă
- ▣ Replicări: Engle și Manganelli (2004) și Patton, Ziegel și Chen (2019), cu specificațiile din lucrări, pe datele noastre

VaR și ES ca funcționale (1/2): definiții

- VaR este o cuantilă a distribuției randamentelor, cu semn schimbat

$$q_\alpha(F) = \inf\{y : F(y) \geq \alpha\}, \quad \text{VaR}_\alpha(F) = -q_\alpha(F)$$

- ▶ Y : randamentul, cu funcția de repartiție F ; α : nivelul, adică rata de depășire țintă (VaR 1%: $\alpha = 0,01$)
- ▶ $q_\alpha(F)$: cel mai mic y cu $F(y) \geq \alpha$; un VaR corect este depășit cu probabilitatea $\Pr(Y < -\text{VaR}_\alpha) = \alpha$

- ES este media cuantilelor de sub nivelul α , cu semn schimbat [Acerbi și Tasche \(2002\)](#)

$$\text{ES}_\alpha(F) = -\frac{1}{\alpha} \int_0^\alpha q_u(F) du$$

- ▶ pentru F continuă: $\text{ES}_\alpha = -\mathbb{E}[Y \mid Y \leq q_\alpha]$, media randamentelor din cea mai proastă fracțiune α a zilelor, cu semn schimbat
- ▶ ES este coerent (subaditiv) [Artzner et al. \(1999\)](#); VaR nu este; ES cere $\mathbb{E}|Y| < \infty$

VaR și ES ca funcționale (2/2): convenții

- În formule lucrăm pe scala randamentelor cu perechea $(v, e) = (q_\alpha, -ES_\alpha)$
 - ▶ v : cuantila de nivel α a randamentelor; e : media randamentelor dincolo de ea; pentru nivelurile uzuale ambele sînt negative, iar $e \leq v < 0$
- Ambele sînt **funcționale** $T(F)$: aplicații de la o distribuție la un număr
 - ▶ o prognoză a lor este o prognoză punctuală a distribuției predictive, ca în [Capitolul 1](#)

Prognoze condiționate de risc: trei căi (1/2)

- ▣ Ținta: funcționala distribuției condiționate

$$(v_t, e_t) = T(F_{t|t-1})$$

- ▶ $F_{t|t-1}$: distribuția randamentului Y_t condiționată de $\mathcal{F}_{t-1}$, informația pînă în ziua $t - 1$

- ▣ **Poziție–scală**: randamentul este o medie plus produsul dintre volatilitate și un șoc i.i.d.


$$Y_t = \mu_t + \sigma_t \eta_t \Rightarrow v_t = \mu_t + \sigma_t q_\alpha(\eta), \quad e_t = \mu_t + \sigma_t \mathbb{E}[\eta \mid \eta \leq q_\alpha(\eta)]$$

- ▶ μ_t, σ_t : media și volatilitatea condiționate (ARMA, GARCH); $q_\alpha(\eta)$: cuantila distribuției șocului
- ▶ GARCH cu inovații din distribuția Normală, t asimetrică Hansen (1994) sau empirice (EDF); raportul e_t/v_t este constant în timp cînd $\mu_t = 0$

Prognoze condiționate de risc: trei căi (2/2)

- ▣ **Dinamica directă a cuantilei** Engle și Manganelli (2004): $v_t = v(\mathcal{F}_{t-1}; \beta)$
 - ▶ $v(\cdot; \beta)$: o recursie cu parametrii β , estimată prin pierderea cuantilică (pinball), fără o distribuție
- ▣ **Semiparametric comun**: $(v_t, e_t) = (v, e)(\mathcal{F}_{t-1}; \theta)$
 - ▶ două recursii cu parametrii θ , estimate printr-o pierdere Fissler–Ziegel Patton, Ziegel și Chen (2019), Dimitriadis și Bayer (2019)
- ▣ Fiecare cale produce o prognoză punctuală a unei funcționale; funcția de scor din secțiunea următoare le face comparabile

Treizeci și șase de ani de prognoze ale cozii



- Randamentele zilnice ale S&P 500; modelul GAS-1F al lui Patton, Ziegel și Chen, cu parametrii estimați o singură dată pe 1990–1999 și apoi doar filtrați; zonele colorate: cele patru perioade de criză

Interpretarea prognozelor pe termen lung

- ▣ Prognoza ES 2,5% variază de la circa $-2,44\%$ (mediana) la $-10,5\%$ la 17 martie 2020: riscul de coadă se mișcă la fel de mult ca volatilitatea
- ▣ Prognozele reacționează doar în zilele cu depășiri și scad lin în rest: actualizarea prin scor a modelului GAS
- ▣ Parametrii fixați în 1999 urmăresc încă anii 2008, 2020 și 2025: dinamica se generalizează, nivelul nu cere reestimare
- ▣ Dacă aceasta este suficient este o întrebare de testare (secțiunile 5–6), nu una vizuală

Recapitulare: măsurile de risc ca funcționale

- ▣ VaR este o cuantilă, ES o integrală de cuantile; ambele sînt funcționale ale distribuției predictive
- ▣ Trei căi: poziție—scală, dinamica directă a cuantilei, modele semiparametrice comune
- ▣ Convenția: VaR 1%, ES 2,5%, α este rata de depășire țintă

Consistență, elicitabilitate, identificare (1/2)

- O funcție de scor $S(x, y)$ atribuie o pierdere prognozei x când se observă y ; ea este **consistentă** pentru T pe o clasă $\mathcal{F}$ dacă [Gneiting \(2011\)](#)

$$\mathbb{E}_F S(T(F), Y) \leq \mathbb{E}_F S(x, Y) \quad \text{pentru orice } x \text{ și } F \in \mathcal{F}$$

- ▶ $\mathbb{E}_F$: media când $Y \sim F$; valoarea adevărată a funcționalei are cea mai mică pierdere așteptată
- ▶ **strict** consistentă: egalitatea impune $x = T(F)$; T este **elicitabilă** dacă există o funcție S strict consistentă ([Capitolul 1](#))

Consistență, elicitabilitate, identificare (2/2)

- ▣ **Funcție de identificare:** o funcție $V(x, y)$ a cărei medie este zero exact în valoarea adevărată

$$\mathbb{E}_F V(x, Y) = 0 \iff x = T(F)$$

► cuantila: $V(x, y) = 1\{y \leq x\} - \alpha$, cu $1\{\cdot\}$ indicatorul (1 dacă este adevărat, 0 altfel); media: $V(x, y) = x - y$

- ▣ Principiul lui Osband: panta scorului așteptat este un multiplu pozitiv al funcției de identificare așteptate [Fissler și Ziegel \(2016\)](#)

$$\partial_x \mathbb{E}_F S(x, Y) = h(x) \mathbb{E}_F V(x, Y), \quad h > 0$$

► scorurile sînt funcții de identificare integrate

- ▣ Funcțiile de identificare dau **backtesting** (este prognoza calibrată?); funcțiile de scor dau **comparații** (care prognoză este mai bună?) [Nolde și Ziegel \(2017\)](#)

Cuantilele: toate scorurile consistente

- ▣ **Teoremă Gneiting (2011):** în condiții slabe, S este consistentă pentru q_α dacă și numai dacă este liniară pe porțiuni generalizată (GPL)



$$S(x, y) = (1\{y \leq x\} - \alpha)(G(x) - G(y)), \quad G \text{ nedescrescătoare}$$

- ▶ $G(x) = x$: pierderea pinball; G strict crescătoare dă consistența strictă; $G(x) = \ln x$ pentru variabile pozitive dă un scor independent de scală (omogen de grad zero)
- ▶ motivul: $\partial_x \mathbb{E}_F S(x, Y) = G'(x)(F(x) - \alpha)$, negativă sub q_α , pozitivă deasupra (▶ Anexă)
- ▣ Funcții G diferite dau aceeași prognoză optimă, dar pot ordona diferit două prognoze greșite: alegerea lui G este o decizie de modelare
- ▣ Expectilele (pierdere pătratică asimetrică) sînt singurele măsuri de risc coerente și elicitable [Ziegel \(2016\)](#); [Taylor \(2008\)](#) le folosește pentru VaR și ES

ES nu este elictabil

- **Condiție necesară Gneiting (2011):** dacă T este elictabilă, mulțimile ei de nivel sînt convexe
 - ▶ mulțimea de nivel: $\{F : T(F) = t\}$, toate distribuțiile cu aceeași valoare t a funcționalei; convexă: închisă la amestecuri $\lambda F_0 + (1 - \lambda)F_1$, $\lambda \in [0, 1]$
 - ▶ demonstrație: dacă $\mathbb{E}_{F_0} S(t, Y) \leq \mathbb{E}_{F_0} S(x, Y)$ și la fel pentru F_1 , inegalitatea rămîne pentru amestec, deoarece media este liniară în F
- Cuantilele trec testul: dacă $F_0(t) = F_1(t) = \alpha$, orice amestec are $F_\lambda(t) = \alpha$
- ES nu trece: amestecul schimbă cuantila, deci schimbă partea din fiecare componentă care intră în media cozii Weber (2006)
 - ▶ consecință: nicio funcție de pierdere nu poate ordona prognoze ES singure; pierderile medii ale prognozelor ES nu au sens luate separat
- Varianța nu trece din același motiv; perechile (medie, al doilea moment) și (VaR, ES) sînt elictabile (Fissler și Ziegel (2016), „elicitabilitate de ordin superior”)

Mulțimile de nivel la amestecare



- Stînga: $N(0, 1)$ și o $t(3)$ rescalată la aceeași cuantilă de 2,5%; dreapta: $N(0, 1)$ și o $t(3)$ rescalată la același ES 2,5%;
curbele: funcționala amestecului

Interpretarea mulțimilor de nivel

- ▣ Cuantila oricărui amestec rămîne $-1,96$: mulțimea de nivel a lui $q_{0,025}$ este convexă
- ▣ Ambele componente au media cozii $-2,338$; amestecul se îndepărtează cu pînă la $0,055$ (la ponderea $0,38$): mulțimea de nivel a ES nu este convexă
- ▣ Diferența este mică numeric, dar decisivă logic: un singur contraexemplu exclude orice pierdere strict consistentă pentru ES singur
- ▣ Soluția este prognoza cuantilei împreună cu ES: perechea are mulțimi de nivel convexe

Elicitabilitatea comună: clasa Fissler–Ziegel (1/2)

- ▣ **Teoremă Fissler și Ziegel (2016)**, în forma din Patton, Ziegel și Chen (2019), ec. (4): pentru $e \leq v$, pierderea

$$S(v, e, y) = (1\{y \leq v\} - \alpha)(G_1(v) - G_1(y)) + G_2(e)\left(v - e + \frac{1}{\alpha}1\{y \leq v\}(y - v)\right) - \mathcal{G}_2(e)$$

- ▶ este consistentă pentru $(q_\alpha, -\text{ES}_\alpha)$ dacă G_1 este nedescrescătoare, iar $G_2 = \mathcal{G}_2'$ este pozitivă și crescătoare; strict consistentă în condiții slabe
- ▣ Interpretarea celor două părți
 - ▶ primul termen: un scor GPL pentru cuantila v (slide-urile anterioare); G_1 : orice funcție nedescrescătoare
 - ▶ partea a doua: un scor de tip Bregman pentru e , evaluat față de media cozii implicată de v ; $\mathcal{G}_2$: o primitivă a lui G_2

Elicitabilitatea comună: clasa Fissler–Ziegel (2/2)

- ▣ Funcția de identificare a perechii: o componentă pentru cuantilă și una pentru media cozii

$$V_1 = 1\{y \leq v\} - \alpha, \quad V_2 = e - v + \frac{1}{\alpha} 1\{y \leq v\}(v - y)$$

- ▶ $\mathbb{E}V_1 = 0$: v este cuantila de nivel α ; $\mathbb{E}V_2 = 0$ la cuantila corectă este formula Acerbi–Tasche
- ▶ ES este media cozii doar împreună cu cuantila corectă
- ▣ Consecință [Fissler, Ziegel și Gneiting \(2016\)](#): ES poate fi **comparat** prin pereche; backtesting-ul clasic al ES cere în continuare mai mult decât ES (secțiunea 5)



FZ0: membrul omogen de grad zero

- Patton, Ziegel și Chen (2019), Propoziția 1: cu $v, e < 0$, **diferențele** de pierdere sînt invariante la rescalarea lui Y dacă și numai dacă $G_1 = 0$ și $G_2(e) = -1/e$

$$L_{FZ0}(y, v, e; \alpha) = -\frac{1}{\alpha e} 1\{y \leq v\}(v - y) + \frac{v}{e} + \ln(-e) - 1$$

- ▶ primul termen: pozitiv doar în zilele cu depășire ($y \leq v$), proporțional cu mărimea depășirii; $v/e \in (0, 1]$; $\ln(-e)$ penalizează un ES exagerat
- ▶ partea de VaR seamănă cu pierderea pinball; partea de ES seamănă cu QLIKE (Capitolul 8)
- De ce contează omogenitatea de grad zero pentru serii de timp
 - ▶ cu un scor neomogen, zilele volatile domină pierderea medie și testul DM (diferențe de pierdere heteroscedastice)
 - ▶ FZ0 ordonează la fel prognozele în % și în puncte de bază; valoarea ei poate fi negativă (EUR/RON)
- Contururile de pierdere așteptată constantă sînt convexe în condiții slabe, ceea ce ajută minimizarea numerică Patton, Ziegel și Chen (2019)

Pierderile așteptate în jurul valorii corecte



- Distribuția Student $t(5)$ cu varianță unitară, $\alpha = 0,025$, mediile prin simulare (4×10^5 extrageri): stînga, pierderea pinball așteptată; dreapta, contururile pierderii FZ0 așteptate

Interpretarea pierderilor așteptate

- ▣ Curba pinball este minimă la $-1,98$, cuantila corectă fiind $-1,99$: consistența în acțiune
- ▣ Suprafața FZ0 este minimă în $(-1,99; -2,73)$, cu minimul $1,004$; contururile sînt convexe și alungite
- ▣ Ambele suprafețe sînt plate lîngă optim: diferențe mari între prognoze costă puțin în pierdere așteptată, deci testele cer multe zile din coadă
- ▣ Prognozele cu $e > v$ sînt inadmisibile: estimarea trebuie să impună ordinea


Diagramele Murphy: ordonarea pentru toate scorurile consistente

- ▣ Ehm et al. (2016): orice scor GPL pentru cuantile este un amestec de **scoruri elementare**

$$S_{\theta}(x, y) = (1\{y < x\} - \alpha)(1\{\theta < x\} - 1\{\theta < y\}), \quad S(x, y) = \int S_{\theta}(x, y) dH(\theta)$$

- ▶ θ : un prag; S_{θ} : pierderea unei decizii binare „este randamentul sub θ ?”; H : o pondere nedescrescătoare pe praguri, care corespunde lui G
- ▣ **Diagrama Murphy**: media $\bar{S}_{\theta}$ a fiecărei prognoze, reprezentată în funcție de θ
 - ▶ prognoza A domină B pentru orice scor consistent dacă și numai dacă curba ei este dedesubt pentru orice θ
 - ▶ curbe care se intersectează: ordonarea depinde de G , adică de pragurile care contează pentru utilizator
- ▣ O verificare a ordonării pinball care costă o singură linie de cod

O diagramă Murphy pentru VaR 2,5%



- S&P 500, în afara eșantionului 2000–2016 (schema PZC); scorurile elementare medii ale celor trei prognoze VaR 2,5% în funcție de pragul θ

Interpretarea diagramei Murphy

- ▣ GARCH-EDF este sub RW-250 la 91% din praguri: prognoza dinamică domină aproape uniform
- ▣ GAS-1F și GARCH-EDF se intersectează: GAS-1F este mai bun doar la 38% din praguri; pinball mediu 7,66 și 7,45 ($\times 10^{-2}$)
- ▣ Cele două modele bune diferă la pragurile adânci (sub -4%), unde datele sînt puține
- ▣ O afirmație de tipul „modelul A este mai bun” trebuie să precizeze pentru ce scoruri; diagrama răspunde

Recapitulare: elicitabilitate

- ▣ Scorurile compară, funcțiile de identificare testează; ambele provin din aceeași teorie
- ▣ Cuantilele: scoruri GPL; ES: nu singur; (VaR, ES): clasa Fissler–Ziegel
- ▣ FZ0 nu depinde de scală; diagramele Murphy verifică ordonarea pentru toate scorurile consistente

Regresia cuantilică ca M-estimare (1/2)



Roger Koenker, Oberwolfach, 2012

Foto: Ivonne Vetter, MFO (2012); CC

BY-SA 2.0 de; Wikimedia Commons

- **Koenker și Bassett (1978)**: cuantila de nivel α a lui y_t condiționat de x_t este modelată ca $x_t'\beta$ și estimată prin minimizarea pierderii pinball

$$\hat{\beta}(\alpha) = \arg \min_{\beta} \sum_t \rho_{\alpha}(y_t - x_t'\beta), \quad \rho_{\alpha}(u) = u(\alpha - 1\{u < 0\})$$

- ▶ x_t : vectorul regresorilor; ρ_{α} : funcția pinball, cu panta α pentru reziduuri pozitive și $\alpha - 1$ pentru reziduuri negative; problema este una de programare liniară
- ▶ condiția de ordinul întâi: $\sum_t x_t(1\{y_t \leq x_t'\hat{\beta}\} - \alpha) \approx 0$, funcția de identificare

Regresia cuantilică ca M-estimare (2/2)

- ▣ Distribuția asimptotică [Koenker \(2005\)](#): un sandwich în care apare densitatea în cuantilă

$$\sqrt{T}(\hat{\beta} - \beta) \rightarrow N(0, \alpha(1 - \alpha)D^{-1}\Omega D^{-1}), \quad \Omega = \mathbb{E}[x_t x_t'], \quad D = \mathbb{E}[f_t(q_t)x_t x_t']$$

- ▶ $f_t(q_t)$: densitatea condiționată a lui y_t în cuantila adevărată q_t ; inversul ei se numește „sparsity”
- ▶ puține observații în jurul cuantilei (f_t mic) înseamnă un $\hat{\beta}$ imprecis; f_t se estimează cu un kernel și o lățime de bandă
- ▣ Serii de timp: autoregresia cuantilică [Koenker și Xiao \(2006\)](#) permite coeficienților AR să varieze între cuantile; CAViaR face cuantila însăși autoregresivă

CAViaR: cele patru specificații



Robert Engle, 2022

Foto: Jon Demske (2022); CC BY-SA

4.0; Wikimedia Commons

- **Engle și Manganelli (2004)**, scrise pentru $\text{VaR}_t = -q_t(\alpha) > 0$; y_{t-1} : randamentul de ieri; β_j : parametri:
- **SAV** (valoare absolută simetrică): $\text{VaR}_t = \beta_1 + \beta_2 \text{VaR}_{t-1} + \beta_3 |y_{t-1}|$
 - β_2 : persistența cozii; β_3 : reacția la mărimea randamentului de ieri
- **AS** (pantă asimetrică): $\text{VaR}_t = \beta_1 + \beta_2 \text{VaR}_{t-1} + \beta_3 (y_{t-1})^+ + \beta_4 (y_{t-1})^-$
 - $(y)^+ = \max(y, 0)$, $(y)^- = -\min(y, 0)$: câștigurile și pierderile întră separat; $\beta_4 > \beta_3$ înseamnă efect de levier
- **IG** (GARCH indirect): $\text{VaR}_t = (\beta_1 + \beta_2 \text{VaR}_{t-1}^2 + \beta_3 y_{t-1}^2)^{1/2}$, un GARCH(1,1) cu inovații i.i.d.
- **Adaptiv**: $\text{VaR}_t = \text{VaR}_{t-1} + \beta_1 ([1 + e^{G(y_{t-1} + \text{VaR}_{t-1})}]^{-1} - \alpha)$
 - paranteza este un indicator neted al depășirii ($G = 10$): VaR crește după o depășire și scade lent în rest; niciuna dintre cele patru specificații nu presupune o distribuție

Estimare și inferență (1/2): criteriul

- Criteriul de regresie cuantilică: pierderea pinball medie a traiectoriei cuantilei implicate

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{T} \sum_t \rho_{\alpha}(y_t + \text{VaR}_t(\beta))$$

- ▶ $\text{VaR}_t(\beta)$: traiectoria generată de recursie cu parametrii β ; criteriul este nediferențiable și neconvex în β
- Procedura EM (secțiunea empirică)
 - ▶ VaR_1 : cuantila empirică din primele 300 de zile; 10^4 vectori de parametri aleatori, cei mai buni 10 rafinați alternând pași simplex și cvasi-Newton

Estimare și inferență (2/2): covarianța

- Consistență și normalitate asimptotică, cu o covarianță de tip sandwich

$$\sqrt{T}(\hat{\beta} - \beta) \rightarrow N(0, \alpha(1 - \alpha)D^{-1}AD^{-1}), \quad A = \mathbb{E}[\nabla q_t \nabla q_t'], \quad D = \mathbb{E}[f_t(q_t) \nabla q_t \nabla q_t']$$

- $\nabla q_t = \partial q_t(\beta) / \partial \beta$: gradientul traiectoriei cuantilei, care urmează propria recursie (sau derivarea numerică a traiectoriei)
- $f_t(q_t)$: densitatea condiționată a lui y_t în cuantilă, ca în regresia cuantică

- Estimatorul lui D : se numără reziduurile aflate la cel mult $\hat{c}$ de zero

$$\hat{D} = \frac{1}{2T\hat{c}} \sum_t 1\{|y_t - \hat{q}_t| < \hat{c}\} \nabla \hat{q}_t \nabla \hat{q}_t'$$

- $\hat{c}$: lățimea de bandă, din regula Hall–Sheather pe scala reziduurilor [Koenker \(2005\)](#); modelul dinamic este un M-estimator recursiv

Testul dinamic pe cuantile (DQ)

- Sub specificarea corectă, șirul depășirilor este o diferență de martingal

$$\text{Hit}_t = 1\{y_t < q_t\} - \alpha, \quad \mathbb{E}[\text{Hit}_t \mid \mathcal{F}_{t-1}] = 0$$

- ▶ regresăm Hit_t pe $X_t = (1, \text{Hit}_{t-1}, \dots, \text{Hit}_{t-4}, q_t)$, toate din $\mathcal{F}_{t-1}$ [Engle și Manganelli \(2004\)](#)

- Statistica în afara eșantionului: un test Wald că toți coeficienții regresiei sînt zero

$$\text{DQ} = \frac{\text{Hit}'X(X'X)^{-1}X'\text{Hit}}{\alpha(1-\alpha)} \rightarrow \chi_6^2$$


- ▶ Hit: vectorul depășirilor; X: matricea cu rîndurile X_t ; 6 = numărul regresorilor; un DQ mare respinge calibrarea
- ▶ în eșantion, β estimat face depășirile ortogonale pe gradienti: covarianța cere corecția derivată de EM

- Testele Kupiec (doar constanta) și Christoffersen (primul lag al depășirilor) sînt cazuri particulare; regresorul VaR adaugă putere împotriva erorilor care depind de nivel
- Cu $\alpha = 1\%$ și cîteva sute de zile, aproximarea χ^2 este slabă (secțiunea 5): raportați p-value-uri simulate sau exacte cînd se poate

Studiu de caz: Engle și Manganelli (2004) pe datele de azi

- Schema din secțiunea empirică a lucrării EM: 3 392 de randamente zilnice, primele 2 892 pentru estimare, ultimele 500 în afara eșantionului; VaR 1% și 5%
 - ▶ EM au folosit 1986–1999 (GM, IBM, S&P 500); noi folosim S&P 500 de la 25 martie 2013 la 18 septembrie 2026, în afara eșantionului din 20 septembrie 2024
- Aceleași specificații, valori de pornire și căutare; șocul tarifelor din aprilie 2025 cade în perioada din afara eșantionului
- Întrebări: ce specificație descrie coada de 1%, sînt prognozele calibrate în afara eșantionului și este răspunsul la veștile proaste asimetric?

VaR 1% CAViaR pentru S&P 500



- Ultimul an al eșantionului de estimare și cele 500 de zile din afara lui; liniile: cuantila de 1% a randamentelor $q_t = -\text{VaR}_t$ pentru cele patru specificații

Estimații, erori standard și teste DQ


Modelul	β_1	β_2	β_3	β_4	$RQ \times 10^2$	depășiri în eșantion (%)	depășiri în afara eșantionului (%)	DQ în afara eșantionului (p)
SAV	0,359 (0,217)	0,702 (0,118)	0,604 (0,243)	–	3,305	1,00	1,4	14,4 (0,025)
AS	0,264 (0,137)	0,805 (0,080)	0,044 (0,185)	0,616 (0,149)	3,220	1,00	1,2	15,8 (0,015)
IG	0,942 (0,467)	0,674 (0,105)	1,429 (0,702)	–	3,267	1,00	1,2	2,3 (0,891)
ADAPT	1,190 (0,069)	–	–	–	4,044	0,90	0,8	27,5 (<0,001)

- Erorile standard din covarianța asimptotică EM; RQ: criteriul minimizat în eșantion; DQ în afara eșantionului cu patru laguri ale depășirilor și VaR, χ^2_6 ; 500 de zile dau 5 depășiri așteptate
- Pierderea pinball medie în afara eșantionului ($\times 10^2$): SAV 3,87, AS 3,66, IG 3,66, adaptiv 4,42

Interpretarea estimațiilor CAViaR

- ▣ Toate cele trei modele autoregresive reproduc rata din eșantion (circa 1%) prin construcție: pierderea cuantilică calibrează nivelul
- ▣ AS: un randament negativ mută VaR de circa 14 ori mai mult decât unul pozitiv de aceeași mărime; β_3 nu se deosebește de zero
- ▣ În afara eșantionului IG trece testul DQ ($p = 0,891$); SAV ($p = 0,025$) și AS ($p = 0,015$) sînt respinse la 5%, modelul adaptiv clar ($p < 0,001$)
- ▣ Cinci depășiri așteptate în 500 de zile: respingerile vin din depășirile grupate din aprilie 2025, nu din numărul lor; o astfel de evidență este fragilă
- ▣ Modelul adaptiv reacționează doar la depășiri, ca un termostat lent: după grupul de depășiri din aprilie 2025 rămîne prea sus timp de luni de zile

Curbele de impact al știrilor



□ VaR_t în funcție de y_{t-1} , cu VaR_{t-1} la mediana din eșantion (2,16% pentru AS); parametrii estimați din tabel

Interpretarea curbelor de impact

- ▣ SAV și IG sînt simetrice prin construcție: o creștere de 5% ridică VaR 1% la fel de mult ca o cădere de 5%
- ▣ AS este aproape plat pentru câștiguri și abrupt pentru pierderi: efectul de levier estimat direct în coadă
- ▣ Curba adaptivă este o treaptă: contează doar semnul depășirii, nu mărimea ei
- ▣ Forma curbei este o restricție testabilă: AS include SAV ($\beta_3 = \beta_4$), un test Wald cu covarianța asimptotică EM

Recapitulare: CAViaR

- ▣ Regresia cuantilică este M-estimare cu pierderea pinball; covarianța ei cere densitatea în cuantilă
- ▣ CAViaR face cuantila autoregresivă; estimarea cere multe puncte de pornire
- ▣ DQ testează depășirile față de informație; modelul asimetric descrie coada acțiunilor

M-estimarea cu pierderea FZ0

- Un model dinamic pentru pereche, estimat prin minimizarea pierderii FZ0 medii [Patton, Ziegel și Chen \(2019\)](#)

$$(v_t, e_t) = (v, e)(\mathcal{F}_{t-1}; \theta), \quad \hat{\theta} = \arg \min_{\theta} \frac{1}{T} \sum_t L_{FZ0}(y_t, v_t(\theta), e_t(\theta); \alpha)$$

- ▶ θ : parametrii celor două recursii; consistența rezultă din consistența strictă a FZ0 și din identificarea lui θ
- ▶ normalitatea asimptotică este ca la CAViaR, cu o covarianță de tip sandwich
- De ce nu verosimilitate maximă?
 - ▶ Verosimilitatea maximă cere întreaga distribuție; un corp sau o coadă dreaptă greșite distorsionează estimațiile cozii stîngi
 - ▶ Estimarea FZ țintește exact cele două funcționale de coadă: mai puțin eficientă dacă modelul este corect, robustă dacă nu este (PZC, Tabelele 3–4)
- Înrudite: cvasi-verosimilitatea Laplace asimetrică [Taylor \(2019\)](#); regresiiile pentru ES [Dimitriadis și Bayer \(2019\)](#); dinamica determinată de scor (GAS) [Creal, Koopman și Lucas \(2013\)](#)

Modelul GAS cu doi factori

- ▣ Patton, Ziegel și Chen (2019), ec. (9)–(16): perechea urmează un VAR(1) determinat de scorul scalat al FZ0 (generalised autoregressive score, GAS)

$$\begin{pmatrix} v_{t+1} \\ e_{t+1} \end{pmatrix} = w + B \begin{pmatrix} v_t \\ e_t \end{pmatrix} + A \lambda_t$$

- ▶ w : vectorul termenilor liberi; B : matrice diagonală 2×2 de persistență; A : matricea 2×2 a reacțiilor la variabilele de impuls $\lambda_t = (\lambda_{v,t}, \lambda_{e,t})'$
- ▣ Variabilele de impuls, din scorul FZ0

$$\lambda_{v,t} = -v_t(1\{y_t \leq v_t\} - \alpha), \quad \lambda_{e,t} = \frac{1}{\alpha} 1\{y_t \leq v_t\} y_t - e_t$$

- ▶ ambele sînt funcții de identificare: medie condiționată nulă sub specificarea corectă
- ▶ hessiana se scalează cu $f_t(v_t) \approx k_\alpha/v_t$, k_α o constantă (exact pentru randamente de tip poziție–scală), deci nu se estimează nicio densitate
- ▶ opt parametri; în zilele fără depășire $\lambda_{e,t} = -e_t$, iar ambele măsuri de risc scad determinist spre mediile lor

Modelele cu un factor, GARCH-FZ și Hybrid

- ▣ **GAS-1F**, ec. (20): o singură log-scală latentă κ_t multiplică ambele măsuri de risc

$$v_t = a e^{\kappa_t}, \quad e_t = b e^{\kappa_t}, \quad \kappa_t = \beta \kappa_{t-1} + \gamma \frac{-1}{e_{t-1}} \left(\frac{1}{\alpha} 1_{\{y_{t-1} \leq v_{t-1}\}} y_{t-1} - e_{t-1} \right)$$

- ▶ $b < a < 0$: VaR și ES pentru $\kappa_t = 0$; β : persistența log-scalei; γ : reacția la variabila de impuls a ES
- ▶ termenul liber ω nu este identificat împreună cu (a, b) și se fixează la 0

- ▣ **GARCH-FZ**, ec. (25)–(26): $\kappa_t^2 = 1 + \beta \kappa_{t-1}^2 + \gamma y_{t-1}^2$, $(v_t, e_t) = (a, b) \kappa_t$: un GARCH a cărui scală κ_t este ajustată pentru coadă
- ▣ **Hybrid**, ec. (27): GAS-1F plus $\delta \ln |y_{t-1}|$ în recursia lui κ_t
 - ▶ reacționează în fiecare zi prin δ , mai puternic în zilele cu depășiri
- ▣ În toate trei raportul $e_t/v_t = b/a$ este constant: forma cozii este fixă, doar scala ei se mișcă

Estimarea modelelor recursive nenetede

- ▣ Funcția obiectiv FZ0 este discontinuă în θ (prin $1\{y_t \leq v_t(\theta)\}$), iar recursia propagă fiecare salt
- ▣ Anexa C a lucrării [Patton, Ziegel și Chen \(2019\)](#): indicatorul se înlocuiește cu o aproximare logistică în pierdere și în variabila de impuls


$$\Gamma(y, v; \tau) = \frac{1}{1 + e^{\tau(y-v)}}$$

- ▶ $\tau > 0$: parametrul de netezire; când $\tau \rightarrow \infty$, $\Gamma \rightarrow 1\{y \leq v\}$
- ▶ cvasi-Newton cu $\tau = 5$, apoi $\tau = 20$, apoi pierderea exactă cu metoda simplex, fiecare pas pornind din cel anterior
- ▣ Valorile noastre de pornire: parametri dinamici aleatori, cu (a, b) potriviți la VaR și ES din eșantion; cei mai buni patru sînt rafinați
- ▣ Restricții impuse prin penalizare: $e_t \leq v_t$, $e_t < 0$, staționaritatea recursiei

Studiu de caz: Patton, Ziegel și Chen (2019), secțiunea 5

- ▣ Date: randamentele zilnice ale S&P 500, ianuarie 1990 – decembrie 2016; estimare pe primii zece ani, parametrii păstrați ficși pentru 2000–2016 ($T = 4\,275$)
- ▣ Zece modele, ca în lucrare
 - ▶ ferestre mobile de 125, 250 și 500 de zile (RW); ARMA (ordinul după BIC) – GARCH(1,1) cu inovații din distribuția Normală, t asimetrică sau empirice
 - ▶ GAS-2F, GAS-1F, GARCH-FZ și Hybrid estimate prin minimizarea FZ0
- ▣ Rezultate replicate: pierderile FZ0 medii în afara eșantionului (Tabelul 8, $\alpha = 5\%$; Tabelul S5, $\alpha = 2,5\%$), statisticile DM (Tabelul 9), testele de adecvare (ec. 41)
- ▣ Datele noastre: închiderile EODHD ale aceluiași indice; diferențe de câteva miimi sînt de așteptat din revizuirile datelor și din traseele optimizatorului

Trei moduri de a prognoza coada




- VaR și ES 5% pentru S&P 500 în 2015–2016 (PZC, Figura 5 pe datele noastre): RW-125, GARCH-EDF și GAS-1F

Interpretarea celor trei prognoze

- ▣ Fereastra mobilă se mișcă în trepte, pe măsură ce zilele extreme intră și ies din fereastră, la luni după șoc
- ▣ GARCH-EDF se mișcă în fiecare zi cu pătratele randamentelor; GAS-1F se mișcă doar în zilele cu depășiri și apoi scade lin
- ▣ August 2015: GARCH reacționează cel mai mult, GAS-1F sare mai puțin, dar rămîne; în 2008, ES 5% GAS-1F a ajuns la $-9,9\%$
- ▣ Ce reacție este corectă decide pierderea FZ0, nu aspectul traiectoriei

Replicare: pierderea FZ0 medie în afara eşantionului



- Bare: datele și codul nostru, aceeași schemă; romburi: valorile tipărite în PZC, Tabelul 8 ($\alpha = 5\%$) și Tabelul S5 ($\alpha = 2,5\%$)

Replicarea în cifre


Modelul	$\alpha = 5\%$		$\alpha = 2,5\%$		GoF $p, \alpha = 5\%$	
	noi	PZC	noi	PZC	VaR	ES
RW-125	0,916	0,914	1,120	1,119	0,004	0,005
RW-250	0,959	0,959	1,165	1,164	<0,001	0,011
RW-500	1,025	1,023	1,247	1,245	<0,001	<0,001
GCH-N	0,876	0,876	1,089	1,089	0,018	<0,001
GCH-Skt	0,865	0,866	1,044	1,043	0,001	0,001
GCH-EDF	0,862	0,862	1,028	1,028	0,001	0,007
FZ-2F	0,862	0,856	1,044	1,041	<0,001	0,003
FZ-1F	0,853	0,853	1,038	1,032	0,001	0,037
GCH-FZ	0,867	0,862	1,040	1,020	0,005	0,016
Hybrid	0,869	0,869	1,051	1,034	<0,001	<0,001

- Cea mai mare diferență: 0,006 la 5%, 0,020 la 2,5%; BIC alege ARMA(0, 0) pentru medie (PZC: ARMA(1,1)); GARCH $\alpha = 0,052$, $\beta = 0,942$

Interpretarea replicării

- ▣ Ordonarea din lucrare se reproduce: GAS-1F cel mai mic la 5% (0,853, lucrarea 0,853), RW-500 cel mai slab, GARCH-N în urma celorlalte modele GARCH
- ▣ Estimațiile GAS-1F: $\beta = 0,995$, $\gamma = -0,0069$ (PZC, Tabelul 7: 0,990 și $-0,010$); Hybrid $\delta = 0,017$ (0,018)
- ▣ Nereprodus: testele de adecvare; PZC găsesc că GAS-1F trece (p 0,242 și 0,313), pe datele noastre este respins (0,001; 0,037)
- ▣ Pierderile medii sînt robuste la mici diferențe ale datelor; testele pe cîteva zile din coadă nu sînt, iar alegerea covarianței regresiei contează

Teste Diebold–Mariano pe pierderile FZ0



- S&P 500, 2000–2016, $\alpha = 5\%$: statistica DM a rîndului minus coloana, varianță Newey–West; roșu: modelul de pe rînd este mai slab (PZC, Tabelul 9)

Interpretarea matricei DM

- ▣ Coloana GAS-1F, noi față de PZC: RW-125 4,02 (3,91), RW-500 5,87 (5,48), GARCH-N 2,22 (1,99), GARCH-EDF 1,19 (1,20)
- ▣ Modelele cele mai slabe se separă ușor; primele cîteva nu (GARCH-Skt, GARCH-EDF, FZ-2F față de GAS-1F sub 1,96)
- ▣ O diferență: GARCH-FZ față de GAS-1F, 2,02 aici și 1,27 în lucrare; normalizarea scalei la GARCH-FZ face estimațiile fragile
- ▣ Nouăzeci de teste pe perechi cer un răspuns la testarea multiplă: MCS (secțiunea 6)


Regresia comună (VaR, ES)

- Dimitriadis și Bayer (2019): ambele funcționale sînt liniare în covariabile

$$q_{\alpha}(Y_t | x_t) = x_t' \beta, \quad -ES_{\alpha}(Y_t | x_t) = x_t' \gamma$$

- ▶ x_t : covariabile cunoscute la $t - 1$; β, γ : efectele asupra cuantilei și asupra mediei cozii; estimate împreună prin minimizarea unei pierderi Fissler–Ziegel
- ▶ M-estimator: consistent și asimptotic normal pentru orice membru al clasei; alegerea lui (G_1, G_2) afectează doar eficiența
- Utilizări
 - ▶ ce variabile mișcă coada și cît: analogul pentru ES al regresiei cuantilice
 - ▶ backtesting pentru ES: regresăm randamentele realizate pe prognoza ES și testăm termen liber 0, pantă 1 Bayer și Dimitriadis (2022) (MFM, Capitolul 8)
- Aplicație: randamentele S&P 500 2000–2026 pe VIX-ul închiderii anterioare, $\alpha = 2,5\%$, pierderea FZ0, erori standard prin bootstrap pe blocuri mobile (blocuri de 20 de zile)

Coadă S&P 500 în funcție de VIX



- Randamentele zilnice în funcție de VIX-ul închiderii anterioare, $T = 6714$; liniile: cuantila de 2,5% și media cozii estimate prin regresia comună

Interpretarea regresiei comune

- ▣ Cuantila: $0,499 - 0,135 \text{ VIX}$ (erori standard 0,150; 0,009); media cozii: $0,524 - 0,170 \text{ VIX}$ (erori standard 0,245; 0,015)
- ▣ Un punct de VIX coboară cuantila de 2,5% cu 0,14 și media cozii cu 0,17 puncte procentuale: coada se lărgțește de 1,25 ori mai repede în ES
- ▣ Partea de cuantilă este apropiată de regresia cuantilică (0,560, $-0,139$); rata de depășire în eșantion 2,50%; testele PZC nu resping ($p = 0,978$; 0,744)
- ▣ VIX este o prognoză de piață a volatilității: regresia arată că piața opțiunilor evaluează coada stângă aproape liniar

Recapitulare: modelele semiparametrice (VaR, ES)

- ▣ Minimizarea FZ0 estimează perechea din coadă fără o distribuție
- ▣ Variabilele de impuls GAS sînt funcții de identificare: modelul se corectează doar cînd coada aduce informație nouă (în zilele cu depășiri)
- ▣ Ordonarea PZC se replică; rezultatele testelor de adecvare nu; regresia comună leagă coada de covariabile

Recapitulare: numărarea depășirilor

- Depășirile $I_t = 1\{y_t < v_t\}$; un VaR corect face ca I_t să fie i.i.d. Bernoulli(α) (MFM, Capitolul 8)
 - ▶ Kupiec (1995): acoperirea necondiționată, statistica raportului de verosimilitate $LR \sim \chi_1^2$ (este rata depășirilor egală cu α ?)
 - ▶ Christoffersen (1998): independența depășirilor consecutive și acoperirea condiționată (ambele împreună), χ_2^2
 - ▶ Semaforul Basel Comitetul de la Basel (1996): verde pînă la 4 depășiri ale VaR 1% în 250 de zile, galben 5–9, roșu de la 10
- Ce nu vede numărarea
 - ▶ depășirile care depind de altă informație decît ultima depășire (DQ)
 - ▶ mărimea pierderilor din coadă (backtesting pentru ES); distanța dintre depășiri (teste de durată)
 - ▶ efectul parametrilor estimați asupra distribuției sub ipoteza nulă

Calibrarea condiționată

- O prognoză x_t a lui T este **calibrată condiționat** dacă funcția ei de identificare V are media condiționată zero *Nolde și Ziegel (2017)*

$$\mathbb{E}[V(x_t, Y_t) \mid \mathcal{F}_{t-1}] = 0 \Rightarrow \mathbb{E}[h_{t-1} V(x_t, Y_t)] = 0$$

- ▶ h_{t-1} : orice instrument cunoscut la $t - 1$ (constanta, laguri ale depășirilor, prognoza însăși); un test de momente (Wald, χ^2)
- PZC, ec. (40)–(41): reziduurile generalizate standardizate

$$\lambda_{v,t}^s = 1\{y_t \leq v_t\} - \alpha, \quad \lambda_{e,t}^s = \frac{1\{y_t \leq v_t\} y_t}{\alpha e_t} - 1$$

- ▶ regresăm fiecare pe (1, propriul lag de ordinul întâi, v_t sau e_t) și testăm că toți cei trei coeficienți sînt zero; folosim covarianța White (HC0)
- ▶ DQ este cazul particular pentru VaR; regresia pentru ES testează ES doar împreună cu VaR, cum prevede elicitabilitatea
- Puterea vine din instrumente: lagurile depășirilor detectează gruparea, nivelul prognozei detectează erorile de scală


Teste pe baza duratelor

- ▣ Christoffersen și Pelletier (2004): pentru un VaR corect, duratele d_i (zilele dintre două depășiri consecutive) sînt geometrice, fără memorie, cu media $1/\alpha$
 - ▶ alternativa: hazardul Weibull $\lambda(d) = a^b b d^{b-1}$, probabilitatea unei depășiri după d zile liniștite; $a > 0$: scala, $b > 0$: forma
 - ▶ $b = 1$: hazard constant (fără memorie, ca sub H_0); $b < 1$: hazard descrescător, adică depășirile se grupează
- ▣ Verosimilitatea cu cenzurare: primul și ultimul interval sînt incomplete și intră prin funcția de supraviețuire $S(d) = e^{-(ad)^b}$

$$LR = 2[\ln L(\hat{a}, \hat{b}) - \ln L(\tilde{a}, 1)] \rightarrow \chi_1^2$$

- ▶ $(\hat{a}, \hat{b})$: estimațiile nerestricționate; $\tilde{a}$: estimația sub $b = 1$; pentru eșantioane mici se recomandă p-value-uri obținute prin simulare
- ▣ Duratele surprind gruparea la orice distanță, nu doar în zile consecutive, ca testul lui Christoffersen

Cît de departe sînt depășirile una de alta?



- S&P 500, VaR 2,5%, în afara eșantionului 2000–2026; funcția de supraviețuire empirică a duratelor dintre depășiri (scară logaritmică) față de legea geometrică a unui model corect

Interpretarea duratelor

- ▣ RW-250: 40% din durate sînt de cel mult 5 zile (geometric: 12%); Weibull $b = 0,67$, $p < 0,001$: grupare puternică
- ▣ GARCH-EDF: $b = 0,92$, $p = 0,107$; GAS-1F: $b = 0,88$, $p = 0,019$: modelele dinamice elimină cea mai mare parte a grupării
- ▣ Coda lungă a RW-250 (ani calmi fără depășiri) este cealaltă față a grupării: fereastra își amintește crizele vechi
- ▣ Toate modelele au prea multe depășiri în total (tabelul din secțiunea 5): parametrii fixați în 1999 sînt prea optimiști după 2000

Backtesting pentru ES: ce cere fiecare test

Testul	Statistica	Date necesare
McNeil și Frey (2000)	media lui $(y_t - e_t)/\sigma_t$ în zilele cu depășiri, bootstrap	v_t, e_t, σ_t
Acerbi și Székely (2014) Z_2	$1 - \frac{1}{T\alpha} \sum_t \frac{y_t I_t}{e_t}$	v_t, e_t și distribuția prognozată (p-value simulat)
Du și Escanciano (2017)	depășirile cumulate $H_t = \frac{1}{\alpha}(\alpha - u_t)1\{u_t \leq \alpha\}$	PIT $u_t = F_{t t-1}(y_t)$
Kratz, Lok și McNeil (2018)	test multinomial pentru mai multe niveluri VaR	PIT sau VaR la mai multe niveluri
Patton, Ziegel și Chen (2019), Bayer și Dimitriadis (2022)	regresie pe (v_t, e_t)	v_t, e_t

- σ_t : volatilitatea prognozată; I_t : indicatorul depășirii; $u_t = F_{t|t-1}(y_t)$: transformarea integrală de probabilitate (PIT), uniformă pe $[0, 1]$ dacă distribuția prognozată este corectă
- Doar testele prin regresie nu folosesc nimic în plus față de perechea (VaR, ES): celelalte testează o distribuție, pe care ES singur nu o furnizează


Riscul de estimare în backtesting

- Testele presupun că VaR este cunoscut; în practică $\hat{v}_t = v_t(\hat{\theta}_R)$, estimat pe R zile și testat pe următoarele P zile
Escanciano și Olmo (2010)

$$\frac{1}{\sqrt{P}} \sum_t (\hat{I}_t - \alpha) = \frac{1}{\sqrt{P}} \sum_t (I_t - \alpha) + \underbrace{\sqrt{P/R} \cdot \mathbb{E}[f_t(v_t) \nabla v_t'] \sqrt{R}(\hat{\theta}_R - \theta)}_{\text{termenul de estimare}}$$

- $\hat{I}_t, I_t$: depășirile VaR estimat și ale VaR adevărat; $f_t(v_t)$: densitatea condiționată în VaR; ∇v_t : gradientul VaR în raport cu θ
- Termenul de estimare dispare doar dacă $P/R \rightarrow 0$; cu o fereastră fixă crește odată cu eșantionul de test
 - varianța Kupiec $\alpha(1 - \alpha)$ este atunci prea mică, iar testul respinge prea des un model corect
 - remedii: varianța corectată a lui Escanciano și Olmo, subeșantionarea sau bootstrap pentru întreaga procedură de estimare și testare
- Un experiment Monte Carlo arată mărimea problemei pentru ferestrele folosite efectiv de bănci

Mărimea testelor cu parametri estimați



- Date GARCH(1,1) ($\omega = 0,02$, $\alpha = 0,08$, $\beta = 0,90$, distribuția Normală), modelul corect estimat prin QML pe R zile, VaR 1% pe următoarele P zile; 500 de replicări; mărimea nominală 5%

Interpretarea experimentului Monte Carlo

- ▣ Parametri cunoscuți: Kupiec respinge 10%, 5% și 4% pentru $P = 250, 1000, 2500$: aproape de 5%, cu excepția cazului cu puține depășiri
- ▣ Estimat pe $R = 250$: 18%, 30%, 43%: un model corect este respins mai des cu cât testăm mai mult
- ▣ Cu $R = 1000$ distorsiunea scade (13% la $P = 2500$); rata de depășire între replicări are abaterea standard 0,99 pp față de 0,29 pp
- ▣ DQ respinge prea des chiar cu parametri cunoscuți (10%): depășirile rare fac aproximarea χ^2_6 slabă

Teste de calibrare pe active



- Regresiile de adecvare PZC pentru VaR și ES 2,5%, zece modele, parametri estimați pe primii zece ani (cinci pentru Bitcoin) și păstrați ficși pînă la 18 septembrie 2026

Interpretarea testelor de calibrare

- Doar 4 din 50 de perechi activ-model trec ambele regresii la 10%: pe 10–26 de ani cu parametri ficși, aproape orice model este necalibrat undeva
- Ratele de depășire S&P 500 la 2,5%: GAS-1F 3,2%, GARCH-EDF 3,0%, RW-250 3,3%: nivelul derivă după deceniul de estimare
- EUR/RON: estimate pe 2005–2015 (criză și managed float), modelele GARCH supraestimează apoi riscul (GARCH-EDF 0,6% depășiri): și necalibrarea în direcția prudentă este respinsă
- Bitcoin: istorie scurtă și coadă zgomotoasă, putere redusă; modelele simple trec (RW-500 2,5%)
- Un backtest răspunde la „este calibrat?”; dacă un model respins este preferabil altuia este o întrebare de comparație

Recapitulare: backtesting

- Backtesting-ul înseamnă teste de momente ale funcției de identificare cu instrumente alese
- Duratele surprind gruparea la orice distanță; testele ES cer mai mult decât ES, cu excepția testelor prin regresie
- Parametrii estimați cresc mărimea testelor; evaluările lungi, cu parametri ficși, resping aproape totul


De la backtesting la backtesting comparativ

- **Nolde și Ziegel (2017)**: backtesting-ul tradițional testează H_0 : „modelul băncii este calibrat”; backtesting-ul comparativ testează modelul băncii față de unul standard cu un scor consistent
 - ▶ H_0^- : modelul intern cel puțin la fel de bun ca cel standard; H_0^+ : cel mult la fel de bun; verde dacă H_0^+ se respinge, roșu dacă H_0^- se respinge, galben altfel
- Contează mulțimea de informații **Holzmann și Eulert (2014)**: o prognoză calibrată care folosește mai multă informație are un scor consistent așteptat mai mic
 - ▶ deci o ordonare prin FZ0 răsplătește și calibrarea, și informația, ceea ce un backtest nu poate face
- Instrumente din **Capitolul 1**: DM cu varianță HAC **Diebold și Mariano (1995)**, Giacomini–White pentru metode de prognoză estimate **Giacomini și White (2006)**, MCS **Hansen, Lunde și Nason (2011)**

Schema comparației

- ▣ Cele zece modele PZC, $\alpha = 2,5\%$, pierderi FZ0 în afara eșantionului: S&P 500 și DAX din 2000, BET din 2010, EUR/RON din iulie 2015, Bitcoin din 2020
- ▣ MCS de 90% cu statistica $T_{\max}$, bootstrap pe blocuri mobile (blocuri de 10 zile pe toată perioada, 5 zile într-o perioadă de criză), 1000 de replicări
- ▣ Perioadele de criză fixate înainte de a vedea pierderile
 - ▶ 2008: septembrie 2008 – martie 2009; 2020: 19 februarie – 30 iunie 2020; 2022: anul calendaristic; 2025: martie – iunie 2025
 - ▶ S&P 500 în 2020: 93 de zile, dintre care 9 depășiri GAS-1F; în 2025: 83 de zile, 5 depășiri
- ▣ O fereastră de criză conține puține zile din coadă: ne așteptăm la mulțimi MCS largi și la câștigători instabili

Pierderile în perioadele de criză



- Pierdere FZ0 medie a fiecărui model minus cea a celui mai bun model din aceeași perioadă (scară logaritmică simetrică); bare lipsesc cînd perioada nu este în afara eșantionului

Interpretarea pierderilor din perioadele de criză

- Câștigătorii pe toată perioada: S&P 500 GCH-EDF, DAX GCH-Skt, BET GCH-Skt, EUR/RON Hybrid, Bitcoin GCH-Skt
- În 2020 câștigătorul se schimbă: S&P 500 GCH-FZ, BET FZ-2F, Bitcoin FZ-2F; ferestrele mobile pierd cel mai mult în fiecare criză
- Crizele separă modelele cu un ordin de mărime mai mult decât anii calmi: o medie pe toată perioada este dominată de câteva săptămîni
- Niciun model nu câștigă fiecare criză; modelele semiparametrice sînt competitive, dar nu domină în afara eșantionului după 2016

Mulțimi de încredere ale modelelor



□ P-value-urile MCS (pierderea FZ0, $\alpha = 2,5\%$); verde: în MCS de 90%

Interpretarea mulțimilor MCS

- ▣ Toată perioada, mărimea MCS: S&P 500 6, DAX 6, BET 3, EUR/RON 8, Bitcoin 10 din 10
- ▣ Ferestrele mobile sînt eliminate pe eșantioanele lungi de acțiuni; în 2020 și 2022 aproape totul rămîne (2020: 10 pe S&P 500; 2022: 10)
- ▣ EUR/RON în 2020 este excepția: rămîn doar 4 modele, ferestrele mobile și Hybrid
- ▣ O mulțime MCS mare este un rezultat, nu un eșec: ferestrele de criză sînt prea scurte pentru a separa prognozele cozii

Recapitulare: compararea

- Backtesting-ul comparativ pune sarcina probei pe model și răsplătește informația
- Ordonările se schimbă în crize; mediile pe toată perioada ascund acest lucru
- Raportați MCS, nu câștigătorul

Limitele regulii rădăcinii pătrate a timpului (1/2)

- Regula scalează VaR pe o zi la h zile

$$\text{VaR}^{(h)} = \sqrt{h} \text{VaR}^{(1)}$$

- $\text{VaR}^{(h)}$: VaR al randamentului pe h zile, $\sum_{k=1}^h y_{t+k}$; exactă pentru randamente i.i.d. din distribuția Normală cu media zero
- pentru legi stabile i.i.d. cu indicele $\gamma \in (0, 2]$, factorul este $h^{1/\gamma}$ ($\gamma = 2$: cazul distribuției Normale)
- Cozi groase care nu sînt stabile: suma pe h zile este mai apropiată de distribuția Normală decît randamentul zilnic
 - deci $\sqrt{h}$ supraestimează cuantila la orizonturi lungi [Dánielsson și Zigrand \(2006\)](#)
- Efectul de levier (GJR) face pierderile pe mai multe zile mai asimetrice decît cele zilnice: coada stîngă a sumei este mai groasă decît coada zilnică scalată

Limitele regulii rădăcinii pătrate a timpului (2/2)

- Volatility clustering: pentru GARCH(1,1), varianța randamentului pe h zile depinde de volatilitatea de azi



$$\text{Var}_t\left(\sum_{k=1}^h y_{t+k}\right) = \sum_{k=0}^{h-1} [\bar{\sigma}^2 + (\alpha + \beta)^k (\sigma_{t+1}^2 - \bar{\sigma}^2)]$$

- ▶ $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$: varianța necondiționată; σ_{t+1}^2 : varianța prognozată pentru mâine; $\alpha + \beta$: persistența
 - ▶ în perioade calme ($\sigma_{t+1}^2 < \bar{\sigma}^2$), $\sqrt{h}$ subestimează riscul, în crize îl supraestimează: revenirea volatilității la medie
- Remedii: simularea distribuției pe h zile (FHS) sau prognoza directă a cuantilei pe h zile (regresie cuantilică pe randamentele pe h zile)

Prognozele pe mai multe zile și testarea lor

- FHS: GJR-GARCH(1,1) prin QML pe o fereastră mobilă de 2000 de zile (reestimat la fiecare 250 de zile); 2000 de traiectorii de 10 zile cu reziduuri standardizate extrase prin bootstrap [Bollerslev \(1986\)](#), [Glosten, Jagannathan și Runkle \(1993\)](#)
- Backtesting pentru VaR pe 10 zile
 - ▶ prognozele zilnice pe 10 zile se suprapun: depășirile sînt MA(9) chiar sub H_0 ; tratarea lor ca independente crește mărimea testului ([Capitolul 0](#), observații suprapuse)
 - ▶ variante: ferestre fără suprapunere (fiecare a zecea zi, puține depășiri) sau varianță HAC pentru depășirile suprapuse
- Basel folosește orizonturi de 10 zile și orizonturi ajustate pentru lichiditate la ES (MAR33): problema orizontului este una de reglementare, nu academică

VaR 1% pe 10 zile față de regula rădăcinii pătrate



- S&P 500, 2001–2026: raportul dintre VaR 1% pe 10 zile prin FHS și $\sqrt{10}$ înmulțit cu VaR 1% pe o zi al aceluiași model; dreapta: raportul în funcție de volatilitatea prognozată azi

Interpretarea raportului de orizont

- ▣ Raportul median 1,19, între 0,89 și 1,90: scalarea cu $\sqrt{10}$ subestimează de obicei VaR 1% pe 10 zile pentru S&P 500
- ▣ Zilele cu volatilitate scăzută: mediana 1,26; zilele cu volatilitate ridicată: 1,14: revenirea la medie împinge raportul spre 1 în crize
- ▣ Backtesting fără suprapunere (646 de ferestre, 6,5 depășiri așteptate): FHS 6, regula $\sqrt{10}$ 7; Kupiec p 0,85 și 0,83
- ▣ Atît de puține depășiri nu le pot separa: erori de orizont de această mărime sînt invizibile pentru un backtest fără suprapunere

Recapitulare: orizontul

- Regula rădăcinii pătrate cere randamente i.i.d. din distribuția Normală; volatility clustering, efectul de levier și cozile groase o contrazic în direcții opuse
- Simulați orizontul sau modelați-l direct; testați cu ferestre fără suprapunere sau cu varianțe HAC
- Testele pe mai multe zile au o putere foarte mică


Riscul de model al modelelor de risc

- Danielsson et al. (2016): **raportul de risc** între modele standard măsoară dezacordul la care trebuie să se aștepte un supraveghetor

$$RR_t = \frac{\max_m VaR_{m,t}}{\min_m VaR_{m,t}} \geq 1$$

- ▶ $VaR_{m,t}$: prognoza modelului m pentru ziua t ; $RR_t = 1$: toate modelele sînt de acord; 2: modelul cel mai prudent cere de două ori capitalul celui mai puțin prudent
- ▶ ei găsesc raportul cel mai mare tocmai în crize, cînd cifrele de risc contează cel mai mult
- Boucher et al. (2014): **risk models-at-risk**: cuantificăm riscul de model al unei prognoze VaR și ajustăm prognoza pentru erorile de estimare și de specificare
- Kellner și Rösch (2016): ES are mai mult risc de model decît VaR la niveluri comparabile: extrapolează mai departe în coadă
- Cele șase modele ale noastre, ferestre mobile de 1000 de zile: simulare istorică, distribuția Normală cu volatilitatea ferestrei, EWMA ($\lambda = 0,94$), GARCH-N, GARCH-t, FHS

Cît de mult diferă modelele standard?



- Raportul de risc al celor șase prognoze VaR 1%, mediana mobilă pe 21 de zile, S&P 500 și BET, 2002–2026 (BET din 2004); zonele colorate: perioadele de criză


Interpretarea raportului de risc

- Raportul de risc median 1,9 (S&P 500) și 1,8 (BET); percentila 90 2,7 și 3,0; maximul 10,5 la 17 martie 2020
- Primăvara 2020: mediana 2,9 (S&P 500), 2,5 (BET): simularea istorică lentă și EWMA rapid diverg cel mai mult după un salt
- HS este cel mai prudent model în 73% din zilele S&P 500, EWMA cel mai puțin prudent în 53%
- Ratele de depășire VaR 1% (S&P 500): HS 1,4%, GARCH-N 2,2%, GARCH-t 1,4%, FHS 1,3%: dezacordul nu este zgomot, modelele cu distribuția Normală greșesc

Riscul de estimare în prognozele cozii

- ▣ Gao și Song (2008): pentru VaR și ES din GARCH, $\sqrt{T}(\widehat{ES}_t - ES_t)$ este asimptotic normal; varianța are o parte din volatilitate și una din forma cozii
- ▣ Bootstrap Christoffersen și Gonçalves (2005): reestimăm modelul pe traiectorii simulate și recalculăm prognoza **condiționat de istoria observată**
 - ▶ algoritm: estimăm GARCH-t pe 2000 de zile; simulăm 150 de traiectorii de 2000 de zile din modelul estimat; reestimăm pe fiecare; filtrăm randamentele observate cu fiecare $\hat{\theta}^*$; ES^* pentru ziua următoare
 - ▶ intervalul de 90%: cuantilele de 5% și 95% ale ES^*
- ▣ Intervalul măsoară doar incertitudinea parametrilor: este condiționat de corectitudinea modelului, deci este o limită inferioară a incertitudinii totale

O prognoză ES cu eroarea ei de estimare



- S&P 500, ES 2,5% GARCH-t pentru ziua următoare la sfârșitul fiecărui semestru 2019–2026, cu intervale bootstrap parametric de 90% (cîte 150 de reestimări)

Interpretarea erorii de estimare

- ▣ Lățimea intervalului raportată la prognoză: mediana 13%, între 8% și 19%
- ▣ Iunie 2020: ES 4,49% cu intervalul [4,06; 4,72]: două mii de zile de date lasă totuși o bandă de câteva zecimi de procent
- ▣ Riscul de estimare este mic față de riscul de model (rapoarte de risc în jur de 2): alegerea modelului contează mai mult decât precizia lui
- ▣ Regulile de capital care multiplică o prognoză punctuală le ignoră pe amîndouă: raportarea intervalului este minimul necesar

Recapitulare: riscul de model și de estimare

- ▣ Modelele standard diferă cu un factor de circa doi, mai mult în crize
- ▣ Intervalele bootstrap pentru ES sînt înguste față de acest dezacord
- ▣ Raportați ambele: prognoza, intervalul ei și dispersia între modele

Extremele seriilor dependente

- Pentru o serie staționară, dependența schimbă legea maximului doar printr-un număr, **indicele extremal** θ Embrechts, Klüppelberg și Mikosch (1997)


$$\Pr \left(\max_{t \leq n} X_t \leq u_n \right) \approx F(u_n)^{n\theta}, \quad \theta \in (0, 1]$$

- ▶ X_t : pierderea zilnică; F : distribuția ei marginală; u_n : un prag ridicat care crește cu mărimea eșantionului n
- ▶ $1/\theta$ = mărimea medie a unui grup de depășiri; $\theta = 1$: extremele nu se grupează
- Estimatorul pe intervale Ferro și Segers (2003), din distanțele T_i dintre cele N depășiri (cînd $\max T_i > 2$)

$$\hat{\theta} = \min \left(1, \frac{2(\sum_i (T_i - 1))^2}{(N - 1) \sum_i (T_i - 1)(T_i - 2)} \right)$$

- McNeil și Frey (2000): estimăm GARCH, aplicăm EVT reziduurilor standardizate; metoda funcționează dacă filtrarea elimină gruparea (θ aproape de 1 după filtrare)

Indicele extremal înainte și după filtrare



- Depășiri ale pierderilor zilnice peste cuantila lor de 95%, eșantioanele întregi; pierderi brute și pierderi standardizate prin GARCH (parametri ARMA-GARCH din eșantion)

Interpretarea indicelui extremal

- ▣ Pierderi brute: $\hat{\theta} = 0,30$ (S&P 500), 0,32 (BET), 0,13 (EUR/RON): extremele vin în grupuri de două pînă la opt zile
- ▣ După filtrare: 0,92; 0,85; 0,98 pentru S&P 500, DAX și Bitcoin: GARCH elimină cea mai mare parte a grupării, cum presupun McNeil și Frey
- ▣ EUR/RON rămîne grupat (0,39) și BET parțial (0,82): un curs în regim de managed float și o piață mică au o dependență pe care GARCH nu o surprinde
- ▣ Cu parametri ficși din eșantion, filtrul este imperfect după perioada de estimare: o parte din gruparea rămasă este derivă


Calibrarea conformală a VaR

- ▣ Cuantilele conformale split garantează acoperirea sub interschimbabilitate ([Capitolul 13](#)); randamentele nu sînt interschimbabile, deci garanția nu mai este valabilă
- ▣ **Inferența conformală adaptivă** (ACI) [Gibbs și Candès \(2021\)](#): se prognozează la un nivel de lucru α_t , corectat după fiecare zi

$$\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t), \quad \text{err}_t = 1\{y_t < q_t(\alpha_t)\}$$

- ▶ $q_t(\alpha_t)$: cuantila modelului la nivelul α_t ; $\gamma > 0$: mărimea pasului; după o depășire α_{t+1} scade (VaR crește), după o zi liniștită crește ușor
- ▶ garanție deterministă: $|T^{-1} \sum_t \text{err}_t - \alpha| \leq \frac{\max(\alpha_1, 1 - \alpha_1) + \gamma}{\gamma T}$ pentru **orice** șir de randamente (α_1 : nivelul inițial)
- ▶ doar frecvența pe termen lung: nici calibrare condiționată, nici vreo afirmație despre ES
- ▣ Lectură suplimentară: recalibrarea conformală a cuantilelor extreme sub dependență [Pele et al. \(Conformal_Oracle\)](#)

Corecția conformală adaptivă a VaR 1%



- VaR 1% GARCH-N (fereastră mobilă de 1000 de zile, reestimat la fiecare 250 de zile) din 2016 și corecția ACI cu $\gamma = 0,005$; ratele de depășire pe 250 de zile

Interpretarea corecției conformale

- BET: GARCH-N are depășiri în 2,36% din 2 675 de zile (Kupiec $p < 0,001$); cu ACI 1,08% ($p = 0,666$), acoperire condiționată $p = 0,662$
- Bitcoin: de la 1,28% la 1,02%; rata mobilă nu se netezește: maximul crește de la 3,2% la 4,8% după o supracorecție
- ACI corectează frecvența, nu dinamica: nivelul adaptat poate coborî sub zero (VaR devine atunci infinit) după un șir de zile liniștite
- O corecție utilă pentru numărătoarea supraveghetorului; pentru DQ și pentru ES este în continuare nevoie de un model calibrat

Recapitulare: extreme și calibrare conformală

- ▣ Extremele se grupează; filtrarea elimină cea mai mare parte a grupării pe piețele lichide, nu și pentru cursurile în regim de managed float
- ▣ ACI garantează frecvența pe termen lung a depășirilor pentru orice date, nimic mai mult
- ▣ Ambele sînt corecții ale unui model, nu înlocuitori ai lui

O întrebare deschisă

- Sînt modelele semiparametrice (VaR, ES) mai bune decît modelele de tip poziție–scală în afara eșantionului atunci cînd estimarea se repetă? Este avantajul concentrat în crize?
 - ▶ formal: H_0 : pierdere FZ0 așteptată egală pentru GAS-1F și GARCH-EDF cu reestimare mobilă, pe active, perioade și niveluri preînregistrate
 - ▶ infirmată de o statistică GW semnificativă în ferestrele de criză preînregistrate, robustă pentru $\alpha = 1\%, 2,5\%, 5\%$
- Miza: Basel cere modele ES; evidența PZC provine din parametri ficși și patru indici
 - ▶ literatura de pornire: Patton, Ziegel și Chen (2019), Taylor (2019), Nolde și Ziegel (2017), Dimitriadis și Bayer (2019)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate din 2017 încoace care compară modele dinamice pentru ES în afara eșantionului cu pierderi FZ; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** În ce procese generatoare ar trebui ca un model GAS cu un factor să fie mai bun decât GARCH cu inovații empirice pentru ES 2,5%?
 - ▶ **cod și replicare:** cereți recursia GAS-1F, apoi reproduceți întâi o cifră publicată (PZC, Tabelul 8: 0,853)
 - ▶ **critica:** Joacă rolul unui recenzent ostil: enumeră felurile în care o ordonare FZ0 poate fi un artefact al eșantionului, al nivelului sau al valorilor de pornire.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Pierderea este consistentă pentru țintă: fără „eroarea medie a ES”, fără MSE pentru prognozele VaR
- ▣ Convenția este corectă: VaR 1% este cuantila de 1% a randamentelor cu semn schimbat, niciodată „VaR 99%”; semnele lui v și e sînt consecvente
- ▣ Prognozele folosesc doar informația disponibilă la $t - 1$; fereastra de estimare și schema de reestimare sînt precizate
- ▣ Ordonările se raportează cu incertitudinea DM sau MCS și se verifică pe o diagramă Murphy

Mini studiu de caz: există un cel mai bun model ES?



- 28 de celule: cinci active $\times$ două niveluri (2,5%, 5%) $\times$ până la trei perioade (toată, înainte de 2020, din 2020); stînga: modelul cu cea mai mică pierdere FZ0; dreapta: mărimea MCS de 90%
- 6 câștigători diferiți; GARCH-Skt câștigă 13 celule, GAS-1F 2; mărimea MCS între 3 și 10, mediana 7; GAS-1F este în MCS în 22 de celule: un rezumat AI care numește „cel mai bun model ES” greșește

Idee de proiect

- ▣ **Modele ES pentru piețele din Europa Centrală și de Est cu reestimare mobilă:** întâi replicare, apoi extindere
 - ▶ replicați: Tabelele 8 și S5 din PZC pentru S&P 500 (GAS-1F 0,853 și 1,032) și schema EM cu VaR 1%
 - ▶ extindeți: BET, WIG20, BUX, PX și EUR/RON; reestimare mobilă; regresii comune (VaR, ES) cu VIX și dobânda BNR; ACI ca strat de corecție
 - ▶ preînregistrați: eșantioanele, nivelurile, modelele, ferestrele, perioadele de criză și schema MCS
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ O prognoză de risc este o prognoză punctuală a unei funcționale; judecați-o cu o pierdere consistentă pentru acea funcțională
- ▣ VaR este elicibil, ES doar împreună cu VaR; FZ0 este alegerea independentă de scală pentru serii de timp
- ▣ Modelele CAViaR și GAS-FZ estimează direct coada; ordonările publicate se replică, testele publicate nu
- ▣ Backtesting-ul înseamnă teste de momente cu risc de estimare; comparațiile cer DM, MCS și diagrame Murphy
- ▣ Riscul de orizont, de model și de estimare sînt mai mari decît sugerează majoritatea rezultatelor raportate

Autoevaluare

Întrebări

- ▣ De ce exclude o mulțime de nivel neconvexă existența unei pierderi strict consistente pentru ES?
- ▣ Ce alegere a lui (G_1, G_2) dă FZ0 și ce aduce omogenitatea de grad zero?
- ▣ De ce este testul DQ cu regresorul VaR mai puternic decât testul lui Christoffersen?
- ▣ De ce crește o fereastră fixă de estimare mărimea testului Kupiec?
- ▣ Când supraestimează scalarea cu $\sqrt{10}$ VaR pe 10 zile?

Urmează:

- ▣ Memorie lungă și rough volatility
- ▣ ARFIMA, cointegrare fracționară, rough volatility

Anexă: consistența scorurilor GPL pentru cuantile

- $\mathbb{E}_F S(x, Y) = \int_{-\infty}^x (1 - \alpha)(G(x) - G(y)) dF(y) + \int_x^{\infty} \alpha(G(y) - G(x)) dF(y)$
- Derivăm (Leibniz; termenii de frontieră se anulează):

$$\frac{d}{dx} \mathbb{E}_F S(x, Y) = G'(x)[(1 - \alpha)F(x) - \alpha(1 - F(x))] = G'(x)(F(x) - \alpha)$$
- $G' \geq 0$: derivata este ≤ 0 pentru $x < q_\alpha$ și ≥ 0 pentru $x > q_\alpha$, deci q_α minimizează; strict dacă G este strict crescătoare și F are o singură cuantilă de nivel α
- Același calcul cu $G(x) = x$ este condiția de ordinul întâi a regresiei cuantile

Anexă: FZ0, consistență și omogenitate

- Fixăm e ; în v , FZ0 este $-\frac{1}{\alpha e} [1\{y \leq v\}(v - y) - \alpha v]$ plus termeni fără v : deoarece $-1/(\alpha e) > 0$, un multiplu pozitiv al pierderii pinball, minimizat în q_α
- La $v = q_\alpha$: $\mathbb{E} L = \frac{c}{e} + \ln(-e) - 1$ cu $c = v - \frac{1}{\alpha} \mathbb{E}[1\{Y \leq v\}(v - Y)] = \mathbb{E}[Y \mid Y \leq q_\alpha] = -\text{ES}_\alpha$; derivata $-c/e^2 + 1/e$ se anulează în $e = c$
- Omogenitate: înlocuind (y, v, e) cu (sy, sv, se) , $s > 0$, FZ0 se schimbă doar cu $\ln s$, la fel pentru orice prognoză: diferențele de pierdere nu depind de scală
- Minimizarea comună în (v, e) cu $e \leq v < 0$ dă deci $(q_\alpha, -\text{ES}_\alpha)$

Bibliografie (1/4)

- ▣ Acerbi, C., & Székely, B. (2014). Backtesting expected shortfall. *Risk*, December 2014 (MSCI working paper). [msci.com](https://www.msci.com)
- ▣ Acerbi, C., & Tasche, D. (2002). On the coherence of expected shortfall. *Journal of Banking & Finance*, 26(7), 1487–1503. doi:10.1016/S0378-4266(02)00283-2
- ▣ Artzner, P., Delbaen, F., Eber, J.-M., & Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228. doi:10.1111/1467-9965.00068
- ▣ Basel Committee on Banking Supervision (2019). *MAR33: Internal models approach, capital requirements calculation*. Basel Framework, Bank for International Settlements. [bis.org](https://www.bis.org)
- ▣ Basel Committee on Banking Supervision (1996). *Supervisory framework for the use of "backtesting in conjunction with the internal models approach to market risk capital requirements"*. Bank for International Settlements. [bis.org](https://www.bis.org)
- ▣ Bayer, S., & Dimitriadis, T. (2022). Regression-based expected shortfall backtesting. *Journal of Financial Econometrics*, 20(3), 437–471. doi:10.1093/jjfinc/nbaa013
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- ▣ Boucher, C. M., Daniélsson, J., Kouontchou, P. S., & Maillet, B. B. (2014). Risk models-at-risk. *Journal of Banking & Finance*, 44, 72–92. doi:10.1016/j.jbankfin.2014.03.019
- ▣ Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862. doi:10.2307/2527341
- ▣ Christoffersen, P., & Gonçalves, S. (2005). Estimation risk in financial risk management. *The Journal of Risk*, 7(3), 1–28. doi:10.21314/JOR.2005.112
- ▣ Christoffersen, P., & Pelletier, D. (2004). Backtesting value-at-risk: A duration-based approach. *Journal of Financial Econometrics*, 2(1), 84–108. doi:10.1093/jjfinc/nbh004
- ▣ Creal, D., Koopman, S. J., & Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795. doi:10.1002/jae.1279
- ▣ Daniélsson, J., & Zigrand, J.-P. (2006). On time-scaling of risk and the square-root-of-time rule. *Journal of Banking & Finance*, 30(10), 2701–2713. doi:10.1016/j.jbankfin.2005.10.002

Bibliografie (2/4)

- Danielsson, J., James, K. R., Valenzuela, M., & Zer, I. (2016). Model risk of risk models. *Journal of Financial Stability*, 23, 79–91. doi:10.1016/j.jfs.2016.02.002
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Dimitriadis, T., & Bayer, S. (2019). A joint quantile and expected shortfall regression framework. *Electronic Journal of Statistics*, 13(1), 1823–1871. doi:10.1214/19-EJS1560
- Du, Z., & Escanciano, J. C. (2017). Backtesting expected shortfall: Accounting for tail risk. *Management Science*, 63(4), 940–958. doi:10.1287/mnsc.2015.2342
- Ehm, W., Gneiting, T., Jordan, A., & Krüger, F. (2016). Of quantiles and expectiles: Consistent scoring functions, Choquet representations and forecast rankings. *Journal of the Royal Statistical Society: Series B*, 78(3), 505–562. doi:10.1111/rssb.12154
- Embrechts, P., Klüppelberg, C., & Mikosch, T. (1997). *Modelling Extremal Events for Insurance and Finance*. Springer. doi:10.1007/978-3-642-33483-2
- Engle, R. F., & Manganelli, S. (2004). CAViaR: Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381. doi:10.1198/073500104000000370
- Escanciano, J. C., & Olmo, J. (2010). Backtesting parametric value-at-risk with estimation risk. *Journal of Business & Economic Statistics*, 28(1), 36–51. doi:10.1198/jbes.2009.07063
- Ferro, C. A. T., & Segers, J. (2003). Inference for clusters of extreme values. *Journal of the Royal Statistical Society: Series B*, 65(2), 545–556. doi:10.1111/1467-9868.00401
- Fissler, T., Ziegel, J. F., & Gneiting, T. (2016). Expected shortfall is jointly elicitable with value at risk: Implications for backtesting. *Risk*, January 2016, 58–61; arXiv:1507.00244. [arxiv.org](https://arxiv.org/abs/1507.00244)
- Fissler, T., & Ziegel, J. F. (2016). Higher order elicibility and Osband's principle. *The Annals of Statistics*, 44(4), 1680–1707. doi:10.1214/16-AOS1439
- Gaglianone, W. P., Lima, L. R., Linton, O., & Smith, D. R. (2011). Evaluating value-at-risk models via quantile regression. *Journal of Business & Economic Statistics*, 29(1), 150–160. doi:10.1198/jbes.2010.07318
- Gao, F., & Song, F. (2008). Estimation risk in GARCH VaR and ES estimates. *Econometric Theory*, 24(5), 1404–1424. doi:10.1017/S0266466608080559

Bibliografie (3/4)

- ▣ Giacomini, R., & White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578. doi:10.1111/j.1468-0262.2006.00718.x
- ▣ Gibbs, I., & Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems*, 34; arXiv:2106.00170. arxiv.org
- ▣ Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779–1801. doi:10.1111/j.1540-6261.1993.tb05128.x
- ▣ Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762. doi:10.1198/jasa.2011.r10138
- ▣ Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/0162145060000001437
- ▣ Hansen, B. E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730. doi:10.2307/2527081
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- ▣ Holzmann, H., & Eulert, M. (2014). The role of the information set for forecasting – with applications to risk management. *The Annals of Applied Statistics*, 8(1), 595–621. doi:10.1214/13-AOAS709
- ▣ Kellner, R., & Rösch, D. (2016). Quantifying market risk with value-at-risk or expected shortfall? Consequences for capital requirements and model risk. *Journal of Economic Dynamics and Control*, 68, 45–63. doi:10.1016/j.jedc.2016.05.002
- ▣ Koenker, R., & Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50. doi:10.2307/1913643
- ▣ Koenker, R. (2005). *Quantile Regression*. Cambridge University Press. doi:10.1017/CBO9780511754098
- ▣ Koenker, R., & Xiao, Z. (2006). Quantile autoregression. *Journal of the American Statistical Association*, 101(475), 980–990. doi:10.1198/0162145060000000672
- ▣ Kratz, M., Lok, Y. H., & McNeil, A. J. (2018). Multinomial VaR backtests: A simple implicit approach to backtesting expected shortfall. *Journal of Banking & Finance*, 88, 393–407. doi:10.1016/j.jbankfin.2018.01.002

Bibliografie (4/4)

- ▣ Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- ▣ McNeil, A. J., & Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: An extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300. doi:10.1016/S0927-5398(00)00012-8
- ▣ Nolde, N., & Ziegel, J. F. (2017). Elicitability and backtesting: Perspectives for banking regulation. *The Annals of Applied Statistics*, 11(4), 1833–1874. doi:10.1214/17-AOAS1041
- ▣ Patton, A. J., Ziegel, J. F., & Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413. doi:10.1016/j.jeconom.2018.10.008
- ▣ Pele, D. T., Bolovăneanu, V., Ginavar, A., Lessmann, S., & Härdle, W. K. Conformal recalibration of extreme tail quantiles under temporal dependence. Working paper and replication package (further reading). github.com
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Taylor, J. W. (2008). Estimating value at risk and expected shortfall using expectiles. *Journal of Financial Econometrics*, 6(2), 231–252. doi:10.1093/jjfinec/nbn001
- ▣ Taylor, J. W. (2019). Forecasting value at risk and expected shortfall using a semiparametric approach based on the asymmetric Laplace distribution. *Journal of Business & Economic Statistics*, 37(1), 121–133. doi:10.1080/07350015.2017.1281815
- ▣ Weber, S. (2006). Distribution-invariant risk measures, information, and dynamic consistency. *Mathematical Finance*, 16(2), 419–441. doi:10.1111/j.1467-9965.2006.00277.x
- ▣ Ziegel, J. F. (2016). Coherence and elicibility. *Mathematical Finance*, 26(4), 901–918. doi:10.1111/mafi.12080