



Analiza avansată a seriilor de timp și previziune

Capitolul 10: Memorie lungă și rough volatility



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ACF: Autocorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARFIMA: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv fracționar integrat cu medie mobilă
- ARMA: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- BIC: Bayesian Information Criterion (criteriul informațional bayesian (Schwarz))
- BNR: Banca Națională a României
- BSS: Brownian Semistationary (process) — proces brownian semistaționar
- CPIAUCSL: Consumer Price Index for All Urban Consumers (FRED series code) — indicele prețurilor de consum pentru toți consumatorii urbani (codul seriei în FRED)
- DFA: Detrended Fluctuation Analysis (analiza fluctuațiilor fără tendință)
- DFT: Discrete Fourier Transform (transformata Fourier discretă)
- DM: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ELW: Exact Local Whittle (estimator) — estimatorul local Whittle exact
- EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață
- FCVAR: Fractionally Cointegrated VAR (model VAR cointegrat fracționar)
- FFT: Fast Fourier Transform (transformata Fourier rapidă)
- FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) — furnizorul de indici FTSE Russell
- FTW: Fukasawa, Takabatake and Westphal (2022) — Fukasawa, Takabatake și Westphal (2022)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GJR: Gatheral, Jaisson and Rosenbaum (2018) — Gatheral, Jaisson și Rosenbaum (2018)
- GMM: Generalized Method of Moments (metoda generalizată a momentelor)
- GPH: Geweke–Porter–Hudak (estimator) — estimatorul Geweke–Porter–Hudak al parametrului de memorie lungă

Acronime folosite în acest material (2/3)

- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- HAR: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- HYGARCH: Hyperbolic GARCH (Davidson) — GARCH hiperbolic (Davidson)
- IAPC: Indicele armonizat al prețurilor de consum
- IPC: Indicele prețurilor de consum
- LLM: Large Language Model (model lingvistic de mari dimensiuni)
- LMSV: Long-Memory Stochastic Volatility (volatilitate stohastică cu memorie lungă)
- LR: Likelihood Ratio (test) — testul raportului de verosimilitate
- LW: Local Whittle (estimator) — estimatorul local Whittle
- MFM: Modelling Financial Markets (Modelarea piețelor financiare, cursul de master)
- ML: Machine Learning (învățare automată)
- MSE: Mean Squared Error (eroarea pătratică medie)
- NBLS: Narrow-Band Least Squares (cele mai mici pătrate în bandă îngustă de frecvențe)
- OHLC: Open, High, Low, Close (deschidere, maxim, minim, închidere)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- OU: Ornstein–Uhlenbeck (process) — procesul Ornstein–Uhlenbeck
- QLIKE: Quasi-LIKElihood loss (pierderea de tip cvasi-verosimilitate)
- QML: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- RFSV: Rough Fractional Stochastic Volatility (model) — modelul de volatilitate stohastică fracționară rugoasă
- RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- RV: Realised Variance (varianța realizată)
- SE: Standard Error (eroare standard)
- SUA: Statele Unite ale Americii
- SV: Stochastic Volatility (volatilitate stohastică)
- TED: Technology, Entertainment, Design (conference) — conferința Technology, Entertainment, Design
- TSA: Time Series Analysis (Serii de timp, cursul de licență)

Acronime folosite în acest material (3/3)

- ▣ VAR: Vector AutoRegression (model vector autoregresiv)
- ▣ VECM: Vector Error Correction Model (model vectorial cu corecția erorii)
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- ▣ WIG20: Warszawski Indeks Giełdowy 20 (indicele celor mai mari 20 de companii de la Bursa din Varșovia)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cât de încet se sting șocurile asupra volatilității și inflației, cât de rugoasă este volatilitatea pe orizonturi scurte și cum deosebim memoria lungă reală de rupturi și de erorile de măsurare?
 - ▶ două scări ale aceluiași obiect: persistența logaritmului volatilității pe luni și rugozitatea lui pe zile
- ▣ **Traseul** capitolului
 - ▶ caracterizarea spectrală și procesele fracționare; asimptotica estimatorilor GPH, local Whittle și local Whittle exact; lățimea de bandă și deplasarea
 - ▶ testarea memoriei lungi împotriva salturilor de nivel (Qu 2011); cointegrarea fracționară (FCVAR)
 - ▶ memoria lungă a volatilității: FIGARCH, HYGARCH, LMSV, HAR ca aproximare
 - ▶ rough volatility: fBm, simulare, evidența lui Gatheral, Jaisson și Rosenbaum, critici, prognoză
- ▣ Pornim de la [TSA](#), [Capitolul 8](#) (ARFIMA, R/S, GPH), [Capitolul 1](#) (evaluarea prognozelor), [Capitolul 2](#) (rupturi) și [Capitolul 8](#) (măsurile realizate, HAR); Seminarul 10 are loc înaintea acestui curs

Rezultatele învățării

- Caracterizați memoria lungă în domeniul timpului și al frecvenței și deduceți autocorelațiile și spectrul proceselor ARFIMA
- Enunțați teoria asimptotică a estimatorilor GPH, local Whittle și local Whittle exact și alegeți lățimea de bandă din compromisul deplasare–varianță
- Testați memoria lungă față de memoria scurtă cu salturi de nivel (Qu 2011) și estimați un VAR cointegrat fracționar
- Estimați modele FIGARCH și HYGARCH, precum și memoria lungă a volatilității robust la zgomotul de măsurare
- Simulați mișcarea browniană fracționară, replicați evidența rugozității pe varianța realizată și evaluați onest, în afara eșantionului, prognozele de rough volatility

Bibliografie, date și instrumente

- ▣ Memorie lungă: Granger și Joyeux (1980); Hosking (1981); Robinson (1995b); Shimotsu și Phillips (2005); Beran et al. (2013)
 - ▶ Rupturi și memorie comună: Qu (2011); Perron și Qu (2010); Johansen și Nielsen (2012)
 - ▶ Volatilitate: Baillie, Bollerslev și Mikkelsen (1996); Corsi (2009); Gatheral, Jaisson și Rosenbaum (2018); Bennedsen, Lunde și Pakkanen (2022)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_10](#)
 - ▶ estimatorii pe periodogramă, testul Qu, FCVAR, FIGARCH, scufundarea circulantă, schema hibridă și predictorul RFSV scrise în `numpy/scipy`
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa, eşantionul	Utilizarea
Varianța realizată a șase indici bursieri	Heber et al. (2009): RV din randamente de 5 minute, ianuarie 2000 – februarie 2022 (sfârșitul bibliotecii)	memorie, rugozitate, prognoze
Varianța realizată a Bitcoin	prețuri Binance la un minut (date publice), măsurile noastre, ianuarie 2018 – septembrie 2026	rugozitate, prognoze
S&P 500, DAX, BET, Bitcoin, VIX	EODHD, prețuri zilnice OHLC și de închidere, 2000 – septembrie 2026	FIGARCH, $ r $, amplitudini, FCVAR
EUR/RON	cursul de referință BNR, iulie 2005 – septembrie 2026	memoria lui $ r $
Inflația	IPC SUA (FRED CPIAUCSL), IAPC România (Eurostat prc_hicp_minr), lunar	persistență și rupturi

- Acolo unde nu există date intraday (BET, EUR/RON), volatilitatea este aproximată prin $|r_t|$ și $\log r_t^2$; amplitudinea Parkinson arată cum un proxy mai zgomotos distorsionează rugozitatea

De la Nil la memoria lungă



Harold Edwin Hurst, 1953

Foto: Elliott & Fry (1953); domeniu public; Wikimedia

[Commons](#)

- Hurst a studiat secole de niveluri ale Nilului pentru a dimensiona rezervoarele de deasupra Aswanului [Hurst \(1951\)](#)
- Amplitudinea ajustată a aflurilor cumulate creștea ca n^H cu $H \approx 0,7$, nu ca $n^{1/2}$: **efectul Hurst**
- Anii ploioși urmează anilor ploioși în serii lungi: o dependență pe care niciun ARMA finit nu o reproduce
- Explicat prin zgomotul gaussian fracționar [Mandelbrot și Van Ness \(1968\)](#) și prin diferențierea fracționară [Granger și Joyeux \(1980\)](#), [Hosking \(1981\)](#)

Înregistrările fluviului





Nilometrul de pe insula Roda, Cairo

Foto: Willyman (2009); CC BY-SA 4.0; Wikimedia

[Commons](#)

- Nilometrul de pe Roda a înregistrat minimele anuale ale Nilului începînd cu secolul al VII-lea: una dintre cele mai vechi serii de timp
- Aceste minime sînt setul clasic de date cu memorie lungă [Beran et al. \(2013\)](#)
- Azi aceeași întrebare se pune pentru volatilitate, inflație și dobînzii: se stinge un șoc geometric sau hiperbolic?
- Și una mai nouă: pe orizonturi scurte, este volatilitatea mai netedă sau mai rugoasă decît mișcarea browniană?

Douăzeci și doi de ani de logaritm al varianței realizate



- Stînga: S&P 500 (Oxford-Man, $n = 5\,552$ zile pînă la 25 februarie 2022) și Bitcoin ($n = 3\,165$ zile pînă la 18 septembrie 2026); dreapta: ACF de eșantion a logaritmului RV pentru S&P 500, decalaje 1–500, scară log-log

Interpretarea imaginii de ansamblu

- ▣ ACF 0,82 la decalajul 1, 0,53 la 22, încă 0,18 la 250: un AR(1) cu același prim decalaj ar da circa 10^{-22} la decalajul 250
- ▣ Pe decalajele 5–200, ACF este o dreaptă în scara log-log, cu panta $-0,33$: o descreștere hiperbolică k^{2d-1} cu $d \approx 0,34$
- ▣ Estimația local Whittle este mai mare, 0,62: sub memorie lungă, ACF de eșantion este deplasată în jos la decalaje mari
- ▣ Restul capitoului întreabă în care dintre aceste cifre putem avea încredere și de ce aceeași serie pare și rugoasă

Cunoscut din TSA și elemente noi

- ▣ Cunoscut (TSA, Capitolul 8): diferențierea fracționară, ARFIMA(p, d, q), R/S și DFA, GPH și local Whittle ca rețete, FIGARCH și HAR pe scurt, memoria lungă aparentă prin exemple
- ▣ Nou: teoria din spatele rețetelor
 - ▶ definiții echivalente, agregare, varianța mediei de eșantion
 - ▶ legile limită ale estimatorilor semiparametrici, d nestăționar, deplasarea și alegerea lui m
 - ▶ un test formal împotriva salturilor de nivel; cointegrarea fracționară; rough volatility
- ▣ Replicări: agregarea Granger (1980), designul Qu (2011), scalarea Gatheral, Jaisson și Rosenbaum (2018, secțiunea 2) pe datele Oxford-Man folosite de ei


Două definiții ale memoriei lungi

- **Domeniul timpului:** $\gamma(k) \sim c_\gamma k^{2d-1}$ când $k \rightarrow \infty$, $0 < d < 1/2$; atunci $\sum_k |\gamma(k)| = \infty$
 - ▶ $a_k \sim b_k$ înseamnă $a_k/b_k \rightarrow 1$; memorie scurtă: $\sum_k |\gamma(k)| < \infty$
- **Domeniul frecvenței:** $f(\lambda) \sim c_f \lambda^{-2d}$ când $\lambda \rightarrow 0^+$: un pol în frecvența zero
 - ▶ $d < 0$: antipersistentă, $f(0) = 0$, $\sum_k \gamma(k) = 0$; $d = 0$: memorie scurtă
- Echivalența: pentru γ cvasi-monotonă, $c_f = c_\gamma \Gamma(2d) \sin(\pi/2 - \pi d)/\pi$ (teoreme abeliene–tauberiene) [Beran et al. \(2013\)](#)
 - ▶ fără regularitate, cele două definiții diferă; estimatorii semiparametrici folosesc doar definiția din domeniul frecvenței
- Scara Hurst: $H = d + 1/2$ pentru seria staționară; $H > 1/2$ persistentă, $H < 1/2$ antipersistentă

Integrarea fracționară și ARFIMA

- $(1 - L)^d = \sum_{k \geq 0} \pi_k L^k$, $\pi_0 = 1$, $\pi_k = \pi_{k-1} \frac{k-1-d}{k}$, $\pi_k \sim k^{-d-1}/\Gamma(-d)$ Granger și Joyeux (1980), Hosking (1981)
- ARFIMA(p, d, q): $\phi(L)(1 - L)^d(X_t - \mu) = \theta(L)\varepsilon_t$; staționar și inversabil pentru $-1/2 < d < 1/2$
 - ▶ spectrul $f(\lambda) = \frac{\sigma^2}{2\pi} |2 \sin(\lambda/2)|^{-2d} \frac{|\theta(e^{-i\lambda})|^2}{|\phi(e^{-i\lambda})|^2} = |2 \sin(\lambda/2)|^{-2d} f^*(\lambda)$
 - ▶ f^* : partea netedă de memorie scurtă; lângă zero $f(\lambda) \approx f^*(0)\lambda^{-2d}$
- ARFIMA(0, d , 0): $\gamma(0) = \sigma^2 \frac{\Gamma(1-2d)}{\Gamma(1-d)^2}$, $\rho(k) = \frac{\Gamma(k+d)\Gamma(1-d)}{\Gamma(k-d+1)\Gamma(d)} \sim \frac{\Gamma(1-d)}{\Gamma(d)} k^{2d-1}$
 - ▶ recursia $\rho(k) = \rho(k-1)(k-1+d)/(k-d)$, $\rho(1) = d/(1-d)$

Descreștere hiperbolică și geometrică



- Stînga: ACF pentru ARFIMA(0, d , 0) și pentru un AR(1) cu același $\rho(1)$, scară log-log; dreapta: densitățile spectrale lîngă zero, AR(1) scalat la aceeași varianță



Interpretarea celor două descreșteri

- ▣ $d = 0,4$: $\rho(1) = 0,667$, $\rho(10) = 0,424$, $\rho(100) = 0,267$; AR(1) corespunzător are $\rho(100)$ de ordinul 10^{-18}
- ▣ Sumele parțiale $\sum_{k \leq 100} \rho(k) = 33,0$ și $\sum_{k \leq 200} \rho(k) = 57,8$: continuă să crească, precum K^{2d}
- ▣ În spectru diferența este un pol față de un platou: memoria lungă se află la frecvențele cele mai joase, unde există puține ordonate ale periodogramei
- ▣ De aceea toți estimatorii semiparametrici privesc doar cele mai joase m frecvențe Fourier

Originea memoriei lungi: agregarea

- ▣ Granger (1980): $X_t = N^{-1/2} \sum_{i=1}^N x_{it}$, $x_{it} = \phi_i x_{i,t-1} + \varepsilon_{it}$, unități independente cu ϕ_i aleator
 - ▶ $\phi_i^2 \sim \text{Beta}(p, q)$, adică densitatea $\propto \phi^{2p-1}(1-\phi^2)^{q-1}$ pe $(0, 1)$
- ▣ Derivare: $\gamma_X(k) = \mathbb{E}[\phi^k / (1 - \phi^2)] \propto \int_0^1 \phi^{k+2p-1} (1 - \phi^2)^{q-2} d\phi \propto B(\frac{k}{2} + p, q - 1) \sim c k^{-(q-1)}$
 - ▶ identificăm cu k^{2d-1} : $d = 1 - q/2$, memorie lungă pentru $1 < q < 2$
- ▣ Lectura economică: inflația, volatilitatea sau producția agregată combină mulți agenți cu memorie scurtă și persistență eterogenă; cîteva unități apropiate de rădăcina unitară domină frecvențele joase
- ▣ Memoria lungă poate fi deci structurală, nu o curiozitate a estimatorului

Agregarea seriilor AR(1)



□ $\phi_i^2 \sim \text{Beta}(1; 1, 4)$, deci $d = 1 - q/2 = 0,3$; $n = 4000$; local Whittle cu $m = 219$, 20 replicări pentru fiecare N ; stînga: periodograma unui agregat de 3000 de serii

Interpretarea agregării

- Un singur AR(1): mediana $\hat{d} = 0,04$; zece serii: 0,30; 100 de serii: 0,41; 3000 de serii: 0,41 (10%–90%: între 0,38 și 0,51)
- Estimația se stabilizează peste limita 0,3: spectrul agregatului este λ^{-2d} doar foarte aproape de zero, iar $m = n^{0,65}$ intră în zona în care nu mai este
- Aceasta este problema deplasării din secțiunea 2 în forma ei cea mai pură: un estimator semiparametric este atât de bun cât îi este lățimea de bandă
- Direcția efectului, de la lipsa memoriei la memorie lungă clară, este esența teoremei lui Granger

Consecințe pentru inferență: media de eșantion

- $\text{Var}(\bar{X}_n) = \frac{1}{n} \sum_{|k| < n} \left(1 - \frac{|k|}{n}\right) \gamma(k) \sim \frac{c_\gamma}{d(2d+1)} n^{2d-1}$
 - media converge cu viteza $n^{1/2-d}$, nu $n^{1/2}$; cu $d = 0,4$: $n^{0,1}$
- Erorile standard HAC ([Capitolul 0](#)) presupun $\sum_k |\gamma(k)| < \infty$: sub memorie lungă, varianța de termen lung este infinită, iar intervalele Newey–West sînt prea înguste
 - la fel pentru testele DM ([Capitolul 1](#)) aplicate diferențelor de pierderi care moștenesc memoria lungă
- Regresie cu regresori și erori cu memorie lungă: pantele OLS converg încet; regresie falsă între serii fracționare independente cînd $d_x + d_u > 1/2$
- Fiecare test din acest curs construit pe asimptotica $\sqrt{n}$ trebuie reexaminat cînd $d > 0$

Recapitulare: memoria lungă

- Memoria lungă: ACF hiperbolică k^{2d-1} și un pol spectral λ^{-2d} ; $H = d + 1/2$
- ARFIMA separă polul $|2 \sin(\lambda/2)|^{-2d}$ de partea de memorie scurtă f^*
- Agregarea unităților AR(1) eterogene produce memorie lungă; media converge cu $n^{1/2-d}$

Periodograma lîngă frecvența zero

$$\square I(\lambda_j) = \frac{1}{2\pi n} \left| \sum_{t=1}^n X_t e^{-i\lambda_j t} \right|^2 \text{ în } \lambda_j = 2\pi j/n, j = 1, \dots, m$$

► memorie scurtă: $I(\lambda_j)/f(\lambda_j)$ asimptotic i.i.d. $\text{Exp}(1)$

□ Memorie lungă: pentru j fix, $\mathbb{E} I(\lambda_j)/f(\lambda_j) \not\rightarrow 1$, iar ordonatele rămîn corelate [Robinson \(1995a\)](#)

► distorsiunea dispare cînd $j \rightarrow \infty$: demonstrațiile cer $m \rightarrow \infty$, $m/n \rightarrow 0$ și tratează separat primele frecvențe

□ Modelul semiparametric: $f(\lambda) = G\lambda^{-2d}(1 + O(\lambda^\beta))$ cînd $\lambda \rightarrow 0$, $\beta \in (0, 2]$; nimic nu se presupune departe de zero

► $\beta = 2$ pentru ARFIMA: f^* este netedă și pară, deci $f^*(\lambda) = f^*(0)(1 + \frac{1}{2} \frac{f^{*''}(0)}{f^*(0)} \lambda^2 + \dots)$

GPH: regresia pe logaritmul periodogramei

- $\log I(\lambda_j) = \log G - 2d \log \lambda_j + \log \xi_j$, $\xi_j = I(\lambda_j)/f(\lambda_j)$ Geweke și Porter-Hudak (1983)
 - ▶ OLS pe $j = 1, \dots, m$; cu $\xi_j \sim \text{Exp}(1)$: $\mathbb{E} \log \xi_j = -\gamma_E$ (Euler), $\text{Var} \log \xi_j = \pi^2/6$
- Robinson (1995a): pentru $|d| < 1/2$ și X gaussian, $\sqrt{m}(\hat{d}_{GPH} - d) \rightarrow N(0, \pi^2/24)$ dacă $m \rightarrow \infty$ și $m^5/n^4 \rightarrow 0$
 - ▶ de unde vine $\pi^2/24$: $\text{Var}(\hat{d}) = \frac{\pi^2/6}{4 \sum_j \nu_j^2}$, $\nu_j = \log j - \overline{\log j}$, iar $\sum_j \nu_j^2 \sim m$
- MSE și deplasare pentru ARFIMA Hurvich, Deo și Brodsky (1998): $\mathbb{E} \hat{d} - d \approx -\frac{2\pi^2}{9} \frac{f^{*''}(0)}{f^*(0)} \frac{m^2}{n^2}$
 - ▶ condiția $m^5/n^4 \rightarrow 0$ face deplasarea neglijabilă față de abaterea standard $m^{-1/2}$

Local Whittle: derivare

- ▣ Aproximarea Whittle a log-verosimilității gaussiene restrânsă la $j \leq m$, cu $f(\lambda_j) = G\lambda_j^{-2d}$:

► $Q(G, d) = \frac{1}{m} \sum_{j=1}^m \left[\log(G\lambda_j^{-2d}) + \frac{I(\lambda_j)}{G\lambda_j^{-2d}} \right]$

- ▣ Concentrăm G : $\hat{G}(d) = \frac{1}{m} \sum_j \lambda_j^{2d} I(\lambda_j)$, deci Robinson (1995b)

► $\hat{d}_{LW} = \arg \min_d R(d)$, $R(d) = \log \hat{G}(d) - \frac{2d}{m} \sum_{j=1}^m \log \lambda_j$

- ▣ Scorul în valoarea adevărată: $R'(d) = \frac{2}{m} \sum_j \nu_j \left(\frac{\lambda_j^{2d} I(\lambda_j)}{\hat{G}(d)} - 1 \right)$, o sumă ponderată de $\xi_j - 1$

► $\text{Var}(\xi_j) = 1$ și $R''(d) \rightarrow 4$: $\sqrt{m}(\hat{d} - d) \rightarrow N(0, 4/16) = N(0, 1/4)$

- ▣ Nicio ipoteză de distribuție în afara unui proces liniar cu inovații diferențe de martingal; eficiența relativă față de GPH: $(\pi^2/24)/(1/4) = \pi^2/6 \approx 1,64$

Local Whittle: teorema și limitele ei

- ▣ Robinson (1995b): pentru $d \in (-1/2, 1/2)$, $f(\lambda) = G\lambda^{-2d}(1 + O(\lambda^\beta))$, $1/m + m^{1+2\beta}(\log m)^2/n^{2\beta} \rightarrow 0$:
 - ▶ $\hat{d} \rightarrow_p d$ și $\sqrt{m}(\hat{d} - d) \rightarrow N(0, 1/4)$
- ▣ d nestăionar: consistent pentru $d < 1$, asimptotic normal pentru $d < 3/4$ Velasco (1999)
 - ▶ pentru $d > 1$ converge în probabilitate la 1; între $3/4$ și 1 limita nu este normală Phillips și Shimotsu (2004)
- ▣ Remedii: diferențiem întâi datele (trebuie să știm că $d > 1/2$), aplicăm o fereastră periodogramei (cu cost în varianță) sau estimăm exact

Local Whittle exact

- Shimotsu și Phillips (2005): înlocuim $\lambda_j^{2d} I_X(\lambda_j)$ prin periodograma datelor diferențiate fracționar

$$\Delta^d X_t = \sum_{k=0}^{t-1} \pi_k X_{t-k}$$

$$\blacktriangleright R_E(d) = \log \left(\frac{1}{m} \sum_j I_{\Delta^d X}(\lambda_j) \right) - \frac{2d}{m} \sum_j \log \lambda_j$$

- Explicația: $\lambda^{2d} I_X(\lambda)$ aproximează $I_{\Delta^d X}(\lambda)$ doar pentru $d < 1/2$; versiunea exactă elimină eroarea de aproximare care strică LW pentru d mare


$$\blacktriangleright \sqrt{m}(\hat{d}_{ELW} - d) \rightarrow N(0, 1/4) \text{ pentru orice } d \text{ dintr-un interval de căutare de lățime } < 9/2$$

- Media necunoscută Shimotsu (2010): $X_t - \hat{\mu}(d)$ cu $\hat{\mu}(d) = w(d)\bar{X} + (1 - w(d))X_1$

$$\blacktriangleright w(d) = 1 \text{ pentru } d \leq 1/2, 0 \text{ pentru } d \geq 3/4, \text{ netedă între ele: media de eșantion estimează prost nivelul când } d > 1/2$$

- Costul: o diferență fracționară pentru fiecare evaluare, $O(n \log n)$ prin FFT

GPH, local Whittle și local Whittle exact prin Monte Carlo



- 400 de traiectorii ARFIMA(0, d , 0) gaussiene, $n = 2000$, $m = n^{0.65} = 139$; abaterea standard asimptotică: GPH 0,054, local Whittle 0,042; $d = 1,2$ se simulează ca sumă parțială a unui ARFIMA(0; 0,2; 0)


Interpretarea experimentului Monte Carlo

- ▣ $d = 0,3$: medii 0,301; 0,297; 0,298; abateri standard 0,057; 0,045; 0,045; acoperirea de 95%: 94%, 94%, 95% (GPH, LW, ELW)
- ▣ Legile asimptotice sînt precise la $n = 2000$; local Whittle este de circa $\sqrt{\pi^2/6}$ ori mai strîns decît GPH
- ▣ $d = 1,2$: GPH 1,057 și LW 1,072 se strîng spre 1 (acoperire 26% și 22%); ELW 1,202, acoperire 93%
- ▣ Pentru seriile care pot fi nestaționare (prețuri, inflația în nivel, logaritmul RV cu d aproape de 0,5) raportați ELW

Lățimea de bandă: deplasare și varianță

- Deplasarea principală (GPH și LW): regresăm $\log f^*(\lambda_j) \approx \log f^*(0) + b\lambda_j^2$, $b = \frac{1}{2}f^{*''}(0)/f^*(0)$, pe $-2\nu_j$:
 - ▶ $\mathbb{E}\hat{d} - d \approx -\frac{1}{2}b \left(\frac{2\pi m}{n}\right)^2 \frac{\int_0^1 (1 + \log x)x^2 dx}{\int_0^1 (1 + \log x)^2 dx} = -\frac{2\pi^2}{9} \frac{f^{*''}(0)}{f^*(0)} \left(\frac{m}{n}\right)^2$
 - ▶ integralele sînt $2/9$ și 1 ; ARFIMA(1, d , 0): $f^{*''}(0)/f^*(0) = -2\phi/(1 - \phi)^2$, deplasare în sus pentru $\phi > 0$
- $\text{MSE} \approx C^2(m/n)^4 + 1/(4m)$ cu constanta deplasării C ; minimizăm: $m^* = (n^4/(16C^2))^{1/5} \propto n^{4/5}$ Henry și Robinson (1996)
 - ▶ C este necunoscută: regulile plug-in o estimează; local Whittle polinomial Andrews și Sun (2004) elimină termenul în λ^2 cu un cost în varianță
- La m^* deplasarea și abaterea standard sînt de același ordin, deci intervalele nominale acoperă prea puțin; în practică: graficul lui $\hat{d}(m)$ pe un interval de valori, raportat împreună cu intervalele

Deplasarea și RMSE în funcție de lățimea de bandă



- Local Whittle, ARFIMA(1; 0,3; 0) cu $\phi = 0,6$, $n = 2000$, 300 de replicări, $m = n^a$ pentru $a = 0,40, \dots, 0,80$; linie întreruptă: deplasarea principală $C(m/n)^2$ cu $C = 16,4$ și RMSE asimptotic

Interpretarea compromisului lățimii de bandă

- ▣ m mic ($a = 0,40$): deplasare 0,006, RMSE 0,16, dominat de varianță; m mare ($a = 0,80$): deplasare 0,31, RMSE 0,31
- ▣ Cel mai mic RMSE Monte Carlo, 0,070, la $m = 95$ ($a = 0,60$); teoria: $m^* = 82$ ($a = 0,58$)
- ▣ Termenul principal supraestimează deplasarea la m mare (0,79 față de 0,31): dezvoltarea în λ^2 este locală
- ▣ O regulă fixă precum $m = n^{0,8}$ poate transforma o componentă AR de memorie scurtă în memorie lungă aparentă

Alternativa parametrică: Whittle și ML exact

- ▣ Whittle: $\hat{\vartheta} = \arg \min \sum_{j=1}^{\lfloor (n-1)/2 \rfloor} \left[\log f(\lambda_j; \vartheta) + \frac{I(\lambda_j)}{f(\lambda_j; \vartheta)} \right]$ pe toate frecvențele Fox și Taqqu (1986)
 - ▶ consistent cu viteza $\sqrt{n}$ și eficient pentru un ARFIMA(p, d, q) corect specificat; $\text{Var}(\hat{d}) \approx 6/(\pi^2 n)$ pentru $(0, d, 0)$
- ▣ Compromisul este între robustețe și eficiență: un (p, q) greșit deplasează $\hat{d}$ pentru orice n
 - ▶ semiparametric: viteza $\sqrt{m}$, robust la f^* ; parametric: viteza $\sqrt{n}$, expus la specificarea greșită
- ▣ Practica obișnuită: întâi $\hat{d}$ semiparametric, apoi un model parametric al cărui d cade în intervalul lui, apoi prognoze

Recapitulare: estimarea semiparametrică

- GPH: $N(d, \pi^2/(24m))$; local Whittle: $N(d, 1/(4m))$; local Whittle exact păstrează $N(d, 1/(4m))$ pentru d nestăționar
- Deplasarea $\propto (m/n)^2$, abaterea standard $\propto m^{-1/2}$: m optim în $\text{MSE} \propto n^{4/5}$, cu o constantă necunoscută
- Raportați întotdeauna $\hat{d}(m)$ pentru mai multe lățimi de bandă



Mecanismele memoriei lungi aparente

- Diebold și Inoue (2001): schimbarea de regim markoviană în medie, cu probabilitatea de comutare $p_n \rightarrow 0$ când $n \rightarrow \infty$, produce $\text{Var}(\sum_{t \leq n} X_t) = O(n^{2d+1})$, ca un proces $I(d)$
 - ▶ rupturile rare sînt invizibile la frecvențe înalte și arată ca un pol la frecvențe joase Granger și Hyung (2004)
- Salturi aleatoare de nivel Lu și Perron (2010): $X_t = \mu_t + u_t$, $\mu_t = \mu_{t-1} + \delta_t \eta_t$, $\delta_t \sim \text{Bernoulli}(p)$
 - ▶ spectrul $\approx \frac{p\sigma_\eta^2}{2\pi\lambda^2}$ peste frecvența $\approx p$, plus f_u plat: o pantă -2 care trece într-un platou
- Semnătura Perron și Qu (2010): sub salturi de nivel, $\hat{d}(m)$ scade abrupt cînd m crește; sub memorie lungă reală este plat
 - ▶ același raționament se aplică trendurilor, schimbărilor de regim și sezonaliității deterministe rămase în date
- TSA, Capitolul 8 a arătat fenomenul prin exemple; aici: un test formal cu mărime cunoscută

Testul Qu (2011)

- Sub H_0 (memorie lungă staționară) scorul LW are media zero în orice bandă de frecvențe; sub salturi de nivel, frecvențele joase sînt supraponderate [Qu \(2011\)](#)
- $$W = \sup_{r \in [\varepsilon, 1]} \left(\sum_{j=1}^m \nu_j^2 \right)^{-1/2} \left| \sum_{j=1}^{\lfloor mr \rfloor} \nu_j \left(\frac{I(\lambda_j)}{\hat{G} \lambda_j^{-2\hat{d}}} - 1 \right) \right|$$
 - ▶ $\hat{d}, \hat{G}$: local Whittle pe aceleași m frecvențe; $\nu_j = \log \lambda_j - \overline{\log \lambda}$; suma parțială în $r = 1$ este zero prin condiția de ordinul întâi
- Limita: supremul unui proces gaussian care nu depinde de d și G ; Qu recomandă $m = n^{0,7}$, $\varepsilon = 0,02$ (pentru n mare) sau 0,05
 - ▶ valorile critice simulate de noi: $\varepsilon = 0,02$: 1,09; 1,22; 1,56; $\varepsilon = 0,05$: 1,00; 1,14; 1,45 (10%, 5%, 1%)
- Respingem pentru W mare: evidență împotriva memoriei lungi staționare, de obicei rupturi, salturi de nivel sau trenduri

Mărime, putere și semnătura lățimii de bandă





□ $n = 2000$, 300 de replicări, $m = n^{0.7} = 204$, $\varepsilon = 0.02$; stînga: media $\hat{d}(m)$ local Whittle (100 de traiectorii) și logaritmul RV pentru S&P 500; dreapta: ratele de respingere la 5%

Interpretarea testului Qu

- ▣ Mărimea: 5% sub ARFIMA(0;0,3;0), 12% când se adaugă un AR(1) cu $\phi = 0,5$: dinamica de termen scurt distorsionează mărimea în eşantioane finite
- ▣ Puterea: 99% împotriva salturilor de nivel şi 100% împotriva unei singure rupturi, deşi LW raportează $\hat{d} = 0,39$ şi 0,21
- ▣ Semnătura: sub salturi de nivel, $\hat{d}(m)$ scade de la 0,83 la 0,34; logaritmul RV pentru S&P 500 rămîne între 0,51 şi 0,62, iar $W = 0,66$ este mult sub valoarea de 10%
- ▣ Memoria varianţei realizate trece acest test; secţiunea 5 arată că $|r_t|$ pentru BET şi EUR/RON nu îl trece

Persistența inflației și dezinflația



- Inflația lunară, % anualizat: IPC SUA (ajustat sezonier) pînă în august 2026, IAPC România (fără mediile lunare) pînă în august 2026; local Whittle exact cu media necunoscută, benzi de 95%; eşantionul complet și după dezinflație (SUA din 1985, România din 2005)

Interpretarea persistenței inflației

- SUA: $\hat{d} = 0,49$ (SE 0,06) pe 1960–2026, dar 0,22 după 1985; Qu $W = 1,62$ (valoarea de 1%: 1,45) respinge pentru eșantionul complet, $W = 0,55$ după 1985
- România: $\hat{d} = 0,70$ cu dezinflația din 1997–2004, 0,23 din 2005 (între 0,20 și 0,50 după lățimea de bandă); $W = 0,86$ și 1,04, cu doar 356 și 260 de luni
- Local Whittle simplu pe eșantionul complet pentru România dă 0,31: cu un salt de nivel asemănător unui trend, doar versiunea exactă cu media Shimotsu este de încredere
- În interiorul unui regim monetar stabil, inflația păstrează o memorie lungă moderată, $\hat{d} = 0,22$ și 0,23 Hassler și Wolters (1995), Baillie, Chung și Tieslau (1996); estimațiile mari aparțin schimbărilor de regim

Recapitulare: memorie scurtă sau lungă

- ▣ Rupturile, salturile de nivel și schimbările rare de regim creează un pol spectral și un $\hat{d}$ mare
- ▣ Diagnostic: $\hat{d}(m)$ scade cu m ; test: Qu (2011), cu valori critice simulate
- ▣ Inflația din SUA: memoria lungă provine în mare parte din Marea Inflație; logaritmul RV trece testul

Cointegrarea fracționară și FCVAR

- ▣ $X_t \in \mathbb{R}^p$ este $I(d)$; este **cointegrat fracționar** dacă $\beta' X_t$ este $I(d-b)$, $b > 0$ ([Capitolul 4](#) este cazul $d = b = 1$)
- ▣ FCVAR [Johansen și Nielsen \(2012\)](#): $\Delta^d X_t = \alpha \beta' L_b \Delta^{d-b} X_t + \sum_{i=1}^k \Gamma_i \Delta^d L_b^i X_t + \varepsilon_t$, $L_b = 1 - \Delta^b$
 - ▶ L_b este un decalaj fracționar ($L_1 = L$): cu $d = b = 1$ obținem VECM; α : ajustarea, β : vectorii de cointegrare, rangul r
- ▣ Estimare: pentru (d, b) fixat, modelul este o regresie de rang redus a lui $Z_0 = \Delta^d X$ pe $Z_1 = L_b \Delta^{d-b} X$; profilăm verosimilitatea în (d, b)
 - ▶ $\ell_r(d, b) = -\frac{T}{2} [\log \det S_{00} + \sum_{i \leq r} \log(1 - \hat{\lambda}_i)]$, $\hat{\lambda}_i$ valorile proprii Johansen
- ▣ Testele de rang: pentru $b < 1/2$, statistica trace LR este asimptotic $\chi^2_{(p-r)^2}$; pentru $b > 1/2$ se folosesc distribuțiile Dickey-Fuller fracționare din [MacKinnon și Nielsen \(2014\)](#)



Memorie comună semiparametrică

- ▣ Cele mai mici pătrate în bandă îngustă Robinson (1994), Christensen și Nielsen (2006):

$$\hat{\beta} = \text{Re} \sum_{j=1}^m I_{xy}(\lambda_j) / \sum_{j=1}^m I_{xx}(\lambda_j)$$

- ▶ doar frecvențele joase, acolo unde se află componenta comună cu memorie lungă: robust la corelația de termen scurt dintre x și eroare, care deplasează OLS
- ▣ Rangul prin ELW Nielsen și Shimotsu (2007): estimăm d pentru fiecare serie, testăm egalitatea lui d , apoi numărăm valorile proprii mici ale matricei spectrale de frecvență joasă
- ▣ Varianța implicită și cea realizată Bandi și Perron (2006): conține VIX componenta cu memorie lungă a varianței realizate viitoare?
 - ▶ dacă $\log RV$ și $\log VIX^2$ au un trend fracționar comun, o combinație are d mai mic, iar VIX prognozează partea persistentă

FCVAR: varianța realizată și cea implicită



- Logaritmul RV de 5 minute pentru S&P 500 și $\log(VIX^2/252)$, $n = 5523$ zile comune pînă la 25 februarie 2022; dreapta: log-verosimilitatea profilată a FCVAR de rang unu cu $k = 0$ în (d, b) , ultimele 60 de puncte logaritmice sub maxim

Interpretarea modelului FCVAR

- ▣ Local Whittle: $d = 0,62$ pentru logaritmul RV, $0,83$ pentru logaritmul VIX^2 , $0,49$ pentru combinația $\beta'X_t$ (SE $0,03$): combinația este mai puțin persistentă
- ▣ FCVAR: $\hat{d} = 0,88$, $\hat{b} = 0,42$, $\beta = (1; -1,70)$, $\alpha = (-1,55; 0,006)$: varianța realizată se ajustează, VIX nu (exogenitate slabă)
- ▣ Testele trace ($\hat{b} < 1/2$, deci χ^2): rangul 0 față de 2: $1453,94$ ($p < 0,001$); rangul 1 față de 2: $18,26$ ($p < 0,001$): cu $k = 0$ datele resping și ipoteza unei singure relații
- ▣ Panta NBLS a logaritmului RV pe logaritmul VIX^2 : $1,27$, față de $1/1,70 = 0,59$ implicată de FCVAR: dinamica de termen scurt ($k > 0$) și intervalul overnight al RV lipsesc; o întrebare de proiect

Recapitulare: cointegrarea fracționară

- FCVAR generalizează VECM cu doi parametri de memorie, d și b , estimați prin verosimilitate profilată și regresie de rang redus
- Testele de rang sînt χ^2 doar pentru $b < 1/2$; NBLS și ELW dau verificări semiparametrice
- Varianța realizată și cea implicită au componente persistente comune; structura exactă cere dinamica de termen scurt

FIGARCH

▣ GARCH(1,1) ca ARCH(∞): $\sigma_t^2 = \omega/(1 - \beta) + \sum_k \alpha \beta^{k-1} \varepsilon_{t-k}^2$: ponderi geometrice

▣ FIGARCH(1, d ,1) [Baillie, Bollerslev și Mikkelsen \(1996\)](#):

$$\sigma_t^2 = \frac{\omega}{1 - \beta} + \left[1 - \frac{(1 - \phi L)(1 - L)^d}{1 - \beta L} \right] \varepsilon_t^2 = \frac{\omega}{1 - \beta} + \sum_{k \geq 1} \lambda_k \varepsilon_{t-k}^2$$


► $\lambda_k \sim c k^{-d-1}$: ponderi hiperbolice; pozitivitatea cere de exemplu $\beta - d \leq \phi \leq (2 - d)/3$

▣ Paradoxul: $\sum_k \lambda_k = 1$, deci $\mathbb{E} \varepsilon_t^2 = \infty$: FIGARCH nu este staționar în covarianță pentru niciun $d > 0$, deși este strict staționar

► memoria lungă a lui ε_t^2 nu este deci definită printr-o autocovarianță

▣ HYGARCH [Davidson \(2004\)](#): $(1 - L)^d$ înlocuit cu $1 + a((1 - L)^d - 1)$; $a < 1$ dă o varianță finită și memorie hiperbolică, $a = 1$ este FIGARCH

Ponderi ARCH: geometrice și hiperbolice



- Randamentele zilnice ale S&P 500, 2000–2026 ($n = 6\,714$), QML cu distribuția Student t , ARCH(∞) trunchiat la 1000 de decalaje; GARCH (α, β) = (0,119; 0,876), FIGARCH $d = 0,61$, $\phi = 0,04$, $\beta = 0,59$

Interpretarea estimațiilor FIGARCH


Piața	$\hat{d}$	LR	$\hat{a}$	BIC GARCH	BIC FIGARCH	ponderea după decalajul 22
S&P 500	0,61	40,8	0,99	18197	18165	15% / 5%
BET	0,46	79,0	1,00	19514	19444	17% / 1%
Bitcoin	0,98	13,6	1,06	20942	20936	12% / 8%

- LR pentru FIGARCH față de GARCH (un parametru în plus): 40,8; 79,0; 13,6; BIC preferă FIGARCH pe toate cele trei piețe
- Ponderea șocurilor pătratice mai vechi de 22 de zile: FIGARCH 15%, GARCH 5% (S&P 500); după 250 de zile 2,0% față de practic zero
- Amplitudinea HYGARCH $\hat{a} = 0,99$ și 1,00: nicio evidență împotriva lui $a = 1$ (LR 0,22 și 0,01); pentru Bitcoin $\hat{d} = 0,98$ se află la marginea integrată
- LR: statistica raportului de verosimilitate pentru FIGARCH față de GARCH; $\hat{a}$: amplitudinea HYGARCH; ultima coloană: FIGARCH / GARCH

Volatilitate stochastică cu memorie lungă și zgomot

- ▣ LMSV Breidt, Crato și de Lima (1998): $r_t = \sigma_t \eta_t$, $\log \sigma_t^2 = \mu + h_t$, h_t ARFIMA(p, d, q); atunci $\log r_t^2 = \mu + \mathbb{E} \log \eta^2 + h_t + \xi_t$
 - ▶ $\xi_t = \log \eta_t^2 - \mathbb{E} \log \eta^2$: zgomot i.i.d. cu varianța $\pi^2/2$ pentru η gaussian, adesea mai mare decât $\text{Var}(h_t)$
- ▣ Spectrul lui $\log r_t^2$: $f(\lambda) = G\lambda^{-2d} + \sigma_\xi^2/(2\pi)$: zgomotul plat aplatizează panta de frecvență joasă și deplasează $\hat{d}$ în jos
 - ▶ LW cu zgomot Hurvich, Moulines și Soulier (2005): $f(\lambda) = G(\lambda^{-2d} + \theta)$, $\theta \geq 0$ estimat simultan; consistent, cu o viteză mai mică
- ▣ Varianța realizată reduce zgomotul prin medierea randamentelor intraday Andersen et al. (2003): $\log RV_t = \log IV_t + \text{o eroare mică}$
- ▣ Memoria lungă a volatilității în timp continuu: Comte și Renault (1998); alternativa rugoasă urmează în secțiunea 6

Memoria proxy-urilor de volatilitate pe mai multe piețe



- $\hat{d}$ local Whittle cu $m = n^{0.65}$ pentru $|r_t|$ și $\log(r_t^2 + c)$, $c = 1\%$ din varianță; LW cu zgomot pentru $\log(r_t^2 + c)$ cu $m = n^{0.8}$; logaritmul RV acolo unde există măsuri realizate (S&P 500, DAX până în 2022; Bitcoin până în 2026)



Interpretarea memoriei volatilității pe mai multe piețe

- ▣ S&P 500: $|r|$ 0,53, $\log r^2$ 0,44, cu zgomot 0,59, logaritmul RV 0,62: corecția de zgomot aduce $\log r^2$ la nivelul RV
- ▣ Bitcoin: $\log r^2$ 0,41, cu zgomot 0,66, logaritmul RV 0,53; DAX: 0,42; 0,59; 0,64
- ▣ Testul Qu pe $|r_t|$ (valoarea de 1%: 1,56): S&P 500 0,78, DAX 0,72, Bitcoin 0,79; BET 1,71 și EUR/RON 1,88 resping
- ▣ Pentru BET și leu, o parte a memoriei aparente vine din schimbări de regim (2008, regimul de managed float): modelați întâi rupturile ([Capitolul 2](#))

HAR ca aproximare a memoriei lungi

- ▣ HAR [Corsi \(2009\)](#): $y_{t+1} = \beta_0 + \beta_d y_t + \beta_w \bar{y}_t^{(5)} + \beta_m \bar{y}_t^{(22)} + u_{t+1}$, $y = \log RV$ ([Capitolul 8](#))
 - un AR(22) cu trei parametri liberi: o aproximare în trepte a ponderilor AR cu descreștere hiperbolică
- ▣ Formal, memorie scurtă: ACF scade geometric, dar pe orizonturi de pînă la cîteva luni imită k^{2d-1}
 - interpretarea în cascadă: participanți cu orizonturi zilnice, săptămînale și lunare (ipoteza pieței eterogene)
- ▣ Estimat prin OLS, ușor de extins (salturi, semivarianțe, [Capitolul 8](#)): reperul pe care orice model cu memorie lungă sau rugos trebuie să îl bată

Ponderile HAR și ACF implicată



- Logaritmul RV pentru S&P 500; HAR prin OLS: $\beta_d = 0,39$, $\beta_w = 0,40$, $\beta_m = 0,15$; stînga: ponderile AR implicate și $-\pi_k$ ARFIMA cu $d = 0,62$; dreapta: ACF a unei simulări lungi a HAR estimat și ACF de eşantion

Interpretarea aproximării HAR

- ▣ Suma ponderilor HAR 0,946: aproape de o rădăcină unitară, așa își obține persistența un model de memorie scurtă
- ▣ ACF la decalajul 100: eșantion 0,31, HAR 0,179; la 250: 0,18 față de 0,017
- ▣ ACF implicată scade sub jumătatea ACF de eșantion după decalajul 112: HAR captează memoria pînă la circa o jumătate de an
- ▣ Pentru prognoze de pînă la o lună aceasta ajunge, de aceea HAR este greu de bătut (secțiunea 7)

Recapitulare: memoria lungă a volatilității

- ▣ FIGARCH are ponderi ARCH hiperbolice, dar varianță infinită; HYGARCH îl include
- ▣ $\log r_t^2$ este memorie lungă plus zgomot mare: folosiți LW robust la zgomot sau măsurile realizate
- ▣ HAR este un model cu memorie scurtă care imită memoria lungă pe orizonturile relevante pentru prognoză

Mișcarea browniană fracționară



A. N. Kolmogorov

Foto: Konrad Jacobs; CC BY-SA 2.0 de;

Wikimedia Commons




B. B. Mandelbrot, TED 2010

Foto: Steve Jurvetson (2010); CC BY 2.0;

Wikimedia Commons

- W_t^H gaussian, $W_0^H = 0$, $\mathbb{E}W_t^H = 0$, $\mathbb{E}W_t^H W_s^H = \frac{1}{2}(t^{2H} + s^{2H} - |t - s|^{2H})$, $H \in (0, 1)$ Mandelbrot și Van Ness (1968)
 - creșteri staționare cu $\mathbb{E}|W_{t+\Delta}^H - W_t^H|^2 = \Delta^{2H}$; autosimilar: $W_{ct}^H \stackrel{d}{=} c^H W_t^H$
- Traectoriile sînt continue Hölder de orice ordin $< H$: $H < 1/2$ mai rugoase, $H > 1/2$ mai netede decît mișcarea browniană
- Creșterile (fGn): $\rho(k) = \frac{1}{2}(|k+1|^{2H} - 2|k|^{2H} + |k-1|^{2H}) \sim H(2H-1)k^{2H-2}$
 - memorie lungă pentru $H > 1/2$ ($d = H - 1/2$); corelație negativă pentru $H < 1/2$

Traectorii browniene fracționare



- O traiectorie pentru fiecare valoare, pe 1000 de pași, simulare exactă prin scufundare circulantă; $H = 0,5$ este mișcarea browniană

Interpretarea traiectoriilor

- ▣ Corelația de ordinul unu a creșterilor: $-0,426$ pentru $H = 0,1$, $-0,242$ pentru $H = 0,3$, 0 pentru $H = 0,5$, $0,320$ pentru $H = 0,7$
- ▣ $H = 0,1$: fiecare creștere este probabil urmată de o scădere, deci traiectoria este zimțată la toate scările, dar se abate puțin
- ▣ $H = 0,7$: trendurile persistă; aceasta este lectura fBm a efectului Hurst
- ▣ Rugozitatea este o afirmație despre scările mici, persistența despre cele mari: păstrați-le separate


Simularea fBm: Cholesky, scufundarea circulantă

- ▣ Cholesky: $\Gamma = LL'$, $X = LZ$; exact, dar cu timp $O(n^3)$ și memorie $O(n^2)$
- ▣ Davies–Harte [Davies și Harte \(1987\)](#), [Dietrich și Newsam \(1997\)](#): scufundăm matricea Toeplitz Γ a fGn într-o matrice circulantă de ordin $2(n-1)$ cu primul rând $(\gamma_0, \dots, \gamma_{n-1}, \gamma_{n-2}, \dots, \gamma_1)$
 - ▶ o matrice circulantă este diagonalizată de DFT: valorile proprii $\Lambda = \text{FFT}(c)$
 - ▶ dacă $\Lambda \geq 0$: $Y = \text{FFT}(\sqrt{\Lambda/M}(Z_1 + iZ_2))$; $\text{Re } Y$ și $\text{Im } Y$ sînt două traiectorii exacte independente
- ▣ $O(n \log n)$; pentru fGn $\Lambda \geq 0$ pentru orice H (Seminarul 10, A7); fBm = fGn cumulat
- ▣ Același algoritm simulează exact ARFIMA(0, d , 0) (folosit în fiecare experiment Monte Carlo din acest capitol)

Schema hibridă pentru procesele Volterra

- Modelele de rough volatility folosesc procese Volterra $X_t = \int_0^t g(t-s) dW_s$, de exemplu Riemann–Liouville $g(x) = x^{H-1/2}$, nu fBm cu creșteri staționare [Bayer, Friz și Gatheral \(2016\)](#)
 - scufundarea circulantă nu se aplică (proces nestaționar, posibil negaussian când este cuplat cu un preț corelat)
- Schema hibridă [Bennedsen, Lunde și Pakkanen \(2017\)](#): lângă singularitate integrăm nucleul exact (funcție putere înmulțită cu creșteri Wiener, gaussiene împreună); mai departe folosim o sumă Riemann în puncte optime
 - $X_i \approx \int_{t_{i-1}}^{t_i} (t_i - s)^{H-1/2} dW_s + \sum_{k \geq 2} (b_k/n)^{H-1/2} \Delta W_{i-k+1}$, $b_k = \left(\frac{k^{H+1/2} - (k-1)^{H+1/2}}{H+1/2} \right)^{1/(H-1/2)}$
- Suma este o convoluție: $O(n \log n)$ prin FFT; schema se extinde la procesele browniene semistaționare

Suma Riemann și schema hibridă



- $\text{Var}X(1)$ pentru procesul Riemann–Liouville, valoarea exactă $1/(2H)$; $n = 250$ pași, 4 000 de traiectorii



Interpretarea schemelor de simulare

- ▣ Suma Riemann înainte: 0,45 din varianța adevărată la $H = 0,05$ și 0,69 la $H = 0,1$: ratează masa nucleului de lângă singularitate
- ▣ Schema hibridă: 1,05 și 1,04, în limita erorii Monte Carlo față de 1
- ▣ Eroarea schemei naive crește exact acolo unde se află rough volatility ($H \approx 0,1$): prețurile opțiunilor obținute cu ea ar fi deplasate

Evidența: scalarea logaritmului volatilității

- Gatheral, Jaisson și Rosenbaum (2018), secțiunea 2: $\sigma_t = \sqrt{RV_t}$ zilnic din biblioteca Oxford-Man;
$$m(q, \Delta) = \frac{1}{N} \sum_t |\log \sigma_{t+\Delta} - \log \sigma_t|^q$$
 - dacă $\log \sigma$ are creșteri de tip fBm: $m(q, \Delta) = K_q \nu^q \Delta^{\zeta_q}$ cu $\zeta_q = qH$ (scalare monofractală)
- Procedura: OLS al lui $\log m(q, \Delta)$ pe $\log \Delta$ pentru fiecare q dă ζ_q ; regresăm ζ_q pe q prin origine pentru a obține H
 - folosim $q \in \{0,5; 1; 1,5; 2; 3\}$ și $\Delta = 1, \dots, 50$ de zile
- Rezultatul lor: ζ_q liniar și H de ordinul 0,1 pentru toți indicii; creșterile logaritmului volatilității sînt apropiate de distribuția Normală
- Aceasta contrazice orice model SV markovian (Heston, log-OU), al cărui logaritm al volatilității are $H = 1/2$ la decalaje scurte

Replicarea scalării pe S&P 500



- RV de 5 minute Oxford-Man pentru S&P 500, ianuarie 2000 – februarie 2022; stînga: $\log m(q, \Delta)$ și dreptele OLS; dreapta: ζ_q și dreapta qH


Interpretarea scalării

- ▣ $\zeta_q = 0,073; 0,146; 0,220; 0,295; 0,452$ pentru $q = 0,5; 1; 1,5; 2; 3$: liniar în q , $\hat{H} = 0,149$
- ▣ Volatilitatea volatilității $\hat{\nu} = 0,35$ din $m(2, \Delta) = \nu^2 \Delta^{2H}$; subeșantioane: 0,140 (2000–2010), 0,155 (2011–2022)
- ▣ Rezultatul lucrării se replică: aproximativ $H \approx 0,1$ –0,15, stabil în timp
- ▣ Legătura cu secțiunea 1: pe scara ARFIMA aceasta înseamnă $d = H + 1/2 \approx 0,65$, aproape de $\hat{d}$ local Whittle al logaritmului RV

Modelul RFSV

- ▣ Gatheral, Jaisson și Rosenbaum (2018): $\sigma_t = \exp(X_t)$, $dX_t = \nu dW_t^H - \alpha(X_t - m) dt$, un proces OU fracționar cu $H < 1/2$ și α foarte mic
 - ▶ pentru $\alpha T \ll 1$ creșterile se comportă ca ale lui νW^H ; staționaritatea apare doar pe orizonturi de ordinul $1/\alpha$
- ▣ Legătura cu memoria lungă: pe orizonturile observabile, $\log \sigma$ este aproape de o fBm nestăționară cu $H \approx 0,1$, a cărei lectură ARFIMA este $d = H + 1/2 \approx 0,6$
 - ▶ GJR arată că local Whittle și estimatori similari aplicați simulărilor RFSV dau valorile de „memorie lungă” găsite în literatură
- ▣ Evaluarea opțiunilor: rough Bergomi Bayer, Friz și Gatheral (2016) și rough Heston El Euch și Rosenbaum (2019) reproduc structura la termen a pantei volatilității implicite, $\propto \tau^{H-1/2}$, cu puțini parametri; estimările din opțiuni dau tot H mic Livieri et al. (2018)
 - ▶ partea de evaluare aparține MFM; aici testăm afirmația de serie de timp

Rugozitatea pe mai multe piețe și proxy-uri



- H din RV de 5 minute (Oxford-Man; Bitcoin: Binance) prin regresia momentelor și cu un termen liber pentru eroarea de măsurare; amplitudinea Parkinson din maximele și minimele zilnice EODHD pe aceleași zile, acolo unde există


Interpretarea rugozității pe mai multe piețe

- RV: H între 0,09 și 0,15 pentru șase indici și Bitcoin (S&P 500 0,15, DAX 0,13, Euro Stoxx 50 0,09, Bitcoin 0,10)
- Termenul liber pentru eroare schimbă puțin (S&P 500 0,15); doar pentru FTSE 100 absoarbe 31% din $m(2, 1)$
- Amplitudinea Parkinson, un proxy mult mai zgomotos: S&P 500 0,09, DAX 0,07; cu termenul liber 0,15 și 0,11 (ponderea zgomotului 52% și 42%)
- Eroarea de măsurare împinge H în jos; corecția aduce amplitudinea aproape de estimația din RV, dar nu peste ea

Critici: este rugozitatea un artefact?

- RV este o estimatie a varianței integrate: $\log RV_t = \log \int_{t-1}^t \sigma_s^2 ds + \epsilon_t$
 - două deplasări opuse: integrarea pe zi netezește (împinge $\hat{H}$ în sus), eroarea ϵ_t adaugă un salt la origine în $m(2, \Delta)$ (împinge $\hat{H}$ în jos)
- [Fukasawa, Takabatake și Westphal \(2022\)](#): un estimator de tip Whittle consistent sub asimptotica de înaltă frecvență cu eroare de măsurare; volatilitatea rămîne rugoasă, H chiar sub 0,1
 - [Bolko et al. \(2023\)](#): GMM pe momentele varianței integrate cu zgomot; tot H mic
- [Cont și Das \(2024\)](#): estimatorii de rugozitate aplicați RV pot raporta H mic chiar și pentru o volatilitate netedă (markoviană): un artefact de eșantion finit al proxy-ului
 - răspunsul depinde de mărimea erorii față de variația zilnică a logaritmului volatilității: simulați-o

Eroarea de măsurare și estimația lui H



- Logaritmul volatilității este un OU fracționar pe 78 de pași intraday pe zi, 2 500 de zile, 8 replicări; IV zilnic (fără eroare) și RV din cele 78 de randamente pătratice; estimatorul GJR


Interpretarea simulării

- ▣ H adevărat = 0,1: din IV 0,20, din RV 0,11, RV cu termen liber 0,11: deplasarea de integrare și cea de eroare aproape se anulează
- ▣ H adevărat = 0,5: IV 0,48, RV 0,43, cu termen liber 0,43; H adevărat = 0,3: 0,34; 0,28; 0,29
- ▣ Cu RV de 5 minute, eroarea este prea mică pentru a transforma $H = 0,5$ în valorile 0,1–0,15 observate în date
- ▣ Un proxy mai zgomotos (Parkinson, randamente pătratice) sau un alt model de volatilitate ar putea; concluzia depinde de acest design

Rugozitate și persistență

- În fBm un singur parametru le fixează pe amîndouă: H mic înseamnă traiectorii rugoase și (pentru creșteri) antipersistență
 - ▶ modelele Cauchy și cu nucleu gamma separă dimensiunea fractală (scări mici) de efectul Hurst (scări mari) Gneiting și Schlather (2004)
- Bennedsen, Lunde și Pakkanen (2022): modelul brownian semistaționar $X_t = \int_{-\infty}^t g(t-s) dW_s$, $g(x) \approx x^\alpha$ lângă 0 (rugozitate, $H = \alpha + 1/2$), $g(x) \approx x^{-\beta}$ la infinit (memorie)
 - ▶ rezultatul lor: logaritmul volatilității este atît rugos ($\alpha < 0$), cît și persistent ($\beta < 1$); cele două se estimează separat
- Verificarea empirică: panta variogramei la decalaje scurte față de descreșterea ACF la decalaje lungi

Scări mici și scări mari



- Logaritmul volatilității pentru S&P 500, decalaje 1–1000 de zile; stînga: variograma $m(2, \Delta)$ cu pantele pe decalajele 1–10 și 100–1000; dreapta: ACF de eșantion cu o ajustare k^{2d-1} pe decalajele 10–250

Interpretarea celor două scări

- ▣ Decalaje scurte: panta $2H = 0,32$, $H = 0,16$; decalaje lungi: panta $0,20$, încă în creștere la 1000 de zile, peste $2\text{Var}(\log \sigma)$
- ▣ Citită ca proces fracționar nestaționar, panta la decalaje lungi $2d - 1$ dă $d = 0,60$; local Whittle cu $m = 74$ dă $0,56$
- ▣ Ajustarea ACF dă doar $d = 0,31$: ACF de eșantion este deplasată în jos când d este aproape de $1/2$ sau peste
- ▣ Rugoasă la scări mici, foarte persistentă la scări mari: ambele afirmații sînt valabile pentru aceeași serie

Recapitulare: rough volatility

- ▣ fBm cu $H < 1/2$: traiectorii rugoase; se simulează exact prin scufundare circulantă, versiunile Volterra prin schema hibridă
- ▣ Scalarea logaritmului RV dă $H \approx 0,1-0,15$ pe toate piețele încercate, stabil în timp
- ▣ Eroarea de măsurare și integrarea zilnică deplasează $\hat{H}$ în direcții opuse; rugozitatea și persistența sînt proprietăți separate

Predictorul RFSV

- Pentru fBm (Nuzman–Poor), cu $\alpha \approx 0$, Gatheral, Jaisson și Rosenbaum (2018), secțiunea 5:

- ▶ $\mathbb{E}[\log \sigma_{t+h}^2 \mid \mathcal{F}_t] = \frac{\cos(H\pi)}{\pi} h^{H+1/2} \int_{-\infty}^t \frac{\log \sigma_s^2}{(t-s+h)(t-s)^{H+1/2}} ds$

- Nucleul are integrala unu: o medie ponderată a logaritmului varianței trecute, cu mai multă pondere pe trecutul recent pentru H mic


- ▶ discretizat pe zile: $w_k = \int_k^{k+1} du / ((u+h)u^{H+1/2})$, trunchiat la 500 de zile și normalizat

- Prognoza varianței: $\mathbb{E}[\sigma_{t+h}^2 \mid \mathcal{F}_t] = \exp(\mathbb{E}[\log \sigma_{t+h}^2 \mid \mathcal{F}_t] + 2c\nu^2 h^{2H})$, $c = \frac{\Gamma(3/2 - H)}{\Gamma(H + 1/2)\Gamma(2 - 2H)}$

- ▶ corecția lognormală folosește varianța condiționată a lui $\log \sigma$; cu valorile pentru S&P 500, $c = 0,707$

- Doi parametri (H, ν) , ambii din variogramă: fără verosimilitate, fără optimizare

Cît de departe privesc prognozele



- Nucleul RFSV cu $H = 0,15$ (S&P 500) pentru $h = 1$ și $h = 22$ de zile, față de ponderile HAR normalizate pentru $h = 1$


Interpretarea nucleelor

- ▣ $h = 1$: RFSV pune 68% pe ultima zi, 86% pe ultima săptămână, 95% pe ultima lună; HAR: 51% și 87%
- ▣ $h = 22$: doar 29% pe ultima zi, 71% pe ultima lună, 90% în ultimele 100 de zile: orizonturile mai lungi privesc mai departe în trecut
- ▣ Nucleul își adaptează automat memoria la orizont; HAR cere o regresie separată pentru fiecare orizont
- ▣ RFSV nu are revenire la medie: în perioadele calme lungi nu trage prognozele spre un nivel de termen lung

O comparație onestă în afara eșantionului

- ▣ Designul fixat dinainte: fereastră mobilă de 1000 de zile, parametrii reestimați la fiecare 20 de zile doar cu datele pînă la t ; ținta RV_{t+h} , $h \in \{1, 5, 22\}$
 - ▶ HAR: regresie directă a lui $\log RV_{t+h}$; ARFIMA(0, d , 0): d local Whittle (limitat la 0,49), AR(∞) iterat; RFSV: H , ν din fereastră
- ▣ Pierderea: QLIKE $L = RV/F - \log(RV/F) - 1$, robustă la zgomotul proxy-ului RV [Patton \(2011\)](#); și MSE al logaritmilor
 - ▶ prognozele de nivel din prognoze logaritmice cer corecția lognormală: $\exp(\hat{\mu} + \hat{\sigma}^2/2)$ pentru HAR și ARFIMA, $2c\nu^2 h^{2H}$ pentru RFSV
- ▣ Inferența: DM cu varianță Newey–West ([Capitolul 1](#)) [Diebold și Mariano \(1995\)](#); diferențele de pierderi sînt ele însele persistente, deci valorile p sînt optimiste

RFSV și ARFIMA față de HAR



- QLIKE mediu relativ la HAR (sub 1: mai bun decât HAR); o stea marchează o valoare p DM sub 5%; S&P 500 6 ianuarie 2004 – 24 ianuarie 2022 ($T = 4\,531$), DAX ($T = 4\,593$), Bitcoin 10 octombrie 2020 – 27 august 2026 ($T = 2\,144$)

Interpretarea comparației prognozelor

QLIKE / HAR	S&P 500		DAX		Bitcoin	
	ARFIMA	RFSV	ARFIMA	RFSV	ARFIMA	RFSV
$h = 1$	0,984	1,003	0,988	1,026	0,992	1,022
$h = 5$	1,006	0,964	0,996	0,969	1,025	1,174
$h = 22$	1,002	0,969	0,968	0,982	0,986	1,027

- S&P 500 și DAX: RFSV este cu 1,8% până la 3,6% mai bun decât HAR la 5 și 22 de zile, dar mai slab la o zi; DM la 5 zile: $-1,78$ (p 0,07) și $-1,62$ (p 0,11)
- Bitcoin: RFSV este mai slab la toate orizonturile (1,174 la 5 zile); $\hat{H}$ mobil variază între 0,04 și 0,15, cu mediana 0,08
- ARFIMA se află peste tot la cel mult 3,2% de HAR; dintre cele 18 comparații QLIKE, niciuna este semnificativă la 5%
- Rugozitatea este un fapt stilizat robust; câștigul ei în prognoză față de HAR este mic și depinde de orizont, ca în Gatheral, Jaisson și Rosenbaum (2018) și Wang, Xiao și Yu (2023)

Recapitulare: prognoza

- ▣ RFSV prognozează cu un nucleu putere dependent de orizont și o corecție lognormală, din doi parametri ai variogramei
- ▣ În afara eșantionului, RFSV, ARFIMA și HAR sînt apropiate; RFSV cîștigă cîteva procente la orizonturi săptămînale și lunare pentru indicii bursieri
- ▣ Preînregistrați designul, folosiți QLIKE și tratați cu prudență valorile p DM cînd diferențele de pierderi sînt persistente

O întrebare deschisă

- ▣ Este rugozitatea volatilității o proprietate a procesului de volatilitate sau a felului în care o măsurăm?
 - ▶ formal: $H_0: H \geq 0,3$ pentru varianța integrată; testat cu estimatori consistenți sub eroare de măsurare, pe active, măsuri și eșantioane preînregistrate
 - ▶ infirmată dacă estimațiile corectate rămân sub 0,2 pentru toate frecvențele de eșantionare și piețele
- ▣ Miza: modelele rugoase schimbă evaluarea opțiunilor și acoperirea; dacă rugozitatea este un artefact, modelele markoviene sînt suficiente
 - ▶ literatura de pornire: Gatheral, Jaisson și Rosenbaum (2018), Fukasawa, Takabatake și Westphal (2022), Bolko et al. (2023), Cont și Das (2024), Bennedsen, Lunde și Pakkanen (2022)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate din 2018 încoace care estimează exponentul Hurst al volatilității cu metode robuste la eroarea de măsurare; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** Ce procese generatoare cu $H = 0,5$ ar face ca estimatorul momentelor pe RV de 5 minute să dea H aproape de 0,1?
 - ▶ **cod și replicare:** cereți regresia pe variogramă, apoi reproduceți întâi valoarea pentru S&P 500 (0,149 aici) și tabelul de simulare
 - ▶ **critica:** Joacă rolul unui recenzent ostil: enumeră cum ar putea alegerea decalajelor, randamentele overnight, salturile și zgometul de microstructură să deplaseze H .
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Scara este precizată: H pentru fBm, d pentru ARFIMA, $H = d + 1/2$ pentru seriile staționare; logaritmul volatilității sau al varianței
- ▣ Lățimile de bandă, decalajele și trimming-ul sînt raportate, cu estimații pe un interval de valori, nu o singură alegere convenabilă
- ▣ Rupturile și salturile de nivel sînt testate (Qu) înainte de a afirma memoria lungă
- ▣ Comparațiile prognozelor sînt în afara eșantionului, preînregistrate, cu QLIKE și DM

Mini studiu de caz: cât de robust este „ H de ordinul 0,1”?



- 70 de celule: șapte active $\times$ cinci măsuri realizate $\times$ două jumătăți ale eșantionului; doi estimatori pentru fiecare (140 de estimări); dreapta: H față de d local Whittle din aceeași celulă
- H între 0,06 și 0,24, mediana 0,13 (momente 0,12, cu termen liber 0,14); 96% sub 0,2; d între 0,47 și 0,68; corelația dintre H și d 0,24: un rezumat AI care numește volatilitatea „cu memorie scurtă pentru că $H < 1/2$ ” greșește

Idee de proiect

- ▣ **Rugozitatea și persistența volatilității pe piețele din Europa Centrală și de Est:** întâi replicare, apoi extindere
 - ▶ replicați: Gatheral, Jaisson și Rosenbaum (2018), secțiunea 2 pe datele Oxford-Man pentru S&P 500 ($H = 0,149$ aici) și comparația prognozelor din secțiunea 5
 - ▶ extindeți: date intraday pentru BET, WIG20 și EUR/RON; estimatori robuști la zgomot (FTW, GMM); teste Qu; un model BSS cu rugozitate și memorie separate
 - ▶ preînregistrați: activele, măsurile, decalajele, lățimile de bandă, designul prognozei și pierderea
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Memoria lungă este un pol în frecvența zero; estimați-o cu local Whittle sau local Whittle exact și raportați $\hat{d}(m)$
- ▣ Salturile de nivel imită memoria lungă: testați cu Qu (2011) și urmăriți semnătura lățimii de bandă
- ▣ Volatilitatea este persistentă pe luni (FIGARCH, LMSV, HAR) și rugoasă pe zile ($H \approx 0,1$)
- ▣ Proxy-urile contează: zgomotul scade $\hat{d}$ și $\hat{H}$; corecțiile există și trebuie raportate
- ▣ În prognoză, HAR rămîne un reper greu de bătut; modelele rugoase cîștigă puțin și doar la unele orizonturi

Autoevaluare

Întrebări

- ▣ De ce este varianța asimptotică a local Whittle $1/(4m)$, iar a GPH $\pi^2/(24m)$?
- ▣ De ce eșuează local Whittle pentru $d > 1$ și cum corectează local Whittle exact problema?
- ▣ Ce formă spectrală produce un salt aleator de nivel?
- ▣ De ce nu este FIGARCH staționar în covarianță?
- ▣ Cum poate o serie să fie rugoasă și cu memorie lungă în același timp?

Urmează:

- ▣ Analiză spectrală și analiză wavelet
- ▣ multitaper, coerență, wavelets: instrumentele de frecvență din spatele acestui capitol

Anexă: varianța estimatorului local Whittle

- ▣ Dezvoltăm $R'(\hat{d}) = 0$ în jurul lui d : $\sqrt{m}(\hat{d} - d) = -\sqrt{m}R'(d)/R''(\bar{d})$
- ▣ $\sqrt{m}R'(d) = \frac{2}{\sqrt{m}} \sum_j \nu_j(\xi_j - 1) + o_p(1)$, $\xi_j = \lambda_j^{2d} I(\lambda_j)/G$; cu $\text{Var}\xi_j \rightarrow 1$ și $\frac{1}{m} \sum \nu_j^2 \rightarrow 1$: $\rightarrow N(0, 4)$
- ▣ $R''(d) = \frac{4}{m} \sum_j \nu_j^2 \xi_j / \bar{\xi} - \left(\frac{2}{m} \sum_j \nu_j \xi_j / \bar{\xi} \right)^2 \rightarrow_p 4$
- ▣ Deci $\sqrt{m}(\hat{d} - d) \rightarrow N(0, 4/16) = N(0, 1/4)$; la GPH aceleași ponderi înmulțesc $\log \xi_j$ cu varianța $\pi^2/6$: $N(0, \pi^2/24)$

Anexă: scalarea momentelor fBm

- $W_{t+\Delta}^H - W_t^H \sim N(0, \Delta^{2H})$, deci $\mathbb{E}|W_{t+\Delta}^H - W_t^H|^q = \Delta^{qH} \mathbb{E}|Z|^q$, $\mathbb{E}|Z|^q = 2^{q/2} \Gamma(\frac{q+1}{2}) / \sqrt{\pi}$
- Cu $\log \sigma_t = \nu W_t^H$: $\log m(q, \Delta) = q \log \nu + \log \mathbb{E}|Z|^q + qH \log \Delta$: panta $\zeta_q = qH$
- Abateri: ζ_q concav semnalează multifractalitate sau cozi groase; un termen liber în $m(2, \Delta) = \nu^2 \Delta^{2H} + 2s^2$ semnalează o eroare de măsurare i.i.d. cu varianța s^2
- Spectrul fGn lângă zero: $f(\lambda) \propto |\lambda|^{1-2H}$, adică creșterile sînt de tip ARFIMA cu $d = H - 1/2$

Bibliografie (1/4)

- Andersen, T. G., Bollerslev, T., Diebold, F. X., & Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2), 579–625. doi:10.1111/1468-0262.00418
- Andrews, D. W. K., & Sun, Y. (2004). Adaptive local polynomial Whittle estimation of long-range dependence. *Econometrica*, 72(2), 569–614. doi:10.1111/j.1468-0262.2004.00501.x
- Baillie, R. T., Bollerslev, T., & Mikkelsen, H. O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30. doi:10.1016/S0304-4076(95)01749-6
- Baillie, R. T., Chung, C.-F., & Tieslau, M. A. (1996). Analysing inflation by the fractionally integrated ARFIMA–GARCH model. *Journal of Applied Econometrics*, 11(1), 23–40. doi:10.1002/(SICI)1099-1255(199601)11:1<23::AID-JAE374>3.0.CO;2-M
- Bandi, F. M., & Perron, B. (2006). Long memory and the relation between implied and realized volatility. *Journal of Financial Econometrics*, 4(4), 636–670. doi:10.1093/jjfinec/nbl003
- Bayer, C., Friz, P., & Gatheral, J. (2016). Pricing under rough volatility. *Quantitative Finance*, 16(6), 887–904. doi:10.1080/14697688.2015.1099717
- Bennedsen, M., Lunde, A., & Pakkanen, M. S. (2022). Decoupling the short- and long-term behavior of stochastic volatility. *Journal of Financial Econometrics*, 20(5), 961–1006. doi:10.1093/jjfinec/nbaa049
- Bennedsen, M., Lunde, A., & Pakkanen, M. S. (2017). Hybrid scheme for Brownian semistationary processes. *Finance and Stochastics*, 21(4), 931–965. doi:10.1007/s00780-017-0335-5
- Beran, J., Feng, Y., Ghosh, S., & Kulik, R. (2013). *Long-Memory Processes: Probabilistic Properties and Statistical Methods*. Springer. doi:10.1007/978-3-642-35512-7
- Bolko, A. E., Christensen, K., Pakkanen, M. S., & Veliyev, B. (2023). A GMM approach to estimate the roughness of stochastic volatility. *Journal of Econometrics*, 235(2), 745–778. doi:10.1016/j.jeconom.2022.06.009
- Breidt, F. J., Crato, N., & de Lima, P. (1998). The detection and estimation of long memory in stochastic volatility. *Journal of Econometrics*, 83(1–2), 325–348. doi:10.1016/S0304-4076(97)00072-9
- Christensen, B. J., & Nielsen, M. Ø. (2006). Asymptotic normality of narrow-band least squares in the stationary fractional cointegration model and volatility forecasting. *Journal of Econometrics*, 133(1), 343–371. doi:10.1016/j.jeconom.2005.03.018
- Comte, F., & Renault, E. (1998). Long memory in continuous-time stochastic volatility models. *Mathematical Finance*, 8(4), 291–323. doi:10.1111/1467-9965.00057
- Cont, R., & Das, P. (2024). Rough volatility: Fact or artefact? *Sankhya B*, 86(1), 191–223. doi:10.1007/s13571-024-00322-2

Bibliografie (2/4)

- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jffinec/nbp001
- ▣ Davidson, J. (2004). Moment and memory properties of linear conditional heteroscedasticity models, and a new model. *Journal of Business & Economic Statistics*, 22(1), 16–29. doi:10.1198/073500103288619359
- ▣ Davies, R. B., & Harte, D. S. (1987). Tests for Hurst effect. *Biometrika*, 74(1), 95–101. doi:10.1093/biomet/74.1.95
- ▣ Diebold, F. X., & Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159. doi:10.1016/S0304-4076(01)00073-2
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Dietrich, C. R., & Newsam, G. N. (1997). Fast and exact simulation of stationary Gaussian processes through circulant embedding of the covariance matrix. *SIAM Journal on Scientific Computing*, 18(4), 1088–1107. doi:10.1137/S1064827592240555
- ▣ El Euch, O., & Rosenbaum, M. (2019). The characteristic function of rough Heston models. *Mathematical Finance*, 29(1), 3–38. doi:10.1111/mafi.12173
- ▣ Fox, R., & Taqqu, M. S. (1986). Large-sample properties of parameter estimates for strongly dependent stationary Gaussian time series. *The Annals of Statistics*, 14(2), 517–532. doi:10.1214/aos/1176349936
- ▣ Fukasawa, M., Takabatake, T., & Westphal, R. (2022). Consistent estimation for fractional stochastic volatility model under high-frequency asymptotics. *Mathematical Finance*, 32(4), 1086–1132. doi:10.1111/mafi.12354
- ▣ Gatheral, J., Jaisson, T., & Rosenbaum, M. (2018). Volatility is rough. *Quantitative Finance*, 18(6), 933–949. doi:10.1080/14697688.2017.1393551
- ▣ Geweke, J., & Porter-Hudak, S. (1983). The estimation and application of long memory time series models. *Journal of Time Series Analysis*, 4(4), 221–238. doi:10.1111/j.1467-9892.1983.tb00371.x
- ▣ Gneiting, T., & Schlather, M. (2004). Stochastic models that separate fractal dimension and the Hurst effect. *SIAM Review*, 46(2), 269–282. doi:10.1137/S0036144501394387
- ▣ Granger, C. W. J., & Hyung, N. (2004). Occasional structural breaks and long memory with an application to the S&P 500 absolute stock returns. *Journal of Empirical Finance*, 11(3), 399–421. doi:10.1016/j.jempfin.2003.03.001
- ▣ Granger, C. W. J., & Joyeux, R. (1980). An introduction to long-memory time series models and fractional differencing. *Journal of Time Series Analysis*, 1(1), 15–29. doi:10.1111/j.1467-9892.1980.tb00297.x

Bibliografie (3/4)

- ▣ Granger, C. W. J. (1980). Long memory relationships and the aggregation of dynamic models. *Journal of Econometrics*, 14(2), 227–238. doi:10.1016/0304-4076(80)90092-5
- ▣ Hassler, U., & Wolters, J. (1995). Long memory in inflation rates: International evidence. *Journal of Business & Economic Statistics*, 13(1), 37–45. doi:10.1080/07350015.1995.10524577
- ▣ Heber, G., Lunde, A., Shephard, N., & Sheppard, K. K. (2009). Oxford-Man Institute's realized library, version 0.3. Oxford-Man Institute, University of Oxford. web.archive.org
- ▣ Henry, M., & Robinson, P. M. (1996). Bandwidth choice in Gaussian semiparametric estimation of long range dependence. In *Athens Conference on Applied Probability and Time Series Analysis*, Lecture Notes in Statistics 115, 220–232. Springer. doi:10.1007/978-1-4612-2412-9_16
- ▣ Hosking, J. R. M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176. doi:10.1093/biomet/68.1.165
- ▣ Hurst, H. E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770–799. doi:10.1061/TACEAT.0006518
- ▣ Hurvich, C. M., Deo, R., & Brodsky, J. (1998). The mean squared error of Geweke and Porter-Hudak's estimator of the memory parameter of a long-memory time series. *Journal of Time Series Analysis*, 19(1), 19–46. doi:10.1111/1467-9892.00075
- ▣ Hurvich, C. M., Moulines, E., & Soulier, P. (2005). Estimating long memory in volatility. *Econometrica*, 73(4), 1283–1328. doi:10.1111/j.1468-0262.2005.00616.x
- ▣ Johansen, S., & Nielsen, M. Ø. (2012). Likelihood inference for a fractionally cointegrated vector autoregressive model. *Econometrica*, 80(6), 2667–2732. doi:10.3982/ECTA9299
- ▣ Livieri, G., Mouti, S., Pallavicini, A., & Rosenbaum, M. (2018). Rough volatility: Evidence from option prices. *IIEE Transactions*, 50(9), 767–776. doi:10.1080/24725854.2018.1444297
- ▣ Lu, Y. K., & Perron, P. (2010). Modeling and forecasting stock return volatility using a random level shift model. *Journal of Empirical Finance*, 17(1), 138–156. doi:10.1016/j.jempfin.2009.10.001
- ▣ MacKinnon, J. G., & Nielsen, M. Ø. (2014). Numerical distribution functions of fractional unit root and cointegration tests. *Journal of Applied Econometrics*, 29(1), 161–171. doi:10.1002/jae.2295
- ▣ Mandelbrot, B. B., & Van Ness, J. W. (1968). Fractional Brownian motions, fractional noises and applications. *SIAM Review*, 10(4), 422–437. doi:10.1137/1010093
- ▣ Nielsen, M. Ø., & Shimotsu, K. (2007). Determining the cointegrating rank in nonstationary fractional systems by the exact local Whittle approach. *Journal of Econometrics*, 141(2), 574–596. doi:10.1016/j.jeconom.2006.10.008

Bibliografie (4/4)

- ▣ Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *The Journal of Business*, 53(1), 61–65. doi:10.1086/296071
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Perron, P., & Qu, Z. (2010). Long-memory and level shifts in the volatility of stock market return indices. *Journal of Business & Economic Statistics*, 28(2), 275–290. doi:10.1198/jbes.2009.06171
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Phillips, P. C. B., & Shimotsu, K. (2004). Local Whittle estimation in nonstationary and unit root cases. *The Annals of Statistics*, 32(2), 656–692. doi:10.1214/0090536040000000139
- ▣ Qu, Z. (2011). A test against spurious long memory. *Journal of Business & Economic Statistics*, 29(3), 423–438. doi:10.1198/jbes.2010.09153
- ▣ Robinson, P. M. (1995a). Log-periodogram regression of time series with long range dependence. *The Annals of Statistics*, 23(3), 1048–1072. doi:10.1214/aos/1176324636
- ▣ Robinson, P. M. (1995b). Gaussian semiparametric estimation of long range dependence. *The Annals of Statistics*, 23(5), 1630–1661. doi:10.1214/aos/1176324317
- ▣ Robinson, P. M. (1994). Semiparametric analysis of long-memory time series. *The Annals of Statistics*, 22(1), 515–539. doi:10.1214/aos/1176325382
- ▣ Shimotsu, K. (2010). Exact local Whittle estimation of fractional integration with unknown mean and time trend. *Econometric Theory*, 26(2), 501–540. doi:10.1017/S0266466609100075
- ▣ Shimotsu, K., & Phillips, P. C. B. (2005). Exact local Whittle estimation of fractional integration. *The Annals of Statistics*, 33(4), 1890–1933. doi:10.1214/0090536050000000309
- ▣ Velasco, C. (1999). Gaussian semiparametric estimation of non-stationary time series. *Journal of Time Series Analysis*, 20(1), 87–127. doi:10.1111/1467-9892.00127
- ▣ Wang, X., Xiao, W., & Yu, J. (2023). Modeling and forecasting realized volatility with the fractional Ornstein–Uhlenbeck process. *Journal of Econometrics*, 232(2), 389–415. doi:10.1016/j.jeconom.2021.08.001