



Analiza avansată a seriilor de timp și previziune

Capitolul 11: Analiză spectrală și analiză wavelet



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AIC:** Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARMA:** AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BC:** Breitung–Candelon (frequency-domain causality test) — testul de cauzalitate în domeniul frecvenței Breitung–Candelon
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BK:** Baxter–King (band-pass filter) — filtrul trece-bandă Baxter–King
- ▣ **BUX:** Budapesti Értéktőzsde index (indicele Bursei din Budapesta)
- ▣ **CF:** Christiano–Fitzgerald (band-pass filter) — filtrul trece-bandă Christiano–Fitzgerald
- ▣ **CFR:** Croux, Forni and Reichlin (2001) — Croux, Forni și Reichlin (2001)
- ▣ **COI:** Cone Of Influence (of a wavelet transform) — conul de influență al transformatei wavelet
- ▣ **CWT:** Continuous Wavelet Transform (transformata wavelet continuă)
- ▣ **DCC-GARCH:** Dynamic Conditional Correlation GARCH (model GARCH cu corelație condiționată dinamică)

Acronime folosite în acest material (2/3)

- ▣ **DFT**: Discrete Fourier Transform (transformata Fourier discretă)
- ▣ **DPSS**: Discrete Prolate Spheroidal Sequences (Slepian tapers) — șiruri sferoidale prolate discrete (taper-ele Slepian)
- ▣ **DWT**: Discrete Wavelet Transform (transformata wavelet discretă)
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **FFT**: Fast Fourier Transform (transformata Fourier rapidă)
- ▣ **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- ▣ **HICP**: Harmonised Index of Consumer Prices (indicele armonizat al prețurilor de consum (IAPC))
- ▣ **HP**: Hodrick–Prescott (filter) — filtrul Hodrick–Prescott
- ▣ **LA**: Least Asymmetric (Daubechies wavelet filter) — filtrul wavelet Daubechies cel mai puțin asimetric
- ▣ **LLM**: Large Language Model (model lingvistic de mari dimensiuni)

Acronime folosite în acest material (3/3)

- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MODWT**: Maximal Overlap Discrete Wavelet Transform (transformata wavelet discretă cu suprapunere maximă)
- ▣ **MRA**: MultiResolution Analysis (analiza multirezoluție)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **PIB**: Produsul intern brut
- ▣ **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — indicele Bursei din Praga
- ▣ **QS**: Quadratic Spectral (kernel) — nucleul spectral pătratic
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **SSA**: Singular Spectrum Analysis (analiza spectrului singular)
- ▣ **SVD**: Singular Value Decomposition (descompunerea valorilor singulare)
- ▣ **TSA**: Time Series Analysis (Serii de timp, cursul de licență)
- ▣ **US**: United States (Statele Unite ale Americii)
- ▣ **VAR**: Vector AutoRegression (model vector autoregresiv)
- ▣ **VARMA**: Vector AutoRegressive Moving Average (model — model vectorial autoregresiv cu medie mobilă)
- ▣ **WIG20**: Warszawski Indeks Giełdowy 20 (indicele celor mai mari 20 de companii de la Bursa din Varșovia)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum se distribuie pe frecvențe varianța unei serii de timp și co-mișcarea a două serii și cum se schimbă această distribuție în timp?
 - ▶ ciclurile de lungimi diferite răspund unor întrebări economice diferite: ciclul economic, sezonalitatea, reacția piețelor într-o săptămână
- ▣ **Traseul** capitolului
 - ▶ reprezentarea spectrală; teoria estimării: consistență, lățime de bandă, multitaper
 - ▶ două serii: coerență, fază, corelație dinamică, cauzalitate în domeniul frecvenței
 - ▶ filtre trece-bandă și critica lui Hamilton la adresa filtrului HP; România și zona euro
 - ▶ spectre evolutive; wavelets: MODWT, varianța și corelația pe scale, coerența wavelet
- ▣ Pornim de la [TSA, Capitolul 12](#) (periodogramă, netezire, testul lui Fisher, coerență), de la [Capitolul 6](#) (spațiul stărilor) și de la [Capitolul 10](#) (polul spectral al memoriei lungi); Seminarul 11 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Enunțați reprezentarea spectrală a unui proces staționar și derivați spectrul unui proces filtrat
- ▣ Derivați deplasarea și varianța estimatorilor cu fereastră de laguri, alegeți lățimea de bandă și construiți estimări multitaper cu benzi de încredere valide
- ▣ Estimați și testați coerența, faza, câștigul și corelația dinamică și testați cauzalitatea Granger la o frecvență dată
- ▣ Evaluați filtrele de tendință și ciclu prin funcția lor de câștig și măsurați sincronizarea ciclurilor economice
- ▣ Descompuneți varianța și corelația pe scale prin MODWT și testați coerența wavelet prin Monte Carlo

Bibliografie, date și instrumente


- Teoria și estimarea spectrală: Brockwell și Davis (1991); Percival și Walden (1993); Shumway și Stoffer (2017); Thomson (1982)
 - ▶ Wavelets: Percival și Walden (2000); Torrence și Compo (1998); Grinsted, Moore și Jevrejeva (2004); Aguiar-Conraria și Soares (2014)
 - ▶ Ciclul economic: Baxter și King (1999); Christiano și Fitzgerald (2003); Hamilton (2018); Croux, Forni și Reichlin (2001)
 - ▶ Sinteză despre practica prognozei: Petropoulos et al. (2022)
- Quantlet-urile Python ale capitolului: [Quantlets/Ch_11](#)
 - ▶ spectre, multitaper, spectre încrucișate, Geweke și Breitung–Candelon, filtre, MODWT, transformata Morlet și coerența wavelet scrise în `numpy/scipy`; `PyWavelets` furnizează filtrele wavelet
- Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Eșantionul
PIB real: România, zona euro, Polonia, Ungaria, Cehia	Eurostat, volume înălțuite, ajustate sezonier și pentru zilele lucrătoare, trimestrial	T1 1995 – T2 2026
Producția industrială: România, zona euro	Eurostat, lunar, ajustată și neajustată	ianuarie 2000 – iulie 2026
Inflația anuală HICP: România, Polonia, zona euro	Eurostat, lunar	ianuarie 2001 – august 2026
BET, DAX, S&P 500	închideri zilnice EODHD; randamente săptămânale din închiderile de vineri	2000 – 2026
Petrol Brent	FRED (US Energy Information Administration), zilnic	2000 – 2026

- Ratele de creștere și randamentele sînt diferențe logaritmice înmulțite cu 100; ciclurile sînt în % din tendință; piețele sînt aliniate pe zilele comune de tranzacționare

De la analiza armonică la seriile de timp



Norbert Wiener

Foto: Konrad Jacobs, MFO; CC BY-SA 2.0 de;

Wikimedia Commons

- 1930: analiza armonică generalizată a lui Wiener; 1934: Hincin; autocovarianța și spectrul formează o pereche Fourier
- 1942: reprezentarea lui Cramér a unui proces staționar ca suprapunere aleatoare de sinusoide
- 1961–1966: ferestre de laguri Parzen (1961); forma spectrală tipică a variabilelor economice Granger (1966)
- 1982: estimarea multitaper Thomson (1982); cauzalitatea în domeniul frecvenței Geweke (1982)
- 1984–1989: wavelets Grossmann și Morlet (1984), Daubechies (1988), Mallat (1989); 1998: ghidul practic Torrence și Compo (1998)

Cunoscut din TSA și elemente noi

- Cunoscut (TSA, Capitolul 12): frecvențele Fourier, spectrul modelelor ARMA, periodograma și legea ei χ^2_2 , netezirea Daniell, ponderarea datelor (taper), testul lui Fisher, o primă privire asupra coerenței și a wavelets
- Nou: instrumentele de cercetare
 - ▶ teoria asimptotică a estimatorilor spectrali: deplasare, varianță, lățime de bandă optimă, benzi de încredere valide, multitaper
 - ▶ inferență asupra co-mișcării: praguri pentru coerență, erorile fazei, corelația dinamică, cauzalitatea pe frecvențe
 - ▶ filtre judecate după câștig; analiză timp–frecvență cu teste de semnificație care controlează descoperirile false
- Studii de caz, cu specificațiile din lucrări, pe datele noastre
 - ▶ spectrale: Thomson (1982); Croux, Forni și Reichlin (2001); Breitung și Candelon (2006)
 - ▶ filtre și wavelets: Baxter și King (1999); Cogley și Nason (1995); Hamilton (2018); Torrence și Compo (1998); Grinsted, Moore și Jevrejeva (2004)

Autocovarianța și distribuția spectrală (1/2)

- **Herglotz Brockwell și Davis (1991):** $\gamma(\cdot)$ este autocovarianța unui proces staționar dacă și numai dacă

$$\gamma(h) = \int_{(-\pi, \pi]} e^{i\omega h} dF(\omega)$$

- $\gamma(h) = \text{Cov}(X_{t+h}, X_t)$; ω : frecvența unghiulară, în radiani pe perioadă; F : **distribuția spectrală**, nedescrescătoare, continuă la dreapta și mărginită

- Dacă $\sum_h |\gamma(h)| < \infty$, F are o densitate, **densitatea spectrală**

$$dF(\omega) = f(\omega) d\omega, \quad f(\omega) = \frac{1}{2\pi} \sum_h \gamma(h) e^{-i\omega h}$$

Autocovarianța și distribuția spectrală (2/2)

- Pentru $h = 0$: spectrul este o **descompunere a varianței pe frecvențe**

$$\gamma(0) = \text{Var}(X_t) = \int_{-\pi}^{\pi} f(\omega) d\omega$$

- ▶ $f(\omega) d\omega$: varianța adusă de ciclurile cu frecvența apropiată de ω ; perioada $2\pi/\omega$
- ▶ date trimestriale: banda ciclului economic de 6–32 de trimestre este $\omega \in [\pi/16, \pi/3]$
- Un salt al lui F în $\pm\omega_0$ este un ciclu determinist (un **spectru de linii**); memoria lungă este un pol al lui f în $\omega = 0$ ([Capitolul 10](#))

Reprezentarea lui Cramér



Harald Cramér, 1951

Foto: fotograf necunoscut, Svenska Dagbladet (1951); domeniu public; Wikimedia Commons

- Orice proces staționar de medie zero este o sumă de sinusoide cu amplitudini aleatoare [Brockwell și Davis \(1991\)](#)

$$X_t = \int_{(-\pi, \pi]} e^{i\omega t} dZ(\omega)$$

- ▶ $dZ(\omega)$: amplitudinea aleatoare la frecvența ω ; Z are **creșteri ortogonale**: $\mathbb{E}[dZ(\omega)\overline{dZ(\lambda)}] = 0$ pentru $\omega \neq \lambda$, $\mathbb{E}|dZ(\omega)|^2 = dF(\omega)$

- Amplitudinile aleatoare de la frecvențe diferite sînt necorelate: componentele de frecvență se pot studia separat
- Transformata Fourier discretă (DFT) în frecvențele Fourier $\omega_j = 2\pi j/n$

$$d(\omega_j) = n^{-1/2} \sum_{t=1}^n x_t e^{-i\omega_j t}$$

- ▶ analogul de eșantion al lui $dZ(\omega_j)$: aproape necorelată între frecvențele Fourier

Filtre liniare în domeniul frecvenței

- Un filtru liniar înmulțește fiecare componentă de frecvență cu **funcția de transfer** $A(\omega)$

$$Y_t = \sum_j a_j X_{t-j} \Rightarrow dZ_Y(\omega) = A(\omega) dZ_X(\omega), \quad A(\omega) = \sum_j a_j e^{-i\omega j}$$

$$f_Y(\omega) = |A(\omega)|^2 f_X(\omega)$$

- ▶ a_j : ponderile filtrului, $\sum_j |a_j| < \infty$; $|A(\omega)|$: **cîștigul**; $\arg A(\omega)$: **defazajul**
- ▶ ponderi simetrice $a_j = a_{-j}$: $A(\omega)$ este real, fără defazaj; proprietatea dorită de orice filtru de tendință și ciclu
- Prima diferență: $|1 - e^{-i\omega}|^2 = 2(1 - \cos \omega)$, nulă în $\omega = 0$
 - ▶ diferențierea elimină ciclurile lungi și le amplifică pe cele scurte
- Efectul Slutsky: o sumă mobilă a unui zgomot alb are un vîrf în spectru, adică **cicluri create de filtru**; critica filtrului HP din secțiunea 4 este același fenomen

Matricea densităților spectrale (1/2)

- Proces vectorial X_t de dimensiune k : transformata Fourier a matricelor de autocovarianță

$$f(\omega) = \frac{1}{2\pi} \sum_h \Gamma(h) e^{-i\omega h}, \quad \Gamma(h) = \text{Cov}(X_{t+h}, X_t)$$

- ▶ $f(\omega)$: o matrice $k \times k$ hermitică ($f = f^*$, transpusa conjugată) și nenegativ definită la fiecare frecvență

- VARMA $\Phi(L)X_t = \Theta(L)\varepsilon_t$: analogul multivariat al spectrului ARMA

$$f(\omega) = \frac{1}{2\pi} \Phi(e^{-i\omega})^{-1} \Theta(e^{-i\omega}) \Sigma \Theta(e^{-i\omega})^* \Phi(e^{-i\omega})^{-*}$$

- ▶ Φ, Θ : polinoamele matriceale AR și MA; Σ : covarianța inovațiilor ε_t ; $^{-*}$: inversa transpusei conjugate


Matricea densităților spectrale (2/2): spectrele încrucișate

- ▣ Elementele din afara diagonalei: **spectrul încrucișat**, cu valori complexe

$$f_{xy}(\omega) = c_{xy}(\omega) - i q_{xy}(\omega)$$

- ▶ c_{xy} : cospectrul, par în ω (co-mișcare simultană), $\int c_{xy} = \text{Cov}(X_t, Y_t)$
- ▶ q_{xy} : spectrul în cuadratură, impar în ω (avans-întârziere între serii)
- ▣ Secțiunea 2 estimează diagonala, secțiunea 3 elementele din afara diagonalei, iar secțiunea 4 factorizează f pentru a măsura cauzalitatea

Varianța pe benzi de frecvență



- O traiectorie $AR(2)$, $X_t = 1,3X_{t-1} - 0,7X_{t-2} + \varepsilon_t$, 240 de „trimestre”, separată prin DFT în trei benzi; ponderile varianței în eșantion și $2 \int_{banda} f / \gamma(0)$ în teorie

Interpretarea descompunerii pe benzi

- ▣ Vîrful spectral se află la perioada 9,5: 84% din varianță se află în banda de 6–32 de perioade (în eșantion: 84%)
- ▣ Ciclurile lungi și cele scurte au 9% și 7% în teorie: cele trei componente sînt necorelate conform teoremei lui Cramér, deci ponderile se adună
- ▣ „Ciclul economic” al unui $AR(2)$ este un pseudo-ciclu stochastic: amplitudine și lungime neregulate, fără linie în spectru
- ▣ Filtrele trece-bandă (secțiunea 4) estimează exact această componentă din mijloc pe un eșantion finit

Recapitulare: reprezentarea spectrală

- Spectrul descompune varianța pe frecvențe; Cramér: amplitudini aleatoare necorelate la fiecare frecvență
- Un filtru liniar înmulțește spectrul cu pătratul câștigului; filtrele simetrice nu defazează
- Matricea spectrală conține spectrele încrucișate: co-mișcarea și relațiile de avans-întârziere pe frecvențe

Limitele periodogramei

- Pentru un proces liniar, ordonatele periodogramei sînt asimptotic variabile χ_2^2 scalate [Brockwell și Davis \(1991\)](#)

$$X_t = \sum_j \psi_j \varepsilon_{t-j} \Rightarrow I(\omega_j) \Rightarrow f(\omega_j) \frac{\chi_2^2}{2}$$

- ▶ ψ_j : ponderi cu $\sum_j |j|^{1/2} |\psi_j| < \infty$; ε_t : inovații i.i.d.; $f > 0$; asimptotic independente pe frecvențe Fourier ω_j fixate
- ▶ $\mathbb{E}I(\omega_j) \rightarrow f(\omega_j)$, dar $\text{Var}I(\omega_j) \rightarrow f(\omega_j)^2$: **inconsistentă**, varianța nu scade cu n
- ▶ derivarea pentru zgomot alb și pentru un proces liniar: [▶ Anexa](#)
- Leakage-ul spectral: media periodogramei este spectrul adevărat netezit cu nucleul Fejér F_n

$$\mathbb{E}I(\omega) = \int F_n(\omega - \lambda) f(\lambda) d\lambda$$

- ▶ lobi lateralii ai lui F_n scad doar ca $1/(n\omega^2)$, deci puterea se **scurge** de la frecvențele puternice spre cele slabe
- Două remedii: **medierea** frecvențelor vecine (consistență) și **ponderarea** datelor cu un taper (deplasare); estimatorul multitaper le face pe amîndouă

Estimatori cu fereastră de laguri (1/2)

- Se reduc ponderile autocovarianțelor de eșantion zgomotoase de la laguri mari **Parzen (1961)**

$$\hat{f}(\omega) = \frac{1}{2\pi} \sum_{|h| < n} k(h/M) \hat{\gamma}(h) e^{-i\omega h}$$

- $\hat{\gamma}(h)$: autocovarianța de eșantion; k : **fereastră de laguri**, $k(0) = 1$, descrescătoare în $|h|$; M : parametrul de trunchiere (lățimea de bandă)

- Echivalent: o medie ponderată a periodogramei cu **fereastră spectrală** W_M

$$\hat{f}(\omega) = \int W_M(\omega - \lambda) I(\lambda) d\lambda, \quad W_M(\omega) = \frac{1}{2\pi} \sum_h k(h/M) e^{-i\omega h}$$

- un M mare dă o fereastră W_M îngustă: netezire redusă


Estimatori cu fereastră de laguri (2/2): nucleeele

- Bartlett $k(u) = 1 - |u|$; Parzen; Tukey–Hanning; pătratic spectral (QS): aceleași nucleee ca estimatorii HAC din Capitolul 0 în $\omega = 0$
 - un W_M nenegativ garantează $\hat{f} \geq 0$ (Bartlett, Parzen, QS); Tukey–Hanning poate deveni negativ
- Exponentul caracteristic q : cât de plat este nucleul în zero

$$k_q = \lim_{u \rightarrow 0} \frac{1 - k(u)}{|u|^q}$$

- Bartlett $q = 1$, $k_1 = 1$; Parzen $q = 2$, $k_2 = 6$; QS $q = 2$, $k_2 = 1,42$; un q mai mare înseamnă deplasare mai mică (slide-urile următoare)

Ferestre de laguri și ferestre spectrale



- Stînga: $k(u)$; dreapta: fereastra spectrală $W_M(\omega)$ pentru $M = 10$, ponderile pe care fiecare estimator le dă periodogramei în jurul lui ω

Interpretarea ferestrelor

- ▣ O fereastră W_M îngustă înseamnă deplasare mică și varianță mare
 - ▶ la $M = 10$, Parzen este cea mai largă ($\int k^2 = 0,54$ este cel mai mic), iar QS cea mai îngustă
- ▣ Bartlett are lobi laterali (leakage prin fereastră însăși); Tukey–Hanning are ponderi negative
- ▣ Compararea nucleelor la același M este înșelătoare: comparați-le la aceeași varianță (același număr echivalent de grade de libertate)
- ▣ Nucleul QS este optim în MSE printre nucleele cu estimări nenegative [Andrews \(1991\)](#)

Deplasare, varianță și lățimea de bandă optimă (1/2)

□ Dacă $M \rightarrow \infty$ și $M/n \rightarrow 0$: $\hat{f}(\omega) \rightarrow_p f(\omega)$ (**consistență**) Parzen (1961); varianța și deplasarea

$$\text{Var}\hat{f}(\omega) \approx \frac{M}{n} f(\omega)^2 \int k^2(u) du, \quad \mathbb{E}\hat{f}(\omega) - f(\omega) \approx -k_q M^{-q} f^{(q)}(\omega)$$

- ▶ varianța crește cu M (se dublează în $\omega = 0, \pm\pi$); deplasarea scade cu M
- ▶ $f^{(q)}(\omega) = \frac{1}{2\pi} \sum_h |h|^q \gamma(h) e^{-i\omega h}$: o derivată generalizată de ordinul q a lui f , mare unde spectrul este curbat (vîrfuri)

Deplasare, varianță și lățimea de bandă optimă (2/2)

- Minimizarea MSE = pătratul deplasării + varianța, în raport cu M


$$M^* = \left(\frac{q k_q^2 f^{(q)}(\omega)^2 n}{f(\omega)^2 \int k^2} \right)^{1/(2q+1)} \propto n^{1/(2q+1)}, \quad \text{MSE} \propto n^{-2q/(2q+1)}$$

- nucleele cu $q = 2$ converg mai repede ($n^{-4/5}$) decât Bartlett ($n^{-2/3}$)
- Inferența: o variabilă χ^2 scalată, cu ν grade de libertate echivalente

$$\frac{\nu \hat{f}(\omega)}{f(\omega)} \approx \chi_\nu^2, \quad \nu = \frac{2n}{M \int k^2}$$

- banda de încredere $[\nu \hat{f} / \chi_{\nu;0,975}^2, \nu \hat{f} / \chi_{\nu;0,025}^2]$ are lățime constantă pe scară logaritmică

Compromisul deplasare–varianță într-un vîrf spectral



- Estimatorul Parzen în vîrf (perioada 11,1) lui $X_t = 1,6X_{t-1} - 0,9X_{t-2} + \varepsilon_t$, $n = 512$, 400 de simulări; curbele sînt împărțite la $f(\text{vîrf})^2$; linii întrerupte: formulele asimptotice

Interpretarea compromisului

- ▣ Cu $M = 12$, RMSE relativ este 0,79, aproape în întregime deplasare (0,79): o netezire puternică aplatizează vârful
- ▣ Optimul Monte Carlo este $M = 96$ (RMSE relativ 0,36); formula asimptotică dă $M^* = 148$: același ordin de mărime, dar formula ignoră termenii de deplasare de ordin superior
- ▣ Varianța asimptotică este precisă doar când fereastra este mai îngustă decât vârful; deplasarea asimptotică explodează pentru M mic
- ▣ Un vârf spectral ascuțit cere un M mult mai mare decât ar sugera regula HAC pentru $\omega = 0$: lățimea de bandă este locală

Alegerea lăţimii de bandă

- ▣ **Plug-in Andrews (1991):** aproximăm $f^{(q)}/f$ printr-un model parametric (AR(1)), apoi folosim M^*

$$M = 1,1447 (\hat{\alpha}(1) n)^{1/3} \text{ (Bartlett)}, \quad M = 1,3221 (\hat{\alpha}(2) n)^{1/5} \text{ (QS)}, \quad \omega = 0$$

- ▶ $\hat{\alpha}(q)$: raportul $(f^{(q)}(0)/f(0))^2$ calculat din AR(1) estimat, de exemplu $\hat{\alpha}(2) = 4\hat{\rho}^2/(1 - \hat{\rho})^4$ ($\hat{\rho}$: coeficientul AR)
- ▶ bun pentru varianţele pe termen lung ([Capitolul 0](#)); slab lângă vîrfuri ascuţite, unde aproximarea AR(1) este greşită

- ▣ **Validare încrucişată Hurvich (1985):** minimizăm în M un criteriu Whittle fără observaţia j

$$CV(M) = \sum_j \left[\log \hat{f}_{-j}(\omega_j) + \frac{I(\omega_j)}{\hat{f}_{-j}(\omega_j)} \right]$$

- ▶ $\hat{f}_{-j}$: estimaţia netezită calculată fără ordonata $I(\omega_j)$
- ▣ **Rezoluţia:** două vîrfuri mai apropiate decît lăţimea de bandă (circa $1/M$ cicluri) se contopesc; stabiliţi rezoluţia necesară înainte de a privi datele
- ▶ raportaţi estimarea pentru două sau trei lăţimi de bandă: concluziile care depind de M nu sînt concluzii

Estimarea multitaper (1/2): taper-ele Slepian

▣ **Taper-ele Slepian (DPSS)** $v^{(k)}$, $k = 0, \dots, K - 1$ Thomson (1982)

- ▶ șiruri de ponderi ortonormate de lungime n care maximizează ponderea λ_k a energiei lor spectrale în intervalul $[-W, W]$; W : semilățimea de bandă în cicluri
- ▶ aproximativ $2nW$ dintre ele au $\lambda_k \approx 1$; de obicei $K = 2NW - 1$, cu $NW = nW$ (de exemplu $NW = 4$, $K = 7$)

▣ Spectrele proprii: câte o periodogramă ponderată pentru fiecare taper; estimația este media lor

$$\hat{S}_k(\omega) = \frac{1}{2\pi} \left| \sum_t v_t^{(k)} x_t e^{-i\omega t} \right|^2, \quad \hat{f}^{\text{mt}}(\omega) = \frac{1}{K} \sum_{k=0}^{K-1} \hat{S}_k(\omega)$$

- ▶ $\hat{S}_k$ sînt aproape necorelate: $2K\hat{f}^{\text{mt}}/f \approx \chi_{2K}^2$; varianța f^2/K , deplasarea controlată de concentrarea taper-elor



Estimarea multitaper (2/2): ponderi adaptive

- ▣ **Ponderi adaptive** Percival și Walden (1993): se reduce ponderea taper-elor cu leakage mare acolo unde f este mic

$$d_k(\omega) = \frac{\sqrt{\lambda_k} f(\omega)}{\lambda_k f(\omega) + (1 - \lambda_k) \sigma^2}$$

- ▶ σ^2 : varianța seriei; $1 - \lambda_k$: leakage-ul taper-ului k ; ponderile depind de f necunoscut, deci se iterează pornind de la $\hat{f}^{\text{mt}}$
- ▣ Alternative cu aceeași logică: taper-ele sinus Riedel și Sidorenko (1995); medierea Welch a segmentelor ponderate Welch (1967)

Taper-ele Slepian




□ $n = 512$, $NW = 4$: primele patru taper-e și leakage-ul $1 - \lambda_k$ a primelor zece (albastru: $k < 2NW - 1$)

ATS_ch11_spectral_estimation

Interpretarea taper-elor

- ▣ Taper-ul k are k treceri prin zero: taper-ele de ordin mare ponderează capetele eșantionului, deci împreună folosesc toate datele
- ▣ Leakage-ul crește repede cu k : $\lambda_6 = 0,937$, dar $\lambda_7 = 0,70$ și $\lambda_8 = 0,30$; dincolo de $2NW - 1$ taper-ele nu mai sînt utile
- ▣ Un singur taper Hann aruncă extremitățile; estimarea multitaper recuperează această informație ca grade de libertate suplimentare
- ▣ NW este singura alegere de calibrare: fixează împreună rezoluția $2W = 2NW/n$ și varianța f^2/K

Leakage-ul spectral pe un spectru cu domeniu dinamic mare




- Modelul AR(4) al lui Percival și Walden (1993), $n = 1024$, 65 dB între vîrf și minim; o traiectorie simulată (cu leakage-ul median din 21)

Interpretarea leakage-ului

- ▣ Deplasarea medie la frecvențe peste 0,3 cicluri (200 de simulări): periodograma +11,2 dB, taper Hann -2,5 dB, multitaper +6,3 dB, multitaper adaptiv -0,8 dB
- ▣ Periodograma brută umple minimul cu putere scursă din vîrfuri: o mediere suplimentară nu ar ajuta, deplasarea este în fiecare ordonată
- ▣ Cu ponderi egale, taper-ele de ordin mare, care au leakage mare, contamineză încă minimul; ponderile adaptive o elimină
- ▣ Datele economice au rareori domenii de 60 dB, dar spectrele nivelurilor, cu un vîrf în zero ca la o rădăcină unitară, le au: aplicați un taper sau o prealbire înainte de estimare

Cinci estimatori într-un experiment Monte Carlo




- $X_t = 1,6X_{t-1} - 0,9X_{t-2} + \varepsilon_t$, $n = 512$, 400 de simulări: deplasarea medie în logaritmi pe frecvențe și acoperirea benzilor χ^2 nominale de 95%

Interpretarea experimentului Monte Carlo

- ▣ Abaterea standard a lui $10 \log_{10}(\hat{f}/f)$: periodograma 5,6 dB, Daniell 1,8, multitaper 1,7, Parzen 0,9, Welch 1,1
- ▣ În vîrf: Parzen $-2,3$ dB, Welch $-1,4$ dB, multitaper $-0,5$ dB; valoarea $-2,0$ dB a periodogramei este media lui $\log \chi_2^2/2$, nu o deplasare în niveluri
- ▣ Acoperirea benzii de 95%: multitaper 94,3%, adaptiv 94,6%, Daniell 90,3% (banda lui ignoră deplasarea de pe pante)
- ▣ Multitaper este singurul estimator de aici care are simultan deplasare mică, varianță mică și benzi corecte

Producția industrială: România și zona euro



- Creșterea lunară a producției industriale (ajustată sezonier și pentru zilele lucrătoare), februarie 2000 – iulie 2026, 318 luni; multitaper $NW = 4$ cu benzi de 95%

Interpretarea spectrelor producției industriale

- Creșterea lunară este dominată de perioadele scurte: ciclurile sub 6 luni au 77% din varianță în România și 69% în zona euro
- Banda ciclului economic (18–96 de luni) are 2,1% (România) și 7,3% (zona euro): ratele de creștere ascund ciclurile vizibile în niveluri (câștigul primei diferențe)
- România este mai volatilă (abaterea standard 3,61 față de 1,98), iar surplusul este la frecvențe înalte, unde benzile nu se suprapun: zgomot, revizuirii și efecte de calendar reziduale
- La perioade de peste 12 luni, cele două spectre nu se pot distinge în interiorul benzilor

Linii în spectru: testul F al lui Thomson (1/2)

- Modelul: o sinusoidă plus un zgomot cu spectru neted Thomson (1982)

$$x_t = \mu \cos(\omega_0 t + \phi) + e_t$$

- ▶ μ : amplitudinea; ω_0 : frecvența liniei; ϕ : faza; e_t : zgomot staționar
- ▶ sub o linie, fiecare DFT ponderat este $Y_k(\omega_0) \approx \mu U_k(0)$, cu $U_k(0) = \sum_t v_t^{(k)}$ suma taper-ului k
- O regresie a coeficienților proprii Y_k pe sumele taper-elor $U_k(0)$, frecvență cu frecvență: separă o linie deterministă de un vîrf stochastic, ceea ce testul lui Fisher (TSA) nu poate


Linii în spectru: testul F al lui Thomson (2/2)

- Amplitudinea estimată și statistica F: variația explicată față de cea reziduală

$$\hat{\mu}(\omega) = \frac{\sum_k U_k(0) Y_k(\omega)}{\sum_k U_k(0)^2}, \quad F(\omega) = \frac{(K-1) |\hat{\mu}|^2 \sum_k U_k(0)^2}{\sum_k |Y_k - \hat{\mu} U_k(0)|^2} \sim F_{2, 2K-2}$$

- un $F(\omega)$ mare: o linie în ω ; K : numărul de taper-e
- Aplicație: sezonabilitatea reziduală este o mulțime de linii la $k/12$ cicluri pe lună; efectele zilelor lucrătoare sînt linii la 0,348 și 0,432 cicluri pe lună
- Testarea la sute de frecvențe: așteptați circa 1% respingeri false la nivelul de 1%; testați doar frecvențe stabilite dinainte

Sezonalitatea reziduală în producția industrială a României



- Testul F armonic ($NW = 4$, $K = 7$) pe creșterea lunară, seria neajustată și seria ajustată; liniile punctate: cele șase frecvențe sezoniere

Interpretarea testului F

- ▣ Seria neajustată: 3 din 6 armonici sezoniere sînt linii la 1% ($p < 0,0001$ și $< 0,0001$ la 2 și 3 cicluri pe an); armonica anuală este la limită ($p = 0,012$)
- ▣ O linie puternică la 4,18 cicluri pe an ($p < 0,0001$): frecvența zilelor lucrătoare, un efect de calendar, nu sezonabilitate
- ▣ Seria ajustată: niciuna dintre cele șase armonici nu este semnificativă și nu există nicio linie la frecvența zilelor lucrătoare ($p = 0,22$): ajustarea trece această verificare
- ▣ Armonica anuală este slabă deoarece sezonabilitatea românească nu este o sinusoidă pură: puterea ei se află în armonicile superioare

Recapitulare: teoria estimării spectrale

- Periodograma este asimptotic nedeplasată, dar inconsistentă și afectată de leakage; netezirea aduce consistență, iar taper-ul aduce deplasare mică
- Lățimea de bandă este o alegere deplasare–varianță cu $M^* \propto n^{1/(2q+1)}$; vîrfurile cer ferestre înguste
- Multitaper: benzi χ^2_{2K} care își respectă nivelul, ponderi adaptive împotriva leakage-ului și un test F pentru linii

Coerența, faza și câștigul (1/2): coerența

- ▣ **Coerența pătratică:** R^2 al regresiei lui $dZ_y(\omega)$ pe $dZ_x(\omega)$

$$\kappa_{xy}^2(\omega) = \frac{|f_{xy}(\omega)|^2}{f_x(\omega)f_y(\omega)} \in [0, 1]$$

- ▶ f_x, f_y : cele două spectre; f_{xy} : spectrul încrucișat; $\kappa^2 = 1$: y este exact un filtru liniar al lui x la frecvența ω ;
 $\kappa^2 = 0$: nicio relație liniară la acea frecvență
 - ▶ invariantă la filtrarea fiecărei serii cu un filtru inversabil: coerența nu depinde de felul în care sînt transformate seriile (▶ Anexa)
- ▣ **Câștigul** $|f_{xy}(\omega)|/f_x(\omega)$: coeficientul de regresie al lui y pe x la frecvența ω

Coerența, faza și câștigul (2/2): faza

- ▣ **Faza:** unghiul spectrului încrucișat, cu $\gamma_{xy}(h) = \text{Cov}(x_{t+h}, y_t)$

$$\phi_{xy}(\omega) = \arg f_{xy}(\omega)$$

- ▶ exemplu: dacă $y_t = x_{t-d}$, atunci $f_{xy} = e^{i\omega d} f_x$, faza $\omega d > 0$: x conduce cu ϕ/ω perioade
- ▶ faza este definită modulo 2π : un avans de d și o întârziere de $2\pi/\omega - d$ dau aceeași fază

- ▣ Interpretați faza doar unde coerența este semnificativă


Inferență pentru coerență și fază

- Periodograma încrucișată brută dă $\hat{\kappa}^2 \equiv 1$ la orice frecvență: coerența **trebuie** netezită (aici: mediată pe K taper-e)

$$\Pr(\hat{\kappa}^2 > c \mid \kappa^2 = 0) = (1 - c)^{L-1} \Rightarrow c_{0,05} = 1 - 0,05^{1/(L-1)}$$

- L : numărul ordonatelor independente mediate ($L = K$ pentru multitaper); c : pragul; un $\hat{\kappa}^2$ peste $c_{0,05}$ este semnificativ la 5%
- $\hat{\kappa}^2$ este deplasat în sus când κ^2 este mic; intervale de încredere prin transformarea Fisher $\tanh^{-1} \hat{\kappa}$ [Shumway și Stoffer \(2017\)](#)
- faza: $\text{se}(\hat{\phi}) \approx \sqrt{(1/\hat{\kappa}^2 - 1)/(2L)}$; crește foarte mult când coerența scade
- Deplasarea din nealiniere: o întârziere mare d rotește faza în interiorul benzii de netezire și scade $\hat{\kappa}^2$; aliniați seriile (sau aplicați o prealbire) mai întâi

România și zona euro: coerență, fază și câștig



- Creșterea lunară a producției industriale, zona euro (x) și România (y); multitaper $NW = 6$, $K = 11$; zona colorată: 18–96 de luni

Q.ATS_ch11_cross_spectrum

Interpretarea spectrului încrucișat

- Coerența medie este 0,69 în banda ciclului economic și 0,47 sub 12 luni; pragul de 5% este 0,26: semnificativă la 100% din frecvențele ciclului economic și la 71% din cele scurte
- Faza este aproape de zero: avansul median implicat este de 0,5 luni, în interiorul a două erori standard: industria românească se mișcă odată cu zona euro în aceeași lună
- Câștigul este 0,85 la frecvențele ciclului economic și 1,24 la cele scurte: România amplifică șocurile din zona euro doar la frecvențe înalte
- Corelația simplă (0,66) amestecă aceste benzi; coerența separă zonele cu co-mișcare puternică de cele cu zgomot

Corelația dinamică

- ▣ Croux, Forni și Reichlin (2001): corelația componentelor în fază (reale) la frecvența ω

$$\rho_{xy}(\omega) = \frac{c_{xy}(\omega)}{\sqrt{f_x(\omega)f_y(\omega)}} \in [-1, 1]$$

$$\kappa^2 = \rho^2 + \left(\frac{q_{xy}}{\sqrt{f_x f_y}} \right)^2$$

- ▶ c_{xy} , q_{xy} : cospectrul și spectrul în cuadratură; spre deosebire de coerență, ρ_{xy} are **semn** și nu este mărit artificial de mișcarea defazată

- ▣ Pe o bandă Λ de frecvențe

$$\rho_{xy}(\Lambda) = \frac{\int_{\Lambda} c_{xy}}{\sqrt{\int_{\Lambda} f_x \int_{\Lambda} f_y}}$$

- ▶ pe $[0, \pi]$ este corelația obișnuită; pe o bandă este egală cu corelația seriilor filtrate trece-bandă (secțiunea 4)
- ▣ **Coeziunea**: o medie ponderată a corelațiilor $\rho_{xy}(\omega)$ pe perechi într-un grup de țări; CFR o folosesc pentru ciclurile economice din zona euro

Cauzalitatea Granger pe frecvențe (1/2): măsura Geweke

- Geweke (1982): într-un VAR bivariat, normalizăm inovațiile astfel încât inovația lui x să fie necorelată cu inovația transformată a lui y ; atunci

$$f_x(\omega) = \frac{1}{2\pi} \left(|\tilde{H}_{xx}(\omega)|^2 \tilde{\sigma}_{xx} + |\tilde{H}_{xy}(\omega)|^2 \tilde{\sigma}_{yy} \right)$$

- $\tilde{H}$: funcția de transfer (reprezentarea de medie mobilă) a VAR normalizat; $\tilde{\sigma}_{xx}$, $\tilde{\sigma}_{yy}$: varianțele celor două inovații ortogonale

- Partea din $f_x(\omega)$ care provine de la y

$$M_{y \rightarrow x}(\omega) = \ln \frac{2\pi f_x(\omega)}{|\tilde{H}_{xx}(\omega)|^2 \tilde{\sigma}_{xx}} \geq 0$$

$$\frac{1}{\pi} \int_0^\pi M_{y \rightarrow x}(\omega) d\omega = \ln \frac{\sigma_{x|x}^2}{\sigma_{x|x,y}^2}$$

- integrala este măsura Granger din domeniul timpului (sub o condiție slabă): $\sigma_{x|x}^2$, $\sigma_{x|x,y}^2$ sînt varianțele prognozei cu un pas a lui x fără și cu trecutul lui y


Cauzalitatea Granger pe frecvențe (2/2): testul Breitung–Candelon

- Breitung și Candelon (2006): lipsa cauzalității la frecvența ω înseamnă două restricții liniare asupra coeficienților lui y din ecuația lui x

$$M_{y \rightarrow x}(\omega) = 0 \iff \sum_{j=1}^p \psi_j \cos(j\omega) = 0 \text{ și } \sum_{j=1}^p \psi_j \sin(j\omega) = 0$$

- ▶ ψ_j : coeficientul lui y_{t-j} în ecuația lui x ; p : ordinul VAR; un test $F(2, T - 2p - 1)$ la fiecare ω , T : numărul de observații
- ▶ cu $p \leq 2$ cele două restricții fixează toți ψ_j , deci testul este același la orice frecvență
- BC arată că testul se extinde la VAR cointegrate (cauzalitate pe termen lung în $\omega = 0$); testele punctuale pe frecvențe nu sînt un test comun

Cauzează zona euro industria românească și la ce frecvențe?



- VAR(3) pentru creșterea lunară a producției industriale (ordinul ales prin AIC, cel puțin 3); stînga: măsurile Geweke; dreapta: statistica F Breitung–Candelon cu valoarea critică de 5% 3,03

Interpretarea cauzalității în domeniul frecvenței

- ▣ Zona euro → România: măsura Geweke totală 0,146 (integrala curbei: 0,145); România → zona euro: 0,004
- ▣ Măsura este 0,087 în banda ciclului economic și 0,168 la perioade sub 6 luni: creșterea trecută din zona euro prezice creșterea românească mai ales la orizonturi scurte
- ▣ Testul BC respinge la 100% din frecvențe pentru zona euro → România și la nicio frecvență în cealaltă direcție
- ▣ O economie mică și deschisă își urmează piața principală, nu invers; profilul pe frecvențe arată ce tip de șoc se transmite cel mai repede

Recapitulare: două serii

- Coerența este un R^2 pe frecvențe; trebuie netezită și testată față de $1 - \alpha^{1/(L-1)}$
- Faza dă avansurile și întârzierile, modulo 2π , doar unde coerența este semnificativă; corelația dinamică păstrează semnul
- Geweke descompune cauzalitatea Granger pe frecvențe; Breitung–Candelon o testează prin două restricții liniare

Filtre trece-bandă

- ▣ Filtrul ideal pentru perioadele $[p_l, p_u]$: câștig 1 pe frecvențele $[\omega_1, \omega_2] = [2\pi/p_u, 2\pi/p_l]$, 0 în rest; ponderile lui sînt în număr infinit

$$b_0 = \frac{\omega_2 - \omega_1}{\pi}, \quad b_j = \frac{\sin j\omega_2 - \sin j\omega_1}{\pi j}, \quad j = \pm 1, \pm 2, \dots$$

- ▣ [Baxter și King \(1999\)](#): trunchiem la K laguri și adăugăm o constantă astfel încît $\sum_{j=-K}^K a_j = 0$
 - a_j : ponderile ajustate; suma nulă elimină o rădăcină unitară și o tendință liniară; simetric, fără defazaj
 - recomandarea trimestrială: BK(6, 32, $K = 12$); prețul: K observații pierdute la fiecare capăt; $a_0 = 0,28$
- ▣ [Christiano și Fitzgerald \(2003\)](#): minimizăm $\mathbb{E}[(y_t^{\text{ideal}} - \hat{y}_t)^2 \mid y_1, \dots, y_n]$, presupunînd un mers aleator
 - y_t^{ideal} : componenta trece-bandă ideală; ponderi asimetrice, variabile în timp, care folosesc tot eșantionul: nicio observație pierdută, dar defazaje lîngă capete
- ▣ Banda ciclului economic de 6–32 de trimestre (1,5–8 ani) urmează definiția Burns și Mitchell, preluată de [Baxter și King \(1999\)](#)

Filtrul Hodrick–Prescott



Edward C. Prescott, 2015

Foto: Narodowy Bank Polski (2015); CC

BY-SA 2.0; Wikimedia Commons

- Hodrick și Prescott (1997): tendința echilibrează potrivirea cu netezimea

$$\hat{\tau} = \arg \min_{\tau} \sum_t (y_t - \tau_t)^2 + \lambda \sum_t (\Delta^2 \tau_t)^2 = (I + \lambda D' D)^{-1} y$$

- ▶ τ_t : tendința; $\Delta^2 \tau_t$: diferența ei de ordinul doi; λ : penalizarea pentru lipsa de netezime; D : matricea diferențelor de ordinul doi; ciclul $y_t - \hat{\tau}_t$
- Câștigul ciclului pe un eșantion infinit: un filtru trece-sus

$$G(\omega) = \frac{4\lambda(1 - \cos \omega)^2}{1 + 4\lambda(1 - \cos \omega)^2}$$

- ▶ netezitorul Kalman al unei tendințe liniare locale cu raportul semnal-zgomot $1/\lambda$ (Capitolul 6); $\lambda = 1600$ pentru trimestre; scalarea Ravn–Uhlig $\lambda \propto s^4$ (s : numărul de observații pe trimestru): 129 600 pentru luni, 6,25 pentru ani Ravn și Uhlig (2002)


Critica lui Hamilton

- **Hamilton (2018):** „de ce nu ar trebui să folosiți niciodată filtrul HP”
 - ▶ (1) aplicat unui mers aleator, HP produce un ciclu cu o dinamică creată de filtru **Cogley și Nason (1995)**
 - ▶ (2) valorile de la sfârșitul eșantionului diferă mult de cele pe care același filtru le dă după ce sosesc date noi (unilateral față de bilateral)
 - ▶ (3) λ implicat de un model statistic estimat pe date este departe de 1600
- Alternativa: **filtrul de regresie**, ciclul este eroarea unei prognoze prin regresie cu h pași înainte

$$y_{t+h} = \beta_0 + \beta_1 y_t + \dots + \beta_p y_{t-p+1} + v_{t+h}, \quad \text{ciclul}_{t+h} = \hat{v}_{t+h}$$

- ▶ trimestrial $h = 8$, $p = 4$; unilateral prin construcție; pentru un mers aleator $v_{t+h} = y_{t+h} - y_t$
- Răspunsuri: filtrul HP iterat (boosting) **Phillips și Shi (2021)**; un filtru Hamilton modificat pentru timp real **Quast și Wolters (2022)**; dezbaterile privește ce câștig doriți

Filtre judecate după câștig




- Câștigul de la nivel la ciclu, pe perioade în trimestre; Christiano–Fitzgerald: ponderile din mijlocul unui eșantion de 126 de trimestre; Hamilton: $h = 8$, $p = 4$

Interpretarea câștigurilor

- HP este un filtru trece-sus: câștig 0,70 la 32 de trimestre, 0,49 la 40 și încă 0,16 la 60: „ciclul HP” conține cicluri mai lungi de 8 ani
- BK oscilează în jurul lui 1 (maximum 1,10) și lasă să treacă 0,41 din ciclul de 40 de trimestre; CF este mai aproape de forma ideală în mijlocul eșantionului
- Filtrul lui Hamilton nu este trece-bandă: câștig 2,00 la 16 trimestre și 0,00 la 8 (pentru ponderile mersului aleator); ponderile estimate pentru România (suma 0,97) dau 1,99 și 0,26
- Fiecare filtru își definește propriul ciclu: comparați ciclurile doar după ce ați comparat câștigurile

Un ciclu creat de filtru




- Spectrul ciclului HP ($\lambda = 1600$) al unui mers aleator: $G(\omega)^2 / (2\pi \cdot 2(1 - \cos \omega))$ și periodograma medie a unor mersuri aleatoare simulate filtrate HP

Interpretarea ciclului fals

- Un mers aleator nu are niciun ciclu, totuși ciclul lui HP are un vîrf la perioada de 30,1 trimestre (7,5 ani); simulare: 28,6
- Derivarea (Seminarul 11, A1): maximizăm $u^3/(1 + 4\lambda u^2)^2$ în $u = 1 - \cos \omega$: $u^* = \sqrt{3/(4\lambda)}$; replică [Cogley și Nason \(1995\)](#)
- Vîrfurile se află în banda ciclului economic: „faptele stilizate” calculate din ciclurile HP pot fi proprietăți ale filtrului
- Scalarea Ravn–Uhlig păstrează vîrfurile în jur de 7,5 ani și la frecvențele lunară și anuală (Seminarul 11, A2)

Ciclurile economice ale României după patru filtre




- $100 \times$ logaritmul PIB-ului real al României, T1 1995 – T2 2026; HP ($\lambda = 1600$), BK(6, 32, 12), CF(6, 32, mers aleator cu derivă), Hamilton ($h = 8, p = 4$)

Interpretarea ciclurilor României

- Toate cele patru filtre situează la fel vârful din 2008 (HP 9,5%, BK 8,4%) și minimul din T3 2010 (HP -7,3%, BK -4,4%)
- Amplitudinile diferă: abaterea standard HP 2,9, BK 2,5, CF 2,2, Hamilton 6,6; ciclul Hamilton este o eroare de prognoză la 8 trimestre, cu un minim de -19,0%
- Corelații: BK-HP 0,84, BK-CF 0,84, HP-Hamilton 0,69, CF-Hamilton 0,49
- Poziția de azi este incertă: HP -2,4%, CF -2,0%, Hamilton -4,8% în T2 2026; BK se oprește în T2 2023

Problema capetelor de eșantion



- PIB-ul României: ciclul la fiecare dată calculat cu datele disponibile la acea dată (timp real) și cu tot eșantionul (final), din T4 2004

Interpretarea revizuirilor în timp real

- HP: revizuirea medie pătratică 2,8 puncte, cât ciclul însuși (abaterea standard 2,8); corelația dintre ciclul în timp real și cel final 0,57; semnul greșit în 38% din trimestre
- Hamilton: corelația 0,76, semnul greșit în 24% din trimestre; dar revizuirea este de 4,6 puncte, deoarece regresia se reestimează pe eșantioane scurte într-o economie în tranziție
- Filtrul HP în timp real a văzut doar o mică parte din boom-ul din 2008: deviația PIB-ului de la potențial de care avea nevoie politica economică era tocmai cea pe care o măsura cel mai prost
- Raportați proprietățile în timp real ale oricărei estimări a deviației; estimarea finală nu este o informație pe care o avea cineva

Măsurarea sincronizării ciclurilor economice

- ▣ Corelația ciclurilor filtrate; depinde de filtru (cîștig) și de cîteva episoade mari
- ▣ **Concordanța** [Harding și Pagan \(2002\)](#): ponderea perioadelor în care cele două economii se află în aceeași fază

$$C = \frac{1}{T} \sum_t [S_{xt}S_{yt} + (1 - S_{xt})(1 - S_{yt})]$$

- ▶ $S_{xt} = 1$ dacă x este în expansiune (aici: ciclul peste tendință), 0 altfel; sub independență
 $\mathbb{E}C = p_x p_y + (1 - p_x)(1 - p_y)$, p_x , p_y : ponderile perioadelor de expansiune
- ▣ Corelația dinamică pe banda ciclului economic [Croux, Forni și Reichlin \(2001\)](#), care nu cere niciun filtru
- ▣ Evidența pentru Europa Centrală și de Est: o meta-analiză a 35 de publicații [Fidrmuc și Korhonen \(2006\)](#)
 - ▶ unele țări aveau deja corelații mari cu zona euro
 - ▶ metoda de estimare schimbă semnificativ corelația

România și zona euro: sincronizarea în timp




□ Ciclurile Baxter–King ale PIB-ului real, T1 1998 – T2 2023, și corelația lor mobilă pe 20 de trimestre

Interpretarea sincronizării

- ▣ Corelația ciclurilor: 0,54 pe tot eșantionul; 0,34 înainte de 2008, 0,47 în 2008–2012, 0,90 în 2013–2019, 0,96 din 2020
- ▣ Concordanța 0,75 față de 0,50 sub independență: cele două economii sînt împreună peste sau sub tendință în majoritatea timpului
- ▣ Ciclul României este mai amplu (abaterea standard 2,5 față de 1,7): sincronizat ca moment, nu ca amplitudine
- ▣ Corelația de după 2020 este determinată de un singur șoc comun (pandemia): cîteva trimestre pot face un deceniu să pară sincronizat

Corelația dinamică cu zona euro



- Creșterea trimestrială a PIB, multitaper $NW = 3$; stînga: $\rho(\omega)$ pentru 1995–2019; dreapta: mediile pe banda de 6–32 de trimestre (bare) și 2–6 trimestre (romburi), fără și cu 2020–2026

Interpretarea corelațiilor dinamice

- ▣ Înainte de 2020, corelația dinamică pe banda ciclului economic: Ungaria 0,81, Cehia 0,80, Polonia 0,60, România 0,28
- ▣ Corelația pe termen scurt a Poloniei este $-0,14$: creșterea ei s-a mișcat împreună cu zona euro doar prin ciclul economic
- ▣ Cu 2020–2026 toate valorile cresc (România 0,50, Polonia 0,75): trimestrul pandemiei domină orice periodogramă încrucișată
- ▣ Raportați sincronizarea cu și fără șocurile comune extreme; spectrele robuste (trunchiate sau pe ranguri) sînt o temă de cercetare

Recapitulare: filtre și ciclul economic

- Un ciclu este definit de un câștig: HP este trece-sus, BK și CF aproximează un filtru trece-bandă, filtrul de regresie al lui Hamilton nu este niciunul
- HP creează dintr-un mers aleator un ciclu de 30 de trimestre și nu este fiabil în timp real
- România este sincronizată cu zona euro ca moment din 2010, cu o amplitudine mai mare


Spectre evolutive și staționaritate locală

- Priestley (1965): reprezentarea lui Cramér cu o amplitudine care se schimbă lent

$$X_t = \int A_t(\omega) e^{i\omega t} dZ(\omega), \quad f_t(\omega) = |A_t(\omega)|^2 f(\omega)$$

- ▶ $A_t(\omega)$: amplitudinea variabilă în timp; $f_t(\omega)$: **spectrul evolutiv** la momentul t
- Dahlhaus (1997): procese **local staționare** $X_{t,T}$, cu $A(t/T, \omega)$ netedă în timpul rescalat $u = t/T$
 - ▶ T : mărimea eșantionului; un spectru variabil în timp $f(u, \omega)$ care se poate estima consistent printr-un spectru cu taper pe o fereastră mobilă (spectrograma)
- **Principiul incertitudinii**: o fereastră de lungime L separă frecvențele doar pînă la circa $1/L$; ferestrele lungi estompează timpul, cele scurte estompează frecvența
- Wavelets (secțiunile următoare) lasă lungimea ferestrei să varieze cu frecvența: scurtă pentru frecvențele înalte, lungă pentru cele joase

Un spectru care alunecă



- $X_t = 2r \cos(\theta_t) X_{t-1} - r^2 X_{t-2} + \varepsilon_t$, $r = 0,95$, perioada vârfului trece de la 20 la 5 pe 2048 de observații; multitaper pe ferestre de 256 (pas 16)

Interpretarea spectrogramei

- ▣ Spectrograma urmărește vârful care se deplasează: un singur spectru al întregului eșantion ar arăta o bandă estompată de la 0,05 la 0,2 cicluri
- ▣ Rezoluția $2NW/L = 0,023$ cicluri: bună la frecvențe înalte, grosieră pentru perioadele lungi de la început
- ▣ Primele și ultimele 128 de observații nu au estimare: orice metodă timp–frecvență pierde marginile (conul de influență al wavelets)
- ▣ Exemple economice: lungimea variabilă a ciclului economic, scurtarea ciclurilor de tranzacționare, schimbări de regim în volatilitate

Analiza spectrului singular pe un slide

- ▣ Scufundăm $x_1, \dots, x_n$ în matricea traiectoriilor (Hankel) X , de dimensiune $L \times (n - L + 1)$; descompunerea SVD $X = \sum_i \sigma_i u_i v_i'$ Vautard și Ghil (1989)
- ▣ Grupăm tripletele proprii (tendința: u_i care variază lent; oscilațiile: perechi cu σ_i egale și sinusoidale decalate) și reconstruim fiecare grup prin medierea antidiagonalelor
- ▣ O bază adaptată la date în locul sinusoidelor sau al wavelets fixe; fără model și fără ipoteza de staționaritate; inferența este mai puțin dezvoltată
- ▣ O schiță de cod (ssa) se află în nucleul Quantlet al capitolului; este un reper natural pentru analiza multirezoluție wavelet

Recapitulare: spectre care se schimbă în timp

- Priestley și Dahlhaus dau un sens unui spectru variabil în timp
- O fereastră fixă schimbă rezoluția în timp pe rezoluția în frecvență
- Wavelets adaptează fereastra la frecvență; SSA adaptează baza la date

De la sinusoide la wavelets



Ingrid Daubechies, 2005

Foto: lucrarea autorului încărcării (2005);
domeniu public; Wikimedia Commons

- Un **wavelet** ψ : o undă scurtă, localizată în timp și în frecvență [Grossmann și Morlet \(1984\)](#)
 - ▶ $\int \psi = 0$, $\int \psi^2 = 1$; admisibil dacă $C_\psi = \int |\hat{\psi}(\omega)|^2 / |\omega| d\omega < \infty$, cu $\hat{\psi}$ transformata Fourier a lui ψ
- Transformata wavelet continuă (CWT): corelăm seria cu copii dilatate și translatate ale lui ψ

$$W(s, \tau) = \int x(t) \frac{1}{\sqrt{s}} \psi^* \left(\frac{t - \tau}{s} \right) dt$$

- ▶ $s > 0$: scala (invers legată de frecvență); τ : poziția în timp; ψ^* : conjugatul complex
- Wavelets ortonormate cu suport compact [Daubechies \(1988\)](#) și algoritmul piramidal [Mallat \(1989\)](#) dau DWT: n coeficienți pentru n observații; aplicații: [Crowley \(2007\)](#); [Gençay, Selçuk și Whitcher \(2002\)](#); [Aguiar-Conraria și Soares \(2014\)](#)

DWT, MODWT și analiza multirezoluție (1/2)

- Două filtre de lungime L Percival și Walden (2000)

de scalare (trece-jos): g_l , wavelet (trece-sus): $h_l = (-1)^l g_{L-1-l}$

- ▶ Haar $L = 2$; Daubechies cel mai puțin asimetric LA(8) $L = 8$; nivelul j captează perioadele $[2^j, 2^{j+1}]$: o bandă de o **octavă**; J niveluri plus o componentă netedă

- **MODWT** (DWT cu suprapunere maximă): fără eșantionare redusă, cu filtre rescalate

$$\tilde{h} = h/\sqrt{2}, \quad \tilde{g} = g/\sqrt{2}, \quad \tilde{W}_{j,t} = \sum_l \tilde{h}_{j,l} X_{t-l \bmod n}$$

- ▶ $\tilde{h}_{j,l}$: filtrul wavelet de nivel j ; $\tilde{W}_{j,t}$: coeficientul wavelet de nivel j la momentul t ; $\bmod n$: eșantionul este tratat circular

DWT, MODWT și analiza multirezoluție (2/2)

▣ Proprietățile MODWT

- ▶ orice mărime a eșantionului, invariantă la translații (mutarea datei de început nu schimbă coeficienții), $J \times n$ coeficienți
- ▶ energia se conservă: $\|X\|^2 = \sum_j \|\tilde{W}_j\|^2 + \|\tilde{V}_J\|^2$, cu $\tilde{V}_J$ coeficienții de scalare (netezi)


▣ Analiza multirezoluție (MRA): seria este suma detaliilor și a unei componente netede

$$X_t = \sum_{j=1}^J \mathcal{D}_{j,t} + \mathcal{S}_{J,t}$$

- ▶ $\mathcal{D}_j$: inversa MODWT a nivelului j singur; $\mathcal{S}_J$: componenta netedă; fără defazaj, aliniate cu datele

▣ Marginile: primii $L_j - 1 = (2^j - 1)(L - 1)$ coeficienți folosesc date de la celălalt capăt (filtrare circulară) și se exclud din estimare

Filtre wavelet și wavelet-ul Morlet




□ Stînga: pătratele câștigurilor filtrelor MODWT LA(8) pentru nivelurile 1–5; dreapta: wavelet-ul Morlet

$$\psi_0(\eta) = \pi^{-1/4} e^{i\omega_0 \eta} e^{-\eta^2/2}, \quad \omega_0 = 6$$

Interpretarea filtrelor wavelet

- ▣ Fiecare nivel MODWT este un filtru trece-bandă aproximativ pentru o octavă; benzile se suprapun, deci leakage-ul între niveluri vecine face parte din construcție
- ▣ Lățimea benzii crește cu frecvența: rezoluție fină în frecvență pentru ciclurile lungi, rezoluție fină în timp pentru cele scurte
- ▣ Morlet este complex: modulul dă amplitudinea, argumentul dă faza; perioada Fourier = $1,033 \times$ scala pentru $\omega_0 = 6$
- ▣ Filtrele ortonormate (MODWT) servesc descompunerii varianței și corelației pe scale; CWT Morlet servește hărților timp-frecvență și fazei

Randamentul BET descompus pe scale



- Analiza multirezoluție MODWT, LA(8), $J = 6$, randamentele zilnice BET 2000–2026 (6 670 de zile); patru dintre cele șase detalii și componenta netedă

Interpretarea analizei multirezoluție

- ▣ Ponderile energiei pe nivelurile 1–6: 43,0; 26,6; 15,0; 6,8; 3,5; 2,3%; un zgomot alb ar da 50,0; 25,0; 12,5; 6,2; 3,1; 1,6%
- ▣ Mai puțină energie la scala cea mai scurtă și mai multă la scalele lungi decât un zgomot alb: autocorelația pozitivă a randamentelor BET la orizonturi scurte
- ▣ Volatility clustering apare la toate scalele în 2008 și 2020, dar componentele lente ($\mathcal{D}_6$, $\mathcal{S}_6$) se mișcă doar în criza din 2008–2009
- ▣ Detaliile se adună exact la serie: o descompunere fără pierderi și fără defazaj

Varianța, corelația și beta wavelet pe scale (1/2)

- ▣ **Varianța wavelet:** varianța coeficienților de nivel j ; nivelurile însumează varianța seriei [Percival \(1995\)](#)

$$\nu_X^2(\tau_j) = \text{Var} \tilde{W}_{j,t}, \quad \sum_j \nu_X^2(\tau_j) = \text{Var} X$$

- ▶ $\tau_j = 2^{j-1}$: scala nivelului j ; o versiune pe octave a spectrului; zgomot alb: $\nu^2(\tau_j) = \sigma^2/2^j$, se înjumătățește la fiecare nivel
- ▶ estimatorul nedeplasat: media lui $\tilde{W}_{j,t}^2$ pe cei $M_j = n - L_j + 1$ coeficienți din afara marginilor; $\eta \hat{\nu}^2 / \nu^2 \approx \chi_\eta^2$, cu $\eta = \max(M_j/2^j, 1)$ grade de libertate echivalente

Varianța, corelația și beta wavelet pe scale (2/2)


- ▣ **Corelația wavelet** Whitcher, Guttorp și Percival (2000) și **beta wavelet** Gençay, Selçuk și Whitcher (2005)

$$\rho_{XY}(\tau_j) = \frac{\text{Cov}(\tilde{W}_j^X, \tilde{W}_j^Y)}{\nu_X(\tau_j)\nu_Y(\tau_j)}$$

$$\beta(\tau_j) = \frac{\text{Cov}(\tilde{W}_j^r, \tilde{W}_j^m)}{\text{Var}\tilde{W}_j^m}$$

- ▶ $\tilde{W}_j^r, \tilde{W}_j^m$: coeficienții randamentului unui activ și ai randamentului pieței; $\beta(\tau_j)$: riscul sistematic la orizontul de investiție τ_j
- ▶ intervalul de 95% pentru corelație: $\tanh\left(\tanh^{-1}\hat{\rho} \pm z/\sqrt{M_j/2^j - 3}\right)$, $z = 1,96$
- ▣ Mărimea efectivă a eșantionului se înjumătățește la fiecare nivel: estimările pe scale lungi sînt largi chiar și cu 25 de ani de date zilnice

Varianța wavelet a trei indici bursieri




- Randamente logaritmice zilnice 2000–2026, MODWT LA(8), nivelurile 1–8 cu intervale de 95%; linii întrerupte: zgomot alb cu aceeași varianță la nivelul 1

Interpretarea varianțelor wavelet

- ▣ Raportul dintre varianța de la nivelul 6 (64–128 de zile) și linia zgomotului alb: BET 1,60, DAX 0,97, S&P 500 0,75
- ▣ BET are mai multă varianță pe orizonturi lungi decât implică varianța zilnică (nivelul 8: 2,25): momentum, o piață mică; S&P 500 are mai puțină (0,59): revenirea la medie a mișcărilor zilnice
- ▣ Este testul raportului varianțelor pentru eficiența pieței, făcut scală cu scală, cu intervale valide
- ▣ Riscul măsurat pe date zilnice și scalat cu $\sqrt{h}$ subestimează riscul BET pe orizonturi lungi

Co-mișcarea pe scale: BET, DAX și S&P 500



- ☐ Randamente zilnice în 6 433 de zile comune de tranzacționare, MODWT LA(8); stînga: trei perechi, 2000–2026; dreapta: BET–DAX în două jumătăți; intervale Fisher-z de 95%

Interpretarea corelațiilor wavelet

- BET–DAX crește de la 0,26 (2–4 zile) la 0,77 (256–512 zile); corelația zilnică (0,31) subestimează integrarea pe termen lung
- BET–S&P 500 la nivelul 1 este doar 0,13, DAX–S&P 500 0,50: New York închide după Europa, deci co-mișcarea zilnică apare cu o zi întârziere; dispare la scale mai lungi
- BET–DAX la 8–16 zile: 0,34 în 2000–2012 față de 0,47 în 2013–2026 (nivelul 3): integrarea a crescut la scale scurte și medii
- Beta wavelet a BET față de DAX: 0,24 la nivelul 1, 0,56 la nivelul 6: beneficiul diversificării prin BET scade cu orizontul (Gençay, Selçuk și Whitcher (2005); Rua și Nunes (2009))

Recapitulare: wavelets: descompunerea pe scale

- MODWT împarte varianța și covarianța pe benzi de o octavă, pentru orice n și fără defazaj
- Varianța wavelet este un test al raportului varianțelor scală cu scală; corelația și beta wavelet arată integrarea pe orizonturi
- Excludeți coeficienții de margine și folosiți grade de libertate echivalente pentru intervale

Transformata Morlet și semnificația ei (1/2)

- ▣ **Torrence și Compo (1998)**: CWT calculată prin FFT pe o grilă de scale

$$W_n(s) = \sum_k \hat{x}_k \hat{\psi}^*(s\omega_k) e^{i\omega_k n\delta t}, \quad s_j = s_0 2^{j\delta j}$$

- ▶ $\hat{x}_k$: DFT al seriei la frecvența ω_k ; $\hat{\psi}$: transformata Fourier a wavelet-ului Morlet; δt : pasul de timp; s_0 : scala cea mai mică; δj : pasul scalelor, în octave
- ▶ puterea wavelet $|W_n(s)|^2$: varianța seriei la momentul n și scala s
- ▣ **Conul de influență** (COI): zona în care wavelet-ul de scală s atinge marginea, la mai puțin de $\sqrt{2}s$ de oricare capăt
 - ▶ rezultatele din COI sînt deplasate și nu se interpretează

Transformata Morlet și semnificația ei (2/2)

- Ipoteza nulă de zgomot roșu, un AR(1) cu autocorelația de ordinul 1 egală cu a : puterea este o variabilă χ_2^2 scalată

$$\frac{|W_n(s)|^2}{\sigma^2} \sim P_k \frac{\chi_2^2}{2}, \quad P_k = \frac{1 - a^2}{1 + a^2 - 2a \cos(2\pi k/N)}$$


- ▶ σ^2 : varianța seriei; P_k : spectrul zgomotului roșu la indicele Fourier k care corespunde scalei s ; N : numărul de observații

- Spectrul wavelet global: media în timp a puterii, un spectru Fourier netezit

$$\bar{W}^2(s) = \frac{1}{n} \sum_n |W_n(s)|^2, \quad \nu = 2 \sqrt{1 + \left(\frac{n\delta t}{2,32 s} \right)^2} \text{ grade de libertate}$$

- Rectificați puterea prin $1/s$ când comparați scalele [Liu, Liang și Weisberg \(2007\)](#); testul punctual se aplică în mii de puncte: așteptați 5% zone false [Maraun și Kurths \(2004\)](#)

Puterea wavelet a BET



- Randamente săptămânale BET (standardizate), 1 379 de săptămîni 2000–2026, Morlet $\omega_0 = 6$, $\delta j = 1/12$; contururi negre: testul de 5% față de zgomotul roșu; hașurat: conul de influență; dreapta: spectrul wavelet global

Q ATS_ch11_wavelet_coherence

Interpretarea puterii wavelet

- ▣ Puterea maximă la perioada de 2,6 săptămîni, la 17 octombrie 2008: săptămînilile Lehman; putere semnificativă în 2007–2011 la perioade de 32–128 de săptămîni
- ▣ Autocorelația de ordinul 1 este 0,04: ipoteza nulă de zgomot roșu este aproape albă; 11% din aria fiabilă este semnificativă la 5%
- ▣ Puterea în randamente este varianță, nu un ciclu: harta arată cînd s-a concentrat volatilitatea și la ce orizonturi
- ▣ Spectrul global rămîne în interiorul benzii zgomotului roșu: niciun ciclu persistent în randamentele BET, cum prezice eficiența pieței

Coerența și faza wavelet (1/2)

- Transformata wavelet încrucișată și **coerența wavelet pătratică** Torrence și Webster (1999), Grinsted, Moore și Jevrejeva (2004)

$$W_n^{xy}(s) = W_n^x(s) W_n^{y*}(s)$$


$$R_n^2(s) = \frac{|\mathcal{S}(s^{-1} W_n^{xy}(s))|^2}{\mathcal{S}(s^{-1} |W_n^x(s)|^2) \mathcal{S}(s^{-1} |W_n^y(s)|^2)} \in [0, 1]$$

- $\mathcal{S}$: netezirea, gaussiană în timp (lățime s) și o medie pe 0,6 octave în scală; $R_n^2(s)$: un R^2 local la momentul n și scala s
- fără netezire $R^2 \equiv 1$, ca pentru coerența brută: netezirea o face un estimator

Coerența și faza wavelet (2/2)

- Faza $\arg S(s^{-1}W^{xy})$, reprezentată prin săgeți
 - ▶ spre dreapta = în fază, spre stînga = în antifază, în sus = $\times$ conduce; avansul în timp = faza $\times$ perioada/ 2π
- Semnificația prin **Monte Carlo** [Grinsted, Moore și Jevrejeva \(2004\)](#)
 - ▶ simulăm perechi de serii AR(1) independente cu autocorelațiile de ordinul 1 ale datelor; percentila 95 a lui R^2 la fiecare scală este pragul de 5%
- Extensii: coerența wavelet parțială și multiplă, diferențe de fază cu benzi de încredere [Aguiar-Conraria și Soares \(2014\)](#); politica monetară [Aguiar-Conraria, Azevedo și Soares \(2008\)](#); energie [Vacha și Barunik \(2012\)](#)

BET și DAX în timp și frecvență




- Randamente săptămânale 2000–2026; contururi: semnificația de 5% din 500 de perechi AR(1); săgeți doar unde coerența este semnificativă

Interpretarea coerenței BET–DAX

- 23% din aria fiabilă este semnificativă (percentila 95 sub ipoteza nulă: 7,7%): co-mișcarea este reală, dar concentrată
- R^2 mediu la 8–64 de săptămîni: 0,37 în 2000–2006, 0,76 în 2008–2009, 0,36 în 2014–2019, 0,77 în 2020–iunie 2021
- Faza aproape zero în crize (0,03 rad în 2008–2009), negativă înainte de 2007 (–0,97 rad): DAX conducea BET cu cîteva săptămîni cînd piața de la București era tînă ră
- Crizele cresc coerența: este contagiune sau doar volatilitate mai mare? Corelațiile cresc mecanic cu volatilitatea [Forbes și Rigobon \(2002\)](#), la fel și R^2

BET și S&P 500 în timp și frecvență




- Randamente săptămânale 2000–2026; semnificația Monte Carlo ca mai înainte

Q ATS_ch11_wavelet_coherence

Interpretarea coerenței BET-S&P 500

- ▣ Aria semnificativă 26% (percentila 95 sub ipoteza nulă: 7,7%); R^2 la 8–64 de săptămîni 0,76 în 2008–2009 și 0,48 în 2014–2019
- ▣ În 2000–2006 faza este $-1,24$ rad: S&P 500 conducea cu circa o cincime din ciclu; în crize piețele se mișcă în fază
- ▣ Datele săptămînale elimină întârzierea de o zi din corelația wavelet zilnică: alegerea frecvenței datelor contează pentru afirmațiile despre avans și întârziere
- ▣ Imaginea noastră confirmă evidența internațională: co-mișcarea este cea mai puternică la frecvențe joase și în crize [Rua și Nunes \(2009\)](#)

Petrolul și acțiunile




- Randamente săptămânale ale petrolului Brent (FRED) și ale S&P 500, 2000–2026; semnificația Monte Carlo din 500 de perechi AR(1)

Interpretarea coerenței petrol–acțiuni

- ▣ Aria semnificativă 15% (percentila 95 sub ipoteza nulă: 7,1%): petrolul și acțiunile sînt legate doar în anumite episoade
- ▣ Înainte de 2007: R^2 0,41, cu faza $-1,86$ rad, nici în fază, nici în antifază: o legătură slabă, de tip avans–întîrziere; 2008–2010: 0,70, în fază ($-0,09$ rad): un șoc comun de cerere
- ▣ 2020–2021: 0,58 în fază; 2022–2023: faza $-2,31$ rad, mai aproape de antifază: șocul prețurilor energiei din timpul războiului din Ucraina
- ▣ Semnul legăturii petrol–acțiuni depinde de tipul de șoc [Kilian și Park \(2009\)](#); faza wavelet arată schimbarea fără să o identifice

Inflația în România și în zona euro



- Inflația anuală HICP (lunar), ianuarie 2001 – august 2026; semnificația Monte Carlo față de perechi AR(1) cu autocorelația de ordinul 1 egală cu 0,97

Interpretarea co-mișcării inflației

- România–zona euro: R^2 la 24–64 de luni 0,23 în 2002–2012, 0,85 din 2015; aria semnificativă 17% (percentila 95 sub ipoteza nulă: 8,7%)
- Polonia: 0,29 și 0,91; corelații simple 0,34 (România) și 0,86 (Polonia): dezinflația României pînă în 2012 a fost internă, ciclul de după 2015 este comun
- Creșterea din 2021–2024, 12–48 de luni: R^2 0,78, faza 0,14 rad: niciun avans detectabil, un șoc energetic comun
- Ratele anuale se suprapun pe douăsprezece luni: perioadele scurte sînt netezite prin construcție; doar ciclurile mai lungi de un an sînt informative

Recapitulare: coerența wavelet

- Coerența wavelet este o coerență locală în timp, netezită; fără netezire este identic egală cu unu
- Testați-o prin Monte Carlo față de perechi AR(1); citiți faza doar în zonele semnificative și în afara conului de influență
- Co-mișcarea acțiunilor este maximă în crize și pe orizonturi lungi; faza petrol-acțiuni se inversează cu tipul de șoc

O întrebare deschisă

- Este creșterea coerenței dintre piețele bursiere în crize contagiune sau efectul mecanic al volatilității mai mari asupra unui R^2 local în timp?
 - ▶ formal: H_0 : coerența wavelet dintre BET și DAX în ferestrele de criză preînregistrate este egală cu valoarea ei într-un model cu aceleași volatilități variabile în timp și dependență constantă
 - ▶ infirmată dacă coerența din criză depășește percentila 95 a unui bootstrap dintr-un DCC-GARCH cu corelație constantă (Capitolul 8), la scale preînregistrate
- Miza: diversificarea eșuează tocmai când este nevoie de ea; corecția Forbes–Rigobon există pentru corelații, nu și pentru coerența wavelet
 - ▶ literatura de pornire: Forbes și Rigobon (2002), Rua și Nunes (2009), Maraun și Kurths (2004), Schulte (2016), Aguiar-Conraria și Soares (2014)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate din 2009 încoace care testează coerența wavelet dintre piețe bursiere față de o ipoteză nulă cu aceeași volatilitate; dă DOI-urile. Apoi verificați fiecare DOI pe Crossref
 - ▶ **ipoteza:** Derivează deplasarea coerenței wavelet netezite când ambele serii au o volatilitate GARCH comună și corelație constantă.
 - ▶ **cod și replicare:** cereți operatorul de netezire Grinsted, apoi reproduceți întâi un caz cunoscut (două serii AR(1): 5% arie semnificativă)
 - ▶ **critica:** Joacă rolul unui recenzent ostil: enumeră felurile în care poate apărea o insulă semnificativă de coerență wavelet fără nicio schimbare a dependenței.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Convențiile: frecvență unghiulară sau cicluri, factorii 2π , perioada = $1,033 \times$ scala pentru Morlet, convenția de semn a fazei
- ▣ Coerența este netezită; pragul ei și ipoteza nulă Monte Carlo sînt precizate; nimic nu se interpretează în conul de influență
- ▣ Semnificația punctuală nu este semnificație pe arii: numărați cîte insule produce ipoteza nulă
- ▣ Filtre: cîștigul precizat; ciclul în timp real separat de cel final; rezultate cu și fără șocurile comune extreme

Mini studiu de caz: cîte insule produce întîmplarea?



- Ponderea ariei timp–perioadă fiabile dintr-o hartă de coerență wavelet care este semnificativă punctual la 5%: 200 de perechi noi de serii AR(1) independente, cu autocorelațiile BET și DAX, și harta observată BET–DAX
- Ipoteza nulă: media 5,0%, percentila 95 7,7%, maximum 9,0%; 100% din hărțile nule conțin insule semnificative; BET–DAX: 22,7%. Un rezumat AI care citește fiecare insulă ca un episod de contagiune greșește; surplusul total este real

Idee de proiect

- ▣ **Contagiune sau volatilitate? Coerența wavelet a piețelor bursiere din Europa Centrală și de Est sub o ipoteză nulă cu aceeași volatilitate**
 - ▶ replicați: testul Monte Carlo al lui [Grinsted, Moore și Jevrejeva \(2004\)](#) și hărțile de co-mișcare internațională ale lui [Rua și Nunes \(2009\)](#) pe BET, WIG20, BUX, PX față de DAX
 - ▶ extindeți: o ipoteză nulă bootstrap dintr-un DCC-GARCH (dependență constantă, volatilitate variabilă); teste pe arii [Schulte \(2016\)](#); coerență parțială controlînd pentru S&P 500 [Aguilar-Conraria și Soares \(2014\)](#)
 - ▶ preînregistrați: piețele, frecvența datelor, ferestrele de criză, scalele, modelul nul și numărul de replicări
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Spectrul descompune varianța pe frecvențe; filtrele acționează asupra lui prin pătratul câștigului
- ▣ Estimarea este o alegere deplasare–varianță; multitaper dă leakage mic, varianță stabilă și benzi corecte
- ▣ Coerența, faza, corelația dinamică și testele Breitung–Candelon descriu co-mișcarea și cauzalitatea pe frecvențe
- ▣ Un ciclu economic este ceea ce lasă să treacă câștigul filtrului; HP adaugă cicluri false și eșuează în timp real
- ▣ Wavelets localizează varianța și co-mișcarea în timp și pe scale; semnificația cere Monte Carlo și o judecată pe arii

Autoevaluare

Întrebări

- ▣ De ce este periodograma inconsistentă, deși este asimptotic nedeplasată?
- ▣ Cum crește lățimea de bandă optimă cu n pentru un nucleu cu $q = 2$?
- ▣ De ce este coerența brută (nenetezită) întotdeauna egală cu unu?
- ▣ De unde provine vârful ciclului HP al unui mers aleator?
- ▣ De ce este preferată MODWT față de DWT pentru varianța wavelet?

Urmează:

- ▣ Machine learning și deep learning pentru serii de timp
- ▣ modele globale, validare fără leakage, arhitecturi deep

Anexă: distribuția periodogramei

- ▣ Zgomot alb gaussian: $a_j = \sqrt{2/n} \sum_t x_t \cos(\omega_j t)$, $b_j = \sqrt{2/n} \sum_t x_t \sin(\omega_j t)$ sînt i.i.d. $N(0, \sigma^2)$ pentru $0 < \omega_j < \pi$ (ortogonalitatea bazei Fourier)
- ▣ $I(\omega_j) = (a_j^2 + b_j^2)/(4\pi) = \frac{\sigma^2}{2\pi} \cdot \frac{\chi_2^2}{2}$: media $f = \sigma^2/(2\pi)$, varianța f^2 , oricare ar fi n
- ▣ Proces liniar: $d_X(\omega_j) = \Psi(e^{-i\omega_j})d_\varepsilon(\omega_j) + o_p(1)$, deci $I_X(\omega_j) \approx |\Psi(e^{-i\omega_j})|^2 I_\varepsilon(\omega_j) = f(\omega_j) \chi_2^2/2$
- ▣ Medierea a L astfel de ordonate: media f , varianța f^2/L ; aceasta este logica oricărui estimator netezit sau multitaper

Anexă: două proprietăți ale filtrelor

- ▣ **Coerența este invariantă la filtrare:** $\tilde{x} = A(L)x$, $\tilde{y} = B(L)y$ dau $f_{\tilde{x}\tilde{y}} = A(\omega)\overline{B(\omega)}f_{xy}$, $f_{\tilde{x}} = |A|^2 f_x$, $f_{\tilde{y}} = |B|^2 f_y$, deci $\kappa_{\tilde{x}\tilde{y}}^2 = \kappa_{xy}^2$ acolo unde $A, B \neq 0$
- ▣ Faza se schimbă cu $\arg A - \arg B$: o prealbire cu filtre diferite mută faza; folosiți același filtru pentru ambele serii
- ▣ **Ciclul HP al unui mers aleator:** $\Delta y = \varepsilon$, deci $f_c(\omega) = G(\omega)^2 \sigma^2 / (2\pi \cdot 2(1 - \cos \omega))$; cu $u = 1 - \cos \omega$, aceasta este proporțională cu $u^3 / (1 + 4\lambda u^2)^2$
- ▣ Anulînd derivata: $3(1 + 4\lambda u^2) = 16\lambda u^2$, deci $u^* = \sqrt{3/(4\lambda)}$, iar perioada este $2\pi / \arccos(1 - u^*)$

Bibliografie (1/3)

- ▣ Aguiar-Conraria, L., Azevedo, N., & Soares, M. J. (2008). Using wavelets to decompose the time–frequency effects of monetary policy. *Physica A*, 387(12), 2863–2878. doi:10.1016/j.physa.2008.01.063
- ▣ Aguiar-Conraria, L., & Soares, M. J. (2014). The continuous wavelet transform: Moving beyond uni- and bivariate analysis. *Journal of Economic Surveys*, 28(2), 344–375. doi:10.1111/joes.12012
- ▣ Andrews, D. W. K. (1991). Heteroskedasticity and autocorrelation consistent covariance matrix estimation. *Econometrica*, 59(3), 817–858. doi:10.2307/2938229
- ▣ Baxter, M., & King, R. G. (1999). Measuring business cycles: Approximate band-pass filters for economic time series. *Review of Economics and Statistics*, 81(4), 575–593. doi:10.1162/003465399558454
- ▣ Breitung, J., & Candelon, B. (2006). Testing for short- and long-run causality: A frequency-domain approach. *Journal of Econometrics*, 132(2), 363–378. doi:10.1016/j.jeconom.2005.02.004
- ▣ Brockwell, P. J., & Davis, R. A. (1991). *Time Series: Theory and Methods* (2nd ed.). Springer. doi:10.1007/978-1-4419-0320-4
- ▣ Christiano, L. J., & Fitzgerald, T. J. (2003). The band pass filter. *International Economic Review*, 44(2), 435–465. doi:10.1111/1468-2354.t01-1-00076
- ▣ Cogley, T., & Nason, J. M. (1995). Effects of the Hodrick–Prescott filter on trend and difference stationary time series: Implications for business cycle research. *Journal of Economic Dynamics and Control*, 19(1–2), 253–278. doi:10.1016/0165-1889(93)00781-X
- ▣ Croux, C., Forni, M., & Reichlin, L. (2001). A measure of comovement for economic variables: Theory and empirics. *Review of Economics and Statistics*, 83(2), 232–241. doi:10.1162/00346530151143770
- ▣ Crowley, P. M. (2007). A guide to wavelets for economists. *Journal of Economic Surveys*, 21(2), 207–267. doi:10.1111/j.1467-6419.2006.00502.x
- ▣ Dahlhaus, R. (1997). Fitting time series models to nonstationary processes. *The Annals of Statistics*, 25(1), 1–37. doi:10.1214/aos/1034276620
- ▣ Daubechies, I. (1988). Orthonormal bases of compactly supported wavelets. *Communications on Pure and Applied Mathematics*, 41(7), 909–996. doi:10.1002/cpa.3160410705
- ▣ Fidrmuc, J., & Korhonen, I. (2006). Meta-analysis of the business cycle correlation between the euro area and the CEECs. *Journal of Comparative Economics*, 34(3), 518–537. doi:10.1016/j.jce.2006.06.007
- ▣ Forbes, K. J., & Rigobon, R. (2002). No contagion, only interdependence: Measuring stock market comovements. *The Journal of Finance*, 57(5), 2223–2261. doi:10.1111/0022-1082.00494
- ▣ Gençay, R., Selçuk, F., & Whitcher, B. (2005). Multiscale systematic risk. *Journal of International Money and Finance*, 24(1), 55–70. doi:10.1016/j.jimonfin.2004.10.003
- ▣ Gençay, R., Selçuk, F., & Whitcher, B. (2002). Wavelets for variance–covariance estimation. In *An Introduction to Wavelets and Other Filtering Methods in Finance and Economics*. Academic Press. doi:10.1016/B978-012279670-8.50010-0

Bibliografie (2/3)

- ▣ Geweke, J. (1982). Measurement of linear dependence and feedback between multiple time series. *Journal of the American Statistical Association*, 77(378), 304–313. doi:10.1080/01621459.1982.10477803
- ▣ Granger, C. W. J. (1966). The typical spectral shape of an economic variable. *Econometrica*, 34(1), 150–161. doi:10.2307/1909859
- ▣ Grinsted, A., Moore, J. C., & Jevrejeva, S. (2004). Application of the cross wavelet transform and wavelet coherence to geophysical time series. *Nonlinear Processes in Geophysics*, 11(5/6), 561–566. doi:10.5194/npg-11-561-2004
- ▣ Grossmann, A., & Morlet, J. (1984). Decomposition of Hardy functions into square integrable wavelets of constant shape. *SIAM Journal on Mathematical Analysis*, 15(4), 723–736. doi:10.1137/0515056
- ▣ Hamilton, J. D. (2018). Why you should never use the Hodrick–Prescott filter. *The Review of Economics and Statistics*, 100(5), 831–843. doi:10.1162/rest_a_00706
- ▣ Harding, D., & Pagan, A. (2002). Dissecting the cycle: A methodological investigation. *Journal of Monetary Economics*, 49(2), 365–381. doi:10.1016/S0304-3932(01)00108-8
- ▣ Hodrick, R. J., & Prescott, E. C. (1997). Postwar U.S. business cycles: An empirical investigation. *Journal of Money, Credit and Banking*, 29(1), 1–16. doi:10.2307/2953682
- ▣ Hurvich, C. M. (1985). Data-driven choice of a spectrum estimate: Extending the applicability of cross-validation methods. *Journal of the American Statistical Association*, 80(392), 933–940. doi:10.1080/01621459.1985.10478207
- ▣ Kilian, L., & Park, C. (2009). The impact of oil price shocks on the U.S. stock market. *International Economic Review*, 50(4), 1267–1287. doi:10.1111/j.1468-2354.2009.00568.x
- ▣ Liu, Y., San Liang, X., & Weisberg, R. H. (2007). Rectification of the bias in the wavelet power spectrum. *Journal of Atmospheric and Oceanic Technology*, 24(12), 2093–2102. doi:10.1175/2007JTECHO511.1
- ▣ Mallat, S. G. (1989). A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7), 674–693. doi:10.1109/34.192463
- ▣ Maraun, D., & Kurths, J. (2004). Cross wavelet analysis: Significance testing and pitfalls. *Nonlinear Processes in Geophysics*, 11(4), 505–514. doi:10.5194/npg-11-505-2004
- ▣ Parzen, E. (1961). Mathematical considerations in the estimation of spectra. *Technometrics*, 3(2), 167–190. doi:10.1080/00401706.1961.10489939
- ▣ Percival, D. B. (1995). On estimation of the wavelet variance. *Biometrika*, 82(3), 619–631. doi:10.1093/biomet/82.3.619
- ▣ Percival, D. B., & Walden, A. T. (1993). *Spectral Analysis for Physical Applications: Multitaper and Conventional Univariate Techniques*. Cambridge University Press. doi:10.1017/CBO9780511622762
- ▣ Percival, D. B., & Walden, A. T. (2000). *Wavelet Methods for Time Series Analysis*. Cambridge University Press. doi:10.1017/CBO9780511841040

Bibliografie (3/3)

- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Phillips, P. C. B., & Shi, Z. (2021). Boosting: Why you can use the HP filter. *International Economic Review*, 62(2), 521–570. doi:10.1111/iere.12495
- ▣ Priestley, M. B. (1965). Evolutionary spectra and non-stationary processes. *Journal of the Royal Statistical Society: Series B*, 27(2), 204–229. doi:10.1111/j.2517-6161.1965.tb01488.x
- ▣ Quast, J., & Wolters, M. H. (2022). Reliable real-time output gap estimates based on a modified Hamilton filter. *Journal of Business & Economic Statistics*, 40(1), 152–168. doi:10.1080/07350015.2020.1784747
- ▣ Ravn, M. O., & Uhlig, H. (2002). On adjusting the Hodrick–Prescott filter for the frequency of observations. *Review of Economics and Statistics*, 84(2), 371–376. doi:10.1162/003465302317411604
- ▣ Riedel, K. S., & Sidorenko, A. (1995). Minimum bias multiple taper spectral estimation. *IEEE Transactions on Signal Processing*, 43(1), 188–195. doi:10.1109/78.365298
- ▣ Rua, A., & Nunes, L. C. (2009). International comovement of stock market returns: A wavelet analysis. *Journal of Empirical Finance*, 16(4), 632–639. doi:10.1016/j.jempfin.2009.02.002
- ▣ Schulte, J. A. (2016). Cumulative areawise testing in wavelet analysis and its application to geophysical time series. *Nonlinear Processes in Geophysics*, 23(1), 45–57. doi:10.5194/npg-23-45-2016
- ▣ Shumway, R. H., & Stoffer, D. S. (2017). *Time Series Analysis and Its Applications: With R Examples* (4th ed.). Springer. doi:10.1007/978-3-319-52452-8
- ▣ Thomson, D. J. (1982). Spectrum estimation and harmonic analysis. *Proceedings of the IEEE*, 70(9), 1055–1096. doi:10.1109/PROC.1982.12433
- ▣ Torrence, C., & Compo, G. P. (1998). A practical guide to wavelet analysis. *Bulletin of the American Meteorological Society*, 79(1), 61–78. doi:10.1175/1520-0477(1998)079<0061:APGTWA>2.0.CO;2
- ▣ Torrence, C., & Webster, P. J. (1999). Interdecadal changes in the ENSO–monsoon system. *Journal of Climate*, 12(8), 2679–2690. doi:10.1175/1520-0442(1999)012<2679:ICITEM>2.0.CO;2
- ▣ Vacha, L., & Barunik, J. (2012). Co-movement of energy commodities revisited: Evidence from wavelet coherence analysis. *Energy Economics*, 34(1), 241–247. doi:10.1016/j.eneco.2011.10.007
- ▣ Vautard, R., & Ghil, M. (1989). Singular spectrum analysis in nonlinear dynamics, with applications to paleoclimatic time series. *Physica D*, 35(3), 395–424. doi:10.1016/0167-2789(89)90077-8
- ▣ Welch, P. D. (1967). The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. *IEEE Transactions on Audio and Electroacoustics*, 15(2), 70–73. doi:10.1109/TAU.1967.1161901
- ▣ Whitcher, B., Guttorp, P., & Percival, D. B. (2000). Wavelet analysis of covariance with application to atmospheric time series. *Journal of Geophysical Research: Atmospheres*, 105(D11), 14941–14962. doi:10.1029/2000JD900110