



Analiza avansată a seriilor de timp și previziune

Capitolul 12: Machine learning și deep learning pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ACF: Autocorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARIMA: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ARMA: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ARX: AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- BPTT: BackPropagation Through Time (retropropagarea în timp)
- CRPS: Continuous Ranked Probability Score (scorul probabilistic continuu)
- CUDA: Compute Unified Device Architecture (arhitectura de calcul paralel NVIDIA)
- DM: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ENTSO-E: European Network of Transmission System Operators for Electricity (Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- ERM: Empirical Risk Minimisation (minimizarea riscului empiric)
- ES-RNN: Exponential Smoothing – Recurrent Neural Network (hybrid) — hibridul netezire exponențială – rețea recurentă (Smyl 2020)
- ETS: Error, Trend, Seasonality (exponential smoothing state space models) — eroare, trend, sezonabilitate (modele de netezire exponențială)
- ETT: Electricity Transformer Temperature (data set) — setul de date Electricity Transformer Temperature
- FFT: Fast Fourier Transform (transformata Fourier rapidă)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GRN: Gated Residual Network (rețea reziduală cu poartă)
- GRU: Gated Recurrent Unit (unitate recurentă cu porți)
- GW: Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- HAR: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- HGB: Histogram Gradient Boosting (gradient boosting pe histograme)
- HLN: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- IAPC: Indicele armonizat al prețurilor de consum

Acronime folosite în acest material (2/3)

- KKT: Karush–Kuhn–Tucker (conditions) — condițiile Karush–Kuhn–Tucker
- LLM: Large Language Model (model lingvistic de mari dimensiuni)
- LOOCV: Leave-One-Out Cross-Validation (validare încrucișată cu omiterea câte unei observații)
- LSTM: Long Short-Term Memory (network) — rețea cu memorie pe termen lung și scurt
- LTSF: Long-Term Series Forecasting (proгноza seriilor pe termen lung)
- MA: Moving Average (medie mobilă)
- MAE: Mean Absolute Error (eroarea absolută medie)
- MAPAE: Mean Absolute Predictive Accuracy Error (eroarea absolută medie a estimării acurateței)
- MASE: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MIMO: Multiple-Input Multiple-Output (forecast strategy) — strategia cu ieșiri multiple
- ML: Machine Learning (învățare automată)
- MLP: MultiLayer Perceptron (perceptron multistrat)
- MPAAE: Mean Predictive Accuracy Error (eroarea medie (deplasarea) a estimării acurateței)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MT: Malta (country code) — Malta (codul țării)
- MW: MegaWatt (megawatt)
- NL: NonLinear (shrinkage) — neliniar (shrinkage)
- NVIDIA: NVIDIA Corporation (graphics processors) — compania NVIDIA (procesoare grafice)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- OOS: Out-Of-Sample (în afara eșantionului)
- OWA: Overall Weighted Average (of sMAPE and MASE relative to Naive 2) — media ponderată generală a sMAPE și MASE relative la Naive 2
- QLIKE: Quasi-LIKelihood loss (pierdere de tip cvasi-verosimilitate)
- QRF: Quantile Regression Forest (pădure de regresie cuantilică)
- RF: Risk-Free rate (Fama–French data) / Random Forest (machine learning) — rata fără risc (datele Fama–French) / pădure aleatoare (machine learning)
- RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)

Acronime folosite în acest material (3/3)

- RNN: Recurrent Neural Network (rețea neuronală recurentă)
- RV: Realised Variance (varianța realizată)
- SGD: Stochastic Gradient Descent (coborîre stochastică pe gradient)
- SHAP: SHapley Additive exPlanations (explicații aditive Shapley)
- SPA: Superior Predictive Ability (test) — testul abilității predictive superioare
- SUA: Statele Unite ale Americii
- TCN: Temporal Convolutional Network (rețea convoluțională temporală)
- TFT: Temporal Fusion Transformer (Transformer de fuziune temporală (Lim et al. 2021))
- TSA: Time Series Analysis (Serii de timp, cursul de licență)
- UE: Uniunea Europeană
- VAR: Vector Autoregression (model vector autoregresiv)
- VC: Vapnik–Chervonenkis (dimension) — dimensiunea Vapnik–Chervonenkis
- VIX: CBOE Volatility Index (indicele de volatilitate CBOE)
- WIG20: Warszawski Indeks Giełdowy 20 (indicele celor mai mari 20 de companii de la Bursa din Varșovia)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** când prognozează instrumentele flexibile (regresii penalizate, ansambluri de arbori, rețele deep) seriile de timp mai bine decât reperele statistice puternice și cum stabilim aceasta onest?
 - ▶ dependența strică logică i.i.d. a machine learning: validarea, generalizarea și inferența se schimbă toate
- ▣ **Traseul** capitolului
 - ▶ învățarea din date dependente: mixing, margini de eroare, când este validă validarea încrucișată
 - ▶ modele globale și locale; lasso și variantele lui în dimensiune mare; ansambluri de arbori în profunzime
 - ▶ rețele recurente și convoluționale; atenție și Transformers; N-BEATS, N-HiTS, DeepAR, TFT
 - ▶ interpretare și comparația onestă: repere, teste, data snooping
- ▣ Pornim de la [TSA](#), [Capitolul 9](#) (variabile cu decalaje, validare walk-forward, arbori, un MLP mic, M4 și M5) și de la [Capitolul 1](#) (DM, MCS, reguli de scor); Seminarul 12 are loc înaintea acestui curs

Rezultatele învățării

- Enunțați când este validă validarea încrucișată cu K subeșantioane pentru predicția autoregresivă și construiți validări pe blocuri, cu purjare și cu origine mobilă, fără scurgere de informație
- Deduceți soluțiile lasso, lasso adaptiv și elastic net, enunțați condițiile lor de consistență pentru date dependente și explicați de ce inferența naivă după selecție eșuează
- Explicați mecanica deplasare–varianță pentru bagging, păduri aleatoare, păduri de regresie cuantilică și gradient boosting cu restricții
- Deduceți stingerea gradientilor în rețelele recurente și rolul porților; citiți arhitecturile TCN, Transformers, N-BEATS, N-HiTS, DeepAR și TFT
- Realizați o comparație preînregistrată cu repere puternice, raportînd DM, MCS și seed-urile, și interpretați corect valorile Shapley și atenția

Bibliografie, date și instrumente

- ▣ Validare și teoria învățării: Bergmeir, Hyndman și Koo (2018); Racine (2000); Mohri și Rostamizadeh (2010); Hewamalage, Ackermann și Bergmeir (2023)
 - ▶ Dimensiune mare și arbori: Tibshirani (1996); Zou (2006); Basu și Michailidis (2015); Meinshausen (2006); Friedman (2001); Ke et al. (2017)
 - ▶ Deep learning: Hochreiter și Schmidhuber (1997); Vaswani et al. (2017); Zeng et al. (2023); Oreshkin et al. (2020); Salinas et al. (2020); Lim et al. (2021); sinteza Benidis et al. (2022)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_12](#)
 - ▶ `numpy`, `scikit-learn` și `PyTorch` pe procesor: rețele mici, seed-uri fixate, rulări de câteva minute
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa, eşantionul	Utilizarea
Consumul de electricitate al României, orar	Energy-Charts (date de transparență ENTSO-E), 1 369 de zile pînă la 30 septembrie 2026	arbori, Transformers, DLinear
Inflația IAPC, 27 de țări UE	Eurostat prc_hicp_minr, rate anuale, lunar, ianuarie 2000 – august 2026	modele globale, lasso
S&P 500 și alți cinci indici, varianța realizată	Heber et al. (2009) : RV din randamente de 5 minute, 5 552 de zile pînă la 25 februarie 2022	modele deep față de HAR
Subsetul orar M4	Makridakis, Spiliotis și Assimakopoulos (2020) : 414 de serii de 700–960 de ore, orizont 48	N-BEATS, N-HiTS, DeepAR

- Fiecare comparație are o perioadă de prognoză fixată înainte de rularea modelelor; pierderile, testele și seed-urile sînt raportate împreună cu ea

Patru generații de modele de prognoză




Geoffrey Hinton, Premiul Nobel pentru fizică 2024

Foto: Arthur Petron (2024); CC BY-SA 4.0;

[Wikimedia Commons](#)

- ▣ **Statistică:** ARIMA, ETS, HAR, spațiul stărilor: puțini parametri, un model pe serie
- ▣ **Machine learning:** regresii penalizate, păduri, boosting pe variabile cu decalaje, adesea globale
- ▣ **Modele deep de secvențe:** RNN, LSTM, TCN, Transformers, N-BEATS, DeepAR; retropropagarea [Rumelhart, Hinton și Williams \(1986\)](#)
- ▣ **Foundation models:** preantrenate pe multe serii, folosite zero-shot ([Capitolul 13](#))
- ▣ Fiecare generație trebuie să o bată pe cea dinainte în afara eșantionului, cu teste, pe aceleași date

Patru seturi de date, patru tipuri de structură



- Consumul României (media zilnică, în medie 6,06 GW); inflația UE (România cu roșu); varianța realizată S&P 500 (scară logaritmică); trei serii orare M4 (ultimele două săptămîni)

Interpretarea celor patru seturi de date

- Consumul: sezonalitate zilnică și săptămînală puternică, sărbători, ciclu anual lent: o structură de calendar pe care arborii și modelele liniare o captează bine
- Inflația: 27 de serii scurte, care se mișcă împreună, cu un șoc comun în 2021–2023: terenul natural pentru modelele globale și pentru panelul în dimensiune mare
- Variația realizată: memorie lungă și cozi groase; reperul HAR din [Capitolul 8](#) este greu de bătut
- M4 orar: multe serii înrudite de aceeași frecvență, cadrul în care modelele deep globale au câștigat prima dată

Cunoscut din TSA și elemente noi

- Cunoscut (TSA, Capitolul 9): variabile cu decalaje, validare walk-forward, scurgere de informație prin exemple, ridge și lasso, arbori, păduri aleatoare, gradient boosting, un MLP mic, elemente de predicție conformală, M4 și M5
- Nou: statistica din spatele rețetelor
 - ▶ generalizarea sub mixing; când este validă validarea încrucișată; modele globale
 - ▶ consistența selecției și inferența după selecție; păduri cuantilice; boosting cu restricții
 - ▶ gradienti în timp; atenție; dezvoltări în baze de funcții; modele deep cu verosimilitate; interpretare
- Replicări: Bergmeir, Hyndman și Koo (2018, secțiunea 4); Montero-Manso și Hyndman (2021) pe inflația UE; protocolul Zeng et al. (2023) pe consumul României; evaluarea M4 pe seriile orare

Riscul, riscul empiric și decalajul de generalizare

- ▣ Regula de prognoză $f \in \mathcal{F}$, pierderea ℓ ; **riscul** $R(f) = \mathbb{E} \ell(Y_{t+h}, f(X_t))$ sub legea staționară; **riscul empiric** $\hat{R}_n(f) = \frac{1}{n} \sum_t \ell(y_{t+h}, f(x_t))$
 - ▶ ERM: $\hat{f} = \arg \min_{\mathcal{F}} \hat{R}_n$; decalajul $R(\hat{f}) - \hat{R}_n(\hat{f}) \leq \sup_{\mathcal{F}} |R - \hat{R}_n|$
- ▣ Date i.i.d.: $\sup_{\mathcal{F}} |R - \hat{R}_n| = O_p(\sqrt{\text{complexitate}(\mathcal{F})/n})$ (dimensiunea VC, complexitatea Rademacher)
- ▣ Date dependente: cele n observații conțin mai puțină informație; marginea este valabilă cu o **dimensiune efectivă a eșantionului** mai mică decât n
 - ▶ și numai dacă seria își uită trecutul suficient de repede: mixing
- ▣ Nestaționaritatea (rupturi, [Capitolul 2](#)) adaugă un al doilea decalaj: legea viitoare diferă de cea de antrenare; nicio margine nu îl acoperă

Coeficienții de mixing

- β -mixing: $\beta(a) = \sup_t \mathbb{E} \sup_{B \in \sigma(X_{t+a}, \dots)} |P(B | \sigma(\dots, X_t)) - P(B)|$; α -mixing folosește $|P(A \cap B) - P(A)P(B)|$
 - mixing: $\beta(a) \rightarrow 0$ când distanța $a \rightarrow \infty$: viitorul îndepărtat este aproape independent de trecut
- ARMA staționar cu inovații continue, GARCH și modelele cu schimbare de regim cu lanț ergodic sînt β -mixing **geometric**: $\beta(a) \leq Cr^a$
 - memoria lungă ([Capitolul 10](#)) nu este mixing geometric: dimensiunea efectivă a eșantionului scade mult mai mult
- Mixing-ul este presupus, rar testat: este o afirmație despre procesul generator, nu despre eșantion

Blocuri și o margine de generalizare

- **Yu (1994)**: împărțim eșantionul în 2μ blocuri alternante de lungime a ; sub β -mixing, blocurile impare se comportă ca μ blocuri **independente**, pînă la o eroare $\mu\beta(a)$
 - ▶ instrumentele i.i.d. se aplică apoi cu $\mu = n/(2a)$ observații în loc de n
- **Mohri și Rostamizadeh (2010)**: pentru un algoritm uniform stabil (stabilitatea κ_n), cu probabilitatea $\geq 1 - \delta$:
 $R(\hat{f}) \leq \hat{R}_n(\hat{f}) + O(\kappa_n a) + O(\sqrt{\log(1/\delta')/\mu})$, $\delta' = \delta - 2(\mu - 1)\beta(a)$
 - ▶ compromisul în a : blocurile lungi fac $\beta(a)$ mic, dar lasă puține blocuri μ
 - ▶ ridge, ridge cu nucleu și modelele regularizate sînt uniform stabile; rețelele deep antrenate prin SGD doar aproximativ
- Aceeași idee a blocurilor dă bootstrap-ul pe blocuri (**Capitolul 0**) și validarea încrucișată pe blocuri

Validarea încrucișată pentru serii de timp: schemele

- ▣ **K subeșantioane aleatoare**: rîndurile matricei de decalaje $(y_t; y_{t-1}, \dots, y_{t-p})$ repartizate aleator
- ▣ **Validarea nedependentă** Bergmeir, Hyndman și Koo (2018): aceleași subeșantioane, dar rîndurile de antrenare aflate la mai puțin de p decalaje de un rînd de test sînt eliminate
- ▣ **K blocuri contigue** și **hv-block** Burman, Chow și Nolan (1994), Racine (2000): blocuri de test contigue, cu un interval de h rînduri (purjare) de fiecare parte
- ▣ **În afara eșantionului (OOS)** și **originea mobilă**: test doar la sfîrșit; singura schemă care imită utilizarea reală, cu prețul unei varianțe mari
- ▣ Întrebarea nu este care schemă este „corectă”, ci care estimează riscul viitor cu deplasare mică și varianță mică


Validitatea validării cu K subeșantioane: Bergmeir, Hyndman și Koo (2018)

- Modelul $y_t = g(y_{t-1}, \dots, y_{t-p}; \theta) + \varepsilon_t$ cu erori ε_t **necorelate** Bergmeir, Hyndman și Koo (2018)
 - ▶ rîndurile matricei de decalaje sînt atunci suficient de schimbabile: un rînd de test nu are nicio eroare comună cu un rînd de antrenare
 - ▶ rezultat: estimația MSE prin K subeșantioane este asimptotic nedeplasată și are o varianță mai mică decît OOS, pentru că fiecare rînd este folosit
- Eșuează cînd reziduurile sînt autocorelate: un model subspecificat, ținte suprapuse la h pași sau variabile care identifică momentul
 - ▶ atunci o eroare de test este previzibilă din erorile de antrenare vecine: estimații optimiste
- Regula practică: verificați ACF a reziduurilor modelului estimat (Ljung–Box, TSA, Capitolul 2) înainte de a avea încredere în K subeșantioane aleatoare

Designul replicării: Bergmeir, Hyndman și Koo (2018, secțiunea 4)

- ▣ Serii de lungime 200: 140 de observații de estimare, 60 de evaluare; modele AR(1)–AR(5) prin OLS; prognoze la un pas
- ▣ Procedurile pe datele de estimare: 5 subeșantioane, LOOCV, validare nedependentă ($p = 5$), OOS (ultimele 20%); eroarea „adevărată”: modelul pe toate datele de estimare, RMSE pe datele de evaluare
- ▣ 1 000 de repetări pentru fiecare proces: AR(3) staționar cu coeficienți aleatori, MA(1) inversabil și un AR sezonier estimat pe decesele accidentale din SUA 1973–1978 ($\phi = 0,76$, $\Phi_{12} = 0,85$) drept contraexemplu
- ▣ Precizia MAPAE = $\text{media}|\widehat{PE} - PE|$, deplasarea MPAAE = $\text{media}(\widehat{PE} - PE)$

Precizia și deplasarea schemelor de validare



□ Sus: precizia (scară logaritmică); jos: deplasarea, după ordinul AR estimat și procesul generator


Interpretarea replicării

- ▣ Date AR(3), model AR(3): 5 subeșantioane dau MAPAE 0,094 față de 0,137 pentru OOS, deplasare 0,001: ca în lucrare, validarea încrucișată este nedeplasată și mai precisă
- ▣ AR(1) subspecificat pe date AR(3): reziduurile sînt autocorelate, iar validarea încrucișată își pierde avantajul (MAPAE 0,284 față de 0,349)
- ▣ Contraexemplul sezonier: orice $AR(p \leq 5)$ ratează decalajul 12; validarea încrucișată este deplasată în jos (MPAE $-0,077$ pentru AR(5)) și nu mai este mai precisă decît OOS (0,130 față de 0,136)
- ▣ Validarea nedependentă elimină atît de multe rînduri încît modelele ei sînt slabe: deplasare 0,232 pentru AR(3); prețul independenței se plătește în date

Scurgerea de informație prin ținte suprapuse și variabile de timp

- Ținta $z_t = \frac{1}{h} \sum_{j=1}^h y_{t+j}$ (o lună de volatilitate, un trimestru de vânzări): $\text{corr}(z_t, z_{t+1}) \geq (h-1)/h$ când y este zgomot alb, mai mult când y este persistent
 - un subeșantion aleator pune z_{t-1} și z_{t+1} în antrenare când z_t este testat: răspunsul este aproape în setul de antrenare
- Un indice de timp sau o variabilă de dată permite unui algoritm flexibil să **localizeze** rîndul de test între vecinii lui
- Simulare: AR(1) cu $\phi = 0,9$, $h = 20$, o pădure aleatoare pe $y_t, \dots, y_{t-4}$ și un indice de timp; 60 de repetări; raportul dintre RMSE estimat și RMSE adevărat pe date noi

Optimismul fiecărei scheme de validare



□ Raportul 1: schema estimează fără deplasare eroarea pe date noi; sub 1: optimistă

Interpretarea experimentului de scurgere

- ▣ 5 subeșantioane aleatoare: raportul median 0,34 (quartile 0,28–0,39): pretinde o eroare de trei ori mai mică decât cea reală
- ▣ 5 blocuri contigue 0,92, 5 blocuri cu purjare 0,98, ultimele 20% 0,98: contiguitatea și purjarea elimină cea mai mare parte a deplasării
- ▣ Blocurile interioare lasă încă pădurea să interpoleze în timp; doar ultimul bloc reproduce extrapolarea în viitor
- ▣ Regula: purjați cel puțin h rînduri în jurul fiecărui bloc de test și eliminați indicii de timp, cu excepția cazului în care trendul este modelat explicit

Recapitulare: învățarea din date dependente

- Marginile de generalizare sînt valabile cu o dimensiune efectivă a eșantionului dată de mixing; blocurile sînt instrumentul comun
- Validarea cu K subeșantioane aleatoare este validă pentru autoregresii cu erori necorelate și atunci este mai bună decît OOS
- Țintele suprapuse, subspecificarea și variabilele de timp o strică: blocuri, purjare și o perioadă finală neatinsă


Modele locale și modele globale

- **Local**: un model pentru fiecare serie, $\hat{y}_{i,t+h} = f_i(y_{i,t}, y_{i,t-1}, \dots)$; **global**: o singură funcție pentru toate seriile, $\hat{y}_{i,t+h} = f(y_{i,t}, y_{i,t-1}, \dots)$
 - modelele globale reunes $N \times T$ rânduri: mult mai multe date pe parametru
- **Montero-Manso și Hyndman (2021)**: pentru orice mulțime de serii există un model global care prognozează la fel de bine ca modelele locale; modelele globale își permit **memorie mai lungă** și complexitate mai mare
 - marginea lor: complexitatea unui model global crește cu NT , cea a N modele locale cu câte T
- Câștigătorii M4 și M5 au fost globali (**Smyl (2020)**; LightGBM în **Makridakis, Spiliotis și Assimakopoulos (2022)**): reunirea datelor, nu adâncimea, a fost ingredientul comun
- Scalarea contează: seriile de niveluri diferite se împart la propria scală înainte de reunire (ratele inflației au aceeași scală)

Design: inflația UE, local față de global

- ▣ Inflația anuală IAPC a celor 27 de țări UE; prognoze directe la $h = 1$ și $h = 12$ luni din modele $AR(p)$, $p \in \{1, 2, 3, 6, 12, 18, 24, 36\}$
- ▣ Fereastră mobilă de 120 de luni; origini ale prognozei din ianuarie 2015 (139 origini pentru $h = 1$)
- ▣ Local: 27 de regresii OLS pentru fiecare origine; global: o singură regresie OLS reunită (aceiași coeficienți pentru toate țările), ca în [Montero-Manso și Hyndman \(2021\)](#)
- ▣ Pierderea: RMSE în puncte procentuale; testul DM pe diferența medie a pierderilor dintre țări (corecția HLN, [Capitolul 1](#))

Memoria ajută modelele globale și le afectează pe cele locale



□ RMSE în funcție de memoria p ; cercuri: media celor 27 de țări; pătrate: România

ATS_ch12_global_models

Interpretarea modelelor locale și globale

- ▣ $h = 1$: RMSE local este minim la $p = 3$ (0,67), apoi se deteriorează; cel global scade pînă la $p = 36$ (0,58); DM pe media celor 27 de țări $-4,40$ ($p < 0,001$)
- ▣ $h = 12$: valul din 2021–2023 domină; AR(36) local ajunge la 11,39 față de 5,99 global; cel mai bun global 4,51 față de cel mai bun local 5,60, DM $-1,09$ (p 0,277)
- ▣ România separat: modelul global ajută la $h = 1$ cu memorie lungă (0,55 față de 0,61 la $p = 36$), nesemnificativ (DM p 0,19)
- ▣ Lecția lui Montero-Manso și Hyndman se confirmă: reunirea datelor cumpără memorie; pentru o singură serie, câștigul este real, dar greu de demonstrat

Lasso: condițiile de optimalitate

- **Tibshirani (1996)**: $\hat{\beta} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|^2 + \lambda \|\beta\|_1$; KKT: $\frac{1}{n} x_j'(y - X\hat{\beta}) = \lambda \text{sign}(\hat{\beta}_j)$ dacă $\hat{\beta}_j \neq 0$ și $\leq \lambda$ în valoare absolută altfel
 - ▶ design ortonormal ($X'X = nI$): $\hat{\beta}_j = \text{sign}(z_j)(|z_j| - \lambda)_+$, pragul moale aplicat coeficientului OLS z_j
 - ▶ ridge: $\hat{\beta}_j = z_j/(1 + \lambda)$: micșorează, nu selectează niciodată
- **Predicția**: cu s coeficienți nenuli și o valoare proprie restrânsă κ , $\frac{1}{n} \|X(\hat{\beta} - \beta)\|^2 = O_p(s \log p / (n\kappa^2))$ pentru $\lambda \asymp \sigma \sqrt{\log p / n}$
 - ▶ serii de timp: aceeași rată pentru VAR stabile, cu κ dependent de marginile densității spectrale **Basu și Michailidis (2015)**; erori cu cozi groase și heteroscedastice **Medeiros și Mendes (2016)**
- **Selecția este mai grea decât predicția**: consistența semnelor cere **condiția de nereprezentare** $\|X_{S^c}' X_S (X_S' X_S)^{-1} \text{sign}(\beta_S)\|_{\infty} < 1$ **Zhao și Yu (2006)**: eșuează când predictorii relevanți și irelevanți sînt corelați (țări vecine, decalaje)

Lasso adaptiv și elastic net

- ▣ **Lasso adaptiv Zou (2006)**: penalizarea $\lambda \sum_j w_j |\beta_j|$, $w_j = 1/|\tilde{\beta}_j|^\gamma$ dintr-o estimatie de prima etapă (OLS, ridge)
 - ▶ coeficienții mari sînt penalizați puțin, cei mici mult: **proprietatea de oracol** (selecție consistentă și estimatii $\sqrt{n}$ -normale ale coeficienților nenuli) fără condiția de nereprezentare
- ▣ **Elastic net Zou și Hastie (2005)**: $\lambda(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2)$; design ortonormal:
 $\hat{\beta}_j = \text{sign}(z_j)(|z_j| - \lambda\alpha)_+ / (1 + \lambda(1 - \alpha))$
 - ▶ efectul de grup: predictorii corelați intră împreună, în loc să fie ales unul la întâmplare
- ▣ Penalizarea se alege prin validare încrucișată: cu ținte la h pași folosiți blocuri cu purjare de h perioade (secțiunea 1)


Inferența după selecție

- Practica naivă: selecție cu lasso, apoi raportarea statisticilor t OLS ale variabilelor selectate: valorile p sînt **prea mici**
 - ▶ aceleași date au ales modelul și îl testează: distribuția lui $\hat{\beta}$ este condiționată de faptul că a fost selectat
- Remedii: intervale **PoSI**, valabile pentru orice selecție [Berk et al. \(2013\)](#); intervale **condiționate exacte** pentru lasso (un eveniment de selecție poliedral) [Lee et al. \(2016\)](#)
- Pentru un coeficient de interes (o dobîndă de politică, un șoc extern): **dubla selecție** [Belloni, Chernozhukov și Hansen \(2014\)](#): lasso al lui y pe variabilele de control, lasso al regresorului de interes pe aceleași variabile, OLS pe reuniune
 - ▶ cu erori standard HAC pentru serii de timp ([Capitolul 0](#))
- Pentru prognoză, selecția este un mijloc: se judecă după pierderea în afara eșantionului și după stabilitatea a ceea ce este selectat

Design: inflația României din panelul UE

- ▣ Ținta: inflația anuală IAPC a României peste 12 luni; fereastră de 120 de luni, reestimare la fiecare 3 luni; 128 de prognoze (ianuarie 2016 – august 2026)
- ▣ Variabile: 3 decalaje proprii (nepenalizate) și 3 decalaje ale celorlalte 26 de țări: 78 predictorii penalizați pentru circa 105 observații
- ▣ Modele: AR(3) (reper), ridge, lasso, lasso adaptiv, elastic net ($\alpha = 0,5$), OLS după lasso, AR(12) global al panelului; penalizarea prin 5 blocuri cu purjare de 12 luni
- ▣ Literatura despre prognoza inflației cu multe date [Medeiros et al. \(2021\)](#), [Goulet Coulombe et al. \(2022\)](#), aplicată aici pe panelul UE

Selecția lasso pe panel și acuratețea ei



- Stînga: ponderea originilor din fiecare an în care o țară intră în lasso; dreapta: RMSE relativ la AR(3), culoarea după testul DM

Interpretarea lasso pe panel

- ▣ Selecția este instabilă: mediana de 34 din 78 predictorii (între 15 și 61); cele mai frecvente sînt EL, NL, MT, nu vecinii României
- ▣ Acuratețea: RMSE AR(3) 4,13; lasso de 1,44 ori, lasso adaptiv de 1,67 ori, elastic net de 1,49 ori, ridge de 1,49 ori mai mare; AR(12) global 1,06
- ▣ Niciuna dintre diferențe nu este semnificativă (DM p între 0,20 și 0,39): circa 10 perioade independente de 12 luni, una dominată de valul din 2022
- ▣ Dimensiune mare cu 105 observații ale unei ținte persistente: validarea alege penalizări mici, panelul potrivește co-mișcări trecute care nu se repetă; aici câștigă parcimonia

Recapitulare: modele globale și dimensiune mare

- ▣ Modelele globale reunesc multe serii și își permit memorie lungă; pe inflația UE câștigă la o lună
- ▣ Lasso prognozează bine sub raritate și valori proprii restrânse; selectează bine doar sub condiția de nereprezentare; lasso adaptiv și elastic net o relaxează
- ▣ Raportați stabilitatea selecției și folosiți inferența PoSI, exactă sau prin dubla selecție, niciodată statisticile t naive

Bagging: varianța unei medii

- B predictorii $\hat{f}_b(x)$, identic distribuiți, cu varianța σ^2 și corelația între perechi ρ (după date și randomizare) [Breiman \(1996\)](#)
 - ▶ $\text{Var}\left(\frac{1}{B} \sum_b \hat{f}_b\right) = \frac{1}{B^2} (B\sigma^2 + B(B-1)\rho\sigma^2) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$
 - ▶ mai mulți arbori elimină doar al doilea termen; pragul $\rho\sigma^2$ scade doar prin **decorelarea** arborilor
- **Pădurile aleatoare** [Breiman \(2001\)](#): un subset aleator de m_{try} variabile la fiecare ramificare scade ρ , cu prețul unei deplasări mici
- Teorie: consistența pădurilor lui Breiman pentru regresia aditivă [Scornet, Biau și Vert \(2015\)](#); arborii onești (eșantioane separate pentru ramificări și valorile din frunze) dau prognoze asimptotic normale, cu estimatii ale varianței [Wager și Athey \(2018\)](#)
- Arborii nu pot extrapola: o prognoză este o medie a țințelor trecute, deci trendurile și salturile de nivel cer diferențiere sau o parte liniară

Păduri de regresie cuantilică

- ▣ **Meinshausen (2006)**: păstrăm **toate** țintele de antrenare în frunze; ponderile $w_i(x) = \frac{1}{B} \sum_b \frac{1_{\{x_i \in L_b(x)\}}}{|L_b(x)|}$,
 $\sum_i w_i(x) = 1$
 - ▶ funcția de repartiție condiționată $\hat{F}(y | x) = \sum_i w_i(x) 1_{\{y_i \leq y\}}$; cuantila $\hat{q}_\tau(x) = \inf\{y : \hat{F}(y | x) \geq \tau\}$
- ▣ Aceeași pădure dă toate cuantilele: fără încrucișări, fără reestimare pentru fiecare nivel
 - ▶ consistentă pentru distribuția condiționată, în condiții de regularitate; o pădure aleatoare este o metodă adaptivă de tip vecini apropiați
- ▣ Evaluarea prin pierderea pinball și acoperire (**Capitolul 1**): benzile sînt oneste doar dacă pădurea a fost antrenată pe date asemănătoare viitorului

Gradient boosting ca coborîre pe gradient în spațiul funcțiilor

- ▣ **Friedman (2001)**: $F_m = F_{m-1} + \nu h_m$, h_m un arbore mic ajustat pe gradientul negativ $g_i = -\partial \ell(y_i, F) / \partial F|_{F_{m-1}(x_i)}$
 - pierderea pătratică: $g_i = \text{reziduul}$; pierderea pinball: $g_i = \tau - 1\{y_i < F\}$ (boosting cuantilic); micșorarea ν schimbă pași pe varianță
- ▣ Ordinul doi **Chen și Guestrin (2016)**: cu gradientii G și hessianele H însumate într-o frunză, valoarea optimă este $w^* = -G / (H + \lambda)$, iar o ramificare câștigă $\frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{G^2}{H + \lambda} \right] - \gamma$
- ▣ **LightGBM Ke et al. (2017)**: variabile grupate în histograme (cel mult 255 de intervale), creștere pe frunze, eșantionare unilaterală după gradient; HistGradientBoosting din scikit-learn, folosit aici, urmează același design
- ▣ Restricțiile de monotonie: o ramificare este permisă doar dacă valorile frunzelor stîngă și dreaptă respectă ordinea, iar descendenții moștenesc limitele; funcția estimată este atunci monotonă în acea variabilă peste tot

Design: consumul României pentru ziua următoare





Linie de 750 kV la Mărășești, România

Foto: TrainSimFan (2022); CC BY-SA 4.0;

Wikimedia Commons

- Prognoză cele 24 de valori orare ale zilei $d + 1$ cu date pînă în ziua d ; evaluare pe 638 de zile, ianuarie 2025 – septembrie 2026
- Reper: ARX-ul expert din [Capitolul 1](#) ([Ziel și Weron \(2018\)](#)): o regresie pe oră, fereastră de 364 de zile, reestimat zilnic
- Algoritmi globali (un model pentru toate orele) pe aceleași decalaje, ora, ziua săptămînii, sărbătorile din România, ciclul anual; reestimați lunar pe toate datele anterioare: RF cu benzi QRF, HGB, HGB crescător în cele trei decalaje ale consumului, HGB cuantilic
- Pierderi: MAE, pinball mediu pe decile, acoperirea de 80%; DM față de ARX și MCS ([Capitolul 1](#))

Arbori față de ARX-ul expert




- Stînga: o săptămînă din ianuarie cu benzile QRF 10%–90%; dreapta: MAE în MW, MCS marchează modelele din mulțimea de încredere de 90%

Interpretarea comparației pentru consum

- MAE (MW): ARX 221, RF 232, HGB 225, HGB monoton 228; pădurea este semnificativ mai slabă (DM 2,84), boosting nu diferă semnificativ de ARX
- Media egală dintre ARX și boosting: 211 MW, DM $-3,36$ ($p < 0,001$), singurul model din MCS: combinarea bate selecția ([Capitolul 1](#))
- Cuantile: pinball (MW) ARX 89,1, HGB cuantilic 89,5, QRF 92,8; acoperirea de 80%: 78%, 61%, 83%: boosting-ul cuantilic este îngust, dar acoperă prea puțin, QRF acoperă prea mult
- Un model liniar reestimat zilnic, cu structura corectă, este un reper puternic; arborii aduc valoare ca o completare, nu ca un înlocuitor

Restricțiile de monotonie în practică



- Dependența parțială a prognozei boosting de consumul din ziua d la aceeași oră, antrenat pe 2023–2024


Interpretarea restricției

- Fără restricție: 3 pași descrescători (cel mai mare de 7,5 MW): mai mult consum ieri ar însemna uneori mai puțin consum mâine, o potrivire a zgomotului
- Cu restricție: monoton prin construcție; amplitudinea totală 1,52 GW față de 1,84 GW: o parte a efectului trece la celelalte decalaje
- Acuratețea abia se schimbă (228 față de 225 MW); câștigul este plauzibilitatea și robustețea la marginile datelor
- Restricțiile sînt calea prin care cunoașterea economică intră într-o cutie neagră: restricții de semn, ca în [Capitolul 3](#), dar pentru algoritmi neliniari

Recapitulare: ansamblurile de arbori

- ▣ Bagging-ul și pădurile reduc varianța pînă la pragul $\rho\sigma^2$; decorelarea, nu numărul de arbori, îl coboară
- ▣ QRF dă întreaga distribuție condiționată dintr-o singură pădure; boosting-ul ajustează gradienti, cu frunze de ordinul doi și histograme în LightGBM
- ▣ Pe consumul României, arborii egalează, dar nu bat ARX-ul expert; combinația lor cîștigă

De la MLP la modelele de secvențe



NVIDIA G80, primul procesor grafic CUDA (2006)

Foto: Hyins (2011); domeniu public; Wikimedia Commons

- Un MLP pe o fereastră de L decalaje este un $AR(L)$ neliniar:
 $\hat{y}_{t+h} = W_2 \sigma(W_1 x_t + b_1) + b_2$, $\sigma = \text{ReLU}$ sau $\tanh$
- Antrenarea: retropropagare [Rumelhart, Hinton și Williams \(1986\)](#) cu Adam [Kingma și Ba \(2015\)](#); oprire timpurie pe ultimul bloc al eșantionului de antrenare; intrări standardizate doar cu momentele de antrenare
- Aproximarea universală nu spune nimic despre necesarul de date: cu câteva mii de observații zilnice, o rețea are puțin spațiu față de un model liniar
- Modelele de secvențe partajează ponderile în timp: recurență (RNN), convoluție (TCN) sau atenție (Transformer)

Rețele recurente și retropropagarea în timp

- ▣ RNN Elman: $h_t = \tanh(W h_{t-1} + U x_t + b)$, $\hat{y}_t = V h_t$; starea h_t rezumă trecutul, ca starea Kalman ([Capitolul 6](#)), dar învățată
- ▣ BPTT: $\frac{\partial \mathcal{L}_T}{\partial W} = \sum_{t \leq T} \frac{\partial \mathcal{L}_T}{\partial h_T} \left(\prod_{k=t+1}^T \frac{\partial h_k}{\partial h_{k-1}} \right) \frac{\partial^+ h_t}{\partial W}$, $\frac{\partial h_k}{\partial h_{k-1}} = \text{diag}(1 - h_k^2) W$
 - ▶ contribuția decalajului $T - t$ este un produs de $T - t$ jacobiene
- ▣ [Bengio, Simard și Frasconi \(1994\)](#), [Pascanu, Mikolov și Bengio \(2013\)](#): $\| \prod_k \partial h_k / \partial h_{k-1} \| \leq (\gamma \|W\|)^{T-t}$ cu $\gamma = \max |\tanh'| \leq 1$
 - ▶ $\gamma \|W\| < 1$: gradienti care **se sting**, decalajele lungi nu pot fi învățate; rază spectrală > 1 : posibilă **explozie**, tratată prin limitarea normei gradientului

LSTM și GRU: porțile




Sepp Hochreiter, coautor al LSTM

Foto: Eulenreich (2015); CC BY-SA 4.0;

Wikimedia Commons

- LSTM Hochreiter și Schmidhuber (1997): porțile $i_t, f_t, o_t = \sigma(W_\bullet[h_{t-1}, x_t] + b_\bullet)$, candidatul $\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$
- celula $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$, ieșirea $h_t = o_t \odot \tanh(c_t)$; de-a lungul celulei, $\partial c_t / \partial c_{t-1} = \text{diag}(f_t)$: aditiv, fără compresie
- Poarta de uitare Gers, Schmidhuber și Cummins (2000) trebuie să rămână deschisă: $f \approx 1$; un bias de 1 al porții de uitare este inițializarea obișnuită Jozefowicz, Zaremba și Sutskever (2015)
- GRU Cho et al. (2014): porțile de actualizare z_t și de resetare r_t , $h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$: mai puțini parametri, comportament asemănător

Distanța în timp pînă la care ajunge gradientul



- Media $|\partial h_T / \partial x_t|$ pentru rețele proaspăt inițializate (32 de unități, $T = 100$, intrări gaussiene, media a 5 seed-uri), scară logaritmică

Interpretarea gradientelor

- ▣ La decalajul 50, gradientul este o fracțiune 10^{-10} din valoarea de la decalajul 1 pentru RNN tanh, 10^{-9} pentru GRU și 10^{-9} pentru LSTM cu bias-ul implicit 0 al porții de uitare
- ▣ Bias 1 al porții de uitare: 10^{-4} ; bias 3: 0,47: porțile ajută doar când poarta de uitare este deschisă ($\sigma(3) = 0,95$)
- ▣ Ratele de stingere pe decalaj: 0,51 (RNN), 0,45 (LSTM, bias 0), 0,03 (LSTM, bias 3): geometrice în toate cazurile
- ▣ Pentru seriile zilnice contează mai puțin decît pare: memoria de tip HAR (22 de decalaje) este accesibilă; pentru datele orare cu ciclu săptămînal (168 de decalaje), ea decide arhitectura

Rețele convoluționale temporale

- Convoluția causală: $z_t = \sum_{j=0}^{k-1} w_j x_{t-dj}$ folosește doar trecutul; dilatarea d sare $d - 1$ pași [van den Oord et al. \(2016\)](#)
 - ▶ TCN [Bai, Kolter și Koltun \(2018\)](#): blocuri reziduale cu cîte două convoluții cauzale dilatate, $d = 1, 2, 4, \dots, 2^{\ell-1}$
- Cîmpul receptiv: $R = 1 + 2(k - 1)(2^\ell - 1)$; $k = 3$, $\ell = 4$: $R = 61$; o săptămîină de ore cere $\ell = 7$ ($R = 509$)
 - ▶ memoria este fixată de arhitectură, nu învățată: fără stingere în timp, dar nimic dincolo de R
- Paralelă în timp (antrenare rapidă), gradienti stabili; Bai et al. au găsit TCN competitive cu LSTM pe sarcini standard de secvențe


Prognoze pe mai mulți pași și sequence-to-sequence

- ▣ **Recursive**: un model la un pas iterat, prognozele reintroduse ca intrări: erorile se acumulează, modelul este antrenat doar pentru $h = 1$
- ▣ **Direct**: un model pentru fiecare orizont h (prognozele HAR și ale rețelelor de aici); **MIMO**: o rețea dă întregul vector $(\hat{y}_{t+1}, \dots, \hat{y}_{t+H})$ (DLinear, N-BEATS, Transformers aici)
- ▣ **Encoder-decoder** [Sutskever, Vinyals și Le \(2014\)](#): o rețea recurentă codifică trecutul într-o stare, alta desfășoară viitorul; antrenare cu teacher forcing
 - deplasarea de expunere: la test, decodorul își vede propriile erori; DeepAR simulează în schimb traiectorii
- ▣ Sinteza practicii recurente [Hewamalage, Bergmeir și Bandara \(2021\)](#): desezonalizare sau decalaje sezoniere, scalare pe serie, antrenare globală, ansamblu de seed-uri

Design: modele deep față de HAR

- ▣ Ținta $y = \log RV$ pentru S&P 500 (Heber et al. (2009)); prognoze ale RV_{t+h} , $h \in \{1, 5, 22\}$, directe; prognoza nivelului $\exp(\hat{m} + s^2/2)$ cu varianța reziduală de antrenare
- ▣ Fereastră extinsă, prima prognoză după 2500 de zile (24 decembrie 2009), reestimare la fiecare 500 de zile; 3 051 de prognoze pe orizont
- ▣ Modele pe ultimele 22 de valori: HAR Corsi (2009) (OLS), MLP (2×32 de unități), LSTM (16 unități), TCN (3 niveluri, $R = 29$), HGB pe cele 22 de decalaje; un seed pe rețea
- ▣ QLIKE Patton (2011), DM (HLN) față de HAR, MCS; literatura: rețelele neuronale câștigă puțin față de HAR Bucci (2020); câștigurile ML apar mai ales cu mulți predictorii Christensen, Siggaard și Veliyev (2023)

Rețele deep față de HAR



□ QLIKE relativ la HAR (1 = HAR); steaua marchează o respingere DM la 5%

Interpretarea modelelor deep față de HAR

- ▣ $h = 1$: MLP 1,019, LSTM 1,040 (DM 2,77), TCN 1,002, HGB 1,074 (DM 3,84): nimic nu bate HAR, două modele sînt semnificativ mai slabe
- ▣ $h = 22$: MLP 0,951, LSTM 0,946, TCN 0,968: câștiguri de 3–5% pe care DM nu le confirmă (p 0,132; 0,444); HAR rămîne în MCS (p 0,49)
- ▣ Boosting-ul pe decalajele brute este cel mai slab la toate orizonturile: arborii nu pot extrapola la vîrfurile de volatilitate din 2020
- ▣ HAR este un model liniar cu cele trei variabile potrivite; o rețea trebuie să le redescopere din cîteva mii de zile

Recapitulare: deep learning pentru secvențe

- ▣ Gradienții în timp sînt produse de jacobiene: se sting geometric, cu excepția cazului în care poarta de uitare LSTM rămîne deschisă
- ▣ TCN fixează memoria prin cîmpul receptiv; prognozele pe mai mulți pași sînt recursive, directe sau MIMO
- ▣ Pe varianța realizată zilnică, rețelele nu bat semnificativ HAR la niciun orizont

Atenția cu produs scalar scalat

- ▣ Vaswani et al. (2017): tokeni $X \in \mathbb{R}^{n \times d}$; $Q = XW_Q$, $K = XW_K$, $V = XW_V$;
 $\text{Att}(Q, K, V) = \text{softmax}(QK'/\sqrt{d_k})V$
 - ▶ fiecare ieșire este o medie ponderată a valorilor, cu ponderi dependente de date; $\sqrt{d_k}$ menține logiții de ordinul unu
 - ▶ multi-head: mai multe proiecții în paralel, concatenate
- ▣ Echivariantă la permutări: fără **codificări poziționale**, ordinea tokenilor se pierde, ceea ce este fatal pentru serii de timp
- ▣ Cost $O(n^2d)$ în timp și memorie: un token pe oră și o săptămână de intrare dau $n = 168$; o lună dă $n = 720$
 - ▶ Transformers pentru orizonturi lungi din 2020–2022 au urmărit mai ales acest cost

Transformers pentru orizonturi lungi

- ▣ **Informer** Zhou et al. (2021): atenție ProbSparse (doar interogările cele mai informative), distilarea atenției, un decodor generativ care dă orizontul dintr-o dată: $O(n \log n)$
- ▣ **Autoformer** Wu et al. (2021): descompunerea seriei în fiecare strat (trend prin medie mobilă și rest) și un mecanism de autocorelație care agregă subserii la decalaje găsite prin FFT
- ▣ **PatchTST** Nie et al. (2023): tokenii sînt **segmente** de valori consecutive (de exemplu 16 sau 24), fiecare canal modelat separat, normalizare pe instanță
 - ▶ mai puțini tokeni (n/P), semnificație locală în fiecare token, ferestre de intrare mai lungi accesibile
- ▣ Toate au fost evaluate pe aceleași cîteva seturi de date (electricitate, trafic, vreme, ETT), cu MSE pe date standardizate



Critica lui Zeng et al. (2023): eficiența Transformers

- ▣ Zeng et al. (2023): auto-atenția este invariantă la permutări; tokenii punctuali nu au semnificație locală; codificările poziționale restabilesc ordinea doar parțial
- ▣ Reperele LTSF-Linear: **Linear** $\hat{y}_{t+1:t+H} = Wx_{t-L+1:t}$; **NLinear** scade și adaugă înapoi ultima valoare; **DLinear** separă x într-un trend prin medie mobilă și un rest, câte un strat liniar pentru fiecare
 - ▶ DLinear este el însuși o aplicație liniară: $\hat{y} = (W_s(I - A) + W_t A)x$, A matricea mediei mobile (Seminarul 12, A8)
- ▣ Rezultatul lor: aceste modele cu un singur strat bat Informer, Autoformer și succesorii lor pe majoritatea seturilor standard pentru orizonturi lungi
 - ▶ iar Transformers nu se îmbunătățeau cu o fereastră L mai lungă: un semn că nu foloseau istoria suplimentară
- ▣ PatchTST a fost răspunsul: segmentarea și independența canalelor au readus Transformers înaintea DLinear pe aceleași seturi de date

Designul replicării: protocolul Zeng et al. pe consumul României

- ▣ Consumul orar al României ca o singură serie ($n = 32\,856$ ore), standardizat cu momentele de antrenare; împărțire cronologică 7:1:2; testul de la 31 decembrie 2025
- ▣ Fereastra de intrare $L = 336$ de ore; orizonturi $H = 96$ și 336 ; MSE și MAE pe seria standardizată, ca în tabelele lor
- ▣ Modele: repetarea ultimei valori, naiv sezonier (ultima săptămână), Linear, NLinear, DLinear (nucleu 25), un Transformer pe segmente (14 segmente de 24 de ore, 1 strat, 4 capete) și același Transformer cu un token pe oră
- ▣ Adam, MSE, oprire timpurie pe blocul de validare; media a trei seed-uri (unul pentru Transformer-ul cu tokeni punctuali, al cărui cost este $O(n^2)$)

Modele liniare, Transformers și rolul tokenilor



- Stînga: MSE de test după orizont (repetarea ultimei valori, 1,585 și 1,699, iese din scară); dreapta: o fereastră de test la $H = 96$ (ultima săptămînă de intrare, consumul real și trei prognoze)

Interpretarea protocolului

- ▣ $H = 96$: naiv sezonier 0,393, Linear 0,265, NLinear 0,253, DLinear 0,257; Transformer cu tokeni punctuali 0,258; Transformer pe segmente 0,226
- ▣ $H = 336$: DLinear 0,374, tokeni punctuali 0,402 (mai slab decât orice model liniar), segmente 0,364
- ▣ Ambele lucrări se replică pe datele noastre: Transformer-ul cu tokeni punctuali nu este mai bun decât NLinear sau DLinear la $H = 96$ și este mai slab decât orice model liniar la $H = 336$; segmentarea răstoarnă clasamentul
- ▣ Distanța dintre cel mai bun model liniar și Transformer-ul pe segmente scade de la 0,253 față de 0,226 la $H = 96$ la 0,371 față de 0,364 la $H = 336$: la orizonturi lungi seria este mai ales nivel sezonier

Temporal Fusion Transformer

- ▣ [Lim et al. \(2021\)](#): construit pentru prognoze pe mai multe orizonturi, cu trei tipuri de intrări: statice (magazinul, țara), viitoare cunoscute (calendar, prețuri), trecute observate
- ▣ Componente
 - ▶ rețele reziduale cu poartă (GRN): $\text{LayerNorm}(a + \text{GLU}(\eta))$, o poartă care poate opri un bloc
 - ▶ rețele de selecție a variabilelor: ponderi softmax pe intrări la fiecare moment
 - ▶ codificatori ai covariatelor statice care condiționează celelalte blocuri; un encoder-decoder LSTM pentru tipare locale
 - ▶ atenție multi-head interpretabilă (valori comune tuturor capetelor) pentru dependența de lungă durată; ieșiri cuantile antrenate cu pierderea pinball
- ▣ „Interpretabilitatea” lui înseamnă ponderile de selecție a variabilelor și tiparul atenției: diagnostice utile, nu explicații cauzale (secțiunea 7)

Recapitulare: atenție și Transformers

- ▣ Atenția este o medie ponderată dependentă de date; ordinea vine doar din codificările poziționale; costul este pătratic în numărul de tokeni
- ▣ Zeng et al.: un strat liniar a bătut Transformers cu tokeni punctuali; PatchTST: segmentele refac avantajul; ambele se replică pe consumul României
- ▣ TFT organizează intrările statice, cunoscute și observate prin porți, selecție și atenție și dă cuantile

N-BEATS: dezvoltare în baze de funcții cu stivuire reziduală

- ▣ **Oreshkin et al. (2020)**: blocul ℓ transformă intrarea x_ℓ prin patru straturi complet conectate în coeficienții $\theta_\ell^b, \theta_\ell^f$; reconstrucția $\hat{x}_\ell = g^b(\theta_\ell^b)$, prognoza $\hat{y}_\ell = g^f(\theta_\ell^f)$
 - ▶ dublu rezidual: $x_{\ell+1} = x_\ell - \hat{x}_\ell$, $\hat{y} = \sum_\ell \hat{y}_\ell$: fiecare bloc explică ce au lăsat cele anterioare
- ▣ **Generic**: g liniar și învățat; **interpretabil**: baza de trend $\{(t/H)^j\}_{j \leq 3}$ și baza sezonieră $\{\cos 2\pi jt/H, \sin 2\pi jt/H\}$: o descompunere învățată, asemănătoare netezirii exponențiale
- ▣ Deep learning pur, fără variabile specifice seriilor de timp; antrenat global pe fiecare frecvență cu pierderi sMAPE/MASE; rezultatele publicate sînt ansambluri de 180 de rețele
 - ▶ rezultatul lor pe M4 l-a depășit pe câștigătorul competiției, hibridul ES-RNN al lui [Smyl \(2020\)](#)



N-HiTS: intrări pe mai multe rate, ieșiri ierarhice

- ▣ [Challu et al. \(2023\)](#): blocul ℓ aplică întâi max-pooling cu nucleul k_ℓ (de exemplu 8, 4, 1): blocurile de rezoluție mică văd forma pe termen lung, cele de rezoluție mare detaliul
- ▣ Fiecare bloc dă doar H/r_ℓ coeficienți, interpolați la H puncte: raportul de expresivitate r_ℓ obligă blocurile grosiere să prognozeze componente netede
 - ▶ o descompunere explicită pe frecvențe a prognozei, apropiată de multirezoluția wavelet din [Capitolul 11](#)
- ▣ Mai puțini parametri și mai puțin calcul decât N-BEATS la orizonturi lungi, cu acuratețe asemănătoare la cele scurte
- ▣ Ale noastre: N-BEATS generic (3 blocuri $\times$ 3 straturi $\times$ 256 de unități) și N-HiTS (pooling 8, 4, 1), intrare de 336 de ore, fiecare fereastră împărțită la nivelul ei mediu absolut, pierdere MAE, mediana a 3 seed-uri

Design: subsetul orar M4

- ▣ Makridakis, Spiliotis și Assimakopoulos (2020): 414 de serii orare, orizont 48; sMAPE, MASE cu perioada sezonieră 24 Hyndman și Koehler (2006) și $OWA = \frac{1}{2} (sMAPE/sMAPE_{Naive2} + MASE/MASE_{Naive2})$
- ▣ Naive, naivul sezonier și Naive 2 calculate aici reproduc exact fișierul oficial de evaluare M4: Naive 2 sMAPE 18,38 (oficial 18,38), MASE 2,40 (oficial 2,40)
- ▣ Repere din același fișier: reperele M4 MLP și RNN (OWA 0,921 și 1,036), Theta 1,006, câștigătorul Smyl (2020) 0,440, locul doi Montero-Manso et al. 0,484
- ▣ Toate modelele globale sînt antrenate doar pe părțile de antrenare: perioada de test nu este văzută niciodată

Modele deep globale pe seriile orare M4



□ Stînga: OWA (Naive 2 = 1); dreapta: o serie cu prognozele naivului sezonier, N-BEATS și N-HiTS


Interpretarea rezultatelor M4 orare

- OWA: naiv sezonier 0,628, DLinear 0,683, N-BEATS 0,539 (sMAPE 10,73, MASE 1,19), N-HiTS 0,548
- Cîteva minute de antrenare pe procesor pun N-BEATS înaintea tuturor reperelor M4 și a reperelor neuronale M4 (0,921; 1,036), în urma primelor două participări (0,440; 0,484)
- Reperele neuronale M4 erau locale (o rețea pe serie); ale noastre sînt globale: reunirea celor 414 serii face diferența
- DLinear este mai slab aici: seriile orare M4 cer interacțiuni neliniare între nivel și sezon pe care un singur strat liniar nu le poate exprima

DeepAR: prognoze probabilistice dintr-o rețea recurentă globală

- ▣ Salinas et al. (2020): $h_{i,t} = \text{LSTM}(h_{i,t-1}, z_{i,t-1}, x_{i,t})$, verosimilitatea $z_{i,t} \sim \ell(\cdot \mid \theta(h_{i,t}))$: gaussiană (μ, σ) pentru date reale, binomială negativă pentru numărări
 - ▶ antrenarea: maximizăm $\sum_{i,t} \log \ell(z_{i,t} \mid \theta(h_{i,t}))$ pe ferestre aleatoare din toate seriile, fiecare scalată cu $1 + \text{media contextului}$
 - ▶ intrările includ valori întârziate la decalaje sezoniere (aici 1, 24, 168) și variabile de calendar
- ▣ Prognoza: simulare ancestrală, fiecare extragere reintrodusă ca intrare următoare; cuantilele din traiectoriile simulate
 - ▶ evaluat prin pierderea cuantică ponderată $w_{\text{QL}} = \sum_{\tau} 2 \sum_{i,t} \rho_{\tau}(z - \hat{q}_{\tau}) / \sum_{i,t} |z|$, o aproximare a CRPS Gneiting și Raftery (2007)
- ▣ Modelul preferat pentru paneluri mari din retail și energie; baza mai multor foundation models (Capitolul 13)

Un DeepAR mic pe seriile orare M4



- LSTM cu două straturi (40 de unități), context de 168 de ore, 4000 de pași de antrenare cu câte 64 de ferestre, 100 de traiectorii simulate; aceeași serie ca în graficul anterior

Interpretarea DeepAR

- wQL după bugetul de antrenare (pași): 500: 0,0344, 1000: 0,0338, 2000: 0,0374, 4000: 0,0405; naivul sezonier cu cuantile empirice: 0,0375
- După 1000 de pași, DeepAR bate reperul (acoperirea de 80%: 83%); cu antrenare mai lungă, supraajustează ferestrele de antrenare și pierde (76% la 4000 de pași)
- Alegerea celui mai bun punct de control din acest tabel ar fi data snooping: bugetul trebuie fixat pe un bloc de validare înainte de a deschide perioada de test
- Modelele deep probabilistice sînt sensibile la bugetul de antrenare; raportați regula care l-a fixat și reperul sub o regulă de scor proprie

Lecțiile competiției M5

- ▣ [Makridakis, Spiliotis și Assimakopoulos \(2022\)](#): 42 840 de serii Walmart într-o ierarhie, vânzări zilnice în unități, 28 de zile înainte; secțiunile de acuratețe și de incertitudine
 - ▶ metodele câștigătoare la acuratețe au fost modele LightGBM globale pe variabile construite (decalaje, medii mobile, prețuri, calendar), adesea combinate
- ▣ Modelele globale, învățarea între serii și informația externă (prețuri, evenimente) au contat mai mult decât arhitectura
- ▣ Reperele simple au fost bătute, dar cu marje mai mici decât sugerează publicitatea ML și cel mai puțin la nivelul de jos al ierarhiei
- ▣ Un avertisment anterior: metodele ML au pierdut în fața celor statistice pe datele lunare M3 [Makridakis, Spiliotis și Assimakopoulos \(2018\)](#); diferența dintre M3 și M5 este volumul de date și învățarea între serii


Recapitulare: modele deep globale

- N-BEATS și N-HiTS: stive reziduale de blocuri complet conectate, generice sau cu baze de trend și sezon, pe mai multe rate în N-HiTS
- Pe M4 orar, N-BEATS global bate toate reperele și rețelele neuronale locale din M4
- DeepAR dă traiectorii dintr-o verosimilitate; bate naivul sezonier sub wQL doar la bugetul de antrenare potrivit, care trebuie fixat pe date de validare

Valorile Shapley

- **Shapley (1953)**: un joc $v : 2^{\{1..G\}} \rightarrow \mathbb{R}$; $\phi_g = \sum_{S \subseteq \{1..G\} \setminus g} \frac{|S|!(G - |S| - 1)!}{G!} [v(S \cup g) - v(S)]$
 - ▶ singura alocare cu eficiență ($\sum_g \phi_g = v(\text{toate}) - v(\emptyset)$), simetrie, jucător nul și aditivitate
- **SHAP Lundberg și Lee (2017)**: $v(S) = \mathbb{E}[f(x_S, X_{\bar{S}})]$; **intervențional**: $X_{\bar{S}}$ dintr-un eșantion de fundal, independent de x_S ; **observațional**: condiționat de x_S
 - ▶ cu decalaje, variabilele sînt puternic corelate: valorile intervenționale evaluează modelul pe istorii imposibile; grupați în schimb decalaje corelate
- Aici: valori Shapley exacte pentru trei grupuri de decalaje (ziua, zilele 2–5, zilele 6–22) pentru boosting pe logaritmul RV S&P 500, 300 de zile de prognoză, 100 de zile de fundal

Tiparul învățat de modelul boosting



□ Fiecare punct: o zi de prognoză; orizontal: media logaritmului RV a grupului; vertical: valoarea lui Shapley


Interpretarea valorilor Shapley

- ▣ Ponderile mediei $|\phi|$: ultima zi 37%, zilele 2–5 46%, zilele 6–22 17%
- ▣ HAR pe același eșantion: coeficienți 0,28; 0,50; 0,17 pentru mediile zilnică, săptămînală și lunară: arborii boosting au redescoperit cascada HAR
- ▣ Valorile se aplatizează la extreme: arborii își limitează prognozele la intervalul de antrenare, motivul pentru care boosting a pierdut față de HAR în 2020
- ▣ Valorile Shapley descriu modelul, nu procesul generator: descrierea corectă a unui model greșit rămîne greșită

Atenția nu este explicație

- Jain și Wallace (2019): ponderile atenției sînt adesea necorelate cu importanța bazată pe gradient, iar tipare de atenție foarte diferite dau aceleași prognoze
- Wiegrefe și Pinter (2019): atenția poate fi o explicație fidelă în anumite condiții, dar acest lucru trebuie testat, nu presupus
- Un test: importanța prin ocluzie, creșterea MSE cînd un segment de intrare este înlocuit cu media ferestrei, față de atenția primită de fiecare segment
 - ▶ pe Transformer-ul pe segmente din secțiunea 5 ($H = 96$), primele 1000 de ferestre de test

Atenția Transformer-ului și informația folosită



- Ponderea atenției primite de fiecare dintre cele 14 segmente zilnice față de ponderea importanței prin ocluzie

 [ATS_ch12_interpretation](#)


Interpretarea atenției și ocluziei

- ▣ Ultima zi poartă 46% din importanța prin ocluzie, dar primește doar 8% din atenție
- ▣ Cea mai mare atenție merge la segmentul de acum 14 zile; cel mai important segment este cel de acum 1 zi; corelația Spearman $-0,09$
- ▣ Capul care aplatizează citește direct stările tokenilor: ce contează poate ocoli complet ponderile atenției
- ▣ Raportați hărțile de atenție drept ceea ce sînt, un tipar de amestecare; pentru importanță folosiți ocluzia, Shapley sau gradientii, cu o verificare de control

Comparația onestă

- Întii repere puternice: naiv sezonier, ETS/Theta, HAR, un ARX expert; Lago et al. au construit un reper deschis pentru că modelele publicate de prețuri ale electricității erau rar comparate cu ele [Lago et al. \(2021\)](#)
- Capcanele inventariate de [Hewamalage, Ackermann și Bergmeir \(2023\)](#): reutilizarea setului de test, scurgeri prin scalare și variabile, erori mediate pe serii de scări diferite, fără teste de semnificație, buget de reglare neraportat
- Teste ([Capitolul 1](#)): DM pentru două modele, MCS [Hansen, Lunde și Nason \(2011\)](#) pentru mai multe, reality check [White \(2000\)](#) și SPA [Hansen \(2005\)](#) când cel mai bun dintre multe a fost ales pe aceleași date
- Raportați seed-urile, hardware-ul, timpul de antrenare, fiecare arhitectură încercată; preînregistrați designul ([Capitolul 0](#))

Seed-uri și data snooping



- Stînga: MLP față de HAR pentru RV S&P 500, $h = 1$, cu 10 seed-uri și ansamblul lor; dreapta: simulare, K modele la fel de bune, 2500 de zile de test, corelație 0,5

Interpretarea seed-urilor și a data snooping

- Doar seed-urile mută raportul QLIKE între 1,019 și 1,041 (mediana 1,027); ansamblul seed-urilor ajunge la 1,013, mai bun decât orice seed individual
- Alegerea celui mai bun dintre K modele la fel de bune pe setul de test: testul DM îl declară mai bun (unilateral, nivel nominal 2,5%) în 2% din cazuri pentru $K = 1$, 14% pentru $K = 10$, 40% pentru $K = 100$
- Căutările de hiperparametri, seed-urile și arhitecturile sînt toate K : numărați-le și testați câștigătorul cu SPA sau MCS pe date nefolosite pentru alegere
- Ansamblurile sînt remediul ieftin pentru varianța seed-urilor; preînregistrarea este remediul pentru data snooping

Recapitulare: interpretare și comparații oneste

- ▣ Valorile Shapley au axiome; cu variabile întârziate folosiți grupuri și amintiți-vă că ele descriu modelul
- ▣ Ponderile atenției nu sînt importantă: pe Transformer-ul nostru ele indică în direcția opusă
- ▣ Repere puternice, DM/MCS/SPA, toate seed-urile și toate încercările raportate: altfel orice model poate fi făcut să cîștige

O întrebare deschisă

- Prognozează modelele de machine learning și deep learning volatilitatea realizată mai bine decât HAR, pe mai multe piețe și orizonturi, atunci când comparația este preînregistrată?
 - ▶ formal: $H_0: \mathbb{E}[\text{QLIKE}_{\text{ML}} - \text{QLIKE}_{\text{HAR}}] \geq 0$ în fiecare celulă; o celulă susține ML doar dacă DM respinge la 5% și MCS exclude HAR
 - ▶ infirmată dacă mai puțin de o cincime din celule susțin ML
- Miza: sistemele de risc (VaR, marje, acoperirea opțiunilor) se bazează pe prognoze de volatilitate; un câștig ML aparent devine un risc de model
 - ▶ literatura de pornire: Corsi (2009), Bucci (2020), Christensen, Siggaard și Veliyev (2023), Hewamalage, Ackermann și Bergmeir (2023)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate din 2019 încoace care compară rețele neuronale sau boosting cu HAR pentru volatilitatea realizată în afara eșantionului; dă DOI-urile și testul folosit. Apoi verificați fiecare DOI pe Crossref
 - ▶ **designul:** Scrie o preînregistrare: active, orizonturi, ferestre, calendarul reestimării, pierderea, testele, seed-urile, ce înseamnă un câștig.
 - ▶ **cod și replicare:** reproduceți întâi QLIKE HAR pentru S&P 500 (0,253 la $h = 1$ aici), apoi adăugați algoritmi pe rând
 - ▶ **critica:** Joacă rolul unui recenzent ostil: enumeră fiecare sursă de scurgere de informație, data snooping și reglare inechitabilă din această comparație.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Nicio informație din viitor: scalarea, construcția variabilelor și reglarea folosesc doar date dinaintea fiecărei origini; purjare în jurul țintelor la h pași
- ▣ Reperul este reglat la fel de atent ca algoritmul și reestimat după același calendar
- ▣ Seed-urile, arhitecturile și hiperparametrii încercați sînt toți raportați; câștigătorul este testat cu MCS sau SPA
- ▣ O afirmație AI de tipul „LSTM captează memoria lungă, deci bate HAR” se verifică pe cifre, nu se acceptă

Mini studiu de caz: algoritmi față de HAR pe mai multe piețe



- 36 de celule: șase indici $\times$ trei orizonturi $\times$ doi algoritmi (MLP, boosting), designul extins din secțiunea 4; raportul QLIKE față de HAR, o stea unde DM respinge la 5%
- Rapoarte între 0,95 și 1,14, mediana 1,024 (MLP 1,009, boosting 1,052); 9 celule sub 1, 1 semnificativ mai bune, 10 semnificativ mai slabe: ipoteza este infirmată pentru acești algoritmi

Idee de proiect

- ▣ **Deep learning față de HAR pentru volatilitatea din Europa Centrală și de Est:** întâi replicare, apoi extindere
 - ▶ replicați: HAR [Corsi \(2009\)](#) și comparația neuronală din [Bucci \(2020\)](#) pe indicii Oxford-Man, cu designul din secțiunea 4
 - ▶ extindeți: RV din date intraday pentru BET, WIG20 și EUR/RON; modele globale pe mai multe piețe; predictor exogeni (VIX, știri macro) ca în [Christensen, Siggaard și Veliyev \(2023\)](#)
 - ▶ preînregistrați: piețele, orizonturile, ferestrele, fiecare algoritm și bugetul lui de reglare, QLIKE, DM, MCS, seed-urile
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Validarea trebuie să respecte dependența: K subeșantioane doar pentru autoregresii bine specificate; altfel blocuri, purjare și o perioadă finală de test
- ▣ Modelele globale reunesc seriile și își permit memorie; selecția în dimensiune mare pe eșantioane macro scurte este instabilă
- ▣ Arborii și rețelele bat rar singure reperele puternice și structurate (ARX expert, HAR); ajută în combinații și în paneluri mari
- ▣ Detaliile de arhitectură contează: porți de uitare deschise, segmente în loc de tokeni punctuali, antrenare globală
- ▣ Atenția nu este explicație; seed-urile și căutările sînt testare multiplă ascunsă

Autoevaluare

Întrebări

- De ce este validă validarea cu K subeșantioane aleatoare pentru un $AR(3)$ estimat pe date $AR(3)$, dar nu pentru ținte de 22 de zile?
- Ce condiție elimină lasso-ul adaptiv și cum?
- De ce adăugarea de arbori nu reduce varianța unei păduri sub $\rho\sigma^2$?
- Care este câmpul receptiv al unui TCN cu $k = 3$ și cinci niveluri?
- De ce poate un Transformer pe segmente să bată DLinear, iar unul cu tokeni punctuali nu?

Urmează:

- Foundation models și predicție conformală
- modele preantrenate folosite zero-shot și intervale fără ipoteze de distribuție pentru orice model, inclusiv cele din acest capitol

Anexă: deplasarea validării cu K subeșantioane sub erori autocorelate

- Model liniar $y = X\beta + \varepsilon$; omitem rîndul i : $e_{(i)} = e_i / (1 - h_{ii})$, h_{ii} efectul de pîrghie
- $\mathbb{E} e_{(i)}^2 \approx \sigma^2(1 + h_{ii}) - 2 \sum_{j \neq i} \frac{H_{ij}}{1 - h_{ii}} \text{Cov}(\varepsilon_i, \varepsilon_j)$, la ordinul întâi
- Erori necorelate: al doilea termen dispăre, iar LOOCV estimează MSE în afara eșantionului $\sigma^2(1 + h)$: cazul Bergmeir–Hyndman–Koo
- Corelație pozitivă între eroarea omisă și erorile de antrenare vecine ($H_{ij} > 0$ pentru vecinii cu decalaje asemănătoare): estimația este prea mică; purjarea anulează termenii vecini

Anexă: pragul moale și elastic net

- Cu $X'X = nI$, funcția obiectiv se separă: $\frac{1}{2}(\beta_j - z_j)^2 + \lambda|\beta_j|$ pentru fiecare j , $z_j = x_j'y/n$
- Subgradientul: $0 \in \beta_j - z_j + \lambda \partial|\beta_j|$; dacă $|z_j| \leq \lambda$, $\beta_j = 0$; altfel $\beta_j = z_j - \lambda \text{sign}(z_j)$
- Elastic net: $\frac{1}{2}(\beta_j - z_j)^2 + \lambda\alpha|\beta_j| + \frac{\lambda(1-\alpha)}{2}\beta_j^2$ dă $\beta_j = S(z_j, \lambda\alpha)/(1 + \lambda(1 - \alpha))$
- Lasso adaptiv: pragul $\lambda w_j = \lambda/|\tilde{\beta}_j|^\gamma$, mic pentru $|\tilde{\beta}_j|$ mare: deplasarea coeficienților mari dispare, de unde proprietatea de oracol

Bibliografie (1/6)

- Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. [arXiv:1803.01271](https://arxiv.org/abs/1803.01271). [arxiv.org](https://arxiv.org/abs/1803.01271)
- Basu, S., & Michailidis, G. (2015). Regularized estimation in sparse high-dimensional time series models. *The Annals of Statistics*, 43(4), 1535–1567. [doi:10.1214/15-AOS1315](https://doi.org/10.1214/15-AOS1315)
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *The Review of Economic Studies*, 81(2), 608–650. [doi:10.1093/restud/rdt044](https://doi.org/10.1093/restud/rdt044)
- Bengio, Y., Simard, P., & Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2), 157–166. [doi:10.1109/72.279181](https://doi.org/10.1109/72.279181)
- Benidis, K., Rangapuram, S. S., Flunkert, V., Wang, Y., et al. (2022). Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, 55(6), 1–36. [doi:10.1145/3533382](https://doi.org/10.1145/3533382)
- Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213. [doi:10.1016/j.ins.2011.12.028](https://doi.org/10.1016/j.ins.2011.12.028)
- Bergmeir, C., Hyndman, R. J., & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83. [doi:10.1016/j.csda.2017.11.003](https://doi.org/10.1016/j.csda.2017.11.003)
- Berk, R., Brown, L., Buja, A., Zhang, K., & Zhao, L. (2013). Valid post-selection inference. *The Annals of Statistics*, 41(2), 802–837. [doi:10.1214/12-AOS1077](https://doi.org/10.1214/12-AOS1077)
- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140. [doi:10.1007/BF00058655](https://doi.org/10.1007/BF00058655)
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. [doi:10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324)
- Bucci, A. (2020). Realized volatility forecasting with neural networks. *Journal of Financial Econometrics*, 18(3), 502–531. [doi:10.1093/jjfinec/nbaa008](https://doi.org/10.1093/jjfinec/nbaa008)
- Burman, P., Chow, E., & Nolan, D. (1994). A cross-validatory method for dependent data. *Biometrika*, 81(2), 351–358. [doi:10.1093/biomet/81.2.351](https://doi.org/10.1093/biomet/81.2.351)
- Challu, C., Olivares, K. G., Oreshkin, B. N., Garza Ramirez, F., Mergenthaler Canseco, M., & Dubrawski, A. (2023). NHITS: Neural hierarchical interpolation for time series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(6), 6989–6997. [doi:10.1609/aaai.v37i6.25854](https://doi.org/10.1609/aaai.v37i6.25854)
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. [doi:10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785)

Bibliografie (2/6)

- ▣ Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. *Proceedings of EMNLP 2014*, 1724–1734. doi:10.3115/v1/D14-1179
- ▣ Christensen, K., Siggaard, M., & Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727. doi:10.1093/jjfinec/nbac020
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jjfinec/nbp001
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- ▣ Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). Learning to forget: Continual prediction with LSTM. *Neural Computation*, 12(10), 2451–2471. doi:10.1162/089976600300015015
- ▣ Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/016214506000001437
- ▣ Goulet Coulombe, P., Leroux, M., Stevanovic, D., & Surprenant, S. (2022). How is machine learning useful for macroeconomic forecasting? *Journal of Applied Econometrics*, 37(5), 920–964. doi:10.1002/jae.2910
- ▣ Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5), 2223–2273. doi:10.1093/rfs/hhaa009
- ▣ Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. doi:10.1198/073500105000000063
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- ▣ Heber, G., Lunde, A., Shephard, N., & Sheppard, K. K. (2009). Oxford-Man Institute's realized library, version 0.3. Oxford-Man Institute, University of Oxford. web.archive.org
- ▣ Hewamalage, H., Ackermann, K., & Bergmeir, C. (2023). Forecast evaluation for data scientists: Common pitfalls and best practices. *Data Mining and Knowledge Discovery*, 37(2), 788–832. doi:10.1007/s10618-022-00894-5
- ▣ Hewamalage, H., Bergmeir, C., & Bandara, K. (2021). Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 37(1), 388–427. doi:10.1016/j.ijforecast.2020.06.008

Bibliografie (3/6)

- ▣ Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. doi:10.1162/neco.1997.9.8.1735
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Jain, S., & Wallace, B. C. (2019). Attention is not explanation. *Proceedings of NAACL-HLT 2019*, 3543–3556. doi:10.18653/v1/N19-1357
- ▣ Jozefowicz, R., Zaremba, W., & Sutskever, I. (2015). An empirical exploration of recurrent network architectures. *Proceedings of the 32nd International Conference on Machine Learning*, PMLR 37, 2342–2350. proceedings.mlr.press
- ▣ Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30. proceedings.neurips.cc
- ▣ Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations*. arXiv:1412.6980. arxiv.org
- ▣ Lago, J., Marcjasz, G., De Schutter, B., & Weron, R. (2021). Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293, 116983. doi:10.1016/j.apenergy.2021.116983
- ▣ Lee, J. D., Sun, D. L., Sun, Y., & Taylor, J. E. (2016). Exact post-selection inference, with application to the lasso. *The Annals of Statistics*, 44(3), 907–927. doi:10.1214/15-AOS1371
- ▣ Lim, B., Ank, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748–1764. doi:10.1016/j.ijforecast.2021.03.012
- ▣ Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. proceedings.neurips.cc
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. doi:10.1016/j.ijforecast.2021.11.013
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE*, 13(3), e0194889. doi:10.1371/journal.pone.0194889
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. doi:10.1016/j.ijforecast.2019.04.014
- ▣ Medeiros, M. C., & Mendes, E. F. (2016). ℓ_1 -regularization of high-dimensional time-series models with non-Gaussian and heteroskedastic errors. *Journal of Econometrics*, 191(1), 255–271. doi:10.1016/j.jeconom.2015.10.011

Bibliografie (4/6)

- ▣ Medeiros, M. C., Vasconcelos, G. F. R., Veiga, Á., & Zilberman, E. (2021). Forecasting inflation in a data-rich environment: The benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), 98–119. doi:10.1080/07350015.2019.1637745
- ▣ Meinshausen, N. (2006). Quantile regression forests. *Journal of Machine Learning Research*, 7, 983–999. jmlr.org
- ▣ Mohri, M., & Rostamizadeh, A. (2010). Stability bounds for stationary φ -mixing and β -mixing processes. *Journal of Machine Learning Research*, 11, 789–814. jmlr.org
- ▣ Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting*, 37(4), 1632–1653. doi:10.1016/j.ijforecast.2021.03.004
- ▣ Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with Transformers. *International Conference on Learning Representations*. arXiv:2211.14730. arxiv.org
- ▣ Oreshkin, B. N., Carpo, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations*. arXiv:1905.10437. arxiv.org
- ▣ Pascanu, R., Mikolov, T., & Bengio, Y. (2013). On the difficulty of training recurrent neural networks. *Proceedings of the 30th International Conference on Machine Learning*, PMLR 28(3), 1310–1318. proceedings.mlr.press
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Racine, J. (2000). Consistent cross-validated model-selection for dependent data: hv-block cross-validation. *Journal of Econometrics*, 99(1), 39–61. doi:10.1016/S0304-4076(00)00030-0
- ▣ Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536. doi:10.1038/323533a0
- ▣ Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3), 1181–1191. doi:10.1016/j.ijforecast.2019.07.001
- ▣ Scornet, E., Biau, G., & Vert, J.-P. (2015). Consistency of random forests. *The Annals of Statistics*, 43(4), 1716–1741. doi:10.1214/15-AOS1321
- ▣ Shapley, L. S. (1953). A value for n -person games. In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games II*, 307–318. Princeton University Press. doi:10.1515/9781400881970-018

Bibliografie (5/6)

- ▣ Smyl, S. (2020). A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. *International Journal of Forecasting*, 36(1), 75–85. doi:10.1016/j.ijforecast.2019.03.017
- ▣ Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in Neural Information Processing Systems*, 27. arXiv:1409.3215. [arxiv.org](https://arxiv.org/abs/1409.3215)
- ▣ Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288. doi:10.1111/j.2517-6161.1996.tb02080.x
- ▣ van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A generative model for raw audio. arXiv:1609.03499. [arxiv.org](https://arxiv.org/abs/1609.03499)
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. [proceedings.neurips.cc](https://proceedings.neurips.cc/paper/2017/file/3e924a60bed44f4006482ccf51660945-Paper.pdf)
- ▣ Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242. doi:10.1080/01621459.2017.1319839
- ▣ White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126. doi:10.1111/1468-0262.00152
- ▣ Wiegreffe, S., & Pinter, Y. (2019). Attention is not not explanation. *Proceedings of EMNLP-IJCNLP 2019*, 11–20. doi:10.18653/v1/D19-1002
- ▣ Wu, H., Xu, J., Wang, J., & Long, M. (2021). Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. *Advances in Neural Information Processing Systems*, 34. [proceedings.neurips.cc](https://proceedings.neurips.cc/paper/2021/file/00000000000000000000000000000000-Paper.pdf)
- ▣ Yu, B. (1994). Rates of convergence for empirical processes of stationary mixing sequences. *The Annals of Probability*, 22(1), 94–116. doi:10.1214/aop/1176988849
- ▣ Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128. doi:10.1609/aaai.v37i9.26317
- ▣ Zhao, P., & Yu, B. (2006). On model selection consistency of lasso. *Journal of Machine Learning Research*, 7, 2541–2563. [jmlr.org](https://jmlr.org/papers/v7/zhao06a.html)
- ▣ Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106–11115. doi:10.1609/aaai.v35i12.17325
- ▣ Ziel, F., & Weron, R. (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics*, 70, 396–420. doi:10.1016/j.eneco.2017.12.016

Bibliografie (6/6)

- Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320. doi:10.1111/j.1467-9868.2005.00503.x
- Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429. doi:10.1198/016214506000000735