



Analiza avansată a seriilor de timp și previziune

Capitolul 13: Foundation models și predicție conformală



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ API: Application Programming Interface (interfață de programare a aplicațiilor)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ARX: AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- ▣ BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ BH: Benjamini–Hochberg (procedure) — procedura Benjamini–Hochberg
- ▣ BOOM: Benchmark Of Observability Metrics (benchmark de metrici de observabilitate (Toto))
- ▣ CPM: Contiguous Patch Masking (mascarea patch-urilor contigue)
- ▣ CPU: Central Processing Unit (procesorul central)
- ▣ CQR: Conformalized Quantile Regression (regresia cuantică conformalizată)
- ▣ CRPS: Continuous Ranked Probability Score (scorul probabilistic continuu)
- ▣ DM: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ DQ: Dynamic Quantile (test of Engle and Manganelli) — testul dinamic pe cuantile al lui Engle și Manganelli
- ▣ ENTSO-E: European Network of Transmission System Operators for Electricity (Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- ▣ EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ ETS: Error, Trend, Seasonality (exponential smoothing state space models) — eroare, trend, sezonabilitate (modele de netezire exponențială)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GIFT: General Time Series Forecasting Model Evaluation (the GIFT-Eval benchmark) — benchmark general pentru evaluarea modelelor de prognoză
- ▣ GPT-2: Generative Pre-trained Transformer 2 (OpenAI language model) — model de limbaj al OpenAI, a doua generație
- ▣ GPT4TS: GPT for Time Series (One Fits All) — GPT pentru serii de timp (One Fits All)
- ▣ GW: Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație

Acronime folosite în acest material (2/2)

- HAR: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- HICP: Harmonised Index of Consumer Prices (indicele armonizat al prețurilor de consum (IAPC))
- HLN: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- LLM: Large Language Model (model lingvistic de mari dimensiuni)
- LOTSA: Large-scale Open Time Series Archive (arhiva deschisă de serii de timp de mari dimensiuni (Moirai))
- MAE: Mean Absolute Error (eroarea absolută medie)
- MASE: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MOMENT: MOMENT, a family of open time-series foundation models (familie de foundation models deschise pentru serii de timp)
- MSE: Mean Squared Error (eroarea pătratică medie)
- NVIDIA: NVIDIA Corporation (graphics processors) — compania NVIDIA (procesoare grafice)
- OOD: Out Of Distribution (în afara distribuției de antrenare)
- PID: Proportional–Integral–Derivative (controller) — controler proporțional–integral–derivat
- QLIKE: Quasi-LIKelihood loss (pierderea de tip cvasi-verosimilitate)
- RLHF: Reinforcement Learning from Human Feedback (învățare prin recompensă din evaluări umane)
- RV: Realised Variance (varianța realizată)
- TS: Time Series (in TS-Arena) — serii de timp (în numele TS-Arena)
- TSA: Time Series Analysis (Serii de timp, cursul de licență)
- TVA: Taxa pe valoarea adăugată
- UE: Uniunea Europeană
- WQL: Weighted Quantile Loss (pierderea cuantică ponderată)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** poate un model preantrenat să prognozeze serii pe care nu le-a văzut niciodată și cum transformăm orice prognoză, preantrenată sau nu, în intervale a căror acoperire o putem garanta sau măcar controla?
 - ▶ două jumătăți ale aceleiași probleme: acuratețea punctuală și a cuantilelor (foundation models), apoi o incertitudine onestă (predicția conformală)
- ▣ **Traseul** capitolului
 - ▶ preantrenarea: date, token-uri, patch-uri, legi de scalare; familiile de modele și alegerile de proiectare
 - ▶ benchmark-uri, contaminare și testare pe multe serii; dovezi pe date românești și europene; LLM și critica lor
 - ▶ predicția conformală: interschimbabilitate, split conformal, CQR, limitele acoperirii condiționate
 - ▶ date dependente: ponderi, EnbPI, ACI, PID conformal; diagnosticare; calibrarea intervalelor produse de foundation models și VaR
- ▣ Cunoștințe necesare; Seminarul 13 are loc înaintea acestui curs
 - ▶ [TSA, Capitolul 11](#): Chronos, TimesFM, Moirai, teste zero-shot, CRPS și WQL
 - ▶ [Capitolul 1](#) (reguli de scor, DM, MCS), [Capitolul 9](#) (backtesting VaR, ACI pentru VaR), [Capitolul 12](#) (arhitecturi deep)

Rezultatele învățării

- ▣ Explicați cum se preantrenează un foundation model pentru serii de timp: corpus, scalare, tokenizare sau patching, stratul de ieșire și funcția de pierdere
- ▣ Comparați familiile de modele și alegeți între folosirea zero-shot, fine-tuning și covariabilele în context
- ▣ Proiectați un benchmark fără leakage sau contaminare și testați diferențele pe multe serii cu corecții pentru testarea multiplă
- ▣ Demonstrați acoperirea metodelor split conformal și CQR și precizați ce nu poate garanta predicția conformală
- ▣ Aplicați predicția conformală ponderată, EnbPI, ACI și PID conformal pe date dependente, diagnosticați acoperirea și calibrați intervalele produse de foundation models

Bibliografie, date și instrumente

- ▣ Foundation models și benchmark-uri
 - ▶ modele: Ansari et al. (2024); Ansari et al. (2025); Das et al. (2024); Woo et al. (2024); Auer et al. (2025)
 - ▶ benchmark-uri: Aksu et al. (2024); Shchur et al. (2025); critică și evaluare: Tan et al. (2024); Hewamalage, Ackermann și Bergmeir (2023)
- ▣ Predicție conformală
 - ▶ teorie: Vovk, Gammerman și Shafer (2022); Angelopoulos și Bates (2023); Romano, Patterson și Candès (2019); Barber et al. (2023)
 - ▶ serii de timp: Gibbs și Candès (2021); Angelopoulos, Candès și Tibshirani (2023); Xu și Xie (2021); sinteză despre practica prognozei: Petropoulos et al. (2022)
- ▣ Quantlet-urile Python ale capitolului: [Quantlets/Ch_13](#)
 - ▶ modele deschise pe un CPU: `chronos-forecasting` (Chronos-Bolt, Chronos-2), `timesfm` (TimesFM 2.5), `tirex-ts` (TiRex); metodele conformale, DM, MCS și backtesting-ul scrise în `numpy`
- ▣ Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa	Eșantionul
Consumul de electricitate al României, orar	Energy-Charts (date de transparență ENTSO-E)	2022 – 30 septembrie 2026
Temperatura aerului la București, orar	arhiva istorică Open-Meteo	2022 – 2026
Inflația anuală HICP, 27 de țări UE	Eurostat, lunar	2000 – august 2026
Varianța realizată, randamente de 5 minute	Bitcoin: Binance; S&P 500: Oxford-Man Heber et al. (2009)	2018 – 2026; 2000 – 2022
BET, S&P 500, NVIDIA, zilnic	închideri zilnice EODHD	2000 – 2026

- Randamentele sînt diferențe logaritmice înmulțite cu 100; varianța realizată este în procente la pătrat; orice prognoză folosește doar datele disponibile la momentul emiterii ei

Două direcții de cercetare care s-au întâlnit



Royal Holloway, Universitatea din Londra: Founder's Building

Foto: Diliff (2015); CC BY-SA 3.0; Wikimedia Commons

- Anii 1990–2005: predicția conformală la Royal Holloway: Vovk, Gammerman și Shafer, cu rădăcini în aleatorismul algoritmic al lui Kolmogorov Vovk, Gammerman și Shafer (2005)
- 2002–2018: split conformal (inductiv) Papadopoulos et al. (2002); regresie fără ipoteze de distribuție Lei et al. (2018); 2019: CQR Romano, Patterson și Candès (2019)
- 2021–2023: serii de timp: ACI Gibbs și Candès (2021), EnbPI Xu și Xie (2021), PID conformal Angelopoulos, Candès și Tibshirani (2023), dincolo de interschimbabilitate Barber et al. (2023)
- 2017–2025: Transformers Vaswani et al. (2017), foundation models Bommasani et al. (2021); pentru serii: Lag-Llama, TimesFM, Moirai, Chronos (2023–2024), TiRex, Chronos-2 (2025)

Cunoscut din TSA și elemente noi

□ Cunoscut (TSA, Capitolul 11)

- ▶ folosirea zero-shot a modelelor Chronos, TimesFM, Moirai și Lag-Llama; scalarea prin medie și cuantizarea, pe scurt
- ▶ pierderea pinball, CRPS, WQL, MASE; primele avertismente despre contaminare

□ Nou: instrumentele de cercetare

- ▶ alegerile de proiectare și consecințele lor (limitele de domeniu, straturi de cuantile, patching, covariabile în context), dovezile de scalare
- ▶ benchmark-uri cu ferestre preînregistrate după lansarea modelelor, teste pe multe serii cu corecțiile Holm și BH
- ▶ teoria conformală cu demonstrații, eșecul ei sub dependență și metodele online care o corectează, cu diagnosticarea acoperirii

□ Studii de caz: designul din lucrări, pe datele noastre

- ▶ foundation models: Ansari et al. (2024); Tan et al. (2024)
- ▶ predicție conformală: Romano, Patterson și Candès (2019); Gibbs și Candès (2021); Barber et al. (2023); Angelopoulos, Candès și Tibshirani (2023); Xu și Xie (2021)

Un foundation model ca prognozator amortizat (1/2)

- ▣ **Preantrenarea:** o singură rețea este estimată o singură dată, prin minimizarea pierderii de prognoză însumate pe toate seriile și pe toate originile unui corpus mare

$$\hat{\theta} = \arg \min_{\theta} \sum_{s \in \mathcal{D}_{\text{pre}}} \sum_t \ell(y_{t+1:t+H}^{(s)}, f_{\theta}(y_{t-C+1:t}^{(s)}))$$

- ▣ **Notățiile**

- ▶ $\mathcal{D}_{\text{pre}}$: corpusul de preantrenare, o colecție de multe serii; s indexează seriile, t originea prognozei
- ▶ $y_{t-C+1:t}^{(s)}$: ultimele C valori ale seriei s (**contextul**); $y_{t+1:t+H}^{(s)}$: următoarele H valori (**orizontul**)
- ▶ f_{θ} : rețeaua cu ponderile θ ; transformă un context într-o prognoză a următoarelor H valori (o distribuție sau un set de cuantile)
- ▶ ℓ : o regulă de scor (entropie încrucișată, pinball, log-verosimilitate negativă); $\hat{\theta}$: ponderile estimate

- ▣ Termenul **foundation model** [Bommasani et al. \(2021\)](#): model antrenat o singură dată pe date diverse, apoi adaptat la multe sarcini

Un foundation model ca prognozator amortizat (2/2)

- Folosirea **zero-shot**: ponderile rămân $\hat{\theta}$, iar prognoza pentru o serie nouă $y_1, \dots, y_T$ este rețeaua aplicată ultimelor ei C valori

$$\hat{y}_{T+1:T+H} = f_{\hat{\theta}}(y_{T-C+1:T})$$

- ▶ T : ultima perioadă observată a seriei-țintă; niciun parametru nu se estimează pe ea
- **Inferența amortizată**
 - ▶ un model clasic este reestimat pe fiecare serie nouă; aici rețeaua face pasul de estimare în interiorul trecerii înainte (forward pass)
 - ▶ costul estimării este plătit o singură dată, la preantrenare, și împărțit între toate prognozele ulterioare
- Modelul global și foundation model
 - ▶ un model global din [Capitolul 12](#) este antrenat pe seriile unui singur set de date
 - ▶ un foundation model este antrenat pe multe seturi de date, frecvențe și domenii

Structuri comune între serii

- ▣ Formele se repetă între domenii: profiluri sezoniere, tendințe amortizate, salturi de nivel, volatility clustering, intermitență
 - ▶ după scalare, o curbă de consum și una de trafic web pot arăta la fel: modelul învață o distribuție a priori asupra formelor
- ▣ Elemente care nu se transferă: economia unei serii anume (o modificare de taxe, o regulă de politică, un calendar al sărbătorilor)
 - ▶ decât dacă este transmisă ca o covariabilă în context (Chronos-2) sau învățată prin fine-tuning
- ▣ O rezervă de tip „no free lunch”: în medie pe toate procesele niciun prognozator nu câștigă; preantrenarea ajută doar dacă seria-țintă seamănă cu corpusul
 - ▶ randamentele financiare sînt aproape de o diferență de martingală: puțină structură transferabilă și un risc mare de supraajustare

Datele de preantrenare: volum și compoziție

- ▣ Chronos [Ansari et al. \(2024\)](#)
 - ▶ seturi de date publice plus două augmentări
 - ▶ **TSMixup**: combinații convexe de serii reale; **KernelSynth**: serii extrase din procese gaussiene cu nuclee compuse aleatoare
- ▣ TimesFM [Das et al. \(2024\)](#); Moirai [Woo et al. \(2024\)](#)
 - ▶ TimesFM: aproximativ 10^{11} momente de timp: Google Trends, accesări Wikipedia, serii sintetice și publice
 - ▶ Moirai: LOTSA, peste 27 de miliarde de observații din nouă domenii
- ▣ Toto [Cohen et al. \(2025\)](#); GIFT-Eval [Aksu et al. \(2024\)](#)
 - ▶ Toto: metrice de observabilitate ale unui furnizor cloud, un corpus de 4–10 ori mai mare decât al modelelor anterioare
 - ▶ GIFT-Eval: un set de preantrenare **fără leakage** de circa 230 de miliarde de puncte
- ▣ Pentru noi compoziția contează mai mult decât volumul: seriile economice și financiare sînt o parte mică, de frecvență joasă, a oricărui corpus

Tokenizarea: de la valori reale la un vocabular (1/2)

- ▣ Chronos [Ansari et al. \(2024\)](#), pasul 1, **scalarea prin medie**: fiecare valoare din context se împarte la media valorilor absolute din context


$$\tilde{x}_t = x_t / s, \quad s = \frac{1}{C} \sum_{t=1}^C |x_t|$$

- ▶ $x_1, \dots, x_C$: valorile din context; s : scala, calculată doar pe context; $\tilde{x}_t$: valoarea scalată, în medie apropiată de 1 în valoare absolută
- ▣ Pasul 2, **intervale egale**: intervalul $[-15, 15]$ este acoperit de intervale egale, câte un token pentru fiecare; împreună cu token-urile speciale, vocabularul are 4096 de token-uri
 - ▶ fiecare valoare scalată este înlocuită cu token-ul intervalului care o conține
- ▣ Pasul 3: un model de limbaj (T5) antrenat cu **entropia încrucișată** prezice token-ul următor
 - ▶ prognoza este o distribuție categorială pe intervale, eșantionată autoregresiv (câte un token o dată)
 - ▶ nu există o noțiune de distanță între token-uri: intervalele vecine sînt la fel de diferite ca cele îndepărtate, dacă datele nu arată altceva

Tokenizarea: de la valori reale la un vocabular (2/2)

- **Rezoluția:** centrele a două intervale vecine sînt la distanța $30/4092$ pe axa scalată, adică $30s/4092$ în unitățile seriei
 - ▶ $30 = 15 - (-15)$ este lungimea domeniului acoperit; eroarea de cuantizare este cel mult jumătate din această distanță
- **Domeniu limitat:** o valoare peste $15s$ (sau sub $-15s$) nu are token și nu poate fi prognozată
- **Invarianța la scală:** înmulțirea seriei cu $c > 0$ înmulțește s cu c și lasă token-urile neschimbate
- Alte reprezentări ale intrării
 - ▶ LLMTime [Gruver et al. \(2023\)](#): cifrele fiecărei valori, ca token-uri de text
 - ▶ Lag-Llama [Rasul et al. \(2023\)](#): valorile cu lag ca variabile
 - ▶ modelele cu patch-uri: fără vocabular (slide-urile următoare)

Tokenizatorul Chronos pe date reale



- Stînga: închiderile BET, 27 august 2024 – 18 septembrie 2026 ($C = 512$), și o cuantizare cu 64 de intervale (ilustrare); dreapta: un context în jurul valorii 1, urmat de o creștere pînă la un nivel de 25 de ori mai mare

Interpretarea tokenizatorului

- BET: $s = 23\,072$ puncte, lăţimea intervalului 169,1 puncte, eroarea maximă de cuantizare 84,5 puncte: neglijabilă pentru preţuri, dar o pondere fixă din nivel
- Panoul din dreapta: scala este fixată de context, deci traiectoria care urcă peste 15s este trunchiată: 42% dintre paşii viitori nu pot fi atinşi, ultimul are o eroare de 40%
- Seriile explozive (bule, [Capitolul 16](#); hiperinflaţie) sînt în afara suportului unui vocabular scalat prin medie; Chronos-2 îl înlocuieşte cu o transformare arcsinh şi ieşiri sub formă de cuantile

Patching și stratul de ieșire

- ▣ **Patching** Nie et al. (2023): contextul se împarte în patch-uri de P valori consecutive, iar fiecare patch devine un token de intrare
 - ▶ P : lungimea unui patch; un context de C valori dă C/P token-uri
 - ▶ atenția compară fiecare pereche de token-uri, deci costul ei crește ca $O((C/P)^2)$ în loc de $O(C^2)$; $O(\cdot)$: ordinul de mărime
 - ▶ TimesFM Das et al. (2024): patch-uri de intrare de 32, de ieșire de 128 (mai puțini pași autoregresivi); Chronos-Bolt și Chronos-2: patch-uri de 16; Moirai Woo et al. (2024): mai multe mărimi, după frecvență
- ▣ Straturi de ieșire
 - ▶ distribuție categorială pe intervale (Chronos)
 - ▶ **strat de cuantile** antrenat cu pierderea pinball (Chronos-Bolt: 10%–90%; Chronos-2: 1%–99%; TimesFM 2.5, TiRex: decile)
 - ▶ parametric: Student- t (Lag-Llama Rasul et al. (2023)), un amestec de distribuții (Moirai)
- ▣ **Cuantile directe pe mai mulți pași**: o singură trecere dă cuantilele pentru toți cei H pași
 - ▶ erorile nu se acumulează de la un pas la altul
 - ▶ dar ieșirea este distribuția marginală a fiecărui pas, nu distribuția lor comună: o funcțională de traiectorie (un maxim, o sumă pe orizont) nu se poate citi din ea


Legi de scalare

- ▣ Modelele de limbaj [Kaplan et al. \(2020\)](#), [Hoffmann et al. \(2022\)](#): pierderea pe datele de test scade ca o lege de putere în mărimea modelului și, la fel, în volumul datelor și în calcul, pe mai multe ordine de mărime

$$L(N) \approx (N_c/N)^{\alpha_N}$$

- ▶ $L(N)$: pierderea pe datele de test a unui model cu N parametri; N_c : o constantă de scală estimată; $\alpha_N > 0$: exponentul estimat
- ▶ interpretare: dublarea lui N înmulțește pierderea cu $2^{-\alpha_N}$; pe un grafic log-log relația este o dreaptă cu panta $-\alpha_N$
- ▣ Serii de timp: Transformers de tip decoder-only arată aceleași legi de putere în parametri, date și calcul [Edwards et al. \(2024\)](#); lungimea contextului interacționează cu volumul datelor [Shi et al. \(2024\)](#)
 - ▶ în afara distribuției: log-verosimilitatea se scalează asemănător în și în afara distribuției, dar arhitectura contează; ajustările care ajută în distribuție pot reduce scalabilitatea OOD [Yao et al. \(2025\)](#)
- ▣ O lege de scalare privește pierderea medie pe distribuția corpusului
 - ▶ ea nu spune nimic despre o serie românească anume
 - ▶ modele mici (TiRex, 35 de milioane de parametri) le întrec pe cele mari în clasamentele publice [Auer et al. \(2025\)](#)

Mărimea și acuratețea pe cele trei sarcini ale noastre



- Pierderi relative la modelul de referință al fiecărei sarcini: consumul României (MAE / ARX expert, 2025–2026), inflația UE (MAE / mers aleator, $h = 12$, medie geometrică pe 27 de țări), log RV Bitcoin (MSE / HAR)
- Parametrii sînt numărați în modelele încărcate; o valoare sub 1 înseamnă că modelul întrece modelul de referință

Interpretarea relației dintre mărime și acuratețe

- ▣ Familia Chronos-Bolt (9–205 M parametri): consum 1,143 → 1,034, inflație 1,086 → 1,034, Bitcoin 0,800 → 0,690
- ▣ Între familii, mărimea nu determină clasamentul: Chronos-2 (119 M) 0,951 la consum; TiRex (35 M) 1,078; TimesFM 2.5 (231 M) 1,121
- ▣ În familia Chronos-Bolt pierderea scade odată cu mărimea pe toate cele trei sarcini (o excepție: mini la inflație)
 - ▶ între familii, arhitectura, corpusul și procedura de antrenare se schimbă simultan
 - ▶ deci trei sarcini nu constituie un studiu de scalare

Recapitulare: preantrenarea

- Preantrenarea amortizează estimarea pe un corpus; folosirea zero-shot rulează estimatorul într-o singură trecere înainte
- Scalarea prin medie și intervalele dau invarianță la scală, dar un domeniu limitat; patching și straturile de cuantile le înlocuiesc cu cuantile directe pe mai mulți pași
- Legile de scalare sînt valabile în medie pe corpusuri; pe o serie economică dată, proiectarea și datele contează mai mult decît mărimea

Principalele modele deschise

Modelul	Arhitectura	Parametri	Ieșirea
Chronos Ansari et al. (2024)	T5 encoder–decoder pe token-uri	20–710 M	categorială, traiectorii eșantionate
Chronos-Bolt	T5 pe patch-uri de 16	9–205 M	9 cuantile, 10%–90%, 64 de pași
Chronos-2 Ansari et al. (2025)	encoder cu atenție de grup	119 M	21 de cuantile, 1%–99%; covariabile
TimesFM 2.5 Das et al. (2024)	decoder-only, patch-uri	231 M	media și decilele
Moirai Woo et al. (2024)	encoder mascat, atenție pe orice număr de variabile	14–311 M	amestec de distribuții
Lag-Llama Rasul et al. (2023)	decoder-only pe valori cu lag	mic	Student- t
MOMENT Goswami et al. (2024)	encoder T5 mascat, multi-sarcină	40–385 M	reconstrucție; straturi pe sarcină
TiRex Auer et al. (2025)	xLSTM	35 M	decile

- Toto [Cohen et al. \(2025\)](#) (151 M, date de observabilitate) și Moirai 2.0 [Liu et al. \(2025\)](#) sînt și ele deschise; TimeGPT [Garza et al. \(2023\)](#) este accesibil doar printr-un API cu plată

Familia Chronos

▣ Chronos Ansari et al. (2024)

- ▶ procedura de antrenare a modelelor de limbaj, nemodificată; prognoze prin eșantionarea traiectoriilor de token-uri
- ▶ rezultate zero-shot comparabile cu cele ale modelelor antrenate pe datele-țintă (Benchmark II din lucrare)

▣ Chronos-Bolt

- ▶ intrări sub formă de patch-uri și un decodor direct de cuantile: mult mai rapid decât Chronos
- ▶ context de până la 2048, 64 de pași; cuantile doar între 10% și 90%
- ▶ un interval de 95% sau un VaR 1% nu se pot citi din ieșirea lui: cererea este trunchiată la cel mai apropiat nivel antrenat

▣ Chronos-2 Ansari et al. (2025)

- ▶ atenția de grup împarte informația între seriile unui grup (variabile, serii înrudite, covariabile)
- ▶ **învățare în context** a efectelor covariabilelor, fără reestimare
- ▶ antrenat în mare parte pe structuri multivariate sintetice impuse unor serii univariate
- ▶ context de 8192; 21 de cuantile de la 1% la 99%; scalare arcsinh

TimesFM, Moirai, Lag-Llama, MOMENT (1/2)

▣ **TimesFM** [Das et al. \(2024\)](#)

- ▶ decoder-only, cu patch-uri; patch-ul de ieșire este mai lung decât cel de intrare
- ▶ antrenat pe multe frecvențe; versiunea 2.5 adaugă un strat de cuantile și contexte lungi

▣ **Moirai** [Woo et al. \(2024\)](#)

- ▶ encoder mascat; mărimi de patch specifice frecvenței
- ▶ atenția pe orice număr de variabile aplatizează intrările multivariate într-o singură secvență
- ▶ ieșire sub formă de amestec: Student- t , log-normală, binomială negativă
- ▶ Moirai 2.0 [Liu et al. \(2025\)](#): o simplificare decoder-only, mai mică și mai bună pe GIFT-Eval

TimesFM, Moirai, Lag-Llama, MOMENT (2/2)

▣ **Lag-Llama** Rasul et al. (2023)

- ▶ un decodor de tip LLaMA ale cărui token-uri sînt vectori de valori cu lag, la multe laguri sezoniere
- ▶ strat de ieșire Student- t ; puternic după fine-tuning

▣ **MOMENT** Goswami et al. (2024)

- ▶ preantrenat prin reconstrucție mascată pe Time series Pile
- ▶ un singur encoder pentru prognoză, clasificare, detectarea anomaliilor și imputare

Din nou recurente, observabilitate și un API închis

▣ **TiRex** Auer et al. (2025)

- ▶ un xLSTM păstrează o stare de-a lungul contextului, ceea ce permite urmărirea stării pe orizonturi lungi
- ▶ xLSTM: celulele recurente din [Capitolul 12](#), cu porți exponențiale și memorie matriceală
- ▶ mascarea patch-urilor contigue (CPM) la antrenare: modelul învață să prognozeze mai mulți pași fără reacție

▣ **Toto** Cohen et al. (2025)

- ▶ decoder-only, pentru metrice multivariate de observabilitate; benchmark-ul BOOM (2807 serii)
- ▶ alcătuirea pe domenii a corpusului determină rezultatele


▣ **TimeGPT** Garza et al. (2023)

- ▶ ponderi închise și un corpus nedezevăluit, în spatele unui API cu plată
- ▶ contaminarea nu poate fi verificată; rezultatele nu sînt reproductibile dacă serviciul schimbă modelul
- ▶ datele ies din instituția dumneavoastră

Zero-shot, fine-tuning, covariabile în context

- ▣ **Zero-shot:** prognoza este $f_{\hat{\theta}}(y_{T-C+1:T})$
 - ▶ fără antrenare, deci fără risc de supraajustare pe seria-țintă; singurele alegeri sînt C și modelul
- ▣ **Fine-tuning:** ponderile pornesc de la $\hat{\theta}$ și fac cîțiva pași de gradient pe datele-țintă
 - ▶ toate ponderile sau adaptoare de rang mic (LoRA) adăugate ponderilor înghețate
 - ▶ cere o împărțire de validare care respectă timpul ([Capitolul 12](#)); poate uita distribuția a priori; pe serii economice scurte rareori merită
- ▣ **Covariabile în context** (Chronos-2)
 - ▶ valorile trecute ale unei covariabile x_t (de exemplu temperatura) și valorile viitoare ale regresorilor cunoscuți dinainte intră în context
 - ▶ modelul deduce efectul lor în timpul trecerii înainte, fără niciun parametru estimat
 - ▶ învățarea încrucișată: prognoza în comun a unui lot de serii înrudite (toate cele 27 de țări UE la aceeași origine)
- ▣ Covariabilele viitoare cunoscute trebuie să fie chiar cunoscute la origine
 - ▶ prognoze meteo, nu vremea realizată, cu excepția cazului în care se urmărește o limită superioară

Patru prognoze zero-shot cu același model



- Chronos-2 de la ultima origine a fiecărui set de date: consumul României (48 de ore), inflația HICP a României (12 luni), logaritmul varianței realizate Bitcoin și randamentele zilnice BET (22 de zile); benzi 10–90% și 1–99%

Interpretarea celor patru prognoze

- ▣ Consumul: profilurile zilnice și săptămânale sînt continuate cu benzi înguste: cazul cel mai favorabil pentru transferul de formă
- ▣ Inflația: o traiectorie netedă spre nivelul recent, cu benzi care se lărgesc cu orizontul: aproape de ce ar da un model AR persistent
- ▣ Log RV pentru Bitcoin: un tipar săptămînal (varianță mai mică la sfîrșit de săptămîină) în jurul unui nivel stabilit de context
- ▣ Randamentele: o mediană constantă și o bandă simetrică, adică o distribuție necondiționată
- ▣ Benzile randamentelor din cuantilele de 1% și 99%: VaR 1% Chronos-2 pentru ziua următoare este 3,90 (% din valoare); secțiunea 8 verifică dacă astfel de cifre sînt calibrate

Recapitulare: familiile de modele

- ▣ Familiile diferă prin intrare (token-uri, patch-uri, laguri), arhitectură (encoder, decoder, recurentă) și ieșire (categorială, cuantile, parametrică)
- ▣ Domeniul cuantilelor este o constrângere de proiectare: doar decile, cu excepția Chronos-2
- ▣ Zero-shot este varianta implicită; covariabilele în context și învățarea încrucișată sînt noile pîrghii; API-urile închise nu pot fi verificate

Benchmark-uri pentru modelele preantrenate

- ▣ **GIFT-Eval** Aksu et al. (2024): 23 de seturi de date, peste 144 000 de serii, 177 de milioane de puncte, șapte domenii, zece frecvențe, orizonturi scurte și lungi; un set de preantrenare fără leakage
- ▣ **fev-bench** Shchur et al. (2025): 100 de sarcini în șapte domenii, 46 cu covariabile; rate de câștig și scoruri de abilitate cu intervale de încredere bootstrap
- ▣ **Benchmark-uri live**: prognoze înregistrate înainte să existe rezultatele, de exemplu TS-Arena Meyer et al. (2025) și Impermanent Garza et al. (2026): singurul design imun la contaminare prin construcție
- ▣ Repere clasice pentru ce cere o comparație corectă: M5 Makridakis, Spiliotis și Assimakopoulos (2022); capcanele catalogate de Hewamalage, Ackermann și Bergmeir (2023)

Agregarea scorurilor pe mai multe serii (1/2)

- ▣ **MASE** Hyndman și Koehler (2006): eroarea absolută medie a prognozei împărțită la eroarea absolută medie, în eșantion, a prognozei naive sezoniere

$$\text{MASE} = \frac{\frac{1}{H} \sum_{h=1}^H |y_{T+h} - \hat{y}_{T+h}|}{\frac{1}{T-m} \sum_{t=m+1}^T |y_t - y_{t-m}|}$$

- ▶ $\hat{y}_{T+h}$: prognoza la h pași după originea T ; m : perioada sezonieră (1 fără sezonabilitate)
- ▶ $\text{MASE} < 1$: mai bun decât prognoza naivă în eșantion; nu depinde de unitățile lui y
- ▣ **WQL** (pierdere cuantică ponderată): pierderile pinball ale cuantilelor prognozate, însumate și împărțite la nivelul absolut total al seriei

$$\text{WQL} = \frac{2 \sum_t \sum_{\tau} \rho_{\tau}(y_t - \hat{q}_{\tau,t})}{\sum_t |y_t|}, \quad \rho_{\tau}(u) = u(\tau - 1\{u < 0\})$$

- ▶ $\hat{q}_{\tau,t}$: cuantila prognozată de nivel $\tau \in (0, 1)$ pentru perioada t ; $1\{\cdot\}$: 1 dacă condiția este îndeplinită, 0 altfel
- ▶ ρ_{τ} : pierdere pinball; media ei pe τ aproximează CRPS ([Capitolul 1](#)); $\text{WQL} = 0$ doar pentru cuantile perfecte

Agregarea scorurilor pe mai multe serii (2/2)

- ▣ **Scorul relativ** al seriei s : pierderea modelului împărțită la pierderea unui model de referință pe aceeași serie

$$r_s = \frac{L_s(\text{model})}{L_s(\text{baseline})}, \quad \bar{r}_{\text{geo}} = \left(\prod_{s=1}^S r_s \right)^{1/S}$$

- ▶ L_s : o pierdere (MAE, MASE, WQL) pe seria s ; S : numărul de serii; $r_s < 1$: modelul întrece modelul de referință pe seria s
- ▣ **Media geometrică** $\bar{r}_{\text{geo}}$ [Fleming și Wallace \(1986\)](#): clasamentele nu depind de alegerea modelului de referință, iar un câștig și o pierdere de același raport se compensează
 - ▶ **scorul de abilitate** (skill score) $1 - \bar{r}_{\text{geo}}$: câștigul proporțional mediu față de modelul de referință (0: niciun câștig)
 - ▶ **rata de câștig** (win rate): ponderea seriilor pe care un model îl întrece pe altul
- ▣ Două agregări de evitat
 - ▶ media aritmetică a rapoartelor: dominată de seriile pe care modelul de referință este slab
 - ▶ media erorilor brute: dominată de seria cu scala cea mai mare

Leakage și contaminare

▣ Leakage-ul seriilor

- ▶ o serie de evaluare (sau o copie apropiată) se află în corpul de preantrenare
- ▶ Chronos separă din acest motiv rezultatele în domeniu (Benchmark I) de cele zero-shot (Benchmark II) [Ansari et al. \(2024\)](#)

▣ Contaminarea temporală

- ▶ fereastra de test precede data-limită a antrenării: modelul poate să fi văzut rezultatele altor serii, corelate, din aceeași perioadă
- ▶ LLM-urile reproduc valori economice exacte din perioada dinaintea datei-limită [Lopez-Lira, Tang și Zhu \(2025\)](#)
- ▶ un design cu două seturi de date împotriva contaminării, pentru prețurile electricității [Pan și Ezzat \(2026\)](#)

▣ Designuri care ajută

- ▶ evaluați doar după lansarea (sau data-limită declarată) a fiecărui model din comparație; folosim 1 noiembrie 2025, după ultimul dintre modelele noastre (Chronos-2, 30 octombrie 2025)
- ▶ comparați abilitatea relativă înainte și după: o scădere mare după lansare este un semnal de alarmă
- ▶ preînregistrați originile, orizonturile, metricile și modelele de referință înainte de a vedea rezultatele

Testarea pe multe serii (1/2)

- ▣ O serie (toate în Capitolul 1)
 - ▶ DM cu corecția HLN Diebold și Mariano (1995), Harvey, Leybourne și Newbold (1997); capacitatea condiționată Giacomini și White (2006)
 - ▶ multe modele: MCS Hansen, Lunde și Nason (2011)
- ▣ S serii testate separat, fiecare la nivelul de 5%: sub ipoteza nulă se așteaptă aproximativ $0,05S$ respingeri false
 - ▶ cu $S = 27$ de țări, aproximativ una sau două țări „semnificative” doar din întâmplare
- ▣ Două rate de eroare pentru o familie de teste
 - ▶ **FWER** (family-wise error rate): probabilitatea a cel puțin unei respingeri false
 - ▶ **FDR** (false discovery rate): proporția așteptată a respingerilor false printre toate respingerile
- ▣ Notățiile: $p_{(1)} \leq \dots \leq p_{(S)}$ sînt cele S p-value-uri ordonate crescător; α : nivelul-țintă al familiei (de exemplu 5%)

Testarea pe multe serii (2/2)

- ▣ **Holm Holm (1979)**, controlează FWER: se parcurge lista ordonată și se respinge cât timp

$$p_{(k)} \leq \frac{\alpha}{S - k + 1}, \quad k = 1, 2, \dots$$

- ▶ cel mai mic p-value este comparat cu pragul Bonferroni α/S , următoarele cu praguri treptat mai permissive; se oprește la primul eșec

- ▣ **Benjamini–Hochberg Benjamini și Hochberg (1995)**, controlează FDR: se resping cele mai mici k^* p-value-uri, unde

$$k^* = \max\{k : p_{(k)} \leq k\alpha/S\}$$

- ▶ mai multe respingeri decât Holm; valid sub independență sau dependență pozitivă între teste

- ▣ **Test agregat**: se mediază diferența de pierdere pe serii la fiecare origine, apoi se aplică un singur test DM cu varianță HAC

- ▶ corelația dintre serii rămîne în seria de timp mediată, deci varianța HAC o ia în calcul

- ▣ Ranguri pe multe seturi de date: testele Friedman și Nemenyi **Demšar (2006)**; ele ignoră mărimea diferențelor și presupun seturi de date independente



Recapitulare: benchmark-urile și testarea

- ▣ Agregați scoruri relative fără scală prin medii geometrice și raportați incertitudinea pe serii
- ▣ Contaminarea este o proprietate a perechii (model, fereastră de test): evaluați după lansare sau live
- ▣ Multe serii înseamnă multe teste: corecții cu Holm sau BH sau agregați înainte de testare

Designul comparațiilor noastre

- ▣ **Consumul României:** pentru ziua următoare, 24 de ore, în fiecare zi de la 1 ianuarie 2025 la 30 septembrie 2026 (638 de zile); context de 2048 de ore pentru foundation models
 - ▶ modele de referință: naiv săptămînal; modelul ARX expert al lui Ziel și Weron (2018) pentru fiecare oră (Capitolul 1); DLinear Zeng et al. (2023) și N-BEATS Oreshkin et al. (2020) antrenate global (Capitolul 12)
- ▣ **Inflația UE:** 27 de țări, origini lunare mobile ianuarie 2012 – august 2025, $h = 1, \dots, 12$; mers aleator, $AR(p)$ după AIC, ETS amortizat Hyndman et al. (2002), DLinear și N-BEATS antrenate pe panel
- ▣ **Varianța realizată:** o zi înainte, log RV; HAR Corsi (2009) pe o fereastră mobilă de 1000 de zile; QLIKE Patton (2011)
- ▣ Foundation models: Chronos-Bolt small, Chronos-2, TimesFM 2.5, TiRex, zero-shot, pe un CPU; Moirai și Lag-Llama nu au fost rulate (bibliotecile lor cer versiuni software mai vechi)

Consumul României: acuratețea pentru ziua următoare



- Stînga: MAE (GW) pe 24 de ore și 638 de zile, modelele din MCS de 10% marcate; dreapta: ultima săptămînă din eșantion, ARX expert și Chronos-2 cu banda lui de 80%

Interpretarea comparației pentru consum

- MAE: Chronos-2 0,210, ARX expert 0,221, TiRex 0,238, Chronos-Bolt 0,239, TimesFM 0,248; DLinear 0,311, N-BEATS 0,325, naiv săptămînal 0,417 GW
- DM față de ARX expert: Chronos-2 $t = -3,05$ ($p = 0,002$); celelalte trei foundation models sînt semnificativ mai slabe; MCS de 10% este {Chronos-2}
- Acoperirea intervalului de 80%: Chronos-2 75,5%, Chronos-Bolt 81,2%, TimesFM 81,2%, ARX expert 78,1%: niciunul nu este departe, niciunul nu este exact
- Un model univariat zero-shot egalează un model de domeniu consacrat pe o serie cu forme puternice și regulate; modelele deep globale antrenate pe trei ani pierd în fața ambelor

Covariabile în context: calendarul și temperatura




- MAE Chronos-2 pe toate zilele, pe zilele obișnuite și pe cele 29 de zile de sărbătoare legală: univariat, cu indicatori de weekend și de sărbătoare și cu indicatori plus temperatura orară la București (valorile realizate pentru ziua prognozată: o limită superioară)

Interpretarea experimentului cu covariabile

- ▣ Sărbători: MAE 0,527 univariat, 0,396 cu calendarul, 0,365 cu temperatura; zile obișnuite: 0,195; 0,193; 0,178
- ▣ Calendarul față de varianta univariată: DM $t = -2,79$ ($p = 0,005$); temperatura în plus: $t = -7,02$ ($p < 0,001$)
- ▣ Efectul sărbătorilor este învățat în context din câteva sărbători anterioare aflate în fereastra de 2048 de ore; niciun parametru nu a fost estimat
- ▣ Temperatura realizată nu este disponibilă la origine: un test operațional cere prognoze meteo arhivate

Inflația UE: 27 de țări, 12 orizonturi




□ Stînga: MAE relativ la mersul aleator pe orizonturi, medie geometrică pe țări; dreapta: $h = 12$ cu intervale bootstrap de 95% pe țări; origini ianuarie 2012 – august 2025

Interpretarea panelului de inflație

- ▣ $h = 1$: AR 0,999, Chronos-2 0,976, TimesFM 0,956, TiRex 0,956; $h = 12$: AR 1,050, ETS 1,036, Chronos-2 0,933, TimesFM 0,932, TiRex 0,936, Bolt 1,054
- ▣ Modelele deep globale la $h = 12$: DLinear 0,959, N-BEATS 0,999; Chronos-2 cu învățare încrucișată pe cele 27 de țări: 0,845
- ▣ CRPS relativ la AR (medie geometrică pe țări): Chronos-2 0,860, TimesFM 0,875, TiRex 0,865, ETS 0,972
- ▣ Creșterea din 2021–2023 domină orice medie: nicio metodă univariată nu a anticipat-o, deci diferențele țin de viteza de adaptare, nu de anticipare

România: prognoze din trei origini




- Inflația anuală HICP a României și prognoze pe 12 luni cu benzi de 80% din Chronos-2 și AR(p), de la iunie 2021, noiembrie 2022 și august 2025

Interpretarea traiectoriilor pentru România

- ▣ De la iunie 2021: după 12 luni inflația a fost 13,0%; mediana Chronos-2 3,8% (80%: 1,5 – 6,6), AR 3,7%
- ▣ De la noiembrie 2022, aproape de vîrf (14,6% în noiembrie 2022): rezultat 6,9%; Chronos-2 16,5%, AR 13,7%
- ▣ De la august 2025: rezultat 6,3%; Chronos-2 11,4%, AR 9,0%; ultima observație este 6,3% (august 2026)
- ▣ Ambele metode extrapolează persistența; punctele de întoarcere vin din informații din afara seriei
 - ▶ prețurile energiei, sfîrșitul plafonării prețurilor, majorarea TVA din august 2025 (efectul ei asupra inflației anuale durează exact 12 luni)
 - ▶ acestea sînt cunoscute dinainte, deci sînt covariabile naturale

Douăzeci și șapte de teste deodată




- Statisticile DM-HLN pe țări (HAC cu $h - 1$ laguri) ale erorilor absolute Chronos-2 minus $AR(p)$ la $h = 12$; negativ: Chronos-2 este mai bun

Interpretarea testelor multiple

- ▣ 23 din 27 de statistici sînt negative; 2 sînt semnificative la 5% fără corecție (1 în favoarea Chronos-2, 1 în favoarea AR)
- ▣ Cu Holm: 0 respingeri; cu Benjamini–Hochberg: 0; România: $t = 2,88$, $p = 0,005$
- ▣ Agregat pe cele 27 de țări (diferența medie de pierdere la fiecare origine, varianță HAC): $t = -1,35$, $p = 0,180$
 - intervalele bootstrap din graficul anterior tratează țările ca independente și par mai precise decît sînt
- ▣ O lucrare care raportează țările în care modelul ei cîștigă la 5% raportează zgomot; testul agregat și numerele ajustate pentru multiplicitate sînt rezumatul onest

Varianța realizată: foundation models față de HAR





- Log RV pentru ziua următoare: MSE și QLIKE relativ la HAR; Bitcoin (Binance, 1 ianuarie 2021 – 18 septembrie 2026, $n = 2\,084$), S&P 500 (Oxford-Man, 4 ianuarie 2010 – 25 februarie 2022, $n = 3\,047$)

Interpretarea comparației pentru volatilitate

- ▣ Bitcoin, QLIKE relativ la HAR: Chronos-2 0,825, TimesFM 0,800, TiRex 0,824, Bolt 0,864; MCS (10%): {Chronos-2, TimesFM 2.5, TiRex}
- ▣ S&P 500: Chronos-2 0,963, TimesFM 0,968, TiRex 0,956, Bolt 1,004; MCS (10%): {Chronos-2, TimesFM 2.5, TiRex}
- ▣ Trei dintre cele patru modele zero-shot întrec HAR pe ambele active, iar HAR nu intră în niciun MCS
 - ▶ memoria lentă a lui log RV ([Capitolul 10](#)) este o structură pe care modelul o poate învăța din corpus
 - ▶ câștigul este mare pentru Bitcoin și mic pentru S&P 500
- ▣ Studii recente ajung la verdicte mixte [Goel et al. \(2025\)](#), [Brini \(2026\)](#), [Rahimikia, Ni și Wang \(2025\)](#)
 - ▶ câștigurile depind de activ, de orizont și de funcția de pierdere; fine-tuning-ul sau preantrenarea pe date financiare contează adesea

Înainte și după lansări



- Pierdere relativă a fiecărui model într-o fereastră anterioară și în fereastra de după toate lansările (din 1 noiembrie 2025): consum (MAE / ARX expert) și Bitcoin (QLIKE / HAR)

Interpretarea verificării contaminării

- ▣ Consum, Chronos-2: 0,952 înainte, 0,950 după; TimesFM: 1,133; 1,112; fereastra anterioară (ianuarie–octombrie 2025) precede ambele lansări
- ▣ Bitcoin, Chronos-2: 0,886 (2021 – 24 noiembrie 2024) și 0,631 (după); TiRex: 0,874; 0,658; ferestrele de după lansare au 334 și 322 de zile
- ▣ Nicio deteriorare după lansări (pentru Bitcoin rapoartele sînt chiar mai mici): nicio dovadă de contaminare aici
 - ▶ dar absența unei scăderi nu dovedește absența leakage-ului, iar piețele se schimbă între ferestre

Recapitulare: dovezile

- ▣ Forme puternice (consum): cel mai bun foundation model egalează sau întrece modelul de domeniu; forme slabe (randamente): puțin de transferat
- ▣ Inflația: înaintea modelelor AR și ETS în media panelului (cel mai mult cu învățarea încrucișată), dar nicio diferență pe țară nu rezistă corecțiilor Holm sau BH, iar testul agregat nu este semnificativ
- ▣ Varianța realizată: modelele zero-shot întrec HAR, clar pentru Bitcoin, la limită pentru S&P 500
- ▣ Covariabilele în context ajută acolo unde calendarul contează; ferestrele de după lansare nu arată semne de contaminare

LLMTime: numerele ca text

- ▣ Gruver et al. (2023): se rescalează, se rotunjește la un număr fix de cifre, valorile se scriu ca cifre separate prin spații și virgule; un LLM obișnuit continuă șirul
 - ▶ probabilitățile cifră cu cifră definesc o densitate ierarhică (pe mai multe intervale) pentru valori continue; eșantionarea repetată dă cuantile
- ▣ Rezultatele lucrării
 - ▶ competitiv zero-shot pe unele benchmark-uri
 - ▶ tokenizarea numerelor contează: un model mai nou putea fi mai slab din cauza felului în care împarte cifrele
 - ▶ alinierea (RLHF) deteriorează calibrarea
- ▣ Costuri: mii de token-uri pe serie și multe eșantioane pentru o prognoză; fereastra de context limitează istoria; LLM-ul poate să fi memorat datele

Reprogramarea unui LLM înghețat

▣ **Time-LLM** Jin et al. (2024)

- ▶ patch-urile seriei sînt proiectate pe prototipuri de text (embedding-uri de cuvinte)
- ▶ un prefix de prompt descrie sarcina și statisticile seriei
- ▶ LLM-ul rămîne înghețat; o proiecție antrenată citește prognoza

▣ **One Fits All** (GPT4TS) Zhou et al. (2023)

- ▶ un GPT-2 înghețat; se antrenează doar embedding-ul de intrare, normalizările de strat și stratul de ieșire
- ▶ un singur model pentru prognoză, clasificare și detectarea anomaliilor

▣ Afirmația: cunoașterea din limbaj se transferă la serii

- ▶ testul afirmației este o ablație care elimină modelul de limbaj

Studiu de caz: sînt modelele de limbaj chiar utile?

- ▣ Tan et al. (2024): trei prognozatori pe bază de LLM (inclusiv Time-LLM și GPT4TS), aceleași benchmark-uri, trei ablații
- ▣ Ablațiile
 - ▶ eliminarea LLM-ului; înlocuirea lui cu un strat de atenție; înlocuirea cu un bloc Transformer simplu
- ▣ Rezultat: nicio degradare, adesea o îmbunătățire
 - ▶ LLM-urile preantrenate nu sînt mai bune decît același model antrenat de la zero
 - ▶ nu modelează dependența secvențială și nu ajută cînd datele sînt puține
- ▣ Antrenarea și inferența costă cu ordine de mărime mai mult
- ▣ Metoda contează mai mult decît rezultatul
 - ▶ o afirmație despre arhitectură cere o ablație cu calcul și ajustare comparabile
- ▣ Ce vizează critica
 - ▶ LLM-urile folosite ca prognozatori sînt vizate
 - ▶ foundation models antrenate pe serii (Chronos, TimesFM, TiRex) nu sînt vizate
 - ▶ LLM-urile rămîn utile în jurul prognozei: cod, literatură, critică (secțiunea 9)

Memorare și anticiparea viitorului

- ▣ LLM-urile își amintesc perioada de antrenare [Lopez-Lira, Tang și Zhu \(2025\)](#)
 - ▶ reproduc cu mare precizie valori macroeconomice și de piață din acea perioadă, chiar și când li se cere să nu folosească informații viitoare
 - ▶ un backtest înainte de data-limită a antrenării măsoară memoria, nu capacitatea de prognoză
- ▣ Aceeași logică pentru foundation models pe serii de timp
 - ▶ ea se aplică seriilor publice din corpus (electricitate, trafic, M4)
 - ▶ dovezile noastre: ferestre de după toate lansările (secțiunea 4)
 - ▶ cele mai puternice dovezi: prognoze live, preînregistrate
- ▣ O regulă practică
 - ▶ precizați data-limită de antrenare a fiecărui model și începutul ferestrei de evaluare în același tabel

Recapitulare: LLM

- ▣ LLMTime și reprogramarea arată că modelele de text pot fi adaptate la serii; ablațiile arată că partea de limbaj rareori este cea care ajută
- ▣ Memorarea face ca evaluarea prognozelor LLM înainte de data-limită să nu fie validă
- ▣ Pentru prognoză, foundation models antrenate pe serii sînt alegerea implicită; LLM-urile rămîn utile pentru cod, literatură și critică

Originea predicției conformale



Alexander Gammerman, Royal Holloway, 2018

Foto: Jaguar224 (2018); CC BY-SA 4.0; Wikimedia Commons

- Vovk, Gammerman și Shafer (2005); Vovk, Gammerman și Shafer (2022)
 - ▶ mulțimi de predicție valide în eșantioane finite
 - ▶ se presupune doar interschimbabilitatea, pentru orice model predictiv
- Ideea
 - ▶ cât de „conformă” este o valoare candidat cu datele văzute, măsurat printr-un rang
- Statistica modernă Lei et al. (2018); Angelopoulos și Bates (2023)
 - ▶ a adoptat-o ca înveliș în jurul metodelor de machine learning

Interschimbabilitatea și garanția urmărită (1/2)

- Datele: n puncte de calibrare și un punct de test, $Z_i = (X_i, Y_i)$, $i = 1, \dots, n+1$
 - ▶ X_i : predictorii (variabile, laguri, o prognoză de model); Y_i : valoarea care trebuie acoperită; Z_{n+1} : punctul de test, al cărui Y_{n+1} este necunoscut
- **Interschimbabilitatea**: orice reordonare a punctelor are aceeași distribuție comună

$$(Z_{\pi(1)}, \dots, Z_{\pi(n+1)}) \stackrel{d}{=} (Z_1, \dots, Z_{n+1}) \quad \text{pentru orice permutare } \pi$$

- ▶ π : o permutare (reordonare) a mulțimii $\{1, \dots, n+1\}$; $\stackrel{d}{=}$: egalitate în distribuție
- Exemple
 - ▶ datele i.i.d. sînt interschimbabile
 - ▶ extragerile fără întoarcere sînt interschimbabile, dar dependente
 - ▶ un AR(1) staționar $y_t = \phi y_{t-1} + \varepsilon_t$, $0 < |\phi| < 1$, nu este: $\text{corr}(y_1, y_2) = \phi \neq \phi^2 = \text{corr}(y_1, y_3)$, deci schimbarea între ele a lui y_2 și y_3 modifică legea comună

Interschimbabilitatea și garanția urmărită (2/2)

- ▣ **Acoperirea marginală:** mulțimea de predicție conține valoarea de test cu probabilitatea de cel puțin $1 - \alpha$

$$\Pr\{Y_{n+1} \in \hat{C}(X_{n+1})\} \geq 1 - \alpha$$

- ▶ $\hat{C}(x)$: mulțimea de predicție (de obicei un interval) construită din datele de calibrare; α : rata de ratare admisă, de exemplu 0,1 pentru un interval de 90%
- ▶ probabilitatea este luată împreună pe datele de calibrare și pe punctul de test

- ▣ Ce nu garantează

- ▶ acoperirea **condiționată**, $\Pr\{Y \in \hat{C}(x) \mid X = x\} \geq 1 - \alpha$ pentru orice valoare x
- ▶ acoperirea condiționată de un anumit eșantion de calibrare

- ▣ Un **scor de neconformitate** $s(x, y)$: un număr care este mare când y este neobișnuit dat fiind x

- ▶ exemple: $|y - \hat{\mu}(x)|$, $|y - \hat{\mu}(x)|/\hat{\sigma}(x)$ sau scorul CQR de mai jos
- ▶ $\hat{\mu}(x)$: o prognoză punctuală a lui y dat fiind x ; $\hat{\sigma}(x)$: o prognoză a dispersiei (de exemplu o volatilitate GARCH)

Predicția split conformal (1/2)

- ▣ Pasul 1: se estimează un model de prognoză $\hat{\mu}$ pe un set de antrenare [Papadopoulos et al. \(2002\)](#), [Lei et al. \(2018\)](#)

- ▣ Pasul 2: se calculează scorurile celor n puncte de calibrare, nefolosite la pasul 1

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

- ▣ Pasul 3: pragul $\hat{q}$ este al k -lea cel mai mic scor de calibrare

$$\hat{q} = S_{(k)}, \quad k = \lceil (n+1)(1-\alpha) \rceil$$

- ▶ $S_{(k)}$: statistica de ordine k a scorurilor $S_1, \dots, S_n$; $\lceil \cdot \rceil$: rotunjirea în sus la un întreg; $\hat{q} = +\infty$ dacă $k > n$
- ▶ exemplu: $n = 99$, $\alpha = 0,1$ dă $k = 90$, al 90-lea cel mai mic dintre cele 99 de scoruri

- ▣ Pasul 4: mulțimea de predicție păstrează orice valoare candidată al cărei scor nu depășește pragul

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\}$$

- ▶ cu $s(x, y) = |y - \hat{\mu}(x)|$: intervalul $\hat{\mu}(x) \pm \hat{q}$


Predicția split conformal (2/2)

- ▣ **Teoremă:** dacă punctele (X_i, Y_i) , $i = 1, \dots, n+1$, sînt interschimbabile, atunci

$$1 - \alpha \leq \Pr\{Y_{n+1} \in \hat{C}(X_{n+1})\} \leq 1 - \alpha + \frac{1}{n+1}$$

- ▶ marginea superioară cere ca scorurile să nu aibă egalități (scoruri continue)
- ▣ Ideea demonstrației (▶ Anexă)
 - ▶ dat fiind $\hat{\mu}$, scorurile $S_1, \dots, S_{n+1}$ sînt interschimbabile, deci rangul lui S_{n+1} printre ele este uniform pe $\{1, \dots, n+1\}$
 - ▶ $Y_{n+1} \in \hat{C}(X_{n+1})$ exact atunci cînd acest rang este cel mult k , ceea ce are probabilitatea $k/(n+1) \geq 1 - \alpha$
- ▣ Nicio ipoteză asupra modelului sau a distribuției
 - ▶ un model slab dă intervale largi, nu intervale invalide

Acoperirea condiționată de setul de calibrare



- Acoperirea $F(\hat{q})$ a punctului următor pentru 4000 de seturi de calibrare cu $n = 50$ și cu $n = 500$ de scoruri, $\alpha = 0,1$, și legea exactă $\text{Beta}(k, n + 1 - k)$
- F : funcția de repartiție a scorurilor, deci $F(\hat{q}) = \Pr\{S_{n+1} \leq \hat{q} \mid \text{setul de calibrare}\}$ este acoperirea obținută cu un anumit set de calibrare

Interpretarea distribuției acoperirii

- ▣ Acoperirea medie 0,902 ($n = 50$) și 0,900 ($n = 500$), cum dă teoria (0,902; 0,900): garanția marginală este valabilă în medie pe seturile de calibrare
- ▣ Un set de calibrare este o singură extragere: abaterea standard 0,041 și 0,014; cu $n = 50$, 26% dintre seturi dau acoperire sub 0,88, cu $n = 500$ doar 7%
- ▣ Deoarece $F(\hat{q}) \sim \text{Beta}(k, n + 1 - k)$, alegerea lui n este un calcul de mărime a eșantionului
 - ▶ abaterea standard a acoperirii realizate este aproximativ $\sqrt{\alpha(1 - \alpha)/n}$: pentru a o înjumătăți, n trebuie înmulțit cu 4

Regresia cuantică conformalizată



Emmanuel Candès, 2012


Foto: Renate Schmid, MFO (2012); CC BY-SA
2.0 de; Wikimedia Commons

- Romano, Patterson și Candès (2019): se estimează două regresii cuantile Koenker și Bassett (1978) pe setul de antrenare
 - ▶ $\hat{q}_{\alpha/2}(x)$, $\hat{q}_{1-\alpha/2}(x)$: cuantilele condiționate inferioară și superioară ale lui Y dat fiind $X = x$, estimate
- Scorul CQR: distanța cu semn a lui y în afara benzii

$$s(x, y) = \max\{\hat{q}_{\alpha/2}(x) - y, y - \hat{q}_{1-\alpha/2}(x)\}$$
 - ▶ negativ în interiorul benzii, pozitiv în afara ei
- Intervalul: banda lărgită pe ambele părți cu pragul conformal $\hat{q}$ al acestor scoruri

$$\hat{C}(x) = [\hat{q}_{\alpha/2}(x) - \hat{q}, \hat{q}_{1-\alpha/2}(x) + \hat{q}]$$
 - ▶ $\hat{q} < 0$: banda era prea largă și este îngustată
- Proprietăți
 - ▶ acoperirea marginală rezultă din teorema split; lățimea se adaptează la heteroscedasticitate prin modelele cuantile
 - ▶ același scor calibrează cuantilele oricărui foundation model (secțiunea 8)

CQR pe designul lui Romano, Patterson și Candès



- Date simulate (Figura 1 din lucrare): $Y = \text{Pois}(\sin^2 X + 0,1) + 0,03X\varepsilon_1 + 25 \cdot 1\{U < 0,01\}\varepsilon_2$, $X \sim U[0, 5]$
- $\text{Pois}(\lambda)$: o extragere Poisson cu media λ ; $\varepsilon_1, \varepsilon_2$: zgomot cu distribuția Normală standard; $U \sim U[0, 1]$, deci 1% dintre puncte primesc o valoare extremă mare; zgomotul crește cu X
- 1000 de puncte de antrenare și 1000 de calibrare; gradient boosting pentru medie și pentru cuantilele de 5% și 95%

Interpretarea CQR

- ▣ Acoperirea pe datele de test: split conformal 0,918, CQR 0,915, modelele cuantilice brute 0,883; lățimea medie 2,84; 2,20 și 2,17
- ▣ Regresiile cuantilice brute au o acoperire prea mică; CQR le corectează aproape fără lățime suplimentară, în timp ce banda split de lățime constantă este cu 29% mai largă
- ▣ Pe intervale ale lui X , ambele rămân la câteva puncte de 90% (cele mai slabe intervale: CQR 0,892, split 0,896)
 - ▶ câștigul CQR este în lățime: îngust acolo unde Y este concentrat, larg acolo unde zgomotul Poisson este mare

Limitele acoperirii condiționate

- ▣ **Imposibilitate** Vovk (2012); Lei și Wasserman (2014); Foygel Barber et al. (2021)
 - ▶ dacă $\hat{C}$ are acoperire condiționată $\geq 1 - \alpha$ în aproape orice x , pentru orice distribuție cu X continuu, lungimea lui așteptată este infinită
 - ▶ nicio metodă nu poate certifica în eșantioane finite acoperirea în fiecare punct al unei covariabile continue fără ipoteze
- ▣ Rezultate posibile
 - ▶ acoperire în fiecare dintre un număr finit de grupuri (conformal Mondrian: calibrare separată pe grupuri)
 - ▶ acoperire condiționată aproximativă, sub ipoteze de netezime
 - ▶ acoperire condiționată de setul de calibrare, cu probabilitate mare (legea Beta)
- ▣ Pentru serii de timp, condiția relevantă este trecutul: ținta este $\Pr\{Y_t \in \hat{C}_t \mid \mathcal{F}_{t-1}\} = 1 - \alpha$
 - ▶ $\mathcal{F}_{t-1}$: informația disponibilă la $t - 1$; $\hat{C}_t$: mulțimea construită la $t - 1$ pentru perioada t
 - ▶ un backtest VaR (Capitolul 9) testează exact această proprietate pentru mulțimi unilaterale

Recapitulare: predicția conformală

- Split conformal: un argument de rang dă acoperire marginală în eșantioane finite sub interschimbabilitate, pentru orice model
- CQR adaugă adaptivitate; mărimea eșantionului de calibrare controlează variabilitatea acoperirii realizate
- Acoperirea condiționată este imposibilă în general: testați-o, nu o afirmați

Interschimbabilitatea încălcată: rezultatele care rămân valabile

- ▣ Seriile de timp încălcă interschimbabilitatea în trei feluri: dependența serială, volatilitatea variabilă, schimbările structurale; ultimele două afectează cel mai mult acoperirea
- ▣ **Staționar și mixing:** split conformal rămîne aproximativ valid [Oliveira et al. \(2024\)](#)
 - ▶ abaterea acoperirii scade cu mărimea calibrării și cu coeficienții β -mixing, care măsoară cît de repede dispare dependența dintre observațiile îndepărtate
 - ▶ permutările pe blocuri refac exactitatea sub condiții mai slabe [Chernozhukov, Wüthrich și Zhu \(2018\)](#)
- ▣ **Nestaționar:** nicio metodă statică nu poate funcționa; pragul trebuie să se miște odată cu datele
 - ▶ ponderi (Barber et al.), reestimare (EnbPI), reacție la erori (ACI, PID)
- ▣ **Un cadru online comun** pentru slide-urile următoare
 - ▶ $S_t = s(X_t, Y_t)$: scorul perioadei t , calculat dintr-o prognoză în afara eșantionului
 - ▶ q_t : pragul folosit la t , ales din scorurile trecute $S_1, \dots, S_{t-1}$; mulțimea este $\hat{C}_t = \{y : s(X_t, y) \leq q_t\}$
 - ▶ $\text{err}_t = 1\{S_t > q_t\}$: indicatorul ratării, 1 dacă Y_t cade în afara lui $\hat{C}_t$

Predicția conformală dincolo de interschimbabilitate (1/2)

- Barber et al. (2023): fiecare scor de calibrare primește o pondere fixă $w_i \in [0, 1]$, aleasă înainte de a vedea datele; punctul de test primește ponderea $w_{n+1} = 1$
 - ▶ ponderile normalizate $\tilde{w}_i = w_i / (1 + \sum_{j=1}^n w_j)$, $i = 1, \dots, n+1$; însumează 1
- Pragul $\hat{q}$ este cuantila $(1 - \alpha)$ a distribuției ponderate a scorurilor, cu punctul de test plasat la $+\infty$

$$\hat{q} = Q_{1-\alpha} \left(\sum_{i=1}^n \tilde{w}_i \delta_{S_i} + \tilde{w}_{n+1} \delta_{+\infty} \right)$$

- ▶ δ_a : o masă de probabilitate unitară în punctul a ; $Q_{1-\alpha}(\cdot)$: cuantila $(1 - \alpha)$ a unei distribuții
- ▶ cu toate $w_i = 1$, acesta este pragul split conformal
- **Schimbarea distribuției covariabilelor** cu raport de verosimilitate cunoscut: ponderile $w(x) = dP_{\text{test}}/dP_{\text{train}}$ dau acoperire exactă Tibshirani et al. (2019)
 - ▶ $dP_{\text{test}}/dP_{\text{train}}$: raportul densităților lui X în populația de test și în cea de antrenare


Predicția conformală dincolo de interschimbabilitate (2/2)

- ▣ **Teoremă Barber et al. (2023):** pierderea de acoperire este mărginită de distanța ponderată față de interschimbabilitate

$$\Pr\{Y_{n+1} \in \hat{C}(X_{n+1})\} \geq 1 - \alpha - \sum_{i=1}^n \tilde{w}_i d_{TV}(Z, Z^i)$$

- ▶ $Z = (Z_1, \dots, Z_{n+1})$: datele; Z^i : aceleași date, cu punctul de test și punctul i schimbate între ele
- ▶ d_{TV} : distanța în variație totală dintre două distribuții, în $[0, 1]$; 0 când coincid
- ▣ Sub interschimbabilitate, toți termenii $d_{TV}(Z, Z^i)$ sînt 0, iar abaterea dispare
- ▣ Sub o derivă lentă, d_{TV} este mic pentru punctele recente: acestea primesc ponderile cele mai mari
 - ▶ ponderi geometrice $w_i = \rho^{n+1-i}$, $\rho \in (0, 1)$: ponderea se înjumătățește la fiecare $\ln 2 / |\ln \rho|$ pași
 - ▶ mărimea efectivă a eșantionului $\approx 1/(1 - \rho)$: $\rho = 0,99$ folosește aproximativ 100 de scoruri recente
 - ▶ un ρ mai mic se adaptează mai repede, dar face pragul mai variabil

Predicția conformală ponderată la puncte de schimbare



- Regresie simulată $Y_t = X_t' \beta_t + \varepsilon_t$: $X_t \sim N(0, I_4)$, patru regresori independenți cu distribuția Normală standard (I_4 : matricea unitate 4×4); ε_t : zgomot cu distribuția Normală; vectorul de coeficienți β_t se schimbă la $t = 500$ și $t = 1500$
- Cele mai mici pătrate pe toate datele trecute; scorurile: reziduurile absolute la un pas (prequential: fiecare calculat înainte ca Y_t să fie folosit); acoperirea mediată pe 200 de rulări (medie mobilă pe 20 de pași)

Interpretarea metodei ponderate

- ▣ Acoperirea medie după perioada inițială: standard 0,836, ponderat ($\rho = 0,99$) 0,900; cea mai slabă medie pe 20 de pași 0,36 față de 0,43
- ▣ Acoperirea ambelor metode scade brusc la o ruptură, pentru că estimarea prin cele mai mici pătrate rămîne greșită o perioadă; pragul ponderat uită scorurile vechi și își revine în aproximativ 100 de pași
- ▣ Costul: lățimea medie 7,47 față de 6,22; garanția este o margine exprimată prin d_{TV} , nu o acoperire exactă

EnbPI: ansambluri fără împărțirea datelor

- ▣ Xu și Xie (2021), Xu și Xie (2023): se estimează B modele pe B eșantioane bootstrap ale perioadei de antrenare (blocuri de observații consecutive, pentru a respecta dependența)
 - ▶ reziduuri leave-one-out: pentru punctul i se agregă doar modelele al căror eșantion bootstrap l-a exclus pe i
- ▣ Intervalul la t : prognoza ansamblului plus sau minus o cuantilă a reziduurilor absolute recente

$$\hat{C}_t = \hat{f}(x_t) \pm Q_{1-\alpha}(|e_{t-W}|, \dots, |e_{t-1}|)$$

- ▶ $\hat{f}(x_t)$: prognoza agregată a celor B modele, dați predictorii x_t ; e_s : reziduul perioadei s ; W : lungimea ferestrei
- ▶ după ce y_t este observat, reziduul lui intră în fereastră, iar cel mai vechi iese
- ▣ Fără reestimare la fiecare pas, fără împărțire pentru calibrare: eficient pe fluxuri lungi
- ▣ Garanția: acoperire asimptotică, condiționată, dacă erorile sînt staționare și puternic mixing, iar ansamblul este consistent; gândit pentru serii de energie (solară și eoliană)

Inferența conformală adaptivă (1/2)

- ▣ Gibbs și Candès (2021): nivelul nominal este înlocuit cu un nivel de lucru α_t , actualizat după fiecare observație
 - ▶ q_t : cuantila conformală ($1 - \alpha_t$) a scorurilor recente; α : rata-țintă a ratărilor (de exemplu 0,1)

- ▣ **Actualizarea:** după observarea lui Y_t , nivelul de lucru se mută în sens opus ultimei erori

$$\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t)$$

- ▶ $\gamma > 0$: pasul; $\text{err}_t \in \{0, 1\}$: indicatorul ratării de pe slide-urile anterioare

- ▣ Interpretarea actualizării

- ▶ o ratare ($\text{err}_t = 1$) scade α_t cu $\gamma(1 - \alpha)$: mulțimea următoare este mai largă
- ▶ o acoperire ($\text{err}_t = 0$) crește α_t cu $\gamma\alpha$: mulțimea următoare este mai îngustă
- ▶ $\alpha_t \leq 0$ dă $q_t = +\infty$ (toată dreapta reală); $\alpha_t \geq 1$ dă mulțimea vidă


Inferența conformală adaptivă (2/2)

- ▣ **Teoremă Gibbs și Candès (2021):** pentru orice șir de date, frecvența ratărilor pe T perioade este apropiată de α

$$\left| \frac{1}{T} \sum_{t=1}^T \text{err}_t - \alpha \right| \leq \frac{\max\{\alpha_1, 1 - \alpha_1\} + \gamma}{\gamma T}$$

- ▶ α_1 : nivelul de pornire; marginea scade ca $1/T$ și este mai strânsă pentru un γ mai mare
- ▣ Ideea demonstrației (▶ [Anexă](#))
 - ▶ α_t rămîne mereu în $[-\gamma, 1 + \gamma]$
 - ▶ însumînd actualizările, $\alpha_{T+1} - \alpha_1 = \gamma \sum_t (\alpha - \text{err}_t)$; se împarte la γT
- ▣ O frecvență pe termen lung, nu o acoperire condiționată
 - ▶ garanția este valabilă și pentru un șir de date ales advers
 - ▶ alegerea adaptivă a lui γ : AgACI [Zaffran et al. \(2022\)](#), DtACI [Gibbs și Candès \(2024\)](#); ACI pentru VaR: [Capitolul 9](#)

ACI pe volatilitatea bursieră




- Designul din [Gibbs și Candès \(2021\)](#): ținta este $V_t = r_t^2$, randamentul zilnic la pătrat; $\hat{\sigma}_t^2$: prognoza ei dintr-un GARCH(1,1) estimat pe ultimele 1250 de zile
- Scorul $|V_t - \hat{\sigma}_t^2|/\hat{\sigma}_t^2$ (eroarea relativă a prognozei de varianță), $\alpha = 0,1$, $\gamma = 0,005$; acoperirea locală pe 500 de zile; evaluare din 15 decembrie 2009

Interpretarea ACI pe volatilitate

- ▣ Trei praguri comparate
 - ▶ static: split conformal calibrat o singură dată, pe primele 1250 de scoruri
 - ▶ mobil: split conformal pe ultimele 1250 de scoruri, cu nivelul fix α
 - ▶ ACI: aceeași fereastră mobilă, cu nivelul α_t
- ▣ Acoperirea totală, S&P 500: static 0,918, mobil 0,903, ACI 0,901; BET: 0,928; 0,903; 0,899; NVIDIA: 0,882; 0,900; 0,901
- ▣ Acoperirea locală a metodei statice variază între 0,884 și 0,962 (S&P 500); ACI rămîne între 0,870 și 0,928
- ▣ Testul Christoffersen de acoperire condiționată a ratărilor (S&P 500): static $p < 0,001$, ACI $p = 0,968$
 - ▶ o calibrare fixată pe 2005–2009 este prea largă ulterior
 - ▶ actualizarea reface atît frecvența, cît și independența ratărilor

Pasul ACI



- Scorurile S&P 500 din graficul anterior: nivelul α_t pentru $\gamma = 0,001$, $0,005$ și $0,05$

Interpretarea pasului

- ▣ Frecvențele ratărilor 0,0987; 0,0994; 0,0999 față de marginile 0,2138; 0,0430; 0,0045 ($T = 4214$): teorema este respectată cu o marjă largă
- ▣ γ mare: α_t variază între $-0,04$ și $0,27$, intervale infinite în 1,6% din zile; γ mic: reacție lentă, serii lungi de ratări după un șoc
- ▣ γ echilibrează adaptivitatea și stabilitatea: alegeți-l pe o fereastră trecută sau lăsați DtACI să agrege mai multe valori

Controlul PID conformal (1/2)

- ▣ Angelopoulos, Candès și Tibshirani (2023), **urmărirea cuantilei** (termenul P): pragul însuși este actualizat după fiecare observație

$$q_{t+1} = q_t + \eta (\text{err}_t - \alpha)$$

- ▶ $\eta > 0$: pasul, în unitățile scorurilor; o rată ridică pragul cu $\eta(1 - \alpha)$, o acoperire îl coboară cu $\eta\alpha$
- ▶ este coborârea pe gradient online pe pierderea pinball a scorului la nivelul $1 - \alpha$
- ▣ **Propoziție**: dacă scorurile sînt în $[0, B]$, frecvența ratărilor este apropiată de α pentru orice șir

$$\left| \frac{1}{T} \sum_{t=1}^T (\text{err}_t - \alpha) \right| \leq \frac{B + \eta}{\eta T}$$

- ▶ B : o margine superioară a scorurilor; pragul se mișcă pe scala scorurilor, nu pe cea a lui α , ca la ACI
- ▣ ACI este cazul particular care urmărește nivelul în loc de cuantilă


Controlul PID conformal (2/2)

- ▣ **Integratorul** (termenul I): adaugă o corecție determinată de eroarea de acoperire acumulată

$$r_t \left(\sum_{i \leq t} (\text{err}_i - \alpha) \right), \quad r_t(x) = K_I \tan \left(x \log t / (t C_{\text{sat}}) \right)$$

- ▶ $\sum_{i \leq t} (\text{err}_i - \alpha)$: ratările peste țintă, acumulate pînă la t
- ▶ $K_I > 0$: câștigul integratorului; $C_{\text{sat}} > 0$: constanta de saturație; $\tan$ crește nemărginit lîngă polul său, ceea ce păstrează garanția pe termen lung
- ▣ **Prognozatorul de scor** (un termen asemănător lui D): un model care prognozează scorul următor din trecutul lui și se adaugă la prag
 - ▶ anticipează tiparele previzibile ale erorilor: sezonalitate, tendințe
- ▣ Denumirea vine din teoria controlului automat
 - ▶ proporțional (reacție la ultima eroare), integral (la eroarea acumulată), derivativ (la schimbarea anticipată)

Metode online pe consumul României



- Intervale de 90% pentru ziua următoare în jurul mediane Chronos-Bolt, câte un flux de scoruri pe oră (24 de fluxuri), fereastra de calibrare 91 de zile; EnbPI pe regresorii ARX expert (ridge, 20 de modele bootstrap pe blocuri); evaluare din 2 aprilie 2025

Interpretarea metodelor online

- ▣ Acoperirea: static 0,903, mobil 0,902, ACI 0,905, urmărirea cuantilei 0,902, PID 0,902, EnbPI 0,881
- ▣ Lățimea medie (GW): 1,06; 1,04; 1,05; 1,03; 1,03; 0,92; cea mai slabă acoperire pe 30 de zile: static 0,747, PID 0,787
- ▣ Pe toată perioada, toate metodele în afară de EnbPI sînt aproape de 90%; diferențele țin de scăderile după tranzițiile sezoniere și de lățime, iar PID este cel mai bun la ambele
- ▣ EnbPI centrează banda pe propriul ansamblu ridge, mai puțin precis decît prognoza de bază: intervale mai înguste, acoperire mai mică

Diagnosticarea acoperirii

▣ Frecvența și independența ratărilor (Capitolul 9)

- ▶ frecvența ratărilor și testul Kupiec [Kupiec \(1995\)](#) (este frecvența egală cu α ?); testul Christoffersen [Christoffersen \(1998\)](#) (sînt ratările independente în timp?)
- ▶ o verificare prin regresie în spiritul testului DQ [Engle și Manganelli \(2004\)](#): regresia lui $\text{err}_t - \alpha$ pe ratările cu lag și pe lățimea prognozată

▣ Acoperirea locală: echivalentul empiric al acoperirii condiționate

- ▶ acoperirea pe ferestre mobile
- ▶ acoperirea pe clase ale unei variabile cunoscute la origine (volatilitatea prognozată, ora, regimul)


▣ Precizia (sharpness): lățimea medie și scorul de interval [Winkler \(1972\)](#), [Gneiting și Raftery \(2007\)](#), care adaugă o penalizare pentru fiecare rată

$$\text{IS} = (u - \ell) + \frac{2}{\alpha}(\ell - y)1\{y < \ell\} + \frac{2}{\alpha}(y - u)1\{y > u\}$$

- ▶ $[\ell, u]$: intervalul central de $(1 - \alpha)$; $u - \ell$: lățimea lui; y : valoarea realizată; o valoare mai mică este mai bună
- ▶ o regulă de scor proprie: recompensează intervalele înguste doar dacă își păstrează acoperirea nominală

▣ Raportați toate trei: o metodă validă, dar de două ori mai largă, nu este o metodă mai bună

Acoperirea pe regimuri de volatilitate



- S&P 500, intervalele de volatilitate de 90% din graficul ACI: acoperirea pe terțile ale varianței prognozate de GARCH și în ziua de după o ratare

Interpretarea acoperirii condiționate

- ▣ Static: 0,921 (varianță mică), 0,918 (mare), 0,916 după o rată; ACl: 0,893; 0,912; 0,897
- ▣ Acoperirea este aproape constantă pe terțile de volatilitate și după o rată, pentru toate metodele: împărțirea la varianța GARCH face scorul aproape pivotal
- ▣ Contrast: cu scorul brut $|r_t|$ (Seminarul 13, B3) ratările se grupează în anii agitați, oricare ar fi calibrarea; acoperirea condiționată este o proprietate a scorului, nu a pasului conformal

Recapitulare: metodele conformale pentru serii de timp

- ▣ Conformal ponderat: o margine a acoperirii exprimată prin variația totală; ponderile geometrice se adaptează derivei
- ▣ EnbPI: ansambluri bootstrap și o fereastră mobilă de reziduuri, validitate asimptotică sub mixing
- ▣ ACI și PID: reacția la ratări dă acoperire pe termen lung pentru orice șir; acoperirea condiționată trebuie totuși testată

Nevoia de calibrare a cuantilelor foundation models (1/2)

- ▣ Cuantilele preantrenate sînt calibrate pe distribuția corpusului, nu pe seria dumneavoastră
 - ▶ calibrarea greșită este situația implicită, în ambele sensuri (benzi prea înguste sau prea largi)
- ▣ Majoritatea modelelor dau doar cuantilele de 10%–90%
 - ▶ un interval de 95% sau un VaR 1% cere extrapolare dincolo de nivelurile antrenate
- ▣ Procedura: CQR online pe banda proprie de 10%–90% a modelului


$$S_t = \max\{\hat{q}_{0,1,t} - y_t, y_t - \hat{q}_{0,9,t}\}, \quad \hat{C}_t = [\hat{q}_{0,1,t} - q_t, \hat{q}_{0,9,t} + q_t]$$

- ▶ $\hat{q}_{0,1,t}$, $\hat{q}_{0,9,t}$: cuantilele de 10% și 90% prognozate de model pentru perioada t ; S_t : scorul CQR
- ▶ q_t : pragul ales de ACI pentru orice nivel-țintă (80% sau 95%)

Nevoia de calibrare a cuantilelor foundation models (2/2)

- ▣ Varianta unilaterală pentru VaR
 - ▶ scorul $S_t = \hat{q}_{0,1,t} - y_t$; pragul q_t urmărit la nivelul α
 - ▶ cuantila calibrată este $\hat{q}_{0,1,t} - q_t$
 - ▶ $\text{VaR}_t = -(\hat{q}_{0,1,t} - q_t)$: VaR exprimat ca pierdere pozitivă
- ▣ Ce schimbă deplasarea
 - ▶ $q_t > 0$ coboară cuantila (un VaR mai mare); $q_t < 0$ o ridică
 - ▶ modelul însuși nu este reestimat: doar ieșirea lui este recalibrată
- ▣ Lectură suplimentară
 - ▶ recalibrarea conformală a VaR pentru foundation models: [Pele et al., Conformal_Oracle \(GitHub\)](#); [Pele et al., TSFM_VaR_CEE \(GitHub\)](#)

Acoperirea brută și cea conformală a foundation models




- Acoperirea benzii brute de 10–90% și a intervalelor CQR online de 80% și 95% (ACI, fereastra 250, $\gamma = 0,005$): consumul României (24 de fluxuri orare), log RV Bitcoin, inflația UE la $h = 1$ (27 de fluxuri), randamentele zilnice BET

Interpretarea calibrării

- ▣ Benzile brute de 80%: consum 75–81%, Bitcoin 77–81%, inflație 76–85%, randamente BET 72–78% pentru cele patru modele
- ▣ După CQR online: intervalele de 80% acoperă 79–81%, cele de 95% 94,5–95,4% în toate sarcinile
- ▣ Benzile brute sînt necalibrate în ambele sensuri: prea înguste (Chronos-2 la consum), prea largi (TimesFM la inflație)
 - ▶ pasul conformal le lărgeste sau le îngustează: lățimea medie este între 0,90 și 1,24 ori lățimea brută
 - ▶ și ajunge la 95% pornind de la modele care produc doar decile

Valoarea la risc din foundation models



- Depășirile VaR 1%, BET și S&P 500 din 28 decembrie 2017 (2 175 de zile): GARCH-t (fereastră mobilă de 1000 de zile, Capitolul 9), Chronos-2 brut și cu ACI, decilele celorlalte modele extinse printr-o deplasare conformală unilaterală

Interpretarea backtesting-ului VaR

- ▣ BET, VaR 1%: GARCH- t 1,31% (Kupiec $p = 0,170$), Chronos-2 brut 1,22% ($p = 0,331$), Chronos-2 + ACI 1,03% ($p = 0,893$), TimesFM + conformal 1,08%
- ▣ S&P 500: GARCH- t 1,66% (Kupiec $p = 0,007$), Chronos-2 brut 1,56% ($p = 0,021$), + ACI 1,06% ($p = 0,802$, p Christoffersen = 0,454)
- ▣ Calibrarea corectează rata de depășire a oricărui model, dar nu adaugă informație despre coadă
 - ▶ decilele extinse conformal au o pierdere cuantilică mai mare decât GARCH- t (BET, Chronos-Bolt: DM $t = 2,70$)
 - ▶ Chronos-2, antrenat pe cuantile de 1%, nu are o pierdere mai mare ($t = 0,10$)

Recapitulare: calibrarea

- ▣ Tratați cuantilele foundation models ca scoruri de calibrat, nu ca probabilități
- ▣ CQR online cu ACI dă acoperirea-țintă la orice nivel, inclusiv dincolo de cuantilele antrenate
- ▣ Testați VaR calibrat ca în [Capitolul 9](#): frecvență, independență și pierdere

O întrebare deschisă

▣ Întrebarea

- ▶ întrec foundation models pentru serii de timp modelele econometrice de domeniu pe datele din Europa Centrală și de Est?
- ▶ într-o fereastră de după lansarea lor și cu corecție pentru testarea multiplă

▣ O formă testabilă

- ▶ formal: H_0 : pierderea așteptată egală (agregată pe serii preînregistrate) a celui mai bun foundation model și a celui mai bun model de domeniu, într-o fereastră care începe după lansarea tuturor modelelor
- ▶ infirmată de un test DM agregat la 5% și de un MCS care exclude una dintre părți, pe serii și orizonturi fixate înainte de sosirea datelor

▣ Miza

- ▶ băncile centrale și operatorii de rețea iau în calcul înlocuirea modelelor ajustate cu modele zero-shot
- ▶ câștigurile publicate provin adesea dintr-o alegere favorabilă a seriilor
- ▶ literatura de pornire: Aksu et al. (2024), Shchur et al. (2025), Meyer et al. (2025), Pan și Ezzat (2026), Brini (2026)


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează articole recenzate sau de pe arXiv din 2024 încoace care evaluează foundation models pentru serii de timp doar după datele lor de lansare; dă identificatorii arXiv sau DOI. Apoi verificați fiecare identificator
 - ▶ **ipoteza:** Scrie o preînregistrare: seriile, originile, orizonturile, funcțiile de pierdere, modelele de referință, testul agregat și nivelul MCS.
 - ▶ **cod și replicare:** cereți o funcție care întoarce cuantile la niveluri fixe pentru fiecare model; reproduceți întâi o cifră cunoscută (domeniul cuantilelor Chronos-Bolt, MAE-ul nostru pentru consum)
 - ▶ **critica:** Joacă rolul unui recenzent ostil: enumeră toate felurile în care acest benchmark ar putea favoriza foundation models.
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (identificatorul arXiv sau DOI funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Datele de lansare și datele-limită de antrenare ale fiecărui model, din fișele modelelor, comparate cu începutul ferestrei de evaluare
- ▣ Nivelurile de cuantile produse efectiv de fiecare model (o cerere pentru 1% poate întoarce, fără avertisment, 10%)
- ▣ Modelele de referință ajustate cu aceeași grijă; contextul disponibil este același pentru toate modelele
- ▣ Multiplicitatea: numărul de serii, orizonturi și modele testate; raportarea testului agregat și a p-value-urilor ajustate

Mini studiu de caz: cât poate schimba verdictul alegerea benchmark-ului?



- Statisticile DM-HLN ale Chronos-2 față de AR(p) la $h = 12$ pe 2000 de benchmark-uri aleatoare cu 5 țări UE și 3 ani de origini și pe întregul panel
- 11,2% dintre benchmark-urile aleatoare declară Chronos-2 semnificativ mai bun, iar 2,1% semnificativ mai slab; panelul întreg dă $t = -1,35$ ($p = 0,180$)
- Un rezumat AI care prezintă o astfel de lucrare ca dovadă pentru (sau împotriva) foundation models greșeste; doar panelul preînregistrat răspunde la întrebare

Idee de proiect

- ▣ **Un benchmark preînregistrat, de după lansare, al foundation models pentru macroeconomia și riscul din Europa Centrală și de Est, cu calibrare conformală**
 - ▶ replicați: protocolul zero-shot din [Ansari et al. \(2024\)](#) (WQL, MASE, medii geometrice) și designul ACI pentru volatilitate din [Gibbs și Candès \(2021\)](#) pe datele noastre
 - ▶ extindeți: inflația, consumul și indicii bursieri din România, Polonia, Ungaria și Cehia; covariabile în context (prețurile energiei, calendare); CQR online pentru 95% și VaR 1%; teste agregate cu Holm și BH
 - ▶ preînregistrați: seriile, originile după 1 noiembrie 2025, orizonturile, funcțiile de pierdere, modelele de referință și regula de decizie; prognozele pentru lunile următoare se notează înainte de sosirea datelor
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Foundation models amortizează estimarea pe un corpus; alegerile de proiectare (scalarea, patch-urile, domeniul cuantilelor) stabilesc ce pot și ce nu pot prognoza
- ▣ Pe datele noastre cel mai bun model zero-shot este competitiv cu modelele de domeniu; câștigurile depind de sarcină și nu rezistă alegerii selective
- ▣ Evaluați după lansare, agregați pe serii, corectați pentru multiplicitate
- ▣ Predicția conformală dă acoperire marginală în eșantioane finite sub interschimbabilitate; sub dependență, ponderile, ansamblurile și reacția la erori refac acoperirea pe termen lung
- ▣ Acoperirea condiționată este imposibilă în general: diagnosticați-o cu testele Christoffersen și cu acoperirea pe regimuri

Autoevaluare

Întrebări

- ▣ De ce nu poate Chronos să prognozeze o valoare peste 15s?
- ▣ De ce încalcă un $AR(1)$ staționar interschimbabilitatea?
- ▣ Care este legea acoperirii split conformal condiționată de setul de calibrare?
- ▣ Ce mărime rămîne mărginită în demonstrația teoremei ACI?
- ▣ De ce este necesară o fereastră de după lansare într-un benchmark al foundation models?

Urmează:

- ▣ Inferență causală pentru serii de timp
- ▣ cauzalitatea Granger și cea structurală, descoperirea relațiilor cauzale, evaluarea politicilor

Anexă: demonstrația acoperirii split conformal

- Condiționăm pe setul de antrenare, astfel încât $\hat{\mu}$ și s sînt fixate; interschimbabilitatea lui $Z_1, \dots, Z_{n+1}$ implică interschimbabilitatea lui $S_1, \dots, S_{n+1}$
- Fără egalități, rangul R al lui S_{n+1} printre $S_1, \dots, S_{n+1}$ este uniform pe $\{1, \dots, n+1\}$ (orice ordonare este la fel de probabilă)
- $S_{n+1} \leq S_{(k)}$ (statistica de ordine a primelor n) $\iff R \leq k$; deci $\Pr\{Y_{n+1} \in \hat{C}\} = k/(n+1)$
- $k = \lceil (n+1)(1-\alpha) \rceil$ dă $1-\alpha \leq k/(n+1) < 1-\alpha + 1/(n+1)$; egalitățile doar cresc acoperirea
- Condiționat de setul de calibrare, acoperirea este $F(S_{(k)})$, unde F este distribuția scorului; $F(S_i)$ sînt uniforme i.i.d., deci $F(S_{(k)}) \sim \text{Beta}(k, n+1-k)$

Anexă: cele două garanții online

- **ACI:** dacă $\alpha_t < 0$, atunci $q_t = +\infty$ și $\text{err}_t = 0$, deci $\alpha_{t+1} = \alpha_t + \gamma\alpha > \alpha_t$; dacă $\alpha_t > 1$, $\text{err}_t = 1$ și α_t scade
 - ▶ deci $\alpha_t \in [-\gamma, 1 + \gamma]$ pentru orice t ; însumînd actualizările,

$$\gamma \left| \sum_{t \leq T} (\alpha - \text{err}_t) \right| = |\alpha_{T+1} - \alpha_1| \leq \max\{\alpha_1, 1 - \alpha_1\} + \gamma$$
- **Urmărirea cuantilei:** dacă $q_t > B$, atunci $\text{err}_t = 0$ și q_t scade cu $\eta\alpha$; dacă $q_t < 0$, atunci $\text{err}_t = 1$ și q_t crește
 - ▶ deci $q_t \in [-\eta, B + \eta]$ (pornind din interior); $\eta \sum_{t \leq T} (\text{err}_t - \alpha) = q_{T+1} - q_1$, deci abaterea medie este cel mult $(B + \eta)/(\eta T)$
- Niciuna dintre demonstrații nu folosește probabilități: garanțiile sînt valabile pentru orice șir, motiv pentru care nu spun nimic despre acoperirea condiționată

Bibliografie (1/6)

- ▣ Aksu, T., Woo, G., Liu, J., Liu, X., Liu, C., Savarese, S., Xiong, C., & Sahoo, D. (2024). GIFT-Eval: A benchmark for general time series forecasting model evaluation. *arXiv:2410.10393*. [arXiv:2410.10393](#)
- ▣ Angelopoulos, A. N., & Bates, S. (2023). Conformal prediction: A gentle introduction. *Foundations and Trends in Machine Learning*, 16(4), 494–591. [doi:10.1561/22000000101](#)
- ▣ Angelopoulos, A. N., Candès, E. J., & Tibshirani, R. J. (2023). Conformal PID control for time series prediction. *Advances in Neural Information Processing Systems* 36; *arXiv:2307.16895*. [arXiv:2307.16895](#)
- ▣ Ansari, A. F., Shchur, O., Küken, J., Auer, A., Han, B., Mercado, P., et al. (2025). Chronos-2: From univariate to universal forecasting. *arXiv:2510.15821*. [arXiv:2510.15821](#)
- ▣ Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*; *arXiv:2403.07815*. [arXiv:2403.07815](#)
- ▣ Auer, A., Podest, P., Klotz, D., Böck, S., Klambauer, G., & Hochreiter, S. (2025). TiRex: Zero-shot forecasting across long and short horizons with enhanced in-context learning. *Advances in Neural Information Processing Systems*; *arXiv:2505.23719*. [arXiv:2505.23719](#)
- ▣ Barber, R. F., Candès, E. J., Ramdas, A., & Tibshirani, R. J. (2023). Conformal prediction beyond exchangeability. *The Annals of Statistics*, 51(2), 816–845. [doi:10.1214/23-AOS2276](#)
- ▣ Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300. [doi:10.1111/j.2517-6161.1995.tb02031.x](#)
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. [doi:10.1016/0304-4076\(86\)90063-1](#)
- ▣ Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., et al. (2021). On the opportunities and risks of foundation models. *arXiv:2108.07258*. [arXiv:2108.07258](#)
- ▣ Brini, A. (2026). Forecasting realized volatility with time series foundation models: A comparison with econometric benchmarks. *arXiv:2607.05291*. [arXiv:2607.05291](#)
- ▣ Chernozhukov, V., Wüthrich, K., & Zhu, Y. (2018). Exact and robust conformal inference methods for predictive machine learning with dependent data. *Proceedings of the 31st Conference on Learning Theory (COLT)*; *arXiv:1802.06300*. [arXiv:1802.06300](#)
- ▣ Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862. [doi:10.2307/2527341](#)
- ▣ Cohen, B., Khwaja, E., Doubli, Y., Lemaachi, S., Lettieri, C., Masson, C., et al. (2025). This time is different: An observability perspective on time series foundation models. *arXiv:2505.14766*. [arXiv:2505.14766](#)

Bibliografie (2/6)

- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jffinec/nbp001
- ▣ Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of the 41st International Conference on Machine Learning (ICML)*; arXiv:2310.10688. arXiv:2310.10688
- ▣ Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1–30. jmlr.org
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Edwards, T. D. P., Alvey, J., Alsing, J., Nguyen, N. H., & Wandelt, B. D. (2024). Scaling-laws for large time-series models. arXiv:2405.13867. arXiv:2405.13867
- ▣ Engle, R. F., & Manganelli, S. (2004). CAViaR: Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381. doi:10.1198/073500104000000370
- ▣ Fleming, P. J., & Wallace, J. J. (1986). How not to lie with statistics: The correct way to summarize benchmark results. *Communications of the ACM*, 29(3), 218–221. doi:10.1145/5666.5673
- ▣ Foygel Barber, R., Candès, E. J., Ramdas, A., & Tibshirani, R. J. (2021). The limits of distribution-free conditional predictive inference. *Information and Inference: A Journal of the IMA*, 10(2), 455–482. doi:10.1093/imaiai/iaaa017
- ▣ Garza, A., Challu, C., & Mergenthaler-Canseco, M. (2023). TimeGPT-1. arXiv:2310.03589. arXiv:2310.03589
- ▣ Garza, A., Rosillo, R., Mendoza-Smith, R., Salinas, D., Williams, A. R., Ashok, A., Goswami, M., et al. (2026). Impermanent: A live benchmark for temporal generalization in time series forecasting. arXiv:2603.08707. arXiv:2603.08707
- ▣ Giacomini, R., & White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578. doi:10.1111/j.1468-0262.2006.00718.x
- ▣ Gibbs, I., & Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems 34*; arXiv:2106.00170. arXiv:2106.00170
- ▣ Gibbs, I., & Candès, E. J. (2024). Conformal inference for online prediction with arbitrary distribution shifts. *Journal of Machine Learning Research*, 25(162), 1–36. jmlr.org
- ▣ Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/016214506000001437

Bibliografie (3/6)

- ▣ Goel, A., Pasricha, P., Magris, M., & Kannianen, J. (2025). Foundation time-series AI model for realized volatility forecasting. *arXiv:2505.11163*. [arXiv:2505.11163](#)
- ▣ Goswami, M., Szafer, K., Choudhry, A., Cai, Y., Li, S., & Dubrawski, A. (2024). MOMENT: A family of open time-series foundation models. *Proceedings of the 41st International Conference on Machine Learning (ICML)*; *arXiv:2402.03885*. [arXiv:2402.03885](#)
- ▣ Gruver, N., Finzi, M., Qiu, S., & Wilson, A. G. (2023). Large language models are zero-shot time series forecasters. *Advances in Neural Information Processing Systems 36*; *arXiv:2310.07820*. [arXiv:2310.07820](#)
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. [doi:10.3982/ECTA5771](#)
- ▣ Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. [doi:10.1016/S0169-2070\(96\)00719-4](#)
- ▣ Heber, G., Lunde, A., Shephard, N., & Sheppard, K. (2009). *Oxford-Man Institute's realized library*, version 0.3. Oxford-Man Institute, University of Oxford. [web.archive.org](#)
- ▣ Hewamalage, H., Ackermann, K., & Bergmeir, C. (2023). Forecast evaluation for data scientists: Common pitfalls and best practices. *Data Mining and Knowledge Discovery*, 37, 788–832. [doi:10.1007/s10618-022-00894-5](#)
- ▣ Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., et al. (2022). Training compute-optimal large language models. *arXiv:2203.15556*. [arXiv:2203.15556](#)
- ▣ Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70. [jstor.org](#)
- ▣ Hong, T., & Fan, S. (2016). Probabilistic electric load forecasting: A tutorial review. *International Journal of Forecasting*, 32(3), 914–938. [doi:10.1016/j.ijforecast.2015.11.011](#)
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. [doi:10.1016/j.ijforecast.2006.03.001](#)
- ▣ Hyndman, R. J., Koehler, A. B., Snyder, R. D., & Grose, S. (2002). A state space framework for automatic forecasting using exponential smoothing methods. *International Journal of Forecasting*, 18(3), 439–454. [doi:10.1016/S0169-2070\(01\)00110-8](#)
- ▣ Jin, M., Wang, S., Ma, L., Chu, Z., Zhang, J. Y., Shi, X., et al. (2024). Time-LLM: Time series forecasting by reprogramming large language models. *International Conference on Learning Representations (ICLR)*; *arXiv:2310.01728*. [arXiv:2310.01728](#)
- ▣ Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., et al. (2020). Scaling laws for neural language models. *arXiv:2001.08361*. [arXiv:2001.08361](#)

Bibliografie (4/6)

- Koenker, R., & Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50. doi:10.2307/1913643
- Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J., & Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111. doi:10.1080/01621459.2017.1307116
- Lei, J., & Wasserman, L. (2014). Distribution-free prediction bands for non-parametric regression. *Journal of the Royal Statistical Society: Series B*, 76(1), 71–96. doi:10.1111/rssb.12021
- Lim, B., Ank, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748–1764. doi:10.1016/j.ijforecast.2021.03.012
- Liu, C., Aksu, T., Liu, J., Liu, X., Yan, H., Pham, Q., Savarese, S., et al. (2025). Moirai 2.0: When less is more for time series forecasting. arXiv:2511.11698. arXiv:2511.11698
- Lopez-Lira, A., Tang, Y., & Zhu, M. (2025). The memorization problem: Can we trust LLMs' economic forecasts? arXiv:2504.14765. arXiv:2504.14765
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. doi:10.1016/j.ijforecast.2021.11.013
- Meyer, M., Kaltenpoth, S., Albers, H., Zalipski, K., & Müller, O. (2025). TS-Arena: A live forecast pre-registration platform. arXiv:2512.20761. arXiv:2512.20761
- Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with Transformers. *International Conference on Learning Representations (ICLR)*; arXiv:2211.14730. arXiv:2211.14730
- Oliveira, R. I., Orenstein, P., Ramos, T., & Romano, J. V. (2024). Split conformal prediction and non-exchangeable data. *Journal of Machine Learning Research*, 25; arXiv:2203.15885. arXiv:2203.15885
- Oreshkin, B. N., Carpo, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations (ICLR)*; arXiv:1905.10437. arXiv:1905.10437
- Pan, Z., & Ezzat, A. A. (2026). Evaluating time series foundation models for electricity price forecasting: Contamination risk, distributional shifts, and covariate dependence. arXiv:2607.02623. arXiv:2607.02623
- Papadopoulos, H., Proedrou, K., Vovk, V., & Gammerman, A. (2002). Inductive confidence machines for regression. In *Machine Learning: ECML 2002, Lecture Notes in Computer Science* 2430, 345–356. Springer. doi:10.1007/3-540-36755-1_29

Bibliografie (5/6)

- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Pele, D. T., et al. Conformal_Oracle: conformal VaR recalibration for time series foundation models and classical models. GitHub repository. github.com
- ▣ Pele, D. T., et al. TSFM_VaR_CEE: benchmarking time-series foundation models for VaR and ES forecasting in Central and Eastern European markets. GitHub repository. github.com
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., et al. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Rahimikia, E., Ni, H., & Wang, W. (2025). Re(Visiting) time series foundation models in finance. *arXiv:2511.18578*. [arXiv:2511.18578](https://arxiv.org/abs/2511.18578)
- ▣ Rasul, K., Ashok, A., Williams, A. R., Ghonia, H., Bhagwatkar, R., Khorasani, A., et al. (2023). Lag-Llama: Towards foundation models for probabilistic time series forecasting. *arXiv:2310.08278*. [arXiv:2310.08278](https://arxiv.org/abs/2310.08278)
- ▣ Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems* 32; *arXiv:1905.03222*. [arXiv:1905.03222](https://arxiv.org/abs/1905.03222)
- ▣ Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3), 1181–1191. doi:10.1016/j.ijforecast.2019.07.001
- ▣ Shchur, O., Ansari, A. F., Turkmen, C., Stella, L., Erickson, N., Gueron, P., et al. (2025). fev-bench: A realistic benchmark for time series forecasting. *arXiv:2509.26468*. [arXiv:2509.26468](https://arxiv.org/abs/2509.26468)
- ▣ Shi, J., Ma, Q., Ma, H., & Li, L. (2024). Scaling law for time series forecasting. *Advances in Neural Information Processing Systems* 37; *arXiv:2405.15124*. [arXiv:2405.15124](https://arxiv.org/abs/2405.15124)
- ▣ Tan, M., Merrill, M. A., Gupta, V., Althoff, T., & Hartvigsen, T. (2024). Are language models actually useful for time series forecasting? *Advances in Neural Information Processing Systems* 37; *arXiv:2406.16964*. [arXiv:2406.16964](https://arxiv.org/abs/2406.16964)
- ▣ Tibshirani, R. J., Barber, R. F., Candès, E. J., & Ramdas, A. (2019). Conformal prediction under covariate shift. *Advances in Neural Information Processing Systems* 32; *arXiv:1904.06019*. [arXiv:1904.06019](https://arxiv.org/abs/1904.06019)
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems* 30; *arXiv:1706.03762*. [arXiv:1706.03762](https://arxiv.org/abs/1706.03762)
- ▣ Vovk, V. (2012). Conditional validity of inductive conformal predictors. *Proceedings of the Asian Conference on Machine Learning*, PMLR 25, 475–490. proceedings.mlr.press

Bibliografie (6/6)

- ▣ Vovk, V., Gammerman, A., & Shafer, G. (2022). *Algorithmic Learning in a Random World* (2nd ed.). Springer. doi:10.1007/978-3-031-06649-8
- ▣ Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer. doi:10.1007/b106715
- ▣ Winkler, R. L. (1972). A decision-theoretic approach to interval estimation. *Journal of the American Statistical Association*, 67(337), 187–191. doi:10.1080/01621459.1972.10481224
- ▣ Woo, G., Liu, C., Kumar, A., Xiong, C., Savarese, S., & Sahoo, D. (2024). Unified training of universal time series forecasting Transformers. *Proceedings of the 41st International Conference on Machine Learning (ICML)*; arXiv:2402.02592. arXiv:2402.02592
- ▣ Xu, C., & Xie, Y. (2023). Conformal prediction for time series. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(10), 11575–11587. doi:10.1109/TPAMI.2023.3272339
- ▣ Xu, C., & Xie, Y. (2021). Conformal prediction interval for dynamic time-series. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, PMLR 139, 11559–11569. proceedings.mlr.press
- ▣ Yao, Q., Yang, C.-H. H., Jiang, R., Liang, Y., Jin, M., & Pan, S. (2025). Towards neural scaling laws for time series foundation models. *International Conference on Learning Representations (ICLR)*; arXiv:2410.12360. arXiv:2410.12360
- ▣ Zaffran, M., Dieuleveut, A., Féron, O., Goude, Y., & Josse, J. (2022). Adaptive conformal predictions for time series. *Proceedings of the 39th International Conference on Machine Learning (ICML)*; arXiv:2202.07282. arXiv:2202.07282
- ▣ Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128. doi:10.1609/aaai.v37i9.26317
- ▣ Zhou, T., Niu, P., Wang, X., Sun, L., & Jin, R. (2023). One fits all: Power general time series analysis by pretrained LM. *Advances in Neural Information Processing Systems* 36; arXiv:2302.11939. arXiv:2302.11939
- ▣ Ziel, F., & Weron, R. (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics*, 70, 396–420. doi:10.1016/j.eneco.2017.12.016