



Analiza avansată a seriilor de timp și previziune

Capitolul 14: Inferență cauzală pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ADH: Abadie, Diamond and Hainmueller (Abadie, Diamond și Hainmueller)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ BNR: Banca Națională a României
- ▣ BSTS: Bayesian Structural Time Series (serii de timp structurale bayesiene)
- ▣ CAR: Cumulative Abnormal Return (randamentul anormal cumulat)
- ▣ CCM: Convergent Cross Mapping (estimare încrucișată convergentă (Sugihara et al. 2012))
- ▣ CS: Callaway and Sant'Anna (estimator) — estimatorul Callaway și Sant'Anna
- ▣ DML: Double/Debiased Machine Learning (machine learning dublu (fără deplasare))
- ▣ ECOFIN: Economic and Financial Affairs Council (of the EU) — Consiliul Afaceri Economice și Financiare al UE
- ▣ EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- ▣ IAPC: Indicele armonizat al prețurilor de consum
- ▣ ITS: Interrupted Time Series (serie de timp întreruptă)
- ▣ LLM: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ LP: Local Projection (proiecție locală)
- ▣ MCI: Momentary Conditional Independence (independență condiționată momentană)
- ▣ MCMC: Markov Chain Monte Carlo (metode Monte Carlo cu lanțuri Markov)
- ▣ MSPE: Mean Squared Prediction Error (eroarea medie pătratică de prognoză)
- ▣ OCDE: Organizația pentru Cooperare și Dezvoltare Economică
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ PC1: first Principal Component (prima componentă principală)
- ▣ PCMCi: PC algorithm + Momentary Conditional Independence (algoritmul PC urmat de testul de independență condiționată momentană (Runge et al. 2019))
- ▣ PIB: Produsul intern brut

Acronime folosite în acest material (2/2)

- RMSPE: Root Mean Squared Prediction Error (rădăcina erorii pătratice medii de predicție)
- SC: Synthetic Control (control sintetic)
- SDID: Synthetic Difference in Differences (diferența în diferențe sintetică)
- SEC: Securities and Exchange Commission (Comisia americană pentru valori mobiliare)
- SUA: Statele Unite ale Americii
- SVAR: Structural Vector AutoRegression (model vector autoregresiv structural)
- TE: Transfer Entropy (entropia de transfer)
- TVA: Taxa pe valoarea adăugată
- TWFE: Two-Way Fixed Effects (efecte fixe bidirecționale (unitate și perioadă))
- UE: Uniunea Europeană
- UE-26: cele 26 de țări UE în afară de România
- VAR: Vector AutoRegression (model vector autoregresiv)
- VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cînd ne spune o analiză de serii de timp *ce s-ar fi întîmplat* fără un șoc sau fără o politică și cît de siguri putem fi?
 - ▶ predicția nu este intervenție: o variabilă o poate prognoza pe alta fără să o cauzeze
- ▣ **Traseul** capitolului
 - ▶ cauzalitatea Granger, rezultate potențiale pentru serii de timp, entropia de transfer
 - ▶ descoperirea relațiilor cauzale: PCMCI și convergent cross mapping, cu limitele lor
 - ▶ serii de timp întrerupte și studii de eveniment cu erori dependente
 - ▶ controlul sintetic și succesorii lui; DiD eşalonat; CausalImpact; DML
- ▣ Pornim de la [Capitolul 0](#) (HAC), [Capitolul 3](#) (SVAR, proiecții locale, proxy SVAR) și [Capitolul 6](#) (spațiul stărilor, BSTS); Seminarul 14 are loc înaintea acestui curs

Rezultatele învățării

- ▣ Distingeți cauzalitatea Granger de un efect cauzal dinamic și enunțați condițiile în care o mărime estimată din serii de timp are sens cauzal
- ▣ Aplicați teste Granger condiționate cu covarianță HAC, estimați entropia de transfer și citiți critic rezultatele PCMCI și convergent cross mapping
- ▣ Estimați efecte din serii de timp întrerupte și din studii de eveniment cu erori standard care respectă dependența serială
- ▣ Construiți controale sintetice (clasic, cu termen liber, augmentat, DiD sintetic), aplicați inferența prin placebo și replicați un rezultat publicat
- ▣ Folosiți contrafactice în spațiul stărilor de tip CausalImpact și judecați onest ipotezele de identificare ale fiecărei metode

Bibliografie, date și instrumente

- Cauzalitate și serii de timp: Granger (1969); Sims (1972); Rambachan și Shephard (2021); Bojinov și Shephard (2019); Angrist, Jordà și Kuersteiner (2018); Stock și Watson (2018)
 - ▶ Descoperire: Schreiber (2000); Runge et al. (2019a); Runge et al. (2019b); Sugihara et al. (2012)
 - ▶ Evaluarea politicilor: Abadie, Diamond și Hainmueller (2010); Abadie, Diamond și Hainmueller (2015); Abadie (2021); Ben-Michael, Feller și Rothstein (2021); Arkhangelsky et al. (2021); Callaway și Sant'Anna (2021); Brodersen et al. (2015); sinteza Athey și Imbens (2017)
- Quantlet-urile Python ale capitolului: [Quantlets/Ch_14](#)
 - ▶ `numpy`, `scipy` (ponderile controlului sintetic prin programare pătratică) și `statsmodels` (spațiul stărilor); fiecare estimator este scris explicit, fără cutii negre
- Notebook-ul cursului: [deschideți în Google Colab](#)

Datele folosite în acest capitol

Seria	Sursa, eşantionul	Utilizarea
Inflația IAPC, 27 de țări UE; IAPC la cote de taxare constante	Eurostat (2026a) , Eurostat (2026b) : lunar, 2015 – august 2026	ITS, control sintetic pentru România
PIB pe locuitor, Germania de Vest și 16 țări OCDE	Abadie, Diamond și Hainmueller (2014) : 1960–2003	replicarea ADH (2015)
PIB real, Regatul Unit și 23 de țări OCDE	OECD (2026) : trimestrial, 1995–2019	dublura Brexit
Prețuri zilnice ale indicilor și criptoactivelor; EUR/RON	EODHD; cursul de referință BNR; până la 18 septembrie 2026	Granger, PCMCi, studiu de eveniment, CausalImpact

- Datele tratamentului, ferestrele de eşantion și estimatorii sînt fixați înainte de a privi datele de după tratament; fiecare placebo este raportat

Două limbaje ale cauzalității



Judea Pearl, Premiul Turing 2011

Foto: Better Than Bacon (2013); CC BY 2.0;

Wikimedia Commons




Guido Imbens, Premiul Nobel pentru economie

2021

Foto: Filetime (2022); CC0; Wikimedia Commons

- **Modele cauzale structurale** Pearl (2009): grafuri, operatorul $do(\cdot)$, condiții în care un efect cauzal este identificat din date observaționale
- **Rezultate potențiale** Rubin (1974), Imbens și Rubin (2015): $Y(1)$, $Y(0)$, mecanisme de alocare, designul înaintea analizei
- **Seriile de timp** adaugă ordinea, dependența și o singură realizare: o țară, o istorie, un singur drum al tratamentului
- Granger și PCMCi vorbesc limbajul grafurilor; controlul sintetic, DiD și CausalImpact vorbesc limbajul rezultatelor potențiale

Patru studii de caz



- Inflația României față de 26 de țări UE; Germania de Vest față de eșantionul OCDE; PIB-ul real al Regatului Unit față de 23 de țări OCDE; varianța realizată a Bitcoin în jurul aprobării ETF-urilor spot

Interpretarea celor patru studii de caz

- România: inflația IAPC anuală 5,6% în iunie 2025, 8,2% în august 2025, maximum 9,3% în mai 2026; 6,1% în august 2026 (mediana UE 3,1%)
- Fiecare caz are o singură unitate tratată și un grup de unități netratate sau de serii de control observate pe o perioadă lungă înainte: designul studiului de caz comparativ
- România se află în afara intervalului donatorilor înaintea tratamentului (cea mai mare inflație din UE): un avertisment pentru orice metodă care interpolează
- Volatilitatea Bitcoin este zgomotoasă, iar seriile de control sînt slabe: cadrul în care o analiză onestă poate să nu găsească nimic

Cunoscut din TSA și din Capitolul 3 și elemente noi

- ▣ Cunoscut: testul Granger bivariat într-un VAR (TSA, Capitolul 6); identificarea SVAR, proiecțiile locale și proxy SVAR (Capitolul 3); HAC (Capitolul 0); filtrul Kalman și BSTS (Capitolul 6)
- ▣ Nou: ce pot și ce nu pot spune aceste instrumente despre intervenții
 - ▶ rezultate potențiale pentru serii de timp; non-anticipare; când un răspuns la impuls este un efect cauzal
 - ▶ descoperire neliniară și pe grafuri; studii de caz comparative cu o singură unitate tratată
- ▣ Replicări: Abadie, Diamond și Hainmueller (2015, tabelul 1, figurile 2–5); Born et al. (2019, tabelul 2, figura 2); Sugihara et al. (2012, figura 3)

Cauzalitatea Granger: definiția (1/2)

- ▣ **Granger (1969):** x **cauzează în sens Granger** pe y dacă trecutul lui x reduce eroarea pătratică medie a celei mai bune prognoze la un pas a lui y

$$\mathbb{E}[(y_{t+1} - \mathbb{E}[y_{t+1} | \mathcal{I}_t])^2] < \mathbb{E}[(y_{t+1} - \mathbb{E}[y_{t+1} | \mathcal{I}_t \setminus x])^2]$$

- ▶ $\mathcal{I}_t$: toată informația disponibilă pînă la t ; $\mathcal{I}_t \setminus x$: aceeași informație, fără trecutul lui x
- ▶ $\mathbb{E}[y_{t+1} | \cdot]$: media condiționată, adică cea mai bună prognoză în sensul erorii pătratice medii
- ▣ În practică, $\mathcal{I}_t$ este o mulțime finită de laguri dintr-o regresie

$$y_t = c + \sum_{j=1}^p a_j y_{t-j} + \sum_{j=1}^p b_j x_{t-j} + \sum_{j=1}^p \gamma'_j z_{t-j} + u_t$$

- ▶ p : numărul de laguri; a_j , b_j : coeficienții lagurilor lui y și ale lui x ; z_t : un vector de alte serii de condiționare, cu vectorii de coeficienți γ_j ; u_t : eroarea
- ▶ ipoteza nulă de non-cauzalitate Granger: $H_0: b_1 = \dots = b_p = 0$

Cauzalitatea Granger: definiția (2/2)

- ▣ **Statistica Wald:** o formă pătratică a coeficienților estimați ai lagurilor lui x

$$W = \hat{b}' \hat{V}_b^{-1} \hat{b} \rightarrow \chi_p^2 \quad \text{sub } H_0$$

- ▶ $\hat{b} = (\hat{b}_1, \dots, \hat{b}_p)'$; $\hat{V}_b$: matricea ei de covarianță estimată; H_0 se respinge pentru un W mare (p-value mic)
- ▶ $\hat{V}_b$ HAC (Capitolul 0) când u_t este heteroscedastic, ca pentru randamente Newey și West (1987)
- ▣ Serii integrate sau cointegrate Toda și Yamamoto (1995)
 - ▶ se adaugă atâtea laguri suplimentare cît este ordinul maxim de integrare și se testează doar primele p laguri
- ▣ **Intensitatea:** măsura Geweke Geweke (1982), care se poate descompune pe frecvențe Breitung și Candelon (2006) (Capitolul 11)

$$F_{x \rightarrow y} = \ln (\sigma_{\text{restrns}}^2 / \sigma_{\text{complet}}^2)$$

- ▶ $\sigma_{\text{restrns}}^2, \sigma_{\text{complet}}^2$: varianțele reziduale ale regresiei fără și cu lagurile lui x ; $F_{x \rightarrow y} \geq 0$, iar 0 înseamnă absența cauzalității Granger

Cauzalitatea Granger privește predicția




Clive Granger, Premiul Nobel pentru economie
2003

Foto: Olaf Storbeck (2008); CC BY-SA 2.0;
Wikimedia Commons

- Patru moduri în care x cauzează în sens Granger pe y fără să îl cauzeze:
- **un factor comun** cu întârzieri diferite (z omis)
- **anticipări**: prețurile activelor se mișcă înaintea evenimentelor pe care le anticipează (prețurile acțiunilor „cauzează” PIB-ul; [Sims \(1972\)](#))
- **momentul observării**: ore de închidere diferite, agregarea și eșantionarea transformă legături instantanee în legături cu lag
- **erori de măsurare** în y , pe care x ajută să le filtreze
- Și invers: un efect real poate fi invizibil pentru test (neliniar, contemporan sau compensat de reacția politicii)

Un factor comun creează cauzalitate Granger




- Sistem simulat: un factor $w_t = 0,9w_{t-1} + \eta_t$ (AR(1), $\phi = 0,9$); $x_t = w_{t-1} + e_t$, $y_t = w_{t-3} + u_t$; η_t, e_t, u_t : zgomot independent
- x nu are niciun efect asupra lui y; teste cu $p = 2$ laguri (pe perechi) și $p = 4$ (condiționat de w), 500 de repetări

Interpretarea experimentului cu factor comun

- Pe perechi, x „cauzează în sens Granger” pe y în 100% din eșantioane încă de la $T = 100$: x aduce informație despre w cu două perioade înainte de y
- Condiționat de factorul comun, rata de respingere scade la nivelul nominal (4% la $T = 1000$): cauzalitatea Granger este relativă la mulțimea de informație
- Testul invers respinge și el tot mai des (9% la $T = 100$, 75% la $T = 1000$): trecutul lui y este și el informativ despre factorul persistent
- Eșantioanele mai mari fac o concluzie falsă mai sigură, nu mai puțin sigură: puterea nu înseamnă validitate

Relații lead-lag între New York, Frankfurt și București



- Randamente logaritmice zilnice, zile comune de tranzacționare 6 ianuarie 2015 – 18 septembrie 2026 ($T = 2815$); corelația BET la t cu S&P 500 și DAX la $t - k$

Teste Granger pe cei trei indici

Ipoteza ($p = 2$)	Wald (HAC)	p-value	condiționare
S&P 500 $\nrightarrow$ BET	15,3	<0,001	–
BET $\nrightarrow$ S&P 500	4,5	0,105	–
S&P 500 $\nrightarrow$ BET	9,9	0,007	DAX
DAX $\nrightarrow$ BET	1,6	0,449	–
S&P 500 $\nrightarrow$ DAX	18,3	<0,001	–

- Statistica Wald clasică (fără HAC) pentru S&P 500 $\rightarrow$ BET este 34,3: ignorarea heteroscedasticității ar dubla în mod artificial dovezile
- Interpretare: New York se închide după București și Frankfurt; corelația la lagul 1 (0,11) este informație sosită după închiderea Bucureștiului, nu un efect al prețurilor americane asupra firmelor românești
- DAX, care se închide odată cu Bucureștiul, are corelație contemporană (0,43) și niciun efect cu lag: momentul observării creează rezultatul Granger

Rezultate potențiale pentru serii de timp (1/2)

- ▣ **Traectoria tratamentului:** șirul tratamentelor (sau al șocurilor) $w_{1:T} = (w_1, \dots, w_T)$ [Rambachan și Shephard \(2021\)](#), [Bojinov și Shephard \(2019\)](#)
 - ▶ w_t : tratamentul la t , binar (politica aplicată sau nu) sau continuu (mărimea unui șoc)
- ▣ **Rezultatul potențial** $Y_t(w_{1:T})$: valoarea pe care ar avea-o Y_t dacă traectoria tratamentului ar fi $w_{1:T}$
 - ▶ se observă doar rezultatul potențial al traectoriei care a avut loc efectiv
- ▣ **Non-anticiparea:** rezultatul de azi depinde doar de tratamentele de pînă azi

$$Y_t(w_{1:T}) = Y_t(w_{1:t})$$

- ▶ anunțurile o încalcă, dacă anunțul însuși nu este definit ca tratament

Rezultate potențiale pentru serii de timp (2/2)

- **Efectul cauzal dinamic** la orizontul h : modificarea lui Y_{t+h} când se schimbă doar tratamentul de la t , din w' în w

$$\tau_{t,h} = Y_{t+h}(w_{1:t-1}, w, w_{t+1:t+h}) - Y_{t+h}(w_{1:t-1}, w', w_{t+1:t+h})$$

- ▶ tratamentele anterioare $w_{1:t-1}$ și cele ulterioare $w_{t+1:t+h}$ sînt menținute fixe
- ▶ se observă o singură istorie: doar mediile în timp (sau pe unități) ale lui $\tau_{t,h}$ sînt estimabile
- **Rambachan și Shephard (2021)**: presupunem că w_t este **secvențial la fel de bun ca aleator**, adică independent de rezultatele potențiale, condiționat de trecut
 - ▶ atunci răspunsul la impuls și coeficientul proiecției locale sînt medii ponderate ale lui $\tau_{t,h}$, fără a presupune liniaritatea
- Partea dificilă nu este niciodată regresia, ci afirmația că șocul nu poate fi prezis din rezultatele potențiale

Identificarea efectelor cauzale dinamice în macroeconomie

- **Șocuri narative și de înaltă frecvență** ca instrumente: proiecții locale [Jordà \(2005\)](#) și proxy SVAR [Stock și Watson \(2018\)](#) (Capitolul 3)
 - ▶ instrumentul trebuie să fie relevant, exogen contemporan și necorelat cu valorile anterioare și viitoare ale celorlalte șocuri [Stock și Watson \(2018\)](#)
- **Scoruri de propensitate pentru politică:** [Angrist, Jordà și Kuersteiner \(2018\)](#) modelează decizia Fed pe baza prognozelor pe care le avea și reponderează rezultatele (ponderare prin inversul probabilității)
 - ▶ identificare prin selecție pe variabile observate: mulțimea de informație a Fed este observată prin Greenbook
- **Experimente pe serii de timp:** [Bojinov și Shephard \(2019\)](#) dau teste exacte de randomizare pentru o unitate tratată la momente aleatoare (experimente de tranzacționare)
- Proiecțiile locale și VAR estimează aceleași răspunsuri în populație [Plagborg-Møller și Wolf \(2021\)](#): alegerea privește deplasarea și varianța, nu identificarea

Entropia de transfer (1/2)

- ▣ **Schreiber (2000)**: informația pe care trecutul lui x o adaugă despre y_t , dincolo de trecutul lui y

$$TE_{x \rightarrow y} = I(y_t; x_{t-1}^{(l)} | y_{t-1}^{(k)}) = \mathbb{E} \left[\ln \frac{p(y_t | y_{t-1}^{(k)}, x_{t-1}^{(l)})}{p(y_t | y_{t-1}^{(k)})} \right] \geq 0$$

- ▣ **Notățiile**

- ▶ $y_{t-1}^{(k)} = (y_{t-1}, \dots, y_{t-k})$: ultimele k valori ale lui y ; $x_{t-1}^{(l)}$: ultimele l valori ale lui x
- ▶ $p(\cdot | \cdot)$: o densitate condiționată; $I(A; B | C)$: informația mutuală condiționată a lui A și B , dat C , în nats (logaritm natural)
- ▣ $TE_{x \rightarrow y} = 0$ dacă și numai dacă x nu adaugă nimic distribuției predictive a lui y
 - ▶ non-cauzalitate Granger în distribuție, nu doar în medie

Entropia de transfer (2/2)


- ▣ **Cazul gaussian** Barnett, Barrett și Seth (2009): entropia de transfer este jumătate din măsura Geweke, deci testul Granger liniar este un test TE

$$TE_{x \rightarrow y} = \frac{1}{2} \ln (\sigma_{\text{restrns}}^2 / \sigma_{\text{complet}}^2) = \frac{1}{2} F_{x \rightarrow y}$$

► demonstrația în [► Anexă](#)

- ▣ **Estimarea neparametrică**: estimatori cu k cei mai apropiați vecini Kraskov, Stögbauer și Grassberger (2004), Frenzel și Pompe (2007)
 - densitățile sînt înlocuite cu distanțele pînă la cei mai apropiați vecini în spațiul comun
 - semnificația prin permutarea sursei pe blocuri, care păstrează autocorelația ei
- ▣ Aceleași rezerve ca la Granger: un flux de informație nu este o intervenție

O legătură neliniară pe care testul Granger linear o ratează



- Simulare: $y_t = 0,4y_{t-1} + 0,6(x_{t-1}^2 - 1) + u_t$, x un AR(1) gaussian cu varianța 1, u_t zgomot cu distribuția Normală standard, $T = 1000$
- $x_{t-1}^2 - 1$ are media zero și nu este corelat cu x_{t-1} ; TE kNN cu $k = 5$ vecini, 199 de permutări pe blocuri

Interpretarea entropiei de transfer

- ▣ Granger liniar: p-value 0,86; TE gaussiană $0,05 \times 10^{-3}$ nats: efectul simetric se anulează în medie într-o regresie liniară
- ▣ TE kNN $x \rightarrow y$: 0,189 nats, p prin permutare 0,005; direcția inversă $-0,001$ (p 0,76); fără legătură 0,021 (p 0,26)
- ▣ Pe piețele de pe slide-ul anterior, TE gaussiană de la S&P 500 la BET este $6,1 \times 10^{-3}$ nats: semnificativă, dar foarte mică ca informație
- ▣ TE cere mult mai multe date decât Granger și o alegere atentă a lui k , a lungimii istoriilor și a blocurilor de permutare; preînregistrați-le

Recapitulare: cauzalitatea Granger și efectele cauzale

- ▣ Cauzalitatea Granger înseamnă predictibilitate suplimentară relativ la o mulțime de informație; lărgirea mulțimii o poate crea sau distruge
- ▣ Un efect cauzal cere rezultate potențiale, non-anticipare și o alocare la fel de bună ca una aleatoare, condiționat de trecut
- ▣ Entropia de transfer extinde Granger la distribuții; pentru procese gaussiene cele două coincid

Grafurile seriilor de timp (1/2)

- **Nodurile** X_t^i : variabila i la momentul t ; o **săgeată** $X_{t-\tau}^i \rightarrow X_t^j$ când $X_{t-\tau}^i$ este o cauză directă a lui X_t^j , dat fiind restul trecutului [Runge et al. \(2019b\)](#)
 - ▶ $\tau \geq 1$: lagul legăturii; $\tau_{\max}$: lagul maxim considerat
 - ▶ graful este același la orice t (staționaritate cauzală); săgețile merg doar înainte în timp
- Trei ipoteze transformă independențele în săgeți [Spirtes, Glymour și Scheines \(2000\)](#)
 - ▶ **Markov cauzal**: fiecare variabilă este independentă de non-efectele ei, dați părinții ei (cauzele directe)
 - ▶ **fidelitatea**: nicio independență nu apare prin compensarea efectelor
 - ▶ **suficiența cauzală**: nu există cauze comune ascunse

Grafurile seriilor de timp (2/2)

- Sub aceste ipoteze, o săgeată este o dependență condiționată de întregul trecut

$$X_{t-\tau}^i \rightarrow X_t^j \iff X_{t-\tau}^i \not\perp X_t^j \mid X_t^- \setminus \{X_{t-\tau}^i\}$$

- ▶ $\perp$: independență ($\not\perp$: dependență); X_t^- : toate variabilele la lagurile $1, \dots, \tau_{\max}$ înainte de t
- ▶ acesta este testul Granger condiționat complet (VAR)
- Cu N variabile și $\tau_{\max}$ laguri, mulțimea de condiționare are $N\tau_{\max}$ elemente
- ▶ puterea testului scade drastic în dimensiune mare: motivația pentru PCMC

PCMCI


- ▣ **Runge et al. (2019a)**: doi pași, fiecare o succesiune de teste de independență condiționată (aici corelația parțială; sînt posibile și teste neliniare)
- ▣ **PC1** (selecția condițiilor), pentru fiecare X_t^j
 - ▶ se pornește de la toți candidații cu lag; se elimină cei independenți de X_t^j , dați cei mai puternici p dintre ceilalți, $p = 1, 2, \dots$
 - ▶ rezultatul $\hat{P}(X_t^j)$ este o supramulțime a părinților lui X_t^j

- ▣ **MCI** (independența condiționată momentană): fiecare legătură se testează dați părinții ambelor capete

$$X_{t-\tau}^i \perp X_t^j \mid \hat{P}(X_t^j) \setminus \{X_{t-\tau}^i\}, \hat{P}(X_{t-\tau}^i)$$

- ▶ condiționarea pe părinții **sursei** $X_{t-\tau}^i$ îi elimină autocorelația: rata alarmelor false rămîne aproape de α
- ▶ mulțimile de condiționare rămîn mici, deci puterea se păstrează în dimensiune mare
- ▣ Factorii de confuzie ascunși, legăturile contemporane, nestaționaritatea și erorile de măsurare anulează garanțiile; rezultatul este o ipoteză despre un graf

PCMRI față de corelație și VAR complet




- Un sistem cunoscut cu laguri (un factor comun persistent, lanțuri și un colizor), $\tau_{\max} = 3$, $\alpha = 0,01$, 50 de repetări;
dreapta: 14 serii AR(1) independente în plus

Interpretarea experimentului de descoperire

- ▣ Corelațiile cu lag găsesc majoritatea legăturilor reale, dar semnalează 0,605 dintre cele absente: autocorelația și factorul comun fac totul corelat
- ▣ Șase variabile, $T = 500$: VAR complet și PCMCI sînt echivalente (putere 1,00 și 1,00; alarme false 0,013 și 0,017)
- ▣ Douăzeci de variabile, $T = 150$: VAR condiționează pe 60 de regresori, iar puterea lui scade la 0,78; PCMCI păstrează 0,94, cu alarme false 0,012
- ▣ Avantajul PCMCI ține de dimensiunea mare; în sisteme mici un VAR bine specificat este suficient

Un graf descoperit al volatilității piețelor



- PCMCi pe logaritmul varianțelor realizate săptămânale (suma pătratelor randamentelor zilnice), 13 ianuarie 2008 – 20 septembrie 2026, $T = 973$ de săptămîni, $\tau_{\max} = 2$, $\alpha = 0,01$; săptămînilor elimină ordinea închiderilor zilnice

Interpretarea grafului volatilității

- ▣ Testele de corelație cu lag sînt semnificative pentru 56 dintre cele 60 de legături încrucișate posibile; PCMCi păstrează 8
- ▣ Volatilitatea este un factor comun: cea mai mare parte a dependenței brute se explică prin propriul trecut al fiecărei piețe și prin șocul global comun din aceeași săptămînă
- ▣ Săgețile rămase sînt corelații parțiale mici; transmițerile contemporane din aceeași săptămînă sînt invizibile pentru o analiză doar cu laguri
- ▣ Un factor global ascuns (știri, VIX) încalcă suficiența cauzală: citești graful ca pe o hartă a legăturilor predictive, nu a mecanismelor de transmitere

Convergent cross mapping



George Sugihara

Foto: J Park (2015); CC BY-SA 4.0;


Wikimedia Commons

- Dinamici deterministe cuplate: separabilitatea lui Granger nu mai funcționează, deoarece informația cauzei se află deja în efect [Sugihara et al. \(2012\)](#)
- Takens [Takens \(1981\)](#): vectorii cu întârziere ai lui y reconstruiesc atractorul întregului sistem

$$M_y = \{(y_t, y_{t-\tau}, \dots, y_{t-(E-1)\tau})\}$$

- ▶ E : dimensiunea de scufundare; τ : întârzierea dintre coordonate
- Dacă x îl influențează pe y , vecinii unui punct de pe M_y identifică x_t : se **estimează încrucișat** x din M_y
 - ▶ proiecția simplex: o medie ponderată a lui x în cei $E + 1$ vecini cei mai apropiați; abilitatea: corelația ρ dintre estimatie și valoarea reală
- Criteriul: abilitatea trebuie să **conveargă** (să crească) cu dimensiunea bibliotecii L , numărul de puncte folosite pentru M_y
- Atenție la direcție: abilitatea $M_y \rightarrow x$ este dovadă pentru $x \rightarrow y$

Estimarea încrucișată: o cuplare și un factor periodic comun



- Aplicațiile logistice cuplate din [Sugihara et al. \(2012\)](#): $x_{t+1} = x_t(r_x - r_x x_t - \beta_{xy} y_t)$, $y_{t+1} = y_t(r_y - r_y y_t - \beta_{yx} x_t)$
- $r_x = 3,8$, $r_y = 3,5$: ratele de creștere (regim haotic); $\beta_{yx} = 0,32$: efectul lui x asupra lui y ; $\beta_{xy} = 0$: niciun efect al lui y asupra lui x ; dreapta: două aplicații necuplate cu același factor periodic; $E = 2$

Interpretarea estimării încrucișate

- Stînga: abilitatea pentru $x \rightarrow y$ crește de la 0,47 ($L = 25$) la 0,98 ($L = 800$); direcția inversă rămîne în jur de 0,41: tiparul publicat
- Dreapta: nicio cuplare, totuși ambele direcții ajung la 0,999 și 0,999: un factor periodic comun sincronizează aplicațiile, iar CCM raportează cauzalitate în ambele sensuri
- Critici cunoscute: sezonabilitate și sincronizare [Baskerville și Cobey \(2017\)](#), zgomot și factori externi [Mønster et al. \(2017\)](#), alegerea lagului [Ye et al. \(2015\)](#)
- Folosiți CCM pentru sisteme neliniare cu zgomot redus, cu teste pe serii surogat care păstrează sezonabilitatea; niciodată ca detector automat de cauzalitate pentru serii economice

Recapitulare: descoperirea relațiilor cauzale

- Un graf descoperit este la fel de bun ca ipotezele Markov cauzal, fidelitate și suficiență; factorii comuni ascunși sînt regula în economie
- PCMCI controlează alarmele false sub autocorelație și păstrează puterea în dimensiune mare
- CCM vizează cuplarea deterministă; sincronizarea și factorii comuni produc legături false în ambele sensuri

Serii de timp întrerupte (1/2)

- O singură serie, o intervenție la T_0 Lopez Bernal, Cummins și Gasparrini (2017); pasul 1: se modelează perioada anterioară

$$y_t = f(t, \text{sezon}, x_t; \theta) + u_t, \quad t \leq T_0$$

- ▶ f : trendul, efectele sezoniere și covariatele x_t , cu parametrii θ ; u_t : eroarea

- Pasul 2: efectul este diferența dintre rezultat și modelul extrapolat

$$\hat{\tau}_t = y_t - f(t, \cdot; \hat{\theta}), \quad t > T_0$$

- ▶ regresia segmentată este cazul particular cu variabile dummy de nivel și de pantă după T_0

- **Identificarea**

- ▶ nimic altceva nu se schimbă la T_0 ; modelul perioadei anterioare ar fi continuat; nicio anticipare

Serii de timp întrerupte (2/2)

- ▣ **Inferența cu erori dependente:** varianța efectului cumulat pe n perioade

$$\text{Var}\left(\sum_{t=T_0+1}^{T_0+n} \hat{\tau}_t\right) \approx n\Omega + a' \hat{V}_\theta a$$

- ▶ Ω : varianța pe termen lung a lui u_t ([Capitolul 0](#)); $\hat{V}_\theta$: covarianța lui $\hat{\theta}$; a : suma regresorilor lui f pe cele n perioade
- ▶ primul termen: zgomotul rezultatelor; al doilea: eroarea de estimare a contrafactualului
- ▣ Cu erori AR(1), autocorelația ρ și $\sigma^2 = \text{Var}(u_t)$

$$\Omega = \sigma^2 \frac{1 + \rho}{1 - \rho}$$

- ▶ erorile standard i.i.d. sînt prea mici cu factorul $\sqrt{(1 + \rho)/(1 - \rho)}$, de exemplu 1,7 pentru $\rho = 0,5$

România 2025: două măsuri la o lună distanță





Palatul Parlamentului, București

Foto: William John Gauthier (2017); CC BY-SA 2.0;

Wikimedia Commons

- **1 iulie 2025:** se încheie plafonarea prețului electricității pentru gospodării (în vigoare din 2022); plafonarea prețului gazelor continuă
- **7 iulie 2025:** guvernul își asumă răspunderea în Parlament pentru un pachet fiscal (Legea 141/2025, publicată pe 25 iulie)
- **1 august 2025:** cota standard de TVA 19% → 21%; cotele reduse 5% și 9% → 11%; accize majorate
- Momentul singur nu le poate separa; IAPC la cote de taxare constante poate izola partea fiscală
- Întrebarea: cât au adăugat cele două măsuri la inflația din România în anul următor?

O serie de timp întreruptă pentru inflația României



- Inflația IAPC lunară (variația logaritmică); modelul perioadei anterioare: 12 efecte lunare și o treaptă pentru iulie 2021 – iunie 2023, estimat pe 126 de luni până în iunie 2025; efectele iulie 2025 – iunie 2026

Interpretarea seriei de timp întrerupte

- ▣ Iulie 2025: +1,41 pp peste norma sezonieră; august 2025: +2,11 pp; lunile următoare, în medie +0,25 pp
- ▣ Efectul cumulat pe douăsprezece luni 6,0 pp; eroarea standard 1,55 cu erori i.i.d., 1,98 cu HAC (autocorelația reziduurilor 0,33, varianța pe termen lung de $1,63 \sigma^2$)
- ▣ Contrafactualul ITS este norma sezonieră proprie a României: ignoră tot ce s-a mai întâmplat în Europa după iunie 2025
- ▣ Pentru a elimina șocurile comune este nevoie de un grup de control: controlul sintetic din secțiunea 5 folosește 26 de țări UE


Studii de eveniment cu erori dependente

- MacKinlay (1997), **modelul de piață** estimat pe zilele $[-250, -11]$ dinaintea evenimentului

$$r_t = \alpha + \beta r_t^m + \varepsilon_t, \quad AR_t = r_t - \hat{\alpha} - \hat{\beta} r_t^m, \quad CAR[0, k] = \sum_{t=0}^k AR_t$$

- ▶ r_t : randamentul activului; r_t^m : randamentul pieței; AR_t : randamentul anormal; $CAR[0, k]$: randamentul anormal cumulat pe zilele $0-k$
- Varianța CAR
 - ▶ $(k+1)\sigma^2$ sub erori i.i.d.; $(k+1)\Omega$ cu corelație serială (Ω : varianța pe termen lung)
 - ▶ varianța indusă de eveniment și evenimentele grupate cer corecții transversale sau bootstrap
- Identificarea: evenimentul este o surpriză în ziua 0 și nimic altceva nu s-a întâmplat
 - ▶ știrile anticipate sînt încorporate în preț înaintea ferestrei
- Aici: indicele BET față de Euro Stoxx 50, patru evenimente politice și fiscale din România în 2024–2025, fereastra $[0, 2]$

Acțiunile românești în jurul știrilor politice și fiscale



- Randamentul anormal cumulat al BET, normalizat în ziua -1 ; modelul de piață pe Euro Stoxx 50; acțiunile de rating anunțate după închidere, într-o vineri, sînt date în luna următoare

Interpretarea studiului de eveniment

- ▣ Anularea alegerilor prezidențiale (6 decembrie 2024): $CAR[0, 2] +5,9\%$, $t = 5,25$ (i.i.d.) și 5,08 (HAC): piața a încorporat un risc politic mai mic
- ▣ Perspectiva negativă S&P: $-0,5\%$ ($t = -0,33$); decizia ECOFIN: $-0,9\%$ ($t = -0,52$); pachetul fiscal: $-0,2\%$ ($t = -0,14$)
- ▣ Știrile fiscale erau discutate de luni de zile: nicio surpriză în ziua 0, niciun randament anormal; un rezultat nul aici nu spune nimic despre efectul economic al măsurilor
- ▣ Erorile standard HAC și i.i.d. sînt apropiate pentru randamente zilnice (autocorelație mică); diferă pentru date macro lunare (secțiunea anterioară)

Recapitulare: serii de timp întrerupte și studii de eveniment

- ▣ ITS și studiile de eveniment compară o serie cu propriul trecut extrapolat: valide doar dacă nimic altceva nu s-a schimbat în același timp
- ▣ Efectele cumulate cer varianța pe termen lung a erorilor, nu σ^2
- ▣ Anticiparea mută efectul înaintea ferestrei: datarea știrii face parte din identificare

Estimatorul controlului sintetic (1/2)

- Unitățile: $j = 1$ tratată, $j = 2, \dots, J + 1$ **grupul donatorilor**; tratamentul după perioada T_0 [Abadie și Gardeazabal \(2003\)](#), [Abadie, Diamond și Hainmueller \(2010\)](#)
 - $Y_{jt}(1)$, $Y_{jt}(0)$: rezultatele potențiale ale unității j la t , cu și fără tratament
- Ținta: efectul asupra unității tratate după T_0

$$\tau_{1t} = Y_{1t}(1) - Y_{1t}(0), \quad t > T_0$$

- $Y_{1t}(1) = Y_{1t}$ este observat; $Y_{1t}(0)$ trebuie estimat
- Controlul sintetic**: o medie ponderată a donatorilor ține locul lui $Y_{1t}(0)$

$$\hat{Y}_{1t}(0) = \sum_{j=2}^{J+1} w_j Y_{jt}, \quad \hat{\tau}_{1t} = Y_{1t} - \hat{Y}_{1t}(0)$$

- $w_j \geq 0$: ponderea donatorului j , cu $\sum_j w_j = 1$

Estimatorul controlului sintetic (2/2)

- ▣ **Ponderile:** combinația convexă de donatori cea mai apropiată de unitatea tratată după predictorii anteriori tratamentului

$$w^*(V) = \arg \min_w (X_1 - X_0 w)' V (X_1 - X_0 w), \quad w_j \geq 0, \quad \sum_j w_j = 1$$

- ▶ X_1 : vectorul predictorilor anteriori tratamentului ai unității tratate (medii ale rezultatului, covariate); X_0 : matricea acelorași predictorii pentru donatori
- ▶ o problemă de programare pătratică pe simplex: ponderile sînt rare și interpretabile; nicio extrapolare în afara domeniului donatorilor
- ▣ $V = \text{diag}(v)$: importanța fiecărui predictor
 - ▶ aleasă pentru a minimiza MSPE al rezultatului în perioada anterioară (optimizare imbricată, [Abadie, Diamond și Hainmueller \(2011\)](#)) sau prin validare încrucișată pe o perioadă de antrenare și una de validare [Abadie, Diamond și Hainmueller \(2015\)](#)
 - ▶ MSPE: eroarea pătratică medie de predicție; cu toate rezultatele anterioare în X , covariatele nu primesc nicio pondere [Kaul et al. \(2022\)](#)

Fundamentul: modelul factorial

- ▣ Abadie, Diamond și Hainmueller (2010): rezultatele fără tratament urmează un model factorial (efecte fixe interactive Bai (2009))

$$Y_{jt}(0) = \delta_t + \theta_t Z_j + \lambda_t \mu_j + \varepsilon_{jt}$$

- ▶ δ_t : un efect comun al perioadei; Z_j : covariate observate, cu coeficienții variabili în timp θ_t ; λ_t : factori comuni neobservați; μ_j : încărcările neobservate ale unității j ; ε_{jt} : șocuri tranzitorii
- ▶ DiD presupune λ_t constant (trenduri paralele); SC permite factorilor comuni să varieze în timp
- ▣ Dacă ponderile reproduc unitatea tratată înainte de T_0 , $\sum_j w_j Y_{jt} = Y_{1t}$ pentru orice $t \leq T_0$ și $\sum_j w_j Z_j = Z_1$, atunci
 - ▶ deplasarea lui $\hat{\tau}_{1t}$ este mărginită de un termen care **scade când T_0 crește**, relativ la scala lui ε (▶ Anexă)
 - ▶ o potrivire bună pe o perioadă anterioară lungă arată că încărcările μ_j sînt reproduse
- ▣ O perioadă anterioară scurtă cu potrivire perfectă poate însemna supraajustarea zgomotului: marginea este atunci slabă Abadie (2021)

Condiții de aplicabilitate

- ▣ **Înfășurătoarea convexă:** unitatea tratată trebuie să se afle în domeniul donatorilor; altfel nicio combinație convexă nu o reproduce [Abadie \(2021\)](#)
- ▣ **Grupul donatorilor:** unități cu structură asemănătoare, neafectate de tratament (fără efecte de propagare) și fără șocuri mari proprii după T_0
- ▣ **Nicio anticipare:** efectele nu trebuie să înceapă înainte de T_0 ; mutați T_0 la anunț dacă este nevoie
- ▣ **Perioadă anterioară lungă**, cu potrivire bună; **deplasarea de interpolare:** un amestec de donatori foarte diferiți poate să nu semene cu unitatea tratată chiar dacă mediile coincid
- ▣ Raportați: ponderile, echilibrul predictorilor, RMSPE în perioada anterioară, distribuția placebo, omiterea pe rând a donatorilor

Inferența cu o singură unitate tratată

- ▣ **Placebo în spațiu** [Abadie, Diamond și Hainmueller \(2010\)](#): tratamentul se atribuie pe rând fiecărui donator, se reestimează și se calculează raportul

$$r_j = \text{RMSPE}_{\text{post}} / \text{RMSPE}_{\text{pre}}, \quad \text{p-value} = \#\{j : r_j \geq r_1\} / (J + 1)$$

- ▶ RMSPE: rădăcina erorii pătratice medii de predicție a controlului sintetic, înainte (pre) și după (post) T_0 ; un r_j mare: o diferență mare după tratament, relativ la potrivirea anterioară
- ▶ $\#\{\cdot\}$: numărul de unități; cel mai mic p-value posibil este $1/(J + 1)$; exact doar dacă tratamentul este atribuit aleator între unități, altfel o ordonare descriptivă [Firpo și Possebom \(2018\)](#)
- ▣ **Placebo în timp**: un T_0 fictiv în perioada anterioară nu trebuie să dea niciun efect
 - ▶ **omiterea pe rând**: se elimină fiecare donator cu pondere pozitivă și se reestimează
- ▣ **Inferența conformală** [Chernozhukov, Wüthrich și Zhu \(2021\)](#): se testează $H_0: \tau_{1t} = \tau_0$ permutînd reziduurile în timp
 - ▶ permutări pe blocuri pentru dependență; intervale de încredere prin inversarea testului după τ_0

Studiu de caz: costul economic al reunificării Germaniei



Poarta Brandenburg, Berlin, 11 noiembrie 1989

Foto: Peer Grimm, Bundesarchiv Bild 183-1989-1111-009
(1989); CC BY-SA 3.0 de; Wikimedia Commons

- ▣ Abadie, Diamond și Hainmueller (2015): a scăzut reunificarea din 1990 PIB-ul pe locuitor al Germaniei de Vest?
- ▣ Datele Abadie, Diamond și Hainmueller (2014): Germania de Vest și 16 țări OCDE, 1960–2003; predictorii: PIB pe locuitor, deschiderea comercială, inflația, ponderea industriei, școlarizarea, rata investițiilor
- ▣ V prin validare încrucișată: predictorii de antrenare 1971–1980, rezultate de validare 1981–1990; ponderile din predictorii 1981–1990 cu acest V (secțiunea 4 și codul de replicare)
- ▣ Erată (2026): rezultatul este PIB-ul pe locuitor în USD PPC *curenți*, nu în USD 2002 cum este etichetat în articol


Replicare: ponderile și echilibrul predictorilor

Donator	replicare	ADH, tabelul 1
Austria	0,42	0,42
Statele Unite	0,22	0,22
Japonia	0,16	0,16
Elveția	0,11	0,11
Țările de Jos	0,09	0,09

Predictor	Germania de Vest	sintetic	media OCDE
PIB pe locuitor	15809	15805	13669
Deschidere comercială	56,8	56,9	59,8
Inflația	2,6	3,5	7,6
Ponderea industriei	34,5	34,4	33,8
Școlarizare	55,5	55,3	38,7
Rata investițiilor	27,0	27,0	25,9

- V ales prin validare încrucișată și programarea pătratică reproduc ponderile publicate cu două zecimale; toți ceilalți donatori primesc pondere zero
- Media simplă OCDE diferă la fiecare predictor: comparația neponderată ar fi deplasată

Germania de Vest și controlul ei sintetic






□ Stînga: PIB pe locuitor (PPC, USD curenți); dreapta: diferența; RMSPE înainte de 1990: 121 USD

Interpretarea replicării germane

- Germania de Vest sintetică urmărește seria reală timp de treizeci de ani (1960–1989), apoi crește mai repede
- Diferența medie 1990–2003: 1588 USD pe locuitor pe an (5,6% din nivelul sintetic); în 2003: 3391 USD (10,5%)
- Lucrarea raportează o reducere de aproximativ 1600 USD pe an, în medie: replicarea coincide
- Donatorii (Austria, SUA, Japonia, Elveția, Țările de Jos) sînt economii bogate, industrializate: ponderile au sens economic, o verificare pe care niciun algoritm nu o face în locul nostru

Testele placebo pentru cazul german



- Stînga: raportul RMSPE după/înainte de 1990 cînd fiecare țară este tratată pe rînd (ADH 2015, figura 6); centru: reunificarea mutată în 1975 (ca în figura 4, SC doar pe rezultat); dreapta: cîte un donator omis (figura 5)

Interpretarea testelor placebo germane

- Germania de Vest are cel mai mare raport (16,2; următoarea: Norvegia, 9,2): p-value-ul prin permutare $1/17 = 0,059$, cea mai mică posibilă
- Reunificare placebo în 1975 (SC doar pe rezultat, 1960–1974, RMSPE anterior 19 USD): Germania de Vest crește mai repede decât controlul sintetic (diferența medie +9,9% pînă în 1990): nu apare niciun cost fals
- Cu predictorii publicați pentru 1975, V ales prin validare încrucișată nu este identificat: un punct de pornire dacă ca donator Austria, cel mai bun dintre opt dacă Statele Unite [Klößner et al. \(2018\)](#)
- Omiterea oricărui donator păstrează o diferență negativă în 2003, între 2965 și 5138 USD: rezultatul nu depinde de o singură țară
- Cu 17 unități, testul de permutare nu poate da $p < 0,059$

Studiu de caz: dublura Brexit





Numărarea voturilor la referendumul privind UE, 23
iunie 2016

Foto: [Steve Bowbrick \(2016\)](#); CC BY 2.0; [Wikimedia Commons](#)

- [Born et al. \(2019\)](#): referendumul din 23 iunie 2016 ca experiment natural; rezultat: PIB-ul real al Regatului Unit
- Secțiunea 2.1: 23 de donatori OCDE, PIB real trimestrial normalizat la 1 în 1995, perioada anterioară T1 1995 – T2 2016, plus mediile a șase covariate; ponderile publicate (tabelul 2): Statele Unite 0,51; Italia 0,17; Noua Zeelandă 0,14; Ungaria 0,11; Germania 0,05
- Rezultatul publicat: producția Regatului Unit cu 2,4% sub dublură la sfârșitul lui 2018; semnificativ după testul de instabilitate la sfârșitul eșantionului al lui [Andrews \(2003\)](#)
- Replicarea noastră: aceiași donatori și aceeași fereastră, ediția curentă a datelor OCDE (pînă în T2 2026), doar traiectoria PIB (fără covariate)

Dublura pe datele de azi



- Stînga: PIB-ul real al Regatului Unit și dublura lui (% față de T2 2016), cu dublurile voturilor fictive din fiecare trimestru T1 2010 – T1 2016; dreapta: cele mai mari 12 rapoarte RMSPE după/înainte dintre cele 24 de țări

Interpretarea replicării Brexit

- Ponderile pe datele de azi: Statele Unite 0,36; Japonia 0,19; Canada 0,16; Portugalia 0,10; Ungaria 0,09; dublura se schimbă odată cu ediția datelor
- Diferența: 0,1% în T4 2017, -1,5% în T4 2018 (publicat: -2,4%), -2,5% în T4 2019; abaterea standard înainte de vot 0,51%
- Regatul Unit este pe locul 11 din 24 în testele placebo pe țări; cele 25 de teste placebo în timp dau diferențe în T4 2018 între -4,3% și 1,9%: pe datele revizuite dovezile sînt mult mai slabe
- O replicare schimbă datele (revizuirii), specificația (fără covariate) și inferența (permutare în locul testului de la sfîrșitul eșantionului): raportați fiecare abatere separat

Recapitulare: controlul sintetic

- ▣ O combinație convexă de donatori ajustată pe o perioadă lungă anterioară; justificată de un model factorial; ponderi rare și transparente
- ▣ Inferența prin placebo în spațiu și în timp, omiterea pe rând a donatorilor, metode conformale; $p \geq 1/(J+1)$
- ▣ Reunificarea Germaniei se replică exact; diferența Brexit este sensibilă la revizuirea datelor și la specificație

Termenul liber și augmentarea

- ▣ **SC cu termen liber** Doudchenko și Imbens (2016), Ferman și Pinto (2021): permite o diferență constantă de nivel c între unitatea tratată și donatori

$$\hat{Y}_{1t}(0) = c + \sum_j w_j Y_{jt}$$

- ▶ ponderile se ajustează pe rezultatele anterioare minus media anterioară a fiecărei unități
- ▶ rezolvă partea de nivel a problemei înfășurătorii convexe; consistent cu potrivire imperfectă când factorii sînt staționari Ferman și Pinto (2021)
- ▣ **SC augmentat** Ben-Michael, Feller și Rothstein (2021): corectează estimăția SC cu dezechilibrul rămas al predictorilor, printr-o regresie ridge

$$\hat{Y}_{1t}^{\text{aug}}(0) = \sum_j \hat{w}_j Y_{jt} + \left(X_1 - \sum_j \hat{w}_j X_j \right)' \hat{\eta}_t$$

- ▶ $\hat{w}_j$: ponderile SC; X_j : rezultatele anterioare ale unității j ; $\hat{\eta}_t$: coeficienții regresiei ridge a lui Y_{jt} pe X_j , între donatori, cu penalizarea λ
- ▶ echivalent cu ponderile $\hat{w} + X_0(X_0'X_0 + \lambda I)^{-1}(X_1 - X_0'\hat{w})$, care pot fi negative (extrapolare controlată)
- ▶ $\lambda \rightarrow \infty$ dă SC; $\lambda \rightarrow 0$ dă o regresie a rezultatului; deplasarea scade odată cu dezechilibrul rămas

Diferența în diferențe sintetică (1/2)

- ▣ Arkhangelsky et al. (2021): o regresie cu efecte fixe pe unități și pe perioade, în care unitățile și perioadele sînt ponderate

$$(\hat{\tau}, \hat{\mu}, \hat{\alpha}, \hat{\beta}) = \arg \min \sum_{j,t} (Y_{jt} - \mu - \alpha_j - \beta_t - W_{jt}\tau)^2 \hat{\omega}_j \hat{\lambda}_t$$

- ▶ $W_{jt} = 1$ pentru unitatea tratată după T_0 , 0 altfel; τ : efectul; μ : media generală; α_j : efectele fixe ale unităților; β_t : efectele fixe ale perioadelor
- ▣ **Ponderile unităților** $\hat{\omega}_j$: SC cu termen liber și penalizare ridge
 - ▶ penalizarea $\zeta^2 T_0 \|\omega\|^2$, cu $\zeta = (N_{\text{tr}} T_{\text{post}})^{1/4} \hat{\sigma}$; N_{tr} : unitățile tratate; T_{post} : perioadele de după; $\hat{\sigma}$: nivelul zgomotului controalelor
- ▣ **Ponderile perioadelor** $\hat{\lambda}_t$: perioadele anterioare care prezic cel mai bine media controalelor după tratament


Diferența în diferențe sintetică (2/2)

- Trei estimatori ca și cazuri particulare
 - ▶ DiD: ω și λ uniforme
 - ▶ SC: doar ponderile unităților ω (λ uniforme), fără efect fix al unității
 - ▶ SDID: ambele seturi de ponderi, ambele efecte fixe
- O singură unitate tratată: eroarea standard prin placebo
 - ▶ fiecare control joacă pe rând rolul unității tratate; abaterea standard a estimațiilor placebo este eroarea standard (algoritmul 4)

România 2025: designul controlului sintetic

- ▣ Rezultatul: inflația IAPC anuală (pp), $100(\ln P_t - \ln P_{t-12})$, Eurostat; unitatea tratată: România; donatori: celelalte 26 de țări UE
 - ▶ P_t : indicele prețurilor IAPC în luna t ; pp: puncte procentuale
 - ▶ rata anuală elimină sezonalitatea și face vizibil un șoc al nivelului prețurilor exact douăsprezece luni
- ▣ Perioada anterioară: iulie 2023 – iunie 2025 (24 de luni, după valul 2021–2023); tratament din iulie 2025; fereastra efectului iulie 2025 – iunie 2026
 - ▶ o falsificare încorporată: după ce saltul nivelului prețurilor iese din fereastra de 12 luni (august 2026), diferența trebuie să dispară
- ▣ Estimatori: SC, SC cu termen liber, SC augmentat ridge cu termen liber, SDID; inferența: placebo în spațiu
- ▣ Amenințări: măsurile proprii de energie și fiscale ale altor țări; anticiparea majorării TVA; România în afara domeniului donatorilor

Patru contrafactice pentru inflația României




□ Stînga: România și cele patru contrafactice estimate; dreapta: diferențele; linia verticală: iunie 2025; date pînă în august 2026

Interpretarea celor patru estimatori

Estimator	RMSPE anterior	august 2025	media iul. 2025 – iun. 2026	august 2026
SC	1,45	3,70	4,18	2,73
SC cu termen liber	0,23	2,53	2,70	0,22
SC augmentat	0,09	2,38	2,78	1,01
SDID	–	2,62	2,75 (se 0,70)	0,26

- SC clasic pune toată ponderea pe Croația 0,85; Ungaria 0,15: România se află în afara înfășurătorii convexe, potrivirea anterioară este slabă, iar efectul este supraestimat
- Cu termen liber potrivirea este bună (ponderi Franța 0,38; Slovenia 0,25; Suedia 0,13; Malta 0,10, ...); SC augmentat ($\lambda = 1$, 9 ponderi negative) și SDID sînt de acord: 2,7–2,8 pp pe douăsprezece luni
- Falsificarea: în august 2026 diferența scade la 0,22 (SC cu termen liber) și 0,26 (SDID); SC augmentat păstrează 1,01, prețul extrapolării cu ponderi negative

Inferența prin placebo pentru România




- SC cu termen liber aplicat pe rând fiecărei țări UE; stînga: diferențele; dreapta: cele mai mari 12 rapoarte RMSPE după/înainte pe iulie 2025 – iunie 2026

Interpretarea testelor placebo pentru România

- România are cel mai mare raport (12,0; următoarea Franța, 4,7): $p = 1/27 = 0,037$
- Nicio țară placebo nu are un salt de această mărime în iulie–august 2025: efectul nu este un șoc european comun
- P-value-ul prin permutare tratează România ca pe una dintre 27 de unități interschimbabile; este o măsură a rarității, nu o afirmație de încredere care decurge din eșantionare
- Măsurile altor țări din fereastră (schimbări fiscale, încheierea propriilor plafonări) deplasează efectul spre zero dacă au crescut inflația acolo

Ponderea componentei fiscale



- Stînga: IAPC al României și IAPC la cote de taxare constante ([Eurostat \(2026b\)](#)); dreapta: diferența totală, diferența inflației la taxe constante (aceiași SC cu termen liber pe toate țările) și componenta fiscală

Interpretarea descompunerii fiscale

- Indicele la taxe constante presupune transmiterea completă și imediată a modificărilor fiscale: componenta fiscală crește cu 2,09 pp în august 2025, când a crescut TVA
- Media pe douăsprezece luni: total 2,70 pp = componenta fiscală 1,95 pp + diferența la taxe constante 0,40 pp: aproximativ 72% din efect este fiscal mecanic
- Partea nefiscală are maximum în iulie 2025 (0,96 pp): încheierea plafonării electricității, care este un preț, nu o taxă
- Transmiterea TVA în prețurile de consum este adesea incompletă și asimetrică [Benedek et al. \(2020\)](#); indicele la taxe constante este un reper contabil, nu o transmitere măsurată

Adoptarea eşalonată şi efectele fixe bidirecţionale (1/2)

- ▣ Multe unităţi adoptă la date diferite g (cohorta lor); regresia TWFE statică

$$Y_{it} = \alpha_i + \beta_t + \tau D_{it} + u_{it}$$

- ▶ $D_{it} = 1$ dacă unitatea i este tratată la t ; α_i, β_t : efectele fixe ale unităţilor şi ale perioadelor; τ : un singur efect al tratamentului
- ▣ Goodman-Bacon (2021): $\hat{\tau}$ este o medie ponderată a tuturor DiD 2×2
 - ▶ inclusiv a celor „interzise”, care folosesc unităţi deja tratate drept control
 - ▶ cu efecte care cresc în timp, unele ponderi sînt negative de Chaisemartin şi D'Haultfœuille (2020): $\hat{\tau}$ poate avea chiar semnul greşit


Adoptarea eşalonată şi efectele fixe bidirecţionale (2/2)

- Callaway şi Sant'Anna (2021): efecte pe grup şi perioadă, fiecare comparat doar cu unităţile niciodată tratate

$$ATT(g, t) = \mathbb{E}[Y_t - Y_{g-1} \mid G = g] - \mathbb{E}[Y_t - Y_{g-1} \mid \text{niciodată tratat}]$$

- ▶ G : data de adoptare a unei unităţi; Y_{g-1} : rezultatul din ultima perioadă dinaintea adoptării; ATT : efectul mediu al tratamentului asupra unităţilor tratate
- ▶ apoi agregare după expunere ($t - g$) sau după cohortă
- Metode înrudite: studii de eveniment ponderate prin interacţiuni Sun şi Abraham (2021); un ghid al noii literaturi DiD Roth et al. (2023)
- Testele trendurilor anterioare au putere mică; raportaţi sensibilitatea efectului la încălcarea trendurilor paralele

TWFE față de Callaway și Sant'Anna



- Panel simulat: trei cohorte care adoptă în perioadele 6, 11 și 16 și un grup niciodată tratat; efectele cresc cu expunerea, mai repede pentru cei care adoptă devreme

Interpretarea adoptării eşalonate

- TWFE static: 0,55; efectul mediu real asupra tratatelor: 1,99; Callaway–Sant’Anna: 2,04
- TWFE foloseşte pe cei care adoptă devreme drept control pentru cei care adoptă târziu, în timp ce efectul lor încă creşte: aceste comparaţii scad o parte din efect
- Studiul de eveniment TWFE este distorsionat la expuneri lungi (capătul grupat 3,66 faţă de 2,70); CS dă 2,69
- Cu o singură ţară tratată (România) nu există eşalonare; cu politici la nivelul UE adoptate la date diferite, există

Recapitulare: dincolo de controlul sintetic

- Termenul liber corectează diferențele de nivel; augmentarea ridge corectează dezechilibrul rămas; SDID combină ponderile unităților și ale perioadelor
- România 2025: 2,7–2,8 pp de inflație anuală în plus timp de douăsprezece luni, în mare parte efectul mecanic al TVA, și o falsificare confirmată
- Adoptarea eşalonată invalidează TWFE; folosiți estimatori pe grup și perioadă

Modelul CausallImpact (1/2)

- Brodersen et al. (2015): rezultatul este un trend plus o componentă sezonieră plus o regresie pe serii de control

$$y_t = \mu_t + \gamma_t + \beta' x_t + \varepsilon_t, \quad \mu_{t+1} = \mu_t + \delta_t + \eta_t, \quad \delta_{t+1} = \delta_t + \zeta_t$$

- ▶ μ_t : nivelul local; δ_t : panta locală; γ_t : componenta sezonieră; x_t : serii de control cu coeficienții β ; $\varepsilon_t, \eta_t, \zeta_t$: zgomote independente cu distribuția Normală
- Un model structural de serii de timp Harvey (1989) în formă de spațiu al stărilor, filtrat și netezit prin Kalman (Capitolul 6, Durbin și Koopman (2012))
 - ▶ o distribuție a priori spike-and-slab pe β selectează seriile de control Scott și Varian (2014); distribuția a posteriori se calculează prin MCMC

Modelul CausallImpact (2/2)

- ▣ Estimare pe perioada anterioară; se simulează contrafactualul de după $y_t^{(s)}(0)$ din distribuția predictivă a posteriori, dați x_t observați
 - ▶ s : indicele unei traiectorii simulate; efectele $y_t - y_t^{(s)}(0)$, punctuale și cumulate
 - ▶ intervale de credibilitate din cuantilele efectelor simulate
- ▣ **Identificarea**
 - ▶ seriile de control **nu sînt afectate** de tratament
 - ▶ relația lor cu y rămîne stabilă după T_0

Implementarea folosită

- ▣ statsmodels UnobservedComponents: nivel local + regresie pe seriile de control, verosimilitate maximă pe perioada anterioară
 - ▶ 1000 de traiectorii contrafactuale: parametrii extrași din distribuția lor normală asimptotică, apoi starea simulată înainte de la sfârșitul perioadei anterioare, dați seriile de control observate
- ▣ Diferențe față de pachetul R: fără selecție spike-and-slab, fără MCMC; incertitudinea parametrilor printr-o aproximare gaussiană
 - ▶ versiunea transparentă păstrează fiecare pas vizibil; cu puține serii de control cele două dau intervale asemănătoare
- ▣ Rezultate: efectul mediu cu un interval de 95%, efectul cumulat și probabilitatea din coadă ca media contrafactuală să depășească media observată

Studiu de caz: ETF-urile spot pe Bitcoin din SUA




Un bancomat Bitcoin, Praga

Foto: Perituss (2016); CC0; Wikimedia Commons

- **10 ianuarie 2024:** SEC aprobă unsprezece ETP-uri spot pe Bitcoin SEC (2024); tranzacționarea începe pe 11 ianuarie
- A schimbat aprobarea volatilitatea Bitcoin (cererea instituțională, arbitrajul între spot și ETF)?
- Rezultatul: logaritmul varianței realizate săptămânale a Bitcoin; serii de control: aceeași măsură pentru S&P 500, Nasdaq 100, aur și EUR/USD; perioada anterioară ianuarie 2023 – 7 ianuarie 2024 (53 de săptămâni), după: 25 de săptămâni până în iunie 2024
- Anticipare: BlackRock a depus cererea pe 15 iunie 2023; o instanță a decis în favoarea Grayscale pe 29 august 2023 (liniile punctate)

CausalImpact pentru aprobarea ETF-urilor spot




■ Sus: log RV observat și contrafactual, cu interval de 95%; mijloc: efectul punctual; jos: efectul cumulat

Interpretarea analizei ETF

- Efectul mediu asupra log RV săptămânal: 0,36 (interval de 95% $[-0,87; 1,50]$), probabilitatea din coadă 0,26: nicio schimbare detectabilă
- Varianța nivelului este mică (0,011) față de cea neregulată (0,94): volatilitatea crypto săptămânală este în mare parte zgomot, iar seriile de control explică puțin
- Rezultatul este în acord cu un studiu publicat: niciun efect asupra volatilității proprii a Bitcoin [Babalos, Bouri și Gupta \(2025\)](#)
- Lipsa dovezilor nu este dovada lipsei: cu acest zgomot, o modificare de 50% a volatilității nu ar fi detectată

Date placebo și alegerea seriilor de control



- Aceeași analiză cu 14 date fictive de aprobare în 2019–2022 (cîte 53 de săptămîni înainte și 25 după) și data reală cu aceleași lungimi ale ferestrelor

Interpretarea datelor placebo

- Doar 1 dintre cele 14 intervale placebo exclude zero; estimațiile placebo au abaterea standard 0,97: estimația reală se află în domeniul lor
- Cu Ether ca serie de control suplimentară: 0,18 $[-0,47; 0,87]$; dar Ether poate răspunde el însuși la aprobare: un control tratat deplasează efectul spre zero
- Mutarea lui T_0 la depunerea cererii BlackRock (iunie 2023): $-0,02 [-1,74; 1,62]$: tot nimic, deci anticiparea nu ascunde un efect mare
- Datele placebo calibrează intervalele de credibilitate: dacă multe teste placebo par „semnificative”, modelul este greșit specificat

Recapitulare: BSTS și CausallImpact

- O prognoză în spațiul stărilor a traiectoriei netratate pe baza seriilor de control; incertitudinea vine din parametri și din stări
- Ipoteza esențială privește seriile de control: neafectate și într-o relație stabilă; verificați cu date placebo
- Aprobarea ETF-urilor spot nu a schimbat detectabil volatilitatea Bitcoin; designul nu ar fi putut vedea efecte mici

Double/debiased machine learning pentru serii de timp (1/2)

- Chernozhukov et al. (2018): **modelul parțial liniar**

$$y_t = \theta d_t + g(X_t) + u_t, \quad d_t = m(X_t) + v_t$$

- ▶ d_t : tratamentul; θ : efectul lui; X_t : variabilele de control; g, m : **funcții auxiliare** necunoscute, învățate prin machine learning; u_t, v_t : erori

- **Scorul ortogonal**: se regresează reziduul lui y pe reziduul lui d


$$\psi = (y_t - \ell(X_t) - \theta(d_t - m(X_t)))(d_t - m(X_t)), \quad \ell(X) = \mathbb{E}[y \mid X]$$

- ▶ $\hat{\theta}$ rezolvă $\frac{1}{T} \sum_t \psi_t = 0$; insensibil de ordinul întâi la erorile din ℓ și m

Double/debiased machine learning pentru serii de timp (2/2)

- ▣ **Cross-fitting:** funcțiile auxiliare sînt estimate pe alte subeșantioane decît cel pe care se evaluează ψ
 - ▶ pentru serii de timp se folosesc **blocuri contigue**, cu un interval de separare în jurul blocului omis
 - ▶ eroarea standard dintr-o varianță HAC a lui ψ
- ▣ DML elimină deplasarea din regularizare și supraajustare; nu creează identificare
 - ▶ d_t trebuie să fie neconfundat, dat X_t

DML față de o ajustare liniară



- Date dependente simulate: 10 covariate VAR(1), g și m neliniare, erori AR(1), $\theta = 0,5$, $T = 1000$, 60 de repetări; păduri aleatoare cu cinci blocuri

Interpretarea experimentului DML

- ▣ OLS cu controale liniare: estimația medie 1,07, departe de 0,5: confuzia neliniară nu este eliminată
- ▣ DML: media 0,53, abaterea standard 0,05; intervalele HAC de 95% acoperă valoarea reală în 88% din repetări
- ▣ Deplasarea rămasă provine din erorile pădurilor pe un eșantion finit; scade când T crește
- ▣ În seriile de timp macro, tratamentul este rar neconfundat, dați factorii observați: DML este un instrument pentru etapa de estimare, după ce identificarea a fost argumentată

Identificarea, metodă cu metodă

Metoda	Ipoteza esențială	Verificarea
Granger, PCMCI	nicio cauză comună ascunsă; momentul observării corect; fidelitate	adăugați posibili factori de confuzie; schimbați frecvența
ITS, studiu de eveniment Control sintetic, SDID	nimic altceva nu se schimbă la T_0 ; nicio anticipare model factorial; donatori neafecțați; unitatea tratată în domeniul donatorilor	date placebo; cronologia știrilor potrivirea anterioară, placebo, omiterea pe rând
DiD (eșalonat)	trenduri paralele; nicio anticipare	trenduri anterioare cu analiză de sensibilitate
CausalImpact SVAR, LP, DML	controale neafectate; relație stabilă la fel de bun ca aleator, dat trecutul sau un instrument	date placebo; alte seturi de controale dovezi narative; puterea instrumentului

Raportarea onestă

- ▣ Precizați mărimea țintă (ce efect, asupra cărei unități, pe ce orizont) înainte de a alege metoda
- ▣ Fixați datele tratamentului, ferestrele, donatorii și estimatorii înainte de a privi datele de după tratament; publicați preînregistrarea
- ▣ Raportați fiecare placebo, fiecare specificație și fiecare abatere de la designul publicat; o curbă a specificațiilor le arată împreună
- ▣ Separați incertitudinea statistică (intervalele) de incertitudinea identificării (ipotezele); a doua este de obicei mai mare
- ▣ Citiți [Athey și Imbens \(2017\)](#) și [Abadie \(2021\)](#) înainte de a scrie o evaluare de politică

O întrebare deschisă

- Cît din creșterea inflației din România în 2025–2026 a fost cauzată de încheierea plafonării electricității și de majorarea TVA și cît de robust este răspunsul la alegerea metodei?
 - ▶ formal: H_0 : diferența medie pe iulie 2025 – iunie 2026 este zero; afirmația „între 2 și 3,5 pp” trebuie să fie valabilă pentru orice estimator preînregistrat cu potrivire anterioară bună
 - ▶ infirmată dacă o specificație rezonabilă dă mai puțin de 2 pp sau dacă o țară placebo egalează România
- Miza: politica monetară trebuie să distingă efectele unice asupra nivelului prețurilor de inflația persistentă; efectele de runda a doua determină deciziile privind dobânzile
 - ▶ literatura de pornire: Abadie, Diamond și Hainmueller (2015), Ben-Michael, Feller și Rothstein (2021), Arkhangelsky et al. (2021), Benedek et al. (2020)


Bucla de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează studii recenzate din 2015 încoace care estimează transmiterea TVA în prețurile de consum cu control sintetic sau DiD; dă DOI-urile și transmiterea estimată. Apoi verificați fiecare DOI pe Crossref
 - ▶ **designul:** Scrie o preînregistrare: rezultatul, donatorii, excluderile, perioada anterioară, estimatorii, testele placebo, ce înseamnă un efect robust.
 - ▶ **cod și replicare:** reproduceți întâi ponderile germane (Austria 0,42; SUA 0,22; ...) înainte de a rula ceva pe România
 - ▶ **critica:** Joacă rolul unui recenzent ostil: ce țări UE au avut propriile măsuri de energie sau fiscale în 2025-2026 și cum ar deplasa fiecare estimația?
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ▣ Fiecare referință există și spune ce se afirmă (DOI-ul funcționează, titlul coincide, rezultatul se află în lucrare)
- ▣ Datele politicilor se iau din surse oficiale (Monitorul Oficial, Eurostat, SEC), nu din memoria asistentului
- ▣ Grupul donatorilor exclude țările cu propriile șocuri mari în fereastră, iar excluderile sînt scrise înainte de a vedea rezultatele
- ▣ Testele placebo sînt rulate cu exact același cod și aceleași setări ca estimăția principală
- ▣ O afirmație AI de tipul „controlul sintetic dovedește că TVA a cauzat 3 pp de inflație” se reformulează ca o estimăție cu ipoteze

Mini studiu de caz: curba specificațiilor pentru România



- 48 de specificații: patru estimatori $\times$ trei grupuri de donatori (UE-26, zona euro, UE din afara zonei euro) $\times$ patru perioade anterioare (din 2017, 2019, iulie 2023, 2024; valul 2021–2023 exclus)
- Fără SC clasic: între 2,36 și 3,40 pp, mediana 2,75; SC clasic: mediana 4,47 (potrivire anterioară slabă); 0 specificații dau un efect nepozitiv: ipoteza rezistă

Idee de proiect

- ▣ **Transmiterea taxelor în Europa Centrală și de Est cu controale sintetice:** întâi replicare, apoi extindere
 - ▶ replicați: [Abadie, Diamond și Hainmueller \(2015\)](#) (tabelul 1, figurile 2–5) cu datele publice, apoi estimația pentru România din acest capitol
 - ▶ extindeți: IAPC pe grupe de produse (alimente, energie, servicii) pentru a măsura transmiterea pe cote de TVA; alte episoade (Ungaria 2012, adoptarea euro în Croația în 2023); intervale conformale [Chernozhukov, Wüthrich și Zhu \(2021\)](#)
 - ▶ preînregistrați: donatorii și excluderile, ferestrele, estimatorii, testele placebo, regula de robustețe
- ▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Cauzalitatea Granger și metodele înrudite (TE, PCMC, CCM) descriu structura predictivă; afirmațiile cauzale cer ipoteze despre alocarea tratamentului
- ▣ Seriile întrerupte și studiile de eveniment folosesc propriul trecut al unității; dependența le mărește erorile standard
- ▣ Controlul sintetic și succesorii lui folosesc alte unități; testele placebo sînt inferența, potrivirea pe o perioadă lungă este justificarea
- ▣ Replicarea arată fragilitatea: rezultatul reunificării Germaniei se menține, diferența Brexit depinde de ediția datelor
- ▣ România 2025: un efect robust de 2,7–2,8 pp pe douăsprezece luni, în mare parte TVA mecanic; ETF-urile Bitcoin: niciun efect detectabil asupra volatilității

Autoevaluare

Întrebări

- ▣ De ce poate adăugarea unei variabile la mulțimea de informație să elimine o cauzalitate Granger?
- ▣ Ce obține condiționarea pe părinții sursei în testul MCI?
- ▣ De ce eșuează controlul sintetic clasic pentru inflația României?
- ▣ Care este cel mai mic p-value placebo cu 23 de donatori?
- ▣ De ce poate o estimatie TWFE statică să aibă semnul greșit în cazul adoptării eşalonate?

Urmează:

- ▣ Recapitulare și susținerea proiectelor
- ▣ o sinteză pentru fiecare capitol; proiectul de replicare și susținerea orală

Anexă: marginea deplasării controlului sintetic

- Modelul factorial $Y_{jt}(0) = \delta_t + \lambda_t \mu_j + \varepsilon_{jt}$ (F factori); ponderi cu $\sum_j w_j Y_{jt} = Y_{1t}$, $t \leq T_0$
- Stivim perioada anterioară: $\lambda^P(\mu_1 - \sum_j w_j \mu_j) = -(\varepsilon_1^P - \sum_j w_j \varepsilon_j^P)$; dacă $\lambda^{P'} \lambda^P$ este inversabilă, obținem dezechilibrul încărcărilor
- Atunci $Y_{1t}(0) - \sum_j w_j Y_{jt} = \lambda_t(\lambda^{P'} \lambda^P)^{-1} \lambda^{P'} \sum_j w_j \varepsilon_j^P - \dots + (\varepsilon_{1t} - \sum_j w_j \varepsilon_{jt})$
- Primul termen are media zero doar aproximativ (ponderile depind de ε^P); ADH (2010, anexa B) îl mărginesc printr-o mărime de ordinul $J^{1/p} \bar{m}_p^{1/p} F \bar{\lambda}^2 / (\xi T_0^{1-1/p})$: mică atunci când T_0 este mare relativ la J

Anexă: entropia de transfer gaussiană este jumătate din măsura Geweke

- Pentru variabile gaussiene comune, $I(Y; X | Z) = \frac{1}{2} \ln \frac{\text{Var}(Y | Z)}{\text{Var}(Y | X, Z)}$ (entropia unei variabile gaussiene este $\frac{1}{2} \ln(2\pi e\sigma^2)$)
- Cu $Y = y_t$, $X = x_{t-1}^{(l)}$, $Z = y_{t-1}^{(k)}$, varianțele condiționate sînt varianțele reziduale ale regresiilor Granger restrînsă și completă
- Deci $TE_{x \rightarrow y} = \frac{1}{2} F_{x \rightarrow y}$, iar $2T \cdot \widehat{TE} \approx T\hat{F} \approx W$, forma de raport de verosimilitate a testului Wald Granger Barnett, Barrett și Seth (2009)
- Datele negausiene anulează egalitatea: TE detectează atunci dependențe pe care un test liniar le ratează (secțiunea 1)

Bibliografie (1/5)

- ▣ Abadie, A., Diamond, A., & Hainmueller, J. (2015). Comparative politics and the synthetic control method. *American Journal of Political Science*, 59(2), 495–510. doi:10.1111/ajps.12116
- ▣ Abadie, A., Diamond, A., & Hainmueller, J. (2014). Replication data for: Comparative politics and the synthetic control method. Harvard Dataverse, version 2.1 (CC0); erratum and updated archive, version 3 (2026). doi:10.7910/DVN/24714
- ▣ Abadie, A., Diamond, A., & Hainmueller, J. (2011). Synth: An R package for synthetic control methods in comparative case studies. *Journal of Statistical Software*, 42(13), 1–17. doi:10.18637/jss.v042.i13
- ▣ Abadie, A., Diamond, A., & Hainmueller, J. (2010). Synthetic control methods for comparative case studies: Estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505. doi:10.1198/jasa.2009.ap08746
- ▣ Abadie, A., & Gardeazabal, J. (2003). The economic costs of conflict: A case study of the Basque Country. *American Economic Review*, 93(1), 113–132. doi:10.1257/000282803321455188
- ▣ Abadie, A. (2021). Using synthetic controls: Feasibility, data requirements, and methodological aspects. *Journal of Economic Literature*, 59(2), 391–425. doi:10.1257/jel.20191450
- ▣ Andrews, D. W. K. (2003). End-of-sample instability tests. *Econometrica*, 71(6), 1661–1694. doi:10.1111/1468-0262.00466
- ▣ Angrist, J. D., Jordà, Ò., & Kuersteiner, G. M. (2018). Semiparametric estimates of monetary policy effects: String theory revisited. *Journal of Business & Economic Statistics*, 36(3), 371–387. doi:10.1080/07350015.2016.1204919
- ▣ Arkhangelsky, D., Athey, S., Hirshberg, D. A., Imbens, G. W., & Wager, S. (2021). Synthetic difference-in-differences. *American Economic Review*, 111(12), 4088–4118. doi:10.1257/aer.20190159
- ▣ Athey, S., & Imbens, G. W. (2017). The state of applied econometrics: Causality and policy evaluation. *Journal of Economic Perspectives*, 31(2), 3–32. doi:10.1257/jep.31.2.3
- ▣ Babalos, V., Bouri, E., & Gupta, R. (2025). Does the introduction of US spot Bitcoin ETFs affect spot returns and volatility of major cryptocurrencies? *The Quarterly Review of Economics and Finance*, 102, 102006. doi:10.1016/j.qref.2025.102006
- ▣ Bai, J. (2009). Panel data models with interactive fixed effects. *Econometrica*, 77(4), 1229–1279. doi:10.3982/ECTA6135
- ▣ Barnett, L., Barrett, A. B., & Seth, A. K. (2009). Granger causality and transfer entropy are equivalent for Gaussian variables. *Physical Review Letters*, 103(23), 238701. doi:10.1103/PhysRevLett.103.238701
- ▣ Baskerville, E. B., & Cobey, S. (2017). Does influenza drive absolute humidity? *Proceedings of the National Academy of Sciences*, 114(12), E2270–E2271. doi:10.1073/pnas.1700369114

Bibliografie (2/5)

- ▣ Benedek, D., De Mooij, R. A., Keen, M., & Wingender, P. (2020). Varieties of VAT pass through. *International Tax and Public Finance*, 27(4), 890–930. doi:10.1007/s10797-019-09566-5
- ▣ Ben-Michael, E., Feller, A., & Rothstein, J. (2021). The augmented synthetic control method. *Journal of the American Statistical Association*, 116(536), 1789–1803. doi:10.1080/01621459.2021.1929245
- ▣ Bojinov, I., & Shephard, N. (2019). Time series experiments and causal estimands: Exact randomization tests and trading. *Journal of the American Statistical Association*, 114(528), 1665–1682. doi:10.1080/01621459.2018.1527225
- ▣ Born, B., Müller, G. J., Schularick, M., & Sedláček, P. (2019). The costs of economic nationalism: Evidence from the Brexit experiment. *The Economic Journal*, 129(623), 2722–2744. doi:10.1093/ej/uez020
- ▣ Breitung, J., & Candelon, B. (2006). Testing for short- and long-run causality: A frequency-domain approach. *Journal of Econometrics*, 132(2), 363–378. doi:10.1016/j.jeconom.2005.02.004
- ▣ Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., & Scott, S. L. (2015). Inferring causal impact using Bayesian structural time-series models. *The Annals of Applied Statistics*, 9(1), 247–274. doi:10.1214/14-AOAS788
- ▣ Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230. doi:10.1016/j.jeconom.2020.12.001
- ▣ Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68. doi:10.1111/ectj.12097
- ▣ Chernozhukov, V., Wüthrich, K., & Zhu, Y. (2021). An exact and robust conformal inference method for counterfactual and synthetic controls. *Journal of the American Statistical Association*, 116(536), 1849–1864. doi:10.1080/01621459.2021.1920957
- ▣ de Chaisemartin, C., & D'Haultfoeulle, X. (2020). Two-way fixed effects estimators with heterogeneous treatment effects. *American Economic Review*, 110(9), 2964–2996. doi:10.1257/aer.20181169
- ▣ Doudchenko, N., & Imbens, G. W. (2016). Balancing, regression, difference-in-differences and synthetic control methods: A synthesis. NBER Working Paper 22791. doi:10.3386/w22791
- ▣ Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press. doi:10.1093/acprof:oso/9780199641178.001.0001
- ▣ Eurostat (2026a). Harmonised index of consumer prices (HICP), ECOICOP ver. 2, indices and rates of change, monthly data (prc_hicp_minr). ec.europa.eu
- ▣ Eurostat (2026b). HICP at constant tax rates, monthly data (prc_hicp_ct). European Commission, Luxembourg. ec.europa.eu

Bibliografie (3/5)

- ▣ Eurostat (2026c). Harmonised Index of Consumer Prices (HICP): Methodology. European Commission, Luxembourg. ec.europa.eu
- ▣ Ferman, B., & Pinto, C. (2021). Synthetic controls with imperfect pretreatment fit. *Quantitative Economics*, 12(4), 1197–1221. doi:10.3982/QE1596
- ▣ Firpo, S., & Possebom, V. (2018). Synthetic control method: Inference, sensitivity analysis and confidence sets. *Journal of Causal Inference*, 6(2), 20160026. doi:10.1515/jci-2016-0026
- ▣ Frenzel, S., & Pompe, B. (2007). Partial mutual information for coupling analysis of multivariate time series. *Physical Review Letters*, 99(20), 204101. doi:10.1103/PhysRevLett.99.204101
- ▣ Geweke, J. (1982). Measurement of linear dependence and feedback between multiple time series. *Journal of the American Statistical Association*, 77(378), 304–313. doi:10.1080/01621459.1982.10477803
- ▣ Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277. doi:10.1016/j.jeconom.2021.03.014
- ▣ Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3), 424–438. doi:10.2307/1912791
- ▣ Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. doi:10.1515/9780691218632
- ▣ Harvey, A. C. (1989). *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press. doi:10.1017/CBO9781107049994
- ▣ Hsiao, C., Ching, H. S., & Wan, S. K. (2012). A panel data approach for program evaluation: Measuring the benefits of political and economic integration of Hong Kong with mainland China. *Journal of Applied Econometrics*, 27(5), 705–740. doi:10.1002/jae.1230
- ▣ Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press. doi:10.1017/CBO9781139025751
- ▣ Jordà, Ò. (2005). Estimation and inference of impulse responses by local projections. *American Economic Review*, 95(1), 161–182. doi:10.1257/0002828053828518
- ▣ Kaul, A., Klößner, S., Pfeifer, G., & Schieler, M. (2022). Standard synthetic control methods: The case of using all preintervention outcomes together with covariates. *Journal of Business & Economic Statistics*, 40(3), 1362–1376. doi:10.1080/07350015.2021.1930012
- ▣ Kilian, L., & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*. Cambridge University Press. doi:10.1017/9781108164818

Bibliografie (4/5)

- Klößner, S., Kaul, A., Pfeifer, G., & Schieler, M. (2018). Comparative politics and the synthetic control method revisited: A note on Abadie et al. (2015). *Swiss Journal of Economics and Statistics*, 154, 11. doi:10.1186/s41937-017-0004-9
- Kraskov, A., Stögbauer, H., & Grassberger, P. (2004). Estimating mutual information. *Physical Review E*, 69(6), 066138. doi:10.1103/PhysRevE.69.066138
- Lopez Bernal, J., Cummins, S., & Gasparrini, A. (2017). Interrupted time series regression for the evaluation of public health interventions: A tutorial. *International Journal of Epidemiology*, 46(1), 348–355. doi:10.1093/ije/dyw098
- MacKinlay, A. C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, 35(1), 13–39. jstor.org
- Mønster, D., Fusaroli, R., Tylén, K., Roepstorff, A., & Sherson, J. F. (2017). Causal inference from noisy time-series data: Testing the convergent cross-mapping algorithm in the presence of noise and external influence. *Future Generation Computer Systems*, 73, 52–62. doi:10.1016/j.future.2016.12.009
- Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. doi:10.2307/1913610
- OECD (2026). Quarterly National Accounts: GDP, chain-linked volumes, PPP, seasonally adjusted (DSD_NAMAIN1@DF_QNA). OECD Data Explorer, SDMX API. sdmx.oecd.org
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press. doi:10.1017/CBO9780511803161
- Plagborg-Møller, M., & Wolf, C. K. (2021). Local projections and VARs estimate the same impulse responses. *Econometrica*, 89(2), 955–980. doi:10.3982/ECTA17813
- Rambachan, A., & Shephard, N. (2021). When do common time series estimands have nonparametric causal meaning? Working paper, arXiv:1903.01637. arxiv.org
- Roth, J., Sant'Anna, P. H. C., Bilinski, A., & Poe, J. (2023). What's trending in difference-in-differences? A synthesis of the recent econometrics literature. *Journal of Econometrics*, 235(2), 2218–2244. doi:10.1016/j.jeconom.2023.03.008
- Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688–701. doi:10.1037/h0037350
- Runge, J., Bathiany, S., Boltt, E., Camps-Valls, G., Coumou, D., Deyle, E., Glymour, C., Kretschmer, M., Mahecha, M. D., Muñoz-Marí, J., et al. (2019b). Inferring causation from time series in Earth system sciences. *Nature Communications*, 10, 2553. doi:10.1038/s41467-019-10105-3
- Runge, J., Nowack, P., Kretschmer, M., Flaxman, S., & Sejdinovic, D. (2019a). Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*, 5(11), eaau4996. doi:10.1126/sciadv.aau4996

Bibliografie (5/5)

- ▣ Schreiber, T. (2000). Measuring information transfer. *Physical Review Letters*, 85(2), 461–464. [doi:10.1103/PhysRevLett.85.461](https://doi.org/10.1103/PhysRevLett.85.461)
- ▣ Scott, S. L., & Varian, H. R. (2014). Predicting the present with Bayesian structural time series. *International Journal of Mathematical Modelling and Numerical Optimisation*, 5(1/2), 4–23. [doi:10.1504/IJMMNO.2014.059942](https://doi.org/10.1504/IJMMNO.2014.059942)
- ▣ Sims, C. A. (1972). Money, income, and causality. *American Economic Review*, 62(4), 540–552. [jstor.org](https://www.jstor.org)
- ▣ Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2nd ed.). MIT Press. [doi:10.7551/mitpress/1754.001.0001](https://doi.org/10.7551/mitpress/1754.001.0001)
- ▣ Stock, J. H., & Watson, M. W. (2018). Identification and estimation of dynamic causal effects in macroeconomics using external instruments. *The Economic Journal*, 128(610), 917–948. [doi:10.1111/ecoj.12593](https://doi.org/10.1111/ecoj.12593)
- ▣ Sugihara, G., May, R., Ye, H., Hsieh, C.-h., Deyle, E., Fogarty, M., & Munch, S. (2012). Detecting causality in complex ecosystems. *Science*, 338(6106), 496–500. [doi:10.1126/science.1227079](https://doi.org/10.1126/science.1227079)
- ▣ Sun, L., & Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, 225(2), 175–199. [doi:10.1016/j.jeconom.2020.09.006](https://doi.org/10.1016/j.jeconom.2020.09.006)
- ▣ Takens, F. (1981). Detecting strange attractors in turbulence. In D. Rand & L.-S. Young (Eds.), *Dynamical Systems and Turbulence, Warwick 1980*, Lecture Notes in Mathematics 898, 366–381. Springer. [doi:10.1007/BFb0091924](https://doi.org/10.1007/BFb0091924)
- ▣ Toda, H. Y., & Yamamoto, T. (1995). Statistical inference in vector autoregressions with possibly integrated processes. *Journal of Econometrics*, 66(1–2), 225–250. [doi:10.1016/0304-4076\(94\)01616-8](https://doi.org/10.1016/0304-4076(94)01616-8)
- ▣ U.S. Securities and Exchange Commission (2024). Order granting accelerated approval of proposed rule changes to list and trade bitcoin-based commodity-based trust shares and trust units. Release No. 34-99306, 10 January 2024. [sec.gov](https://www.sec.gov)
- ▣ Xu, Y. (2017). Generalized synthetic control method: Causal inference with interactive fixed effects models. *Political Analysis*, 25(1), 57–76. [doi:10.1017/pan.2016.2](https://doi.org/10.1017/pan.2016.2)
- ▣ Ye, H., Deyle, E. R., Gilarranz, L. J., & Sugihara, G. (2015). Distinguishing time-delayed causal interactions using convergent cross mapping. *Scientific Reports*, 5, 14750. [doi:10.1038/srep14750](https://doi.org/10.1038/srep14750)