



Analiza avansată a seriilor de timp și previziune

Capitolul 15: Recapitulare și susținerea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/4)

- ▣ ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- ▣ ADF: Augmented Dickey–Fuller (test) — testul Dickey–Fuller augmentat
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ ALFRED: Archival Federal Reserve Economic Data (arhiva vintage-urilor FRED (Fed St. Louis))
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ARDL: AutoRegressive Distributed Lag (model) — model autoregresiv cu decalaje distribuite
- ▣ ARX: AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- ▣ BCE: Banca Centrală Europeană
- ▣ BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ BH: Benjamini–Hochberg (procedure) — procedura Benjamini–Hochberg
- ▣ BNR: Banca Națională a României
- ▣ BSADF: Backward Supremum Augmented Dickey–Fuller (statistic) — statistica ADF supremum retrospectivă, pentru fiecare dată de sfârșit
- ▣ BVAR: Bayesian Vector AutoRegression (model vector autoregresiv bayesian)
- ▣ CCE: Common Correlated Effects (estimator) — estimatorul efectelor comune corelate
- ▣ CCM: Convergent Cross Mapping (estimare încrucișată convergentă (Sugihara et al. 2012))
- ▣ CQR: Conormalized Quantile Regression (regresia cuantică conformalizată)
- ▣ CRPS: Continuous Ranked Probability Score (scorul probabilistic continuu)
- ▣ CSW: Chu, Stinchcombe and White (monitoring boundary) — Chu, Stinchcombe și White (frontiera de monitorizare)
- ▣ DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ DCC-NL: DCC with Nonlinear shrinkage of the target (Engle–Ledoit–Wolf 2019) — DCC cu shrinkage neliniar al țintei (Engle–Ledoit–Wolf 2019)
- ▣ DFM: Dynamic Factor Model (model factorial dinamic)
- ▣ DM: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ DQ: Dynamic Quantile (test of Engle and Manganelli) — testul dinamic pe cuantile al lui Engle și Manganelli
- ▣ ECE: Europa Centrală și de Est
- ▣ EM: Expectation–Maximisation (algorithm) — algoritmul expectație–maximizare
- ▣ EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață

Acronime folosite în acest material (2/4)

- ES: Expected Shortfall (pierderea așteptată în coadă)
- EWC: Equal-Weighted Cosine (estimator) — estimatorul cu cosinusi ponderate egal
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- FZ0: Zero-homogeneous Fissler–Ziegel loss (Patton, Ziegel and Chen) — pierderea Fissler–Ziegel omogenă de grad zero (Patton, Ziegel și Chen)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GAS-1F: One-factor GAS model for VaR and ES (model GAS cu un factor pentru VaR și ES)
- GMV: Global Minimum-Variance (portfolio) — portofoliul de varianță minimă globală
- GSADF: Generalised Supremum Augmented Dickey–Fuller (test) — testul ADF supremum generalizat (toate începuturile și sfârșiturile)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- HAR: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- HARQ: HAR with realised Quarticity (HAR cu cuarticitatea realizată)
- HLN: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- HP: Hodrick–Prescott (filter) — filtrul Hodrick–Prescott
- IG: inverse gamma (distribution) — distribuția inverse gamma
- INS: Institutul Național de Statistică
- IPC: Indicele prețurilor de consum
- ITS: Interrupted Time Series (serie de timp întreruptă)
- LLM: Large Language Model (model lingvistic de mari dimensiuni)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LP: Local Projection (proiecție locală)
- LP-IV: Local Projection with Instrumental Variables (proiecție locală cu variabile instrumentale)
- LR: Likelihood Ratio (test) — testul raportului de verosimilitate
- MAE: Mean Absolute Error (eroarea absolută medie)
- MCO: Metoda celor mai mici pătrate obișnuite
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MGARCH: Multivariate GARCH (GARCH multivariat)

Acronime folosite în acest material (3/4)

- MIDAS: Mixed Data Sampling (regression) — regresie cu date de frecvențe mixte
- MNZ: Morley–Nelson–Zivot (2003) — Morley–Nelson–Zivot (2003)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MSFE: Mean Squared Forecast Error (eroarea medie pătratică de prognoză)
- OECD: Organisation for Economic Co-operation and Development (Organizația pentru Cooperare și Dezvoltare Economică)
- OWA: Overall Weighted Average (of sMAPE and MASE relative to Naive 2) — media ponderată generală a sMAPE și MASE relative la Naive 2
- PCMCi: PC algorithm + Momentary Conditional Independence (algoritmul PC urmat de testul de independență condiționată momentană (Runge et al. 2019))
- PIB: Produsul intern brut
- PID: Proportional–Integral–Derivative (controller) — controler proporțional–integral–derivat
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- PMG: Pooled Mean Group (estimator) — estimatorul pooled mean group (termen lung comun, termen scurt eterogen)
- QLIKE: Quasi-LIKelihood loss (pierdere de tip cvasi-verosimilitate)
- QML: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- QPS: Quadratic Probability Score (scorul pătratic al probabilităților)
- RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- RMSPE: Root Mean Squared Prediction Error (rădăcina erorii pătratice medii de predicție)
- SAV: Symmetric Absolute Value (CAViAR specification) — specificația CAViAR cu valoare absolută simetrică
- SC: Synthetic Control (control sintetic)
- SPA: Superior Predictive Ability (test) — testul abilității predictive superioare
- SPF: Survey of Professional Forecasters (ancheta specialiștilor în prognoză (Survey of Professional Forecasters))
- STAR: Smooth Transition AutoRegression (autoregresie cu tranziție netedă)
- SUA: Statele Unite ale Americii
- SVAR: Structural Vector AutoRegression (model vector autoregresiv structural)
- TAR: Threshold AutoRegression (autoregresie cu prag)
- TE: Transfer Entropy (entropia de transfer)
- TPS: Taylor, Peel and Sarno (2001) — Taylor, Peel și Sarno (2001)

Acronime folosite în acest material (4/4)

- UC-SV: Unobserved Components model with Stochastic Volatility (Stock–Watson 2007) — model cu componente neobservate și volatilitate stohastică (Stock–Watson 2007)
- UC0: UC model with uncorrelated trend and cycle shocks (Clark 1987) — model UC cu șocuri necorelate ale trendului și ciclului (Clark 1987)
- UE: Uniunea Europeană
- UE-27: cele 27 de state membre ale Uniunii Europene
- VAR: Vector AutoRegression (model vector autoregresiv)
- VECM: Vector Error Correction Model (model vectorial cu corecția erorii)

Întrebarea de azi și traseul

- **Întrebarea:** ce vă oferă întregul curs pentru un proiect de cercetare și cum se susține proiectul?
 - un capitol care leagă **Capitolele 0–14** și **Capitolul 16** (studiu individual) de proiectul de echipă
- **Traseul**
 - Partea I: harta cursului, câte o recapitulare pentru fiecare capitol, trusa de metode
 - Partea a II-a: fluxul de cercetare, replicarea unei lucrări de referință, reproductibilitatea, erorile frecvente
 - Partea a III-a: susținerea orală, AI în cercetare și alegerea proiectului
- Cursul nu are examen scris: proiectul și susținerea lui reprezintă 70% din notă



Academia de Studii Economice din București

Foto: Joe Mabel (2014); CC BY 3.0; Wikimedia

[Commons](#)

Rezultatele învățării


- ▣ Plasați fiecare capitol pe harta metodelor și formulați ideea-cheie, formula-cheie și rezultatul replicării
- ▣ Alegeți instrumentul potrivit pentru o întrebare de cercetare despre date dependente
- ▣ Planificați un proiect de la întrebare la raport, cu preînregistrare și calculul puterii evaluării
- ▣ Replicați o lucrare de referință, explicați o replicare nereușită și faceți reproductibil fiecare rezultat numeric
- ▣ Recunoașteți data snooping, leakage, look-ahead, p-hacking și afirmațiile exagerate în propria lucrare
- ▣ Pregătiți susținerea orală individuală și documentați folosirea instrumentelor AI

Evaluarea pe scurt

Componenta	Pondere	Cine	Conținut
Propunerea și preînregistrarea	5%	echipa	întrebarea, lucrarea replicată, datele, designul evaluării fixat înaintea estimării
Replicarea și extensia	15%	echipa	repository, raport în forma unui articol, AI_USE.md, AI_ERRORS.md
Susținerea orală	50%	fiecare student	circa 15 minute: 5 minute de prezentare a contribuției proprii și 10 minute de întrebări despre cod, metodă și rezultate
Quiz-uri pe capitole	20%	fiecare student	online, se notează prima încercare
Prezență	10%	fiecare student	cursuri și seminarii

- Echipe de cel mult trei studenți; proiectul se poate redacta și susține în română sau în engleză
- Notele membrilor unei echipe pot fi diferite: jumătate din nota finală este individuală

Harta cursului



- Capitolele 0 și 1 se folosesc peste tot: inferența pentru date dependente și evaluarea corectă în afara eșantionului
- Fiecare capitol alimentează proiectul: o lucrare de referință de replicat și o extensie

Cinci întrebări pentru orice analiză

- **Ținta:** ce funcțională se prognozează sau se estimează (medie, cuantilă, distribuție, efect causal)?
 - ▶ funcția de pierdere sau de scor trebuie să fie consistentă pentru ea ([Capitolele 1 și 9](#))
- **Dependența:** ce erori standard sînt valide cu autocorelație, heteroscedasticitate și persistență?
 - ▶ HAC cu fixed- b sau EWC, bootstrap pe blocuri, mărimea testului prin Monte Carlo la persistența seriei ([Capitolul 0](#))
- **Identificarea:** ce ipoteză transformă o corelație în afirmația pe care o faceți?
 - ▶ ordonarea, semnul, instrumentul, grupul de donatori, etichetarea regimurilor ([Capitolele 3, 7, 14](#))
- **Evaluarea:** este designul fixat înaintea rezultatelor, în timp real, cu un test potrivit?
 - ▶ DM–HLN, Clark–West pentru modele imbricate, MCS și SPA pentru mai multe modele
- **Robustețea:** rezistă concluzia la bifurcațiile analizei?
 - ▶ fiecare capitol se încheie cu un mini studiu de caz care variază specificația

Trei fire comune ale cursului

▣ Inferența sub dependență

- ▶ varianța de termen lung $\Omega = 2\pi f(0)$ ([Capitolul 0](#)), unde $f(0)$ este densitatea spectrală la frecvența zero: varianța unei sume de n termeni dependenți este aproximativ $n\Omega$
- ▶ ea re apare în testele DM ([Capitolul 1](#)), proiecțiile locale ([Capitolul 3](#)), efectele cumulate ([Capitolul 14](#))
- ▶ limite nestandard: teste sup pentru rupturi, testul urmei Johansen, teste pentru regimuri, GSADF; valori critice din distribuția corectă

▣ Evaluarea corectă în afara eșantionului

- ▶ reguli de scor proprii și funcții de pierdere consistente, date în timp real, validare pe blocuri, evaluare după lansarea modelelor ([Capitolele 1, 9, 12, 13](#))

▣ Identificarea și replicarea

- ▶ șocurile structurale, stările latente și efectele cauzale depind de model; rezultatele de referință au fost replicate pe datele de azi, iar unele nu au rezistat

Capitolul 0: Inferență pentru date dependente (1/2)

▣ Idei-cheie

- ▶ Precizia unei medii sau a unei pante este dată de varianța de termen lung, nu de γ_0
- ▶ HAC cu valori critice fixed- b sau EWC; bootstrap-ul pe blocuri reeșantionează dependența, wild bootstrap nu

▣ Formula-cheie

- ▶ $\Omega = \gamma_0 + 2 \sum_{j \geq 1} \gamma_j = 2\pi f(0)$; $\hat{\Omega}_{NW} = \hat{\Gamma}_0 + \sum_{j=1}^L (1 - \frac{j}{L+1})(\hat{\Gamma}_j + \hat{\Gamma}_j')$
- ▶ γ_j : autocovarianța la lagul j ; $f(0)$: densitatea spectrală la frecvența zero; Ω : varianța de termen lung
- ▶ $\hat{\Gamma}_j$: matricea de autocovarianță de selecție la lagul j ; L : numărul de laguri (lățimea de bandă); $1 - j/(L+1)$: ponderile Bartlett

Capitolul 0: Inferență pentru date dependente (2/2)

▣ Replicarea

- ▶ Estrella și Hardouvelis (1991): panta 0,52, cu t clasic = 4,72, dar t fixed- b = 2,04, sub valoarea critică 2,18; 1,12 înainte de 1989, 0,15 după: **replicare parțială**
- ▶ White (2000) pe 50 de reguli cu medii mobile pentru BET: p naiv = 0,006, p Reality Check = 0,06

▣ Greșeli frecvente

- ▶ erori standard i.i.d.: testul naiv respinge 68,1% din ipotezele nule adevărate la $\phi = 0,9$, $T = 100$, și tot 66,2% la $T = 400$
- ▶ cea mai bună dintre multe specificații, raportată fără un p-value ajustat pentru căutare

Capitolul 1: Evaluarea și combinarea prognozelor (1/2)

▣ Idei-cheie

- ▶ Alegeți întâi funcția de pierdere sau de scor: ea definește ținta (medie, mediană, cuantilă, distribuție)
- ▶ Calibrare cu PIT, ierarhizare cu reguli de scor proprii; DM–HLN, Clark–West pentru modele imbricate, SPA și MCS pentru mai multe

▣ Formula-cheie

- ▶ $DM = \bar{d} / \sqrt{\hat{\Omega}_d / P}$, $DM^* = DM \sqrt{(P + 1 - 2h + h(h - 1)/P) / P}$, comparat cu t_{P-1}
- ▶ $\bar{d}$: diferența medie a pierderilor celor două prognoze; $\hat{\Omega}_d$: varianța ei de termen lung; P : numărul de prognoze în afara eșantionului; h : orizontul
- ▶ DM^* : corecția HLN pentru eșantioane mici, comparată cu Student- t cu $P - 1$ grade de libertate

Capitolul 1: Evaluarea și combinarea prognozelor (2/2)

▣ Replicarea

- ▶ Meese și Rogoff (1983) pe EUR/RON: RMSE AR(1) de 1,055 ori cel al mersului aleator, drift 1,006 (Clark–West $p = 0,145$): **replicat**
- ▶ Genre et al. (2013) pe SPF: mediana 0,999, cel mai bun anterior 1,099 (HLN $p = 0,007$); Atkeson și Ohanian (2001): raport 1,75, dar $p = 0,248$

▣ Greșeli frecvente

- ▶ testul DM simplu cu puține prognoze pe mai mulți pași: mărimea 43,6% la $h = 8$, $P = 16$ (HLN: 14,6%)
- ▶ DM pentru modele imbricate; ponderi de combinare estimate pentru prognoze asemănătoare

Capitolul 2: Rupturi structurale și modele neliniare (1/2)

▣ Idei-cheie

- ▶ O dată a rupturii aleasă din date este un parametru de deranj: teste sup, exp și ave cu valori critice proprii
- ▶ Rupturile și neliniaritatea se imită reciproc: testați una ținând cont de cealaltă

▣ Formula-cheie

- ▶ $\sup_{\pi} W_T(\pi) \Rightarrow \sup_{\pi} \|B_p(\pi) - \pi B_p(1)\|^2 / [\pi(1 - \pi)]$; TAR: $y_t = \phi_1' x_t 1\{q_{t-d} \leq \gamma\} + \phi_2' x_t 1\{q_{t-d} > \gamma\} + \varepsilon_t$
- ▶ $W_T(\pi)$: statistica Wald pentru o ruptură la fracțiunea π a eșantionului; B_p : o mișcare browniană p -dimensională; $\Rightarrow$: convergență în distribuție
- ▶ TAR: ϕ_1, ϕ_2 : coeficienții celor două regimuri; x_t : regresorii cu lag; q_{t-d} : variabila de prag cu lagul d ; γ : pragul

Capitolul 2: Rupturi structurale și modele neliniare (2/2)

▣ Replicarea

- ▶ McConnell și Perez-Quiros (2000): ruptură în 1984Q1, $\sup-W = 52,5$; pe eșantionul pînă în 2026 doar 10,7; Bai și Perron (2003): 3 rupturi la datele publicate
- ▶ Hansen (1997): $\hat{\gamma} = 0,261$ (lucrarea: 0,302); Taylor, Peel și Sarno (2001): p Monte Carlo = 0,165 (lucrarea: 0,002): **nereplicat**

▣ Greșeli frecvente

- ▶ testul Chow la o dată aleasă din date: mărimea 33–40%; valoarea critică sup este 8,65, nu 3,84
- ▶ neliniaritatea din eșantion citită drept câștig de prognoză

Capitolul 3: Modele VAR structurale și proiecții locale (1/2)

▣ Idei-cheie

- ▶ Un VAR structural este o formă redusă plus o ipoteză de identificare; ipoteza este partea economică
- ▶ Zerourile, semnele, narațiunile, heteroscedasticitatea și instrumentele identifică prin ipoteze diferite; LP și VAR estimează aceleași răspunsuri

▣ Formula-cheie

- ▶ $u_t = B_0 \varepsilon_t$, $\Theta_h = \Phi_h B_0$; proxy: $\mathbb{E}(u_t z_t) = \alpha b_1$; LP: $y_{t+h} = \mu_h + \beta_h x_t + \gamma_h' w_t + \xi_{t+h}$
- ▶ u_t : reziduurile formei reduse; ε_t : șocurile structurale; B_0 : matricea de impact; Φ_h : răspunsurile formei reduse; Θ_h : răspunsurile structurale la orizontul h
- ▶ proxy: z_t instrumentul, b_1 prima coloană a lui B_0 , α relevanța; LP: β_h răspunsul la h față de x_t , w_t controalele, ξ_{t+h} eroarea

Capitolul 3: Modele VAR structurale și proiecții locale (2/2)

▣ Replicarea

- ▶ Christiano, Eichenbaum și Evans (1999): minimul producției industriale $-0,27\%$ după 21 de luni, cu puzzle-ul prețurilor; Gertler și Karadi (2015): $F = 17,7$, prima de risc a obligațiunilor $+0,14$: **replicat**
- ▶ Kilian (2009): varianța prețului petrolului la 60 de luni: oferta 1% , cererea agregată 64% , cererea specifică 35%

▣ Greșeli frecvente

- ▶ o ordonare recursivă citită ca fapt; wild bootstrap pentru un proxy SVAR (folosiți bootstrap-ul pe blocuri mobile)
- ▶ un VAR scurt la orizonturi lungi: deplasarea $0,71$ la $h = 8$, față de $0,07$ pentru LP, cu o varianță mai mare

Capitolul 4: Cointegrare: VECM, ARDL și date panel (1/2)

▣ Idei-cheie

- ▶ Johansen este o regresie de rang redus; testul rangului este nestandard, depinde de cazul determinist și respinge prea des în eșantioane mici
- ▶ Dat rangul, testele pe β și α sînt χ^2 ; ARDL este un VECM condiționat; la panel se verifică întîi dependența transversală

▣ Formula-cheie

- ▶ $\Delta y_t = \alpha \beta' y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + \Phi D_t + \varepsilon_t$, $LR_{tr}(r) = -T \sum_{i>r} \ln(1 - \hat{\lambda}_i)$
- ▶ Δ : diferența de ordinul întîi; β : vectorii de cointegrare; α : coeficienții de ajustare; Γ_i : matricele de termen scurt; D_t : termenii deterministi, cu coeficienții Φ
- ▶ $LR_{tr}(r)$: statistica urmei pentru rangul cel mult r ; $\hat{\lambda}_i$: valorile proprii ordonate; T : mărimea eșantionului

Capitolul 4: Cointegrare: VECM, ARDL și date panel (2/2)

▣ Replicarea

- ▶ King, Plosser, Stock și Watson (1991): două relații de cointegrare, dar rapoartele mari sînt respinse (LR 16,6, $p < 0,001$): **replicare parțială**
- ▶ Pesaran, Shin și Smith (1999) pe consumul din UE-27: elasticitatea în raport cu venitul 0,69, Hausman $p = 0,300$; efectul inflației nu este robust

▣ Greșeli frecvente

- ▶ valori critice asimptotice la $T = 50$: mărimea 18,2%, față de 4,8% pentru wild bootstrap
- ▶ rangul citit ca o măsurătoare: transmiterea dobînzilor în România, p wild bootstrap = 0,647 cu patru laguri

Capitolul 5: Modele VAR bayesiene, modele factoriale și nowcasting (1/2)

▣ Idei-cheie

- ▶ Multe serii și puține observații: shrinkage (distribuții a priori) sau comprimare (factori); sistemele mai mari cer distribuții a priori mai strânse
- ▶ Nowcasting-ul este filtrare Kalman cu marginea neregulată; fiecare revizuire este o sumă de știri

▣ Formula-cheie

- ▶ Minnesota: $\text{Var}[(A_l)_{ij}] = \lambda^2 / l^2$ dacă $j = i$, $\vartheta \lambda^2 \sigma_i^2 / (l^2 \sigma_j^2)$ altfel
- ▶ $(A_l)_{ij}$: efectul variabilei j cu lagul l asupra variabilei i ; varianța a priori scade cu l^2
- ▶ λ : strângerea generală; ϑ : strângerea suplimentară pentru celelalte variabile; σ_i^2 : scala reziduală a variabilei i

Capitolul 5: Modele VAR bayesiene, modele factoriale și nowcasting (2/2)

▣ Replicarea

- ▶ Bańbura, Giannone și Reichlin (2010), ocuparea, $h = 1$: 1,06; 0,54; 0,50 pentru sistemul mic, mediu, mare (lucrarea: 1,14; 0,54; 0,46): **replicat** pentru 1971–2003
- ▶ Stock și Watson (2002): producția industrială, $h = 12$: 0,58 în 1970–1998, dar 1,07 în 1999–2019: câștigul dispare

▣ Greșeli frecvente

- ▶ un BVAR homoscedastic care include 2020: MSFE relativ 500,06 la 12 luni
- ▶ „nowcast-uri mai bune” pe baza unui RMSE mai mic, fără test: PIB-ul României, DM $t = -0,30$, $p = 0,76$

Capitolul 6: Modele în spațiul stărilor și filtrare bayesiană (1/2)

▣ Idei-cheie

- ▶ Filtrul Kalman este condiționare gaussiană aplicată recursiv; netezirea, verosimilitatea și netezirea prin simulare decurg din el
- ▶ Inițializați exact stările nestaționare; volatilitatea stochastică nu este GARCH; mărimile latente au benzi care depind de model

▣ Formula-cheie

- ▶ $v_t = y_t - Z_t a_t$, $F_t = Z_t P_t Z_t' + H_t$, $K_t = T_t P_t Z_t' F_t^{-1}$, $a_{t+1} = T_t a_t + K_t v_t$
- ▶ a_t , P_t : starea prezisă și varianța ei; v_t , F_t : eroarea de predicție și varianța ei; K_t : câștigul Kalman
- ▶ Z_t : matricea de măsurare; T_t : matricea de tranziție; H_t : varianța zgomotului de măsurare

Capitolul 6: Modele în spațiul stărilor și filtrare bayesiană (2/2)

▣ Replicarea

- ▶ Morley, Nelson și Zivot (2003) pe ediția de azi a PIB: $\hat{\rho} = -0,927$, corelația cu ciclul Beveridge–Nelson 0,999; abaterea standard a ciclului 2,20 (UC0), față de 0,52: **replicat**
- ▶ Volatilitatea stochastică depășește GARCH pe S&P 500 cu 88,5 puncte de log-verosimilitate

▣ Greșeli frecvente

- ▶ o varianță estimată zero citită ca nivel constant: 64% din estimații sînt exact zero cînd varianța reală este zero (pile-up)
- ▶ inițializarea cu „kappa mare”; un output gap fără banda lui

Capitolul 7: Modele cu schimbare de regim (1/2)

▣ Idei-cheie

- ▶ Filtrul Hamilton și netezirea Kim sînt recursii exacte pentru o stare latentă discretă; EM găsește maxime locale și degenerate
- ▶ Numărul de regimuri este o problemă de testare nestandard; regimurile, rupturile și memoria lungă sînt greu de deosebit în date

▣ Formula-cheie

- ▶ $\hat{\xi}_{t|t} = \hat{\xi}_{t|t-1} \odot \eta_t / 1'(\hat{\xi}_{t|t-1} \odot \eta_t)$, $\hat{\xi}_{t+1|t} = P' \hat{\xi}_{t|t}$, $\mathbb{E}D_i = 1/(1 - p_{ii})$
- ▶ $\hat{\xi}_{t|t}$: probabilitățile filtrate ale regimurilor; η_t : densitățile lui y_t în fiecare regim; $\odot$: produsul element cu element; 1 : vectorul de unu
- ▶ P : matricea de tranziție; p_{ii} : probabilitatea de a rămîne în regimul i ; $\mathbb{E}D_i$: durata așteptată a regimului i

Capitolul 7: Modele cu schimbare de regim (2/2)

▣ Replicarea

- ▶ [Hamilton \(1989\)](#) pe datele lui: log-verosimilitatea $-181,26$ cu două implementări, QPS 0,179: **replicat exact**
- ▶ Pe datele de azi regimul scăzut devine o succesiune de căderi bruște: probabilitatea pentru T4 2008 0,95, pentru 2001 cel mult 0,01

▣ Greșeli frecvente

- ▶ valori critice χ^2 pentru numărul de regimuri: LR 71,7, cuantila bootstrap de 95% 12,32, nu 5,99
- ▶ regimuri statistice citite ca regimuri economice; probabilități netezite folosite pentru a judeca datarea în timp real

Capitolul 8: Modelarea avansată a volatilității (1/2)

▣ Idei-cheie

- ▶ QML gaussian are nevoie doar de ecuația varianței; cu cozi groase, folosiți erori standard sandwich
- ▶ Măsurile realizate fac volatilitatea observabilă, cu o eroare cunoscută; HAR, HARQ și Realized GARCH câștigă la o zi

▣ Formula-cheie

- ▶ HARQ: $RV_{t+1} = \beta_0 + (\beta_d + \beta_{dQ} \sqrt{RQ_t})RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + u_{t+1}$
- ▶ RV_t : varianța realizată; $RV_t^{(w)}$, $RV_t^{(m)}$: mediile ei pe 5 și 22 de zile; RQ_t : cvarticitatea realizată, care măsoară eroarea lui RV_t
- ▶ $\beta_{dQ} < 0$: ponderea zilnică scade când RV_t este măsurat cu o eroare mare

Capitolul 8: Modelarea avansată a volatilității (2/2)

▣ Replicarea

- ▶ Bollerslev, Patton și Quaadvlieg (2016) pe crypto: QLIKE relativ la HAR 0,946 (Bitcoin), 0,921 (Ether)
- ▶ Engle, Ghysels și Sohn (2013): producția industrială $t = -1,56$; funcționează doar varianța realizată ($t = 3,86$)
- ▶ Engle, Ledoit și Wolf (2019): volatilitatea GMV 18,33 (DCC-NL), față de 18,35 (DCC): câștigul nu apare aici: **nereplicat**

▣ Greșeli frecvente

- ▶ erori standard din hessiană cu erori Student- $t(5)$: acoperire 73,0%, față de 91,7% pentru sandwich
- ▶ funcții de pierdere nerobuste (MAE, MSE pe logaritmi) cu un indicator zgomotos al volatilității

Capitolul 9: VaR, ES și backtesting (1/2)

▣ Idei-cheie

- ▶ O prognoză de risc este o prognoză punctuală a unei funcționale: judecați-o cu o funcție de pierdere consistentă; VaR este elicitar, ES doar împreună cu VaR
- ▶ Backtest-urile sînt teste de momente cu risc de estimare; comparațiile cer DM, MCS și diagrame Murphy

▣ Formula-cheie

- ▶ $L_{FZ0}(y, v, e; \alpha) = -\frac{1}{\alpha e} \mathbf{1}\{y \leq v\}(v - y) + \frac{v}{e} + \ln(-e) - 1$; $\text{VaR}_\alpha = -q_\alpha$
- ▶ y : randamentul realizat; v : prognoza VaR și e : prognoza ES, ambele ca randamente (negative); α : nivelul (de exemplu 0,025)
- ▶ L_{FZ0} : o pierdere consistentă pentru perechea (VaR, ES), o valoare mai mică este mai bună; q_α : cuantila de nivel α a randamentului

Capitolul 9: VaR, ES și backtesting (2/2)

▣ Replicarea

- ▶ Patton, Ziegel și Chen (2019): pierderea GAS-1F 0,853 (lucrarea: 0,853): ierarhia **se replică**; p-value-urile testelor de adecvare 0,001 și 0,037 (lucrarea: 0,242 și 0,313) **nu**
- ▶ Engle și Manganelli (2004) în afara eșantionului: doar IG trece testul DQ ($p = 0,891$; SAV 0,025)

▣ Greșeli frecvente

- ▶ ierarhizarea prognozelor ES singure; VaR 1% Normal cu o rată a depășirilor de 2,2%
- ▶ regula $\sqrt{h}$ în prezența volatility clustering; „cel mai bun model ES” în locul MCS

Capitolul 10: Memorie lungă și rough volatility (1/2)

▣ Idei-cheie

- ▶ Memoria lungă este un pol la frecvența zero; estimați d prin local Whittle (exact) și raportați $\hat{d}(m)$ pentru mai multe lățimi de bandă
- ▶ Volatilitatea este persistentă la scara lunilor și rough la scara zilelor ($H \approx 0,1$); salturile de nivel imită memoria lungă

▣ Formula-cheie

- ▶ $f(\lambda) \sim c_f \lambda^{-2d}$, $\gamma(k) \sim c_\gamma k^{2d-1}$; $\mathbb{E}|\ln \sigma_{t+\Delta} - \ln \sigma_t|^q \propto \Delta^{qH}$
- ▶ $f(\lambda)$: densitatea spectrală la frecvența λ ; $\gamma(k)$: autocovarianța la lagul k ; d : parametrul de memorie; c_f , c_γ : constante; $\sim$: echivalență asimptotică
- ▶ H : exponentul Hurst al logaritmului volatilității, care măsoară cât de rough este traiectoria; Δ : pasul de timp; q : ordinul momentului; $H < 1/2$: traiectorii rough

Capitolul 10: Memorie lungă și rough volatility (2/2)

▣ Replicarea

- ▶ Gatheral, Jaisson și Rosenbaum (2018) pe S&P 500: $\hat{H} = 0,149$ (0,140 și 0,155 pe cele două jumătăți): **replicat**; Qu (2011): $W = 0,66$, memoria varianței realizate rezistă
- ▶ Câștigul de prognoză rough față de HAR la 5 zile: raportul QLIKE 0,964, $p = 0,07$: mic și dependent de orizont

▣ Greșeli frecvente

- ▶ o singură lățime de bandă, un singur $\hat{d}$; „memorie scurtă pentru că $H < 1/2$ ” (caracterul rough și persistența sînt proprietăți diferite)

Capitolul 11: Analiză spectrală și analiză wavelet (1/2)

▣ Idei-cheie

- ▶ Spectrul descompune varianța pe frecvențe; filtrele acționează prin pătratul câștigului; multitaper dă un leakage spectral redus și benzi corecte
- ▶ Wavelet-urile localizează varianța și co-mișcarea în timp și pe scale; semnificația cere Monte Carlo și raționament pe arii

▣ Formula-cheie

- ▶ câștigul ciclului HP $G(\omega) = \frac{4\lambda(1 - \cos \omega)^2}{1 + 4\lambda(1 - \cos \omega)^2}$; coerența $\kappa^2(\omega) = |f_{xy}|^2 / (f_x f_y)$
- ▶ ω : frecvența; λ : parametrul de netezire HP; $G(\omega) \in [0, 1]$: proporția din varianța de la ω transmisă ciclului
- ▶ f_x, f_y : spectrele; f_{xy} : spectrul încrucișat; $\kappa^2(\omega) \in [0, 1]$: corelația la pătrat a lui x și y la frecvența ω

Capitolul 11: Analiză spectrală și analiză wavelet (2/2)

▣ Replicarea

- ▶ Cogley și Nason (1995): HP aplicat unui mers aleator are vârful la 30,1 trimestre (7,5 ani; simulare 28,6): **replicat**
- ▶ Hamilton (2018) pe PIB-ul României: output gap-ul HP în timp real are corelația 0,57 cu cel final și semnul greșit în 38% din trimestre

▣ Greșeli frecvente

- ▶ fiecare insulă de coerență wavelet citită drept contagiune: BET–DAX 23% arie semnificativă, față de cuantila de 95% sub ipoteza nulă 7,7%
- ▶ teste punctuale pe frecvențe citite drept test comun

Capitolul 12: Machine learning și deep learning (1/2)

▣ Idei-cheie

- ▶ Validarea trebuie să respecte dependența: K-fold doar pentru autoregresii bine specificate; altfel blocuri, purjare și o perioadă finală de test
- ▶ Arborii și rețelele depășesc rar singure modelele de referință structurate; modelele globale combină seriile; seed-urile și căutările sînt testare multiplă ascunsă

▣ Formula-cheie

- ▶ $OWA = \frac{1}{2} (sMAPE/sMAPE_{Naive2} + MASE/MASE_{Naive2})$; $Att(Q, K, V) = \text{softmax}(QK' / \sqrt{d_k})V$
- ▶ OWA: scorul M4, relativ la reperul Naive2 (sub 1: mai bun); sMAPE: eroarea procentuală absolută medie simetrică
- ▶ Q, K, V : matricele de interogare (query), cheie (key) și valoare (value); d_k : dimensiunea cheilor; softmax normalizează fiecare rînd în ponderi care însumează 1

Capitolul 12: Machine learning și deep learning (2/2)

▣ Replicarea

- ▶ Bergmeir, Hyndman și Koo (2018): eroarea validării 5-fold 0,094, față de 0,137 în afara eșantionului: **replicat**
- ▶ Zeng et al. (2023) și Nie et al. (2023) pe consumul de energie al României, $H = 96$: Transformer cu tokeni punctuali 0,258, DLinear 0,257, patch-uri 0,226: ambele lucrări **se replică**

▣ Greșeli frecvente

- ▶ K-fold aleator cu reziduuri autocorelate: raportul dintre eroarea de validare și cea de test 0,34 (leakage)
- ▶ ponderile atenției citite ca importanță; cel mai bun dintre multe seed-uri raportat drept model

Capitolul 13: Foundation models și predicție conformală (1/2)

▣ Idei-cheie

- ▶ Foundation models amortizează estimarea pe un corpus; evaluați după lansare, agregați pe serii, corecți pentru testarea multiplă
- ▶ Predicția conformală dă acoperire marginală în eșantion finit sub interschimbabilitate; sub dependență, ACI restabilește acoperirea pe termen lung

▣ Formula-cheie

- ▶ $\hat{q} = S_{(\lceil (n+1)(1-\alpha) \rceil)}$; ACI: $\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t)$
- ▶ $S_{(k)}$: al k -lea cel mai mic dintre n scoruri de calibrare; α : rata-țintă a ratărilor; $\hat{q}$: pragul conformal
- ▶ ACI: α_t nivelul de lucru; γ : pasul; $\text{err}_t = 1$ după o ratare

Capitolul 13: Foundation models și predicție conformală (2/2)

▣ Replicarea

- ▶ Gibbs și Candès (2021) pe S&P 500 (ținta 0,90): acoperirea statică 0,918, ACI 0,901; Romano, Patterson și Candès (2019): cuantilele brute 0,883, CQR 0,915: **replicat**
- ▶ Consumul de energie al României: MAE Chronos-2 0,210, față de 0,221 pentru ARX expert

▣ Greșeli frecvente

- ▶ țări alese convenabil: Chronos-2 mai bun în 23 din 27 de serii de inflație, semnificativ în 0 după Holm
- ▶ ferestre de evaluare dinaintea lansării modelului; acoperirea condiționată afirmată în loc de testată

Capitolul 14: Inferență causală pentru serii de timp (1/2)

▣ Idei-cheie

- ▶ Cauzalitatea Granger și metodele înrudite (TE, PCMC, CCM) descriu structura predictivă; afirmațiile cauzale cer ipoteze despre alocarea tratamentului
- ▶ Controlul sintetic folosește alte unități: testele placebo sînt inferența, potrivirea pe o perioadă anterioară lungă este justificarea

▣ Formula-cheie

- ▶ $w^* = \arg \min_w (X_1 - X_0 w)' V (X_1 - X_0 w)$, $w_j \geq 0$, $\sum_j w_j = 1$; placebo $p = \#\{j : r_j \geq r_1\} / (J + 1)$
- ▶ X_1 , X_0 : predictorii anteriori tratamentului ai unității tratate și ai donatorilor; V : ponderile predictorilor; w_j : ponderile donatorilor
- ▶ r_j : raportul RMSPE după/înainte al unității j ; J : numărul de donatori; $\#\{\cdot\}$: numărul de elemente

Capitolul 14: Inferență causală pentru serii de timp (2/2)

▣ Replicarea

- ▶ Abadie, Diamond și Hainmueller (2015): PIB-ul pe locuitor al Germaniei de Vest cu 1588 USD pe an (5,6%) sub controlul sintetic, p placebo = 0,059: **replicat**
- ▶ Born et al. (2019) pe date revizuite: diferența $-1,5\%$ în T4 2018 (lucrarea: $-2,4\%$), Regatul Unit pe locul 11 din 24: **nereplicat ca mărime**

▣ Greșeli frecvente

- ▶ cauzalitatea Granger citită drept cauzalitate; un factor comun o produce
- ▶ control sintetic în afara înfășurătorii convexe: SC clasic dă 4,18 pp pentru România, estimatorii robuști 2,7–2,8 pp

Capitolul 16: Rădăcini explozive și bule speculative (studiu individual) (1/2)

▣ Idei-cheie

- ▶ O bulă rațională este o componentă explozivă; bulele care se prăbușesc periodic scapă testelor pe întregul eșantion
- ▶ Valorile critice trebuie să corespundă designului: wild bootstrap sub volatilitate variabilă, control la nivel de familie pentru datare

▣ Formula-cheie

- ▶ $BSADF_{r_2} = \sup_{r_1} ADF'_{r_1}{}^2$, $GSADF = \sup_{r_2} BSADF_{r_2}$; bula: $\mathbb{E}_t B_{t+1} = (1 + r)B_t$
- ▶ $ADF'_{r_1}{}^2$: statistica ADF pe fracțiunea de eșantion $[r_1, r_2]$; BSADF: supremumul ei după începutul r_1 ; GSADF: supremumul BSADF după sfârșitul r_2
- ▶ B_t : componenta de bulă a prețului; r : rata dobânzii; $\mathbb{E}_t$: speranța condiționată de informația de la t

Capitolul 16: Rădăcini explozive și bule speculative (studiu individual) (2/2)

▣ Replicarea

- ▶ Phillips și Yu (2011): raportul preț/chirie în SUA, GSADF 5,75, față de valoarea critică wild 4,47: **replicat**
- ▶ Phillips, Wu și Yu (2011) Nasdaq: 2,92 respinge cu valoarea Monte Carlo (2,28), dar nu cu wild bootstrap (3,22); Phillips, Shi și Yu (2015) S&P 500: 2,19 sub ambele: **nereplicat**

▣ Greșeli frecvente

- ▶ valori critice Monte Carlo după o schimbare a volatilității: mărimea 33,8% (wild bootstrap 3,2%)
- ▶ datarea punctuală citită ca test de 5%: episoade false în 32,5% din traiectoriile fără bulă

Recapitulare: cele șaisprezece capitole

- Majoritatea rezultatelor de referință se replică în sens pe datele de azi; mărimea și testele lor adesea nu
- Aceleași greșeli revin: inferență i.i.d. pe date dependente, valori critice greșite, o căutare raportată ca un singur test
- Fiecare capitol oferă o replicare și o extensie pentru proiect ([▶ Anexă](#))

Instrumentul potrivit fiecărei întrebări (1/3): inferență și evaluare

Întrebarea de cercetare	Instrumentul	Cap.
Este o medie, o pantă sau un coeficient predictiv diferit de zero?	HAC cu fixed- b sau EWC; bootstrap pe blocuri; verificarea mărimii prin Monte Carlo	0
Depășește una dintre multe reguli sau modele un reper?	Reality Check, SPA, StepM; MCS	0, 1
Este prognoza A mai precisă decât prognoza B?	DM-HLN cu HAC; Clark-West pentru modele imbricate; Giacomini-White pentru metode	1
Este calibrată o prognoză de densitate sau de interval?	PIT, Berkowitz; teste de acoperire și independență; CRPS, scorul logaritm	1, 13
Este adecvată o prognoză VaR sau (VaR, ES) și care este cea mai bună?	Kupiec, Christoffersen, DQ; pierderea FZ0, DM, MCS, diagrame Murphy	9
Își păstrează intervalele acoperire sub dependență?	split conformal, CQR, ACI, PID conformal; acoperire pe regimuri	13


Instrumentul potrivit fiecărei întrebări (2/3): structură și dinamică

Întrebarea de cercetare	Instrumentul	Cap.
S-au schimbat parametrii și când?	teste sup/exp/ave, Bai–Perron, monitorizare CSW, teste pentru rupturi în varianță	2
Este dinamica neliniară sau dependentă de stare?	TAR, STAR cu teste bootstrap sau LM; schimbare de regim Markov cu LR bootstrap	2, 7
Care este efectul unui șoc structural?	SVAR (zerouri, semne, proxy), proiecții locale, LP-IV	3
Există un echilibru pe termen lung și cine se ajustează?	Johansen cu bootstrap; teste pe β și α ; testul limitelor ARDL; CCE și PMG pentru panel	4
Cum prognozăm cu mulți predictorii sau frecvențe mixte?	BVAR cu shrinkage optimizat, factori, nowcasting DFM, MIDAS	5
Care este trendul, output gap-ul sau panta variabilă neobservate?	spațiul stărilor prin verosimilitate maximă sau Gibbs, netezire prin simulare, UC-SV, filtre de particule	6

Instrumentul potrivit fiecărei întrebări (3/3): volatilitate, frecvență, învățare, cauzalitate

Întrebarea de cercetare	Instrumentul	Cap.
Cum prognozăm volatilitatea sau o matrice de covarianță?	HAR, HARQ, Realized GARCH; DCC cu shrinkage; QLIKE	8
Este memoria lungă sau sînt salturi de nivel?	local Whittle $\hat{d}(m)$, testul Qu, scalarea logaritmului volatilității	10
La ce frecvențe se mișcă împreună două serii?	coerență și fază multitaper, Breitung–Candelon, coerență wavelet	11
Depășesc metodele flexibile sau foundation models reperul?	validare pe blocuri, repere puternice, teste agregate, Holm și BH	12, 13
Ajută x la prognoza lui y și a avut o politică un efect?	Granger condiționat, PCMCi; ITS, control sintetic cu placebo, CausalImpact	14
Există o bulă și cînd a început?	GSADF și BSADF cu wild bootstrap, datare cu control la nivel de familie	16

Proiectul în opt etape



- Ordinea contează: designul evaluării se fixează înaintea primei estimări, replicarea vine înaintea extensiei
- Fiecare etapă lasă o urmă în repository (un fișier, un commit, o secțiune a raportului)

Etapele 1–2: întrebarea și literatura

- ▣ **O întrebare bună** este îngustă, falsificabilă și are răspuns cu date publice
 - ▶ „Se menține rezultatul Meese–Rogoff pentru EUR/RON la orizonturi de 1–12 luni după 2015?” în loc de „Putem prognoza cursul de schimb?”
- ▣ **Lucrarea de referință**: unul dintre studiile de caz ale [Capitolelor 0–16](#) sau o altă lucrare aprobată în prealabil
 - ▶ identificați tabelul sau figura pe care le veți reproduce, eșantionul, sursa datelor și codul, dacă este publicat
- ▣ **Literatura**: ce s-a găsit de atunci și ce rămîne deschis
 - ▶ fiecare referință verificată după DOI; o referință sugerată de AI este o ipoteză pînă la verificare [Walters și Wilder \(2023\)](#)
- ▣ Extensia răspunde unei întrebări noi: date noi (România, UE, anii recentî), o metodă nouă din curs sau un test nou

Etapa 3: preînregistrarea

- Preînregistrarea fixează analiza înainte ca datele să o poată influența Nosek et al. (2018)
 - ▶ ipotezele și rezultatul principal
 - ▶ datele: surse, ediții, eşantion, transformări, excluderi
 - ▶ evaluarea: ferestrele de estimare și de test, orizonturile, funcțiile de pierdere, testele, reperul
 - ▶ planul pentru testarea multiplă: câte comparații, ce corecție (Holm, MCS, SPA)
 - ▶ regula de robustețe: ce variații și ce înseamnă un rezultat robust
- Un calcul al puterii evaluării: este eşantionul de test destul de lung pentru a detecta câștigul publicat? (mini studiul de caz de la final)
- Abaterile sînt permise, dar se raportează: preînregistrarea este un angajament de transparență, nu o constrîngere rigidă
- Un model cu cele șapte secțiuni (▶ Anexă)

Etapele 4–6: datele, replicarea, extensia

- **Datele:** surse oficiale, documentate o singură dată
 - ▶ date de piață din repository-ul cursului (EODHD); FRED, Eurostat, BCE, INS, BNR online; notați data descărcării (ediția)
 - ▶ întrebările în timp real cer date în timp real: datele revizuite avantajează prognozele ([Capitolele 1 și 5](#))
- **Replicarea:** întâi eșantionul și specificația originale, apoi datele de azi
 - ▶ un tabel care pune rezultatele publicate lângă ale dumneavoastră, cu diferențele explicate
- **Extensia:** o singură întrebare nouă, tratată cu aceeași grijă
 - ▶ eșantion nou, țară nouă, o metodă nouă din curs sau un test mai puternic al afirmației originale

Etapele 7–8: robustețea și raportarea

- **Robustețea:** arătați distribuția rezultatelor pe alegeri rezonabile, nu pe cea mai bună
 - ▶ curba specificațiilor sau multiversul [Simonsohn, Simmons și Nelson \(2020\)](#), [Steegen et al. \(2016\)](#): ferestre, laguri, grupuri de donatori, funcții de pierdere, lățimi de bandă
 - ▶ 164 de echipe care testează aceleași ipoteze pe aceleași date diferă cât sugerează erorile standard [Menkveld et al. \(2024\)](#)
- **Raportul** în forma unui articol: introducere, date, metodă, replicare, extensie, robustețe, concluzie
 - ▶ fiecare rezultat numeric din text produs de cod; figurile după regulile de grafice ale cursului
 - ▶ mărimi ale efectelor cu intervale de încredere, nu steluțe; limitele formulate explicit
- `AI_USE.md` și `AI_ERRORS.md` în repository (secțiunea despre AI în cercetare)

Recapitulare: fluxul de cercetare

- ▣ Întrebarea, literatura și preînregistrarea preced orice estimare
- ▣ Replicați întâi pe eşantionul original; extindeți cu o singură întrebare nouă
- ▣ Raportați distribuția pe specificații și orice abatere de la plan

Reproducere, replicare, robustețe

- ▣ Clemens (2017) distinge
 - ▶ **verificarea**: aceleași date, același cod, aceleași rezultate (un control de calcul)
 - ▶ **reproducerea**: aceeași specificație și populație, cu cod rescris sau date recolectate
 - ▶ **robustețea**: altă specificație, alt eșantion sau altă populație: o extensie, nu un eșec dacă diferă
- ▣ În economie, aproximativ jumătate din lucrări pot fi reproduse din fișierele autorilor fără ajutorul lor Chang și Li (2022); anomaliiile din finanțe eșuează adesea pe eșantioane extinse Hou, Xue și Zhang (2020)
- ▣ O eroare într-o foaie de calcul a schimbat o dezbatere de politică economică: Herndon, Ash și Pollin (2014)
- ▣ În curs, aproape fiecare replicare a fost o reproducere pe datele de azi, urmată de o verificare a robusteții


Tabloul replicărilor din curs (1/2)

Lucrarea	Cap.	Verdict	Ce a decis
Estrella și Hardouvelis (1991)	0	parțial	inferența robustă și un eșantion mai recent elimină semnificația
Meese și Rogoff (1983), Genre et al. (2013)	1	replicat	mersul aleator și media simplă sînt greu de depășit
McConnell și Perez-Quiros (2000), Bai și Perron (2003)	2	replicat	datele reproduse; valorile extreme din 2020 slăbesc extensia
Hansen (1997)	2	parțial	pragul apropiat, lagul variabilei de prag fragil pe date revizuite
Taylor, Peel și Sarno (2001)	2	nereplicat	p-value-ul Monte Carlo; indicele de preț din lucrare nu mai este publicat azi
Christiano, Eichenbaum și Evans (1999), Kilian (2009), Gertler și Karadi (2015)	3	replicat	fișiere de replicare publice; aceeași identificare
King, Plosser, Stock și Watson (1991)	4	parțial	rangul reprodus, rapoartele mari depind de cazul determinist
Bañbura, Giannone și Reichlin (2010)	5	replicat	pînă în 2003; eșuează după 2020 fără volatilitate stochastică
Stock și Watson (2002)	5	parțial	cîștigurile dispar pe 1999–2019
Morley, Nelson și Zivot (2003), Hamilton (1989)	6, 7	replicat	aceleași date; datarea lui Hamilton nu rezistă pe eșantionul de azi

Tabloul replicărilor din curs (2/2)

Lucrarea	Cap.	Verdict	Ce a decis
Bollerslev, Patton și Quaadvlieg (2016)	8	replicat	în QLIKE; ierarhia se schimbă în MSE
Engle, Ghysels și Sohn (2013)	8	parțial	semnul rezistă, efectul macro nu este semnificativ
Engle, Ledoit și Wolf (2019)	8	nereplicat	puține active raportat la eșantion: shrinkage-ul are puțin de corectat
Patton, Ziegel și Chen (2019)	9	parțial	pierderile medii reproduse; testele pe câteva zile din coadă nu
Gatheral, Jaisson și Rosenbaum (2018), Qu (2011)	10	replicat	scalarea stabilă pe jumătăți ale eșantionului și pe piețe
Cogley și Nason (1995), Hamilton (2018)	11	replicat	o proprietate a filtrului, nu a datelor procoloalele reproduse pe consumul de energie al României
Bergmeir, Hyndman și Koo (2018), Zeng et al. (2023)	12	replicat	
Gibbs și Candès (2021), Romano, Patterson și Candès (2019)	13	replicat	garanțiile în eșantion finit sînt valabile prin construcție
Abadie, Diamond și Hainmueller (2015)	14	replicat	date și cod publice; ponderi identice la două zecimale revizuirea datelor, fără covariate, inferență prin permutare valorile critice wild bootstrap decid
Born et al. (2019)	14	nereplicat	
Phillips și Yu (2011); Phillips, Shi și Yu (2015)	16	replicat; nereplicat	

O replicare reușită: Patton, Ziegel și Chen (2019)



- Pierdere FZ0 medie a zece modele (VaR, ES), S&P 500, 2000–2016, designul Patton, Ziegel și Chen (2019): datele noastre (bare), față de tabelul 8 al lucrării (romburi)

Interpretarea celor două tipuri de rezultat

- ▣ Pierderile medii pe 4 000 de zile sînt robuste la mici diferențe de date: GAS-1F 0,853, față de 0,853
- ▣ Testele care se bazează pe cîteva zeci de zile din coadă nu sînt: p-value-ul testului de adecvare 0,001, față de 0,242
- ▣ Același tipar în [Capitolul 2](#) (Taylor, Peel și Sarno (2001): $p = 0,165$, față de 0,002) și în [Capitolul 14](#) (Born et al. (2019): $-1,5\%$, față de $-2,4\%$)
- ▣ Lecția: replicați separat estimația și inferența; raportați care dintre ele rezistă

Cinci surse de diferențe

- **Ediția datelor:** PIB revizuit, indici de preț cu altă bază, serii care nu mai există
 - ▶ diferența Brexit ([Capitolul 14](#)), IPC-ul britanic din TPS ([Capitolul 2](#)), zecimalele MNZ ([Capitolul 6](#))
- **Eșantionul:** efectul era o trăsătură a perioadei lui
 - ▶ marja la termen ([Capitolul 0](#)), indicii de difuzie ([Capitolul 5](#)), recesiunile lui Hamilton ([Capitolul 7](#))
- **Implementarea:** optimizatorul, valorile de start, opțiunile implicite, cazul determinist
 - ▶ maximele EM ([Capitolul 7](#)), rapoartele mari ([Capitolul 4](#)), inițializarea difuză ([Capitolul 6](#))
- **Inferența:** estimația rezistă, eroarea standard sau valoarea critică nu
 - ▶ fixed- b ([Capitolul 0](#)), testele de adecvare ([Capitolul 9](#)), wild bootstrap ([Capitolul 16](#))
- **Designul:** cadrul lucrării diferă de al dumneavoastră
 - ▶ dimensiunea raportată la eşantion pentru DCC-NL ([Capitolul 8](#)); funcția de pierdere pentru HARQ ([Capitolul 8](#))

Replicarea corectă

- ▣ Obțineți pachetul de replicare; dacă nu există, notați fiecare alegere lăsată deschisă de lucrare
- ▣ Reproduceți întâi un singur rezultat (un coeficient, o statistică de test), apoi tabelul, apoi figura
- ▣ Păstrați eșantionul original ca rulare separată înainte de a-l extinde; schimbați un singur lucru odată
- ▣ Folosiți două implementări când este posibil (codul propriu și un pachet), ca pentru modelul lui Hamilton în [Capitolul 7](#)
- ▣ Puneți rezultatele publicate și cele replicate alături, cu diferențele absolute și relative
- ▣ O replicare nereușită este un rezultat: raportați sursa diferenței, testați explicațiile concurente, contactați politicienii dacă este nevoie

Repository-ul

Calea	Conținut
README.md requirements.txt data/raw/, data/processed/ code/01_data.py, 02_replication.py, ... notebooks/main.ipynb output/tables/, output/figures/ report/report.pdf preregistration.md, AI_USE.md, AI_ERRORS.md	întrebarea, descrierea datelor, modul de rulare, durata versiunile pachetelor fișierele brute nu se editează manual scripturi numerotate, rulate în ordine rulează integral în Colab generate de cod, niciodată scrise de mână articolul planul și evidența folosirii AI

- Structura urmează cerințele editorilor de date ai revistelor de economie [Vilhuber \(2020\)](#); pachetele de replicare sînt acum o condiție de publicare [Christensen și Miguel \(2018\)](#)
- Fișierul preregistration.md este salvat (commit) înaintea primului commit cu estimări: istoricul o arată

Lista de verificare a reproductibilității

Date și cod

- ▣ fiecare serie: sursa, codul, data descărcării
- ▣ niciun pas manual între datele brute și rezultate
- ▣ o singură comandă sau un singur notebook rulează totul
- ▣ seed-urile fixate și raportate; rezultatele stabile la schimbarea seed-ului
- ▣ funcțiile testate pe un caz cu răspuns cunoscut (un proces simulat, un rezultat publicat)


Rezultate și raport

- ▣ fiecare rezultat din raport provine dintr-un fișier din output/
- ▣ versiunile pachetelor în requirements.txt
- ▣ testul calculatorului curat: un coleg clonează repository-ul și obține aceleași rezultate [Peng \(2011\)](#)
- ▣ abaterile de la preînregistrare enumerate
- ▣ AI_USE.md și AI_ERRORS.md complete

Data snooping și p-hacking

- **Data snooping:** aceleași date se folosesc pentru a alege și pentru a testa un model; p-value-ul raportat ignoră căutarea [White \(2000\)](#)
 - ▶ remedii: Reality Check, SPA [Hansen \(2005\)](#), StepM [Romano și Wolf \(2005\)](#), MCS [Hansen, Lunde și Nason \(2011\)](#), o perioadă rezervată, neatinsă
- **p-hacking:** flexibilitate nedeclarată (eșantioane, variabile de control, transformări, valori extreme) pînă cînd $p < 0,05$ [Simmons, Nelson și Simonsohn \(2011\)](#)
 - ▶ „grădina potecilor care se bifurcă”: nu este nevoie de o căutare conștientă, ajung alegerile dependente de date [Gelman și Loken \(2014\)](#)
 - ▶ statisticile z publicate se aglomerează imediat peste 1,96 [Brodeur et al. \(2016\)](#); în finanțe, un factor nou are nevoie de $t > 3$ [Harvey, Liu și Zhu \(2016\)](#)
- Predictorii persistenți adaugă o a doua problemă: testele HAC resping prea des, ca în [Capitolul 0 Stambaugh \(1999\)](#)

O căutare de specificații pe o serie fără predictibilitate



- 1 000 seturi de date simulate, $T = 250$; K predictorii candidați persistenți ($\rho = 0,9$, un factor comun); teste t HAC; proporția seturilor cu cel puțin o „descoperire”


Interpretarea căutării de specificații

- Raportarea celui mai bun dintre K ca și cum ar fi singurul încercat: 32% rezultate fals pozitive cu 5 predictorii, 60% cu 20, 79% cu 50
- Bonferroni nu rezolvă problema: 13% la $K = 20$, pentru că fiecare test HAC este deja supradimensionat cu predictorii persistenți (7% la $K = 1$)
- Valoarea critică max- t simulată sub ipoteza nulă, cu aceeași dependență, păstrează rata aproape de 5%: 4% la $K = 20$ (logica Reality Check)
- BET în Capitolul 0: p naiv = 0,006, p Reality Check = 0,06
- Preînregistrați K ; raportați toate cele K rezultate

Leakage și look-ahead

- **Leakage:** informația din perioada de evaluare intră în model [Kaufman et al. \(2012\)](#)
 - ▶ selecția predictorilor, a lagurilor sau a hiperparametrilor pe întregul eșantion
 - ▶ scalare, eliminarea trendului, filtrare (HP, wavelet) sau imputare cu statistici din întregul eșantion
 - ▶ K-fold aleator cu reziduuri dependente sau ținte suprapuse ([Capitolul 12](#))
- **Look-ahead:** folosirea datelor care nu erau disponibile la data prognozei
 - ▶ date revizuite în locul edițiilor în timp real; întârzierile de publicare ignorate
 - ▶ modele preantrenate ale căror date de antrenare acoperă perioada de test ([Capitolul 13](#))
- Testul: aș fi putut calcula această prognoză la acea dată, cu acea informație?

Selecția predictorilor cu look-ahead



- 1 000 de simulări: $T = 240$, ultimele 60 de perioade pentru test, 100 de predictorii candidați de tip zgomot pur, se păstrează cei 5 mai corelați, MCO pe eșantionul de antrenare

Interpretarea experimentului cu leakage

- ▣ Selecție corectă: R^2 mediu în afara eșantionului = $-13,3\%$, pozitiv în 8% din rulări: zgomotul nu prognozează
- ▣ Selecție pe întregul eșantion: media 5,9%, pozitiv în 81% din rulări: un „câștig de prognoză” creat chiar de perioada de test
- ▣ Evaluarea în afara eșantionului vă protejează doar dacă fiecare alegere se face în fereastra de antrenare [Inoue și Kilian \(2005\)](#)
- ▣ Același mecanism a supraestimat scorurile de validare din [Capitolul 12](#) (raport 0,34)

Afirmații exagerate

- **Limbaj causal pentru rezultate predictive**
 - ▶ „cauzează în sens Granger” nu înseamnă „cauzează”; un factor comun sau momentul observării o produc ([Capitolul 14](#))
- **Semnificația în locul mărimii**
 - ▶ un test DM semnificativ cu o reducere a pierderii de 0,3% este un câștig mic; raportați efectul și intervalul lui
- **Generalitate pe baza unui singur eșantion**
 - ▶ o piață, o perioadă, o specificație; spuneți-o în titlu și în rezumat
- **Absența dovezii drept dovadă a absenței**
 - ▶ o nerespingere cu putere mică spune puțin: calculați puterea (nowcast-ul României, $p = 0,76$)



Clive Granger (2008)

Foto: Olaf Storbeck (2008); CC BY-SA 2.0; [Wikimedia](#)

[Commons](#)

Recapitulare: erorile frecvente

- ▣ O căutare raportată ca un singur test produce descoperiri din zgomot; preînregistrați K și corecți
- ▣ Fiecare alegere în fereastra de antrenare, fiecare dată disponibilă la data prognozei
- ▣ Afirmații nu mai puternice decât designul: predicția nu este cauzalitate, semnificația nu este mărime

Formatul susținerii

- ▣ Individuală, circa 15 minute pentru fiecare student
 - ▶ fiecare membru este examinat separat și primește o notă separată (50% din nota finală)
- ▣ 5 minute: prezentarea contribuției proprii, adică a părții de proiect coordonate de student, pe baza raportului și a repository-ului
- ▣ 10 minute: întrebări despre cod, metodă și rezultate
 - ▶ codul: deschideți un fișier, explicați o funcție, spuneți ce se schimbă dacă se schimbă o alegere
 - ▶ metoda: teoria din spatele ei, ipotezele și alternativele
 - ▶ rezultatele: interpretați un rezultat, un test, o figură; apărați inferența
- ▣ Se notează după criteriile de pe slide-ul următor
- ▣ Fiecare membru trebuie să poată răspunde la întrebări despre întregul proiect, nu doar despre partea proprie
- ▣ Fără instrumente AI în timpul susținerii; în română sau în engleză



Academia de Studii Economice din București

Foto: Joe Mabel (2014); CC BY 3.0; Wikimedia

[Commons](#)

Criteriile de evaluare a susținerii individuale

Criteriul	Puncte	Ce aduce punctele
Stăpînirea metodei	25	formulează modelul și ipotezele, derivă rezultatul-cheie, știe cînd metoda nu funcționează
Stăpînirea codului și a datelor	20	explică orice funcție din repository, sursa și ediția datelor, efectul schimbării unei setări
Inferența și interpretarea	25	erori standard valide pentru date dependente, mărimi ale efectelor cu intervale, citirea corectă a testelor și a nerespingerilor
Replicarea și robustețea	20	explică diferențele față de lucrare, designul de robustețe și limitele concluziei
Integritatea cercetării și folosirea AI	10	descrie ce a făcut AI, ce erori au fost depistate și cum; abaterile de la preînregistrare

- Nota la susținere este punctajul din 100 împărțit la 10; un membru care nu poate explica codul predat nu poate promova

Criteriile care diferențiază notele

▣ 9–10

- ▶ răspunde la „de ce” și „ce s-ar întâmpla dacă”, nu doar la „ce”; anticipează punctele slabe și le-a testat

▣ 7–8

- ▶ metode și interpretare corecte; ezită la alternative sau la asimptotică

▣ 5–6

- ▶ poate rula și descrie codul; citește mecanic p-value-urile; legătură limitată cu teoria

▣ sub 5

- ▶ nu poate explica propriul cod sau propriile rezultate; afirmații nesusținute de rezultate; folosire nedeclarată a AI

Întrebări tipice cu răspunsuri-model (1/3): codul

- **Întrebare:** Unde se fixează în codul dumneavoastră mulțimea de informație a prognozei pentru data t ?
 - ▶ **Răspuns-model:** În bucla walk-forward: fereastra de estimare se termină la $t - h$, iar scalarea, selecția și calibrarea hiperparametrilor se recalculează în buclă (arată liniile)
- **Întrebare:** Câte laguri HAC folosiți și de ce?
 - ▶ **Răspuns-model:** Regula Newey–West $\lfloor 4(T/100)^{2/9} \rfloor$ (T : mărimea eșantionului; $\lfloor \cdot \rfloor$: partea întreagă), cel puțin $h - 1$ pentru erori suprapuse la h pași; verificat cu valori critice fixed- b ([Capitolul 0](#))
- **Întrebare:** Ce se întâmplă dacă schimbați seed-ul?
 - ▶ **Răspuns-model:** Am rulat din nou cu zece seed-uri: ierarhia nu se schimbă, pierderea variază cu mai puțin decât eroarea ei standard (un tabel în raport)

Întrebări tipice cu răspunsuri-model (2/3): rezultatele

- **Întrebare:** Testul DM dă $p = 0,03$: este modelul dumneavoastră mai bun?
 - ▶ **Răspuns-model:** Mai bun pentru funcția de pierdere preînregistrată, pe acest eșantion: diferența medie a pierderilor este X , cu un interval HAC; modelele nu sînt imbricate, deci DM este valid; pentru mai multe modele raportăm MCS
- **Întrebare:** Replicarea diferă de tabelul 2 din lucrare. De ce?
 - ▶ **Răspuns-model:** Pe eșantionul original coincidem la două zecimale; diferența apare cu ediția actuală a datelor, deci este revizuire, nu cod (arată cele două rulări)
- **Întrebare:** Ce rezultat v-ar fi făcut să respingeți ipoteza?
 - ▶ **Răspuns-model:** Preînregistrarea o spune: o dată placebo cu un efect asemănător sau un efect care își schimbă semnul între grupurile de donatori

Întrebări tipice cu răspunsuri-model (3/3): capitolele

- **Întrebare:** De ce nu puteți folosi valori critice χ^2 pentru a testa două regimuri față de unul?
 - ▶ **Răspuns-model:** Sub ipoteza nulă, probabilitățile de tranziție nu sînt identificate, un parametru este la limită și scorul este zero: este nevoie de bootstrap sau de metodele lui Hansen și Garcia ([Capitolul 7](#))
- **Întrebare:** De ce este acceptabilă validarea K-fold pentru modelul AR, dar nu pentru random forest?
 - ▶ **Răspuns-model:** Pentru o autoregresie bine specificată reziduurile sînt necorelate, deci partițiile sînt valide [Bergmeir, Hyndman și Koo \(2018\)](#); reziduurile random forest sînt autocorelate, deci folosim blocuri și purjare ([Capitolul 12](#))
- **Întrebare:** Este un test Granger semnificativ un efect cauzal?
 - ▶ **Răspuns-model:** Nu: este predictiv, relativ la o mulțime de informație; o afirmație cauzală cere o ipoteză de identificare despre alocare, de exemplu un instrument sau un control sintetic cu placebo ([Capitolul 14](#))

Unde greșesc susținerile

- ▣ Cod scris de altcineva (un coleg sau un asistent AI) pe care cel care prezintă nu îl poate explica
- ▣ Un p-value citit drept probabilitatea ca ipoteza să fie adevărată
- ▣ Un câștig de prognoză fără test sau un test fără mărimea câștigului
- ▣ Necunoașterea datelor: sursa, frecvența, ediția, transformările, datele eșantionului
- ▣ Rezultate din raport pe care repository-ul nu le reproduce
- ▣ Apărarea fiecărui rezultat în loc de explicarea limitelor lui

AI_USE.md: ce s-a cerut și ce s-a păstrat

- ▣ Instrumentele AI sînt permise și se declară; folosirea nedeclarată este considerată plagiat
- ▣ Pentru fiecare folosire, o intrare
 - ▶ instrumentul și versiunea, data, etapa din fluxul de cercetare
 - ▶ promptul (sau un rezumat fidel al lui)
 - ▶ ce s-a păstrat, ce s-a modificat sau respins și cum s-a verificat
- ▣ Folosiri utile
 - ▶ căutarea literaturii cu DOI verificate; prime variante de cod, cu teste; critica designului în rolul unui recenzent ostil [Korinek \(2023\)](#)
- ▣ Folosiri riscante
 - ▶ referințe, rezultate și date preluate fără verificare [Walters și Wilder \(2023\)](#); text care afirmă mai mult decît rezultatele
 - ▶ iluzia înțelegerii: un text fluent confundat cu cunoașterea [Messori și Crockett \(2024\)](#)

AI_ERRORS.md: cel puțin trei erori depistate

Tipul	Exemplu din curs	Cum se depistează
referință inventată	un titlu plauzibil cu un DOI care duce la altă lucrare	căutare în Crossref: titlul și autorii trebuie să coincidă
formulă greșită	ES evaluat singur cu o pierdere de cuantilă (Capitolul 9)	derivare pe hîrtie; o simulare cu răspuns cunoscut
leakage în cod	o scalare estimată pe întregul eșantion înainte de împărțire	testul datei: recalculați o prognoză doar cu datele de pînă la data ei
opțiune implicită greșită	o valoare critică χ^2 pentru un test sup (Capitolul 2)	citiți documentația și lucrarea; reproduceți o valoare publicată
afirmație exagerată	„cauzalitatea Granger dovedește că ...” (Capitolul 14)	comparați fiecare frază cu designul

- Fiecare intrare: ce a produs instrumentul, de ce era greșit, cum a fost depistat, ce l-a înlocuit

Un protocol de verificare

- Referințele: fiecare DOI verificat și titlul confirmat; rezultatul invocat găsit în lucrare
- Codul: rulat pe un proces simulat cu parametri cunoscuți înainte de datele reale; comparat cu o a doua implementare
- Rezultatele: fiecare rezultat din raport regenerat de repository; niciunul copiat dintr-o conversație
- Datele calendaristice și faptele: din surse oficiale (Eurostat, BNR, Monitorul Oficial), nu din memoria modelului
- Textul: fiecare afirmație verificată față de design (predicție, asociere sau cauzalitate)
- La susținere explicați totul singur: ce nu puteți explica nu ar trebui să fie în proiect

Întrebarea deschisă

- ▣ **Ce rezultate de referință din econometria seriilor de timp rezistă pe date noi și de ce unele nu?**
 - ▶ replicările din curs indică edițiile datelor, eşantioanele și inferența; un răspuns sistematic, pentru mai multe lucrări, nu există
- ▣ Instrumentele AI schimbă costul fiecărei etape
 - ▶ hărți ale literaturii și variante de cod în câteva ore [Wang et al. \(2023\)](#); s-au propus fluxuri complet automatizate [Lu et al. \(2024\)](#)
 - ▶ resursa rară devine judecata: designul, verificările, interpretarea
- ▣ Proiectul dumneavoastră este un punct de date pentru această întrebare: o replicare cu un verdict clar și un motiv documentat


Bucula de cercetare cu un asistent AI

- Un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau Copilot) accelerează fiecare etapă; Semantic Scholar și Elicit ajută la literatură
 - ▶ **literatura:** Listează replicările lucrării Meese și Rogoff (1983) pentru monedele din Europa Centrală și de Est din 2010 încoace, cu DOI, orizonturi și verdictice. Apoi verificați fiecare DOI
 - ▶ **designul:** Pentru o diferență a pierderilor cu autocorelația 0,3, câte luni în afara eșantionului sînt necesare pentru o putere de 80% la detectarea unui câștig mediu de 0,2 abateri standard?
 - ▶ **cod și replicare:** cereți o funcție DM–HLN, apoi testați-o pe date simulate cu răspuns cunoscut
 - ▶ **critica:** Joacă rolul unui recenzent ostil al acestei preînregistrări: unde pot rezultatele să influențeze designul?
- Raportul: ce s-a cerut, ce s-a păstrat, ce s-a respins (AI_USE.md, AI_ERRORS.md)

Verificări necesare

- ❑ Lucrarea există, spune ce se afirmă, iar datele ei sînt disponibile azi
- ❑ Calculul puterii folosește dependența propriei diferențe a pierderilor, estimată pe perioada de antrenare
- ❑ Formula din spatele unui răspuns AI: o afirmație despre putere fără varianța de termen lung este greșită pentru date dependente
- ❑ Extensia este realizabilă într-un semestru cu instrumentele cursului
- ❑ Criteriile verdictului (replicat, parțial, nereplicat) sînt scrise înainte de a rula replicarea

Mini studiu de caz: este eșantionul de evaluare destul de lung?



- Rata de respingere a testului DM–HLN (5%, bilateral, 2 000 de simulări) când diferența pierderilor este un câștig mediu δ plus un zgomot AR(1) cu coeficientul $\rho = 0,3$ și varianța 1
- Punctat: aproximarea $\Phi(\delta\sqrt{P/\Omega} - 1,96)$; Φ : funcția de repartiție a distribuției Normale standard; P : numărul de observații în afara eșantionului; Ω : varianța de termen lung a diferenței

Interpretarea mini studiului de caz

- ▣ Un câștig de 0,2 abateri standard este detectat cu probabilitatea 38% la $P = 100$ și 89% la $P = 500$; o putere de 80% cere aproximativ 364 de observații
- ▣ Un câștig de 0,1 cere aproximativ 1458: mai mult de 120 de ani de date lunare; un câștig de 0,3 aproximativ 162
- ▣ Regula de mărime a eșantionului $P \approx \Omega (z_{0,975} + z_{0,8})^2 / \delta^2$, cu $\Omega = (1 + \rho) / (1 - \rho) = 1,86$: dependența multiplică eșantionul necesar
 - ▶ $z_{0,975} = 1,96$, $z_{0,8} = 0,84$: cuantilele distribuției Normale pentru un test bilateral de 5% și o putere de 80%;
 δ : câștigul mediu, în abateri standard
- ▣ Cu puține observații testul este și supradimensionat: 10,1% la $P = 50$
- ▣ Alegeți o întrebare la care datele pot răspunde: datele macro lunare detectează rar câștiguri mici, datele zilnice sau intrazilnice pot

Idee de proiect

▣ **Alegerea proiectului: patru criterii**

- ▶ o lucrare de referință cu date publice sau o descriere precisă a datelor și un rezultat de reprodus
- ▶ o extensie care răspunde unei întrebări noi, de preferință pe date din România sau din UE
- ▶ suficientă putere pentru evaluarea planificată (mini studiul de caz)
- ▶ o regulă a verdictului scrisă înaintea primei estimări

▣ **Exemplu:** de ce eșuează unele replicări? Un audit de replicare pentru trei lucrări din curs

- ▶ replicați [Taylor, Peel și Sarno \(2001\)](#), [Patton, Ziegel și Chen \(2019\)](#) și [Born et al. \(2019\)](#) pe datele originale și pe cele de azi; atribuiți fiecare diferență ediției, eșantionului, implementării sau inferenței
- ▶ extindeți: ediții arhivate ale datelor (ALFRED, OECD Economic Outlook), o curbă a specificațiilor, o analiză a puterii fiecărui test original

▣ Livrabilele urmează regulile cursului: repository, raport, AI_USE.md, AI_ERRORS.md, susținere orală

Idei de reținut

- ▣ Cinci întrebări pentru orice analiză: ținta, dependența, identificarea, evaluarea, robustețea
- ▣ Majoritatea rezultatelor de referință se replică în sens; mărimea și testele lor depind de ediția datelor, de eșantion și de inferență
- ▣ Preînregistrați designul, calculați puterea și faceți fiecare rezultat reproductibil dintr-o singură comandă
- ▣ Căutările, leakage-ul și look-ahead creează descoperiri din zgomot; cuvintele cauzale cer designuri cauzale
- ▣ Susținerea este individuală: explicați singur metoda, codul, inferența și limitele

Autoevaluare

Întrebări

- ▣ Ce ipoteză identifică rezultatul principal al proiectului dumneavoastră?
- ▣ Câte specificații ați încercat și cum ține cont inferența dumneavoastră de ele?
- ▣ Ar fi putut fi calculată fiecare prognoză la data ei?
- ▣ Care este puterea testului principal?
- ▣ Care dintre rezultatele dumneavoastră s-ar schimba cu o nouă ediție a datelor?

Studiu suplimentar

- ▣ Christensen și Miguel (2018); Clemens (2017); Menkveld et al. (2024)
- ▣ Diebold (2015); Lazarus et al. (2018)
- ▣ Capitolul 16 (studiu individual) și quiz-ul lui

Anexă: idei de proiect pe capitole (1/2)

Cap.	Replicați	Extindeți
0	Estrella și Hardouvelis (1991)	zona euro și România; inferență fixed- b ; stabilitatea pe decenii
1	Meese și Rogoff (1983)	monedele din ECE, prognoze de densitate, fundamente macro în timp real
2	Bai și Perron (2003)	rupturi în inflația României și în dobînda de politică monetară; monitorizare în timp real
3	Gertler și Karadi (2015)	surprizele BCE și condițiile financiare din România cu LP-IV
4	Pesaran, Shin și Smith (1999)	transmiterea dobînzilor în UE cu CCE
5	Bańbura, Giannone și Reichlin (2010)	un BVAR mare cu volatilitate stochastică pentru România, nowcasting cu știri
6	Morley, Nelson și Zivot (2003)	output gap-ul României și revizuirile lui în timp real
7	Hamilton (1989)	probabilități de recesiune în timp real pentru zona euro
8	Bollerslev, Patton și Quaedvlieg (2016)	HARQ pentru BET și EUR/RON cu măsuri realizate

Anexă: idei de proiect pe capitole (2/2)

Cap.	Replicați	Extindeți
9	Patton, Ziegel și Chen (2019)	indicii din ECE; puterea backtest-urilor
10	Gatheral, Jaisson și Rosenbaum (2018)	caracterul rough al volatilității în ECE și pe crypto; robustețea la zgomot
11	Cogley și Nason (1995), Hamilton (2018)	output gap-uri în timp real pentru statele membre UE
12	Zeng et al. (2023)	consumul de electricitate din UE; modele globale; comparații oneste
13	Gibbs și Candès (2021)	VaR conformal pentru BET; acoperire pe regimuri
14	Abadie, Diamond și Hainmueller (2015), Born et al. (2019)	măsurile fiscale și energetice în ECE cu controale sintetice
16	Phillips și Yu (2011)	prețurile și chiriile locuințelor în capitalele UE
15	Taylor, Peel și Sarno (2001), Patton, Ziegel și Chen (2019), Born et al. (2019)	un audit de replicare (ideea de proiect a acestui capitol)

- ☐ Partea C a fiecărui seminar conține încă o idee de proiect, cu datele ei

Anexă: un model de preînregistrare

- ▣ 1. **Întrebarea și ipotezele:** ipoteza principală, într-o frază; ipotezele secundare
- ▣ 2. **Lucrarea replicată:** tabelul sau figura, eşantionul, ce înseamnă „replicat”, „parțial”, „nereplicat”
- ▣ 3. **Datele:** seriile, sursele, data ediției, frecvența, transformările, excluderile
- ▣ 4. **Modelele:** reperul și modelele concurente, metoda de estimare, alegerea hiperparametrilor (în fereastra de antrenare)
- ▣ 5. **Evaluarea:** ferestrele (mobile sau extinse), orizonturile, funcțiile de pierdere, testele, corecția pentru testarea multiplă, calculul puterii
- ▣ 6. **Robustețea:** lista variațiilor și regula pentru un rezultat robust
- ▣ 7. **Echipa:** cine coordonează fiecare parte (baza susținerii individuale)



Bibliografie (1/6)

- ▣ Abadie, A., Diamond, A., & Hainmueller, J. (2015). Comparative politics and the synthetic control method. *American Journal of Political Science*, 59(2), 495–510. doi:10.1111/ajps.12116
- ▣ Atkeson, A., & Ohanian, L. E. (2001). Are Phillips curves useful for forecasting inflation? *Federal Reserve Bank of Minneapolis Quarterly Review*, 25(1), 2–11. doi:10.21034/qv.2511
- ▣ Bańbura, M., Giannone, D., & Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71–92. doi:10.1002/jae.1137
- ▣ Bai, J., & Perron, P. (2003). Computation and analysis of multiple structural change models. *Journal of Applied Econometrics*, 18(1), 1–22. doi:10.1002/jae.659
- ▣ Bergmeir, C., Hyndman, R. J., & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83. doi:10.1016/j.csda.2017.11.003
- ▣ Bollerslev, T., Patton, A. J., & Quaedvlieg, R. (2016). Exploiting the errors: A simple approach for improved volatility forecasting. *Journal of Econometrics*, 192(1), 1–18. doi:10.1016/j.jeconom.2015.10.007
- ▣ Born, B., Müller, G. J., Schularick, M., & Sedláček, P. (2019). The costs of economic nationalism: Evidence from the Brexit experiment. *The Economic Journal*, 129(623), 2722–2744. doi:10.1093/ej/uez020
- ▣ Brodeur, A., Lé, M., Sangnier, M., & Zylberberg, Y. (2016). Star wars: The empirics strike back. *American Economic Journal: Applied Economics*, 8(1), 1–32. doi:10.1257/app.20150044
- ▣ Chang, A. C., & Li, P. (2022). Is economics research replicable? Sixty published papers from thirteen journals say “often not”. *Critical Finance Review*, 11(1), 185–206. doi:10.1561/104.00000053
- ▣ Christensen, G., & Miguel, E. (2018). Transparency, reproducibility, and the credibility of economics research. *Journal of Economic Literature*, 56(3), 920–980. doi:10.1257/jel.20171350
- ▣ Christiano, L. J., Eichenbaum, M., & Evans, C. L. (1999). Monetary policy shocks: What have we learned and to what end? In J. B. Taylor & M. Woodford (Eds.), *Handbook of Macroeconomics*, Vol. 1A, 65–148. Elsevier. doi:10.1016/S1574-0048(99)01005-8
- ▣ Clark, T. E., & West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311. doi:10.1016/j.jeconom.2006.05.023
- ▣ Clemens, M. A. (2017). The meaning of failed replications: A review and proposal. *Journal of Economic Surveys*, 31(1), 326–342. doi:10.1111/joes.12139

Bibliografie (2/6)

- Cogley, T., & Nason, J. M. (1995). Effects of the Hodrick–Prescott filter on trend and difference stationary time series: Implications for business cycle research. *Journal of Economic Dynamics and Control*, 19(1–2), 253–278. doi:10.1016/0165-1889(93)00781-X
- Diebold, F. X. (2015). Comparing predictive accuracy, twenty years later: A personal perspective on the use and abuse of Diebold–Mariano tests. *Journal of Business & Economic Statistics*, 33(1), 1–9. doi:10.1080/07350015.2014.983236
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Engle, R. F., Ghysels, E., & Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95(3), 776–797. doi:10.1162/REST_a_00300
- Engle, R. F., Ledoit, O., & Wolf, M. (2019). Large dynamic covariance matrices. *Journal of Business & Economic Statistics*, 37(2), 363–375. doi:10.1080/07350015.2017.1345683
- Engle, R. F., & Manganelli, S. (2004). CAViaR: Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381. doi:10.1198/073500104000000370
- Estrella, A., & Hardouvelis, G. A. (1991). The term structure as a predictor of real economic activity. *The Journal of Finance*, 46(2), 555–576. doi:10.1111/j.1540-6261.1991.tb02674.x
- Gatheral, J., Jaisson, T., & Rosenbaum, M. (2018). Volatility is rough. *Quantitative Finance*, 18(6), 933–949. doi:10.1080/14697688.2017.1393551
- Gelman, A., & Loken, E. (2014). The statistical crisis in science. *American Scientist*, 102(6), 460–465. doi:10.1511/2014.111.460
- Genre, V., Kenny, G., Meyler, A., & Timmermann, A. (2013). Combining expert forecasts: Can anything beat the simple average? *International Journal of Forecasting*, 29(1), 108–121. doi:10.1016/j.ijforecast.2012.06.004
- Gertler, M., & Karadi, P. (2015). Monetary policy surprises, credit costs, and economic activity. *American Economic Journal: Macroeconomics*, 7(1), 44–76. doi:10.1257/mac.20130329
- Gibbs, I., & Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems 34*; arXiv:2106.00170. arxiv.org
- Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384. doi:10.2307/1912559

Bibliografie (3/6)

- ▣ Hamilton, J. D. (2018). Why you should never use the Hodrick–Prescott filter. *Review of Economics and Statistics*, 100(5), 831–843. doi:10.1162/rest_a_00706
- ▣ Hansen, B. E. (1997). Inference in TAR models. *Studies in Nonlinear Dynamics & Econometrics*, 2(1), 1–14. doi:10.2202/1558-3708.1024
- ▣ Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. doi:10.1198/073500105000000063
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- ▣ Harvey, C. R., Liu, Y., & Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68. doi:10.1093/rfs/hhv059
- ▣ Harvey, D. I., Leybourne, S. J., Sollis, R., & Taylor, A. M. R. (2016). Tests for explosive financial bubbles in the presence of non-stationary volatility. *Journal of Empirical Finance*, 38, 548–574. doi:10.1016/j.jempfin.2015.09.002
- ▣ Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. doi:10.1016/S0169-2070(96)00719-4
- ▣ Herndon, T., Ash, M., & Pollin, R. (2014). Does high public debt consistently stifle economic growth? A critique of Reinhart and Rogoff. *Cambridge Journal of Economics*, 38(2), 257–279. doi:10.1093/cje/bet075
- ▣ Hou, K., Xue, C., & Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133. doi:10.1093/rfs/hhy131
- ▣ Inoue, A., & Kilian, L. (2005). In-sample or out-of-sample tests of predictability: Which one should we use? *Econometric Reviews*, 23(4), 371–402. doi:10.1081/ETC-200040785
- ▣ Ioannidis, J. P. A. (2005). Why most published research findings are false. *PLoS Medicine*, 2(8), e124. doi:10.1371/journal.pmed.0020124
- ▣ Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 15. doi:10.1145/2382577.2382579
- ▣ Kiefer, N. M., & Vogelsang, T. J. (2005). A new asymptotic theory for heteroskedasticity-autocorrelation robust tests. *Econometric Theory*, 21(6), 1130–1164. doi:10.1017/S0266466605050565

Bibliografie (4/6)

- ▣ Kilian, L. (2009). Not all oil price shocks are alike: Disentangling demand and supply shocks in the crude oil market. *American Economic Review*, 99(3), 1053–1069. doi:10.1257/aer.99.3.1053
- ▣ King, R. G., Plosser, C. I., Stock, J. H., & Watson, M. W. (1991). Stochastic trends and economic fluctuations. *American Economic Review*, 81(4), 819–840. jstor.org
- ▣ Korinek, A. (2023). Generative AI for economic research: Use cases and implications for economists. *Journal of Economic Literature*, 61(4), 1281–1317. doi:10.1257/jel.20231736
- ▣ Lazarus, E., Lewis, D. J., Stock, J. H., & Watson, M. W. (2018). HAR inference: Recommendations for practice. *Journal of Business & Economic Statistics*, 36(4), 541–559. doi:10.1080/07350015.2018.1506926
- ▣ Lu, C., Lu, C., Lange, R. T., Foerster, J., Clune, J., & Ha, D. (2024). The AI Scientist: Towards fully automated open-ended scientific discovery. arXiv:2408.06292. arxiv.org
- ▣ McConnell, M. M., & Perez-Quiros, G. (2000). Output fluctuations in the United States: What has changed since the early 1980's? *American Economic Review*, 90(5), 1464–1476. doi:10.1257/aer.90.5.1464
- ▣ Meese, R. A., & Rogoff, K. (1983). Empirical exchange rate models of the seventies: Do they fit out of sample? *Journal of International Economics*, 14(1–2), 3–24. doi:10.1016/0022-1996(83)90017-X
- ▣ Menkveld, A. J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *The Journal of Finance*, 79(3), 2339–2390. doi:10.1111/jofi.13337
- ▣ Messeri, L., & Crockett, M. J. (2024). Artificial intelligence and illusions of understanding in scientific research. *Nature*, 627(8002), 49–58. doi:10.1038/s41586-024-07146-0
- ▣ Morley, J. C., Nelson, C. R., & Zivot, E. (2003). Why are the Beveridge–Nelson and unobserved-components decompositions of GDP so different? *Review of Economics and Statistics*, 85(2), 235–243. doi:10.1162/003465303765299765
- ▣ Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. doi:10.2307/1913610
- ▣ Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with Transformers. *International Conference on Learning Representations*; arXiv:2211.14730. arxiv.org
- ▣ Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11), 2600–2606. doi:10.1073/pnas.1708274114

Bibliografie (5/6)

- ▣ Patton, A. J., Ziegel, J. F., & Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and Value-at-Risk). *Journal of Econometrics*, 211(2), 388–413. doi:10.1016/j.jeconom.2018.10.008
- ▣ Peng, R. D. (2011). Reproducible research in computational science. *Science*, 334(6060), 1226–1227. doi:10.1126/science.1213847
- ▣ Pesaran, M. H., Shin, Y., & Smith, R. P. (1999). Pooled mean group estimation of dynamic heterogeneous panels. *Journal of the American Statistical Association*, 94(446), 621–634. doi:10.1080/01621459.1999.10474156
- ▣ Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Ben Taieb, S., et al. (2022). Forecasting: theory and practice. *International Journal of Forecasting*, 38(3), 705–871. doi:10.1016/j.ijforecast.2021.11.001
- ▣ Phillips, P. C. B., Shi, S., & Yu, J. (2015). Testing for multiple bubbles: Historical episodes of exuberance and collapse in the S&P 500. *International Economic Review*, 56(4), 1043–1078. doi:10.1111/iere.12132
- ▣ Phillips, P. C. B., Wu, Y., & Yu, J. (2011). Explosive behavior in the 1990s Nasdaq: When did exuberance escalate asset values? *International Economic Review*, 52(1), 201–226. doi:10.1111/j.1468-2354.2010.00625.x
- ▣ Phillips, P. C. B., & Yu, J. (2011). Dating the timeline of financial bubbles during the subprime crisis. *Quantitative Economics*, 2(3), 455–491. doi:10.3982/QE82
- ▣ Qu, Z. (2011). A test against spurious long memory. *Journal of Business & Economic Statistics*, 29(3), 423–438. doi:10.1198/jbes.2010.09153
- ▣ Romano, J. P., & Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282. doi:10.1111/j.1468-0262.2005.00615.x
- ▣ Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems 32*; arXiv:1905.03222. [arxiv.org](https://arxiv.org/abs/1905.03222)
- ▣ Silberzahn, R., Uhlmann, E. L., Martin, D. P., Anselmi, P., Aust, F., Awtrey, E., et al. (2018). Many analysts, one data set: Making transparent how variations in analytic choices affect results. *Advances in Methods and Practices in Psychological Science*, 1(3), 337–356. doi:10.1177/2515245917747646
- ▣ Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science*, 22(11), 1359–1366. doi:10.1177/0956797611417632
- ▣ Simonsohn, U., Simmons, J. P., & Nelson, L. D. (2020). Specification curve analysis. *Nature Human Behaviour*, 4(11), 1208–1214. doi:10.1038/s41562-020-0912-z

Bibliografie (6/6)

- ▣ Stambaugh, R. F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421. doi:10.1016/S0304-405X(99)00041-0
- ▣ Steegen, S., Tuerlinckx, F., Gelman, A., & Vanpaemel, W. (2016). Increasing transparency through a multiverse analysis. *Perspectives on Psychological Science*, 11(5), 702–712. doi:10.1177/1745691616658637
- ▣ Stock, J. H., & Watson, M. W. (2002). Macroeconomic forecasting using diffusion indexes. *Journal of Business & Economic Statistics*, 20(2), 147–162. doi:10.1198/073500102317351921
- ▣ Taylor, M. P., Peel, D. A., & Sarno, L. (2001). Nonlinear mean-reversion in real exchange rates: Toward a solution to the purchasing power parity puzzles. *International Economic Review*, 42(4), 1015–1042. doi:10.1111/1468-2354.00144
- ▣ Vilhuber, L. (2020). Reproducibility and replicability in economics. *Harvard Data Science Review*, 2(4). doi:10.1162/99608f92.4f6b9e67
- ▣ Walters, W. H., & Wilder, E. I. (2023). Fabrication and errors in the bibliographic citations generated by ChatGPT. *Scientific Reports*, 13, 14045. doi:10.1038/s41598-023-41032-5
- ▣ Wang, H., Fu, T., Du, Y., Gao, W., Huang, K., Liu, Z., et al. (2023). Scientific discovery in the age of artificial intelligence. *Nature*, 620(7972), 47–60. doi:10.1038/s41586-023-06221-2
- ▣ Welch, I., & Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508. doi:10.1093/rfs/hhm014
- ▣ White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126. doi:10.1111/1468-0262.00152
- ▣ Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128. doi:10.1609/aaai.v37i9.26317