



Analiza avansată a seriilor de timp și previziune

Seminarul 1: Evaluarea prognozelor, reguli de scor și combinarea prognozelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARX:** AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- ▣ **BNR:** Banca Națională a României
- ▣ **COVID:** COronaVirus Disease (2019 pandemic) — boala provocată de coronavirus (pandemia din 2019)
- ▣ **CRPS:** Continuous Ranked Probability Score (scorul probabilistic continuu)
- ▣ **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **ENTSO-E:** European Network of Transmission System Operators for Electricity (Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- ▣ **ES:** Expected Shortfall (pierderea așteptată în coadă)
- ▣ **FRED:** Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ **GARCH:** Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **GW:** Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- ▣ **HAC:** Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație

Acronime folosite în acest material (2/2)

- ▣ **HLN**: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **IS**: In-Sample (în eșantion)
- ▣ **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MCS**: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **MZ**: Mincer–Zarnowitz (regression) — regresia Mincer–Zarnowitz
- ▣ **PIB**: Produsul intern brut
- ▣ **PIT**: Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **RTDSM**: Real-Time Data Set for Macroeconomists (Philadelphia Fed) — setul de date în timp real pentru macroeconomiști (Philadelphia Fed)
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **SPA**: Superior Predictive Ability (test) — testul abilității predictive superioare
- ▣ **SPF**: Survey of Professional Forecasters (Federal Reserve Bank of Philadelphia) — ancheta trimestrială a prognozatorilor profesioniști (Banca Rezervei Federale din Philadelphia)
- ▣ **SUA**: Statele Unite ale Americii

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum decidem, cu inferența corectă, că o prognoză este mai bună decât alta și când ajută medierea prognozelor?
 - ▶ seminarul are loc **înaintea** Cursului 1: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: prognoze optime sub patru pierderi; scorul logaritm, CRPS, un scor impropriu, scorul de interval; DM, HLN și Clark–West de mînă; ponderile Bates–Granger și costul estimării lor
 - ▶ Partea B: creșterea PIB din România; prognozele SPF pentru șomaj; prognoze de densitate pentru EUR/RON; versiunile datelor de PIB; consumul de electricitate din România la vîrf de seară
 - ▶ Partea C: o evaluare preînregistrată a prognozelor inflației din România pe orizonturi; un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	proгноze punctuale optime: pătratică, absolută, pinball, LinEx	Rezolvat, Propus	A1
A3, A4	scorul logaritmăic și CRPS; un scor impropriu; scorul de interval	Rezolvat, Propus	A3
A5, A6	DM și HLN de mîină; Clark–West de mîină	Rezolvat, Propus	A5
A7, A8	ponderile Bates–Granger; costul ponderilor estimate	Rezolvat, Propus	A7
B1, B2	creșterea PIB din România; combinarea prognozelor SPF pentru șomaj	Rezolvat, Propus	B1
B3–B5	densități EUR/RON; versiuni ale PIB; cuantile ale consumului la vîrful de seară	Rezolvat, Propus	B1, B3
C1, C2	proгноzele inflației pe orizonturi; ce este greșit într-un răspuns AI?	Propus	B1, A1–A8

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
PIB real, România (ajustat sezonier)	Eurostat (namq_10_gdp)	trimestrial	1995–2026
proгноzele individuale SPF	Philadelphia Fed	trimestrial	1990–2025
rata șomajului, SUA	FRED (UNRATE)	lunar	1990–2026
EUR/RON	cursul de referință BNR	zilnic	2010–2026
creșterea PIB real, toate versiunile, SUA	Philadelphia Fed (RTDSM)	trimestrial	1990–2025
consumul de electricitate, România	Energy-Charts (date ENTSO-E)	orar	2023–2026
inflația IAPC, România	Eurostat (prc_hicp_minr)	lunar	1997–2026

- În notebook: `dm_test`, `cw_test`, `mz_test`, `berkowitz_test`, `crps_normal`, `combine_spf`, `load_forecasts`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/24): prognoze și erori de prognoză

- Seminarul are loc **înaintea** Cursului 1

- ▶ slide-urile următoare dau doar noțiunile folosite în cerințe; detaliile sînt în [Capitolul 1](#)

- La **originea** t prognozăm **ținta** y_{t+h} , cu h perioade înainte (**orizontul**)

$$\hat{y}_{t+h|t} = \text{o funcție de } \mathcal{F}_t, \quad e_{t+h} = y_{t+h} - \hat{y}_{t+h|t}$$

- ▶ $\mathcal{F}_t$: informația disponibilă la momentul t ; e_{t+h} : **eroarea de prognoză**

- ▶ fereastră **recursivă** (extinsă): estimăm pe toate datele pînă la t ; fereastră **mobilă** (rolling): doar pe ultimele w observații

- Repere și modele simple

- ▶ media istorică $\hat{y}_{t+h|t} = \bar{y}_t$; **fără schimbare** (mers aleator) $\hat{y}_{t+h|t} = y_t$

- ▶ AR(1): $\hat{y}_{t+1|t} = \hat{c} + \hat{\phi}y_t$; AR(p) **direct** la orizontul h : regresăm y_{t+h} pe $y_t, \dots, y_{t-p+1}$

Noțiuni necesare azi (2/24): măsuri de acuratețe

- Pe P prognoze în afara eșantionului de estimare, cu erorile $e_1, \dots, e_P$

$$\text{RMSE} = \sqrt{\frac{1}{P} \sum_{t=1}^P e_t^2}, \quad \text{MAE} = \frac{1}{P} \sum_{t=1}^P |e_t|$$

- ▶ RMSE (rădăcina erorii pătratice medii) și MAE (eroarea absolută medie): în unitățile lui y ; o valoare mai mică este mai bună
- ▶ RMSE pune o pondere mai mare pe erorile mari; $\text{MSE} = \text{RMSE}^2$
- **RMSE relativ:** $\text{RMSE}_{\text{model}} / \text{RMSE}_{\text{reper}}$
 - ▶ sub 1: modelul bate reperul în eșantion; dacă diferența este semnificativă se decide printr-un test (Diebold–Mariano, mai jos)
- O **funcție de pierdere** $L(x, y)$ evaluează costul prognozei x când se realizează y
 - ▶ majoritatea pierderilor depind doar de eroarea $e = y - x$: $L(e)$



Noțiuni necesare azi (3/24): pierderea și prognoza optimă

- $Y \sim F$: **distribuția predictivă** a țintei; prognoza **optimă** minimizează pierderea așteptată

$$x^* = \arg \min_x \mathbb{E}_F L(x, Y)$$


- ▶ minimul, $\mathbb{E}_F L(x^*, Y)$, este **riscul** prognozei optime
- ▶ L este **consistentă** pentru o funcțională (media, cuantila) dacă acea funcțională este optimă pentru orice F
- Trei pierderi și prognozele lor optime
 - ▶ pătratică $e^2 \rightarrow$ media $\mathbb{E}Y$; absolută $|e| \rightarrow$ mediana $F^{-1}(1/2)$
 - ▶ **pinball** $\rho_\tau(e) = (\tau - 1\{e < 0\})e \rightarrow$ cuantila de ordin τ , $F^{-1}(\tau)$
 - ▶ $\tau \in (0, 1)$: nivelul cuantilei; $1\{e < 0\} = 1$ dacă prognoza este prea mare, 0 altfel
 - ▶ condiția de ordinul întâi a pierderii pinball: $F(x) - \tau = 0$

Noțiuni necesare azi (4/24): pierderi simetrice și asimetrice



- Stînga: pierderea pătratică penalizează erorile mari mult mai mult decât pierderea absolută
- Dreapta: cu $\tau = 0,9$, o prognoză prea mică ($e > 0$) costă 0,9 pe unitate, una prea mare doar 0,1; LinEx este exponențială pe o parte

Noțiuni necesare azi (5/24): o distribuție, trei prognoze optime



- O distribuție predictivă asimetrică la dreapta: Gamma(2, 1)
- Fiecare pierdere cere un alt număr
 - ▶ pătratică: media
 - ▶ absolută: mediana
 - ▶ pinball cu $\tau = 0,9$: punctul care are la stînga 90% din probabilitate
- Prognozatorul trebuie să cunoască pierderea **înainte** de a face prognoza
- Exponențială(λ): $F(y) = 1 - e^{-\lambda y}$, $y \geq 0$, media $1/\lambda$

Noțiuni necesare azi (6/24): pierderea LinEx

- **LinEx**: liniară pe o parte, exponențială pe cealaltă

$$L(e) = b[e^{ae} - ae - 1], \quad b > 0$$

- ▶ b : scara; a : asimetria; $a > 0$: prognozele prea mici ($e > 0$) costă exponențial, cele prea mari aproximativ liniar
- ▶ $a \rightarrow 0$: $L(e) \approx ba^2 e^2 / 2$, adică pierderea pătratică

- Prognoza optimă

$$x^* = \frac{1}{a} \ln \mathbb{E} e^{aY}$$

- ▶ $\mathbb{E} e^{aY}$: funcția generatoare de momente a lui Y în a

- Pentru $Y \sim N(\mu, \sigma^2)$

$$\mathbb{E} e^{aY} = \exp(a\mu + a^2 \sigma^2 / 2)$$

- ▶ $Y \mid \mathcal{F}_t \sim N(\mu_t, \sigma_t^2)$: ținta are distribuție Normală dată fiind informația de la origine; μ_t, σ_t^2 : media și varianța condiționate


Noțiuni necesare azi (7/24): prognoze de densitate și PIT

- O **prognoză de densitate** dă întreaga distribuție predictivă
 - ▶ F_t : funcția de repartiție prognozată a lui y_{t+1} ; f_t : densitatea ei
- **PIT** (probability integral transform): probabilitatea prognozată a unei realizări sub cea observată

$$u_t = F_t(y_{t+1}) \in [0, 1]$$

- ▶ dacă F_t este adevărata distribuție condiționată la un pas, valorile u_t sînt i.i.d. $U(0, 1)$ **Diebold, Gunther și Tay (1998)**
- ▶ $U(0, 1)$: distribuția uniformă pe $[0, 1]$; histograma ei este plată
- Verificări ale **calibrării**
 - ▶ proporția valorilor u_t din afara intervalului $[0,05; 0,95]$: aproximativ 10% pentru o prognoză calibrată
 - ▶ **concentrarea** (sharpness): cît de îngustă este F_t ; obiectivul este concentrarea maximă sub condiția calibrării

Noțiuni necesare azi (8/24): citirea unei histograme PIT



- 2000 de realizări din $N(0, 1)$, patru prognoze
- Forme
 - ▶ plată: calibrată
 - ▶ în formă de U: prea multe realizări în ambele cozi, prognoza este **prea îngustă**
 - ▶ cocoasă: **prea largă**
 - ▶ pantă: **deplasată**; aici media prognozată este prea mare, deci valorile mici ale lui u_t sînt prea frecvente
- Linia întreruptă: densitatea constantă 1 a lui $U(0, 1)$

Noțiuni necesare azi (9/24): testul Berkowitz

- **Berkowitz** Berkowitz (2001): ducem PIT-urile pe scala Normală

$$z_t = \Phi^{-1}(u_t), \quad z_t - \mu = \rho(z_{t-1} - \mu) + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2)$$

- ▶ Φ^{-1} : funcția cuantilă a lui $N(0, 1)$; pentru prognoze corecte, z_t i.i.d. $N(0, 1)$, adică $\mu = 0$, $\sigma = 1$, $\rho = 0$

- Statistica **raportului de verosimilitate** (LR)

$$\text{LR} = 2 [\ell(\hat{\mu}, \hat{\sigma}, \hat{\rho}) - \ell(0, 1, 0)] \sim \chi^2(3)$$

- ▶ ℓ : log-verosimilitatea AR(1) gaussiană; $\hat{\mu}, \hat{\sigma}, \hat{\rho}$: valorile care o maximizează
- ▶ $\chi^2(3)$: trei restricții; valoarea critică de 5%: 7,81; un LR mare respinge calibrarea sau independența

Noțiuni necesare azi (10/24): reguli de scor proprii

- Un **scor** $S(F, y)$ evaluează o prognoză de densitate F după ce se observă y (mai mic este mai bine); este **propriu** [Gneiting și Raftery \(2007\)](#) dacă, pentru $Y \sim G$, nicio prognoză nu bate în medie adevărul

$$\mathbb{E}_G S(G, Y) \leq \mathbb{E}_G S(F, Y) \quad \text{pentru orice } F$$

- ▶ **strict propriu**: egalitate doar pentru $F = G$; un scor impropriu răsplătește o prognoză necinstită
- **Scorul logaritm**: $\text{LogS}(F, y) = -\ln f(y)$, cu f densitatea prognozată
 - ▶ **divergența Kullback–Leibler** $\text{KL}(g\|f) = \int g(y) \ln[g(y)/f(y)] dy \geq 0$ măsoară cât de departe este f de densitatea adevărată g
 - ▶ $\text{KL}(g\|f) = 0$ doar dacă $f = g$

Noțiuni necesare azi (11/24): CRPS

- **CRPS** (continuous ranked probability score): distanța pătratică dintre funcția de repartiție prognozată și treapta din punctul realizat

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} [F(z) - 1\{y \leq z\}]^2 dz = \mathbb{E}|X - y| - \frac{1}{2}\mathbb{E}|X - X'|$$


► X, X' : extrageri independente din F ; în unitățile lui y ; strict propriu

- Forma explicită pentru $F = N(\mu, \sigma^2)$, cu $z = (y - \mu)/\sigma$


$$\text{CRPS} = \sigma \left[z(2\Phi(z) - 1) + 2\varphi(z) - \frac{1}{\sqrt{\pi}} \right]$$

► Φ, φ : funcția de repartiție și densitatea lui $N(0, 1)$

Noțiuni necesare azi (12/24): scorul logaritmic și CRPS comparate




- forecast CDF $F(z)$, $N(0, 1)$
- outcome: $\mathbf{1}\{y \leq z\}$, $y = 1.2$
- squared gap integrated: CRPS



- log score, $\sigma = 1$
- - - log score, $\sigma = 0.5$
- CRPS, $\sigma = 1$
- CRPS, $\sigma = 0.5$

- Stînga: CRPS este aria diferenței pătratice dintre F și treapta din y
- Dreapta: departe în cozi, scorul logaritmic crește ca z^2 , iar CRPS doar ca $|z|$: scorul logaritmic penalizează mai dur excesul de încredere

Noțiuni necesare azi (13/24): prognoze de interval și de cuantilă



- Interval central $[l, u]$ la nivelul $1 - \alpha$; **scorul de interval**

$$IS = (u - l) + \frac{2}{\alpha}(l - y)1\{y < l\} + \frac{2}{\alpha}(y - u)1\{y > u\}$$

- ▶ lățimea plus $2/\alpha$ pentru fiecare unitate cu care y iese din interval
- ▶ propriu: răsplătește intervalele înguste doar dacă acoperă în continuare
- Interval **Acoperirea**: proporția realizărilor din $[l, u]$; ținta $1 - \alpha$
 - ▶ raportați și proporțiile sub l și peste u (fiecare $\alpha/2$)
 - ▶ o prognoză de cuantilă τ se evaluează cu pierderea pinball ρ_τ



Noțiuni necesare azi (14/24): testul Diebold–Mariano

- **Diebold–Mariano** Diebold și Mariano (1995): comparăm două prognoze prin **diferențialul de pierdere**

$$d_t = L(e_{1t}) - L(e_{2t}), \quad \text{DM} = \frac{\bar{d}}{\sqrt{\hat{\sigma}_{LR}^2/P}}, \quad \hat{\sigma}_{LR}^2 = \hat{\gamma}_0 + 2 \sum_{k=1}^{h-1} \hat{\gamma}_k$$

- ▶ H_0 : pierdere așteptată egală, $\mathbb{E}d_t = 0$; $\bar{d}$: media lui d_t pe cele P prognoze
 - ▶ $\hat{\gamma}_k$: autocovarianțele de selecție ale lui d_t ; $\hat{\sigma}_{LR}^2$: varianța lui de termen lung (Seminarul 0), cu nucleul dreptunghiular și $h - 1$ laguri
 - ▶ $\text{DM} > 0$: prognoza 2 are pierderea mai mică; distribuția de referință $N(0, 1)$
- De ce $h - 1$ laguri
- ▶ erorile la h pași au în comun $h - 1$ șocuri viitoare cu vecinele lor: d_t este un $\text{MA}(h - 1)$
 - ▶ nu folosiți niciodată varianța i.i.d. $\hat{\gamma}_0$ pentru $h > 1$

Noțiuni necesare azi (15/24): un diferențial de pierdere la $h = 3$



- d_t simulat, cu valoarea așteptată 0,15: țintele la trei pași care se suprapun îl fac un MA(2)
- Dreapta: autocorelațiile la lagurile 1 și 2 ies din bandă; ele trebuie incluse în $\hat{\sigma}_{LR}^2$

Noțiuni necesare azi (16/24): corecția HLN și p-value-uri

- **HLN** Harvey, Leybourne și Newbold (1997): o corecție pentru eșantioane mici a statisticii DM

$$DM^* = DM \sqrt{\frac{P + 1 - 2h + h(h - 1)/P}{P}} \sim t_{P-1}$$

- ▶ factorul elimină deplasarea lui $\hat{\sigma}_{LR}^2$ în eșantioane mici
- ▶ t_{P-1} : distribuția Student t cu $P - 1$ grade de libertate, cu cozi mai groase decât $N(0, 1)$
- p-value-uri
 - ▶ bilateral $2[1 - F_{t_{P-1}}(|DM^*|)]$: sînt prognozele la fel de precise?
 - ▶ unilateral $1 - F_{t_{P-1}}(DM^*)$: este prognoza 2 mai bună? ($F_{t_{P-1}}$: funcția de repartiție a lui t_{P-1})
- Mai multe orizonturi sau modele: corecția Holm (Seminarul 0)
 - ▶ m teste: ordonăm p-value-urile, îl înmulțim pe al k -lea cel mai mic cu $m - k + 1$ și păstrăm șirul crescător

Noțiuni necesare azi (17/24): modele imbricate: Clark–West

- Modelul 1 (mic) este **imbricat** în modelul 2 dacă modelul 2 devine modelul 1 când unii coeficienți sînt 0
 - ▶ exemplu: mersul aleator în interiorul unui model AR al variațiilor
 - ▶ sub H_0 coeficienții suplimentari sînt 0, dar modelul mare îi estimează totuși, cu zgomot
- **Clark–West** Clark și West (2007): adăugăm înapoi termenul de zgomot modelului mare

$$f_t = e_{1t}^2 - [e_{2t}^2 - (\hat{y}_{1t} - \hat{y}_{2t})^2]$$

- ▶ $\hat{y}_{it}$: prognoza modelului i ; test t unilateral pentru $\mathbb{E}f_t = 0$ față de $\mathbb{E}f_t > 0$
- ▶ $t = \bar{f}/\text{se}(\bar{f})$ comparat cu $N(0, 1)$: respingem la 5% dacă $t > 1,645$

Noțiuni necesare azi (18/24): eficiența prognozei: Mincer–Zarnowitz

- **Mincer–Zarnowitz** Mincer și Zarnowitz (1969): regresăm realizarea pe prognoză

$$y_{t+h} = a + b \hat{y}_{t+h|t} + u_{t+h}$$


- ▶ o prognoză eficientă (optimă sub pierderea pătratică) are $a = 0$, $b = 1$: nu rămîne nicio eroare sistematică
- ▶ $b > 1$: prognozele se mișcă prea puțin (prea timide); $b < 1$: prea mult

- **Testul Wald** comun pentru $\theta = (a, b)' = (0, 1)'$

$$W = (\hat{\theta} - \theta_0)' \hat{V}^{-1} (\hat{\theta} - \theta_0) \sim \chi^2(2)$$

- ▶ $\hat{V}$: covarianța HAC a lui $\hat{\theta}$ (u_{t+h} este un $MA(h-1)$); valoarea critică de 5%: 5,99

Noțiuni necesare azi (19/24): prognoze eficiente și prognoze timide



- efficient: $\hat{a} = -0.13, \hat{b} = 1.02$
- timid (shrunk to the mean): $\hat{a} = -2.18, \hat{b} = 2.05$
- 45-degree line: $a = 0, b = 1$

- 150 de perechi prognoză–realizare simulate
- Albastru: prognoza eficientă
 - ▶ dreapta estimată este apropiată de prima bisectoare
- Roșu: aceeași prognoză, adusă la jumătatea distanței față de medie
 - ▶ $\hat{b} \approx 2, \hat{a} < 0$: un prognozator care se mișcă prea puțin
- MZ verifică doar primul moment: o prognoză îl poate trece și să fie totuși o prognoză de densitate slabă

Noțiuni necesare azi (20/24): combinarea a două prognoze

- Prognoza combinată $\hat{y}_c = w\hat{y}_1 + (1 - w)\hat{y}_2$, erori nedeplasate cu varianțele σ_1^2 , σ_2^2 și covarianța $\sigma_{12} = \rho\sigma_1\sigma_2$

$$\text{MSE}(w) = w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w)\sigma_{12}$$


- ▶ ρ : corelația celor două erori de prognoză

- **Bates–Granger** [Bates și Granger \(1969\)](#): ponderea care minimizează MSE

$$w^* = \frac{\sigma_2^2 - \sigma_{12}}{D}, \quad \text{MSE}(w^*) = \frac{\sigma_1^2\sigma_2^2 - \sigma_{12}^2}{D}, \quad D = \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}$$

- ▶ $D = \text{Var}(e_1 - e_2)$; $\text{MSE}(w^*) \leq \min(\sigma_1^2, \sigma_2^2)$: o prognoză mai slabă poate totuși ajuta
- ▶ w^* în afara intervalului $[0, 1]$ este posibil când erorile sînt puternic corelate

Noțiuni necesare azi (21/24): MSE-ul unei combinații



- $MSE(w)$ este o parabolă în w , cu minimumul în w^*
- În jurul lui w^* curba este plată: ponderile egale pierd foarte puțin aici
- **Paradoxul combinării** [Smith și Wallis \(2009\)](#)
 - w^* trebuie estimat din erorile trecute; un $\hat{w}$ estimat adaugă aproximativ $\text{Var}(\hat{w}) D$ la MSE
 - de aceea ponderile egale le bat adesea pe cele estimate

Noțiuni necesare azi (22/24): scheme de combinare

- N prognoze $\hat{y}_{1t}, \dots, \hat{y}_{Nt}$ la fiecare origine
 - ▶ **media** $N^{-1} \sum_i \hat{y}_{it}$; **mediana**; **media trunchiată**: media după eliminarea celor mai mari și celor mai mici 10%
- **Ponderi după inversul MSE**: prognozatorii mai buni în trecut primesc o pondere mai mare

$$w_i = \frac{1/\text{MSE}_i}{\sum_{j=1}^N 1/\text{MSE}_j}$$

- ▶ MSE_i : MSE-ul prognozatorului i pe o fereastră recentă de realizări cunoscute
- **Shrinkage spre ponderi egale**

$$w_i^\lambda = \lambda \hat{w}_i + (1 - \lambda)/N, \quad 0 \leq \lambda \leq 1$$

- ▶ $\lambda = 0$: media; $\lambda = 1$: ponderile estimate; **cel mai bun anterior**: prognozatorul cu cel mai mic MSE trecut [Genre et al. \(2013\)](#)

Noțiuni necesare azi (23/24): densități GARCH- t , elicitalitate, mulțimi de modele

- **GARCH(1,1)- t** Bollerslev (1987): o prognoză de densitate care urmărește volatilitatea

$$r_t = \mu + \sigma_t z_t, \quad \sigma_t^2 = \omega + \alpha(r_{t-1} - \mu)^2 + \beta\sigma_{t-1}^2$$

- ▶ z_t : distribuția Student t cu ν grade de libertate, rescalată la varianța 1 (cozi groase); parametrii prin verosimilitate maximă
- ▶ reper: Normală i.i.d., $r_t \sim N(\mu, \sigma^2)$ cu σ constant

- Funcțională **elicitabilă** Gneiting (2011): una care este prognoza optimă sub o pierdere strict consistentă

- ▶ media (pierdere pătratică) și cuantilele (pinball) sînt elicitalabile

- **Model confidence set** (MCS) Hansen, Lunde și Nason (2011)

- ▶ pornim de la toate modelele; testăm egalitatea pierderilor așteptate la nivelul α ; cît timp testul respinge, eliminăm modelul semnificativ cel mai slab
- ▶ modelele rămase formează MCS de nivel $1 - \alpha$

Noțiuni necesare azi (24/24): date în timp real și anchete

- O **versiune** (vintage): datele așa cum au fost publicate la o anumită dată; PIB-ul se revizuieste ani la rând [Croushore și Stark \(2001\)](#)
 - ▶ prima, a doua, a treia **publicare**: primele trei valori publicate pentru un trimestru; **ultima versiune**: valoarea de azi
 - ▶ **revizuirea**, ultima versiune minus prima publicare, poate fi mare în raport cu eroarea de prognoză, deci alegerea versiunii contează
- **SPF**: Survey of Professional Forecasters (Philadelphia Fed), trimestrial din 1968
 - ▶ răspunsurile individuale sînt publice, deci se pot construi combinații din ele
 - ▶ prognozele de nivel trimestriale devin o rată de creștere anualizată: $100[(Y_{q+1}/Y_q)^4 - 1]$
- O evaluare corectă compară fiecare prognoză cu versiunea pe care urma să o prognozeze, aleasă **înainte** de calcule

A1: prognoze optime pentru o variabilă exponențială [Rezolvat]

Cerință

- ▣ $Y \sim \text{Exponențială}(1)$: $F(y) = 1 - e^{-y}$, $\mathbb{E}Y = 1$, $\text{Var}Y = 1$.
- ▣ 1. Deduceți prognoza optimă sub pierderea pătratică, absolută și pinball cu $\tau = 0,9$.
- ▣ 2. Dați pierderea așteptată minimă (riscul) sub pierderea pătratică și cea absolută.
- ▣ 3. Un prognozator raportează mediana și este evaluat prin RMSE. Calculați pierderea pătratică așteptată suplimentară.
- ▣ Raportați: trei prognoze, două riscuri, o pierdere suplimentară.

Rezolvare

- ▣ 1. Pătratică: $x^* = \mathbb{E}Y = 1$; absolută: $F(x) = 1/2 \Rightarrow x^* = \ln 2 = 0,693$; pinball: $F(x) = 0,9 \Rightarrow x^* = \ln 10 = 2,303$
- ▣ 2. Riscul pătratic = $\text{Var}Y = 1$; riscul absolut $\mathbb{E}|Y - \ln 2| = \ln 2 = 0,693$ (prin integrare); riscul pinball în $\ln 10$: 0,230
- ▣ 3. $\mathbb{E}(Y - m)^2 = \text{Var}Y + (1 - m)^2$, surplusul $(1 - \ln 2)^2 = 0,094$: mediana raportată corect pare cu 9% mai slabă sub MSE
- ▣ pierderea trebuie anunțată înainte de a face prognoza

A2: prognoza optimă sub pierderea LinEx [Propus]

Rezolvarea se discută la seminar

Cerință

- LinEx $L(e) = b[e^{ae} - ae - 1]$, $e = y - x$, $b > 0$; $Y \mid \mathcal{F}_t \sim N(\mu_t, \sigma_t^2)$. Model: A1.
- 1. Arătați că condiția de ordinul întâi este $\mathbb{E}e^{a(Y-x)} = 1$ și rezolvați-o în raport cu x .
- 2. Calculați x^* pentru $\mu = 2$, $\sigma = 1,5$ și $a = 0,5$, apoi $a = -0,5$.
- 3. Explicați de ce un prognozator rațional cu această pierdere pică testul Mincer–Zarnowitz și de ce deplasarea se mișcă odată cu σ_t .
- Raportați: o formulă, două numere, două fraze.

A3: scorul logaritmico și CRPS pentru două prognoze Normale [Rezolvat]

Cerință

- Două prognoze pentru y : $N(2, 1)$ și prognoza mai concentrată $N(2, 0,5^2)$; realizarea este $y = 3,5$.
- 1. Calculați z , scorul logaritmico $-\ln f(y)$ și CRPS pentru fiecare prognoză.
- 2. Care prognoză câștigă sub fiecare scor și care scor penalizează mai mult ratarea?
- 3. Demonstrați că scorul logaritmico este propriu folosind $KL(g\|f) \geq 0$.
- Raportați: un tabel cu patru scoruri, o frază, o demonstrație de două rînduri.

Rezolvare

- 1. $N(2, 1)$: $z = 1,5$, $\text{LogS} = \frac{1}{2} \ln 2\pi + z^2/2 = 2,044$, $\text{CRPS} = 0,994$
- $N(2, 0,25)$: $z = 3,0$, $\text{LogS} = 4,726$, $\text{CRPS} = 1,218$
- 2. Prognoza mai largă câștigă sub ambele; LogS se dublează pentru cea concentrată (z^2 crește de patru ori), CRPS crește cu aproximativ o cincime: scorul logaritmico penalizează mai dur excesul de încredere
- 3. $\mathbb{E}_g[-\ln f(Y)] - \mathbb{E}_g[-\ln g(Y)] = \int g \ln(g/f) = KL(g\|f) \geq 0$, cu egalitate dacă și numai dacă $f = g$: strict propriu

A4: un scor impropriu și scorul de interval [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Adevărul $Y \sim N(0, 1)$; prognozele $N(0, s^2)$. *Scorul liniar* este $-f(y)$. Model: A3.
- ▣ 1. Arătați că $\mathbb{E}f(Y) = [2\pi(1 + s^2)]^{-1/2}$ și evaluați-l pentru $s = 0,5$; 1; 2.
- ▣ 2. Explicați de ce scorul liniar este impropriu și ce comportament răsplătește.
- ▣ 3. Un interval de 90% este $[1, 4]$. Calculați scorul de interval pentru $y = 3$, $y = 5$ și $y = -1$.
- ▣ Raportați: trei medii, o frază, trei scoruri.

A5: testul Diebold–Mariano de mînă [Rezolvat]

Cerință

- Prognoze la doi pași ($h = 2$), $P = 40$; diferențialul de pierdere pătratică cu $\bar{d} = 0,30$, $\hat{\gamma}_0 = 1,2$, $\hat{\gamma}_1 = 0,4$.
- 1. Calculați varianța de termen lung cu nucleul dreptunghiular și $h - 1$ laguri, eroarea standard a lui $\bar{d}$ și statistica DM.
- 2. Aplicați corecția HLN și comparați cu t_{39} .
- 3. Ce ar fi concluzionat varianța i.i.d.?
- Raportați: două statistici, două p-value-uri, o frază.

Rezolvare

- 1. $\hat{\sigma}_{LR}^2 = 1,2 + 2 \cdot 0,4 = 2,0$; $SE = \sqrt{2/40} = 0,224$; $DM = 0,30/0,224 = 1,342$, $p = 0,180$
- 2. factorul $\sqrt{(41 - 4 + 2/40)/40} = 0,962$; $HLN = 1,291$, $p = 0,204$ (valoarea critică t_{39} : 2,023)
- 3. i.i.d.: $SE = \sqrt{1,2/40} = 0,173$, $DM = 1,73$: mai aproape de respingere, în mod greșit, pentru că autocorelația pozitivă a fost ignorată
- nu există dovezi că prognoza 2 este mai bună

A6: Clark–West de mînă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Un mers aleator (modelul 1) este imbricat într-un model AR (modelul 2); $P = 100$ prognoze la un pas: $\overline{e_1^2} = 1,00$, $\overline{e_2^2} = 0,98$, $\overline{(\hat{y}_1 - \hat{y}_2)^2} = 0,06$; abaterile standard ale lui f_t și d_t : 0,5. Model: A5.
- ▣ 1. Calculați statistica DM naivă pentru $e_1^2 - e_2^2$ și p-value-ul ei unilateral.
- ▣ 2. Calculați media corectată Clark–West $\bar{f}$, statistica t și p-value-ul unilateral.
- ▣ 3. Explicați de ce corecția se adaugă modelului mare și de ce DM respinge prea rar aici.
- ▣ Raportați: două statistici, două p-value-uri, două fraze.

A7: ponderile Bates–Granger [Rezolvat]

Cerință

- Două prognoze nedeplasate cu abaterile standard ale erorilor $\sigma_1 = 2$, $\sigma_2 = 3$ și corelația erorilor $\rho = 0,4$.
- 1. Calculați ponderea optimă a prognozei 1.
- 2. Calculați varianța erorii combinate și comparați-o cu σ_1^2 .
- 3. Calculați varianța cu ponderi egale.
- Raportați: o pondere, două varianțe, o frază.

Rezolvare

- 1. $\sigma_{12} = 0,4 \cdot 2 \cdot 3 = 2,4$; $D = 4 + 9 - 4,8 = 8,2$;
 $w^* = (9 - 2,4)/8,2 = 0,805$
- 2. $\sigma_c^2 = (36 - 5,76)/8,2 = 3,688 < 4$: prognoza mai slabă ajută totuși
- 3. $\frac{1}{4}(4 + 9 + 2 \cdot 2,4) = 4,45$: mai rău decît prognoza 1 singură;
cu prognoze foarte inegale, ponderile egale pot strica

A8: costul ponderilor estimate [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ $\sigma_1^2 = 1$, $\sigma_2^2 = 1,1$, $\rho = 0,5$; ponderea se estimează din $n = 40$ de erori trecute. Model: A7.
- ▣ 1. Arătați că $\text{MSE}(w) = \text{MSE}(w^*) + (w - w^*)^2 D$, cu $D = \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}$.
- ▣ 2. Calculați w^* , D și câștigul lui w^* față de $w = 1/2$.
- ▣ 3. O simulare dă $\text{Var}(\hat{w}) = 0,020$ la $n = 40$. Comparați pierderea așteptată din estimare cu câștigul și trageți concluzia.
- ▣ Raportați: o identitate, trei numere, o concluzie.

B1: prognoza creșterii PIB din România [Rezolvat]

- ▣ **Întrebarea:** prognozează un AR(1) creșterea trimestrială a PIB din România mai bine decât media istorică sau decât prognoza fără schimbare și depinde răspunsul de pierdere și de anul 2020?
- ▣ **Date:** creșterea PIB real față de trimestrul anterior (% , Eurostat, ajustat sezonier), prognoze la un pas făcute recursiv, T1 2010–T2 2026 ($P = 66$)
- ▣ **Cerințe**
 1. Calculați prognoze recursive la un pas din AR(1), media istorică și prognoza fără schimbare și raportați RMSE și MAE.
 2. Testați AR(1) față de fiecare reper cu DM–HLN sub pierdere pătratică și absolută.
 3. Repetați testele fără cele patru trimestre din 2020.
 4. Interpretare: este AR(1) o prognoză mai bună decât media și este mai bună decât prognoza fără schimbare?
- ▣ **Raportați:** un tabel cu RMSE și MAE, opt statistici HLN cu p-value-urile lor, o frază
- ▣ Notebook: secțiunea B1

B1: rezolvare (1/2) [Rezolvat]



B1: rezolvare (2/2) [Rezolvat]

Proгноza	RMSE	MAE	RMSE, fără 2020	MAE, fără 2020
AR(1)	2,26	1,48	1,83	1,25
media	2,24	1,48	1,84	1,26
fără schimbare	3,23	2,12	2,78	1,88

- HLN, AR(1) față de medie: 0,43 (p 0,671) pătratică, $-0,12$ (p 0,908) absolută; față de fără schimbare: $-1,88$ (p 0,065) și $-2,58$ (p 0,012); fără 2020: $-2,55$ (p 0,013)
- Interpretare: AR(1) și media nu se pot distinge (persistența creșterii este slabă); amîndouă bat clar prognoza fără schimbare, iar dovezile sub pierdere pătratică sînt mai slabe cu 2020, deoarece cele două trimestre COVID domină varianța HAC


B2: combinarea prognozelor SPF pentru șomaj [Propus]

- **Întrebarea:** poate vreo combinație a prognozelor individuale SPF pentru rata șomajului din SUA să bată media simplă la două trimestre?
- **Date:** variabila SPF UNEMP4 (trimestrul de la două trimestre după anchetă), media trimestrială FRED UNRATE, anchete 1990–2025; model: B1 și A7
- **Cerințe**
 1. Construiți media, mediana, media trunchiată 10%, ponderile după inversul MSE (ultimele 20 de anchete cu realizare cunoscută, cel puțin 8 prognoze), shrinkage-ul lor de 50% și cel mai bun anterior.
 2. Raportați RMSE relativ la medie și DM–HLN cu $h = 3$ față de medie.
 3. Aplicați testul Mincer–Zarnowitz pentru medie, cu și fără 2020.
 4. Interpretare: se confirmă paradoxul pentru șomaj și este prognoza medie eficientă?
- **Raportați:** șase RMSE relative, cinci statistici HLN, două teste MZ, o frază
- Notebook: secțiunea B2

B3: prognoze de densitate pentru EUR/RON [Rezolvat]

- **Întrebarea:** este calibrată o prognoză de densitate GARCH(1,1)- t pentru randamentele zilnice EUR/RON și este mai bună decât o prognoză i.i.d. Normală?
- **Date:** cursul de referință BNR, $100\Delta \ln S_t$; estimare 2010–2018 (2 270 zile), evaluare 2019–2026 (1 925 zile), parametri ficși
- **Cerințe**
 1. Estimați ambele modele prin verosimilitate maximă pe eșantionul de estimare și calculați valorile PIT la o zi pe eșantionul de evaluare.
 2. Reprezentați histogramele PIT, aplicați testul Berkowitz și raportați proporția valorilor PIT în afara intervalului $[0,05; 0,95]$.
 3. Calculați scorul logaritm mediu și CRPS mediu și testați diferențele lor cu DM–HLN.
 4. Interpretare: poate modelul cu scor mai bun să fie totuși necalibrat și de ce?
- **Raportați:** două histograme, două teste Berkowitz, două proporții, patru scoruri, două statistici HLN, o frază
- Notebook: secțiunea B3

B3: rezolvare (1/2) [Rezolvat]



B3: rezolvare (2/2) [Rezolvat]

Model	Scor log.	CRPS	Berkowitz LR	p	În afara 90%
i.i.d. Normal	-0,431	0,0688	1442	< 0,001	1,1%
GARCH(1,1)- t	-1,224	0,0442	539	< 0,001	3,3%

- GARCH- t : $\hat{\alpha} + \hat{\beta} = 0,9999$, $\hat{\nu} = 4,86$; HLN pe diferențele de scor: -49,3 (scor logaritmic), -56,9 (CRPS)
- Interpretare: GARCH- t câștigă detașat la toate scorurile, totuși ambele sînt necalibrate: după 2019 BNR a menținut EUR/RON mult mai calm decît în 2010–2018, deci densitățile fixate în 2018 sînt prea largi (o cocoașă, puține valori PIT în cozi); ierarhizarea și calibrarea răspund la întrebări diferite

B4: prognozele SPF pentru PIB și versiunile datelor [Propus]

- **Întrebarea:** depind acuratețea și eficiența prognozei SPF a PIB pentru trimestrul următor de versiunea datelor folosită ca realizare?
- **Date:** media SPF a $100[(RGDP3/RGDP2)^4 - 1]$; RTDSM: prima, a doua, a treia publicare și ultima versiune; ținte 1990–2025 ($P = 139$); model: B1
- **Cerințe**
 1. Calculați RMSE al mediei SPF față de fiecare dintre cele patru versiuni.
 2. Aplicați testul Mincer–Zarnowitz față de fiecare versiune.
 3. Recalculați RMSE față de prima publicare și față de ultima versiune fără anul 2020.
 4. Interpretare: ce versiune ar trebui să folosească o evaluare preînregistrată a prognozelor SPF și de ce?
- **Raportați:** patru RMSE, patru teste MZ, două RMSE fără 2020, o frază
- Notebook: secțiunea B4

B5: cuantile ale consumului la vârful de seară [Propus]

- **Întrebarea:** sînt calibrate intervalele de 90% pentru consumul dintre orele 19:00 și 20:00 și bate ARX expert prognoza naivă săptămînală la scorul de interval?
- **Date:** consumul orar din România (Energy-Charts), prognoze pentru ziua următoare, 2025–2026 ($P = 638$ zile); cuantile din ultimele 182 de erori; model: B3
- **Cerințe**
 1. Calculați prognozele de cuantile 5%, 50% și 95% ale ARX expert și ale prognozei naive săptămînale la ora de vîrf.
 2. Raportați acoperirea, proporțiile sub și peste interval, lățimea medie și scorul de interval.
 3. Testați diferența scorurilor de interval cu DM–HLN și raportați pierderea pinball la mediană.
 4. Interpretare: este cel mai îngust dintre cele două intervale și cel mai bun?
- **Raportați:** două acoperiri, patru proporții în cozi, două lățimi, două scoruri de interval, o statistică HLN, o frază
- Notebook: secțiunea B5

C1: o evaluare preînregistrată pe orizonturi [Propus]

- ▣ **Întrebarea:** bate un AR(3) direct prognoza fără schimbare pentru inflația din România la vreun orizont, după corecția pentru testarea a patru orizonturi?
- ▣ **Date:** inflația IAPC, anuală; origini din ianuarie 2013, fereastră mobilă de 10 ani; orizonturile 1, 3, 6, 12 luni; model: B1
- ▣ **Cerințe**
 1. Scrieți preînregistrarea: ținta, orizonturile, pierderea, reperul, testul, corecția, în cinci rînduri, înainte de orice calcul.
 2. Calculați RMSE relativ și DM-HLN pentru fiecare orizont.
 3. Aplicați corecția Holm pe cele patru orizonturi.
 4. Interpretare: ce ați fi raportat dacă v-ați fi uitat doar la cel mai bun orizont?
- ▣ **Raportați:** un plan de cinci rînduri, patru RMSE relative, opt p-value-uri, un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre evaluarea prognozelor. Răspunsul:
- (a) Pentru $h = 4$ folosiți Newey-West cu 4 laguri; corecția HLN face testul DM mai liberal în eșantioane mici.
- (b) Pentru o prognoză punctuală (o masă punctuală) CRPS este egal cu eroarea absolută.
- (c) Expected shortfall este elicitable pentru că este media cozii, iar mediile sînt elicibile.
- (d) Pentru a compara un model AR cu mersul aleator imbricat în el, folosiți DM cu valori critice Normale.
- (e) O histogramă PIT în formă de U înseamnă că distribuția predictivă este prea largă.
- (f) MCS de 90% conține cel mai bun model cu probabilitatea de cel puțin 90%, asimptotic.
- (g) Cu $\sigma_1 = 2$, $\sigma_2 = 3$ și $\rho = 0,4$ ponderea optimă a prognozei 1 este 0,6.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de șapte verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Pierderea definește prognoza optimă: media, mediana, cuantila sau o valoare deplasată sub LinEx
- ▣ Scorurile proprii răsplătesc raportarea sinceră; scorul logaritmice penalizează cel mai dur excesul de încredere
- ▣ DM cere varianța HAC cu $h - 1$ laguri și corecția HLN; modelele imbricate cer Clark–West
- ▣ Ponderile estimate plătesc un preț de ordinul $1/n$: cu prognoze asemănătoare, media câștigă
- ▣ Un răspuns AI este o ciornă: verificați lagurile, sensul diagnosticului PIT, elicitabilitatea și calculele

După seminar

- ▣ Cursul 1 dezvoltă fiecare temă de azi: funcțiile de pierdere și pierderile Bregman, calibrarea și scorurile proprii, DM, GW, Clark–West, SPA și MCS, combinarea și datele în timp real
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: combinarea prognozelor inflației din România cu un plan preînregistrat
- ▣ Lectură: Diebold și Mariano (1995); Harvey, Leybourne și Newbold (1997); Gneiting și Raftery (2007); Smith și Wallis (2009)
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie

- Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468. doi:10.1057/jors.1969.103
- Berkowitz, J. (2001). Testing density forecasts, with applications to risk management. *Journal of Business & Economic Statistics*, 19(4), 465–474. doi:10.1198/07350010152596718
- Clark, T. E., & West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311. doi:10.1016/j.jeconom.2006.05.023
- Croushore, D., & Stark, T. (2001). A real-time data set for macroeconomists. *Journal of Econometrics*, 105(1), 111–130. doi:10.1016/S0304-4076(01)00072-0
- Diebold, F. X., Gunther, T. A., & Tay, A. S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883. doi:10.2307/2527342
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Fissler, T., & Ziegel, J. F. (2016). Higher order elicibility and Osband's principle. *The Annals of Statistics*, 44(4), 1680–1707. doi:10.1214/16-AOS1439
- Genre, V., Kenny, G., Meyler, A., & Timmermann, A. (2013). Combining expert forecasts: Can anything beat the simple average? *International Journal of Forecasting*, 29(1), 108–121. doi:10.1016/j.ijforecast.2012.06.004
- Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/016214506000001437
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. doi:10.1016/S0169-2070(96)00719-4
- Mincer, J., & Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (Ed.), *Economic Forecasts and Expectations* (pp. 3–46). NBER. nber.org
- Smith, J., & Wallis, K. F. (2009). A simple explanation of the forecast combination puzzle. *Oxford Bulletin of Economics and Statistics*, 71(3), 331–355. doi:10.1111/j.1468-0084.2008.00541.x