



Analiza avansată a seriilor de timp și previziune

Seminarul 5: Modele VAR bayesiene, modele factoriale și nowcasting



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- **AI:** Artificial Intelligence (inteligență artificială)
- **AR:** AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- **BBE:** Bernanke–Boivin–Eliasz (FAVAR, 2005) — modelul FAVAR Bernanke–Boivin–Eliasz (2005)
- **BGR:** Bańbura–Giannone–Reichlin (large Bayesian VARs, 2010) — modelele VAR bayesiene mari Bańbura–Giannone–Reichlin (2010)
- **BNR:** Banca Națională a României
- **BVAR:** Bayesian Vector AutoRegression (model vector autoregresiv bayesian)
- **DFM:** Dynamic Factor Model (model factorial dinamic)
- **EM:** Expectation–Maximisation (algorithm) — algoritmul expectație–maximizare
- **ESI:** Economic Sentiment Indicator (European Commission) — indicatorul sentimentului economic (Comisia Europeană)
- **ESS:** Effective Sample Size (mărimea efectivă a eșantionului)
- **FAVAR:** Factor-Augmented Vector AutoRegression (model VAR augmentat cu factori)
- **FFR:** Federal Funds Rate (dobânda federal funds)
- **FRED:** Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- **FRED-MD:** FRED Monthly Database for macroeconomic research (McCracken–Ng) — baza de date lunară FRED pentru cercetare macroeconomică (McCracken–Ng)

Acronime folosite în acest material (2/2)

- ▣ **GLP**: Giannone–Lenza–Primiceri (hierarchical prior selection, 2015) — alegerea ierarhică a distribuției a priori Giannone–Lenza–Primiceri (2015)
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **IC**: Interval de încredere
- ▣ **IP**: Industrial Production (producția industrială)
- ▣ **IPC**: Indicele prețurilor de consum
- ▣ **MCMC**: Markov Chain Monte Carlo (metode Monte Carlo cu lanțuri Markov)
- ▣ **MEDIUM**: the 20-variable system of BGR (sistemul cu 20 de variabile din BGR)
- ▣ **MIDAS**: MIxed DAta Sampling (regression) — regresie cu date de frecvențe mixte
- ▣ **NIW**: Normal–inverse–Wishart (prior) — distribuția a priori Normală–Wishart inversă
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **PIB**: Produsul intern brut
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **ROBOR**: Romanian Interbank Offer Rate (rata dobânzii interbancare la care se oferă depozite în lei)
- ▣ **RW**: Random Walk (mers aleator)
- ▣ **SMALL**: the 3-variable system of BGR (employment, CPI, federal funds rate) — sistemul cu 3 variabile din BGR (ocupare, IPC, dobînda federal funds)
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **VAR**: Vector AutoRegression (model vector autoregresiv)

Întrebarea de azi și structura seminarului

- Întrebarea seminarului
 - ▶ **cum estimăm, prognozăm și facem nowcasting cu multe serii și puține observații?**
- Rezultate de obținut
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ analiza cerută în C1 și verdictele asupra răspunsului A1 din C2, fiecare cu un rând de justificare
 - ▶ o frază de interpretare pentru fiecare exercițiu
- Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- Exercițiile, tipurile și ordinea lor: harta exercițiilor (slide-ul următor)
- Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	actualizarea conjugată și Bayes empiric; varianțele a priori Minnesota și o medie a posteriori de tip ridge	Rezolvat, Propus	A1
A3, A4	distribuțiile condiționate Gibbs și diagnosticarea MCMC; observații fictive	Rezolvat, Propus	A1, A3
A5, A6	componentele principale ale unui panel echicorelat; criteriile Bai–Ng	Rezolvat, Propus	A5
A7, A8	ponderile Mariano–Murasawa; știri și ponderi MIDAS	Rezolvat, Propus	A7
B1, B2	hiperparametri prin verosimilitatea marginală (SUA); un BVAR pentru România	Rezolvat, Propus	B1
B3, B4	factori pe trei eșantioane; FAVAR și numărul de factori	Rezolvat, Propus	B3
B5, B6	nowcasting pentru PIB-ul României; știrile din septembrie 2026	Rezolvat, Propus	B5
C1, C2	anchetele după 2020; ce este greșit într-un răspuns AI?	Propus	B5, A1–A8

- **[Rezolvat]**: rezolvarea completă este în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model, iar soluția se discută la seminar
- Partea A: calcule și derivări pe hîrtie; Partea B: date reale, rezolvate în notebook, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise, inclusiv critica unui răspuns AI

Datele folosite

Seria	Sursa	Frecvența	Perioada
panel SUA în format FRED-MD (117 serii)	FRED	lunar	1960–2026
IP, IAPC, ROBOR 3M, șomaj, ESI pentru România	Eurostat	lunar	2005–2026
EUR/RON	cursul de referință BNR	medie lunară	2005–2026
panelul de nowcasting RO (11 serii), PIB real	Eurostat	lunar, trimestrial	2003–2026

- În notebook: `bvar_fit`, `glp_optimize`, `niw_logml`, `em_pca`, `bai_ng`, `favar_run`, `ro_vintage`, `bridge_nowcast`, `midas_nowcast`, `dfm_nowcast`, `news_decomposition`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/22): regula lui Bayes și verosimilitatea marginală

- Regula lui Bayes: distribuția a posteriori este proporțională cu verosimilitatea înmulțită cu distribuția a priori

$$p(\theta | y) = \frac{p(y | \theta) p(\theta)}{p(y)} \propto p(y | \theta) p(\theta)$$

- θ : parametrii; y : datele; $p(\theta)$: distribuția a priori; $p(y | \theta)$: verosimilitatea
- Verosimilitatea marginală: densitatea datelor mediată după distribuția a priori

$$p(y) = \int p(y | \theta) p(\theta) d\theta$$

- nu depinde de θ ; depinde de distribuția a priori și de hiperparametrii ei
- un $p(y)$ mare: distribuția a priori a prezis bine datele; se folosește pentru alegerea hiperparametrilor și compararea modelelor
- Hiperparametrii: parametrii distribuției a priori (de exemplu varianța ei); **Bayes empiric** îi fixează prin maximizarea lui $p(y)$


Noțiuni necesare azi (2/22): actualizarea conjugată normală

- Distribuția a priori $\beta \sim N(m_0, v_0)$; datele rezumate prin $\hat{\beta} \mid \beta \sim N(\beta, s^2)$
 - ▶ $\hat{\beta}$: estimația OLS, cu eroarea standard s ; m_0, v_0 : media și varianța a priori
- Distribuția a posteriori $\beta \mid y \sim N(m_1, v_1)$: preciziile (inversele varianțelor) se adună, mediile se ponderează cu precizii

$$\frac{1}{v_1} = \frac{1}{v_0} + \frac{1}{s^2}, \quad m_1 = v_1 \left(\frac{m_0}{v_0} + \frac{\hat{\beta}}{s^2} \right)$$

- ▶ ponderea distribuției a priori v_1/v_0 : între 0 (a priori vag) și 1 (a priori dogmatic)
 - ▶ distribuția a posteriori este întotdeauna mai precisă decât distribuția a priori și decât datele
- Verosimilitatea marginală: integrând după β obținem $\hat{\beta} \sim N(m_0, v_0 + s^2)$
 - ▶ varianța a priori și varianța de eșantionare se adună

Noțiuni necesare azi (3/22): o actualizare conjugată și Bayes empiric



- Stînga: a priori $N(0.5, 0.3^2)$ și datele $\hat{\beta} = 0.9, s = 0.15$: preciziile $11.1 + 44.4$, ponderea a priori 0.20, media a posteriori $0.2 \cdot 0.5 + 0.8 \cdot 0.9 = 0.82$
- Dreapta: a priori $\beta \sim N(0, \tau^2)$; $\ln p(\hat{\beta} | \tau^2)$ este maxim în $\hat{\tau}^2 = \max(0, \hat{\beta}^2 - s^2)$



Noțiuni necesare azi (4/22): eșantionarea Gibbs

- ▣ **Gibbs Geman și Geman (1984)**: extragem fiecare bloc din distribuția condiționată completă, adică distribuția lui dat fiind celelalte blocuri și datele
 - ▶ pasul m : $\theta_1^{(m)} \sim p(\theta_1 | \theta_2^{(m-1)}, y)$, apoi $\theta_2^{(m)} \sim p(\theta_2 | \theta_1^{(m)}, y)$
 - ▶ extragerile formează un lanț Markov a cărui distribuție limită este distribuția a posteriori comună
- ▣ Regresia $y = X\beta + e$, $e \sim N(0, \sigma^2 I)$: două blocuri
 - ▶ $\beta | \sigma^2, y$ este normal; $\sigma^2 | \beta, y$ este invers gamma
- ▣ **Distribuția invers gamma** $IG(a, d)$: $\sigma^2 \sim IG(a, d)$ dacă $1/\sigma^2 \sim \text{Gamma}$ cu forma a și rata d

$$p(\sigma^2) \propto (\sigma^2)^{-a-1} e^{-d/\sigma^2}, \quad \mathbb{E}\sigma^2 = \frac{d}{a-1} \quad (a > 1)$$

- ▶ conjugată pentru o varianță: datele cu T reziduuri e actualizează $a \rightarrow a + T/2$, $d \rightarrow d + e'e/2$

Noțiuni necesare azi (5/22): un eșantionator Gibbs în funcțiune



—•— first 20 Gibbs sweeps ■ start — draws of θ_1

- Ținta: doi parametri normali standard cu corelația 0,9; fiecare distribuție condiționată este $N(0,9\theta_{\text{celălalt}}, 1 - 0,9^2)$
- Stînga: pași paraleli cu axele, mici de-a lungul diagonalei; dreapta: lanțul lui θ_1 este puternic autocorelat (corelația la lagul 1: 0,81)

Noțiuni necesare azi (6/22): diagnosticarea MCMC

- ▣ **Mărimea efectivă a eșantionului:** numărul de extrageri independente care valorează cât M extrageri corelate

$$\text{ESS} = \frac{M}{1 + 2 \sum_{k \geq 1} \rho_k}$$


- ▶ ρ_k : autocorelația extragerilor la lagul k ; $1 + 2 \sum_k \rho_k$: factorul de ineficiență
- ▶ lanț AR(1), $\rho_k = \rho^k$: $\text{ESS} = M(1 - \rho)/(1 + \rho)$

- ▣ **Factorul potențial de reducere a scalei** [Gelman și Rubin \(1992\)](#): C lanțuri de câte n extrageri

$$\hat{R} = \sqrt{\frac{\hat{V}}{W}}, \quad \hat{V} = \frac{n-1}{n} W + \frac{B}{n}, \quad B = \frac{n}{C-1} \sum_{c=1}^C (\bar{\theta}_c - \bar{\theta})^2$$

- ▶ W : media varianțelor din interiorul lanțurilor; $\bar{\theta}_c$: media lanțului c ; $\bar{\theta}$: media generală
- ▶ $\hat{R} \geq 1$; o valoare apropiată de 1 (sub 1,01) și un ESS mare sînt necesare, nu suficiente, pentru convergență

Noțiuni necesare azi (7/22): trace plot-uri, $\hat{R}$ și ESS



- Stînga: lanțul 4 explorează altă regiune: mediile lanțurilor diferă, B este mare și $\hat{R} = 1,58$; fără el, $\hat{R} = 1,01$
- Dreapta: un lanț cu $\rho = 0,8$; 20 000 de extrageri valorează cât $20\,000 \cdot 0,2/1,8 = 2\,222$ de extrageri independente

Noțiuni necesare azi (8/22): VAR-ul ca regresie

- ▣ VAR(p) cu n variabile

$$y_t = c + A_1 y_{t-1} + \cdots + A_p y_{t-p} + u_t, \quad u_t \sim N(0, \Sigma)$$


- ▣ Scris ca o singură regresie multivariată $Y = XB + U$

- ▶ Y ($T \times n$): rîndurile y'_t ; X ($T \times k$): rîndurile $(1, y'_{t-1}, \dots, y'_{t-p})$, $k = 1 + np$
- ▶ $B = (c, A_1, \dots, A_p)'$ ($k \times n$); U : erorile; $(A_l)_{ij}$: efectul variabilei j cu lagul l asupra variabilei i

- ▣ OLS: $\hat{B} = (X'X)^{-1}X'Y$, ecuație cu ecuație

- ▶ $n = 6$, $p = 12$: $k = 73$ de coeficienți pe ecuație; cu aproximativ 120 de observații OLS modelează zgomotul
- ▶ shrinkage-ul spre un model a priori simplu schimbă puțină deplasare pe o varianță mult mai mică

Noțiuni necesare azi (9/22): distribuția a priori Minnesota



- Mediile a priori [Litterman \(1986\)](#): fiecare variabilă este un mers aleator
 - ▶ $\mathbb{E}(A_1)_{ii} = \delta_i$ ($\delta_i = 1$ sau 0 pentru serii staționare), toți ceilalți coeficienți 0

- Abaterile standard a priori ale lui $(A_l)_{ij}$

$$\frac{\lambda}{l} \quad (i = j), \quad \frac{\lambda}{l} \frac{\sigma_i}{\sigma_j} \quad (i \neq j)$$

- ▶ λ : gradul general de strângere; λ mic: shrinkage puternic
- ▶ $1/l$: lagurile îndepărtate sînt strînse mai mult
- ▶ σ_i^2 : varianța reziduală a unui AR pentru y_i ; σ_i/σ_j fixează unitățile

Noțiuni necesare azi (10/22): distribuția a priori natural conjugată

- ▣ Normal–invers Wishart Kadiyala și Karlsson (1997)

$$\text{vec}B \mid \Sigma \sim N(\text{vec}B_0, \Sigma \otimes \Omega_0), \quad \Sigma \sim IW(\Psi, d)$$

- ▶ $\text{vec}B$: coloanele lui B puse una sub alta; B_0 : media a priori; Ω_0 ($k \times k$): covarianța a priori între regresori
- ▶ $\otimes$: produsul Kronecker, $(\Sigma \otimes \Omega_0)$ are blocurile $\sigma_{ij}\Omega_0$; $IW(\Psi, d)$: invers Wishart cu scala Ψ și d grade de libertate
- ▶ același Ω_0 în fiecare ecuație: shrinkage-ul încrucișat nu poate diferi de cel propriu

- ▣ Media a posteriori: o medie ponderată cu precizii a estimației OLS și a lui B_0

$$\bar{B} = (X'X + \Omega_0^{-1})^{-1}(X'Y + \Omega_0^{-1}B_0)$$

- ▶ $\Omega_0 \rightarrow 0$: $\bar{B} \rightarrow B_0$ (distribuția a priori); $\Omega_0^{-1} \rightarrow 0$: $\bar{B} \rightarrow \hat{B}$ (OLS); o regresie ridge spre B_0

Noțiuni necesare azi (11/22): observațiile fictive

- ▣ **Observații fictive** Bańbura, Giannone și Reichlin (2010): linii artificiale (Y_d, X_d) care exprimă distribuția a priori ca și cum ar fi date

- ▶ OLS pe datele stivuite este egal cu media a posteriori

$$\bar{B} = (X_d' X_d + X' X)^{-1} (X_d' Y_d + X' Y), \quad \Omega_0 = (X_d' X_d)^{-1}, \quad B_0 = \Omega_0 X_d' Y_d$$

- ▶ un coeficient cu a priori $N(\delta, \lambda^2)$ și $\sigma = 1$: un rând $y_d = \delta/\lambda$, $x_d = 1/\lambda$

- ▣ **Suma coeficienților** Doan, Litterman și Sims (1984): n rânduri $Y_d = \text{diag}(\bar{y})/\mu$, $X_d = (0, 1_p' \otimes \text{diag}(\bar{y})/\mu)$

- ▶ $\bar{y}$: mediile primelor p observații; 1_p : un vector de p unități; 0: coloana constantei

- ▶ $\mu \rightarrow 0$: $I - \sum_l A_l \rightarrow 0$, adică rădăcini unitare fără cointegrare (un VAR în diferențe)

- ▣ **Observația inițială** Sims și Zha (1998): un rând $(1/\phi, 1_p' \otimes \bar{y}'/\phi)$ față de $\bar{y}'/\phi$

- ▶ $\phi \rightarrow 0$: rădăcini unitare sau o medie staționară egală cu $\bar{y}$; permite cointegrarea


Noțiuni necesare azi (12/22): hiperparametrii prin verosimilitatea marginală

- GLP [Giannone, Lenza și Primiceri \(2015\)](#): tratăm (λ, μ, ϕ) ca parametri cu propria distribuție a priori (o hiperdistribuție)

$$p(\lambda, \mu, \phi \mid Y) \propto p(Y \mid \lambda, \mu, \phi) p(\lambda) p(\mu) p(\phi)$$

- ▶ $p(Y \mid \lambda, \mu, \phi)$: verosimilitatea marginală a BVAR-ului, în formă închisă pentru distribuția natural conjugată
 - ▶ $p(\cdot)$: distribuții Gamma pentru hiperparametri, cu modul 0,2 pentru λ și 1 pentru μ și ϕ
 - ▶ modul a posteriori al lui (λ, μ, ϕ) se introduce apoi în BVAR
- Interpretarea modului
 - ▶ un $\hat{\lambda}$ mic: datele preferă un shrinkage puternic; scade pe măsură ce crește numărul variabilelor [Bańbura, Giannone și Reichlin \(2010\)](#)
 - ▶ $\hat{\mu}$, $\hat{\phi}$ mici: datele favorizează persistența și rădăcinile aproape unitare

Noțiuni necesare azi (13/22): shrinkage-ul și verosimilitatea marginală



- AR(4) simulat cu $T = 60$, distribuție a priori de mers aleator (lagul 1 în 1, celelalte laguri în 0), abaterea standard λ/I
- Stînga: pe măsură ce λ crește, mediile a posteriori trec de la distribuția a priori la OLS; dreapta: $\ln p(y | \lambda)$ atinge maximumul în $\hat{\lambda} = 0,20$

Noțiuni necesare azi (14/22): evaluarea prognozelor prin RMSE

- Prognoze recursive: reestimăm la fiecare origine τ cu datele pînă la τ și prognozăm cu h pași înainte
 - ▶ $e_{\tau+h} = y_{\tau+h} - \hat{y}_{\tau+h|\tau}$: eroarea de prognoză; N_o : numărul de origini

- Rădăcina erorii pătratice medii, în unitățile lui y

$$\text{RMSE}_h = \sqrt{\frac{1}{N_o} \sum_{\tau} e_{\tau+h}^2}$$

- Reperul: mersul aleator cu derivă, $\hat{y}_{\tau+h|\tau} = y_{\tau} + h\hat{g}$
 - ▶ $\hat{g}$: modificarea medie pînă la τ ; un model este util doar dacă are RMSE mai mic decît reperul
 - ▶ cu puține origini, diferențele dintre RMSE sînt zgomotoase (un test, Diebold–Mariano, este în [Capitolul 1](#))

Noțiuni necesare azi (15/22): modele factoriale și componente principale

- Modelul factorial aproximativ: fiecare serie = parte comună + parte idiosincratică

$$x_{it} = \lambda_i' F_t + e_{it}, \quad X = F\Lambda' + E$$

- ▶ x_{it} : seria i la momentul t , standardizată (N serii, T perioade); F_t : cei r factori; λ_i : ponderile factoriale ale seriei i
- ▶ e_{it} : eroarea idiosincratică, slab corelată între serii

- Componentele principale [Stock și Watson \(2002a\)](#)

$$\hat{F} = \sqrt{T} \times (\text{primii } r \text{ vectori proprii ai lui } XX'), \quad \hat{\Lambda} = X' \hat{F} / T$$

- ▶ X ($T \times N$): panelul; $\hat{F}' \hat{F} / T = I_r$: normalizarea
- ▶ ponderea varianței componente j : $\mu_j / \sum_i \mu_i$, μ_j fiind a j -a valoare proprie a matricei de corelație
- ▶ este identificat doar spațiul factorilor: $F\Lambda' = (FH)(\Lambda H^{-1})'$ pentru orice H inversabilă

- Factori generali: primele r valori proprii cresc ca N , celelalte rămân mărginite

Noțiuni necesare azi (16/22): numărul de factori

- Criteriile Bai–Ng [Bai și Ng \(2002\)](#): potrivire plus o penalizare pe factor

$$IC_{p2}(k) = \ln V(k) + k \frac{N+T}{NT} \ln \min(N, T), \quad PC_{p2}(k) = V(k) + k \hat{\sigma}^2 \frac{N+T}{NT} \ln \min(N, T)$$


- Notățiile

- ▶ $V(k) = (NT)^{-1} \sum_{i,t} (x_{it} - \hat{\lambda}'_i \hat{F}_t)^2$: media pătratelor reziduurilor după k componente
- ▶ $\hat{\sigma}^2 = V(k_{\max})$: o scală pentru penalizarea PC

- Alegem $\hat{k} = \arg \min_{k \leq k_{\max}}$ al criteriului

- ▶ $V(k)$ singur nu crește niciodată cu k : ar alege întotdeauna $k_{\max}$
- ▶ penalizarea tinde la 0, dar mai lent decât zgomotul de estimare al unui factor în plus

Noțiuni necesare azi (17/22): un scree plot și IC_{p2}



- Panel simulat, $N = 60$, $T = 150$, doi factori: primele două componente explică 32% și 20%, celelalte aproximativ 2% fiecare
- $\ln V(k)$ scade la fiecare k ; cu penalizarea de 0,096 pe factor, IC_{p2} este minim la $k = 2$

Noțiuni necesare azi (18/22): FAVAR

- ▣ **FAVAR** Bernanke, Boivin și Elias (2005): un VAR în factorii estimați și dobânda de politică Y_t

$$\begin{pmatrix} \hat{F}_t \\ Y_t \end{pmatrix} = \sum_{l=1}^p \Phi_l \begin{pmatrix} \hat{F}_{t-l} \\ Y_{t-l} \end{pmatrix} + v_t, \quad x_{it} = \lambda_i' \hat{F}_t + \gamma_i Y_t + e_{it}$$

- ▶ Φ_l : coeficienții VAR; v_t : erorile VAR; K : numărul factorilor din $\hat{F}_t$
- ▶ doi pași: componentele principale ale panelului, apoi factorii curățați de Y_t cu ajutorul seriilor lente
- ▣ Identificarea: Y_t ultima în ordine (Cholesky), deci un șoc de politică nu mișcă factorii la impact
- ▶ răspunsul oricărei serii: $\partial x_{i,t+h} / \partial \varepsilon_t^Y = \lambda_i' \Psi_h^F + \gamma_i \Psi_h^Y$
- ▶ Ψ_h^F, Ψ_h^Y : răspunsurile lui $\hat{F}$ și Y după h perioade; anomalia prețurilor: prețuri care cresc după o înăspritare

Noțiuni necesare azi (19/22): frecvențe mixte

- ▣ Creșterea trimestrială dintr-o creștere lunară latentă $y_t = \Delta \ln Y_t^M$ [Mariano și Murasawa \(2003\)](#)

$$y_t^Q \approx \frac{1}{3} (y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4})$$

- ▶ y_t^Q : creșterea PIB față de trimestrul anterior, observată în a treia lună a fiecărui trimestru
- ▶ folosește aproximarea logaritmului nivelului trimestrial prin media celor trei logaritmi lunari

- ▣ Ecuația punte [Baffigi, Golinelli și Parigi \(2004\)](#): completăm trimestrul cu prognoze AR ale indicatorului lunar, facem media pe trimestru, regresăm



- ▶ $y_\tau^Q = a + b \bar{x}_\tau + \varepsilon_\tau$, $\bar{x}_\tau$: media trimestrială a indicatorului (completat)

- ▣ **MIDAS** [Ghysels, Santa-Clara și Valkanov \(2006\)](#): laguri lunare cu ponderi parcimonioase

$$y_\tau = \beta_0 + \beta_1 \sum_{j=0}^{K-1} w_j(\theta) x_{m_\tau-j} + \varepsilon_\tau, \quad w_j(\theta) = \frac{e^{\theta_1 j + \theta_2 j^2}}{\sum_{i=0}^{K-1} e^{\theta_1 i + \theta_2 i^2}}$$

- ▶ τ : trimestrul; m_τ : ultima lui lună disponibilă ($j = 0$); K : numărul valorilor lunare; ponderile w_j au suma 1
- ▶ o regresie pentru fiecare set de informații (poziția în trimestru)


Noțiuni necesare azi (20/22): două scheme de ponderare



$\bullet \quad \theta = (0.0, 0.0)$
 $\bullet \quad \theta = (-0.3, 0.0)$
 $\bullet \quad \theta = (0.4, -0.06)$

- Stînga: ponderile Mariano–Murasawa $(1, 2, 3, 2, 1)/3$ au suma 3, deoarece creșterea trimestrială acoperă cinci luni de creștere lunară
- Dreapta: $\theta = (0, 0)$ dă ponderi egale, $\theta_1 < 0$ ponderi descrescătoare, $\theta_2 < 0 < \theta_1$ o cocoașă

Noțiuni necesare azi (21/22): ragged edge și DFM




- Ragged edge: seriile se încheie în luni diferite
 - ▶ anchetele: fără întârziere; șomajul: 1 lună; datele hard: 2 luni; PIB-ul: 2 luni după trimestru

- DFM (modelul factorial dinamic) în spațiul stărilor

$$x_t = \Lambda f_t + e_t, \quad f_t = \sum_{l=1}^p \Phi_l f_{t-l} + \eta_t$$

- ▶ f_t : factorii latenți, care urmează un VAR
- ▶ filtrul Kalman sare peste x_{it} lipsă: panelul nu trebuie echilibrat
- ▶ PIB-ul intră prin ponderile Mariano–Murasawa

Noțiuni necesare azi (22/22): știrile și revizuirea nowcast-ului



- Știrile Bańbura și Modugno (2014): partea neașteptată a unei publicări

► $I_j = x_j - \mathbb{E}[x_j \mid \Omega_{old}]$; Ω_{old} : informația dinaintea publicării

- Revizuirea = suma ponderată a știrilor

$$\mathbb{E}[y \mid \Omega_{new}] - \mathbb{E}[y \mid \Omega_{old}] = \sum_j w_j I_j$$

► $w = \mathbb{E}[yI'] \mathbb{E}[II']^{-1}$: regresia lui y pe știri
 ► o publicare așteptată ($I_j = 0$) nu schimbă nimic

- Graficul (ilustrativ): IP sub așteptări ($-0,09$) și șomajul peste ($-0,08$) depășesc ancheta ($+0,06$): $1,20 \rightarrow 1,11$

A1: actualizarea conjugată și Bayes empiric [Rezolvat]

Cerință

- ▣ AR(1) fără termen liber, $\sigma^2 = 1$ cunoscut, $\sum x_t^2 = 50$, $\sum x_t y_t = 40$; distribuția a priori $\rho \sim N(1, 0,2^2)$.
- ▣ 1. Calculați $\hat{\rho}$ și eroarea lui standard s .
- ▣ 2. Calculați media și abaterea standard a posteriori și ponderea distribuției a priori.
- ▣ 3. Cu distribuția a priori $\rho \sim N(0, \tau^2)$, găsiți τ^2 care maximizează verosimilitatea marginală a lui $\hat{\rho}$.
- ▣ Raportați: două numere, trei numere, un număr.

Rezolvare

- ▣ 1. $\hat{\rho} = 40/50 = 0,800$, $s = 1/\sqrt{50} = 0,141$
- ▣ 2. Preciziile $25 + 50 = 75$: $m_1 = (25 \cdot 1 + 50 \cdot 0,8)/75 = 0,8667$, abaterea standard $= 1/\sqrt{75} = 0,1155$, ponderea a priori $25/75 = 0,333$
- ▣ 3. $\hat{\rho} \sim N(0, \tau^2 + s^2)$; maximizînd în τ^2 : $\tau^2 + s^2 = \hat{\rho}^2$, deci $\hat{\tau}^2 = \max(0, \hat{\rho}^2 - s^2) = 0,64 - 0,02 = 0,620$
- ▣ Interpretare: datele aleg gradul de shrinkage; aceasta este versiunea cu un parametru a metodei GLP

A2: varianțele a priori Minnesota și o medie a posteriori de tip ridge [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ VAR(2) bivariat, ecuația 1; $\lambda = 0,2$, $\sigma_1 = 1$, $\sigma_2 = 2$, $\delta_1 = 1$. Model: A1.
- ▣ 1. Dați abaterile standard a priori ale coeficienților proprii și încrucișați la lagurile 1 și 2.
- ▣ 2. Păstrați doar $y_{1,t-1}$ și $y_{2,t-1}$: $X'X = \begin{pmatrix} 100 & 20 \\ 20 & 400 \end{pmatrix}$, $X'y = (85; 30)'$, $\sigma^2 = 1$; calculați mediile OLS și a posteriori.
- ▣ 3. Spuneți ce se întîmplă cînd $\lambda \rightarrow 0$ și cînd $\lambda \rightarrow \infty$.
- ▣ Raportați: patru numere, două perechi de numere, două fraze.

A3: distribuțiile condiționate Gibbs și diagnosticarea MCMC [Rezolvat]

Cerință

- $y = X\beta + e$, $e \sim N(0, \sigma^2 I)$, distribuții a priori independente $\beta \sim N(b_0, V_0)$, $\sigma^2 \sim IG(a_0, d_0)$.
- 1. Derivați $\beta \mid \sigma^2, y$ și $\sigma^2 \mid \beta, y$.
- 2. Un lanț de $M = 10\,000$ de extrageri are autocorelație AR(1) $\rho = 0,9$: calculați ESS.
- 3. Patru lanțuri de câte $n = 1\,000$ de extrageri au mediile $(0,10; 0,12; 0,35; 0,11)$ și varianța internă $W = 0,01$: calculați $\hat{R}$.
- Raportați: două densități, un număr, un număr și un verdict.

Rezolvare

- 1. $\beta \mid \cdot \sim N(\bar{b}, \bar{V})$, $\bar{V} = (V_0^{-1} + X'X/\sigma^2)^{-1}$,
 $\bar{b} = \bar{V}(V_0^{-1}b_0 + X'y/\sigma^2)$; $\sigma^2 \mid \cdot \sim IG(a_0 + T/2, d_0 + e'e/2)$
- 2. $\sum_k \rho^k = \rho/(1 - \rho)$: ESS = $M(1 - \rho)/(1 + \rho) = 526,3$ (o extragere efectivă la fiecare 19)
- 3. $B = n \text{var}(\bar{\theta}_c) = 14,467$, $\hat{V} = 0,999W + B/n = 0,0245$,
 $\hat{R} = 1,56$: lanțurile nu au ajuns la convergență; lanțul 3 este blocat în altă zonă (fără el, $\hat{R} = 1,004$)

A4: observații fictive [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ AR(1) din A1; observația fictivă Minnesota $y_d = \sigma\delta/\lambda$, $x_d = \sigma/\lambda$, cu $\sigma = 1$, $\delta = 1$, $\lambda = 0,2$. Model: A1, A3.
- ▣ 1. Arătați că OLS pe datele augmentate este egal cu $(X'X + X_d'X_d)^{-1}(X'y + X_d'y_d)$.
- ▣ 2. Calculați-l și comparați cu A1.
- ▣ 3. Adăugați o observație fictivă pentru suma coeficienților $y = x = \bar{y}/\mu$ cu $\bar{y} = 5$, $\mu = 1$ și recalculați; spuneți încotro împinge ρ .
- ▣ Raportați: o derivare, un număr, un număr și o frază.

A5: componentele principale ale unui panel echicorelat [Rezolvat]

Cerință

- ▣ $N = 3$ serii standardizate, cu toate corelațiile perechi $\rho = 0,6$.
- ▣ 1. Găsiți valorile și vectorii proprii ai matricei de corelație R .
- ▣ 2. Calculați ponderea varianței primei componente și ponderile ei factoriale.
- ▣ 3. Dați ponderea pentru $N = 100$ și limita ei cînd $N \rightarrow \infty$.
- ▣ Raportați: trei valori proprii, o pondere, o pondere și o limită.

Rezolvare

- ▣ 1. $R = (1 - \rho)I + \rho \mathbf{1}\mathbf{1}'$: $\lambda_1 = 1 + 2\rho = 2,2$ cu $1/\sqrt{3}$; $\lambda_{2,3} = 1 - \rho = 0,4$
- ▣ 2. Ponderea $2,2/3 = 73,3\%$; ponderile factoriale $1/\sqrt{3} = 0,577$ fiecare: factorul este media transversală
- ▣ 3. $(1 + 99\rho)/100 = 60,4\%$, limita ρ : prima valoare proprie crește ca N , celelalte rămîn mărginite (caracterul general)

A6: numărul de factori după Bai și Ng [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $N = 100$, $T = 200$; $V(k)$ pentru $k = 0, \dots, 5$: 1,000; 0,620; 0,480; 0,430; 0,415; 0,405. Model: A5.
- ▣ 1. Calculați penalizarea IC_{p2} pentru un factor.
- ▣ 2. Calculați $IC_{p2}(k)$ pentru fiecare k și alegeți k .
- ▣ 3. Explicați de ce $V(k)$ singur alege întotdeauna $k = 5$ și de ce factorii aleși sînt definiți doar pînă la o rotație.
- ▣ Raportați: un număr, un tabel cu șase valori și k , două fraze.



A7: ponderile Mariano–Murasawa [Rezolvat]

Cerință

- ▣ PIB-ul trimestrial este media pe 3 luni a unui nivel lunar latent Y_t^M ; $y_t = \Delta \ln Y_t^M$.
- ▣ 1. Aproximați $\ln Y_t^Q$ prin media celor trei logaritmi lunari.
- ▣ 2. Derivați $y_t^Q = \ln Y_t^Q - \ln Y_{t-3}^Q$ ca o combinație a lui $y_t, \dots, y_{t-4}$.
- ▣ 3. Cu $(y_t, \dots, y_{t-4}) = (0,4; 0,3; -0,1; 0,5; 0,2)$, calculați y_t^Q .
- ▣ Raportați: o formulă, cinci ponderi, un număr.

Rezolvare

- ▣ 1. Media geometrică în locul celei aritmetice:
 $\ln Y_t^Q \approx \frac{1}{3} \sum_{j=0}^2 \ln Y_{t-j}^M$
- ▣ 2. Scriem fiecare diferență de logaritmi pe trei luni ca sumă de rate lunare: ponderile $(1, 2, 3, 2, 1)/3$, cu suma 3
- ▣ 3. $(0,4 + 0,6 - 0,3 + 1,0 + 0,2)/3 = 0,633$

A8: știri și ponderi MIDAS [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ y (creșterea PIB) și publicarea anchetei x , standardizate, $\text{Cov}(y, x) = 0,6$, $\text{Var}x = 1$; $\mathbb{E}[x \mid \Omega_{old}] = 0,2$, valoarea publicată $x = -0,8$. Model: A7.
- ▣ 1. Calculați știrea și revizuirea nowcast-ului.
- ▣ 2. Două publicări cu $\mathbb{E}[II'] = \begin{pmatrix} 1 & 0,5 \\ 0,5 & 1 \end{pmatrix}$, $\mathbb{E}[yI] = (0,6; 0,3)'$: calculați ponderile și spuneți de ce a doua este zero.
- ▣ 3. Almon exponențial cu $\theta = (0,5; -0,2)$, $K = 4$: calculați ponderile.
- ▣ Raportați: două numere, două ponderi și o frază, patru ponderi.

B1: hiperparametri prin verosimilitatea marginală [Rezolvat]

- ▣ **Întrebarea:** cât de strânsă trebuie să fie distribuția a priori Minnesota pentru sistemele SMALL și MEDIUM ale SUA?
- ▣ **Date:** SMALL (ocuparea privată, IPC, dobânda federal funds) și MEDIUM (20 de serii din BGR), $100 \times$ logaritmul nivelului sau niveluri, $p = 13$, 1960:1–2019:12
- ▣ **Cerințe**
 1. Calculați modul a posteriori al lui (λ, μ, ϕ) cu distribuțiile Gamma GLP pentru fiecare sistem.
 2. Reprezentați logaritmul densității a posteriori în funcție de λ și raportați pierderea la $\lambda = 0,2$ și $\lambda = 1$.
 3. Calculați suma coeficienților lagurilor proprii ale IPC în media a posteriori (și prin OLS pentru SMALL).
 4. Interpretare: ce spun modurile despre mărimea sistemului și despre rădăcinile unitare?
- ▣ **Raportați:** șase hiperparametri, patru pierderi, trei sume, o frază
- ▣ Notebook: secțiunea [B1](#)

B1: rezolvare (1/2) [Rezolvat]



B1: rezolvare (2/2) [Rezolvat]

Sistemul	λ	μ	ϕ	pierdere la 0,2 / 1	suma proprie IPC
SMALL ($k = 40$)	0,381	0,199	0,440	-12,6 / -26,3	0,9999 (OLS 0,9980)
MEDIUM ($k = 261$)	0,149	0,134	0,445	-42,6 / -2173,5	1,0000

□ Interpretare: sistemul mai mare cere o distribuție a priori mai strânsă

- ▶ λ 0,381 față de 0,149; regula potrivirii BGR dă 0,158
- ▶ valori mici ale lui μ și ϕ : datele favorizează persistența și rădăcinile aproape unitare
- ▶ suma lagurilor proprii ale IPC este aproape exact 1

B2: un VAR bayesian pentru România [Propus]


- **Întrebarea:** prognozează un BVAR de tip GLP inflația și producția industrială din România mai bine decât un mers aleator și un VAR estimat prin OLS?
- **Date:** lunar 2005:8–2026:7 ($T = 252$): 100 log IP, 100 log IAPC, ROBOR 3M, 100 log EUR/RON (BNR), șomaj, ESI; $p = 12$; model: [B1](#)
- **Cerințe**
 1. Stabiliți $\delta_i = 1$ pentru toate variabilele în afara ESI și calculați modul GLP pe eșantionul complet.
 2. Prognozați recursiv, din originile 2015:1–2025:7, variațiile la 1 și 12 luni ale log IAPC și log IP cu mers aleator cu derivă, VAR(12) prin OLS și BVAR (hiperparametri reoptimizați în fiecare ianuarie).
 3. Raportați tabelul RMSE și intervalul lui λ reoptimizat.
 4. Interpretare: ce arată VAR-ul OLS despre $k = 73$ de regresori și 120 de observații?
- **Raportați:** un set de hiperparametri, un tabel cu 12 RMSE, un interval, o frază
- Notebook: secțiunea [B2](#)



B3: factorii panelului FRED-MD pe trei eșantioane [Rezolvat]

- **Întrebarea:** este stabilă în timp structura factorială a economiei SUA?
- **Date:** panelul în format FRED-MD, transformat și curățat de valori extreme; eșantioanele 1960–1984, 1985–2007, 2008–2026 (serii cu cel puțin 80% din observații)
- **Cerințe**
 1. Estimați opt factori prin componente principale cu EM pe fiecare eșantion.
 2. Raportați alegerile Bai–Ng (IC_{p2} , PC_{p2}), ponderea primei componente și a primelor trei.
 3. Raportați corelația absolută a primului factor cu creșterea IP, inflația IPC (a doua diferență) și variația dobânzii federal funds.
 4. Interpretare: ce s-a schimbat între cele trei perioade?
- **Raportați:** un tabel cu trei rînduri și șapte coloane, o frază
- Notebook: secțiunea [B3](#)

B3: rezolvare (1/2) [Rezolvat]



B3: rezolvare (2/2) [Rezolvat]

Eșantionul	N	IC_{p2}	PC_{p2}	prima, %	3, %	IP	IPC	FFR
1960–1984	103	6	10	19,4	33,5	0,85	0,10	0,40
1985–2007	109	7	10	13,6	29,2	0,77	0,01	0,54
2008–2026	117	8	10	20,0	42,7	0,80	0,29	0,42

□ Interpretare: primul factor este activitatea reală în toate perioadele

- ▶ a explicat cel mai puțin în Marea Moderație și cel mai mult după 2008 (criza financiară, 2020)
- ▶ criteriile aleg între șase și opt factori, mai mulți în eșantionul recent


B4: FAVAR și numărul de factori [Propus]

- **Întrebarea:** depind răspunsurile FAVAR la un șoc de politică monetară de numărul de factori K ?
- **Date:** panelul complet în format FRED-MD 1960:1–2001:8, FAVAR în doi pași din [Bernanke, Boivin și Elias \(2005\)](#), VAR(13), dobînda ultima, șoc de 25 bp; model: [B3](#)
- **Cerințe**
 1. Estimați FAVAR cu $K = 1, 3$ și 5 .
 2. Raportați minimul IP și luna lui, cel mai mare răspuns al IPC în 24 de luni, răspunsul IPC după 48 de luni și maximul șomajului.
 3. Interpretare: ce K ați raporta și cum l-ați apăra înainte de a vedea răspunsurile?
- **Raportați:** un tabel cu trei rînduri și cinci coloane, două fraze
- Notebook: secțiunea [B4](#)

B5: nowcasting pentru PIB-ul României în T2 2026 [Rezolvat]

- **Întrebarea:** cum au evoluat nowcast-urile AR, punte și MIDAS pentru T2 2026 pe măsură ce au sosit datele și cât de precise sînt în general?
- **Date:** panelul lunar (Eurostat) cu întârzieri stilizate de publicare (anchete 0, șomaj 1, date hard 2 luni; PIB-ul la 2 luni după trimestru); creșterea publicată 0,00%
- **Cerințe**
 1. Construiți seturile de informații de la sfîrșitul lunilor aprilie, mai, iunie și iulie 2026.
 2. Calculați nowcast-urile AR(1), punte (IP, comerț, ESI) și MIDAS (IP, ESI, $K = 6$) la fiecare dată.
 3. Calculați RMSE al aceluiași modele pentru T1 2013–T2 2026, fără T2–T3 2020.
 4. Interpretare: este suficient un singur trimestru pentru a clasifica modelele?
- **Raportați:** un tabel cu douăsprezece nowcast-uri, un tabel cu douăsprezece RMSE, o frază
- Notebook: secțiunea [B5](#)

B5: rezolvare (1/2) [Rezolvat]



B5: rezolvare (2/2) [Rezolvat]

Sfârșitul	AR	Punte	MIDAS	RMSE AR	RMSE punte	RMSE MIDAS
aprilie	0,79	−0,02	0,73	1,33	1,43	1,60
mai	0,77	−0,10	−0,76	1,33	1,38	1,26
iunie	0,77	0,26	−0,55	1,33	1,39	1,25
iulie	0,77	−0,17	−0,60	1,33	1,48	1,15

- Interpretare: un singur trimestru nu spune aproape nimic despre o clasificare
- ▶ T2 2026: nowcast-ul punte a fost cel mai apropiat de valoarea publicată 0,00%, iar MIDAS a coborât prea mult
 - ▶ pe 2013–2026, MIDAS este cel mai bun din luna 2, iar puntea cea mai slabă

B6: nowcast-ul pentru T3 2026 și știrile lui [Propus]

- **Întrebarea:** cum au schimbat publicările din septembrie 2026 nowcast-ul factorial dinamic pentru T3 2026?
- **Date:** panelul din B5; DFM cu doi factori (în doi pași, legătura Mariano–Murasawa); seturile de informații de la sfârșitul lunilor august și septembrie 2026; model: B5
- **Cerințe**
 1. Estimați DFM pe setul de informații din august și calculați nowcast-ul pentru T3 2026.
 2. Păstrând parametrii ficși, calculați nowcast-ul din septembrie și descompunerea în știri pe serii.
 3. Verificați că impacturile însumează revizuirea; comparați cu estimarea EM din statsmodels.
 4. Interpretare: ce publicări au mișcat nowcast-ul, datele hard sau cele soft?
- **Raportați:** două nowcast-uri, un tabel de impacturi, o verificare, două numere EM, o frază
- Notebook: secțiunea B6

C1: mai ajută anchetele după 2020? [Propus]

- **Întrebarea:** îmbunătățesc cele șase solduri de încredere din România nowcast-ul DFM de la sfârșitul trimestrului dincolo de datele hard, înainte și după 2020?
- **Date:** panelul din B5; DFM cu toate seriile (doi factori) și doar cu date hard (un factor); trimestrele 2013–2019 și 2021–2026; model: B5
- **Cerințe**
 1. Scrieți o preînregistrare de cinci rînduri: ținta, modelele, setul de informații, împărțirea eșantionului, testul.
 2. Calculați RMSE al celor două DFM și al AR la sfârșitul lunii 3 pe fiecare subeșantion.
 3. Interpretare: ce se poate și ce nu se poate concluziona din aproximativ 25 de trimestre pe subeșantion?
- **Raportați:** un plan de cinci rînduri, un tabel cu șase RMSE, un plan de proiect
- **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre VAR bayesiene, modele factoriale și nowcasting. Răspunsul:
- (a) Cu distribuția a priori Minnesota, $\lambda = 0$ dă estimațiile OLS.
- (b) Distribuția a priori natural conjugată permite un shrinkage între variabile theta sub 1.
- (c) În BVAR mari, λ optim crește cu numărul de variabile.
- (d) Distribuția pentru suma coeficienților împinge VAR-ul spre un model în prime diferențe.
- (e) IC_{p2} Bai-Ng alege numărul de factori care maximizează varianța explicată.
- (f) Știrea unei publicări este valoarea ei; impactul este valoarea înmulțită cu ponderea factorială.
- (g) Un eșantionator Gibbs cu $R\text{-hat} = 1,56$ a ajuns la convergență.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de șapte verdicte, fiecare cu un rînd de justificare.



Idei de reținut

- ▣ O distribuție a priori este informație: preciziile se adună, iar verosimilitatea marginală spune cât să ne bazăm pe ea
- ▣ Observațiile fictive transformă un VAR bayesian într-o regresie OLS pe date augmentate
- ▣ Componentele principale și Bai–Ng rezumă un panel mare; numărul de factori poate schimba concluziile
- ▣ Nowcast-urile se îmbunătățesc pe măsură ce sosesc datele; revizuirile se descompun în știri
- ▣ Un răspuns AI este o ciornă: verificați limitele, numărătorile, semnele diagnosticelor și definițiile

După seminar

- ▣ Cursul 5 dezvoltă fiecare temă de azi: distribuțiile a priori Minnesota și NIW, GLP, BVAR mari, factori, FAVAR, DFM, nowcasting pentru PIB-ul României
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: un model de nowcasting în timp real pentru România
- ▣ Lectură: Bańbura, Giannone și Reichlin (2010); Giannone, Lenza și Primiceri (2015); Stock și Watson (2002b); Bańbura și Modugno (2014)
- ▣ **Seminarul are rol de exercițiu și nu se notează**

Bibliografie (1/2)

- ▣ Bańbura, M., Giannone, D., & Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71–92. doi:10.1002/jae.1137
- ▣ Bańbura, M., & Modugno, M. (2014). Maximum likelihood estimation of factor models on datasets with arbitrary pattern of missing data. *Journal of Applied Econometrics*, 29(1), 133–160. doi:10.1002/jae.2306
- ▣ Baffigi, A., Golinelli, R., & Parigi, G. (2004). Bridge models to forecast the euro area GDP. *International Journal of Forecasting*, 20(3), 447–460. doi:10.1016/S0169-2070(03)00067-0
- ▣ Bai, J., & Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221. doi:10.1111/1468-0262.00273
- ▣ Bernanke, B. S., Boivin, J., & Elias, P. (2005). Measuring the effects of monetary policy: A factor-augmented vector autoregressive (FAVAR) approach. *The Quarterly Journal of Economics*, 120(1), 387–422. doi:10.1162/0033553053327452
- ▣ Doan, T., Litterman, R., & Sims, C. (1984). Forecasting and conditional projection using realistic prior distributions. *Econometric Reviews*, 3(1), 1–100. doi:10.1080/07474938408800053
- ▣ Gelman, A., & Rubin, D. B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4), 457–472. doi:10.1214/ss/1177011136
- ▣ Geman, S., & Geman, D. (1984). Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-6(6), 721–741. doi:10.1109/TPAMI.1984.4767596

Bibliografie (2/2)

- ▣ Ghysels, E., Santa-Clara, P., & Valkanov, R. (2006). Predicting volatility: Getting the most out of return data sampled at different frequencies. *Journal of Econometrics*, 131(1–2), 59–95. doi:10.1016/j.jeconom.2005.01.004
- ▣ Giannone, D., Lenza, M., & Primiceri, G. E. (2015). Prior selection for vector autoregressions. *The Review of Economics and Statistics*, 97(2), 436–451. doi:10.1162/REST_a_00483
- ▣ Kadiyala, K. R., & Karlsson, S. (1997). Numerical methods for estimation and inference in Bayesian VAR-models. *Journal of Applied Econometrics*, 12(2), 99–132. doi:10.1002/(SICI)1099-1255(199703)12:2<99::AID-JAE429>3.0.CO;2-A
- ▣ Litterman, R. B. (1986). Forecasting with Bayesian vector autoregressions: Five years of experience. *Journal of Business & Economic Statistics*, 4(1), 25–38. doi:10.1080/07350015.1986.10509491
- ▣ Mariano, R. S., & Murasawa, Y. (2003). A new coincident index of business cycles based on monthly and quarterly series. *Journal of Applied Econometrics*, 18(4), 427–443. doi:10.1002/jae.695
- ▣ Sims, C. A., & Zha, T. (1998). Bayesian methods for dynamic multivariate models. *International Economic Review*, 39(4), 949–968. doi:10.2307/2527347
- ▣ Stock, J. H., & Watson, M. W. (2002a). Forecasting using principal components from a large number of predictors. *Journal of the American Statistical Association*, 97(460), 1167–1179. doi:10.1198/016214502388618960
- ▣ Stock, J. H., & Watson, M. W. (2002b). Macroeconomic forecasting using diffusion indexes. *Journal of Business & Economic Statistics*, 20(2), 147–162. doi:10.1198/073500102317351921