



Analiza avansată a seriilor de timp și previziune

Seminarul 6: Modele în spațiul stărilor și filtrare bayesiană



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- APF: Auxiliary Particle Filter (filtrul de particule auxiliar)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARIMA: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ARMA: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- BN: Beveridge–Nelson (decomposition) — descompunerea Beveridge–Nelson
- BNR: Banca Națională a României
- DFM: Dynamic Factor Model (model factorial dinamic)
- DK: Durbin–Koopman (simulation smoother, 2002) — simulation smoother-ul Durbin–Koopman (2002)
- ECE: Europa Centrală și de Est
- ESS: Effective Sample Size (mărimea efectivă a eșantionului)
- FFBS: Forward Filtering, Backward Sampling (filtrare înainte, eșantionare înapoi)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- IAPC: Indicele armonizat al prețurilor de consum
- IG: inverse gamma (distribution) — distribuția inverse gamma
- IMA: Integrated Moving Average (model) — model integrat de medie mobilă
- KSC: Kim–Shephard–Chib (1998), mixture sampler for stochastic volatility (Kim–Shephard–Chib (1998), eșantionatorul cu mixtură pentru volatilitatea stochastică)
- LR: Likelihood Ratio (test) — testul raportului de verosimilitate
- MA: Moving Average (medie mobilă)
- ML: Machine Learning (învățare automată)
- MNZ: Morley–Nelson–Zivot (2003) — Morley–Nelson–Zivot (2003)
- PIB: Produsul intern brut
- PMMH: Particle Marginal Metropolis–Hastings (algoritmul Metropolis–Hastings marginal cu filtru de particule)
- QML: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- SUA: Statele Unite ale Americii
- SV: Stochastic Volatility (volatilitate stochastică)

Acronime folosite în acest material (2/2)

- ▣ TSA: Time Series Analysis (Serii de timp, cursul de licență)
- ▣ TVA: Taxa pe valoarea adăugată
- ▣ TVP: Time-Varying Parameter(s) — parametri variabili în timp
- ▣ UC: Unobserved Components (model) — model cu componente neobservate
- ▣ UC-SV: Unobserved Components model with Stochastic Volatility (Stock–Watson 2007) — model cu componente neobservate și volatilitate stohastică (Stock–Watson 2007)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum estimăm ce nu putem observa (un nivel, un trend, o volatilitate, un output gap) și cum deosebim un semnal real de zgomotul estimatorului?
 - ▶ seminarul are loc **înaintea** Cursului 6: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: filtrul difuz exact de mînă, verosimilitatea concentrată, eşantionarea înapoi, blocul Gibbs, momentele SV, un pas al filtrului de particule, APF, Beveridge–Nelson
 - ▶ Partea B: creșterea de trend a României; regresii TVP pentru Ungaria și Polonia; SV pentru EUR/RON prin Gibbs și prin filtrul de particule; output gap-ul României în timp real
 - ▶ Partea C: este ancorată inflația de trend din România? Un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	filtrul Kalman difuz exact de mână; verosimilitatea concentrată	Rezolvat,	A1
A3, A4	un pas de eșantionare înapoi; blocul Gibbs invers gamma	Propus	
		Rezolvat,	A3
A5, A6	momentele modelului SV; ecuația de măsurare QML	Propus	
		Rezolvat,	A5
A7, A8	un pas al filtrului de particule bootstrap; ponderile auxiliare cu o valoare extremă	Propus	
		Rezolvat,	A7
A9, A10	ciclul Beveridge–Nelson; local level, IMA(1,1) și BN	Propus	
		Rezolvat,	A9
B1, B2	creșterea de trend a României; regresii TVP pentru Ungaria și Polonia	Propus	
		Rezolvat,	B1
B3, B4	SV pentru EUR/RON: Gibbs, apoi filtrul de particule	Propus	
		Rezolvat,	B3
B5	output gap-ul României în timp real	Propus	
C1, C2	este ancorată inflația de trend din România?; ce este greșit într-un răspuns AI?	Propus	
			B1, A10
			B3, A1–A10

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
România: PIB real (ajustat)	Eurostat namq_10_gdp	trimestrial	2000–2026
IAPC: România, Ungaria, Polonia, zona euro	Eurostat prc_hicp_minr	lunar	2001–2026
cursul de referință EUR/RON	BNR	zilnic	2016–2026

- În notebook: `kalman_filter`, `kalman_smoother`, `sim_smoother_dk`, `ffbs`, `sv_gibbs`, `pf_sv`, `fit_llt`, `fit_tvp`, `fit_smooth_trend`, `ucsv_gibbs`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/8): modelul în spațiul stărilor

- Modelul (TSA, Capitolul 10): observațiile sînt o funcție liniară cu zgomot a unei stări ascunse care urmează o dinamică liniară

$$y_t = Z_t \alpha_t + \varepsilon_t, \varepsilon_t \sim N(0, H); \quad \alpha_{t+1} = T \alpha_t + R \eta_t, \eta_t \sim N(0, Q)$$

- Notățiile

- y_t : observația; α_t : starea neobservată; Z_t : matricea de măsurare; T : matricea de tranziție; R : alege stările care primesc șocuri
- H : varianța zgomotului de măsurare ε_t ; Q : covarianța șocurilor stării η_t ; n : lungimea eșantionului
- $Y_t = (y_1, \dots, y_t)$; $a_t = \mathbb{E}(\alpha_t | Y_{t-1})$, $P_t = \text{Var}(\alpha_t | Y_{t-1})$: starea prezisă și varianța ei

- Exemplul local level: $Z = T = R = 1$, $y_t = \mu_t + \varepsilon_t$, $\mu_{t+1} = \mu_t + \eta_t$

Noțiuni necesare azi (2/8): filtrul Kalman

- Eroarea de predicție și varianța ei: $v_t = y_t - Z_t a_t$, $F_t = Z_t P_t Z_t' + H$
 - ▶ v_t : informația nouă din y_t ; este independentă de datele trecute
- Câștigul Kalman $K_t = TP_t Z_t' / F_t$: cât din surpriza v_t mută predicția stării următoare
 - ▶ $a_{t+1} = Ta_t + K_t v_t$, $P_{t+1} = TP_t(T - K_t Z_t)' + RQR'$
 - ▶ starea filtrată (după observarea lui y_t): $a_{t|t} = a_t + P_t Z_t' v_t / F_t$
- Log-verosimilitatea: $\sum_t -\frac{1}{2}(\ln 2\pi + \ln F_t + v_t^2 / F_t)$, un produs secundar al filtrului

Noțiuni necesare azi (3/8): startul difuz exact

- Stările nestaționare (măsurări aleatoare) nu au varianță staționară: $P_1 = \kappa P_\infty + P_*$, $\kappa \rightarrow \infty$
 - ▶ P_∞ : marchează elementele difuze; P_* : covarianța celorlalte; $F_{\infty,t} = Z_t P_{\infty,t} Z_t'$ și $F_{*,t}$: părțile difuză și finită ale lui F_t
- Cît timp $F_{\infty,t} > 0$, folosim două câștiguri: $K^{(0)} = TP_\infty Z' / F_\infty$, $K^{(1)} = T(P_* Z' - P_\infty Z' F_*' / F_\infty) / F_\infty$
 - ▶ $a_{t+1} = Ta_t + K^{(0)} v_t$, $P_{\infty,t+1} = TP_\infty L^{(0)'} + TP_* L^{(0)'} + RQR'$
 - ▶ $L^{(0)} = T - K^{(0)} Z$, $L^{(1)} = -K^{(1)} Z$; după d pași difuzi $P_\infty = 0$ și preia filtrul obișnuit
- Log-verosimilitatea difuză: pașii difuzi contribuie cu $-\frac{1}{2}(\ln 2\pi + \ln F_{\infty,t})$, ceilalți cu $-\frac{1}{2}(\ln 2\pi + \ln F_t + v_t^2 / F_t)$
 - ▶ scala eliminată prin concentrare: dacă H, Q sînt proporționale cu σ^2 , atunci $\hat{\sigma}^2 = \frac{1}{n-d} \sum_{t>d} v_t^2 / F_t^*$,
 $F_t^* = F_t / \sigma^2$

Noțiuni necesare azi (4/8): eșantionarea stărilor

- ▣ FFBS (Carter–Kohn): rulăm filtrul înainte, apoi extragem stările înapoi
 - ▶ extragem $\alpha_n \sim N(a_n|n, P_n|n)$; apoi $\alpha_t|\alpha_{t+1} \sim N(a_t|t + G_t(\alpha_{t+1} - Ta_{t|t}), P_t|t - G_tTP_{t|t})$
 - ▶ $G_t = P_{t|t}T'(TP_{t|t}T' + RQR')^{-1}$: cât ne spune starea următoare despre cea curentă
- ▣ Durbin–Koopman: simulăm (α^+, y^+) din model, netezim o singură dată $y - y^+$: $\tilde{\alpha} = \alpha^+ + \hat{\alpha}(y - y^+)$
 - ▶ $\hat{\alpha}(\cdot)$: media netezită a stării; $\tilde{\alpha}$: o extragere exactă a întregii traiectorii a stării

Noțiuni necesare azi (5/8): blocurile Gibbs și frontiera

- Blocul Gibbs pentru o varianță cu a priori $IG(a_0, b_0)$ și m șocuri e_t : $\sigma^2 | e \sim IG(a_0 + m/2, b_0 + \sum e_t^2/2)$
 - ▶ $IG(a, b)$: inverse gamma cu forma a și scala b , media $b/(a - 1)$; e_t : șocurile implicate de extragerea curentă a stării
- Factorul de ineficiență $1 + 2 \sum_k \rho_k$: câte extrageri corelate valorează cât o extragere independentă
 - ▶ ρ_k : autocorelația lanțului la lagul k
- Pile-up: estimația ML a unei varianțe poate fi exact zero chiar dacă valoarea adevărată este pozitivă; testele LR la frontieră au nevoie de bootstrap

Noțiuni necesare azi (6/8): volatilitatea stochastică

- SV: $y_t = e^{h_t/2}\epsilon_t$, $h_t = \mu + \phi(h_{t-1} - \mu) + \sigma_\eta\eta_t$, $\epsilon_t, \eta_t \sim N(0, 1)$
 - ▶ h_t : logaritmul varianței (AR(1) latent); μ : media lui; ϕ : persistența; σ_η : volatilitatea volatilității
 - ▶ $\sigma_h^2 = \sigma_\eta^2/(1 - \phi^2)$: varianța lui h_t ; kurtosis-ul $3e^{\sigma_h^2} > 3$
 - ▶ $\text{Corr}(y_t^2, y_{t-k}^2) = (e^{\sigma_h^2\phi^k} - 1)/(3e^{\sigma_h^2} - 1)$: volatility clustering
- Forma liniară: $\ln y_t^2 = h_t + \ln \epsilon_t^2$, cu $\mathbb{E} \ln \epsilon^2 = -1,2704$, $\text{Var} \ln \epsilon^2 = \pi^2/2$
 - ▶ KSC: o mixtură de șapte distribuții Normale pentru $\ln \epsilon^2$; dați indicatorii mixturii, h este gaussian și se aplică instrumentele Kalman

Noțiuni necesare azi (7/8): filtrele de particule

- ▣ Filtrul de particule bootstrap: N particule $x_t^{(i)}$ aproximează distribuția stării
 - ▶ propagăm $x_t^{(i)} \sim f(\cdot | x_{t-1}^{(i)})$ (f : densitatea de tranziție); ponderăm $w^{(i)} = g(y_t | x_t^{(i)})$ (g : densitatea de măsurare)
 - ▶ termenul de verosimilitate $\hat{p}(y_t | Y_{t-1}) = \frac{1}{N} \sum w^{(i)}$; ponderile normalizate $W^{(i)} = w^{(i)} / \sum_j w^{(j)}$; ESS = $1 / \sum (W^{(i)})^2$; apoi reeșantionăm
- ▣ Reeșantionarea sistematică: $u_i = (U + i - 1) / N$, cu o singură variabilă uniformă U
 - ▶ particula j este copiată pentru fiecare u_i din $(C_{j-1}, C_j]$, C_j = ponderile normalizate cumulate
- ▣ Filtrul auxiliar (Pitt–Shephard): ponderi în prima etapă $\propto g(y_t | \mu_t^{(i)})$, $\mu_t^{(i)} = \mathbb{E}(x_t | x_{t-1}^{(i)})$; apoi propagăm și corectăm

Noțiuni necesare azi (8/8): trend și ciclu

- Trendul Beveridge–Nelson $\tau_t = y_t + \sum_{j \geq 1} \mathbb{E}_t(\Delta y_{t+j} - \mu)$: nivelul la care ajunge y după ce creșterea previzibilă se stinge
 - ▶ μ : creșterea medie; pentru un AR(1) în creștere, $\Delta y_t - \mu = \phi(\Delta y_{t-1} - \mu) + e_t$: ciclul
 $c_t = y_t - \tau_t = -\frac{\phi}{1-\phi}(\Delta y_t - \mu)$
- Local level cu raportul semnal-zgomot $q = \sigma_\eta^2 / \sigma_\varepsilon^2$: Δy_t este MA(1), $\Delta y_t = u_t + \theta u_{t-1}$,
 $\theta = -(1 + q/2) + \sqrt{q + q^2/4}$
 - ▶ local linear trend: $\mu_{t+1} = \mu_t + \nu_t + \xi_t$, $\nu_{t+1} = \nu_t + \zeta_t$; ν_t : panta; $4\nu_t$: creșterea de trend anualizată a unei serii trimestriale în logaritmi
- UC cu trend neted: $y_t = \tau_t + c_t$, $\Delta^2 \tau_{t+1} = \zeta_t$, c_t AR(2)
 - ▶ output gap-ul filtrat $c_{t|t}$ (timp real) față de output gap-ul netezit $\hat{c}_t$ (tot eșantionul)
- UC-SV (Stock–Watson): $\pi_t = \tau_t + \sigma_{\eta,t}\eta_t$, $\tau_t = \tau_{t-1} + \sigma_{\varepsilon,t}\varepsilon_t$: inflația = trend + zgomot tranzitoriu, ambele cu logaritmi varianțelor ca mersuri aleatoare cu varianța γ

A1: filtrul difuz exact de mîină [Rezolvat]

Cerință

- Local level, $\sigma_\varepsilon^2 = 1$, $\sigma_\eta^2 = 0,5$, μ_1 difuz ($a_1 = 0$, $P_{\infty,1} = 1$, $P_{*,1} = 0$); datele $y = (2,0; 3,0; 2,5)$.
- 1. Efectuați pasul difuz la $t = 1$: dați F_∞ , $K^{(0)}$, $K^{(1)}$, a_2 , $P_{\infty,2}$, $P_{*,2}$.
- 2. Rulați filtrul obișnuit pentru $t = 2, 3$: v_t , F_t , K_t , a_{t+1} , P_{t+1} .
- 3. Calculați log-verosimilitatea difuză și explicați de ce y_1 nu aduce informație despre varianțe.
- Raportați: un pas difuz, doi pași obișnuiți, o cifră, o frază.

Rezolvare

- 1. $F_\infty = 1$, $F_* = 0 + 1 = 1$; $K^{(0)} = 1$, $K^{(1)} = 0 - 1 \cdot 1/1 = -1$;
 $a_2 = 0 + 1 \cdot 2 = 2,000$; $P_{\infty,2} = 1(1 - 1) = 0$;
 $P_{*,2} = 1 \cdot 1 + 0 + 0,5 = 1,500$
- 2. $t = 2$: $v = 1,000$, $F = 2,500$, $K = 0,600$, $a_3 = 2,600$,
 $P_3 = 1,5(1 - 0,6) + 0,5 = 1,100$; $t = 3$: $v = -0,100$,
 $F = 2,100$, $K = 0,524$, $a_4 = 2,548$, $P_4 = 1,024$
- 3. Termenii $-0,919$; $-1,577$; $-1,292$; $\ln L_d = -3,788$. Primul termen este $-\frac{1}{2} \ln 2\pi$ oricare ar fi varianțele: y_1 doar fixează nivelul

A2: verosimilitatea concentrată [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Datele din A1, acum cu $\sigma_\eta^2 = 0,5\sigma_\varepsilon^2$ și σ_ε^2 necunoscut. Model: A1.
- ▣ 1. Rulați filtrul cu $\sigma_\varepsilon^2 = 1$ și scrieți $F_t = \sigma_\varepsilon^2 F_t^*$.
- ▣ 2. Derivați $\hat{\sigma}_\varepsilon^2$ prin maximizarea log-verosimilității difuze și calculați-l.
- ▣ 3. Calculați log-verosimilitatea concentrată (fără termenul difuz) și precizați câți parametri rămîn pentru căutarea numerică.
- ▣ Raportați: două rapoarte, o estimatie, o cifră, o frază.

A3: un pas de eșantionare înapoi [Rezolvat]

Cerință

- ▣ Continuăm A1: după y_2 momentele filtrate sînt $a_{2|2}$, $P_{2|2}$; presupunem că extragerea pentru perioada următoare este $\alpha_3 = 3,0$.
- ▣ 1. Calculați $a_{2|2}$ și $P_{2|2}$ din A1.
- ▣ 2. Calculați G_2 , media condiționată m_2 și varianța S_2 pentru $\alpha_2|\alpha_3, y_1, y_2$.
- ▣ 3. Explicați de ce y_3 nu este necesar în această distribuție condiționată.
- ▣ Raportați: două momente, trei cifre, o frază.

Rezolvare

- ▣ 1. $a_{2|2} = 2 + 0,6 \cdot 1 = 2,600$, $P_{2|2} = 1,5 - 1,5^2/2,5 = 0,600$
- ▣ 2. $G_2 = P_{2|2}/(P_{2|2} + \sigma_\eta^2) = 0,545$;
 $m_2 = 2,600 + 0,545(3,0 - 2,600) = 2,818$;
 $S_2 = P_{2|2}(1 - G_2) = 0,273$
- ▣ 3. Proprietatea Markov: dat α_3 , observațiile viitoare nu mai adaugă nimic despre α_2 ; informația lor a intrat deja prin extragerea lui α_3

A4: blocul Gibbs invers gamma [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Un eșantionator Gibbs pentru local level, $n = 50$; extragerea curentă a stării dă $\sum_t (y_t - \mu_t)^2 = 40$ și $\sum_t (\Delta \mu_t)^2 = 6,2$; a priori $IG(2,5; 0,25)$ pentru ambele varianțe. Model: A3.
- ▣ 1. Scrieți cele două distribuții a posteriori condiționate, cu parametrii lor.
- ▣ 2. Calculați mediile lor și raportul q implicat.
- ▣ 3. Explicați de ce acest eșantionator nu poate da niciodată $\sigma_\eta^2 = 0$, spre deosebire de ML.
- ▣ Raportați: două distribuții, trei cifre, o frază.

A5: momentele modelului SV [Rezolvat]

Cerință

- ▣ Modelul SV cu $\phi = 0,98$, $\sigma_\eta = 0,15$, ϵ_t gaussian.
- ▣ 1. Calculați σ_h^2 și kurtosis-ul lui y_t .
- ▣ 2. Calculați $\text{Corr}(y_t^2, y_{t-k}^2)$ pentru $k = 1, 10, 50$ și timpul de înjumătățire al unui șoc de volatilitate.
- ▣ 3. Explicați diferența față de un GARCH(1,1) cu aceeași persistență.
- ▣ Raportați: două cifre, patru cifre, o frază.

Rezolvare

- ▣ 1. $\sigma_h^2 = 0,0225/0,0396 = 0,568$; kurtosis-ul $3e^{0,568} = 5,30$
- ▣ 2. 0,173; 0,138; 0,054: scădere lentă de la un nivel inițial mic; timpul de înjumătățire $\ln 0,5 / \ln 0,98 = 34,3$ zile
- ▣ 3. Varianța GARCH este cunoscută cu un pas înainte; în SV are propriul șoc, deci excesul de kurtosis apare chiar cu ϕ apropiat de 1, iar verosimilitatea cere o integrală

A6: ecuația de măsurare QML [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul SV din A5, scris ca $\ln y_t^2 = h_t + \xi_t$. Model: A5.
- ▣ 1. Dați media și varianța lui ξ_t și raportul semnal-zgomot $\sigma_h^2 / \text{Var} \xi_t$.
- ▣ 2. Calculați $\text{Corr}(\ln y_t^2, \ln y_{t-k}^2)$ pentru $k = 1, 10$ și numiți modelul ARMA pentru $\ln y_t^2$.
- ▣ 3. Explicați de ce filtrul Kalman aplicat lui $\ln y_t^2$ este consistent, dar ineficient.
- ▣ Raportați: trei cifre, două cifre și un model, o frază.

A7: un pas al filtrului de particule bootstrap [Rezolvat]

Cerință

- ▣ Modelul SV, $N = 4$ particule după propagare:
 $h^{(i)} = (-1; 0; 0,5; 1,5)$; observația $y_t = 2,0$; reeșantionare sistematică cu $U = 0,3$.
- ▣ 1. Calculați $w^{(i)} = N(y_t; 0, e^{h^{(i)}})$ și ponderile normalizate.
- ▣ 2. Calculați ESS și incrementul de verosimilitate $\hat{p}(y_t | Y_{t-1})$.
- ▣ 3. Reeșantionați: ce particule supraviețuiesc și de cîte ori?
- ▣ Raportați: opt cifre, două cifre, o listă.

Rezolvare

- ▣ 1. $w = (0,0029; 0,0540; 0,0924; 0,1206)$;
 $W = (0,011; 0,200; 0,342; 0,447)$
- ▣ 2. $ESS = 2,80$ din 4; $\hat{p} = \frac{1}{4} \sum w = 0,0675$, $\ln \hat{p} = -2,696$
- ▣ 3. $u = (0,075; 0,325; 0,575; 0,825)$ față de
 $C = (0,011; 0,211; 0,553; 1)$: particulele 2, 3, 4, 4; particula cu volatilitate mică dispare, cea cu volatilitate mare este copiată de două ori

A8: ponderi auxiliare cu o valoare extremă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Local level, $\sigma_\varepsilon^2 = 0,5$, $\sigma_\eta^2 = 0,25$; particule cu ponderi egale $x_{t-1}^{(i)} = (0; 1; 2; 3)$; valoarea extremă $y_t = 4,0$. Model: A7.
- ▣ 1. Calculați ponderile normalizate din prima etapă $\propto N(y_t; x_{t-1}^{(i)}, \sigma_\varepsilon^2)$ și ESS-ul lor.
- ▣ 2. Calculați ponderile complet adaptate $\propto N(y_t; x_{t-1}^{(i)}, \sigma_\varepsilon^2 + \sigma_\eta^2)$ și comparați.
- ▣ 3. Explicați ce ar face filtrul bootstrap cu aceeași valoare extremă.
- ▣ Raportați: patru ponderi și un ESS, patru ponderi, o frază.

A9: ciclul Beveridge–Nelson al unui ARIMA(1,1,0) [Rezolvat]

Cerință

- Creșterea trimestrială: $\Delta y_t - 0,8 = 0,35(\Delta y_{t-1} - 0,8) + e_t$; în acest trimestru $\Delta y_t = 2,0$.
- 1. Derivați $\sum_{j \geq 1} \mathbb{E}_t(\Delta y_{t+j} - \mu)$ pentru un AR(1).
- 2. Calculați ciclul BN c_t și multiplicatorul pe termen lung al lui e_t asupra trendului.
- 3. Explicați semnul ciclului după un trimestru puternic.
- Raportați: o formulă, două cifre, o frază.

Rezolvare

- 1. $\mathbb{E}_t(\Delta y_{t+j} - \mu) = \phi^j(\Delta y_t - \mu)$, suma = $\frac{\phi}{1-\phi}(\Delta y_t - \mu)$
- 2. $\frac{\phi}{1-\phi} = 0,538$; $c_t = -0,538 \cdot 1,2 = -0,646$; multiplicatorul $1/(1-\phi) = 1,538$
- 3. Cu persistență pozitivă a creșterii, un trimestru puternic ridică creșterea viitoare așteptată: trendul sare mai mult decît producția, deci producția este *sub* trend

A10: local level, IMA(1,1) și Beveridge–Nelson [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ Local level cu $\sigma_\varepsilon^2 = 1$, $q = 0,5$. Model: A9.
- ▣ 1. Găsiți coeficientul MA θ al lui Δy_t .
- ▣ 2. Rezolvați ecuația Riccati staționară $P = P - P^2/(P + 1) + q$ și dați câștigul $k = P/(P + 1)$.
- ▣ 3. Arătați că trendul BN al IMA(1,1), $y_t + \theta u_t$, este egal cu nivelul filtrat staționar $a_t|_t$.
- ▣ Raportați: o cifră, două cifre, o derivare.

B1: creșterea de trend a României [Rezolvat]

- ▣ **Întrebarea:** a scăzut creșterea de trend a României față de anii 2000, dacă ținem cont de incertitudinea estimației?
- ▣ **Date:** $100 \times \log$ PIB real (Eurostat, ajustat), T1 2000–T2 2026, $T = 106$; T2–T4 2020 tratate ca lipsă
- ▣ **Cerințe**
 1. Estimați modelul local linear trend prin ML difuz exact cu filtrul numpy și cu statsmodels; comparați parametrii și log-verosimilitățile.
 2. Neteziți panta și raportați creșterea de trend anualizată $4\hat{\nu}_t$ cu bandă de 90% în 2005, 2012, 2019 și în ultimul trimestru.
 3. Verificați dacă vreo varianță se află la frontieră.
 4. Interpretare: este semnificativă statistic scăderea creșterii de trend?
- ▣ **Raportați:** două seturi de parametri, patru rate de creștere cu benzi, o frază
- ▣ **Notebook:** secțiunea B1

B1: rezolvare [Rezolvat]



- numpy: $\sigma_{\epsilon}^2 = 0,6013$, $\sigma_{\xi}^2 = 3,9577$, $\sigma_{\zeta}^2 = 0,0039$, $\ln L_d = -231,08$; statsmodels: 0,6011; 3,9581; 0,0039; $-229,24$ (diferența în $\ln L$ este $\ln 2\pi$, doi pași difuzi)
- Creșterea de trend: 4,1% (abatere standard 1,1) în 2005, 3,1% (1,0) în 2012, 2,8% (1,1) în 2019, 2,2% (1,4) la final
- Interpretare: varianța pantei este mică, deci creșterea de trend se mișcă lent; benzile se suprapun mult, deci o scădere este sugerată, dar nu demonstrată; șocurile de nivel absorb recesiunea din 2009


B2: regresii TVP pentru Ungaria și Polonia [Propus]

- ▣ **Întrebarea:** s-a schimbat în timp co-mișcarea inflației din Ungaria și Polonia cu inflația din zona euro?
- ▣ **Date:** inflația IAPC trimestrială (% anualizat), din T4 2005; inflația din zona euro fără componenta sezonieră; modelul din B1 extins la $y_t = c_t + b_t x_t + D_t' \gamma + \varepsilon_t$; model: B1
- ▣ **Cerințe**
 1. Estimați regresia TVP prin ML difuz exact (cinci stări difuze) pentru fiecare țară.
 2. Raportați $\hat{\sigma}_b^2$ și b_t netezit, cu erori standard, în T3 2008, T4 2019 și T4 2022.
 3. Calculați testul LR pentru $\sigma_b^2 = 0$ și p-value-ul după regula $\frac{1}{2} \chi_1^2$; spuneți de ce această valoare p este doar orientativă.
 4. Interpretare: este panta mai mare decât unu și diferă ea de cea pentru România (Cursul 6)?
- ▣ **Raportați:** un tabel cu două rînduri, șase pante cu erori standard, două teste, o frază
- ▣ **Notebook:** secțiunea B2

B3: volatilitatea stochastică a cursului EUR/RON [Rezolvat]

- ▣ **Întrebarea:** cât de persistentă este volatilitatea leului față de euro și cum se compară SV cu GARCH?
- ▣ **Date:** randamentele logaritmice zilnice ale cursului de referință BNR EUR/RON, %, centrate, 2016–2026, $T = 2686$; eșantionatorul Gibbs KSC cu $c = 10^{-3}\text{Var}(y)$
- ▣ **Cerințe**
 1. Rulați eșantionatorul Gibbs KSC și raportați mediile a posteriori și intervalele de 90% pentru μ, ϕ, σ_η , cu factorii de ineficiență.
 2. Estimați un GARCH(1,1) gaussian pe aceleași date.
 3. Reprezentați grafic media a posteriori a lui $\exp(h_t/2)$ față de volatilitatea GARCH.
 4. Interpretare: ce spune timpul de înjumătățire al volatilității despre un curs de schimb în regim de managed float?
- ▣ **Raportați:** un tabel cu trei parametri, trei cifre GARCH, un grafic, o frază
- ▣ **Notebook:** secțiunea B3

B3: rezolvare [Rezolvat]



- $\phi = 0,957$ [0,944; 0,969], $\sigma_{\eta} = 0,541$ [0,488; 0,597], $\mu = -5,628$ [-6,032; -5,210]; factorii de ineficiență 18, 42, 1 (20 000 de extrageri)
- GARCH(1,1): $\alpha = 0,225$, $\beta = 0,753$; abaterea standard zilnică 0,121%, kurtosis-ul 27,8
- Interpretare: timpul de înjumătățire al unui șoc al logaritmului volatilității este de aproximativ 16 zile; perioadele liniștite cu episoade rare de agitație sînt specifice unui regim de managed float; kurtosis-ul mare arată că ϵ_t gaussian nu este suficient (B4)

B4: filtrul de particule pentru modelul SV al cursului EUR/RON [Propus]

- **Întrebarea:** este SV mai bun decât GARCH pentru EUR/RON pe scala verosimilității și este fiabilă aici verosimilitatea din filtrul de particule?
- **Date:** datele și mediile a posteriori din B3; filtrul de particule bootstrap cu reeșantionare sistematică; model: B3 și A7
- **Cerințe**
 1. Rulați filtrul cu $N = 500, 2000, 10\,000$ de particule, de câte 30 de ori, și raportați abaterea standard a lui $\ln \hat{L}$.
 2. Raportați ESS minim și median și data minimului.
 3. Comparați $\ln \hat{L}$ (pentru N mare) cu maximul GARCH.
 4. Interpretare: ce vă spune prăbușirea ESS despre model?
- **Raportați:** trei abateri standard, două valori ESS și o dată, două log-verosimilități, o frază
- Notebook: secțiunea B4

B5: output gap-ul României în timp real [Propus]

- **Întrebarea:** cât se schimbă estimația output gap-ului României de la finalul eșantionului când sosesc date noi?
- **Date:** datele din B1; UC cu trend neted și ciclu AR(2) (`fit_smooth_trend`); cvasi-timp real: reestimați pe datele pînă la fiecare trimestru din T4 2012 (parametrii la fiecare 4 trimestre) și păstrați output gap-ul filtrat; model: B1 și A10
- **Cerințe**
 1. Calculați seria output gap-urilor în timp real (filtrate, la finalul eșantionului) și output gap-ul final netezit.
 2. Calculați statisticile Orphanides–van Norden: corelația, raportul zgomot–semnal (abaterea standard a revizuirilor împărțită la abaterea standard a output gap-ului final), proporția semnelor opuse.
 3. Raportați cea mai mare revizuire.
 4. Interpretare: se poate baza politica monetară pe estimația curentă a lagului?
- **Raportați:** patru statistici, o cifră, o frază
- Notebook: secțiunea B5

C1: este ancorată inflația de trend din România? [Propus]

- ▣ **Întrebarea:** se află trendul inflației din România în banda-țintă a BNR ($2,5\% \pm 1$ pp) și cât de robust este răspunsul?
- ▣ **Date:** inflația IAPC trimestrială (% anualizat); UC-SV Stock și Watson (2007) cu variabile dummy sezoniere trimestriale (ucsv_gibbs); model: B3
- ▣ **Cerințe**
 1. Scrieți o preînregistrare de cinci rînduri: ipoteza, datele, statistica de ancorare, grila de robustețe, ce ar infirma afirmația.
 2. Estimați modelul pentru datele de început 2001 și 2006 și pentru $\gamma = 0,1$ și $0,2$; raportați trendul din ultimul trimestru cu bandă de 68%.
 3. Calculați probabilitatea a posteriori ca trendul să se afle în intervalul 1,5–3,5% în ultimul trimestru și în T4 2019.
 4. Interpretare: ce se poate și ce nu se poate concluziona și cum ați transforma acest lucru într-un proiect?
- ▣ **Raportați:** un plan de cinci rînduri, un tabel cu patru rînduri, un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre estimarea modelelor în spațiul stărilor. Răspunsul:
- (a) Filtrul Kalman este inutil dacă erorile nu sînt gaussiene.
- (b) Pentru o stare de tip mers aleator, puneți $P_1 = 10^{-10}$ și păstrați toți cei n termeni ai verosimilității.
- (c) O estimăție ML egală cu zero a varianței nivelului demonstrează că nivelul este constant.
- (d) SV și GARCH sînt același model, pentru că ambele fac volatilitatea persistentă.
- (e) Verosimilitatea din filtrul de particule este nedeplasată, deci și logaritmul ei este nedeplasat.
- (f) Simulation smoother-ul Durbin-Koopman are nevoie de o singură trecere a netezitorului stărilor pentru fiecare extragere.
- (g) Cu un ciclu AR(1), corelația dintre șocurile trendului și ale ciclului poate fi estimată.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați o cifră din cerințele de azi (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de șapte verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Filtrul difuz exact lasă primele observații să fixeze stările nestaționare; ele nu aduc informație despre varianțe
- ▣ Eșantionarea stărilor înseamnă mecanismul Kalman rulat înapoi (FFBS) sau încă o dată pe date simulate (DK)
- ▣ SV adaugă un șoc varianței; filtrele de particule îi estimează verosimilitatea, nedeplasată doar în nivel
- ▣ Creșterea de trend, output gap-urile și trendurile ancorate sînt estimații cu benzi largi: raportați-le și raportați valorile în timp real
- ▣ Un răspuns AI este o ciornă: verificați inițializarea, frontiera, deplasarea log-verosimilității și identificarea

După seminar

- ▣ Cursul 6 dezvoltă fiecare temă de azi: filtrul difuz exact, verosimilitatea la frontieră, cele trei eșantionatoare, KSC, filtrele de particule și PMMH, TVP, DFM, MNZ și UC-SV
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: inflația de trend și ancorarea în Europa Centrală și de Est
- ▣ Lectură: Durbin și Koopman (2012), cap. 4–5; Kim, Shephard și Chib (1998); Morley, Nelson și Zivot (2003); Stock și Watson (2007)
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie (1/2)

- Beveridge, S., & Nelson, C. R. (1981). A new approach to decomposition of economic time series into permanent and transitory components with particular attention to measurement of the 'business cycle'. *Journal of Monetary Economics*, 7(2), 151–174. doi:10.1016/0304-3932(81)90040-4
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- Carter, C. K., & Kohn, R. (1994). On Gibbs sampling for state space models. *Biometrika*, 81(3), 541–553. doi:10.1093/biomet/81.3.541
- Durbin, J., & Koopman, S. J. (2002). A simple and efficient simulation smoother for state space time series analysis. *Biometrika*, 89(3), 603–616. doi:10.1093/biomet/89.3.603
- Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press. doi:10.1093/acprof:oso/9780199641178.001.0001
- Gordon, N. J., Salmond, D. J., & Smith, A. F. M. (1993). Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEEE Proceedings F (Radar and Signal Processing)*, 140(2), 107–113. doi:10.1049/ip-f-2.1993.0015
- Kim, S., Shephard, N., & Chib, S. (1998). Stochastic volatility: Likelihood inference and comparison with ARCH models. *The Review of Economic Studies*, 65(3), 361–393. doi:10.1111/1467-937X.00050
- Koopman, S. J. (1997). Exact initial Kalman filtering and smoothing for nonstationary time series models. *Journal of the American Statistical Association*, 92(440), 1630–1638. doi:10.1080/01621459.1997.10473685
- Morley, J. C., Nelson, C. R., & Zivot, E. (2003). Why are the Beveridge–Nelson and unobserved-components decompositions of GDP so different? *The Review of Economics and Statistics*, 85(2), 235–243. doi:10.1162/003465303765299765
- Orphanides, A., & van Norden, S. (2002). The unreliability of output-gap estimates in real time. *The Review of Economics and Statistics*, 84(4), 569–583. doi:10.1162/003465302760556422
- Pitt, M. K., & Shephard, N. (1999). Filtering via simulation: Auxiliary particle filters. *Journal of the American Statistical Association*, 94(446), 590–599. doi:10.1080/01621459.1999.10474153
- Shephard, N., & Harvey, A. C. (1990). On the probability of estimating a deterministic component in the local level model. *Journal of Time Series Analysis*, 11(4), 339–347. doi:10.1111/j.1467-9892.1990.tb00062.x

Bibliografie (2/2)

- Stock, J. H., & Watson, M. W. (1998). Median unbiased estimation of coefficient variance in a time-varying parameter model. *Journal of the American Statistical Association*, 93(441), 349–358. doi:[10.1080/01621459.1998.10474116](https://doi.org/10.1080/01621459.1998.10474116)
- Stock, J. H., & Watson, M. W. (2007). Why has U.S. inflation become harder to forecast? *Journal of Money, Credit and Banking*, 39(s1), 3–33. doi:[10.1111/j.1538-4616.2007.00014.x](https://doi.org/10.1111/j.1538-4616.2007.00014.x)