



Analiza avansată a seriilor de timp și previziune

Seminarul 6: Modele în spațiul stărilor și filtrare bayesiană



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **APF**: Auxiliary Particle Filter (filtrul de particule auxiliar)
- ▣ **AR**: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARIMA**: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BN**: Beveridge–Nelson (decomposition) — descompunerea Beveridge–Nelson
- ▣ **BNR**: Banca Națională a României
- ▣ **DFM**: Dynamic Factor Model (model factorial dinamic)
- ▣ **DK**: Durbin–Koopman (simulation smoother, 2002) — algoritmul Durbin–Koopman (2002) de simulare a stărilor netezite
- ▣ **ECE**: Europa Centrală și de Est
- ▣ **ESS**: Effective Sample Size (mărimea efectivă a eșantionului)
- ▣ **FFBS**: Forward Filtering, Backward Sampling (filtrare înainte, eșantionare înapoi)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **IG**: inverse gamma (distribution) — distribuția gamma inversă

Acronime folosite în acest material (2/2)

- ▣ **IMA**: Integrated Moving Average (model) — model integrat de medie mobilă
- ▣ **KSC**: Kim–Shephard–Chib (1998), mixture sampler for stochastic volatility (Kim–Shephard–Chib (1998), eșantionatorul cu mixtură pentru volatilitatea stohastică)
- ▣ **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **MNZ**: Morley–Nelson–Zivot (2003) — Morley–Nelson–Zivot (2003)
- ▣ **PIB**: Produsul intern brut
- ▣ **PMMH**: Particle Marginal Metropolis–Hastings (algoritmul Metropolis–Hastings marginal cu filtru de particule)
- ▣ **QML**: Quasi-Maximum Likelihood (verosimilitate cvasi-maximă)
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **SV**: Stochastic Volatility (volatilitate stohastică)
- ▣ **TSA**: Time Series Analysis (Serii de timp, cursul de licență)
- ▣ **TVA**: Taxa pe valoarea adăugată
- ▣ **TVP**: Time-Varying Parameter(s) — parametri variabili în timp
- ▣ **UC**: Unobserved Components (model) — model cu componente neobservate
- ▣ **UC-SV**: Unobserved Components model with Stochastic Volatility (Stock–Watson 2007) — model cu componente neobservate și volatilitate stohastică (Stock–Watson 2007)

Întrebarea de azi și structura seminarului

- ▣ Întrebarea seminarului
 - ▶ **cum estimăm ce nu putem observa (un nivel, un trend, o volatilitate, un output gap) și cum deosebim un semnal real de zgomotul estimatorului?**
- ▣ Rezultate de obținut
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ analiza cerută în **C1** și verdictele asupra răspunsului A1 din **C2**, fiecare cu un rând de justificare
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Exercițiile, tipurile și ordinea lor: harta exercițiilor (slide-ul următor)
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	filtrul Kalman difuz exact de mînă; verosimilitatea concentrată	Rezolvat, Propus	A1
A3, A4	un pas de eșantionare înapoi; blocul Gibbs invers gamma	Rezolvat, Propus	A3
A5, A6	momentele modelului SV; ecuația de măsurare QML	Rezolvat, Propus	A5
A7, A8	un pas al filtrului de particule bootstrap; ponderile auxiliare cu o valoare extremă	Rezolvat, Propus	A7
A9, A10	ciclul Beveridge–Nelson; local level, IMA(1,1) și BN	Rezolvat, Propus	A9
B1, B2	creșterea de trend a României; regresii TVP pentru Ungaria și Polonia	Rezolvat, Propus	B1
B3, B4	SV pentru EUR/RON: Gibbs, apoi filtrul de particule	Rezolvat, Propus	B3
B5	output gap-ul României în timp real	Propus	B1, A10
C1, C2	este ancorată inflația de trend din România?; ce este greșit într-un răspuns AI?	Propus	B3, A1–A10

- **[Rezolvat]**: rezolvarea completă este în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model, iar soluția se discută la seminar
- Partea A: calcule și derivări pe hîrtie; Partea B: date reale, rezolvate în notebook, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise, inclusiv critica unui răspuns AI

Datele folosite

Seria	Sursa	Frecvența	Perioada
România: PIB real (ajustat)	Eurostat namq_10_gdp	trimestrial	2000–2026
IAPC: România, Ungaria, Polonia, zona euro	Eurostat prc_hicp_minr	lunar	2001–2026
cursul de referință EUR/RON	BNR	zilnic	2016–2026

- În notebook: `kalman_filter`, `kalman_smoother`, `sim_smoother_dk`, `ffbs`, `sv_gibbs`, `pf_sv`, `fit_llt`, `fit_tvp`, `fit_smooth_trend`, `ucsv_gibbs`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/19): modelul în spațiul stărilor

- Modelul (TSA, Capitolul 10): observațiile sînt o funcție liniară cu zgomot a unei stări ascunse care urmează o dinamică liniară

$$y_t = Z_t \alpha_t + \varepsilon_t, \varepsilon_t \sim N(0, H); \quad \alpha_{t+1} = T \alpha_t + R \eta_t, \eta_t \sim N(0, Q)$$

- Notățiile

- y_t : observația; α_t : starea neobservată; Z_t : matricea de măsurare; T : matricea de tranziție; R : alege stările care primesc șocuri
- H : varianța zgomotului de măsurare ε_t ; Q : covarianța șocurilor stării η_t ; n : lungimea eșantionului


- Trei estimatii ale stării, $Y_t = (y_1, \dots, y_t)$

- prezisă $a_t = \mathbb{E}(\alpha_t | Y_{t-1})$, $P_t = \text{Var}(\alpha_t | Y_{t-1})$; filtrată $a_{t|t} = \mathbb{E}(\alpha_t | Y_t)$, $P_{t|t}$
- netezită $\hat{\alpha}_t = \mathbb{E}(\alpha_t | Y_n)$, $V_t = \text{Var}(\alpha_t | Y_n)$: folosește tot eșantionul

- Modelul local level: $Z = T = R = 1$, $y_t = \mu_t + \varepsilon_t$, $\mu_{t+1} = \mu_t + \eta_t$; raportul semnal-zgomot $q = \sigma_\eta^2 / \sigma_\varepsilon^2$

Noțiuni necesare azi (2/19): nivelul filtrat și nivelul netezit

Local level, $q = 0.1$



90% band of the smoothed level

observations y_t

true level μ_t

filtered $a_{t|t}$

smoothed $\hat{\alpha}_t$

- Local level simulat, $n = 100$, $\sigma_\epsilon^2 = 1$, $q = 0,1$
 - ▶ punctele: datele; linia punctată: nivelul adevărat μ_t
- Filtrat $a_{t|t}$ (roșu): folosește doar datele pînă la t
 - ▶ ceea ce știe un analist în timp real; reacționează tîrziu
- Netezit $\hat{\alpha}_t$ (albastru): folosește toate cele n observații
 - ▶ mai neted și mai apropiat de μ_t ; banda $\hat{\alpha}_t \pm 1,645\sqrt{V_t}$
 - ▶ la $t = n$ cele două coincid

Noțiuni necesare azi (3/19): filtrul Kalman

- ▣ Eroarea de predicție și varianța ei

$$v_t = y_t - Z_t a_t, \quad F_t = Z_t P_t Z_t' + H$$

- ▶ v_t : informația nouă din y_t (inovația), independentă de Y_{t-1}

- ▣ Actualizarea și predicția, cu câștigul Kalman $K_t = T P_t Z_t' F_t^{-1}$

$$a_{t|t} = a_t + P_t Z_t' F_t^{-1} v_t, \quad a_{t+1} = T a_t + K_t v_t, \quad P_{t+1} = T P_t (T - K_t Z_t)' + R Q R'$$


- ▶ K_t : cât din surpriza v_t mută predicția stării următoare; mare când P_t este mare față de H
- ▶ local level: $a_{t+1} = a_t + k_t v_t$, $k_t = P_t / (P_t + \sigma_\varepsilon^2)$: o medie a datelor cu ponderi exponențiale

- ▣ Log-verosimilitatea prin descompunerea erorilor de predicție, un produs secundar al filtrului

$$\ln L = -\frac{1}{2} \sum_{t=1}^n (\ln 2\pi + \ln F_t + v_t^2 / F_t)$$

- ▶ se maximizează numeric după varianțele din H și Q

Noțiuni necesare azi (4/19): câștigul și netezirea



- Local level, în unități σ_ε^2 : $P_{t+1} = P_t - P_t^2/(P_t + 1) + q$
 - ▶ P_t și k_t converg după câțiva pași (liniile punctate): starea staționară
 - ▶ un q mai mare: un câștig mai mare, nivelul urmează îndeaproape datele

- Netezirea, înapoi de la $t = n$

$$\hat{\alpha}_t = a_{t|t} + G_t(\hat{\alpha}_{t+1} - T a_{t|t})$$

- ▶ $G_t = P_{t|t} T' P_{t+1}^{-1}$: cât ne spune starea următoare despre cea curentă
- ▶ $V_t = P_{t|t} + G_t(V_{t+1} - P_{t+1})G_t'$

Noțiuni necesare azi (5/19): startul difuz exact

- ▣ Stările nestaționare (măsurări aleatoare) nu au varianță staționară

$$P_1 = \kappa P_\infty + P_*, \quad \kappa \rightarrow \infty$$

- ▶ P_∞ : marchează elementele difuze; P_* : covarianța celorlalte; $F_{\infty,t} = Z_t P_{\infty,t} Z_t'$ și $F_{*,t}$: părțile difuză și finită ale lui F_t

- ▣ Cît timp $F_{\infty,t} > 0$, două câștiguri [Koopman \(1997\)](#)


$$K^{(0)} = TP_\infty Z' / F_\infty, \quad K^{(1)} = T(P_* Z' - P_\infty Z' F_* / F_\infty) / F_\infty$$

- ▶ $a_{t+1} = Ta_t + K^{(0)} v_t$, $P_{\infty,t+1} = TP_\infty L^{(0)'} + TP_* L^{(0)'} + RQR'$
- ▶ $L^{(0)} = T - K^{(0)} Z$, $L^{(1)} = -K^{(1)} Z$; după d pași difuzi $P_\infty = 0$ și preia filtrul obișnuit

- ▣ Log-verosimilitatea difuză: un pas difuz contribuie cu $-\frac{1}{2}(\ln 2\pi + \ln F_{\infty,t})$, ceilalți cu termenul obișnuit


- ▶ scala eliminată prin concentrare: dacă H , Q sînt proporționale cu σ^2 , $\hat{\sigma}^2 = \frac{1}{n-d} \sum_{t>d} v_t^2 / F_t^*$, $F_t^* = F_t / \sigma^2$

Noțiuni necesare azi (6/19): un κ mare față de startul difuz exact



- Local level simulat, $n = 80$, $q = 0,5$
 - ▶ roșu: $a_1 = 0$, $P_1 = \kappa$ și toți cei n termeni ai lui $\ln L$
- Primul termen conține $-\frac{1}{2} \ln(\kappa + \sigma_\varepsilon^2)$
 - ▶ $\ln L \rightarrow -\infty$ când κ crește; cresc și erorile de rotunjire
 - ▶ adunînd la loc $\frac{1}{2} \ln \kappa$ (verde) obținem valoarea difuză exactă (albastru)
- Folosiți filtrul difuz exact și eliminați cei d termeni difuzi

Noțiuni necesare azi (7/19): eșantionarea stărilor



- FFBS [Carter și Kohn \(1994\)](#): filtrare înainte, eșantionare înapoi

- ▶ extragem $\alpha_n \sim N(a_{n|n}, P_{n|n})$
- ▶ apoi, pentru $t = n - 1, \dots, 1$: $\alpha_t | \alpha_{t+1} \sim N(m_t, S_t)$

$$m_t = a_{t|t} + G_t(\alpha_{t+1} - Ta_{t|t}), \quad S_t = P_{t|t} - G_tTP_{t|t}$$

- ▶ $G_t = P_{t|t}T'(TP_{t|t}T' + RQR')^{-1}$

- Durbin–Koopman [Durbin și Koopman \(2002\)](#): simulăm (α^+, y^+) , netezim o singură dată

$$\tilde{\alpha} = \alpha^+ + \hat{\alpha}(y) - \hat{\alpha}(y^+)$$

- ▶ $\hat{\alpha}(\cdot)$: media netezită; $\tilde{\alpha}$: o extragere exactă a întregii traiectorii

- Graficul: extragerile se dispersează în jurul lui $\hat{\alpha}_t$; media lor este $\hat{\alpha}_t$

Noțiuni necesare azi (8/19): blocurile Gibbs pentru varianțe

- ▣ Distribuția invers gamma $IG(a, b)$: $\sigma^2 \sim IG(a, b)$ dacă $1/\sigma^2 \sim \text{Gamma}$ cu forma a și rata b


$$p(\sigma^2) \propto (\sigma^2)^{-a-1} e^{-b/\sigma^2}, \quad \mathbb{E}\sigma^2 = \frac{b}{a-1} \quad (a > 1)$$

- ▶ a : forma; b : scala lui σ^2 (rata lui $1/\sigma^2$); densitatea este zero în $\sigma^2 = 0$
- ▣ Blocul Gibbs: a priori $IG(a_0, b_0)$, m șocuri e_t implicate de extragerea curentă a stării

$$\sigma^2 \mid e \sim IG\left(a_0 + \frac{m}{2}, b_0 + \frac{1}{2} \sum_t e_t^2\right)$$

- ▶ local level: $e_t = y_t - \mu_t$ pentru σ_ε^2 ($m = n$), $e_t = \Delta\mu_t$ pentru σ_η^2 ($m = n - 1$)
- ▶ eşantionatorul alternează: stările date fiind varianțele (FFBS), varianțele date fiind stările
- ▣ Factorul de ineficiență $1 + 2 \sum_{k \geq 1} \rho_k$
 - ▶ ρ_k : autocorelația lanțului la lagul k ; numărul de extrageri corelate care valorează cît o extragere independentă

Noțiuni necesare azi (9/19): varianțe la frontieră



- Pile-up [Shephard și Harvey \(1990\)](#): estimația ML a unei varianțe poate fi exact 0
 - ▶ 500 de eșantioane local level, $n = 100$, q adevărat = 0,005
 - ▶ 22% dintre estimații sînt exact $\hat{q} = 0$
- Testul LR pentru $\sigma_\eta^2 = 0$: ipoteza nulă este pe frontieră
 - ▶ $LR = 2(\ln L_1 - \ln L_0) \geq 0$; χ_1^2 standard este greșit
 - ▶ regula practică: $p = \frac{1}{2}P(\chi_1^2 > LR)$ (mixture $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$)
 - ▶ alternative de tip mers aleator: nestandard; folosiți un bootstrap parametric

Noțiuni necesare azi (10/19): trenduri locale și coeficienți variabili în timp

▣ Local linear trend

$$y_t = \mu_t + \varepsilon_t, \quad \mu_{t+1} = \mu_t + \nu_t + \xi_t, \quad \nu_{t+1} = \nu_t + \zeta_t$$

- ▶ ν_t : panta; ξ_t, ζ_t : șocurile nivelului și ale pantei, cu varianțele $\sigma_\xi^2, \sigma_\zeta^2$; două stări difuze
- ▶ $y_t = 100 \ln$ al unei serii trimestriale: $4\nu_t$ este creșterea de trend anualizată, în %

▣ Regresia TVP (cu parametri variabili în timp)

$$y_t = c_t + b_t x_t + D_t' \gamma + \varepsilon_t, \quad c_{t+1} = c_t + \eta_t^c, \quad b_{t+1} = b_t + \eta_t^b$$

- ▶ starea $\alpha_t = (c_t, b_t, \gamma')'$, $Z_t = (1, x_t, D_t')$; D_t : variabile dummy sezoniere, γ : stări constante
- ▶ $\sigma_b^2 = \text{Var}(\eta_t^b) = 0$: pantă constantă; b_t netezit arată când s-a schimbat legătura

Noțiuni necesare azi (11/19): volatilitatea stochastică

- Modelul SV: logaritmul varianței este un AR(1) latent, cu propriul șoc

$$y_t = e^{h_t/2} \epsilon_t, \quad h_t = \mu + \phi(h_{t-1} - \mu) + \sigma_\eta \eta_t, \quad \epsilon_t, \eta_t \sim N(0, 1)$$

- h_t : logaritmul varianței; μ : media lui; ϕ : persistența; σ_η : volatilitatea volatilității
- timpul de înjumătățire al unui șoc asupra lui h_t : $\ln 0,5 / \ln \phi$ perioade

- Momentele, cu $\sigma_h^2 = \sigma_\eta^2 / (1 - \phi^2)$ varianța lui h_t


$$\text{kurtosis} = 3e^{\sigma_h^2}, \quad \text{Corr}(y_t^2, y_{t-k}^2) = \frac{e^{\sigma_h^2 \phi^k} - 1}{3e^{\sigma_h^2} - 1}$$

- kurtosis peste 3 și autocorelație pozitivă, cu scădere lentă, a lui y_t^2 : volatility clustering

- GARCH(1,1) [Bollerslev \(1986\)](#), pentru comparație: $\sigma_t^2 = \omega + \alpha y_{t-1}^2 + \beta \sigma_{t-1}^2$


- varianța este cunoscută cu un pas înainte; în SV are propriul șoc, deci verosimilitatea este o integrală după $h_{1:n}$

Noțiuni necesare azi (12/19): o traiectorie SV simulată



- $\phi = 0,95, \sigma_\eta = 0,25$: $\sigma_h^2 = 0,0625/0,0975 = 0,64$, kurtosis $3e^{0,64} = 5,7$, timpul de înjumătățire $\ln 0,5 / \ln 0,95 = 13,5$ perioade
- Stînga: perioade calme și agitate în banda $\pm 2e^{h_t/2}$; dreapta: ACF-ul lui y_t^2 pornește de jos (0,18) și scade ca ϕ^k

Noțiuni necesare azi (13/19): modelul SV liniarizat



- Ridicăm la pătrat și logaritmăm

$$\ln y_t^2 = h_t + \xi_t, \quad \xi_t = \ln \varepsilon_t^2$$

- ▶ $\mathbb{E}\xi_t = -1,2704$, $\text{Var}\xi_t = \pi^2/2 = 4,93$
- ▶ liniar în h_t : un model în spațiul stărilor

- QML Harvey, Ruiz și Shephard (1994): filtrul Kalman ca și cum ξ_t ar fi normal

- ▶ cel mai bun predictor liniar, dar ξ_t este asimetric (graficul)

- KSC Kim, Shephard și Chib (1998): o mixtură de șapte distribuții Normale

$$p(\xi_t) \approx \sum_{j=1}^7 q_j N(\xi_t; m_j, v_j)$$

- ▶ q_j , m_j , v_j : ponderi, medii și varianțe fixe
- ▶ dată componenta s_t , h este gaussian: se aplică FFBS

Noțiuni necesare azi (14/19): filtrele de particule


- ▣ Filtrul de particule bootstrap [Gordon, Salmond și Smith \(1993\)](#): N particule $x_t^{(i)}$ aproximează distribuția stării
 - ▶ propagăm $x_t^{(i)} \sim f(\cdot | x_{t-1}^{(i)})$ (f : densitatea de tranziție); ponderăm $w^{(i)} = g(y_t | x_t^{(i)})$ (g : densitatea de măsurare)
 - ▶ ponderile normalizate $W^{(i)} = w^{(i)} / \sum_j w^{(j)}$; apoi reeșantionăm

- ▣ Estimația verosimilității și mărimea efectivă a eșantionului

$$\hat{p}(y_t | Y_{t-1}) = \frac{1}{N} \sum_{i=1}^N w^{(i)}, \quad \hat{L} = \prod_{t=1}^n \hat{p}(y_t | Y_{t-1}), \quad \text{ESS}_t = \frac{1}{\sum_i (W^{(i)})^2}$$

- ▶ $\hat{L}$ este nedeplasat: $\mathbb{E}\hat{L} = L$; din inegalitatea lui Jensen, $\mathbb{E} \ln \hat{L} < \ln L$: logaritmul este deplasat în jos
- ▶ ESS_t între 1 și N ; o prăbușire la câteva particule: modelul sau propunerea eșuează la momentul t
- ▣ Reeșantionarea sistematică: o singură variabilă uniformă U , $u_i = (U + i - 1)/N$
 - ▶ particula j este copiată o dată pentru fiecare $u_i \in (C_{j-1}, C_j]$; $C_j = \sum_{l \leq j} W^{(l)}$: ponderile cumulate

Noțiuni necesare azi (15/19): un pas al filtrului de particule



□ Modelul SV, 20 de particule $h_t^{(i)}$, observația $y_t = 2,0$

- ▶ $w^{(i)} = N(y_t; 0, e^{h_t^{(i)}})$: un $|y_t|$ mare favorizează particulele cu volatilitate mare
- ▶ ESS = 12,3 din 20


□ Reesantionarea sistematică (jos)

- ▶ particulele cu volatilitate mică dispar, cele cu volatilitate mare sînt copiate de două ori
- ▶ supraviețuiesc 13 particule distincte

□ Filtrul auxiliar (APF) **Pitt și Shephard (1999)**: privește y_t înainte de propagare

- ▶ ponderi în prima etapă $\propto g(y_t | \mu_t^{(i)})$,
 $\mu_t^{(i)} = \mathbb{E}(x_t | x_{t-1}^{(i)})$
- ▶ apoi propagăm și corectăm ponderile

Noțiuni necesare azi (16/19): descompunerea Beveridge–Nelson



- Trendul BN **Beveridge și Nelson (1981)**: nivelul după stingerea creșterii previzibile

$$\tau_t = y_t + \sum_{j \geq 1} \mathbb{E}_t(\Delta y_{t+j} - \mu)$$

- ▶ μ : creșterea medie; $\mathbb{E}_t$: speranța dat fiind datele pînă la t

- Creștere AR(1): $\Delta y_t - \mu = \phi(\Delta y_{t-1} - \mu) + e_t$

- ▶ ciclul $c_t = y_t - \tau_t = -\frac{\phi}{1-\phi}(\Delta y_t - \mu)$

- ▶ graficul, $\phi = 0,5$: $c_t = -(\Delta y_t - \mu)$, zgomotos, mic

- Local level: $\Delta y_t = u_t + \theta u_{t-1}$, un IMA(1,1)

- ▶ u_t : zgomot alb; $\theta = -(1 + q/2) + \sqrt{q + q^2/4}$

Noțiuni necesare azi (17/19): output gap-ul în timp real

- Modelul UC (componente neobservate) cu trend neted și ciclu AR(2)


$$y_t = \tau_t + c_t, \quad \Delta^2 \tau_{t+1} = \zeta_t, \quad c_t = \phi_1 c_{t-1} + \phi_2 c_{t-2} + \kappa_t$$

- τ_t : producția potențială; c_t : output gap-ul; ζ_t, κ_t : șocuri independente; Δ^2 : a doua diferență
- output gap-ul în timp real: $c_{t|t}$ filtrat din datele până la t ; output gap-ul final: $\hat{c}_t$ netezit

- Statisticile Orphanides–van Norden [Orphanides și van Norden \(2002\)](#), revizuirea $r_t = c_{t|t} - \hat{c}_t$

- $\text{Corr}(c_{t|t}, \hat{c}_t)$; raportul zgomot–semnal $\text{sd}(r_t)/\text{sd}(\hat{c}_t)$, în jur de 1 sau peste: nefiabil
- proporția semnelor opuse: $\frac{1}{n} \sum_t 1\{\text{sign}(c_{t|t}) \neq \text{sign}(\hat{c}_t)\}$

Noțiuni necesare azi (18/19): output gap-ul în timp real față de cel final



- Trend neted plus ciclu AR(2) simulate ($\phi_1 = 1,4$, $\phi_2 = -0,5$), parametri adevărați cunoscuți: acționează doar problema capătului de eșantion
- Output gap-ul filtrat este mai plat și adesea de semn greșit: corelația 0,44, raportul zgomot–semnal 0,91, semne opuse în 36% dintre trimestre

Noțiuni necesare azi (19/19): inflația de trend: UC-SV

- UC-SV Stock și Watson (2007): inflația = trend + zgomot tranzitoriu, ambele cu volatilitate stochastică

$$\pi_t = \tau_t + \sigma_{\eta,t}\eta_t, \quad \tau_t = \tau_{t-1} + \sigma_{\varepsilon,t}\varepsilon_t$$

- ▶ $\eta_t, \varepsilon_t \sim N(0, 1)$, independente; τ_t : inflația de trend
- ▶ $\ln \sigma_{\eta,t}^2 = \ln \sigma_{\eta,t-1}^2 + \nu_{\eta,t}$, $\ln \sigma_{\varepsilon,t}^2 = \ln \sigma_{\varepsilon,t-1}^2 + \nu_{\varepsilon,t}$, cu $\text{Var}\nu = \gamma$
- ▶ γ : netezimea volatilităților, fixată dinainte (0,2 la Stock–Watson)
- Estimarea prin Gibbs: FFBS pentru τ ; pași KSC pentru cei doi logaritmi ai volatilităților
 - ▶ probabilitatea a posteriori a unui eveniment din cele M extrageri $\tau_t^{(m)}$:

$$P(1,5 \leq \tau_t \leq 3,5 \mid Y_n) \approx \frac{1}{M} \sum_m 1\{1,5 \leq \tau_t^{(m)} \leq 3,5\}$$
 - ▶ o bandă de 68%: percentilele 16 și 84 ale extragerilor

A1: filtrul difuz exact de mînă [Rezolvat]

Cerință

- Local level, $\sigma_\varepsilon^2 = 1$, $\sigma_\eta^2 = 0,5$, μ_1 difuz ($a_1 = 0$, $P_{\infty,1} = 1$, $P_{*,1} = 0$); datele $y = (2,0; 3,0; 2,5)$.
- 1. Efectuați pasul difuz la $t = 1$: dați F_∞ , $K^{(0)}$, $K^{(1)}$, a_2 , $P_{\infty,2}$, $P_{*,2}$.
- 2. Rulați filtrul obișnuit pentru $t = 2, 3$: v_t , F_t , K_t , a_{t+1} , P_{t+1} .
- 3. Calculați log-verosimilitatea difuză și explicați de ce y_1 nu aduce informație despre varianțe.
- Raportați: un pas difuz, doi pași obișnuiți, o cifră, o frază.

Rezolvare

- 1. $F_\infty = 1$, $F_* = 0 + 1 = 1$; $K^{(0)} = 1$, $K^{(1)} = 0 - 1 \cdot 1/1 = -1$;
 $a_2 = 0 + 1 \cdot 2 = 2,000$; $P_{\infty,2} = 1(1 - 1) = 0$;
 $P_{*,2} = 1 \cdot 1 + 0 + 0,5 = 1,500$
- 2. $t = 2$: $v = 1,000$, $F = 2,500$, $K = 0,600$, $a_3 = 2,600$,
 $P_3 = 1,5(1 - 0,6) + 0,5 = 1,100$; $t = 3$: $v = -0,100$,
 $F = 2,100$, $K = 0,524$, $a_4 = 2,548$, $P_4 = 1,024$
- 3. Termenii $-0,919$; $-1,577$; $-1,292$; $\ln L_d = -3,788$. Primul termen este $-\frac{1}{2} \ln 2\pi$ oricare ar fi varianțele: y_1 doar fixează nivelul

A2: verosimilitatea concentrată [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Datele din A1, acum cu $\sigma_\eta^2 = 0,5\sigma_\varepsilon^2$ și σ_ε^2 necunoscut. Model: A1.
- ▣ 1. Rulați filtrul cu $\sigma_\varepsilon^2 = 1$ și scrieți $F_t = \sigma_\varepsilon^2 F_t^*$.
- ▣ 2. Derivați $\hat{\sigma}_\varepsilon^2$ prin maximizarea log-verosimilității difuze și calculați-l.
- ▣ 3. Calculați log-verosimilitatea concentrată (fără termenul difuz) și precizați câți parametri rămîn pentru căutarea numerică.
- ▣ Raportați: două rapoarte, o estimatie, o cifră, o frază.



A3: un pas de eșantionare înapoi [Rezolvat]

Cerință

- Continuăm A1: după y_2 momentele filtrate sînt $a_{2|2}$, $P_{2|2}$; presupunem că extragerea pentru perioada următoare este $\alpha_3 = 3,0$.
- 1. Calculați $a_{2|2}$ și $P_{2|2}$ din A1.
- 2. Calculați G_2 , media condiționată m_2 și varianța S_2 pentru $\alpha_2|\alpha_3, y_1, y_2$.
- 3. Explicați de ce y_3 nu este necesar în această distribuție condiționată.
- Raportați: două momente, trei cifre, o frază.

Rezolvare

- 1. $a_{2|2} = 2 + 0,6 \cdot 1 = 2,600$, $P_{2|2} = 1,5 - 1,5^2/2,5 = 0,600$
- 2. $G_2 = P_{2|2}/(P_{2|2} + \sigma_\eta^2) = 0,545$;
 $m_2 = 2,600 + 0,545(3,0 - 2,600) = 2,818$;
 $S_2 = P_{2|2}(1 - G_2) = 0,273$
- 3. Proprietatea Markov: dat α_3 , observațiile viitoare nu mai adaugă nimic despre α_2 ; informația lor a intrat deja prin extragerea lui α_3

A4: blocul Gibbs invers gamma [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Un eșantionator Gibbs pentru local level, $n = 50$; extragerea curentă a stării dă $\sum_t (y_t - \mu_t)^2 = 40$ și $\sum_t (\Delta \mu_t)^2 = 6,2$; a priori $IG(2,5; 0,25)$ pentru ambele varianțe. Model: A3.
- ▣ 1. Scrieți cele două distribuții a posteriori condiționate, cu parametrii lor.
- ▣ 2. Calculați mediile lor și raportul q implicat.
- ▣ 3. Explicați de ce acest eșantionator nu poate da niciodată $\sigma_\eta^2 = 0$, spre deosebire de ML.
- ▣ Raportați: două distribuții, trei cifre, o frază.

A5: momentele modelului SV [Rezolvat]

Cerință

- ▣ Modelul SV cu $\phi = 0,98$, $\sigma_\eta = 0,15$, ϵ_t gaussian.
- ▣ 1. Calculați σ_h^2 și kurtosis-ul lui y_t .
- ▣ 2. Calculați $\text{Corr}(y_t^2, y_{t-k}^2)$ pentru $k = 1, 10, 50$ și timpul de înjumătățire al unui șoc de volatilitate.
- ▣ 3. Explicați diferența față de un GARCH(1,1) cu aceeași persistență.
- ▣ Raportați: două cifre, patru cifre, o frază.

Rezolvare

- ▣ 1. $\sigma_h^2 = 0,0225/0,0396 = 0,568$; kurtosis-ul $3e^{0,568} = 5,30$
- ▣ 2. 0,173; 0,138; 0,054: scădere lentă de la un nivel inițial mic; timpul de înjumătățire $\ln 0,5 / \ln 0,98 = 34,3$ zile
- ▣ 3. Varianța GARCH este cunoscută cu un pas înainte; în SV are propriul șoc, deci excesul de kurtosis apare chiar cu ϕ apropiat de 1, iar verosimilitatea cere o integrală



A6: ecuația de măsurare QML [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul SV din A5, scris ca $\ln y_t^2 = h_t + \xi_t$. Model: A5.
- ▣ 1. Dați media și varianța lui ξ_t și raportul semnal-zgomot $\sigma_h^2 / \text{Var} \xi_t$.
- ▣ 2. Calculați $\text{Corr}(\ln y_t^2, \ln y_{t-k}^2)$ pentru $k = 1, 10$ și numiți modelul ARMA pentru $\ln y_t^2$.
- ▣ 3. Explicați de ce filtrul Kalman aplicat lui $\ln y_t^2$ este consistent, dar ineficient.
- ▣ Raportați: trei cifre, două cifre și un model, o frază.



A7: un pas al filtrului de particule bootstrap [Rezolvat]

Cerință

- ▣ Modelul SV, $N = 4$ particule după propagare:
 $h^{(i)} = (-1; 0; 0,5; 1,5)$; observația $y_t = 2,0$; reeșantionare sistematică cu $U = 0,3$.
- ▣ 1. Calculați $w^{(i)} = N(y_t; 0, e^{h^{(i)}})$ și ponderile normalizate.
- ▣ 2. Calculați ESS și incrementul de verosimilitate $\hat{p}(y_t | Y_{t-1})$.
- ▣ 3. Reeșantionați: ce particule supraviețuiesc și de cîte ori?
- ▣ Raportați: opt cifre, două cifre, o listă.

Rezolvare

- ▣ 1. $w = (0,0029; 0,0540; 0,0924; 0,1206)$;
 $W = (0,011; 0,200; 0,342; 0,447)$
- ▣ 2. $ESS = 2,80$ din 4; $\hat{p} = \frac{1}{4} \sum w = 0,0675$, $\ln \hat{p} = -2,696$
- ▣ 3. $u = (0,075; 0,325; 0,575; 0,825)$ față de
 $C = (0,011; 0,211; 0,553; 1)$: particulele 2, 3, 4, 4; particula cu volatilitate mică dispare, cea cu volatilitate mare este copiată de două ori

A8: ponderi auxiliare cu o valoare extremă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Local level, $\sigma_\varepsilon^2 = 0,5$, $\sigma_\eta^2 = 0,25$; particule cu ponderi egale $x_{t-1}^{(i)} = (0; 1; 2; 3)$; valoarea extremă $y_t = 4,0$. Model: A7.
- ▣ 1. Calculați ponderile normalizate din prima etapă $\propto N(y_t; x_{t-1}^{(i)}, \sigma_\varepsilon^2)$ și ESS-ul lor.
- ▣ 2. Calculați ponderile complet adaptate $\propto N(y_t; x_{t-1}^{(i)}, \sigma_\varepsilon^2 + \sigma_\eta^2)$ și comparați.
- ▣ 3. Explicați ce ar face filtrul bootstrap cu aceeași valoare extremă.
- ▣ Raportați: patru ponderi și un ESS, patru ponderi, o frază.

A9: ciclul Beveridge–Nelson al unui ARIMA(1,1,0) [Rezolvat]

Cerință

- ▣ Creșterea trimestrială: $\Delta y_t - 0,8 = 0,35(\Delta y_{t-1} - 0,8) + e_t$; în acest trimestru $\Delta y_t = 2,0$.
- ▣ 1. Derivați $\sum_{j \geq 1} \mathbb{E}_t(\Delta y_{t+j} - \mu)$ pentru un AR(1).
- ▣ 2. Calculați ciclul BN c_t și multiplicatorul pe termen lung al lui e_t asupra trendului.
- ▣ 3. Explicați semnul ciclului după un trimestru puternic.
- ▣ Raportați: o formulă, două cifre, o frază.

Rezolvare

- ▣ 1. $\mathbb{E}_t(\Delta y_{t+j} - \mu) = \phi^j(\Delta y_t - \mu)$, suma = $\frac{\phi}{1-\phi}(\Delta y_t - \mu)$
- ▣ 2. $\frac{\phi}{1-\phi} = 0,538$; $c_t = -0,538 \cdot 1,2 = -0,646$; multiplicatorul $1/(1-\phi) = 1,538$
- ▣ 3. Cu persistență pozitivă a creșterii, un trimestru puternic ridică creșterea viitoare așteptată: trendul sare mai mult decît producția, deci producția este *sub* trend



A10: local level, IMA(1,1) și Beveridge–Nelson [Propus]

Rezolvarea se discută la seminar

Cerință


- ▣ Local level cu $\sigma_\varepsilon^2 = 1$, $q = 0,5$. Model: A9.
- ▣ 1. Găsiți coeficientul MA θ al lui Δy_t .
- ▣ 2. Rezolvați ecuația Riccati staționară $P = P - P^2/(P + 1) + q$ și dați câștigul $k = P/(P + 1)$.
- ▣ 3. Arătați că trendul BN al IMA(1,1), $y_t + \theta u_t$, este egal cu nivelul filtrat staționar $a_t|_t$.
- ▣ Raportați: o cifră, două cifre, o derivare.



B1: creșterea de trend a României [Rezolvat]

- ▣ **Întrebarea:** a scăzut creșterea de trend a României față de anii 2000, dacă ținem cont de incertitudinea estimației?
- ▣ **Date:** $100 \times \log$ PIB real (Eurostat, ajustat), T1 2000–T2 2026, $T = 106$; T2–T4 2020 tratate ca lipsă
- ▣ **Cerințe**
 1. Estimați modelul local linear trend prin ML difuz exact cu filtrul numpy și cu statsmodels; comparați parametrii și log-verosimilitățile.
 2. Neteziți panta și raportați creșterea de trend anualizată $4\hat{\nu}_t$ cu bandă de 90% în 2005, 2012, 2019 și în ultimul trimestru.
 3. Verificați dacă vreo varianță se află la frontieră.
 4. Interpretare: este semnificativă statistic scăderea creșterii de trend?
- ▣ **Raportați:** două seturi de parametri, patru rate de creștere cu benzi, o frază
- ▣ Notebook: secțiunea [B1](#)

B1: rezolvare [Rezolvat]



- numpy: $\sigma_\varepsilon^2 = 0,6013$, $\sigma_\xi^2 = 3,9577$, $\sigma_\zeta^2 = 0,0039$, $\ln L_d = -231,08$; statsmodels: 0,6011; 3,9581; 0,0039; $-229,24$ (diferența în $\ln L$ este $\ln 2\pi$, doi pași difuzi)
- Creșterea de trend: 4,1% (abatere standard 1,1) în 2005, 3,1% (1,0) în 2012, 2,8% (1,1) în 2019, 2,2% (1,4) la final
- Interpretare: o scădere este sugerată, dar nu demonstrată
 - ▶ varianța pantei este mică, deci creșterea de trend se mișcă lent
 - ▶ benzile se suprapun mult; șocurile de nivel absorb recesiunea din 2009


B2: regresii TVP pentru Ungaria și Polonia [Propus]

- **Întrebarea:** s-a schimbat în timp co-mișcarea inflației din Ungaria și Polonia cu inflația din zona euro?
- **Date:** inflația IAPC trimestrială (% anualizat), din T4 2005; inflația din zona euro fără componenta sezonieră; regresia TVP de pe slide-ul [Trenduri locale și coeficienți variabili în timp](#); model: [B1](#)
- **Cerințe**
 1. Estimați regresia TVP prin ML difuz exact (cinci stări difuze) pentru fiecare țară.
 2. Raportați $\hat{\sigma}_b^2$ și b_t netezit, cu erori standard, în T3 2008, T4 2019 și T4 2022.
 3. Calculați testul LR pentru $\sigma_b^2 = 0$ și p-value-ul după regula $\frac{1}{2}\chi_1^2$; spuneți de ce acest p-value este doar orientativ.
 4. Interpretare: este panta mai mare decât unu, iar co-mișcarea este stabilă sau episodică?
- **Raportați:** un tabel cu două rînduri, șase pante cu erori standard, două teste, o frază
- **Notebook:** secțiunea [B2](#)

B3: volatilitatea stochastică a cursului EUR/RON [Rezolvat]

- ▣ **Întrebarea:** cât de persistentă este volatilitatea leului față de euro și cum se compară SV cu GARCH?
- ▣ **Date:** randamentele logaritmice zilnice ale cursului de referință BNR EUR/RON, %, centrate, 2016–2026, $T = 2686$; eșantionatorul Gibbs KSC cu $c = 10^{-3}\text{Var}(y)$
- ▣ **Cerințe**
 1. Rulați eșantionatorul Gibbs KSC și raportați mediile a posteriori și intervalele de 90% pentru μ, ϕ, σ_η , cu factorii de ineficiență.
 2. Estimați un GARCH(1,1) gaussian pe aceleași date.
 3. Reprezentați grafic media a posteriori a lui $\exp(h_t/2)$ față de volatilitatea GARCH.
 4. Interpretare: ce spune timpul de înjumătățire al volatilității despre un curs de schimb în regim de managed float?
- ▣ **Raportați:** un tabel cu trei parametri, trei cifre GARCH, un grafic, o frază
- ▣ Notebook: secțiunea [B3](#)

B3: rezolvare [Rezolvat]



- $\phi = 0,957$ [0,944; 0,969], $\sigma_\eta = 0,541$ [0,488; 0,597], $\mu = -5,628$ [-6,032; -5,210]; factorii de ineficiență 18, 42, 1 (20 000 de extrageri)
- GARCH(1,1): $\alpha = 0,225$, $\beta = 0,753$; abaterea standard zilnică 0,121%, kurtosis-ul 27,8
- Interpretare: timpul de înjumătățire al unui șoc al logaritmului volatilității este de aproximativ 16 zile
 - perioadele liniștite cu episoade rare de agitație sînt specifice unui regim de managed float
 - kurtosis-ul mare arată că ϵ_t gaussian nu este suficient (B4)

B4: filtrul de particule pentru modelul SV al cursului EUR/RON [Propus]

- **Întrebarea:** este SV mai bun decât GARCH pentru EUR/RON pe scala verosimilității și este fiabilă aici verosimilitatea din filtrul de particule?
- **Date:** datele și mediile a posteriori din B3; filtrul de particule bootstrap cu reeșantionare sistematică; model: B3 și A7
- **Cerințe**
 1. Rulați filtrul cu $N = 500, 2000, 10\,000$ de particule, de câte 30 de ori, și raportați abaterea standard a lui $\ln \hat{L}$.
 2. Raportați ESS minim și median și data minimului.
 3. Comparați $\ln \hat{L}$ (pentru N mare) cu maximul GARCH.
 4. Interpretare: ce vă spune prăbușirea ESS despre model?
- **Raportați:** trei abateri standard, două valori ESS și o dată, două log-verosimilități, o frază
- Notebook: secțiunea B4



B5: output gap-ul României în timp real [Propus]

- **Întrebarea:** cât se schimbă estimația output gap-ului României de la finalul eșantionului când sosesc date noi?
- **Date:** datele din [B1](#); UC cu trend neted și ciclu AR(2) (`fit_smooth_trend`); cvasi-timp real: reestimați pe datele pînă la fiecare trimestru din T4 2012 (parametrii la fiecare 4 trimestre) și păstrați output gap-ul filtrat; model: [B1](#) și [A10](#)
- **Cerințe**
 1. Calculați seria output gap-urilor în timp real (filtrate, la finalul eșantionului) și output gap-ul final netezit.
 2. Calculați statisticile Orphanides–van Norden: corelația, raportul zgomot–semnal (abaterea standard a revizuirilor împărțită la abaterea standard a output gap-ului final), proporția semnelor opuse.
 3. Raportați cea mai mare revizuire.
 4. Interpretare: se poate baza politica monetară pe estimația curentă a output gap-ului?
- **Raportați:** patru statistici, o cifră, o frază
- Notebook: secțiunea [B5](#)



C1: este ancorată inflația de trend din România? [Propus]

- ▣ **Întrebarea:** se află trendul inflației din România în banda-țintă a BNR ($2,5\% \pm 1$ pp) și cât de robust este răspunsul?
- ▣ **Date:** inflația IAPC trimestrială (% anualizat); UC-SV Stock și Watson (2007) cu variabile dummy sezoniere trimestriale (ucsv_gibbs); model: [B3](#)
- ▣ **Cerințe**
 1. Scrieți o preînregistrare de cinci rînduri: ipoteza, datele, statistica de ancorare, grila de robustețe, ce ar infirma afirmația.
 2. Estimați modelul pentru datele de început 2001 și 2006 și pentru $\gamma = 0,1$ și $0,2$; raportați trendul din ultimul trimestru cu bandă de 68%.
 3. Calculați probabilitatea a posteriori ca trendul să se afle în intervalul 1,5–3,5% în ultimul trimestru și în T4 2019.
 4. Interpretare: ce se poate și ce nu se poate concluziona și cum ați transforma acest lucru într-un proiect?
- ▣ **Raportați:** un plan de cinci rînduri, un tabel cu patru rînduri, un plan de proiect
- ▣ **Notebook:** secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre estimarea modelelor în spațiul stărilor. Răspunsul:
- (a) Filtrul Kalman este inutil dacă erorile nu sînt gaussiene.
- (b) Pentru o stare de tip mers aleator, puneți $P_1 = 10^{-10}$ și păstrați toți cei n termeni ai verosimilității.
- (c) O estimăție ML egală cu zero a varianței nivelului demonstrează că nivelul este constant.
- (d) SV și GARCH sînt același model, pentru că ambele fac volatilitatea persistentă.
- (e) Verosimilitatea din filtrul de particule este nedeplasată, deci și logaritmul ei este nedeplasat.
- (f) Simulation smoother-ul Durbin-Koopman are nevoie de o singură trecere a netezitorului stărilor pentru fiecare extragere.
- (g) Cu un ciclu AR(1), corelația dintre șocurile trendului și ale ciclului poate fi estimată.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați o cifră din cerințele de azi (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de șapte verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Filtrul difuz exact lasă primele observații să fixeze stările nestaționare; ele nu aduc informație despre varianțe
- ▣ Eșantionarea stărilor înseamnă mecanismul Kalman rulat înapoi (FFBS) sau încă o dată pe date simulate (DK)
- ▣ SV adaugă un șoc varianței; filtrele de particule îi estimează verosimilitatea, nedeplasată doar în nivel
- ▣ Creșterea de trend, output gap-urile și trendurile ancorate sînt estimații cu benzi largi: raportați-le și raportați valorile în timp real
- ▣ Un răspuns AI este o ciornă: verificați inițializarea, frontiera, deplasarea log-verosimilității și identificarea

După seminar

- ▣ Cursul 6 dezvoltă fiecare temă de azi: filtrul difuz exact, verosimilitatea la frontieră, cele trei eșantionatoare, KSC, filtrele de particule și PMMH, TVP, DFM, MNZ și UC-SV
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: inflația de trend și ancorarea în Europa Centrală și de Est
- ▣ Lectură: Durbin și Koopman (2012), cap. 4–5; Kim, Shephard și Chib (1998); Morley, Nelson și Zivot (2003); Stock și Watson (2007)
- ▣ **Seminarul are rol de exercițiu și nu se notează**

Bibliografie (1/2)

- ▣ Beveridge, S., & Nelson, C. R. (1981). A new approach to decomposition of economic time series into permanent and transitory components with particular attention to measurement of the 'business cycle'. *Journal of Monetary Economics*, 7(2), 151–174. doi:10.1016/0304-3932(81)90040-4
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- ▣ Carter, C. K., & Kohn, R. (1994). On Gibbs sampling for state space models. *Biometrika*, 81(3), 541–553. doi:10.1093/biomet/81.3.541
- ▣ Durbin, J., & Koopman, S. J. (2002). A simple and efficient simulation smoother for state space time series analysis. *Biometrika*, 89(3), 603–616. doi:10.1093/biomet/89.3.603
- ▣ Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press. doi:10.1093/acprof:oso/9780199641178.001.0001
- ▣ Gordon, N. J., Salmond, D. J., & Smith, A. F. M. (1993). Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEE Proceedings F (Radar and Signal Processing)*, 140(2), 107–113. doi:10.1049/ip-f-2.1993.0015
- ▣ Harvey, A., Ruiz, E., & Shephard, N. (1994). Multivariate stochastic variance models. *The Review of Economic Studies*, 61(2), 247–264. doi:10.2307/2297980
- ▣ Kim, S., Shephard, N., & Chib, S. (1998). Stochastic volatility: Likelihood inference and comparison with ARCH models. *The Review of Economic Studies*, 65(3), 361–393. doi:10.1111/1467-937X.00050

Bibliografie (2/2)

- ▣ Koopman, S. J. (1997). Exact initial Kalman filtering and smoothing for nonstationary time series models. *Journal of the American Statistical Association*, 92(440), 1630–1638. doi:10.1080/01621459.1997.10473685
- ▣ Morley, J. C., Nelson, C. R., & Zivot, E. (2003). Why are the Beveridge–Nelson and unobserved-components decompositions of GDP so different? *The Review of Economics and Statistics*, 85(2), 235–243. doi:10.1162/003465303765299765
- ▣ Orphanides, A., & van Norden, S. (2002). The unreliability of output-gap estimates in real time. *The Review of Economics and Statistics*, 84(4), 569–583. doi:10.1162/003465302760556422
- ▣ Pitt, M. K., & Shephard, N. (1999). Filtering via simulation: Auxiliary particle filters. *Journal of the American Statistical Association*, 94(446), 590–599. doi:10.1080/01621459.1999.10474153
- ▣ Shephard, N., & Harvey, A. C. (1990). On the probability of estimating a deterministic component in the local level model. *Journal of Time Series Analysis*, 11(4), 339–347. doi:10.1111/j.1467-9892.1990.tb00062.x
- ▣ Stock, J. H., & Watson, M. W. (1998). Median unbiased estimation of coefficient variance in a time-varying parameter model. *Journal of the American Statistical Association*, 93(441), 349–358. doi:10.1080/01621459.1998.10474116
- ▣ Stock, J. H., & Watson, M. W. (2007). Why has U.S. inflation become harder to forecast? *Journal of Money, Credit and Banking*, 39(s1), 3–33. doi:10.1111/j.1538-4616.2007.00014.x