



Analiza avansată a seriilor de timp și previziune

Seminarul 10: Memorie lungă și rough volatility



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AR**: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARFIMA**: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv fracționar integrat cu medie mobilă
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BNR**: Banca Națională a României
- ▣ **BUX**: Budapesti Értéktőzsde index (indicele Bursei din Budapesta)
- ▣ **CAC**: Cotation Assistée en Continu (CAC 40 index, Paris) — indicele CAC 40 al bursei din Paris
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **ELW**: Exact Local Whittle (estimator) — estimatorul local Whittle exact
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **FCVAR**: Fractionally Cointegrated VAR (model VAR cointegrat fracționar)
- ▣ **FFT**: Fast Fourier Transform (transformata Fourier rapidă)

Acronime folosite în acest material (2/2)

- ▣ **FIGARCH**: Fractionally Integrated GARCH (GARCH integrat fracționar)
- ▣ **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — furnizorul de indici FTSE Russell
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **GPH**: Geweke–Porter–Hudak (estimator) — estimatorul Geweke–Porter–Hudak al parametrului de memorie lungă
- ▣ **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- ▣ **HAR**: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- ▣ **LW**: Local Whittle (estimator) — estimatorul local Whittle
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — indicele Bursei din Praga
- ▣ **QLIKE**: Quasi-LIKelihood loss (pierderea de tip cvasi-verosimilitate)
- ▣ **RFSV**: Rough Fractional Stochastic Volatility (model) — modelul de volatilitate stochastică fracționară rugoasă
- ▣ **RV**: Realised Variance (varianța realizată)
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **VECM**: Vector Error Correction Model (model vectorial cu corecția erorii)
- ▣ **WIG20**: Warszawski Indeks Giełdowy 20 (indicele celor mai mari 20 de companii de la Bursa din Varșovia)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum măsurăm, testăm și folosim memoria lungă și neregularitatea volatilității și inflației?
 - ▶ seminarul are loc **înaintea** Cursului 10: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: autocorelațiile ARFIMA, ponderile fracționare, erorile standard și deplasarea estimatorilor, zgomotul gaussian fracționar, nucleul RFSV, scufundarea circulantă, schimbările de regim care imită memoria lungă
 - ▶ Partea B: memoria varianței realizate pentru FTSE 100, BET și EUR/RON; neregularitatea pentru Euro Stoxx 50 și Bitcoin; prognoza varianței realizate pentru FTSE 100 și CAC 40
 - ▶ Partea C: memoria comună a volatilității DAX și CAC 40; un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	autocorelațiile ARFIMA și media; ponderile fracționare	Rezolvat, Propus	A1
A3, A4	erorile standard GPH și LW; deplasarea și lățimea de bandă	Rezolvat, Propus	A3
A5, A6	zgomotul gaussian fracționar; nucleul RFSV	Rezolvat, Propus	A5
A7, A8	scufundarea circulantă calculată de mână; schimbări de regim care imită memoria lungă	Rezolvat, Propus	A7, A1
B1, B2	memoria logaritmului RV pentru FTSE 100; BET și EUR/RON cu testul Qu	Rezolvat, Propus	B1
B3, B4	neregularitatea Euro Stoxx 50; Bitcoin după intervalul de eșantionare	Rezolvat, Propus	B3
B5, B6	proгноza RV pentru FTSE 100 și CAC 40	Rezolvat, Propus	B5
C1, C2	cointegrarea fracționară a două volatilități; ce este greșit într-un răspuns AI?	Propus	B1, A1–A8

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
RV pentru FTSE 100, Euro Stoxx 50, DAX, CAC 40	Heber et al. (2009)	zilnic, din randamente de 5 minute	2000–2022
RV pentru Bitcoin	prețuri Binance la un minut	zilnic, 1–60 de minute	2018–2026
BET	EODHD	zilnic	2000–2026
EUR/RON	cursul de referință BNR	zilnic	2005–2026

- ▣ RV în $\%^2$, randamente în %
- ▣ Funcțiile din notebook
 - ▶ `gph`, `local_whittle`, `elw`, `qu_stat`, `gjr_scaling`, `h_with_noise`, `rfsv_kernel`, `forecast_rv`, `fcvar_fit`
- ▣ Nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/24): autocorelația și memoria

- Autocovarianța și autocorelația unei serii staționare X_t la lagul k

$$\gamma(k) = \text{Cov}(X_t, X_{t+k}), \quad \rho(k) = \frac{\gamma(k)}{\gamma(0)} \in [-1, 1]$$


- ▶ $\gamma(0) = \text{Var}X_t$; staționar: media și $\gamma(k)$ nu depind de t
- Memoria scurtă: autocorelațiile scad exponențial și sînt sumabile
 - ▶ AR(1) $X_t = \phi X_{t-1} + \varepsilon_t$, $|\phi| < 1$: $\rho(k) = \phi^k$, deci $\sum_k |\rho(k)| < \infty$
 - ▶ ε_t : zgomot alb (necorelat, medie 0, varianță σ^2)
- Memoria lungă: descreștere hiperbolică, nesumabilă, un pol spectral în frecvența zero

$$\rho(k) \sim c k^{2d-1} \quad (k \rightarrow \infty), \quad f(\lambda) \sim G \lambda^{-2d} \quad (\lambda \rightarrow 0), \quad 0 < d < 1/2$$


- ▶ d : parametrul de memorie; $c, G > 0$: constante; $f(\lambda)$: densitatea spectrală la frecvența λ (definită mai jos)
- ▶ $a_k \sim b_k$: raportul $a_k/b_k \rightarrow 1$; exponentul Hurst $H = d + 1/2$

Noțiuni necesare azi (2/24): descreșterea hiperbolică față de cea exponențială

Simulated paths (same variance, shifted)




Autocorrelations



— AR(1), $\phi = 0.67$ — ARFIMA(0, 0.4, 0) - - - $\frac{\Gamma(1-d)}{\Gamma(d)} k^{2d-1}$

- ARFIMA(0; 0.4; 0) (definit mai jos) și un AR(1) cu același $\rho(1)$, $\phi = 0.67$; ambele simulate, $n = 1000$
- La lagul 100: $\rho = 0.27$ pentru ARFIMA, practic 0 pentru AR(1); pe scări logaritmice ACF hiperbolică este o dreaptă cu panta $2d - 1$
- Traectoria ARFIMA se abate de la medie în episoade lungi

Noțiuni necesare azi (3/24): varianța mediei de eșantion



□ Pentru orice serie staționară

$$\text{Var}(\bar{X}_n) = \frac{1}{n} \sum_{|k| < n} \left(1 - \frac{|k|}{n}\right) \gamma(k)$$

- ▶ $\bar{X}_n = \frac{1}{n} \sum_{t=1}^n X_t$; n : mărimea eșantionului
- ▶ i.i.d.: rămîne doar $k = 0$, $\gamma(0)/n$

□ Memoria lungă: de ordinul n^{2d-1} , nu n^{-1}

- ▶ raportul din grafic crește ca n^d
- ▶ $n = 1000$: 1,9; 5,3; 15,3 pentru $d = 0,1; 0,25; 0,4$
- ▶ eroarea standard i.i.d. este de atîtea ori prea mică


Noțiuni necesare azi (4/24): operatorul lag și diferențierea fracționară

- **Operatorul lag** L : $LX_t = X_{t-1}$, $L^k X_t = X_{t-k}$; diferența de ordinul întâi $(1 - L)X_t = X_t - X_{t-1}$
- **Diferența fracționară**: seria binomială a lui $(1 - L)^d$ pentru d real

$$(1 - L)^d X_t = \sum_{k=0}^{\infty} \pi_k X_{t-k}, \quad \pi_0 = 1, \quad \pi_k = \pi_{k-1} \frac{k-1-d}{k}$$

- ▶ π_k : ponderea lui X_{t-k} ; $d = 1$: $\pi_1 = -1$, $\pi_k = 0$ pentru $k \geq 2$ (diferența obișnuită)
- ▶ $0 < d < 1$: intră toate valorile trecute, cu ponderile $\pi_k \sim k^{-d-1}/\Gamma(-d)$
- ▶ $\Gamma(z) = \int_0^{\infty} u^{z-1} e^{-u} du$: funcția gamma, $\Gamma(n) = (n-1)!$; $\Gamma(-d) < 0$ pentru $0 < d < 1$
- ▶ $\sum_k \pi_k = (1-1)^d = 0$: un nivel constant este eliminat doar de filtrul infinit

Noțiuni necesare azi (5/24): ponderile fracționare



- Stînga: $\pi_1 = -d$, apoi ponderi negative mici, care scad lent
- Dreapta: pe scări logaritmice $|\pi_k|$ este o dreaptă cu panta $-(d+1)$: o descreștere hiperbolică, nu exponențială
- Un filtru trunchiat după K laguri omite coada ponderilor

Noțiuni necesare azi (6/24): modelul ARFIMA

- **ARFIMA**(0, d , 0) [Hosking \(1981\)](#): zgomot alb după diferențierea fracționară

$$(1 - L)^d X_t = \varepsilon_t, \quad -\frac{1}{2} < d < \frac{1}{2} \text{ (staționar și inversabil)}$$

- ▶ $d > 0$: memorie lungă; $d < 0$: antipersistență ($\sum_k \rho(k) = 0$); $d \geq 1/2$: nestaționar

- Autocorelațiile: o recursie și limita ei

$$\rho(0) = 1, \quad \rho(k) = \rho(k-1) \frac{k-1+d}{k-d}, \quad \rho(k) \sim \frac{\Gamma(1-d)}{\Gamma(d)} k^{2d-1}$$

- **ARFIMA**(1, d , 0): $(1 - \phi L)(1 - L)^d X_t = \varepsilon_t$

- ▶ ϕ : coeficientul AR, $|\phi| < 1$; modifică lagurile mici, d pe cele mari
- ▶ ARFIMA(p , d , q): un ARMA(p , q) pentru $(1 - L)^d X_t$

Noțiuni necesare azi (7/24): densitatea spectrală și periodograma

- **Densitatea spectrală:** varianța lui X_t descompusă pe frecvențe

$$f(\lambda) = \frac{1}{2\pi} \sum_{k=-\infty}^{\infty} \gamma(k) e^{-i\lambda k}, \quad \gamma(0) = \int_{-\pi}^{\pi} f(\lambda) d\lambda$$

- ▶ $\lambda \in [-\pi, \pi]$: frecvența unghiulară, un ciclu de $2\pi/\lambda$ perioade; λ mic: cicluri lungi
- ▶ ARFIMA(0, d , 0): $f(\lambda) = \frac{\sigma^2}{2\pi} (4 \sin^2(\lambda/2))^{-d} \sim \frac{\sigma^2}{2\pi} \lambda^{-2d}$

- **Periodograma** în frecvențele Fourier: corespondentul de eșantion al lui f

$$I(\lambda_j) = \frac{1}{2\pi n} \left| \sum_{t=1}^n X_t e^{-i\lambda_j t} \right|^2, \quad \lambda_j = \frac{2\pi j}{n}, \quad j = 1, \dots, \lfloor n/2 \rfloor$$

- ▶ $I(\lambda_j)/f(\lambda_j)$ are aproximativ distribuția exponențială cu media 1, independent între j : foarte zgomotoasă
- ▶ lățimea de bandă m : numărul frecvențelor celor mai joase $\lambda_1, \dots, \lambda_m$ folosite pentru estimarea lui d ; $m \rightarrow \infty$, $m/n \rightarrow 0$

Noțiuni necesare azi (8/24): estimatorul GPH

- **GPH** Geweke și Porter-Hudak (1983): logaritmăm $I(\lambda_j) \approx f(\lambda_j) \xi_j$ lângă zero și aplicăm OLS

$$\log I(\lambda_j) = a + d \left[-\log \left(4 \sin^2(\lambda_j/2) \right) \right] + u_j, \quad j = 1, \dots, m$$


- ▶ ξ_j : eroarea exponențială cu media 1; $u_j = \log \xi_j - \mathbb{E} \log \xi_j$; a : termenul liber
- ▶ $\hat{d}$: panta OLS; regresorul $\approx -2 \log \lambda_j$, deci panta pe scări logaritmice este $-2d$

- Eroarea standard asimptotică

- ▶ $\text{Var} u_j = \pi^2/6$, iar regresorul are varianța ≈ 4 : $\text{SE}(\hat{d}) = \pi/\sqrt{24m}$
- ▶ $\sqrt{m}(\hat{d} - d) \rightarrow N(0, \pi^2/24)$; intervalul de 95%: $\hat{d} \pm 1,96 \text{SE}$

- Precizia crește doar cu $\sqrt{m}$, nu cu $\sqrt{n}$: estimarea lui d cere eșantioane lungi

Noțiuni necesare azi (9/24): logaritmul periodogramei lângă zero



- ARFIMA(0; 0,35; 0) simulat, $n = 4096$
- Cele $m = n^{0,65} = 222$ ordonate cele mai joase (închise) se așază în jurul unei drepte
 - ▶ GPH: $\hat{d} = 0,46$; local Whittle: 0,44
 - ▶ ambele la mai puțin de două erori standard de $d = 0,35$
- Dispersia în jurul drepte este zgomotul exponențial ξ_j : nu scade cu n
- Departă de zero (punctele deschise), dinamica de termen scurt curbează f : trebuie lăsată în afara regresiei

Noțiuni necesare azi (10/24): estimatorul local Whittle

- **Local Whittle Robinson (1995b)**: verosimilitatea gaussiană a lui $f(\lambda_j) = G\lambda_j^{-2d}$ pe cele m frecvențe joase

$$\hat{d} = \arg \min_d R(d), \quad R(d) = \log \hat{G}(d) - \frac{2d}{m} \sum_{j=1}^m \log \lambda_j, \quad \hat{G}(d) = \frac{1}{m} \sum_{j=1}^m \lambda_j^{2d} I(\lambda_j)$$

- ▶ $\hat{G}(d)$: nivelul G cel mai potrivit pentru un d dat; $R(d)$: funcția obiectiv profilată (o potrivire de tip QLIKE)


- Inferența

- ▶ $\sqrt{m}(\hat{d} - d) \rightarrow N(0, 1/4)$: $SE = 1/(2\sqrt{m})$, mai mică decât la GPH pentru același m
- ▶ eficiența relativă: raportul celor două varianțe asimptotice, $(\pi^2/24)/(1/4)$
- ▶ consistent pentru $-1/2 < d \leq 1$; pentru $d > 1$ converge la 1

- **Local Whittle exact (ELW) Shimotsu și Phillips (2005), Shimotsu (2010)**

- ▶ înlocuiește $\lambda_j^{2d} I(\lambda_j)$ cu periodograma lui $(1 - L)^d (X_t - \hat{\mu})$, $\hat{\mu}$: media estimată
- ▶ $N(d, 1/(4m))$ pentru orice d din intervalul de căutare, și pentru $d \geq 1/2$ (nestaționar)

Noțiuni necesare azi (11/24): deplasarea și alegerea lățimii de bandă



- Dinamica de termen scurt deplasează $\hat{d}$; pentru ARFIMA(1, d , 0)

$$\mathbb{E}\hat{d} - d \approx C \left(\frac{m}{n} \right)^2, \quad C = \frac{2\pi^2}{9} \cdot \frac{2\phi}{(1-\phi)^2}$$

- ▶ $\phi > 0$: deplasare pozitivă, care crește cu m

- $\text{MSE} = \text{deplasarea}^2 + \frac{1}{4m}$; minim în

$$m^* = \left(\frac{n^4}{16C^2} \right)^{1/5}$$

- ▶ MSE: eroarea medie pătratică; m^* crește ca $n^{4/5}$
- ▶ graficul: $\phi = 0.3$, $n = 2000$: $C = 2.69$,
 $m^* = 169 = n^{0.68}$


Noțiuni necesare azi (12/24): salturi de nivel care imită memoria lungă

- **Lanț Markov cu două stări** $S_t \in \{-1, 1\}$: rămîne în stare cu probabilitatea q , trece în cealaltă cu $1 - q$

$$X_t = \mu S_t + \varepsilon_t, \quad \mathbb{E}(S_t S_{t+k}) = (2q - 1)^k$$

- ▶ μ : mărimea nivelului; ε_t : i.i.d. $N(0, 1)$, independent de S ; durata medie a unui regim $1/(1 - q)$
- ▶ ACF scade exponențial: memorie scurtă în sens strict
- **Timpul de înjumătățire** al unei descreșteri geometrice $\rho(k) = \rho(0) r^k$
 - ▶ $k_{1/2} = \ln 0,5 / \ln r$: lagul la care autocorelația s-a înjumătățit
- Salturile rare, rupturile structurale și trendurile lente pun putere în frecvențele cele mai joase **Diebold și Inoue (2001)**
 - ▶ $\hat{d}$ este atunci mare, deși procesul are memorie scurtă: **memorie lungă falsă**

Noțiuni necesare azi (13/24): o serie simulată cu schimbări de regim




- $q = 0.99$ (regimurile durează în medie 100 de perioade), $\mu = 0.8$, $n = 4000$
- Local Whittle cu $m = n^{0.65}$ dă $\hat{d} = 0.52$, o valoare tipică unei serii cu memorie lungă
- Pe câteva sute de laguri, descreșterea geometrică lentă nu se distinge de una hiperbolică

Noțiuni necesare azi (14/24): testul Qu

- **Testul Qu Qu (2011):** H_0 memorie lungă staționară, $f(\lambda) = G\lambda^{-2d}$ pe cele m frecvențe joase

$$W = \sup_{r \in [\varepsilon, 1]} \left(\sum_{j=1}^m \nu_j^2 \right)^{-1/2} \left| \sum_{j \leq mr} \nu_j \left(\frac{\lambda_j^{2\hat{d}} I(\lambda_j)}{\hat{G}} - 1 \right) \right|$$

- ▶ $\hat{d}$, $\hat{G} = \hat{G}(\hat{d})$: estimațiile local Whittle; $\nu_j = \log \lambda_j - \frac{1}{m} \sum_i \log \lambda_i$
 - ▶ paranteza este scorul local Whittle la frecvența j ; suma ei completă este zero în $\hat{d}$
 - ▶ r : fracțiunea din cele m frecvențe însumate; ε : trimming, primele εm sume parțiale se omit
- Interpretarea
- ▶ sub H_0 , sumele parțiale rămân mici la orice r ; salturile de nivel fac ordonatele cele mai joase prea mari: W mare
 - ▶ respingem pentru W peste valoarea critică; cu $m = n^{0,7}$, $\varepsilon = 0,02$ (simulate): 1,09 (10%), 1,22 (5%), 1,56 (1%)

Noțiuni necesare azi (15/24): sumele parțiale Q_u 

- Două serii simulate, $n = 4000$
- ARFIMA(0; 0,35; 0): curba rămîne jos
 - ▶ $W = 0,61$: nu respingem
- Salturi de nivel Markov ($q = 0,997, \mu = 0,8$)
 - ▶ $\hat{d}$ arată ca o memorie lungă
 - ▶ dar curba sare la r mic: $W = 2,85$, respingem la 1%
- O respingere spune doar că memoria lungă staționară nu se potrivește: rupturile, salturile sau trendurile sînt alternative

Noțiuni necesare azi (16/24): cointegrarea fracționară

- **Cointegrarea fracționară:** p serii, fiecare cu memoria d , ale căror combinații $\beta' X_t$ au memoria $d - b$, $b > 0$
- **FCVAR Johansen și Nielsen (2012):** un VECM scris în diferențe fracționare

$$\Delta^d X_t = \alpha \beta' L_b \Delta^{d-b} X_t + \sum_{i=1}^k \Gamma_i \Delta^d L_b^i X_t + \varepsilon_t, \quad \Delta^d = (1 - L)^d, \quad L_b = 1 - \Delta^b$$

- ▶ β ($p \times r$): vectorii de cointegrare; α ($p \times r$): vitezele de ajustare; r : rangul de cointegrare
- ▶ L_b : operatorul lag fracționar (doar valori trecute); k : numărul termenilor de termen scurt, Γ_i matricele lor; $b = d = 1$: VECM obișnuit
- Estimarea și testele de rang
 - ▶ pentru (d, b) fixat: regresia de rang redus Johansen; verosimilitatea profilată: maximizare pe o grilă de (d, b)
 - ▶ testul trace al rangului r față de p : $LR = 2(\ell_p - \ell_r)$, ℓ : log-verosimilitățile maxime; $\chi_{(p-r)}^2$ când $b < 1/2$

Noțiuni necesare azi (17/24): mișcarea browniană fracționară

- **Mișcarea browniană fracționară (fBm)** W_t^H **Mandelbrot și Van Ness (1968)**: gaussiană, $W_0^H = 0$, medie 0, covarianța

$$\mathbb{E}(W_t^H W_s^H) = \frac{1}{2} (t^{2H} + s^{2H} - |t - s|^{2H}), \quad \mathbb{E}|W_{t+\Delta}^H - W_t^H|^2 = \Delta^{2H}$$

- ▶ $H \in (0, 1)$: exponentul Hurst; $H = 1/2$: mișcarea browniană, creșteri independente
- ▶ $H < 1/2$: traiectorii neregulate (rough), creșteri corelate negativ; $H > 1/2$: traiectorii netede, creșteri persistente


- **Zgomotul gaussian fracționar (fGn)**: creșterile unitare $W_{t+1}^H - W_t^H$

$$\gamma_k = \rho(k) = \frac{1}{2} (|k+1|^{2H} - 2|k|^{2H} + |k-1|^{2H})$$

- ▶ $\rho(1) = 2^{2H-1} - 1$; pentru $H > 1/2$, $\rho(k) \sim H(2H-1)k^{2H-2}$: memorie lungă cu $d = H - 1/2$


Noțiuni necesare azi (18/24): traiectorii neregulate și netede

Paths of W_t^H (shifted vertically)



— $H = 0.1$ — $H = 0.5$ — $H = 0.8$

Fractional Gaussian noise



- Stînga: traiectorii fBm din aceleași numere aleatoare pentru $H = 0,1; 0,5; 0,8$
- Dreapta: $H = 0,1$ dă $\rho(1) \approx -0,43$ și aproape nimic dincolo: traiectoria revine imediat
- $H = 0,8$: autocorelații pozitive care scad lent, memoria lungă din cadrele anterioare

Noțiuni necesare azi (19/24): scufundarea circulantă

- **Scopul:** simularea exactă a n puncte dintr-o serie gaussiană staționară cu autocovarianțele $\gamma_0, \dots, \gamma_{n-1}$
 - ▶ factorizarea Cholesky a covarianței $n \times n$ costă $O(n^3)$
- **Davies–Harte** [Davies și Harte \(1987\)](#): covarianța se scufundă într-o matrice circulantă de dimensiune $M = 2(n - 1)$

$$c = (\gamma_0, \gamma_1, \dots, \gamma_{n-1}, \gamma_{n-2}, \dots, \gamma_1), \quad \lambda_k = \sum_{j=0}^{M-1} c_j e^{-2\pi i j k / M}$$

- ▶ circulantă: fiecare rând este cel anterior deplasat cu o poziție; c : primul ei rând
- ▶ λ_k : valorile ei proprii, FFT (transformata Fourier rapidă) a lui c , reale pentru că c este simetric
- ▶ dacă toate $\lambda_k \geq 0$: $Y = \text{FFT}(\sqrt{\lambda/M} Z)$, Z gaussian complex; primele n valori au covarianța dorită
- ▶ cost $O(n \log n)$; pentru fGn, toate $\lambda_k \geq 0$ pentru orice H

Noțiuni necesare azi (20/24): varianța realizată și scalarea momentelor

- ▣ **Varianța realizată** a zilei t din N_t randamente intraday $r_{t,i}$ (de exemplu, de 5 minute)

$$RV_t = \sum_{i=1}^{N_t} r_{t,i}^2, \quad \sigma_t = \sqrt{RV_t}$$


- ▶ o măsură zgomotoasă a varianței zilnice; mai puține randamente pe zi: o eroare de măsurare mai mare

- ▣ **Scalarea momentelor Gatheral, Jaisson și Rosenbaum (2018)**: pentru $\log \sigma_t = \nu W_t^H$, momentele creșterilor sînt legi putere


$$m(q, \Delta) = \frac{1}{N} \sum_t |\log \sigma_{t+\Delta} - \log \sigma_t|^q \propto \Delta^{\zeta_q}, \quad \zeta_q = qH$$

- ▶ q : ordinul momentului; Δ : lagul în zile; N : numărul de perechi; ν : volatilitatea volatilității (vol-of-vol)
- ▶ ζ_q : panta lui $\log m(q, \Delta)$ în funcție de $\log \Delta$; apoi $\hat{H} = \sum_q q \zeta_q / \sum_q q^2$ (regresie prin origine)
- ▶ o eroare de măsurare i.i.d. cu varianța s^2 adaugă un termen liber: $m(2, \Delta) = \nu^2 \Delta^{2H} + 2s^2$

Noțiuni necesare azi (21/24): regresia de scalare



• $q = 0.5$ • $q = 1$ • $q = 2$ • $q = 3$ • slopes ζ_q — $\zeta_q = \hat{H}q, \hat{H} = 0.112$



- Logaritmul volatilității zilnice simulat, $0,3 W_t^H$ cu $H = 0,12$, 4000 de zile, fără eroare de măsurare
- Stînga: drepte pe scări logaritmice, cîte una pentru fiecare q ; dreapta: pantele stau pe o dreaptă prin origine, $\hat{H} = 0,112$
- Abaterile de la liniaritate în q (multifractalitate, creșteri cu cozi groase) apar la q mare

Noțiuni necesare azi (22/24): HAR, FIGARCH și prognozele lognormale

- ▣ **HAR Corsi (2009)**: mediile zilnică, săptămînală și lunară ale trecutului, $y_t = \log RV_t$

$$y_{t+h} = \beta_0 + \beta_d y_t + \beta_w \bar{y}_t^{(5)} + \beta_m \bar{y}_t^{(22)} + u_{t+h}, \quad \bar{y}_t^{(K)} = \frac{1}{K} \sum_{j=0}^{K-1} y_{t-j}$$

- ▶ h : orizontul; OLS; un AR(22) cu memorie scurtă și ponderi restricționate, care imită memoria lungă

- ▣ **FIGARCH Baillie, Bollerslev și Mikkelsen (1996)**: varianța GARCH cu o diferență fracționară a pătratelor șocurilor e_t^2


$$\sigma_t^2 = \omega + [1 - (1 - \beta L)^{-1}(1 - \varphi L)(1 - L)^d] e_t^2$$

- ▶ $\omega > 0$, β , φ : coeficienți de tip GARCH; paranteza este un filtru ARCH(∞) cu ponderile de sumă unu

- ▣ **Corecția lognormală**: modelele prognozează $\log RV$, ținta este RV

- ▶ dacă $\log RV_{t+h} \sim N(\mu, s^2)$: $\mathbb{E}RV_{t+h} = e^{\mu+s^2/2}$; doar e^μ este mediana, prea mică

Noțiuni necesare azi (23/24): predictorul RFSV



- RFSV: $\log \sigma_t = \nu W_t^H$; prognoza este o medie cu nucleu putere a trecutului

$$\widehat{\log \sigma_{t+h}^2} = \sum_k w_k \log \sigma_{t-k}^2$$

- $w_k \propto \int_k^{k+1} \frac{du}{(u+h)u^{H+1/2}}$, normalizate la suma 1; h : orizontul


- Prognoza varianței

$$\exp(\widehat{\log \sigma_{t+h}^2} + 2c\nu^2 h^{2H})$$

- $c = \frac{\Gamma(3/2-H)}{\Gamma(H+1/2)\Gamma(2-2H)}$; $4c\nu^2 h^{2H}$: varianța erorii de prognoză a lui $\log \sigma^2$, înjumătățită ca în corecția lognormală

- Graficul: nucleul pune ponderea cea mai mare pe ultima zi și o coadă lungă și subțire; HAR folosește trei trepte plate

Noțiuni necesare azi (24/24): QLIKE și testul Diebold–Mariano



- **QLIKE** [Patton \(2011\)](#) pentru o prognoză de varianță F

$$\text{QLIKE} = \frac{RV}{F} - \log \frac{RV}{F} - 1 \geq 0$$

- ▶ 0 doar dacă $F = RV$; ordonează corect prognozele deși RV este un proxy zgomotos
- ▶ penalizează mai mult subestimarea (graficul)
- **Testul DM** ([Capitolul 1](#)): δ_t = pierderea modelului 1 minus pierderea modelului 2

$$DM = \frac{\bar{\delta}}{\sqrt{\hat{\Omega}/T}} \rightarrow N(0, 1)$$

- ▶ $\bar{\delta}$: media pe T prognoze; $\hat{\Omega}$: varianța Newey–West $\hat{\gamma}_0 + 2 \sum_{k=1}^L (1 - \frac{k}{L+1}) \hat{\gamma}_k$ a lui δ_t
- ▶ $DM < -1,96$: modelul 1 semnificativ mai bun la 5%

A1: autocorelațiile ARFIMA și media [Rezolvat]

Cerință

- ▣ ARFIMA(0; 0,3; 0).
- ▣ 1. Arătați că $\rho(1) = d/(1-d)$ și calculați $\rho(1)$, $\rho(10)$, $\rho(100)$ cu recursia.
- ▣ 2. Comparați $\rho(100)$ cu $\frac{\Gamma(1-d)}{\Gamma(d)} 100^{2d-1}$.
- ▣ 3. Pentru $n = 1000$, calculați raportul dintre abaterea standard adevărată a lui $\bar{X}$ și formula i.i.d. $\sqrt{\gamma(0)/n}$ (notebook A1).
- ▣ Raportați: trei numere; două numere; un număr și o frază.

Rezolvare

- ▣ 1. $\rho(1) = \rho(0) \cdot \frac{0+d}{1-d}$; $\rho(1) = 0,429$, $\rho(10) = 0,173$, $\rho(100) = 0,069$
- ▣ 2. Formula asimptotică: 0,069, practic egală deja la $k = 100$
- ▣ 3. Raportul 7,55: eroarea standard i.i.d. este de 7,55 ori prea mică
- ▣ Interpretare: cu $d = 0,3$, 1000 de observații conțin tot atîta informație cît un număr mult mai mic de observații independente; HAC cu lățime de bandă fixă nu poate repara aceasta

A2: ponderile diferențierii fracționare [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $d = 0,4$. Model: A1.
- ▣ 1. Calculați $\pi_1, \dots, \pi_5$ pentru $(1 - L)^{0,4}$.
- ▣ 2. Comparați π_{100} cu $100^{-d-1}/\Gamma(-d)$.
- ▣ 3. Calculați $\sum_{k=0}^{1000} \pi_k$; care este limita sumei și ce înseamnă diferența pentru un filtru trunchiat?
- ▣ Raportați: cinci numere; două numere; un număr și o frază.

A3: erorile standard GPH și local Whittle [Rezolvat]

Cerință

- $n = 5000$, $m = \lfloor n^{0,65} \rfloor$; o estimatie local Whittle $\hat{d} = 0,45$.
- 1. Calculați m și erorile standard asimptotice GPH și local Whittle.
- 2. Dați intervalul de 95% pentru d și eficiența relativă a LW față de GPH.
- 3. Ce m dă o semilățime de 0,05?
- Raportați: trei numere; un interval și un număr; un număr.

Rezolvare

- 1. $m = 253$; GPH $\pi/\sqrt{24m} = 0,0403$; LW $1/(2\sqrt{m}) = 0,0314$
- 2. $[0,388; 0,512]$; eficiența $(\pi^2/24)/(1/4) = \pi^2/6 = 1,645$
- 3. $1,96/(2\sqrt{m}) \leq 0,05 \Rightarrow m \geq 385$
- Interpretare: intervalul include $1/2$, deci staționaritatea nu este stabilită; precizia se obține măbind lățimea de bandă, iar o lățime de bandă mai mare aduce deplasare (A4)

A4: deplasarea și lățimea de bandă optimă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ ARFIMA(1, d , 0) cu $\phi = 0,5$, $n = 5000$. Model: A3.
- ▣ 1. Calculați constanta deplasării C .
- ▣ 2. Pentru $m = \lfloor n^{0,8} \rfloor$, calculați deplasarea și abaterea standard local Whittle.
- ▣ 3. Calculați m^* , exponentul $\log m^* / \log n$ și deplasarea și abaterea standard în m^* .
- ▣ Raportați: un număr; două numere; patru numere și o frază.

A5: zgomotul gaussian fracționar și scalarea [Rezolvat]

Cerință

- ▣ fGn cu $H = 0,1; 0,3$ și $0,7$.
- ▣ 1. Calculați $\rho(1) = 2^{2H-1} - 1$ și $\rho(2)$ pentru fiecare H .
- ▣ 2. Calculați $m(2, 22)/m(2, 1) = 22^{2H}$: cu cît se mișcă mai mult logaritmul volatilității într-o lună decît într-o zi?
- ▣ 3. Arătați că $\zeta_q = qH$ pentru fBm.
- ▣ Raportați: șase numere; trei numere; o derivare.

Rezolvare

- ▣ 1. $H = 0,1$: $-0,426$; $-0,026$; $H = 0,3$: $-0,242$; $-0,049$;
 $H = 0,7$: $0,320$; $0,189$
- ▣ 2. $1,86$; $6,39$; $75,75$: cu $H = 0,1$, varianța modificărilor lunare este sub dublul celei zilnice
- ▣ 3. $W_{t+\Delta}^H - W_t^H \sim N(0, \Delta^{2H})$: $\mathbb{E}|\cdot|^q = \Delta^{qH} \mathbb{E}|Z|^q$; logaritmăm
- ▣ Interpretare: logaritmul volatilității, neregulat, se mișcă mult de la o zi la alta, dar deviază puțin: corelație negativă puternică a modificărilor zilnice

A6: nucleul RFSV și corecția varianței [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $H = 0,1$, $\nu = 0,3$, orizontul $h = 1$; nucleul trunchiat la 500 de zile. Model: A5.
- ▣ 1. Calculați ponderea totală pe ultima zi, pe ultimele 5 și pe ultimele 22 de zile (notebook A6).
- ▣ 2. Calculați $c(H)$ și corecția $2c\nu^2h^{2H}$ pentru $h = 1; 5; 22$.
- ▣ 3. Cu cît ar subestima prognoza varianței la $h = 22$ ignorarea corecției?
- ▣ Raportați: trei ponderi; patru numere; un număr.

A7: scufundarea circulantă calculată de mîină [Rezolvat]

Cerință

- Trei puncte de fGn cu $H = 0,3$: $\gamma_0, \gamma_1, \gamma_2$.
- 1. Calculați γ_1 și γ_2 .
- 2. Scrieți primul rînd al matricei circulante 4×4 și valorile ei proprii $\lambda_k = \sum_j c_j e^{-2\pi ijk/4}$.
- 3. Se poate folosi metoda Davies–Harte?
- Raportați: două numere; un rînd și patru numere; o frază.

Rezolvare

- 1. $\gamma_1 = \frac{1}{2}(2^{0,6} - 2) = -0,2421$,
 $\gamma_2 = \frac{1}{2}(3^{0,6} - 2 \cdot 2^{0,6} + 1) = -0,0491$
- 2. $c = (\gamma_0, \gamma_1, \gamma_2, \gamma_1)$; $\lambda_0 = \gamma_0 + 2\gamma_1 + \gamma_2 = 0,4666$,
 $\lambda_1 = \lambda_3 = \gamma_0 - \gamma_2 = 1,0491$, $\lambda_2 = \gamma_0 - 2\gamma_1 + \gamma_2 = 1,4352$
- 3. Da: toate valorile proprii sînt pozitive, deci matricea circulantă este o covarianță validă, iar primele 3 coordonate au covarianța fGn
- Interpretare: scufundarea dublează dimensiunea, dar transformă o factorizare $O(n^3)$ în două FFT

A8: schimbări de regim care imită memoria lungă [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ $X_t = \mu S_t + \varepsilon_t$, $S_t \in \{-1, 1\}$ un lanț Markov care rămîne în stare cu probabilitatea $q = 0,995$, $\mu = 1$, $\varepsilon_t \sim N(0, 1)$. Model: A1.
- ▣ 1. Arătați că $\rho(k) = \frac{\mu^2}{\mu^2 + 1} (2q - 1)^k$ și calculați $\rho(1)$, $\rho(100)$, $\rho(500)$.
- ▣ 2. Calculați timpul de înjumătățire al autocorelației.
- ▣ 3. Ajustați $\log \rho(k)$ pe $\log k$ pentru $k = 5, \dots, 200$ și transformați panta în d .
- ▣ Raportați: trei numere; un număr; un număr și o frază.

B1: memoria varianței realizate pentru FTSE 100 [Rezolvat]

- **Întrebarea:** cât de mare este d pentru logaritmul varianței realizate a FTSE 100 și este el robust la lățimea de bandă și la salturile de nivel?
- **Date:** RV de 5 minute Oxford-Man pentru FTSE 100, $n = 5\,586$ zile pînă la 25 februarie 2022
- **Cerințe**
 1. Estimați d pentru $\log RV$ prin GPH, local Whittle și local Whittle exact pentru $m = n^{0,5}, n^{0,6}, n^{0,7}$, cu erorile standard.
 2. Reprezentați grafic $\hat{d}(m)$ pentru $m = n^{0,40}, \dots, n^{0,85}$.
 3. Calculați statistica Qu cu $m = n^{0,7}$ și $\varepsilon = 0,02$.
 4. Interpretare: este reală memoria volatilității FTSE 100 și este ea staționară?
- **Raportați:** un tabel cu nouă estimatii și erorile standard, un grafic, o statistică, o frază
- Notebook: secțiunea B1

B1: rezolvare (1/2) [Rezolvat]



B1: rezolvare (2/2) [Rezolvat]

m	GPH (SE)	LW	ELW	SE (LW, ELW)
74	0,604 (0,075)	0,601	0,639	0,058
177	0,611 (0,048)	0,578	0,603	0,038
419	0,620 (0,031)	0,606	0,618	0,024

- Qu: $W = 0,33$ față de valoarea de 10% 1,09: nicio evidență de salturi de nivel
- Interpretare: $\hat{d} \approx 0,6$ la orice lățime de bandă, cu $\hat{d}(m)$ plat: memorie lungă reală, la limita staționarității sau puțin dincolo de ea; raportați ELW


B2: BET și EUR/RON cu testul Qu [Propus]

- ▣ **Întrebarea:** este reală memoria lui $|r_t|$ pe piața din București și pentru leu sau provine din schimbări de regim?
- ▣ **Date:** BET 2000–2026 și din 2010; EUR/RON (BNR) 2005–2026 și din 2014; model: B1
- ▣ **Cerințe**
 1. Estimați d pentru $|r_t|$ prin local Whittle cu $m = n^{0,65}$ pe eșantionul complet și după data de tăiere.
 2. Calculați statistica Qu ($m = n^{0,7}$, $\varepsilon = 0,02$) pe aceleași eșantioane.
 3. Interpretare: care dintre cele două piețe are memorie lungă reală a volatilității?
- ▣ **Raportați:** patru estimări cu erorile standard, patru statistici, o frază
- ▣ Notebook: secțiunea B2

B3: neregularitatea Euro Stoxx 50 [Rezolvat]

- **Întrebarea:** este valabilă scalarea Gatheral–Jaisson–Rosenbaum pentru Euro Stoxx 50 și cât de neregulată este volatilitatea lui?
- **Date:** RV de 5 minute Oxford-Man, $n = 5\,635$ zile; $\sigma_t = \sqrt{RV_t}$; $q = 0,5; 1; 1,5; 2; 3$; $\Delta = 1, \dots, 50$
- **Cerințe**
 1. Calculați $m(q, \Delta)$ și pantele ζ_q ; estimați H regresînd ζ_q pe q prin origine.
 2. Estimați H cu termenul liber pentru eroarea de măsurare, $m(2, \Delta) = \nu^2 \Delta^{2H} + 2s^2$.
 3. Repetați prima estimatie pe cele două jumătăți ale eșantionului.
 4. Interpretare: este ζ_q liniar în q și ce înseamnă o abatere?
- **Raportați:** cinci pante, trei valori ale lui H , ν , o frază
- **Notebook:** secțiunea B3

B3: rezolvare [Rezolvat]



□ $\zeta_q = 0,069; 0,132; 0,183; 0,217; 0,218; \hat{H} = 0,093, \hat{\nu} = 0,38$; cu termenul liber pentru eroare 0,109; jumătățile 0,091 și 0,095

□ Interpretare: linear pînă la $q = 2$, plat între $q = 2$ și 3 : momentele mari sînt determinate de cîteva zile extreme (cozi groase ale creșterilor), deci H din $q \leq 2$ este lectura mai sigură; neregularitatea este stabilă în timp


B4: neregularitatea Bitcoin după intervalul de eșantionare [Propus]

- ▣ **Întrebarea:** depinde estimația lui H pentru Bitcoin de intervalul de eșantionare al varianței realizate?
- ▣ **Date:** RV Binance pentru Bitcoin din randamente de 1, 5, 15, 30 și 60 de minute, 2018–2026; model: B3
- ▣ **Cerințe**
 1. Estimați H pentru fiecare RV prin regresia momentelor și cu termenul liber pentru eroare.
 2. Estimați d pentru $\log RV$ prin local Whittle cu $m = n^{0,65}$.
 3. Interpretare: în ce direcție împinge H o grilă mai rară și de ce?
- ▣ **Raportați:** zece valori ale lui H , cinci valori ale lui d , o frază
- ▣ **Notebook:** secțiunea B4

B5: prognoza varianței realizate pentru FTSE 100 [Rezolvat]

- **Întrebarea:** prognozează un model de tip rough volatility sau unul cu memorie lungă varianța realizată a FTSE 100 mai bine decât HAR?
- **Date:** fereastră mobilă de 1000 de zile, reestimare la fiecare 20 de zile; în afara eșantionului 30 decembrie 2003 – 26 ianuarie 2022 ($T = 4565$); orizonturi de 1, 5 și 22 de zile
- **Cerințe**
 1. Prognozați RV_{t+h} cu HAR, ARFIMA(0, d , 0) și RFSV, cu corecțiile lognormale.
 2. Calculați QLIKE mediu al fiecărui model și raportul față de HAR.
 3. Calculați statisticile DM față de HAR.
 4. Interpretare: ce model ați folosi la fiecare orizont?
- **Raportați:** nouă pierderi, șase rapoarte, șase statistici DM, o frază
- **Notebook:** secțiunea B5

B5: rezolvare (1/2) [Rezolvat]



B5: rezolvare (2/2) [Rezolvat]

h	QLIKE HAR	ARFIMA / HAR	DM	RFSV / HAR	DM
1	0,230	0,985	-0,98	1,038	1,49
5	0,324	0,968	-1,94	0,968	-1,33
22	0,561	0,895	-2,12	0,914	-1,93

- Interpretare: HAR la o zi (RFSV este mai slab); la 22 de zile, ARFIMA ($p = 0,034$) și RFSV ($p = 0,053$) sînt mai bune decît HAR cu aproximativ o zecime; mediana lui $\hat{H}$ mobil = 0,11

B6: prognoza varianței realizate pentru CAC 40 [Propus]

- **Întrebarea:** se transferă ordonarea de la FTSE 100 la CAC 40?
- **Date:** aceeași schemă, în afara eşantionului 22 decembrie 2003 – 26 ianuarie 2022 ($T = 4\,631$); model: B5
- **Cerințe**
 1. Repetați cele trei prognoze și rapoartele QLIKE.
 2. Calculați statisticile DM față de HAR.
 3. Interpretare: există un singur model cel mai bun pentru ambii indici?
- **Raportați:** șase rapoarte, șase statistici DM, o frază
- **Notebook:** secțiunea B6

C1: memoria comună a volatilității DAX și CAC 40 [Propus]

- ▣ **Întrebarea:** au volatilitățile a două piețe vecine un trend fracționar comun?
- ▣ **Date:** logaritmul RV de 5 minute pentru DAX și CAC 40 (Oxford-Man), $n = 5\,600$ zile comune; FCVAR cu $k = 0$; model: B1
- ▣ **Cerințe**
 1. Scrieți o preînregistrare de cinci rânduri: ipoteza, modelul, grila (d, b) , testele, ce v-ar face să vă schimbați concluzia.
 2. Estimați d pentru fiecare serie și pentru combinația $\beta' X_t$ prin local Whittle, apoi FCVAR prin verosimilitate profilată, cu testele trace.
 3. Interpretare: ce susțin datele și ce ați adăuga modelului?
- ▣ **Raportați:** un plan de cinci rânduri, cinci estimări, două teste, un plan de proiect
- ▣ Notebook: secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre memoria lungă și rough volatility. Răspunsul:
- (a) Un ARFIMA cu $d = 0,3$ are autocorelații care scad exponențial, doar mai încet decât un $AR(1)$.
- (b) Eroarea standard a estimatorului local Whittle este $\pi/\sqrt{24m}$.
- (c) O lățime de bandă m mai mare este întotdeauna mai bună, pentru că varianța scade.
- (d) Dacă testul Qu respinge, seria are rupturi structurale.
- (e) $H = 0,1$ înseamnă că volatilitatea are memorie scurtă, pentru că $H < 0,5$ înseamnă antipersistență.
- (f) FIGARCH cu $0 < d < 1$ este staționar în covarianță, cu o varianță necondiționată finită.
- (g) Local Whittle exact rămâne consistent pentru $d = 1,2$, în timp ce local Whittle nu.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de șapte verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ Memoria lungă face erorile standard i.i.d. și HAC mult prea mici
- ▣ Local Whittle este alegerea implicită; local Whittle exact când d poate depăși $1/2$; variați întotdeauna m
- ▣ Testați împotriva salturilor de nivel înainte de a afirma memoria lungă
- ▣ Logaritmul volatilității este neregulat ($H \approx 0,1$) și persistent; proxy-ul influențează H
- ▣ Cîștigurile de prognoză față de HAR sînt mici și depind de orizont

După seminar

- ▣ Cursul 10 dezvoltă fiecare temă de azi: teoria spectrală, asimptotica estimatorilor, testul Q_u , FCVAR, FIGARCH, rough volatility și prognozele ei
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: memoria comună a volatilităților din Europa Centrală și de Est
- ▣ Lectură: Robinson (1995b); Shimotsu și Phillips (2005); Qu (2011); Gatheral, Jaisson și Rosenbaum (2018)
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie (1/2)

- Baillie, R. T., Bollerslev, T., & Mikkelsen, H. O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30. doi:10.1016/S0304-4076(95)01749-6
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jjfinec/nbp001
- Davies, R. B., & Harte, D. S. (1987). Tests for Hurst effect. *Biometrika*, 74(1), 95–101. doi:10.1093/biomet/74.1.95
- Diebold, F. X., & Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159. doi:10.1016/S0304-4076(01)00073-2
- Gatheral, J., Jaisson, T., & Rosenbaum, M. (2018). Volatility is rough. *Quantitative Finance*, 18(6), 933–949. doi:10.1080/14697688.2017.1393551
- Geweke, J., & Porter-Hudak, S. (1983). The estimation and application of long memory time series models. *Journal of Time Series Analysis*, 4(4), 221–238. doi:10.1111/j.1467-9892.1983.tb00371.x
- Heber, G., Lunde, A., Shephard, N., & Sheppard, K. K. (2009). Oxford-Man Institute's realized library, version 0.3. Oxford-Man Institute, University of Oxford. web.archive.org
- Hosking, J. R. M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176. doi:10.1093/biomet/68.1.165

Bibliografie (2/2)

- ▣ Johansen, S., & Nielsen, M. Ø. (2012). Likelihood inference for a fractionally cointegrated vector autoregressive model. *Econometrica*, 80(6), 2667–2732. doi:10.3982/ECTA9299
- ▣ Mandelbrot, B. B., & Van Ness, J. W. (1968). Fractional Brownian motions, fractional noises and applications. *SIAM Review*, 10(4), 422–437. doi:10.1137/1010093
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Qu, Z. (2011). A test against spurious long memory. *Journal of Business & Economic Statistics*, 29(3), 423–438. doi:10.1198/jbes.2010.09153
- ▣ Robinson, P. M. (1995b). Gaussian semiparametric estimation of long range dependence. *The Annals of Statistics*, 23(5), 1630–1661. doi:10.1214/aos/1176324317
- ▣ Shimotsu, K. (2010). Exact local Whittle estimation of fractional integration with unknown mean and time trend. *Econometric Theory*, 26(2), 501–540. doi:10.1017/S0266466609100075
- ▣ Shimotsu, K., & Phillips, P. C. B. (2005). Exact local Whittle estimation of fractional integration. *The Annals of Statistics*, 33(4), 1890–1933. doi:10.1214/009053605000000309