



Analiza avansată a seriilor de timp și previziune

Seminarul 12: Machine learning și deep learning pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- **ACF**: Autocorrelation Function (funcția de autocorelație)
- **AI**: Artificial Intelligence (inteligență artificială)
- **AR**: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- **ARX**: AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- **CV**: Cross-Validation (validare încrucișată)
- **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- **ENTSO-E**: European Network of Transmission System Operators for Electricity (Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — furnizorul de indici FTSE Russell
- **GW**: Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- **HAR**: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- **HLN**: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- **HU**: Hungary (Eurostat country code) — Ungaria (codul de țară Eurostat)
- **IAPC**: Indicele armonizat al prețurilor de consum
- **LSTM**: Long Short-Term Memory (network) — rețea cu memorie pe termen lung și scurt
- **MAE**: Mean Absolute Error (eroarea absolută medie)

Acronime folosite în acest material (2/2)

- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **MCS**: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ **MLP**: MultiLayer Perceptron (perceptron multistrat)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **MW**: MegaWatt (megawatt)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **OOS**: Out-Of-Sample (în afara eșantionului)
- ▣ **OWA**: Overall Weighted Average (of sMAPE and MASE relative to Naive 2) — media ponderată generală a sMAPE și MASE relative la Naive 2
- ▣ **QLIKE**: Quasi-LIKelihood loss (pierderea de tip cvasi-verosimilitate)
- ▣ **QRF**: Quantile Regression Forest (pădure de regresie cuantilică)
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **RNN**: Recurrent Neural Network (rețea neuronală recurentă)
- ▣ **RV**: Realised Variance (varianța realizată)
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **SHAP**: SHapley Additive exPlanations (explicații aditive Shapley)
- ▣ **SPA**: Superior Predictive Ability (test) — testul abilității predictive superioare
- ▣ **TCN**: Temporal Convolutional Network (rețea convoluțională temporală)
- ▣ **UE**: Uniunea Europeană

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum validăm, estimăm și comparăm modele de machine learning și deep learning pe serii de timp fără să ne înșelăm singuri?
 - ▶ seminarul are loc **înaintea** Cursului 12: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: lasso, ridge, lasso adaptiv și elastic net calculate de mână; varianța bagging-ului; boosting-ul ca coborîre pe gradient
 - ▶ Partea A (continuare): gradientii într-un RNN și într-un LSTM; atenția calculată de mână; DLinear ca o singură aplicație liniară
 - ▶ Partea B: validarea încrucișată pe varianța realizată; modele locale și globale ale inflației UE; păduri cuantile și boosting monoton pentru consumul României; LSTM față de HAR; N-BEATS pe serii orare M4
 - ▶ Partea C: algoritmi deep față de HAR pentru cryptoactive; un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	lasso și ridge cu predictorii ortonormali; lasso adaptiv și elastic net	Rezolvat, Propus	A1
A3, A4	varianța bagging-ului; boosting-ul ca coborîre pe gradient	Rezolvat, Propus	A3
A5, A6	gradienții printr-un RNN scalar; poarta de uitare LSTM	Rezolvat, Propus	A5
A7, A8	atenția calculată de mînă; DLinear ca o singură aplicație liniară	Rezolvat, Propus	A7
B1, B2	validarea HAR; o pădure aleatoare cu indice de timp	Rezolvat, Propus	B1
B3, B4	AR local și global pentru inflația UE; lasso pe panel pentru România	Rezolvat, Propus	B3
B5, B6	QRF și ARX pentru vîrfurile de seară; boosting monoton	Rezolvat, Propus	B5
B7, B8	LSTM față de HAR; DLinear și N-BEATS pe 100 de serii M4	Rezolvat, Propus	B7
C1, C2	algoritmi deep pentru volatilitatea cripto; ce este greșit într-un răspuns AI?	Propus	B7, A1–A8

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
RV pentru FTSE 100, DAX	Heber et al. (2009)	zilnic, din randamente de 5 minute	2000–2022
Inflația IAPC, 27 de țări UE	Eurostat	lunar	2000–2026
Consumul României	Energy-Charts (ENTSO-E)	orar	2023–2026
Serii orare M4	Makridakis, Spiliotis și Assimakopoulos (2020)	orar	–
RV pentru Bitcoin, Ether	prețuri Binance la un minut	zilnic	2018–2026

- ▣ RV în %², consumul în GW (MW în răspunsuri)
- ▣ Funcțiile din notebook
 - ▶ `cv_estimates`, `global_local`, `penalised_fit`, `QRF`, `rv_forecasts`, `m4_global`, `dm_test`, `mcs`
- ▣ Nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/24): matricea de laguri și erorile de prognoză

- **Matricea de laguri:** seria de timp transformată într-un set de date de regresie

$$\text{rîndul } t : (y_{t+h}, y_t, y_{t-1}, \dots, y_{t-p+1}), \quad \hat{y}_{t+h} = f(y_t, \dots, y_{t-p+1})$$

- ▶ y_{t+h} : ținta; p : numărul de laguri (variabile); h : orizontul; f : orice algoritm (OLS, arbore, rețea)
- ▶ prognoze **directe**: un model pentru fiecare orizont h ; **recursive**: un model la un pas, iterat de h ori

- **Măsurile erorii** pe T prognoze, $e_t = y_t - \hat{y}_t$

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_t e_t^2}, \quad \text{MAE} = \frac{1}{T} \sum_t |e_t|$$

- ▶ RMSE: rădăcina erorii medii pătratice (MSE); MAE: eroarea absolută medie, mai puțin sensibilă la valori extreme

- **Ferestre**

- ▶ mobilă: ultimele W observații; extinsă: toate observațiile pînă la originea prognozei; reestimare la fiecare k perioade


Noțiuni necesare azi (2/24): schemele de validare încrucișată

- Validarea încrucișată (CV): estimăm eroarea viitoare estimînd modelul pe o parte din rînduri și testîndu-l pe restul

$$\widehat{\text{MSE}}_{\text{CV}} = \frac{1}{K} \sum_{k=1}^K \frac{1}{|F_k|} \sum_{t \in F_k} (y_{t+h} - \hat{f}^{(-k)}(x_t))^2$$


- F_k : rîndurile subeșantionului k ; $|F_k|$: numărul lor; $\hat{f}^{(-k)}$: algoritmul estimat fără subeșantionul k ; x_t : lagurile din rîndul t
- Patru moduri de alegere a subeșantioanelor
 - **K subeșantioane aleatoare**: rîndurile repartizate aleator în cele K subeșantioane
 - **K blocuri**: K blocuri contigue de rînduri
 - **purjare**: eliminăm h rînduri de antrenare de fiecare parte a blocului de test, astfel încît nicio țintă de antrenare să nu se suprapună cu una de test
 - **OOS** (în afara eșantionului): antrenare pe prima parte, test doar pe ultimul bloc
- Leakage: informația din rîndurile de test ajunge în rîndurile de antrenare; eroarea CV este atunci prea optimistă

Noțiuni necesare azi (3/24): cele patru scheme pentru un subeșantion

One of the $K = 5$ folds, $n = 60$ rows

- Subeșantioanele aleatoare pun rîndurile de test printre cele de antrenare: vecinii lor, aproape aceleași numere pentru ținte persistente, sînt folosiți la antrenare
- Purjarea elimină cele h rînduri vecine cu blocul de test; OOS folosește doar trecutul pentru a prognoza viitorul, ca în prognoza reală

Noțiuni necesare azi (4/24): cînd este validă validarea aleatoare



□ **Bergmeir, Hyndman și Koo (2018):** validarea aleatoare este validă pentru o autoregresie bine specificată

- ▶ condiția: erori u_{t+h} **necorelate**
- ▶ eșuează cu o variabilă indice de timp sau cu ținte suprapuse

□ **Ținta suprapusă:** media următoarelor h valori

$$z_t = \frac{1}{h} \sum_{j=1}^h y_{t+j}, \quad \text{corr}(z_t, z_{t+k}) = \frac{h-k}{h}$$

- ▶ egalitate pentru y zgomot alb, $k < h$; y autocorelat pozitiv: mai mare
- ▶ țintele vecine au $h - 1$ termeni comuni

□ **Graficul:** $h = 10$, ACF de eșantion urmează dreapta $(h - k)/h$

Noțiuni necesare azi (5/24): modele locale, globale și HAR

□ N serii $y_{i,t}$, $i = 1, \dots, N$ [Montero-Manso și Hyndman \(2021\)](#)

- ▶ modelul **local**: unul pe serie, $y_{i,t+h} = f_i(x_{i,t})$, circa T rînduri pentru fiecare
- ▶ modelul **global**: același f pentru toate seriile, $y_{i,t+h} = f(x_{i,t})$, estimat pe NT rînduri reunite (OLS reunit pentru un AR)
- ▶ global: mai multe rînduri pe coeficient, varianță mai mică; prețul este o deplasare dacă seriile diferă

□ **HAR** [Corsi \(2009\)](#) pentru $y_t = \log RV_t$

$$y_{t+h} = \beta_0 + \beta_d y_t + \beta_w \bar{y}_t^{(5)} + \beta_m \bar{y}_t^{(22)} + u_{t+h}, \quad \bar{y}_t^{(K)} = \frac{1}{K} \sum_{j=0}^{K-1} y_{t-j}$$

- ▶ RV_t : varianța realizată, suma pătratelor randamentelor intraday; mediile zilnică, săptămînală și lunară; OLS, cîte o regresie pe orizont
- ▶ corecția lognormală: $\widehat{RV}_{t+h} = \exp(\hat{y}_{t+h} + \hat{s}^2/2)$, $\hat{s}^2$: varianța reziduurilor

Noțiuni necesare azi (6/24): regresia penalizată

- ▣ Cele mai mici pătrate plus o penalizare a coeficienților (predictori standardizați, termenul liber nepenalizat)

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|^2 + \lambda P(\beta)$$

► n : rînduri; X : predictorii, $n \times p$; $\lambda \geq 0$: penalizarea, aleasă prin CV; $\lambda = 0$: OLS

- ▣ Penalizările $P(\beta)$

► **lasso** Tibshirani (1996): $\sum_j |\beta_j|$: anulează exact unii coeficienți (selecție)


► **ridge**: $\frac{1}{2} \sum_j \beta_j^2$: micșorează toți coeficienții, niciodată pînă la zero

► **elastic net** Zou și Hastie (2005): $\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2$, $\alpha \in [0, 1]$

► **lasso adaptiv** Zou (2006): $\sum_j w_j |\beta_j|$, $w_j = 1/|\tilde{\beta}_j|^\gamma$ dintr-o primă estimare $\tilde{\beta}$, $\gamma > 0$

- ▣ OLS după lasso: OLS pe predictorii selectați de lasso (elimină deplasarea datorată micșorării)

Noțiuni necesare azi (7/24): micșorarea coeficient cu coeficient



- Predictori ortonormali ($X'X = nI$), coeficientul OLS z_j :
fiecare penalizare acționează separat

$$S(z, \lambda) = \text{sign}(z)(|z| - \lambda)_+$$

► $(u)_+ = \max(u, 0)$; S : pragul moale

- Regulile din grafic

► lasso $S(z_j, \lambda)$; ridge $z_j/(1 + \lambda)$
 ► lasso adaptiv: pragul $\lambda/|z_j|^\gamma$
 ► elastic net $S(z_j, \lambda\alpha)/(1 + \lambda(1 - \alpha))$

- Lectura: distanța verticală pînă la dreapta OLS punctată este deplasarea datorată micșorării

Noțiuni necesare azi (8/24): arbori și păduri aleatoare

- ▣ **Arborele de regresie:** o funcție constantă pe porțiuni, pe o partiție a spațiului predictorilor


$$T(x) = \sum_{m=1}^M c_m \mathbf{1}\{x \in R_m\}, \quad c_m = \text{media valorilor } y_i \text{ din } R_m$$

- ▶ R_m : frunzele (dreptunghiuri); $\mathbf{1}\{\cdot\}$: indicatorul; fiecare ramificare $x_j \leq s$ minimizează suma pătratelor erorilor
- ▶ arbori adânci: deplasare mică, varianță mare; mărimea frunzelor și adâncimea controlează complexitatea
- ▣ **Bagging Breiman (1996) și pădurea aleatoare Breiman (2001):** media a B arbori
 - ▶ bagging: fiecare arbore pe un eșantion bootstrap (rînduri extrase cu revenire)
 - ▶ pădurea aleatoare: în plus, o submulțime aleatoare de predictorii la fiecare ramificare, care decorează arborii
- ▣ **Pădurea de regresie cuantilică (QRF) Meinshausen (2006):** întreaga distribuție condiționată

$$\hat{F}(y | x) = \sum_i w_i(x) \mathbf{1}\{y_i \leq y\}, \quad w_i(x) = \frac{1}{B} \sum_b \frac{\mathbf{1}\{x_i \in R_b(x)\}}{|R_b(x)|}$$

- ▶ $R_b(x)$: frunza arborelui b care conține x ; cuantila $\hat{q}_\tau(x) = \inf\{y : \hat{F}(y | x) \geq \tau\}$

Noțiuni necesare azi (9/24): varianța unei medii



- B predictorii $\hat{f}_b$, fiecare cu varianța σ^2 și corelația între perechi ρ

$$\text{Var}\left(\frac{1}{B} \sum_b \hat{f}_b\right) = \rho\sigma^2 + \frac{(1-\rho)\sigma^2}{B}$$

- ▶ al doilea termen dispare când B crește
- ▶ primul nu dispare: un prag inferior $\rho\sigma^2$
- Graficul: curbele ajung la prag după câteva zeci de arbori
- Un ρ mai mic (arbori decorelați) coboară pragul: ideea pădurii aleatoare


Noțiuni necesare azi (10/24): gradient boosting

- ▣ **Gradient boosting** [Friedman \(2001\)](#): se adaugă arbori mici, ajustați pe gradientul negativ al pierderii

$$F_0 = \text{const}, \quad g_{i,m} = -\frac{\partial \ell(y_i, F)}{\partial F} \Big|_{F=F_{m-1}(x_i)}, \quad F_m = F_{m-1} + \nu h_m$$

- ▶ ℓ : pierderea; h_m : un arbore mic ajustat pe $(x_i, g_{i,m})$; $\nu \in (0, 1]$: rata de învățare (shrinkage); M : numărul de iterații
- ▶ pierderea pătratică $\frac{1}{2}(y - F)^2$: $g = y - F$, reziduurile
- ▶ ν mic: mai multe iterații, o estimare mai stabilă; M și ν se reglează împreună
- ▣ **Histogram gradient boosting**: predictorii sînt grupați în intervale (de exemplu, 255) înainte de căutarea ramificărilor: rapid pe date mari
- ▣ **Restricția monotonă** în x_j : fiecare ramificare după x_j trebuie să păstreze estimarea nedescrescătoare în x_j
 - ▶ dependența parțială: $PD_j(v) = \frac{1}{n} \sum_i \hat{F}(v, x_{i,-j})$, prognoza medie cînd x_j este fixat la v ($x_{i,-j}$: ceilalți predictorii ai rîndului i)

Noțiuni necesare azi (11/24): un arbore, o pădure și boosting



- $y = \sin x + \text{zgomot simulat}$, 200 de puncte; stînga: un arbore de adîncime 3 (8 frunze) și o pădure de 200 de arbori, mai netedă pentru că face media
- Dreapta: boosting cu arbori de o singură ramificare și $\nu = 0,1$ după 1, 10 și 100 de iterații: estimarea se construiește pas cu pas

Noțiuni necesare azi (12/24): rețele neuronale

- **Perceptronul multistrat (MLP):** straturi de aplicații afine urmate de o neliniaritate

$$a^{(l)} = \phi(W^{(l)}a^{(l-1)} + b^{(l)}), \quad a^{(0)} = x, \quad \hat{y} = W^{(L)}a^{(L-1)} + b^{(L)}$$

- ▶ $W^{(l)}, b^{(l)}$: ponderile și bias-urile stratului l ; ϕ : activarea, aplicată pe elemente
- ▶ $\tanh(u) \in (-1, 1)$; sigmoida $\sigma(u) = 1/(1 + e^{-u}) \in (0, 1)$; ReLU $\max(u, 0)$

- **Antrenarea:** minimizarea pierderii medii prin coborîre stocastică pe gradient

- ▶ $\theta \leftarrow \theta - \eta \nabla_{\theta} \frac{1}{|B|} \sum_{i \in B} \ell(y_i, \hat{y}_i)$; B : mini-batch; η : rata de învățare; Adam: o variantă adaptivă
- ▶ gradientii prin regula lanțului (backpropagation); epocă: o trecere prin rîndurile de antrenare
- ▶ seed: numărul aleator care fixează ponderile inițiale și mini-batch-urile; rezultatele variază cu el, deci se face media mai multor seed-uri
- ▶ oprirea timpurie: antrenarea se oprește cînd pierderea pe un bloc de validare nu mai scade

Noțiuni necesare azi (13/24): rețele recurente și LSTM

- **RNN:** o stare ascunsă actualizată la fiecare pas; gradientul față de o stare trecută este un produs de jacobiene

$$h_t = \tanh(W h_{t-1} + U x_t + b), \quad \frac{\partial h_T}{\partial h_t} = \prod_{k=t+1}^T \text{diag}(1 - h_k^2) W$$


- ▶ h_t : starea ascunsă; x_t : intrarea; W, U, b : ponderile; norma $\|W\| < 1$: gradienti care se sting, > 1 : posibil explozivi [Bengio, Simard și Frasconi \(1994\)](#)

- **LSTM Hochreiter și Schmidhuber (1997):** o celulă de memorie aditivă c_t , controlată de trei porți cu valori în $(0, 1)$

$$\begin{aligned} f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), & i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), & o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o), \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c), & c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, & h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

- ▶ f_t : poarta de uitare; i_t : poarta de intrare; o_t : poarta de ieșire; $\tilde{c}_t$: memoria candidată; $\odot$: produsul pe elemente
- ▶ de-a lungul celei $\partial c_t / \partial c_{t-1} = \text{diag}(f_t)$, fără tanh intermediar; b_f : bias-ul porții de uitare

Noțiuni necesare azi (14/24): stingerea gradientelor



- RNN scalar: fiecare pas înmulțește gradientul cu $w(1 - h_t^2)$
 - ▶ deci este cel mult $|w|^k$ după k pași
- Drumul celulei LSTM cu poartă de uitare constantă $f = \sigma(b_f)$: factorul f^k
 - ▶ $b_f = -1$: $f \approx 0,27$, dispare în câțiva pași
 - ▶ $b_f = 5$: $f \approx 0,993$, un semnal supraviețuiește 100 de pași
- O poartă de uitare deschisă (b_f mare) păstrează memoria lungă [Hochreiter și Schmidhuber \(1997\)](#)


Noțiuni necesare azi (15/24): atenția

- **Atenția** Vaswani et al. (2017): fiecare token face o medie ponderată a valorilor tuturor tokenilor

$$\text{Attn}(q, K, V) = \sum_{j=1}^n \alpha_j v_j, \quad \alpha_j = \frac{\exp(q \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q \cdot k_l / \sqrt{d_k})}$$


- ▶ token: un element al intrării (un pas de timp sau un segment); $q = W_Q x$: interogarea lui; $k_j = W_K x_j$: cheile; $v_j = W_V x_j$: valorile
- ▶ d_k : dimensiunea cheilor; softmax: ponderi pozitive α_j cu suma 1; cheie și interogare similare: pondere mare
- **Ordinea și poziția**
 - ▶ formula tratează tokenii ca pe o mulțime; ordinea intră doar printr-o codificare a poziției adunată la x_j (de exemplu, sinusuri și cosinusuri ale poziției)
 - ▶ Transformers pe segmente (PatchTST Nie et al. (2023)): tokenii sînt segmente de 16–64 de valori consecutive, nu puncte individuale
- **Ocluzia**: modificarea prognozei cînd o intrare (sau un segment) este mascată; o măsură directă a dependenței

Noțiuni necesare azi (16/24): atenția pe o serie sezonieră



- Exemplu didactic: cheile și interogarea codifică doar ora din zi; interogarea este ora următoare (ora 72)
- Ponderile se concentrează pe aceeași oră din zilele anterioare (0, 24, 48 au 26% din pondere): atenția găsește analogii sezoniere

Noțiuni necesare azi (17/24): rețele convoluționale temporale



□ Convoluția causală dilatată Bai, Kolter și Koltun (2018)

$$y_t = \sum_{i=0}^{k-1} w_i x_{t-d \cdot i}$$

- k : mărimea nucleului; d : dilatarea; causală: doar x_t și trecutul

□ Cîmpul receptiv: cîte intrări trecute vede o ieșire

- o convoluție pe nivel, dilatările $1, 2, \dots, 2^{\ell-1}$:
 $1 + (k-1)(2^{\ell} - 1)$
- graficul: $k = 2, \ell = 3$: 8 intrări
- blocuri TCN cu două convoluții pe nivel:
 $1 + 2(k-1)(2^{\ell} - 1)$

Noțiuni necesare azi (18/24): DLinear și N-BEATS

- **DLinear** Zeng et al. (2023): fereastra de intrare se împarte în trend și rest, câte o aplicație liniară pentru fiecare

$$\hat{y} = W_s(x - Ax) + W_t Ax$$


- ▶ x : fereastra de intrare, de lungime L ; A : matricea $L \times L$ a mediei mobile (trendul Ax); W_s, W_t : ponderi $H \times L$; H : orizontul

- **N-BEATS** Oreshkin et al. (2020): o stivă de blocuri complet conectate; blocul b scade din intrare ce explică

$$x^{(b+1)} = x^{(b)} - \hat{x}^{(b)}, \quad \hat{y} = \sum_b \hat{y}^{(b)}$$

- ▶ $\hat{x}^{(b)}$: backcast (reconstrucția intrării); $\hat{y}^{(b)}$: prognoza parțială a blocului; antrenat ca model global pe multe serii
- ▶ ansamblu: media mai multor modele (seed-uri, lungimi ale intrării, pierderi)

Noțiuni necesare azi (19/24): descompunerea DLinear



- Fereastră simulată: trend pătratic, un sezon de 12 perioade și zgomot; media mobilă (lungime 25, capetele repetate) dă Ax
- Restul $x - Ax$ păstrează sezonul și zgomotul; fiecare parte primește propria prognoză liniară


Noțiuni necesare azi (20/24): pierderi pentru prognozele de varianță și de cuantile

- **QLIKE** Patton (2011) pentru o prognoză de varianță F a lui RV și **pierdere pinball** pentru o cuantilă

$$\text{QLIKE} = \frac{RV}{F} - \log \frac{RV}{F} - 1 \geq 0, \quad \rho_{\tau}(u) = \max(\tau u, (\tau - 1)u)$$

- ▶ **QLIKE**: zero doar pentru $F = RV$; penalizează mai mult subestimarea varianței
 - ▶ $u = y - \hat{q}_{\tau}$: valoarea reală minus cuantila prognozată; τ : nivelul cuantilei; minimizată în medie de cuantila adevărată
 - ▶ gradientul negativ în $F = \hat{q}_{\tau}$: $\tau - 1\{y < F\}$
- **Prognozele de interval** din decilele $\hat{q}_{0,1}$, $\hat{q}_{0,9}$
- ▶ acoperirea: ponderea valorilor reale din $[\hat{q}_{0,1}, \hat{q}_{0,9}]$, nominal 80%
 - ▶ lățimea: media lui $\hat{q}_{0,9} - \hat{q}_{0,1}$; intervalele bune sînt înguste, cu acoperirea corectă
 - ▶ pinball mediu pe decile: un singur scor care le răsplătește pe amîndouă

Noțiuni necesare azi (21/24): pierderea pinball și acoperirea



- Stînga: $\tau = 0,9$ costă de 9 ori mai mult pentru o valoare reală peste cuantilă decît sub ea, deci prognoza este împinsă în sus
- Dreapta: intervalele simulate de 80% acoperă 90% din valorile reale: prea largi (acoperire excesivă)

Noțiuni necesare azi (22/24): măsurile M4

- Competiția M4 [Makridakis, Spiliotis și Assimakopoulos \(2020\)](#): orizontul H , y_{n+h} valorile reale, $\hat{y}_{n+h}$ prognozele

$$\text{sMAPE} = \frac{200}{H} \sum_{h=1}^H \frac{|y_{n+h} - \hat{y}_{n+h}|}{|y_{n+h}| + |\hat{y}_{n+h}|}, \quad \text{MASE} = \frac{\frac{1}{H} \sum_h |y_{n+h} - \hat{y}_{n+h}|}{\frac{1}{n-m} \sum_{t=m+1}^n |y_t - y_{t-m}|}$$

- ▶ sMAPE: eroarea procentuală absolută medie simetrică, în %; MASE [Hyndman și Koehler \(2006\)](#): MAE scalat prin MAE în eșantion al naivului sezonier
- ▶ n : lungimea părții de antrenare; m : lungimea sezonului (24 pentru date orare)

- Repere și scorul general

$$\text{OWA} = \frac{1}{2} \left(\frac{\text{sMAPE}}{\text{sMAPE}_{\text{Naive 2}}} + \frac{\text{MASE}}{\text{MASE}_{\text{Naive 2}}} \right)$$

- ▶ naivul sezonier: $\hat{y}_{n+h} = y_{n+h-m}$ (aceeași oră din ultima zi)
- ▶ Naive 2: ultima valoare a seriei ajustate sezonier, cu sezonalitatea readăugată; $\text{OWA} < 1$: mai bun decât Naive 2

Noțiuni necesare azi (23/24): compararea prognozelor

- ▣ **Testul Diebold–Mariano** Diebold și Mariano (1995) (Capitolul 1): d_t = pierderea modelului 1 minus pierderea modelului 2, $t = 1, \dots, T$

$$DM = \frac{\bar{d}}{\sqrt{\hat{\Omega}/T}}, \quad \hat{\Omega} = \hat{\gamma}_0 + 2 \sum_{k=1}^{h-1} \hat{\gamma}_k, \quad DM_{HLN} = DM \sqrt{\frac{T+1-2h+h(h-1)/T}{T}}$$

- ▶ $\bar{d}$: diferența medie a pierderilor; $\hat{\gamma}_k$: autocovarianțele lui d_t ($h-1$ laguri pentru prognoze la h pași)
- ▶ HLN: corecția Harvey–Leybourne–Newbold pentru eșantioane mici, comparată cu Student t_{T-1} ; $DM < 0$: modelul 1 mai bun
- ▣ Mai multe modele deodată
 - ▶ MCS Hansen, Lunde și Nason (2011): mulțimea de încredere a modelelor, cele care nu sînt semnificativ mai slabe decît cel mai bun (prin bootstrap)
 - ▶ SPA Hansen (2005): testează dacă vreunul dintre mai multe modele este mai bun decît un reper, cu corecție pentru data snooping
- ▣ ARX expert pentru consum (Capitolul 1) Ziel și Weron (2018): cîte o regresie OLS pentru fiecare oră s a zilei $d+1$

$$L_{d+1,s} = \beta_1 L_{d,s} + \beta_2 L_{d-1,s} + \beta_3 L_{d-6,s} + \beta_4 L_d^{\min} + \beta_5 L_d^{\max} + \beta_6 L_{d,24} + \sum_{j=1}^7 \delta_j D_{j,d+1} + \varepsilon$$

- ▶ $L_{d,s}$: consumul zilei d , ora s ; $L_d^{\min}$, $L_d^{\max}$: minimul și maximul zilei d ; D_j : variabile pentru zilele săptămîinii; cuantilele din erorile empirice

Noțiuni necesare azi (24/24): valorile Shapley

- ▣ **Valoarea Shapley** [Shapley \(1953\)](#) a variabilei j pentru o prognoză $\hat{f}(x)$, p variabile, $N = \{1, \dots, p\}$

$$\varphi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)]$$

- ▶ $v(S)$: prognoza cînd sînt cunoscute doar variabilele din S ; paranteza: contribuția marginală a lui j la coaliția S
- ▶ ponderile mediază această contribuție peste toate ordinele în care pot fi adăugate variabilele

- ▣ **SHAP intervențional** [Lundberg și Lee \(2017\)](#): variabilele necunoscute sînt înlocuite cu rînduri dintr-un eșantion de fundal

$$v(S) = \frac{1}{|\mathcal{B}|} \sum_{z \in \mathcal{B}} \hat{f}(x_S, z_{N \setminus S})$$

- ▶ $\mathcal{B}$: eșantionul de fundal; x_S : variabilele lui x din S ; $z_{N \setminus S}$: celelalte variabile, luate din z
- ▶ calculul exact cere 2^p coaliții; grupurile de variabile (de exemplu, toate lagurile unei serii) reduc p

A1: lasso și ridge cu predictorii ortonormali [Rezolvat]

Cerință

- Coeficienții OLS $z = (2, 0; -0,6; 0,3; 1,2)$, $X'X = nI$, $\lambda = 0,5$.
- 1. Arătați că problema lasso se separă în $\frac{1}{2}(\beta_j - z_j)^2 + \lambda|\beta_j|$ și deduceți soluția prin prag moale.
- 2. Calculați coeficienții lasso și ridge.
- 3. Ce coeficienți anulează fiecare metodă?
- Raportați: o derivare; opt numere; o frază.

Rezolvare

- 1. $\|y - X\beta\|^2 / (2n) = \text{const} + \frac{1}{2}\|\beta - z\|^2$; subgradientul $0 \in \beta_j - z_j + \lambda\partial|\beta_j|$ dacă $\beta_j = 0$ dacă $|z_j| \leq \lambda$, altfel $z_j - \lambda \text{sign}(z_j)$
- 2. Lasso: 1,50; -0,10; 0,00; 0,70; ridge: 1,333; -0,400; 0,200; 0,800
- 3. Lasso anulează al treilea coeficient; ridge nu anulează niciunul
- Interpretare: lasso scade același λ din fiecare coeficient, deci coeficienții mari sînt deplasați cu λ ; ridge micșorează proporțional și nu selectează niciodată

A2: lasso adaptiv și elastic net [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Același z și $\lambda = 0,5$. Model: A1.
- ▣ 1. Lasso adaptiv cu ponderile $w_j = 1/|z_j|$ ($\gamma = 1$): calculați cele patru praguri și coeficienții.
- ▣ 2. Elastic net cu $\alpha = 0,5$: calculați $S(z_j, \lambda\alpha)/(1 + \lambda(1 - \alpha))$.
- ▣ 3. Comparați deplasarea celui mai mare coeficient pentru lasso, lasso adaptiv și elastic net.
- ▣ Raportați: opt numere; patru numere; o frază.

A3: varianța bagging-ului [Rezolvat]

Cerință

- B arbori, fiecare cu varianța $\sigma^2 = 1$, corelația între perechi $\rho = 0,3$.
- 1. Deduceți $\text{Var}(\frac{1}{B} \sum_b \hat{f}_b) = \rho\sigma^2 + (1 - \rho)\sigma^2/B$.
- 2. Calculați-o pentru $B = 1, 10, 100$ și limita ei.
- 3. Ce B aduce varianța la mai puțin de 5% peste limită?
- Raportați: o derivare; patru numere; un număr.

Rezolvare

- 1. $\frac{1}{B^2} [\sum_b \text{Var} \hat{f}_b + \sum_{b \neq c} \text{Cov}(\hat{f}_b, \hat{f}_c)] = \frac{1}{B^2} [B\sigma^2 + B(B-1)\rho\sigma^2]$
- 2. 1,000; 0,370; 0,307; limita 0,30
- 3. $(1 - \rho)/B \leq 0,05\rho \Rightarrow B \geq 47$
- Interpretare: peste cîteva zeci de arbori, doar decorelarea (subeșantionarea variabilelor în pădurile aleatoare) mai scade varianța

A4: boosting-ul ca coborîre pe gradient [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Pierderea pătratică $\ell = \frac{1}{2}(y - F)^2$, rata de învățare $\nu = 0,1$, algoritmul de bază: o constantă (un arbore fără ramificări), $F_0 = 0$. Model: A3.
- ▣ 1. Arătați că gradientul negativ este reziduul și că $F_M = (1 - (1 - \nu)^M)\bar{y}$.
- ▣ 2. Calculați $F_M/\bar{y}$ pentru $M = 10$ și 50 și M necesar pentru 90%.
- ▣ 3. Scrieți gradientul negativ al pierderii pinball $\rho_\tau(y - F)$.
- ▣ Raportați: o derivare; trei numere; o formulă.

A5: gradientii printr-un RNN scalar [Rezolvat]

Cerință

- $h_t = \tanh(wh_{t-1} + ux_t)$ cu $w = 0,9$.
- 1. Arătați că $\partial h_T / \partial h_{T-k} = \prod_{j=0}^{k-1} w(1 - h_{T-j}^2)$ și că $|\partial h_T / \partial h_{T-k}| \leq |w|^k$.
- 2. Calculați marginea pentru $k = 10$ și $k = 50$.
- 3. Dacă $|h_t| = 0,5$ pe traiectorie, calculați factorul efectiv pe pas și gradientul la $k = 10$ și 50 .
- Raportați: o derivare; două numere; trei numere.

Rezolvare

- 1. Regula lanțului: $\partial h_t / \partial h_{t-1} = w \tanh'(\cdot) = w(1 - h_t^2)$, iar $0 < 1 - h_t^2 \leq 1$
- 2. $0,9^{10} = 0,349$, $0,9^{50} = 0,00515$
- 3. Factorul $0,675$; $0,0196$ la $k = 10$, $2,9 \times 10^{-9}$ la $k = 50$
- Interpretare: saturarea unităților accelerează stingerea; un semnal de acum 50 de pași nu mai poate modifica ponderile

A6: poarta de uitare LSTM [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Calea celulei LSTM $c_t = f_t c_{t-1} + i_t \tilde{c}_t$, cu poarta de uitare constantă $f = \sigma(b_f)$. Model: A5.
- ▣ 1. Arătați că drumul direct dă $\partial c_T / \partial c_{T-k} = f^k$.
- ▣ 2. Calculați f pentru $b_f = 0, 1, 3$ și f^{50} în fiecare caz.
- ▣ 3. De ce inițializarea implicită nu protejează împotriva stingerii gradientilor?
- ▣ Raportați: o derivare; șase numere; o frază.

A7: atenția calculată de mîină [Rezolvat]

Cerință

- ▣ Cheile $k_1 = (1, 0)$, $k_2 = (0, 1)$, $k_3 = (1, 1)$; valorile $v = (1, 2, 3)$; interogarea $q = (1, 1)$; $d_k = 2$.
- ▣ 1. Calculați scorurile $qk_j / \sqrt{d_k}$.
- ▣ 2. Calculați ponderile softmax și ieșirea.
- ▣ 3. Ce se întîmplă cu ponderile dacă cei trei tokeni sînt permutați?
- ▣ Raportați: trei numere; patru numere; o frază.

Rezolvare

- ▣ 1. 0,707; 0,707; 1,414
- ▣ 2. Ponderile 0,248; 0,248; 0,503; ieșirea 2,255
- ▣ 3. Ponderile se permută odată cu tokenii, iar ieșirea nu se schimbă: atenția ignoră ordinea, dacă pozițiile nu sînt codificate
- ▣ Interpretare: critica lui Zeng et al. pornește de aici: o serie de timp este un obiect ordonat

A8: DLinear este o singură aplicație liniară [Propus]

Rezolvarea se discută la seminar



Cerință

- ▣ $L = 3$ intrări, o ieșire, medie mobilă de lungime 3 cu repetarea capetelor; $W_s = (0,2; 0,3; 0,5)$, $W_t = (0,1; 0,1; 0,8)$. Model: A7.
- ▣ 1. Scrieți matricea 3×3 A cu trendul $= Ax$.
- ▣ 2. Arătați că prognoza este Wx cu $W = W_s(I - A) + W_tA$ și calculați W .
- ▣ 3. Ce implică rezultatul pentru expresivitatea DLinear?
- ▣ Raportați: o matrice; trei numere; o frază.

B1: validarea HAR pe varianța realizată FTSE 100 [Rezolvat]

- **Întrebarea:** estimează validarea încrucișată aleatoare și cea pe blocuri eroarea viitoare a HAR, pentru ținte de o zi și de 22 de zile?
- **Date:** RV de 5 minute Oxford-Man pentru FTSE 100, $n = 5\,543$ rînduri; datele de estimare: primele 80% (pînă la 5 septembrie 2017); HAR pe log RV
- **Cerințe**
 1. Estimați RMSE pe datele de estimare prin 5 subeșantioane aleatoare, 5 blocuri, 5 blocuri cu purjare de h rînduri și ultimele 20% din datele de estimare.
 2. Calculați RMSE adevărat: modelul estimat pe datele de estimare, evaluat pe ultimele 20% din eșantion.
 3. Repetați pentru ținta „media log RV din următoarele 22 de zile”.
 4. Interpretare: în ce schemă ați avea încredere și de ce sînt toate sub eroarea adevărată?
- **Raportați:** zece valori RMSE, o frază
- Notebook: secțiunea B1

B1: rezolvare (1/2) [Rezolvat]



B1: rezolvare (2/2) [Rezolvat]

ținta	aleator	blocuri	purjare	ultimele 20%	adevărat
ziua următoare	0,572	0,573	0,573	0,626	0,681
media pe 22 de zile	0,434	0,442	0,442	0,453	0,514

- Ziua următoare: aleator și pe blocuri coincid (erorile HAR sînt aproape necorelate, cazul Bergmeir–Hyndman–Koo); media pe 22 de zile: aleator este mai mic (0,434 față de 0,442): țintele suprapuse produc scurgeri
- Interpretare: nicio schemă nu surprinde episodul de volatilitate din 2020 al perioadei de evaluare: validarea estimează riscul regimului trecut; ultimul bloc este cel mai realist


B2: o pădure aleatoare cu indice de timp [Propus]

- **Întrebarea:** cât de mult crește un indice de timp optimismul validării încrucișate aleatoare?
- **Date:** Logaritmul RV pentru DAX (Oxford-Man); pădure aleatoare (100 de arbori) pe cele 22 de laguri; ținta: media $\log RV$ din următoarele 22 de zile; model: B1
- **Cerințe**
 1. Calculați cele patru estimatii prin validare și RMSE adevărat doar cu lagurile.
 2. Adăugați numărul rîndului ca variabilă și repetați.
 3. Interpretare: ce schemă este păcălită de indicele de timp și care nu?
- **Raportați:** zece valori RMSE, o frază
- Notebook: secțiunea B2

B3: AR local și global pentru inflația UE [Rezolvat]

- **Întrebarea:** prognozează un singur model AR pentru toate cele 27 de țări inflația anuală peste trei luni mai bine decât 27 de modele separate?
- **Date:** Rate anuale IAPC Eurostat, 27 de țări UE, ferestre mobile de 120 de luni, 137 de origini din ianuarie 2015; prognoze directe $h = 3$
- **Cerințe**
 1. Estimați $AR(p)$ local (o regresie OLS pe țară) și $AR(p)$ global (o regresie OLS reunită) pentru $p = 3, 12, 24$.
 2. Calculați RMSE pentru cele 27 de țări și pentru România.
 3. Calculați statistica DM a modelului global față de cel local pe pierderea medie a țărilor.
 4. Interpretare: de ce crește diferența odată cu p ?
- **Raportați:** douăsprezece valori RMSE, trei statistici DM, o frază
- Notebook: secțiunea B3

B3: rezolvare (1/2) [Rezolvat]



B3: rezolvare (2/2) [Rezolvat]

p	local	global	DM (27)	p-value	local RO	global RO
3	1,589	1,514	-1,56	0,121	1,463	1,498
12	1,660	1,386	-2,29	0,024	1,327	1,373
24	1,766	1,376	-3,11	0,002	1,395	1,372

- Interpretare: AR local se deteriorează cu p (circa 100 de rânduri pentru $p + 1$ coeficienți), AR global se îmbunătățește (2700 de rânduri); la $p = 24$ câștigul global este semnificativ ($p = 0,002$); pentru România separat diferența nu este semnificativă


B4: lasso pe panel pentru România [Propus]

- ▣ **Întrebarea:** ajută ratele inflației celorlalte 26 de țări UE la prognoza inflației României peste trei luni?
- ▣ **Date:** 3 laguri proprii (nepenalizate) și 3 laguri ale celorlalte 26 de țări; ferestre mobile de 120 de luni, reestimare la 3 luni; penalizarea prin 5 blocuri cu purjare de 3 luni; model: B3
- ▣ **Cerințe**
 1. Prognozați cu AR(3), ridge, lasso, lasso adaptiv, elastic net, OLS după lasso și AR(12) global.
 2. Calculați RMSE și testul DM al fiecărui model față de AR(3).
 3. Raportați numărul median de predictor selectați și cele trei țări selectate cel mai des.
 4. Interpretare: merită aici panelul în dimensiune mare?
- ▣ **Raportați:** șapte valori RMSE, șase p-value-uri DM, rezumatul selecției, o frază
- ▣ Notebook: secțiunea B4

B5: QRF și ARX pentru vârful de seară [Rezolvat]

- **Întrebarea:** dă o pădure de regresie cuantilică cuantile mai bune pentru ziua următoare decât ARX-ul expert pentru consumul de la 19:00–20:00?
- **Date:** Consumul orar al României, ora 19:00–20:00; 638 de zile de prognoză din ianuarie 2025; QRF (200 de arbori, frunze de cel puțin 5) reestimat lunar pe toate datele anterioare; ARX cu cuantile empirice ale erorilor ([Capitolul 1](#))
- **Cerințe**
 1. Calculați decilele ambelor metode pentru fiecare zi.
 2. Calculați pierderea pinball medie, acoperirea de 80%, lățimea medie a intervalului de 80% și MAE al prognozei punctuale.
 3. Testați cu DM diferența pierderilor pinball zilnice.
 4. Interpretare: ce benzi ar prefera un operator de rețea?
- **Raportați:** opt numere, o statistică DM, o frază
- **Notebook:** secțiunea B5

B5: rezolvare (1/2) [Rezolvat]



B5: rezolvare (2/2) [Rezolvat]

	pinball (MW)	acoperire 80%	lățime (MW)	MAE (MW)
QRF	78,5	86,7%	784	195
ARX	77,6	77,6%	530	187

- DM pe diferența pinball: 0,40 ($p = 0,69$): nicio diferență semnificativă
- Interpretare: benzile QRF sînt mai largi și acoperă prea mult (86,7%), cele ARX sînt mai înguste și acoperă puțin prea puțin; scoruri egale, deci alegerea depinde de costul unui deficit pentru operator


B6: boosting monoton pentru vârful de seară [Propus]

- ▣ **Întrebarea:** costă acuratețe obligarea prognozei să crească odată cu consumul din zilele anterioare, la vârful de seară?
- ▣ **Date:** aceleași rînduri ca în B5; histogram gradient boosting (300 de iterații, 15 frunze), cu și fără restricții crescătoare pe cele trei laguri ale consumului, reestimat lunar; model: B5
- ▣ **Cerințe**
 1. Calculați MAE pentru ambele modele și testul DM al erorilor absolute.
 2. Numărați pașii descrescători ai dependenței parțiale de consumul din ziua d în prima estimare.
 3. Interpretare: merită aici restricția costul ei?
- ▣ **Raportați:** două valori MAE, o statistică DM, două numărători, o frază
- ▣ Notebook: secțiunea B6

B7: LSTM față de HAR pentru FTSE 100 [Rezolvat]

- ▣ **Întrebarea:** prognozează un LSTM pe ultimele 22 de zile varianța realizată de a doua zi mai bine decât HAR?
- ▣ **Date:** Logaritmul RV pentru FTSE 100; fereastră extinsă de la 2500 de zile, reestimare la 500 de zile; prognoze 8 decembrie 2009 – 25 februarie 2022 ($T = 3085$); LSTM cu 16 unități, media a trei seed-uri
- ▣ **Cerințe**
 1. Prognozați RV_{t+1} cu HAR și LSTM, cu corecția lognormală.
 2. Calculați QLIKE mediu pentru amândouă și raportul lor.
 3. Calculați statistica DM.
 4. Interpretare: ați înlocui HAR?
- ▣ **Raportați:** două pierderi, un raport, o statistică DM, o frază
- ▣ Notebook: secțiunea B7

B7: rezolvare [Rezolvat]



- QLIKE: HAR 0,2486, LSTM 0,2474; raportul 0,995; DM $-0,63$ ($p = 0,53$)
- Interpretare: LSTM nu se distinge de HAR; costă seed-uri, reglare și minute de antrenare fără un câștig măsurabil: păstrați HAR sau faceți media celor două

B8: DLinear și N-BEATS pe 100 de serii orare M4 [Propus]

- ▣ **Întrebarea:** mai depășește un N-BEATS global reperele atunci când este antrenat doar pe 100 de serii?
- ▣ **Date:** primele 100 de serii orare M4, orizont 48, intrare de 336 de ore, un seed; model: B7
- ▣ **Cerințe**
 1. Prognozați cu Naive 2, naivul sezonier, DLinear global și N-BEATS global.
 2. Calculați sMAPE, MASE și OWA.
 3. Interpretare: comparați cu cursul, unde N-BEATS a folosit toate cele 414 serii și trei seed-uri.
- ▣ **Raportați:** douăsprezece numere, o frază
- ▣ Notebook: secțiunea B8

C1: algoritmi deep față de HAR pentru criptoactive [Propus]

- **Întrebarea:** este volatilitatea cripto, cu tranzacționare 24/7 și schimbări frecvente de regim, un loc în care algoritmii sînt mai buni decît HAR?
- **Date:** RV zilnică din randamente de 5 minute pentru Bitcoin și Ether, din prețuri Binance la un minut, 2018–2026; fereastră extinsă de la 1000 de zile, reestimare la 250 de zile; model: B7
- **Cerințe**
 1. Scrieți o preînregistrare de cinci rînduri: ipoteza, algoritmii, orizonturile, pierderea și testul, ce v-ar face să vă schimbați concluzia.
 2. Prognozați cu HAR, un MLP și boosting la $h = 1$ și $h = 5$; calculați rapoartele QLIKE și testele DM față de HAR.
 3. Interpretare: ce susțin datele și cum ați extinde studiul?
- **Raportați:** un plan de cinci rînduri, opt rapoarte cu p-value-uri, un plan de proiect
- Notebook: secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre machine learning pentru serii de timp. Răspunsul:
- (a) Validarea încrucișată cu K subeșantioane aleatoare nu este niciodată validă pentru serii de timp.
- (b) Un TCN cu nucleul 3 și dilatățile 1, 2, 4, 8 (două convoluții pe bloc) vede ultimele 31 de ore.
- (c) Cu suficienți arbori, bagging-ul aduce varianța prognozei la zero.
- (d) LSTM nu suferă niciodată de stingerea gradientilor, datorită porților.
- (e) Zeng et al. (2023) au demonstrat că orice Transformer este mai slab decât un model liniar.
- (f) Segmentul cu cea mai mare pondere de atenție este cel de care prognoza depinde cel mai mult.
- (g) Valorile Shapley ale tuturor variabilelor au suma egală cu prognoza minus prognoza medie pe eșantionul de fundal.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de șapte verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Validați pe blocuri, cu purjare, când țintele se suprapun sau variabilele poartă timpul; K subeșantioane aleatoare doar pentru autoregresii bine specificate
- ▣ Reunirea seriilor (modele globale) permite o memorie mai lungă; selecția pe paneluri scurte este instabilă
- ▣ Ansambluri: pragul varianței este $\rho\sigma^2$; boosting-ul ajustează gradienti; restricțiile trebuie să fie corecte peste tot
- ▣ Porțile și atenția au o algebră simplă: porțile de uitare trebuie să fie deschise, atenția ignoră ordinea
- ▣ Reperele puternice (HAR, ARX expert, naiv sezonier) sînt greu de depășit; testați fiecare afirmație

După seminar

- ▣ Cursul 12 dezvoltă fiecare temă de azi: teoria învățării pentru date dependente, inferența în dimensiune mare, ansamblurile de arbori, modelele recurente și cu atenție, N-BEATS, DeepAR și comparațiile riguroase
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: algoritmi față de HAR pentru criptoactive, preînregistrat
- ▣ Lectură: [Bergmeir, Hyndman și Koo \(2018\)](#); [Montero-Manso și Hyndman \(2021\)](#); [Zeng et al. \(2023\)](#); [Oreshkin et al. \(2020\)](#)
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie (1/2)

- ▣ Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. [arXiv:1803.01271](https://arxiv.org/abs/1803.01271). [arxiv.org](https://arxiv.org/abs/1803.01271)
- ▣ Bengio, Y., Simard, P., & Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2), 157–166. doi:10.1109/72.279181
- ▣ Bergmeir, C., Hyndman, R. J., & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83. doi:10.1016/j.csda.2017.11.003
- ▣ Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140. doi:10.1007/BF00058655
- ▣ Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi:10.1023/A:1010933404324
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jjfinec/nbp001
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- ▣ Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. doi:10.1198/073500105000000063
- ▣ Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497. doi:10.3982/ECTA5771
- ▣ Heber, G., Lunde, A., Shephard, N., & Sheppard, K. K. (2009). Oxford-Man Institute's realized library, version 0.3. Oxford-Man Institute, University of Oxford. web.archive.org
- ▣ Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. doi:10.1162/neco.1997.9.8.1735
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Jain, S., & Wallace, B. C. (2019). Attention is not explanation. *Proceedings of NAACL-HLT 2019*, 3543–3556. doi:10.18653/v1/N19-1357

Bibliografie (2/2)

- ▣ Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. proceedings.neurips.cc
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. doi:10.1016/j.ijforecast.2019.04.014
- ▣ Meinshausen, N. (2006). Quantile regression forests. *Journal of Machine Learning Research*, 7, 983–999. jmlr.org
- ▣ Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting*, 37(4), 1632–1653. doi:10.1016/j.ijforecast.2021.03.004
- ▣ Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with Transformers. *International Conference on Learning Representations*. arXiv:2211.14730. arxiv.org
- ▣ Oreshkin, B. N., Carpo, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations*. arXiv:1905.10437. arxiv.org
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Shapley, L. S. (1953). A value for n -person games. In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games II*, 307–318. Princeton University Press. doi:10.1515/9781400881970-018
- ▣ Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288. doi:10.1111/j.2517-6161.1996.tb02080.x
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. proceedings.neurips.cc
- ▣ Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128. doi:10.1609/aaai.v37i9.26317
- ▣ Ziel, F., & Weron, R. (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics*, 70, 396–420. doi:10.1016/j.eneco.2017.12.016
- ▣ Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320. doi:10.1111/j.1467-9868.2005.00503.x
- ▣ Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429. doi:10.1198/016214506000000735