



Analiza avansată a seriilor de timp și previziune

Seminarul 13: Foundation models și predicție conformală



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACI**: Adaptive Conformal Inference (inferență conformală adaptivă)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AIC**: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **AR**: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ **ARX**: AutoRegressive model with eXogenous variables (model autoregresiv cu variabile exogene)
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BG**: Bulgaria (Eurostat country code) — Bulgaria (codul de țară Eurostat)
- ▣ **BH**: Benjamini–Hochberg (procedure) — procedura Benjamini–Hochberg
- ▣ **CQR**: Conformalized Quantile Regression (regresia cuantilică conformalizată)
- ▣ **CRPS**: Continuous Ranked Probability Score (scorul probabilistic continuu)
- ▣ **CZ**: Czechia (Eurostat country code) — Cehia (codul de țară Eurostat)
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **ENTSO-E**: European Network of Transmission System Operators for Electricity (Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **FDR**: False Discovery Rate (rata descoperirilor false)

Acronime folosite în acest material (2/2)

- ▣ **FWER**: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **GW**: Giacomini–White (test of conditional predictive ability) — testul Giacomini–White de capacitate predictivă condiționată
- ▣ **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- ▣ **HAR**: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- ▣ **HICP**: Harmonised Index of Consumer Prices (indicele armonizat al prețurilor de consum (IAPC))
- ▣ **HU**: Hungary (Eurostat country code) — Ungaria (codul de țară Eurostat)
- ▣ **LLM**: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **PID**: Proportional–Integral–Derivative (controller) — controler proporțional–integral–derivat
- ▣ **PL**: Poland (Eurostat country code) — Polonia (codul de țară Eurostat)
- ▣ **RV**: Realised Variance (varianța realizată)
- ▣ **SK**: Slovakia (Eurostat country code) — Slovacia (codul de țară Eurostat)
- ▣ **TVA**: Taxa pe valoarea adăugată
- ▣ **UE**: Uniunea Europeană
- ▣ **WIG20**: Warszawski Indeks Giełdowy 20 (indicele celor mai mari 20 de companii de la Bursa din Varșovia)

Întrebarea de azi și structura seminarului

- ▣ Întrebarea seminarului
 - ▶ **cît de bune sînt prognozele zero-shot ale modelelor preantrenate pe datele noastre și cum transformăm orice prognoză în intervale cu acoperire controlată cînd datele sînt dependente?**
- ▣ Rezultate de obținut
 - ▶ răspunsurile la exercițiile A
 - ▶ cîte o figură și un tabel pentru fiecare exercițiu B
 - ▶ analiza cerută în **C1** și verdictele asupra răspunsului A1 din **C2**, fiecare cu un rînd de justificare
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Exercițiile, tipurile și ordinea lor: Harta exercițiilor (slide-ul următor)
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	split conformal de mînă; legea Beta și mărimea calibrării	Rezolvat, Propus	A1
A3, A4	ACI și urmărirea cuantilei de mînă; marginile pe termen lung	Rezolvat, Propus	A3
A5, A6	CQR de mînă; cuantile conformale ponderate	Rezolvat, Propus	A5
A7, A8	tokenizatorul Chronos; limitele domeniului și scalarea arcsinh	Rezolvat, Propus	A7
B1, B2	consumul României după lansări; covariabile de calendar în context	Rezolvat, Propus	B1
B3, B4	conformal static, mobil și adaptiv pentru BET; designul ACI pe DAX	Rezolvat, Propus	B3
B5, B6	CQR online pentru prognozele RV Bitcoin; EnbPI pe vîrfurile de consum	Rezolvat, Propus	B5
B7, B8	inflația din Europa Centrală și de Est cu Holm și BH; VaR pentru WIG20	Rezolvat, Propus	B7
C1, C2	o prognoză preînregistrată a inflației; ce este greșit într-un răspuns AI?	Propus	B5, A1–A8

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model; rezolvarea se discută la seminar
- Partea A: calcule și derivări pe hîrtie; Partea B: date reale, rezolvate în notebook, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Seria	Sursa	Frecvența, perioada
Consumul de electricitate al României	Energy-Charts (ENTSO-E)	orar, 2022–2026
Inflația anuală HICP, țări UE	Eurostat	lunar, 2000–2026
Varianța realizată Bitcoin	Binance, randamente de 5 minute	zilnic, 2018–2026
BET, DAX, WIG20	EODHD	zilnic, 2000–2026

- ▣ Randamentele sînt diferențe logaritmice înmulțite cu 100
- ▣ În notebook; nu este nevoie de cont sau de cheie
 - ▶ `fm_forecast`, `conformal_quantile`, `online_threshold`, `cqr`, `enbpi`
 - ▶ `dm_test`, `holm`, `bh`, `kupiec`, `christoffersen`

Noțiuni necesare azi (1/23): foundation models

- ▣ Un **foundation model** este o rețea $f_{\hat{\theta}}$ preantrenată o singură dată pe un corpus de multe serii; $\hat{\theta}$: ponderile ei estimate
- ▣ Folosirea **zero-shot**: prognoza unei serii noi $y_1, \dots, y_T$ este rețeaua aplicată ultimelor ei C valori; nimic nu se estimează pe seria nouă

$$\hat{y}_{T+1:T+H} = f_{\hat{\theta}}(y_{T-C+1:T})$$

► C : lungimea contextului; H : orizontul; T : originea prognozei

- ▣ **Ieșiri**: prognoze ale cuantilelor $\hat{q}_{\tau}$ la niveluri fixe τ
 - $\hat{q}_{\tau}$: valoarea sub care rezultatul cade cu probabilitatea τ , după model
 - Chronos-Bolt, TimesFM 2.5, TiRex: 10%–90% (decile); Chronos-2: 1%–99% [Ansari et al. \(2025\)](#)
- ▣ **Covariabile în context** (Chronos-2): valorile trecute ale covariabilelor și valorile viitoare ale celor cunoscute dinainte (calendarul) se transmit odată cu seria-țintă
 - efectul lor este dedus în timpul trecerii înainte, nu estimat
- ▣ **Contaminarea**: fereastra de test poate face parte din datele de antrenare
 - evaluați după lansarea tuturor modelelor (aici: din 1 noiembrie 2025)

Noțiuni necesare azi (2/23): tokenizatorul Chronos


- ▣ **Scalarea prin medie** Ansari et al. (2024): fiecare valoare din context se împarte la media valorilor absolute din context

$$s = \frac{1}{C} \sum_{t=1}^C |y_t|, \quad \tilde{y}_t = y_t/s$$

► s : scala; $\tilde{y}_t$: valoarea scalată

- ▣ **Cuantizarea**: 4093 de centre de interval egal distanțate pe $[-15, 15]$; fiecare valoare scalată este înlocuită cu cel mai apropiat centru, iar indicele acestuia este token-ul ei
 - distanța dintre două centre vecine: $30/4092$ în unități scalate, $30s/4092$ în unitățile datelor
 - **valoarea decuantizată**: centrul înmulțit cu s ; eroarea de cuantizare este cel mult jumătate din distanța dintre centre
- ▣ **Limita domeniului**: valorile peste $15s$ sînt trunchiate la ultimul centru și nu pot fi prognozate
 - Chronos-2 folosește în schimb $\operatorname{arcsinh}(y/s)$, cu $\operatorname{arcsinh}(x) = \ln(x + \sqrt{x^2 + 1})$: apropiat de x lîngă 0 și de $\ln(2x)$ pentru x mare

Noțiuni necesare azi (3/23): domeniul tokenizatorului



- Stînga: intervalele uniforme reprezintă o valoare scalată $x = y/s$ doar pînă la 15; $\text{arcsinh}(x)$ nu are plafon și crește ca $\ln(2x)$
 - ▶ arcsinh comprimă valorile mari în loc să le taie: o valoare de 1000 de ori scala devine $\text{arcsinh}(1000) \approx 7,6$
- Dreapta: o serie intermitentă simulată (zero în majoritatea zilelor); scala $s = 0,36$, limita $15s = 5,34$
 - ▶ valoarea rară 14 este de 39 de ori scala: cu scalarea prin medie se află în afara domeniului și nu poate fi prognozată
 - ▶ multe zerouri fac scala s mică, deci limita $15s$ este joasă

Noțiuni necesare azi (4/23): scoruri pentru prognozele de cuantile

- ▣ **Pierdere pinball** a unei prognoze de cuantilă $\hat{q}_\tau$ pentru rezultatul y

$$\rho_\tau(u) = u(\tau - 1\{u < 0\}), \quad u = y - \hat{q}_\tau$$

- ▶ $1\{\cdot\}$: 1 dacă condiția este îndeplinită, 0 altfel; un rezultat peste cuantilă costă τu , unul sub cuantilă costă $(1 - \tau)|u|$
- ▶ valoarea ei așteptată este minimă în cuantila τ adevărată


- ▣ **CRPS** aproximat din K niveluri de cuantile $\tau_1, \dots, \tau_K$ (aici cele nouă decile)

$$\text{CRPS} \approx \frac{2}{K} \sum_{k=1}^K \rho_{\tau_k}(y - \hat{q}_{\tau_k})$$

- ▶ evaluează întreaga distribuție predictivă, în unitățile lui y ; o valoare mai mică este mai bună

- ▣ **MAE** al medianei: media lui $|y - \hat{q}_{0,5}|$

Noțiuni necesare azi (5/23): pierderea pinball și scorurile intervalelor



- Stînga: $\rho_\tau(u)$ are panta τ pentru $u > 0$ și $-(1 - \tau)$ pentru $u < 0$; pentru $\tau = 0,5$ este jumătate din eroarea absolută
- Dreapta: pentru $Y \sim N(0, 1)$ și $\tau = 0,9$, pierderea așteptată este minimă în cuantila adevărată $q_{0,9} = 1,28$
- Acoperirea și lățimea medie** a intervalelor $[l_t, u_t]$ pe n prognoze

$$\widehat{\text{cov}} = \frac{1}{n} \sum_{t=1}^n 1\{l_t \leq y_t \leq u_t\}, \quad \bar{w} = \frac{1}{n} \sum_{t=1}^n (u_t - l_t)$$

- un interval bun are $\widehat{\text{cov}}$ apropiată de nivelul nominal (de exemplu 0,80 pentru banda 10–90%) și cea mai mică $\bar{w}$

Noțiuni necesare azi (6/23): prognozele de referință

- **Prognoza naivă săptămînală** pentru consumul orar: $\hat{y}_{d,h} = y_{d-7,h}$
 - ▶ $y_{d,h}$: consumul din ziua d la ora h ; prognoza repetă aceeași oră de acum o săptămîină
- **ARX expert Ziel și Weron (2018)**: cite o regresie prin cele mai mici pătrate pentru fiecare oră h , pe o fereastră mobilă

$$y_{d,h} = \beta_0 + \beta_1 y_{d-1,h} + \beta_2 y_{d-2,h} + \beta_3 y_{d-7,h} + \beta_4 \underline{y}_{d-1} + \beta_5 \bar{y}_{d-1} + \beta_6 y_{d-1,24} + \sum_j \delta_j D_{j,d} + \varepsilon_{d,h}$$

- ▶ $\underline{y}_{d-1}$, $\bar{y}_{d-1}$: consumul minim și maxim din ziua precedentă; $y_{d-1,24}$: ultima ei oră
- ▶ $D_{j,d}$: 1 dacă ziua d este luni, sîmbătă sau duminică (j), 0 altfel; lagurile 1, 2 și 7: persistența și ciclul săptămînal
- ▶ cuantilele: prognoza punctuală plus cuantilele empirice ale erorilor recente la aceeași oră
- **AR(p)** pentru inflație, cu p ales după AIC

$$y_t = c + \sum_{j=1}^p \phi_j y_{t-j} + \varepsilon_t, \quad \text{AIC}(p) = T \ln \hat{\sigma}_p^2 + 2(p+1)$$

- ▶ ϕ_j : coeficienții autoregresivi; $\hat{\sigma}_p^2$: varianța reziduală a AR(p); T : volumul eșantionului
- ▶ penalizarea $2(p+1)$ numără coeficienții; se păstrează ordinul cu cel mai mic AIC

Noțiuni necesare azi (7/23): compararea a două modele

- ▣ **Testul DM–HLN** (Capitolul 1): sînt egale pierderile așteptate a două modele A și B? Statistica este pe slide-ul următor
 - ▶ $t < 0$: modelul A are pierderea mai mică
- ▣ **Pe mai multe serii**: raportul $r_s = L_s(\text{model})/L_s(\text{referință})$ pe seria s , combinat prin media geometrică Fleming și Wallace (1986)

$$\bar{r}_{\text{geo}} = \exp\left(\frac{1}{S} \sum_{s=1}^S \ln r_s\right)$$

- ▶ L_s : o pierdere pe seria s ; S : numărul de serii; $\bar{r}_{\text{geo}} < 1$: modelul întrece în medie modelul de referință

Noțiuni necesare azi (8/23): statistica DM–HLN

- Diferența de pierdere la originea t și media ei pe n origini; $H_0: E[d_t] = 0$

$$d_t = L(e_{A,t}) - L(e_{B,t}), \quad \bar{d} = \frac{1}{n} \sum_{t=1}^n d_t$$

- ▶ $e_{A,t}$, $e_{B,t}$: erorile de prognoză ale modelelor A și B; L : pierderea (eroarea absolută, pinball, CRPS)

- **Varianța HAC** a lui $\bar{d}$: se adună autocovarianțele lui d_t pînă la lagul ℓ

$$\hat{\Omega} = \hat{\gamma}_0 + 2 \sum_{j=1}^{\ell} w_j \hat{\gamma}_j, \quad \hat{\gamma}_j = \frac{1}{n} \sum_{t=j+1}^n (d_t - \bar{d})(d_{t-j} - \bar{d})$$

- ▶ $\hat{\gamma}_j$: autocovarianța la lagul j ; aici $w_j = 1$ și $\ell = h - 1$ (h : orizontul) sau ponderi Bartlett $w_j = 1 - j/(\ell + 1)$; B7 folosește $\ell = 5$

- **Statistica Diebold și Mariano (1995)** cu corecția pentru eșantioane mici [Harvey, Leybourne și Newbold \(1997\)](#)


$$DM = \frac{\bar{d}}{\sqrt{\hat{\Omega}/n}}, \quad DM_{HLN} = DM \sqrt{\frac{n+1-2h+h(h-1)/n}{n}}$$

- ▶ distribuția de referință: Student- t cu $n - 1$ grade de libertate; $p\text{-value} = 2 \Pr\{t_{n-1} > |DM_{HLN}|\}$

Noțiuni necesare azi (9/23): teste pe multe serii

- Cu S teste, fiecare la 5%, sub H_0 se așteaptă aproximativ $0,05S$ respingeri false; $p_{(1)} \leq \dots \leq p_{(S)}$: p-value-urile ordonate crescător
- **Holm** [Holm \(1979\)](#) controlează FWER, probabilitatea a cel puțin unei respingeri false
 - ▶ se respinge cât timp $p_{(k)} \leq \alpha / (S - k + 1)$, $k = 1, 2, \dots$; se oprește la primul eșec
- **Benjamini–Hochberg** [Benjamini și Hochberg \(1995\)](#) controlează FDR, proporția așteptată a respingerilor false printre respingeri
 - ▶ se resping cele mai mici k^* p-value-uri, $k^* = \max\{k : p_{(k)} \leq k\alpha / S\}$
- **Testul agregat**: se mediază d_t pe serii la fiecare origine, apoi se aplică un singur test DM pe această medie

Noțiuni necesare azi (10/23): trei corecții pe 20 de teste



- Simulare: 20 de teste, 6 cu un efect real; $\alpha = 0,05$
 - ▶ un p-value este respins când se află sub linia lui
- Liniile: pragurile de pe slide-ul anterior, în funcție de rangul k ; Bonferroni: α/S pentru orice k
 - ▶ Holm se oprește la primul p-value aflat peste linia lui
 - ▶ BH respinge toate p-value-urile pînă la ultimul aflat sub linia lui
- Respingeri aici: 6 fără corecție, 1 Bonferroni, 1 Holm, 3 BH
 - ▶ controlul FWER este mai strict decît controlul FDR: Holm respinge mai puține ipoteze decît BH

Noțiuni necesare azi (11/23): split conformal


- Date **interschimbabile** $Z_i = (X_i, Y_i)$, $i = 1, \dots, n+1$: legea comună nu se schimbă la reordonarea punctelor (i.i.d. este un caz particular)
 - ▶ X_i : predictorii; Y_i : valoarea de acoperit; punctul $n+1$ este punctul de test
- Un **scor de neconformitate** $s(x, y)$ este mare când y este neobișnuit dat fiind x , de exemplu $|y - \hat{f}(x)|$, unde $\hat{f}$ este o prognoză punctuală
- **Split conformal** [Lei et al. \(2018\)](#): cu cele n scoruri de calibrare $S_i = s(X_i, Y_i)$ și rata de ratare α

$$k = \lceil (n+1)(1-\alpha) \rceil, \quad \hat{q} = S_{(k)}, \quad \hat{C}(x) = \{y : s(x, y) \leq \hat{q}\}$$


- ▶ $S_{(k)}$: al k -lea cel mai mic scor; $\lceil \cdot \rceil$: rotunjirea în sus; $\hat{q} = +\infty$ dacă $k > n$; cu $|y - \hat{f}(x)|$ mulțimea este $\hat{f}(x) \pm \hat{q}$
- **Garanția** sub interschimbabilitate (fără egalități)

$$1 - \alpha \leq \Pr\{Y_{n+1} \in \hat{C}(X_{n+1})\} \leq 1 - \alpha + \frac{1}{n+1}$$

Noțiuni necesare azi (12/23): pragul conformal și legea lui Beta



- scoruri ordonate $S_{(i)}$
- $\hat{q} = S_{(18)}, k = \lceil 20 \cdot 0,9 \rceil$




- $n = 9$
- $n = 49$
- $n = 499$
- - - media 0,90

- Stînga: 19 reziduuri absolute simulate; cu $\alpha = 0,1$, $\hat{q}$ este al 18-lea cel mai mic scor (aici 1,57)
- Dreapta: acoperirea realizată C , condiționat de setul de calibrare, are densitatea $\text{Beta}(k, n + 1 - k)$

$$f(c) = \frac{c^{k-1}(1-c)^{n-k}}{B(k, n+1-k)}, \quad \mathbb{E}C = \frac{k}{n+1}, \quad \text{Var}(C) = \frac{k(n+1-k)}{(n+1)^2(n+2)}$$

- $B(\cdot, \cdot)$: funcția Beta, care face ca densitatea să aibă integrala 1; abaterea standard pentru $n = 9, 49, 499$: 0,090; 0,042; 0,013

Noțiuni necesare azi (13/23): interschimbabilitatea și seriile de timp



- Stînga: un $AR(1)$ simulat, $x_t = 0,95x_{t-1} + \varepsilon_t$; dreapta: aceleași 300 de valori într-o ordine aleatoare
 - ▶ autocorelația la lagul 1: 0,96 înainte și 0,01 după reordonare
 - ▶ cele două traiectorii au legi comune vizibil diferite: o serie autocorelată nu este interschimbabilă
- **Interschimbabil:** $(Z_{\pi(1)}, \dots, Z_{\pi(n+1)})$ are aceeași lege ca $(Z_1, \dots, Z_{n+1})$ pentru orice permutare π a indicilor
 - ▶ pentru date dependente, garanția split conformal este doar aproximativă, dacă dependența slăbește odată cu lagul (mixing)

Noțiuni necesare azi (14/23): CQR și conformal ponderat

- ▣ **CQR** Romano, Patterson și Candès (2019): se pornește de la prognozele cuantilelor $\hat{q}_{lo}(x)$, $\hat{q}_{hi}(x)$ (de exemplu 10% și 90%)

$$s(x, y) = \max\{\hat{q}_{lo}(x) - y, y - \hat{q}_{hi}(x)\}, \quad \hat{C}(x) = [\hat{q}_{lo}(x) - \hat{q}, \hat{q}_{hi}(x) + \hat{q}]$$


- ▶ scorul este distanța cu semn în afara benzii (negativ în interior); $\hat{q}$: pragul split conformal al acestor scoruri
- ▶ $\hat{q} > 0$ lărgeste banda, $\hat{q} < 0$ o îngustează

- ▣ **Conformal ponderat** Barber et al. (2023): ponderi $w_i \in [0, 1]$ fixate dinainte (de exemplu mai mari pentru punctele recente), $w_{n+1} = 1$ pentru punctul de test


$$\tilde{w}_i = \frac{w_i}{1 + \sum_{j=1}^n w_j}, \quad \hat{q} = Q_{1-\alpha} \left(\sum_{i=1}^n \tilde{w}_i \delta_{S_i} + \tilde{w}_{n+1} \delta_{+\infty} \right)$$

- ▶ δ_a : o masă punctuală în a ; $Q_{1-\alpha}$: cuantila $(1 - \alpha)$; punctul de test este plasat la $+\infty$, cu masa $\tilde{w}_{n+1}$
- ▶ în practică: se ordonează scorurile, se adună ponderile lor $\tilde{w}$ în această ordine și se oprește când suma atinge $1 - \alpha$

Noțiuni necesare azi (15/23): CQR și conformal ponderat în practică



• puncte de test
— cuantile brute 10%, 90%
- - - banda CQR, $\pm \hat{q}$



— ponderea cumulată
- - - $1 - \alpha = 0,7$
..... $1 - \tilde{w}_{n+1}$
— $\hat{q}$ ponderat

- Stînga: date simulate al căror zgomot crește cu x ; prognozele brute ale cuantilelor 10%–90% sînt prea înguste (acoperire 0,57 pe punctele de test)
 - CQR cu 400 de puncte de calibrare: $\hat{q} = 0,38$, acoperire 0,85; banda își păstrează lățimea variabilă
- Dreapta: zece scoruri cu ponderile $w_i = 0,85^{11-i}$; ponderea normalizată cumulată a scorurilor ordonate; $\alpha = 0,3$
 - curba se oprește la $1 - \tilde{w}_{n+1} = 0,820$, restul fiind masa din $+\infty$; atinge 0,7 în $\hat{q} = 2,4$
 - **volumul efectiv** $n_{\text{eff}} = (\sum_i w_i)^2 / \sum_i w_i^2 = 8,3$: numărul de puncte cu ponderi egale care au aceeași informație

Noțiuni necesare azi (16/23): metode conformale online

- ▣ **Cadrul online:** scoruri S_t din prognoze în afara eșantionului; la momentul t , pragul q_t folosește doar $S_1, \dots, S_{t-1}$
 - ▶ indicatorul ratării $\text{err}_t = 1\{S_t > q_t\}$: 1 dacă Y_t cade în afara intervalului
 - ▶ static: calibrat o singură dată; mobil: cuantila conformală a ultimelor w scoruri
- ▣ **ACI Gibbs și Candès (2021):** q_t este cuantila conformală la un nivel de lucru α_t , actualizat după fiecare observație


$$\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t), \quad \left| \frac{1}{T} \sum_{t=1}^T \text{err}_t - \alpha \right| \leq \frac{\max\{\alpha_1, 1 - \alpha_1\} + \gamma}{\gamma T}$$

- ▶ $\gamma > 0$: pasul; α_1 : nivelul de pornire; o ratare scade α_t (interval mai larg); $\alpha_t \leq 0$ dă $q_t = +\infty$
- ▣ **Urmărirea cuantilei Angelopoulos, Candès și Tibshirani (2023):** se mută chiar pragul; cu scoruri în $[0, B]$

$$q_{t+1} = q_t + \eta(\text{err}_t - \alpha), \quad \left| \frac{1}{T} \sum_{t=1}^T (\text{err}_t - \alpha) \right| \leq \frac{B + \eta}{\eta T}$$

- ▶ $\eta > 0$: pasul, în unitățile scorului; PID conformal adaugă un integrator al erorilor trecute și un model care prognozează scorul următor

Noțiuni necesare azi (17/23): ACI în prezența volatility clustering



- Randamente GARCH(1,1) simulate $r_t = \sigma_t z_t$, $\sigma_t^2 = 0,02 + 0,08r_{t-1}^2 + 0,90\sigma_{t-1}^2$, z_t Student- t ; scorul $|r_t|$, $\alpha = 0,1$
 - pragul static: calibrat o singură dată pe primele 500 de zile; ACI: $\gamma = 0,005$ pe ultimele 500 de scoruri
- **Acoperirea locală** pe ultimele $W = 250$ de zile: $\frac{1}{W} \sum_{s=t-W+1}^t (1 - \text{err}_s)$
 - static: global 0,847, local între 0,608 și 0,960; ACI: global 0,893, local între 0,796 și 0,952 (2500 de zile)
 - în perioadele turbulente pragul static este prea jos; ACI ridică q_t după ratări și reface frecvența

Noțiuni necesare azi (18/23): EnbPI

- **EnbPI Xu și Xie (2021):** B modele estimate pe eșantioane bootstrap pe blocuri din perioada de antrenare
 - ▶ bootstrap pe blocuri: B serii formate din blocuri de câte b puncte consecutive de antrenare, extrase cu întoarcere
 - ▶ S_b : mulțimea punctelor din eșantionul b ; blocurile păstrează dependența de termen scurt (**B6**: blocuri de 7 zile)

- **Regresia ridge** pe fiecare eșantion: cele mai mici pătrate cu o penalizare a mărimii coeficienților

$$\hat{\beta}^{(b)} = \arg \min_{\beta} \sum_{i \in S_b} (y_i - x_i' \beta)^2 + \lambda \|\beta\|^2$$

- ▶ $\lambda > 0$: penalizarea; $\|\beta\|^2$: suma pătratelor coeficienților; $\hat{f}^{(b)}(x) = x' \hat{\beta}^{(b)}$

- **Reziduurile leave-one-out** (pentru punctul i , doar modelele al căror eșantion l-a exclus pe i) și **intervalul**


$$\hat{\varepsilon}_i = \left| y_i - \frac{1}{|\{b : i \notin S_b\}|} \sum_{b: i \notin S_b} \hat{f}^{(b)}(x_i) \right|, \quad \hat{C}_t = \hat{f}(x_t) \pm Q_{1-\alpha}(\hat{\varepsilon}_{t-w}, \dots, \hat{\varepsilon}_{t-1})$$

- ▶ $\hat{f}$: media celor B modele; $Q_{1-\alpha}$: cuantila empirică $(1 - \alpha)$ a ultimelor w reziduuri absolute
- ▶ după fiecare observație nouă, reziduul ei intră în fereastră și cel mai vechi iese

Noțiuni necesare azi (19/23): testele acoperirii

- ▣ **Kupiec** Kupiec (1995): testează $H_0: \Pr\{\text{err}_t = 1\} = \alpha$ pe șirul ratărilor
 - ▶ un p-value mic: frecvența ratărilor diferă de α (statistica pe slide-ul următor)
- ▣ **Christoffersen** Christoffersen (1998): adaugă independența, față de o alternativă Markov de ordinul întâi (o ratărie azi schimbă șansa unei ratări mâine)
 - ▶ un p-value mic: frecvență greșită sau ratări grupate
- ▣ **Acoperirea locală**: ponderea acoperirilor pe o fereastră mobilă (Gibbs și Candès folosesc 500 de zile)
 - ▶ sau acoperirea pe clase ale unei variabile cunoscute la origine

Noțiuni necesare azi (20/23): statisticile Kupiec și Christoffersen



- **Kupiec:** x ratări în T perioade, $\hat{\pi} = x/T$

$$LR_{uc} = -2 \ln \frac{(1 - \alpha)^{T-x} \alpha^x}{(1 - \hat{\pi})^{T-x} \hat{\pi}^x} \sim \chi^2(1)$$

- **Christoffersen:** n_{ij} = numărul de zile cu starea i urmată de starea j ($1 = \text{ratare}$)

$$\hat{\pi}_{01} = \frac{n_{01}}{n_{00} + n_{01}}, \quad \hat{\pi}_{11} = \frac{n_{11}}{n_{10} + n_{11}}$$

- ▶ LR_{ind} : raportul de verosimilitate al unei singure probabilități de ratare față de $\hat{\pi}_{01} \neq \hat{\pi}_{11}$
- ▶ $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2(2)$: frecvența și independența testate împreună

- Simulare, $T = 500$, $\alpha = 0,05$

- ▶ independente: 25 de ratări, Kupiec $p = 1,00$, $LR_{cc} p = 0,970$
- ▶ grupate: 25 de ratări, $\hat{\pi}_{11} = 0,280$, Kupiec $p = 1,00$, $LR_{cc} p < 0,001$


Noțiuni necesare azi (21/23): VaR dintr-o prognoză de cuantilă

- ▣ **VaR (Capitolul 9):** $\text{VaR}_\alpha = -q_\alpha$, unde q_α este cuantila de nivel α a distribuției randamentului
 - ▶ VaR 1%: $\alpha = 0,01$; rata-țintă de depășire este α ; pierderea cuantică este pierderea pinball ρ_α
- ▣ **Deplasarea conformală unilaterală** a unei prognoze de cuantilă $\hat{q}_t$

$$S_t = \hat{q}_t - y_t, \quad \text{VaR}_t = -(\hat{q}_t - c_t)$$

- ▶ c_t : pragul online al scorurilor S_t la nivelul α , astfel încât $\Pr\{S_t > c_t\} \approx \alpha$; $c_t > 0$ coboară cuantila (un VaR mai mare)

Noțiuni necesare azi (22/23): deplasarea conformală unilaterală a VaR



- Simulare: randamentele adevărate sînt Student- t cu 4 grade de libertate și varianță 1; modelul este $N(0; 0,8^2)$
 - cuantila de 1% a modelului $\hat{q}_t = -1,86$: este depășită cu probabilitatea 2,9%, nu 1%
- Scorurile S_t de pe slide-ul anterior: pozitive cînd randamentul cade sub cuantila prognozată
 - aici $c_t = 0,79$ mută cuantila în valoarea adevărată $-2,65$: VaR 1% crește de la 1,86 la 2,65
- Deplasarea corectează rata de depășire; nu adaugă informație despre momentele în care tail risk-ul este ridicat

Noțiuni necesare azi (23/23): modelele de referință pentru volatilitate

- ▣ **GARCH(1,1)-t** Bollerslev (1986) (Capitolul 9) pentru randamentele r_t (în %), cu media zero

$$r_t = \sigma_t z_t, \quad \sigma_t^2 = \omega + a_1 r_{t-1}^2 + b_1 \sigma_{t-1}^2, \quad z_t \sim t_\nu \text{ (varianță 1)}$$

- ▶ $\omega > 0$, $a_1, b_1 \geq 0$, $a_1 + b_1 < 1$: persistența; ν : gradele de libertate (grosimea cozilor); estimate prin verosimilitate maximă
- ▶ VaR: $\text{VaR}_{\alpha,t} = -\sigma_t q_\alpha(z)$, unde $q_\alpha(z)$ este cuantila de nivel α a lui z_t
- ▣ **Varianța realizată** a zilei t din M randamente intrazilnice $r_{t,i}$ (randamente de 5 minute: $M = 288$ pentru Bitcoin)

$$RV_t = \sum_{i=1}^M r_{t,i}^2, \quad x_t = \ln RV_t$$

- ▣ **HAR Corsi (2009)**: logaritmul varianței din ziua următoare regresat pe mediile zilnică, săptămînală și lunară

$$x_{t+1} = c + \beta_d x_t + \beta_w \frac{1}{5} \sum_{j=0}^4 x_{t-j} + \beta_m \frac{1}{22} \sum_{j=0}^{21} x_{t-j} + u_{t+1}$$

- ▶ trei orizonturi ale participanților (zi, săptămîină, lună) dau o persistență de lungă durată cu doar patru coeficienți

A1: split conformal de mînă [Rezolvat]

Cerință

- ▣ 19 reziduuri absolute de calibrare, ordonate: 0,2; 0,3; 0,4; 0,5; 0,6; 0,7; 0,8; 0,9; 1,0; 1,1; 1,2; 1,3; 1,5; 1,6; 1,8; 2,0; 2,1; 2,6; 3,2; o nouă prognoză punctuală $\hat{f} = 10$; $\alpha = 0,1$.
- ▣ 1. Calculați k și $\hat{q}$.
- ▣ 2. Scrieți intervalul de 90%.
- ▣ 3. Dați marginile inferioară și superioară ale acoperirii marginale sub interschimbabilitate.
- ▣ Raportați: două numere; un interval; două numere și o frază.

Rezolvare

- ▣ 1. $k = \lceil 20 \cdot 0,9 \rceil = 18$; $\hat{q} = S_{(18)} = 2,6$
- ▣ 2. $[10 - 2,6; 10 + 2,6] = [7,4; 12,6]$
- ▣ 3. $0,90 \leq \text{acoperirea} \leq 0,90 + 1/20 = 0,95$
- ▣ Interpretare: cu 19 puncte, intervalul folosește al doilea cel mai mare reziduu; garanția privește atît seturi de calibrare noi, cît și puncte noi

A2: mărimea setului de calibrare [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $\alpha = 0,1$; legea acoperirii condiționat de setul de calibrare: [Noțiuni necesare \(12/23\)](#). Model: A1.
- ▣ 1. Pentru $n = 19, 99$ și 999 dați k , media și abaterea standard a acoperirii.
- ▣ 2. Pentru fiecare n , calculați probabilitatea ca acoperirea realizată să fie sub $0,85$.
- ▣ 3. Găsiți cel mai mic n pentru care abaterea standard este cel mult $0,01$.
- ▣ Raportați: trei tripleți; trei probabilități; un număr.



A3: ACI de mîină [Rezolvat]

Cerință

- ▣ $\alpha = 0,1$, $\gamma = 0,01$, $\alpha_1 = 0,1$; ratările observate $\text{err}_1, \dots, \text{err}_5 = 1, 1, 0, 1, 0$.
- ▣ 1. Calculați $\alpha_2, \dots, \alpha_6$.
- ▣ 2. Calculați marginea pentru $|\frac{1}{T} \sum \text{err}_t - \alpha|$ cu $T = 1000$.
- ▣ 3. După cîte ratări consecutive pornind de la α_1 intervalul devine infinit? După cîte acoperiri consecutive devine vid?
- ▣ Raportați: cinci numere; un număr; doi întregi și o frază.

Rezolvare

- ▣ 1. O ratare scade $\gamma(1 - \alpha) = 0,009$, o acoperire adaugă $\gamma\alpha = 0,001$: 0,091; 0,082; 0,083; 0,074; 0,075
- ▣ 2. $(\max\{0,1; 0,9\} + 0,01)/(0,01 \cdot 1000) = 0,091$
- ▣ 3. $\lceil 0,1/0,009 \rceil = 12$ ratări; $\lceil 0,9/0,001 \rceil = 901$ acoperiri
- ▣ Interpretare: ACI reacționează de nouă ori mai repede la o ratare decît la o acoperire; aproximativ douăsprezece ratări consecutive duc la un interval egal cu toată dreapta reală, ceea ce menține frecvența pe termen lung

A4: urmărirea cuantilei de mîină [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Scoruri în $[0, 5]$; $\alpha = 0,1$, $\eta = 0,05$, $q_1 = 1$; ratările 1, 0, 0, 1, 1. Model: A3.
- ▣ 1. Calculați $q_2, \dots, q_6$.
- ▣ 2. Calculați marginea $(B + \eta)/(\eta T)$ pentru $T = 2000$.
- ▣ 3. Demonstrați că q_t rămîne în $[-\eta, B + \eta]$ dacă pornește din $[0, B]$.
- ▣ Raportați: cinci numere; un număr; o demonstrație de trei rînduri.



A5: CQR de mînă [Rezolvat]

Cerință

- ▣ 8 puncte de calibrare cu prognozele cuantilelor și rezultatele $(\hat{q}_{lo}, \hat{q}_{hi}, y)$: $(1; 3; 2)$, $(2; 4; 4,6)$, $(0,5; 2,5; 0,2)$, $(1,5; 3; 2,5)$, $(3; 5; 5,4)$, $(2,5; 4; 3,1)$, $(1; 2,5; 2,2)$, $(2; 4,5; 1,6)$; $\alpha = 0,2$.
- ▣ 1. Calculați cele opt scoruri CQR.
- ▣ 2. Calculați k și $\hat{q}$.
- ▣ 3. Dați intervalul conformal pentru un punct nou cu $(\hat{q}_{lo}, \hat{q}_{hi}) = (2, 4)$ și acoperirea brută pe setul de calibrare.
- ▣ Raportați: opt numere; două numere; un interval și o pondere.

Rezolvare

- ▣ 1. $-1,0; 0,6; 0,3; -0,5; 0,4; -0,6; -0,3; 0,4$
- ▣ 2. $k = \lceil 9 \cdot 0,8 \rceil = 8$, $\hat{q} = 0,6$ (cel mai mare scor)
- ▣ 3. $[2 - 0,6; 4 + 0,6] = [1,4; 4,6]$; acoperirea brută 0,50
- ▣ Interpretare: banda brută de 80% acoperă doar jumătate din puncte; CQR o lărgeste cu cea mai mare rată; un $\hat{q}$ negativ ar îngusta o bandă prea largă

A6: cuantile conformale ponderate [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Șase scoruri în ordine temporală: 2,0; 0,5; 1,5; 3,0; 1,0; 2,5; ponderile $w_i = 0,8^{7-i}$, $w_7 = 1$. Model: A5.
- ▣ 1. Calculați ponderile normalizate $\tilde{w}_1, \dots, \tilde{w}_7$.
- ▣ 2. Calculați pragurile conformale ponderat și neponderat pentru $\alpha = 0,3$.
- ▣ 3. Repetați pentru $\alpha = 0,2$ și explicați rezultatul prin masa $\tilde{w}_7$.
- ▣ Raportați: șapte ponderi; două praguri; două praguri și o frază.

A7: tokenizatorul Chronos de mînă [Rezolvat]

Cerință

- Context de opt valori: 100, 104, 98, 102, 106, 110, 96, 104; 4093 de centre egal distanțate pe $[-15, 15]$.
- 1. Calculați scala s și lățimea intervalului în unități scalate și în unitățile datelor.
- 2. Găsiți token-ul ultimei valori (centrele indexate $0, \dots, 4092$), valoarea ei decuantizată și eroarea.
- 3. Dați cea mai mare valoare pe care modelul o poate prognoza și spuneți ce se întîmplă cu o valoare viitoare de 1700.
- Raportați: trei numere; trei numere; un număr și o frază.

Rezolvare

- 1. $s = 102,5$; lățimea $30/4092 = 0,00733$, adică 0,751 în unitățile datelor
- 2. $104/s$ este cel mai apropiat de centrul 2184; valoarea decuantizată 103,70, eroarea 0,30
- 3. $15s = 1537,5$; 1700 se scalează la $16,59 > 15$: trunchiat la ultimul centru, nu poate fi prognozat
- Interpretare: rezoluția este relativă la media contextului; un salt de zece ori poate fi reprezentat, unul de șaisprezece ori nu



A8: limitele domeniului și scalarea arcsinh [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Context: șapte valori de 50 și una de 70; valori viitoare posibile 90, 400, 1500. Model: [A7](#).
- ▣ 1. Calculați s și valorile viitoare scalate; spuneți pe care nu le poate atinge Chronos.
- ▣ 2. Calculați arcsinh al valorilor scalate (transformarea de intrare din Chronos-2) și explicați de ce un strat de cuantile pe această scală nu are o limită fixă.
- ▣ 3. Numiți o serie românească pentru care acest lucru contează.
- ▣ Raportați: patru numere și o listă; trei numere și o frază; un exemplu.

B1: consumul României după lansarea modelelor [Rezolvat]

- **Întrebarea:** este un foundation model zero-shot la fel de precis ca modelul expert pentru consumul României pe ziua următoare, în zile pe care nu le-a putut vedea?
- **Date:** Consumul orar Energy-Charts, zilele prognozate 1 noiembrie 2025 – 30 septembrie 2026 (334 de zile); naiv săptămânal; ARX expert Ziel și Weron ([Capitolul 1](#)); Chronos-Bolt small cu un context de 2048 de ore
- **Cerințe**
 1. Calculați MAE al mediane și CRPS pe decile pentru cele trei modele.
 2. Calculați acoperirea benzii 10–90%.
 3. Aplicați testul DM–HLN pentru fiecare model față de ARX expert, pe MAE zilnic.
 4. Interpretare: este modelul zero-shot suficient de bun pentru a înlocui modelul expert?
- **Raportați:** un tabel cu trei modele și trei scoruri, două statistici DM, o frază
- Notebook: secțiunea [B1](#)



B1: rezolvare [Rezolvat]



- MAE (GW): naiv săptămînal 0,412, ARX expert 0,227, Chronos-Bolt 0,246; CRPS 0,330; 0,184; 0,197; acoperirea benzilor de 80% 76,8%, 78,0%, 81,5%
- DM față de ARX expert: Chronos-Bolt $t = 3,06$ ($p = 0,002$); naiv săptămînal $t = 12,69$
- Interpretare: încă nu: în zile pe care nu le-a putut vedea, Chronos-Bolt este cu 8% mai puțin precis decît modelul expert, o diferență semnificativă, dar nu cere nicio estimare, iar benzile lui sînt mai bine calibrate: o variantă implicită solidă, nu un înlocuitor

B2: covariabile de calendar în context [Propus]


- **Întrebarea:** învață Chronos-2 efectul sărbătorilor legale doar din context?
- **Date:** fereastra din [B1](#); Chronos-2 univariat și cu două covariabile transmise pentru context și pentru ziua prognozată: un indicator de sărbătoare și un indicator de weekend; model: [B1](#)
- **Cerințe**
 1. Calculați MAE al ambelor variante pe toate zilele și pe sărbătorile legale.
 2. Aplicați testul DM–HLN pentru varianta cu covariabile față de cea univariată.
 3. Reprezentați grafic diferența zilnică de MAE și marcați sărbătorile.
 4. Interpretare: de unde provine câștigul?
- **Raportați:** patru numere, o statistică DM, un grafic, o frază
- Notebook: secțiunea [B2](#)

B3: intervale conforme pentru randamentele BET [Rezolvat]

- ▣ **Întrebarea:** își păstrează un interval de 90% calibrat pe o perioadă liniștită acoperirea când volatilitatea se schimbă?
- ▣ **Date:** Randamente logaritmice zilnice BET; prognoza 0, scorul $|r_t|$; split static calibrat pe 2012–2015, mobil (ultimele 750 de zile), ACI cu $\gamma = 0,005$; evaluare 2016–2026 ($n = 2675$)
- ▣ **Cerințe**
 1. Calculați acoperirea totală a celor trei metode și acoperirea pe ani.
 2. Aplicați testele Kupiec și Christoffersen pe șirurile de ratări.
 3. Găsiți anul cel mai slab al metodei statice.
 4. Interpretare: ce proprietate a randamentelor invalidează metoda statică?
- ▣ **Raportați:** trei acoperiri, șase p-value-uri, un an, o frază
- ▣ Notebook: secțiunea [B3](#)



B3: rezolvare [Rezolvat]



- Acoperirea: static 0,876, mobil 0,890, ACI 0,897; Kupiec $p < 0,001$; 0,081; 0,586; Christoffersen $p < 0,001$, $< 0,001$, $< 0,001$
- Metoda statică pe ani: de la 0,765 (2026) la 0,956; pragul ei este fixat la 1,29%
- Interpretare: volatility clustering: scorul $|r_t|$ nu este interschimbabil, deci o calibrare pe o perioadă liniștită are o acoperire prea mică în anii agitați; metodele adaptive corectează frecvența, dar ratările rămân grupate (Christoffersen)


B4: designul ACI pentru volatilitate pe DAX [Propus]

- ▣ **Întrebarea:** este valabil rezultatul lui Gibbs și Candès (2021) pentru DAX și cum depinde el de γ ?
- ▣ **Date:** Randamente zilnice DAX; $V_t = r_t^2$, GARCH(1,1) pe ultimele 1250 de zile, scorul $|V_t - \hat{\sigma}_t^2|/\hat{\sigma}_t^2$, $\alpha = 0,1$; model: B3
- ▣ **Cerințe**
 1. Calculați intervalele mobile (cu nivel fix) și intervalele ACI pentru $\gamma = 0,001, 0,005$ și $0,02$.
 2. Raportați acoperirea totală, domeniul acoperirii locale pe 500 de zile și ponderea intervalelor infinite.
 3. Aplicați testul Christoffersen pentru fiecare metodă.
 4. Interpretare: ce γ ați alege și de ce?
- ▣ **Raportați:** un grafic, patru tripleți, patru p-value-uri, o frază
- ▣ **Notebook:** secțiunea B4

B5: calibrarea unui foundation model pe RV Bitcoin [Rezolvat]

- **Întrebarea:** sînt calibrate benzile 10–90% ale Chronos-Bolt pentru logaritmul varianței realizate Bitcoin și le poate extinde predicția conformală la 95%?
- **Date:** RV din randamente Binance de 5 minute, scară logaritmică, o zi înainte, din 2023, context de 1024 de zile; CQR online ([Noțiuni necesare \(14/23\)](#)) pe cuantilele de 10% și 90%, ACI pe ultimele 250 de scoruri, $\gamma = 0,005$
- **Cerințe**
 1. Calculați acoperirea și lățimea medie a benzii brute.
 2. Calculați acoperirea și lățimea medie a intervalelor conformale de 80% și 95%.
 3. Reprezentați acoperirea pe 90 de zile a celor trei intervale.
 4. Interpretare: ce spune corecția conformală despre model?
- **Raportați:** două numere, patru numere, un grafic, o frază
- Notebook: secțiunea [B5](#)

B5: rezolvare [Rezolvat]



- Banda brută: acoperirea 0,780, lățimea 1,31; conformal 80%: 0,802, lățimea 1,38; conformal 95%: 0,950, lățimea 2,32 (unități logaritmice, 1107 zile din 8 septembrie 2023)
- Interpretare: decilele unui model zero-shot sînt aproape calibrate pe RV Bitcoin (78% pentru 80%); pasul conformal adaugă punctele lipsă și construiește un interval de 95%, de 1,78 ori lățimea brută, pe care modelul nu îl poate produce

B6: EnbPI pe vârful de consum de seară [Propus]


- **Întrebarea:** dă un ansamblu bootstrap cu o fereastră mobilă de reziduuri intervale valide și precise pentru consumul de la ora 19:00?
- **Date:** Consumul României la ora 19:00, 2025–2026; EnbPI: regresii ridge pe regresorii ARX expert, 20 de eșantioane bootstrap pe blocuri (blocuri de 7 zile) din anul anterior; ACI în jurul prognozei ARX expert (ferastră de 91 de zile); model: [B5](#)
- **Cerințe**
 1. Calculați intervalele EnbPI de 90% și intervalele ACI.
 2. Raportați acoperirea, lățimea medie și p-value-ul testului Christoffersen pentru fiecare.
 3. Reprezentați grafic ambele intervale și consumul.
 4. Interpretare: ce metodă ar prefera un operator de rețea?
- **Raportați:** șase numere, un grafic, o frază
- Notebook: secțiunea [B6](#)



B7: inflația din Europa Centrală și de Est, multe țări, multe teste [Rezolvat]

- **Întrebarea:** întrec Chronos-2 și TimesFM modelul AR pentru inflația din Europa Centrală și de Est la șase luni, după corecția pentru testarea multiplă?
- **Date:** Inflația anuală HICP Eurostat, BG, CZ, HU, PL, RO, SK; origini lunare ianuarie 2012 – februarie 2026 (numărul de origini: 170); $h = 6$; AR(p) după AIC; foundation models pe toată istoria
- **Cerințe**
 1. Calculați raportul MAE față de AR pe țări și media lui geometrică, pentru ambele modele.
 2. Aplicați cele șase teste DM–HLN pe țări (HAC cu 5 laguri) și numărați respingerile la 5%: brut, Holm, BH.
 3. Aplicați testul DM agregat pe diferența medie de pierdere dintre țări.
 4. Interpretare: care este rezumatul onest într-un rînd?
- **Raportați:** douăsprezece rapoarte, două medii geometrice, șase numere, două teste agregate, o frază
- Notebook: secțiunea [B7](#)

B7: rezolvare [Rezolvat]



- Chronos-2 / AR: BG 1,03; CZ 0,91; HU 0,87; PL 0,87; RO 1,13; SK 0,92; media geometrică 0,952; respingeri brut/Holm/BH: 1/0/0; testul agregat $t = -1,10$ ($p = 0,273$)
- TimesFM / AR: BG 1,02; CZ 0,81; HU 0,93; PL 0,93; RO 1,05; SK 0,92; media geometrică 0,938; respingeri 0/0/0; testul agregat $t = -1,12$ ($p = 0,264$)
- Interpretare: ambele medii geometrice sînt sub unu, dar nicio diferență pe țară nu rezistă corecțiilor Holm sau BH, iar niciun test agregat nu este semnificativ: un câștig mediu modest pe care acești 14 ani pentru șase țări nu îl pot confirma; România este țara în care Chronos-2 se descurcă cel mai slab

B8: VaR pentru WIG20 din foundation models [Propus]

- **Întrebarea:** poate un foundation model, singur sau calibrat, să dea un VaR care trece testele din [Capitolul 9](#)?
- **Date:** Randamente zilnice WIG20, 2016–2026; GARCH(1,1)- t (1000 de zile, reestimat la fiecare 250); cuantilele brute Chronos-2 și cu ACI; cuantila de 10% Chronos-Bolt deplasată printr-un prag conformal unilateral (ACI, fereastră de 500); model: [B3](#) și [B5](#)
- **Cerințe**
 1. Calculați VaR 1% și VaR 5% cu cele patru metode.
 2. Raportați ratele de depășire și p-value-urile testelor Kupiec și Christoffersen.
 3. Comparați pierderile cuantile cu GARCH- t printr-un test DM.
 4. Interpretare: ce corectează calibrarea și ce nu corectează?
- **Raportați:** un tabel cu opt rînduri, o frază
- **Notebook:** secțiunea [B8](#)

C1: o prognoză preînregistrată a inflației [Propus]

- **Întrebarea:** cât va fi inflația HICP a României în fiecare dintre următoarele șase luni, cu o bandă calibrată de 80%, notată înainte să existe datele?
- **Date:** HICP Eurostat, ultima observație august 2026 (6,3%); medianele și benzile 10–90% Chronos-2 de la ultima origine, lărgite orizont cu orizont cu pragul conformal al scorurilor CQR din ultimele 60 de origini; model: [B5](#)
- **Cerințe**
 1. Scrieți o preînregistrare de cinci rînduri: versiunea datelor, modelul, orizonturile, regula de scor, ce ar însemna un eșec.
 2. Calculați cele șase mediane și benzile de 80% brute și conformale.
 3. Adăugați o covariabilă pe care o considerați importantă și spuneți cum ați transmite-o lui Chronos-2.
 4. Interpretare: cum veți ști peste șase luni dacă prognoza a fost bună?
- **Raportați:** un plan de cinci rînduri, un tabel cu șase luni, un plan de proiect
- Notebook: secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI un rezumat despre foundation models și predicția conformală. Răspunsul:
- (a) Chronos-Bolt dă direct un VaR 1%: cereți cuantila de 0,01.
- (b) Split conformal garantează acoperirea de 90% pentru orice valoare a covariabilei.
- (c) ACI garantează că ratările sînt independente în timp.
- (d) Cu 19 scoruri de calibrare și $\alpha = 0,1$, pragul este al 18-lea cel mai mic scor.
- (e) Orice serie de timp staționară este interschimbabilă, deci split conformal este exact pentru ea.
- (f) Corecția Holm controlează rata descoperirilor false.
- (g) Media geometrică a erorilor relative ordonează modelele la fel, oricare ar fi modelul de referință.
- (h) Tan et al. (2024) au arătat că foundation models pentru serii de timp, precum Chronos, nu sînt utile.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (secțiunea C2 din notebook).
 - ▶ 2. Raportați: o listă de opt verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Un prag conformal este o statistică de ordine: acoperirea lui este exactă în medie și are o lege Beta condiționat de setul de calibrare
- ▣ Sub dependență, reacția la erori (ACI, urmărirea cuantilei) reface frecvența pe termen lung pentru orice șir, nu și independența ratărilor
- ▣ Cuantilele foundation models sînt scoruri de calibrat; tokenizatoarele și straturile de cuantile limitează ce pot exprima
- ▣ Multe serii înseamnă multe teste: agregați sau corectați înainte de a declara un câștigător
- ▣ Un răspuns AI este o ciornă: verificați domeniile cuantilelor, garanțiile și obiectul studiilor citate

După seminar

- Cursul 13 dezvoltă fiecare temă de azi
 - ▶ preantrenarea și proiectarea modelelor; benchmark-urile și contaminarea
 - ▶ teoria conformală și variantele ei pentru serii de timp; calibrarea foundation models
- Încercați cerințele [Propus] în notebook
- C1 poate deveni un proiect de echipă: un benchmark live, preînregistrat, al foundation models pe inflația din Europa Centrală și de Est, cu benzi conformale
- Lectură: Angelopoulos și Bates (2023); Gibbs și Candès (2021); Romano, Patterson și Candès (2019); Ansari et al. (2024); Tan et al. (2024)
- **Seminarul are rol de exercițiu și nu se notează**

Bibliografie (1/2)

- ▣ Angelopoulos, A. N., & Bates, S. (2023). Conformal prediction: A gentle introduction. *Foundations and Trends in Machine Learning*, 16(4), 494–591. doi:10.1561/22000000101
- ▣ Angelopoulos, A. N., Candès, E. J., & Tibshirani, R. J. (2023). Conformal PID control for time series prediction. *Advances in Neural Information Processing Systems* 36; arXiv:2307.16895. arXiv:2307.16895
- ▣ Ansari, A. F., Shchur, O., Küken, J., Auer, A., Han, B., Mercado, P., et al. (2025). Chronos-2: From univariate to universal forecasting. arXiv:2510.15821. arXiv:2510.15821
- ▣ Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*; arXiv:2403.07815. arXiv:2403.07815
- ▣ Barber, R. F., Candès, E. J., Ramdas, A., & Tibshirani, R. J. (2023). Conformal prediction beyond exchangeability. *The Annals of Statistics*, 51(2), 816–845. doi:10.1214/23-AOS2276
- ▣ Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300. doi:10.1111/j.2517-6161.1995.tb02031.x
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- ▣ Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862. doi:10.2307/2527341
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi:10.1093/jjfinec/nbp001
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599

Bibliografie (2/2)

- ▣ Fleming, P. J., & Wallace, J. J. (1986). How not to lie with statistics: The correct way to summarize benchmark results. *Communications of the ACM*, 29(3), 218–221. doi:10.1145/5666.5673
- ▣ Gibbs, I., & Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems 34*; arXiv:2106.00170. arXiv:2106.00170
- ▣ Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. doi:10.1016/S0169-2070(96)00719-4
- ▣ Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70. jstor.org
- ▣ Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- ▣ Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J., & Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111. doi:10.1080/01621459.2017.1307116
- ▣ Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems 32*; arXiv:1905.03222. arXiv:1905.03222
- ▣ Tan, M., Merrill, M. A., Gupta, V., Althoff, T., & Hartvigsen, T. (2024). Are language models actually useful for time series forecasting? *Advances in Neural Information Processing Systems 37*; arXiv:2406.16964. arXiv:2406.16964
- ▣ Xu, C., & Xie, Y. (2021). Conformal prediction interval for dynamic time-series. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, PMLR 139, 11559–11569. proceedings.mlr.press
- ▣ Ziel, F., & Weron, R. (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics*, 70, 396–420. doi:10.1016/j.eneco.2017.12.016